

北京交通大学

博士学位论文

超大城市 MaaS 使用行为建模及推广策略仿真优化研究

Research on MaaS Usage Behavior Modeling and Simulation-Based
Optimization of Promotion Strategies in Megacities

作者：郝赫

导师：姚恩建

北京交通大学

2026 年 8 月

北 京 交 通 大 学

博 士 学 位 论 文

超大城市 MaaS 使用行为建模及推广策略仿真优化研究

Research on MaaS Usage Behavior Modeling and Simulation-Based
Optimization of Promotion Strategies in Megacities

作者姓名: 郝赫

学 号: 22110300

导师姓名: 姚恩建

职 称: 教授

学位类别: 工学

学位级别: 博士

学科专业: 交通运输规划与管理 研究方向: 综合交通运输理论与技术

北京交通大学

2026 年 8 月

摘要

随着城镇化与机动化进程的持续推进，超大城市面临私家车依赖加剧、道路拥堵频发与交通碳排放居高不下的多重挑战。出行即服务（Mobility as a Service, MaaS）通过一站式平台整合多模式出行资源，被视为降低私家车依赖、推动城市交通绿色低碳转型的重要途径，并受到我国政策的大力支持。然而，全球范围内众多 MaaS 试点相继陷入用户订阅低迷、运营持续亏损乃至停运倒闭的发展困境，凸显出 MaaS 规模化推广仍具紧迫性与现实价值。为此，面向 MaaS 在城市内大规模推广的现实问题，本文旨在构建模拟超大城市个体 MaaS 采纳行为的推广策略评估系统，并基于此开展推广策略优化研究，实现用户采纳率、平台净收入与碳减排等多重目标的协同优化，为 MaaS 的可持续发展提供决策支撑。

本文首先从人口合成、活动计划生成、MaaS 采纳意愿建模与推广策略优化等方面开展了国内外研究综述，总结了既有研究进展及待改进之处。在此基础上，以居民出行调查、人口普查与统计年鉴等多源数据为支撑，提出家庭级虚拟人口合成方法与考虑家庭联合活动的活动计划生成方法，构建大规模推广策略仿真的微观个体集合。进一步，设计两步式比较型陈述偏好（Stated Preference, SP）调查获取覆盖 MaaS 单次转移到套餐订阅多阶段的采纳行为数据，并从分阶段与一体化两种视角构建 MaaS 多阶段采纳意愿模型，深入解析用户采纳决策过程、机理及影响因素。最后，构建基于多智能体的 MaaS 推广策略评估模型，建立两类代理模型并结合基于信赖域的多目标优化方法，得到用户采纳率、平台净收入与碳减排等多目标协同的 Pareto 最优推广策略集，为超大城市 MaaS 推广策略的科学制定提供指导。具体而言，本文开展的研究工作及成果如下：

（1）面向出行分析的超大城市家庭级人口合成。针对现有数据源无法支撑大规模 MaaS 推广策略仿真评估的局限，提出家庭画像条件下的分层扩散 Transformer 人口合成模型，其以家庭画像机制压缩下层成员属性的生成空间，以异质图显式表征家庭结构与成员关系，实现家庭属性、家庭结构与成员属性的联合生成。进一步，设计了基于能量引导的多地理尺度边际分布对齐机制与样本零、结构零控制策略，以保证生成数据的合理性。以北京市为算例的实验表明，提出的模型在家庭级、个人级与扩展家庭级的全部属性组合维度下均优于各类基准生成模型，6 维属性组合下家庭级与个人级 SRMSE 分别低至 0.389 与 1.188。此外，提出的边际分布对齐机制能够有效使生成数据对齐多地理尺度的边际分布，零单元控制策略也可将结构零占比由 6.86% 降至近似为零。

（2）考虑家庭联合活动的家庭级活动计划生成。面向生成的大规模虚拟人口，提

出协调式家庭活动计划生成框架 (Coordinated Household ACTivity-chain generator, CoHACT), 赋予其日常的活动模式。以集合注意力和共享—专属多任务设计特征编码表征规模可变的家庭及其成员特征, 进而设计融合任务特定注意力与跨角色注意力的解码器以逐属性、自回归地生成全体家庭成员的活动计划。为刻画居民城市大范围目的地选择机理, 设计考虑空间异质性的目的地注意力层完成城市级活动目的地选择。此外, 为保证生成活动计划的合理性与最优性, 构建基于纳什议价的可微协调层调整家庭活动计划, 并推导其与解码器和编码器的一体化训练策略。算例实验结果表明, CoHACT 在个体与家庭两个层面的全部属性组合维度下均优于六个基准模型, 8 维联合分布下的 SRMSE 低至 1.95, 约为最优基准的 1/15。测试集生成结果能够较好地还原家庭活动计划的联合分布, 预测目的地分布与真实分布高度一致。此外, 模型无须重新训练即可在 37.3 小时内为北京市约 1400 万户虚拟家庭生成全日活动计划, 全市尺度下生成分布的总体结构与居民出行调查一致。

(3) MaaS 多阶段采纳意愿的分阶段建模。针对城市居民 MaaS 采纳机理不明确的问题, 设计并实施两步式 SP 调查, 在北京市获得 1242 份有效问卷。在单次出行阶段, 构建基于混合潜在分类模型的 MaaS 转移行为选择模型, 将态度潜变量、出行惯性与偏好延续变量纳入统一建模框架, 识别出期望经 MaaS 获得高品质出行的类别 1 与偏好私家车出行的类别 2 (样本隶属概率分别为 28.89% 与 71.11%) 两类受访者, 并构建 MaaS 转移意愿指数量化用户的初始印象。在套餐订阅阶段, 构建基于转移意愿的考虑属性无视的混合潜在分类模型, 以转移意愿作为潜在类别划分的关键变量, 识别出 MaaS 存疑者与 MaaS 乐观者, 转移意愿大于 0.576 的用户更可能成为乐观者, 验证了由单次转移向套餐订阅的跨阶段偏好传导机制。灵敏度与弹性分析表明, 缩短 MaaS 选项的出行时间可有效提升转移意愿, 且类别 1 受访者更为敏感。此外, 乐观者对套餐涨价的容忍度高于存疑者, 但两类用户对套餐价格总体敏感度均较低, 服务品质等非价格因素对套餐订阅同样关键。

(4) MaaS 多阶段采纳意愿的一体化建模。针对分阶段建模难以捕捉跨阶段行为状态转移的局限, 构建多指标多原因模型与隐马尔可夫模型相结合的一体化建模框架。以 MIMIC 模型测算态度潜变量并将其纳入初始状态形成过程, 在 HMM 的统一似然下联合刻画初始状态形成、单次出行选择、跨阶段状态转移与套餐订阅选择四个相互衔接的过程。估计结果识别出贯穿采纳全周期的费用敏感型与时间敏感型两种行为状态 (初始占比分别为 63.4% 与 36.6%), 并揭示了受访者的状态转移机理, 即更大幅度的费用节省使用户更可能转入或保持费用敏感型状态, 更大幅度的时间节省则使其更可能转入时间敏感型状态。全周期聚合弹性分析表明, 单次出行阶段 MaaS 选项的平均轨道交通车内时间对套餐整体订阅的聚合弹性为

-0.521，其绝对值比全部套餐内服务水平属性的聚合弹性绝对值均高出一个数量级。与分阶段建模对比表明，分阶段建模的优势在于刻画阶段内偏好异质性与精细人群画像，一体化建模的优势在于识别跨阶段转移机理与全周期关键因素，二者相互补充，共同为推广策略仿真提供微观行为依据。

(5) 面向城市级 MaaS 推广的多目标策略优化。基于生成的超大城市虚拟人口及能够刻画居民对 MaaS 多阶段采纳行为的行为模型，构建融合认知扩散、多阶段采纳与订阅留存机制的 MaaS 采纳多智能体仿真模型，建立动态策略空间与用户采纳率、平台净收入与碳减排三目标的映射关系。在此基础上，构建混合解析代理与深度学习代理，并设计相应的反向求解方法，并将其嵌入到提出的基于信赖域机制的多目标优化算法中，以辅助逐步逼近 Pareto 前沿。在基于居民出行调查的小规模算例中，低预算档位和高预算档位下，深度学习代理模型的城市级总体 NMAE 分别为 3.61% 和 3.01%，均低于混合解析代理的 8.38% 和 8.16%。此外，高预算下深度学习代理模型最终超体积为 0.73，较混合解析方法提高 8.54%，验证了所提方法的预测与寻优能力。基于全市合成人口的大规模算例进一步展示了框架的城市级应用能力。结果表明，提出的方法可在可接受时间内得到差异化的推广策略集合，可为 MaaS 推广策略制定提供量化依据。

图 63 幅，表 51 个，参考文献 204 篇。

关键词：出行即服务；推广策略；人口合成；活动计划生成；多阶段采纳意愿；多智能体仿真；代理模型设计；多目标优化

ABSTRACT

As urbanization and motorization continue, megacities face major challenges, including growing dependence on private cars, frequent road congestion, and high carbon emissions from transport. Mobility as a Service (MaaS) integrates multimodal travel resources on a one-stop platform, which can reduce private-car dependence and support a green, low-carbon transition in urban transport. MaaS has also received strong policy support in China. However, many MaaS pilots around the world have faced low subscription levels, continued operating losses, or even service shutdowns and business failures, highlighting the continued urgency and practical value of large-scale MaaS promotion. To this end, this dissertation aims to develop a promotion strategy evaluation system that simulates individual MaaS adoption behavior in megacities. This system is then used for the joint optimization of promotion strategies under three objectives: the user adoption rate, platform net revenue, and carbon emission reduction. It thereby provides decision support for the sustainable development of MaaS.

This dissertation first reviews related research in China and abroad. The review covers population synthesis, activity plan generation, MaaS adoption intention modeling, and promotion strategy optimization. It summarizes current progress and remaining research gaps. Using data from household travel surveys, population censuses, and statistical yearbooks, this dissertation proposes a household-level population synthesis method and an activity generation method that considers intra-household joint activities. These methods construct a set of individual agents for large-scale promotion strategy simulation. A two-step comparative stated preference (SP) survey is then designed, which collects adoption behavior data across several stages, from shifts to MaaS in one-trip scenarios to MaaS bundle subscriptions. Multi-stage MaaS adoption models are developed from both stage-wise and integrated perspectives, explaining adoption decisions, mechanisms, and key factors. Finally, an agent-based model is developed to evaluate MaaS promotion strategies. Two types of surrogate models are built and combined with a trust-region-based multi-objective optimization method, which produces Pareto-optimal strategies that balance the user adoption rate, platform revenue, and carbon emission reduction, supporting the design of MaaS promotion strategies in megacities. The main work and findings are as follows.

(1) Household-level population synthesis for travel analysis in megacities. Existing data sources cannot support large-scale simulation-based evaluation of MaaS promotion

strategies. To address this limitation, a Hierarchical Diffusion-Transformer (HiDiT) population synthesis model conditioned on household clusters is proposed. The household cluster narrows the generation space for member-level attributes. A heterogeneous graph explicitly represents household structures and relationships among household members. The model can thus jointly generate household attributes, household structures, and member attributes simultaneously. We also propose energy guidance to align marginal distributions across multiple geographic scales and propose a zero-cell strategy controls sampling zeros and structural zeros. These mechanisms ensure the plausibility of the generated data. A case study in Beijing shows that the proposed model outperforms all baseline generative models across attribute combinations of all tested dimensions. For six-dimensional attribute combinations, the household-level and individual-level standardized root mean square error (SRMSE) values are as low as 0.389 and 1.188, respectively. The alignment mechanism also matches the synthetic data to marginal distributions at multiple geographic scales. The zero-cell strategy reduces the share of structural zeros from 6.86% to nearly zero.

(2) Household-level activity generation with household joint activities. To assign daily activity patterns to the generated large-scale synthetic population, the Coordinated Household ACTivity-chain generator (CoHACT) is proposed. It uses set attention and a multi-task learning with shared and task-specific components to encode variable-size households and member features. The decoder combines task-specific attention with cross-role attention, which generates activity chain for all household members in an autoregressive way. Further, a destination attention layer is developed to account for spatial heterogeneity in city-scale destination choice. After generating activity-chains, a differentiable coordination layer based on Nash bargaining then adjusts household activity chains to ensure their plausibility and optimality. Finally, a joint training scheme for the coordination layer, decoder, and encoder is derived. The case study shows that CoHACT outperforms six baseline models across attribute combinations of all tested dimensions at both the individual and household levels. The SRMSE of the proposed model for the eight-dimensional joint distribution is 1.95, which is about 1/15 of that of the best baseline model. Test-set results reproduce the joint distribution of household activity chains well. The predicted destination distribution also closely matches the observed distribution. Without retraining, the model can generate activity chains for about 14 million synthetic households in Beijing within 37.3 hours. At the full-city scale, the overall structure of the generated distribution is consistent with the household travel survey.

(3) Stage-wise modeling of multi-stage MaaS adoption intention. To clarify the mechanisms of MaaS adoption among urban residents, a two-step SP survey is firstly designed and conducted, collecting 1,242 valid responses in Beijing. At the one-trip stage, a hybrid choice model with latent classes is developed to model shifts to MaaS, including an attitudinal latent variable, travel inertia, and preference carryover in one framework. The model identifies two classes of respondents. Class 1 seeks high-quality travel through MaaS, while Class 2 prefers private-car travel. Their membership probabilities are 28.89% and 71.11%, respectively. An index of willingness to shift to MaaS is then developed to measure users' initial impressions of MaaS. At the bundle subscription stage, a Latent Class with a Latent Variable (LCLV) model with attribute non-attendance (ANA) is developed based by using the index as a key variable for latent class membership. The model identifies MaaS Skeptics and MaaS Optimists. Users with an willingness to shift above 0.576 are more likely to be MaaS Optimists. This finding confirms that preferences formed during one-trip can shift to bundle subscriptions. Sensitivity and elasticity analyses show that shorter MaaS travel times increase willingness to shift. Class 1 respondents are more sensitive to this change than Class 2 respondents. MaaS Optimists are more tolerant of bundle price increases than MaaS Skeptics. However, both groups have low overall sensitivity to bundle prices. Non-price factors, such as service quality, are also important for bundle subscriptions.

(4) Integrated modeling of multi-stage MaaS adoption intention. Stage-wise modeling has difficulty capturing transitions in behavioral states across stages. To address this limit, an integrated framework combining a Multiple Indicators Multiple Causes (MIMIC) model with a Hidden Markov Model (HMM) is developed. The MIMIC model estimates the attitudinal latent variables, which are then included in the initial-state formation process. With a unified HMM likelihood, the framework jointly models four linked processes: initial-state formation, one-trip choice, cross-stage state transition, and bundle subscription choice. The estimation results identify two behavioral states over the full adoption cycle: a cost-sensitive state and a time-sensitive state, with the initial shares being 63.4% and 36.6%, respectively. Greater cost savings make users more likely to enter or remain in the cost-sensitive state. Greater time savings make them more likely to enter the time-sensitive state. The aggregate elasticity of overall bundle subscription with respect to the average in-vehicle rail transit time of MaaS options is -0.521 , which is significantly larger than the absolute aggregate elasticity of any level-of-service attribute included in the bundles. A comparison of the two modeling approaches shows

that stage-wise modeling is better at describing within-stage preference heterogeneity and detailed user profiles. Integrated modeling is better at identifying cross-stage transition mechanisms and key factors over the full adoption cycle. The two approaches are complementary and jointly provide a micro-level behavioral basis for promotion strategy simulation.

(5) Multi-objective strategy optimization for city-scale MaaS promotion. Based on the synthetic population generated for a megacity and a behavioral model that describes residents' multi-stage MaaS adoption, an agent-based MaaS adoption simulation model is developed, integrating awareness diffusion, multi-stage adoption, and subscription retention. It maps the dynamic strategy space to three objectives: the user adoption rate, platform revenue, and carbon emission reduction. A hybrid analytical surrogate model and a deep-learning surrogate model are then developed, and a corresponding solution method is designed for each surrogate. These surrogate models are embedded in a proposed trust-region-based multi-objective optimization algorithm, which progressively approximates the Pareto front. In the small-scale case based on the household travel survey, the city-level overall normalized mean absolute error (NMAE) values of the deep-learning surrogate are 3.61% and 3.01% under the low- and high-budget settings, respectively. Both values are lower than the corresponding values of 8.38% and 8.16% for the hybrid analytical surrogate model. Under the high-budget setting, the final hypervolume obtained with the deep-learning surrogate is 0.73, which is 8.54% higher than that obtained with the hybrid analytical method. These results confirm the predictive and optimization performance of the proposed method. A large-scale case using the citywide synthetic population confirms that the framework can be applied at the city scale. The proposed method produces a diverse set of promotion strategies within an acceptable time and provides a quantitative basis for MaaS promotion strategy design.

KEYWORDS: Mobility as a Service; promotion strategy; population synthesis; activity generation; multi-stage adoption intention; agent-based simulation; surrogate model design; multi-objective optimization

目录

摘要	ii
ABSTRACT	v
1 绪论	1
1.1 研究背景及意义	1
1.1.1 研究意义	4
1.2 研究目标及范围界定	5
1.2.1 研究目标	5
1.2.2 研究范围界定	6
1.3 研究内容	7
1.4 技术路线与结构安排	10
1.5 本章小结	13
2 国内外研究现状	14
2.1 人口合成方法研究	14
2.1.1 基于统计推断的人口合成方法	15
2.1.2 基于统计学习的人口合成方法	16
2.2 活动计划生成研究	18
2.2.1 机理模型	20
2.2.2 数据驱动模型	21
2.3 MaaS 采纳意愿研究	22
2.3.1 单次出行场景下 MaaS 选择行为研究	22
2.3.2 MaaS 套餐订阅行为研究	23
2.3.3 MaaS 多阶段采纳行为研究	25
2.4 MaaS 运营与推广策略研究	25
2.4.1 MaaS 运营策略研究	26
2.4.2 MaaS 推广策略研究	27
2.5 既有研究评述	29
2.6 本章小结	30
3 面向出行分析的超大城市家庭级人口合成	31
3.1 本章引论	31
3.2 基于层次密度聚类的家庭画像生成	34
3.2.1 家庭特征构建	34

3.2.2	家庭画像聚类生成	36
3.3	分层扩散 Transformer 模型	37
3.3.1	模型总体结构	37
3.3.2	分层扩散过程	38
3.3.3	家庭级扩散 Transformer 模块	39
3.3.4	基于图处理模块的家庭结构表征	40
3.3.5	个人级扩散 Transformer 模块	43
3.3.6	损失函数与模型训练	45
3.4	生成数据边际分布对齐方法	46
3.4.1	反向采样过程	47
3.4.2	采样过程引导梯度计算	48
3.4.3	梯度间冲突协调方法	49
3.5	样本零与结构零控制策略	50
3.6	两阶段超参数调优策略	51
3.6.1	超参数先验分布构建	52
3.6.2	超参数寻优算法	53
3.7	算例实验	55
3.7.1	算例数据描述	55
3.7.2	实验设置与评价指标	58
3.7.3	基准模型对比分析	60
3.7.4	消融实验分析	61
3.7.5	家庭结构图生成质量分析	64
3.7.6	多地理尺度边际分布对齐效果评估	66
3.7.7	样本零与结构零处理效果评估	68
3.8	本章小结	69
4	考虑家庭联合活动的家庭级活动计划生成	71
4.1	本章引论	71
4.2	融合家庭-成员特征的多任务编码器	73
4.2.1	家庭-成员特征融合	75
4.2.2	活动模式先验构建	75
4.2.3	渐进分层提取编码器	75
4.3	考虑家庭联合活动的多任务学习解码器	77
4.3.1	家庭成员特征协调层	79
4.3.2	自回归活动计划生成器	79

4.4	基于纳什议价的家庭活动计划协调层	82
4.4.1	问题构建	83
4.4.2	两阶段优化算法	85
4.5	损失函数与模型训练策略	88
4.6	小规模算例实验	89
4.6.1	算例数据描述	90
4.6.2	实验设置与评价指标	91
4.6.3	基准模型对比分析	93
4.6.4	消融实验分析	95
4.6.5	家庭级活动计划内部协调性	97
4.6.6	个体级活动计划属性分布	99
4.6.7	目的地空间分布	102
4.7	大规模算例实验	104
4.7.1	算例设置	104
4.7.2	生成规模与计算效率	105
4.7.3	个体级活动计划属性分布	106
4.7.4	目的地空间分布	108
4.8	本章小结	109
5	MaaS 多阶段采纳意愿的分阶段建模	111
5.1	本章引论	111
5.2	MaaS 多阶段采纳意愿调查与特征分析	113
5.2.1	两步式陈述偏好实验设计	113
5.2.2	调查实施与样本统计分析	120
5.3	单次出行场景下 MaaS 转移意愿建模	124
5.3.1	态度潜变量识别	124
5.3.2	基于混合潜在分类模型的 MaaS 转移行为建模	125
5.3.3	模型估计结果	128
5.3.4	MaaS 转移意愿指标构建	133
5.3.5	转移人数灵敏度分析	135
5.4	基于转移意愿的 MaaS 套餐订阅建模	138
5.4.1	单次出行意愿向套餐订阅决策的偏好传导	138
5.4.2	态度潜变量识别	139
5.4.3	考虑属性无视的混合潜在分类模型	141
5.4.4	模型估计结果	144
5.4.5	灵敏度与弹性分析	151

5.5	本章小结	154
6	MaaS 多阶段采纳意愿的一体化建模	156
6.1	本章引论	156
6.2	多指标多原因模型构建	157
6.2.1	结构方程构建	158
6.2.2	测量方程构建	159
6.2.3	似然函数与潜变量计算	159
6.3	基于隐马尔可夫模型的多阶段采纳意愿建模	160
6.3.1	初始行为状态隶属模型	161
6.3.2	单次出行阶段选择模型	161
6.3.3	跨阶段行为状态转移模型	162
6.3.4	套餐订阅阶段选择模型	163
6.3.5	联合似然函数与模型标定	163
6.4	模型结果分析	164
6.4.1	MIMIC 模型估计结果	164
6.4.2	隐马尔可夫模型估计结果	168
6.5	弹性分析与讨论	175
6.5.1	行为状态的条件弹性分析	175
6.5.2	考虑全体用户的 MaaS 服务水平弹性	177
6.5.3	分阶段与一体化建模结果对比	180
6.6	本章小结	181
7	基于仿真优化的 MaaS 推广策略优化	183
7.1	本章引论	183
7.2	基于多智能体仿真的推广策略评估模型	186
7.2.1	仿真模型基本设定	186
7.2.2	MaaS 认知扩散模块	190
7.2.3	多阶段采纳意愿决策模块	193
7.2.4	用户留存与流失模块	196
7.2.5	推广策略效果评估模块	198
7.3	仿真优化代理模型	199
7.3.1	仿真优化问题构建	200
7.3.2	混合解析代理模型设计	202
7.3.3	基于深度学习的代理模型设计	213

7.4	基于信赖域机制的多目标优化算法	227
7.4.1	算法设定	227
7.4.2	算法运行流程	230
7.5	小规模算例实验	232
7.5.1	算例数据与实验设置	233
7.5.2	深度学习代理模型有效性检验	236
7.5.3	代理模型性能对比	237
7.5.4	多目标优化结果分析	240
7.5.5	代表性推广策略效果分析	242
7.6	大规模算例实验	250
7.6.1	算例数据与实验设置	250
7.6.2	多目标优化结果分析	251
7.6.3	代表性推广策略效果分析	252
7.7	本章小结	258
8	总结与展望	260
8.1	研究总结	260
8.2	创新点	262
8.3	研究展望	263
	参考文献	265
	作者简历及攻读博士学位期间取得的研究成果	280

图目录

图 1-1 论文技术路线	11
图 3-1 面向出行分析的超大城市家庭级人口合成方法总体框架	34
图 3-2 分层扩散 Transformer 模型总体结构	38
图 3-3 基于能量引导的多地理尺度边际分布对齐流程	47
图 3-4 北京市人口分布	58
图 3-5 消融实验中家庭级属性分布对比	63
图 3-6 消融实验中个人级属性分布对比	64
图 3-7 家庭结构图邻接矩阵相似度分析	65
图 3-8 家庭结构图边类型与节点类型预测准确率分布	65
图 3-9 栅格尺度机动车拥有比例边际对齐误差空间分布	66
图 3-10 行政区尺度人口边际分布绝对误差对比	67
图 3-11 城市尺度人口边际分布绝对误差对比	68
图 3-12 生成样本与居民出行调查样本在 VAE 潜空间中的 Wasserstein 距离分布	69
图 4-1 考虑家庭联合活动的家庭级活动计划生成方法总体框架	73
图 4-2 融合家庭-成员特征的多任务编码器示意图	74
图 4-3 家庭协调式活动链解码器示意图	78
图 4-4 北京市交通分析小区与兴趣点空间分布	91
图 4-5 CoHACT 生成家庭级活动计划与实际分布对比	98
图 4-6 CoHACT 生成的活动计划与实际活动计划的一维边际分布对比	100
图 4-7 真实调查与 CoHACT 生成样本的出行距离分布	101
图 4-8 真实调查与 CoHACT 生成样本的活动时长分布	102
图 4-9 目的地空间分布对比	103
图 4-10 目的地区域覆盖的长尾验证	104
图 4-11 大规模生成活动计划与居民出行调查数据的一维边际分布对比	107
图 4-12 目的地空间分布对比	108
图 5-1 MaaS 多阶段采纳意愿的分阶段建模总体框架	113
图 5-2 调查问卷总体设计框架	115
图 5-3 第三部分单次出行情境 SP 实验界面示例	117

图 5-4 样本出行模式特征分布（选择“主要出行方式”时允许多选）	123
图 5-5 单次出行场景下 MaaS 转移行为建模框架	126
图 5-6 单次出行场景下备选方案示意图	127
图 5-7 MaaS 转移意愿指数的核密度估计图	134
图 5-8 两类别受访者 MaaS 转移意愿指数的核密度估计图	135
图 5-9 MaaS 多模式出行服务出行时间变化下转移至 MaaS 的人数	136
图 5-10 不同出行距离情境下转移人数随出行时间变化	137
图 5-11 基于单次出行转移意愿的 MaaS 套餐订阅选择模型框架	142
图 5-12 MaaS 存疑者与 MaaS 乐观者的价格灵敏度	152
图 5-13 MaaS 存疑者与 MaaS 乐观者订阅意愿对套餐价格的集计直接点弹性	153
图 5-14 MaaS 存疑者与 MaaS 乐观者套餐订阅对非价格变量的集计直接点弹性	154
图 6-1 MIMIC 模型结构	158
图 6-2 MaaS 多阶段采纳意愿的一体化建模框架	160
图 6-3 服务水平相关属性对 MaaS 多阶段采纳意愿的状态条件弹性	176
图 6-4 MaaS 套餐整体订阅弹性	178
图 6-5 分套餐的订阅弹性	179
图 7-1 基于仿真优化的 MaaS 推广策略优化框架	185
图 7-2 推广策略仿真评估模型框架图	186
图 7-3 混合解析代理模型框架	203
图 7-4 基于深度学习代理模型总体架构	214
图 7-5 低预算档两类代理辅助优化的超体积增长曲线	240
图 7-6 高预算档两类代理辅助优化的超体积增长曲线	240
图 7-7 两类代理模型所得 Pareto 解集的分布	241
图 7-8 三个深度学习代表方案的分阶段推广策略	244
图 7-9 三个深度学习代表方案的分区推广策略	245
图 7-10 小规模案例三种代表方案的分阶段、分区的目标值	247
图 7-11 三种代表方案的用户采纳率分解	248
图 7-12 三种代表方案的 3 年累计净收入分解	249
图 7-13 三种代表方案的累计碳减排分解	250
图 7-14 大规模算例 Pareto 近似集的二维投影与三维分布	251
图 7-15 三种代表方案的分阶段推广策略配置	254
图 7-16 三种代表方案的分区推广策略配置	255

图 7-17 大规模案例三种代表方案的分阶段、分区目标值	257
------------------------------------	-----

表目录

表 2-1	代表性人口合成方法研究汇总	15
表 2-2	代表性活动计划生成方法研究汇总	19
表 3-1	北京市行政区尺度人口边际属性统计	56
表 3-2	北京市城市尺度人口边际属性统计	57
表 3-3	HiDiT 模型主要超参数设置	59
表 3-4	不同模型的平均 SRMSE 对比结果	60
表 3-5	HiDiT 模型不同模块的消融实验结果	62
表 3-6	合成样本中有效样本、潜在样本零与潜在结构零分类结果	68
表 4-1	CoHACT 模型超参数设置	92
表 4-2	CoHACT 与基准模型的多维度 SRMSE 对比（值越小越优，最优模型以加粗标出）	94
表 4-3	消融实验结果（最优模型以加粗标出）	96
表 4-4	大规模算例的分区生成规模与耗时	106
表 5-1	单次出行场景 SP 实验的属性水平设置	118
表 5-2	MaaS 套餐的属性水平设置	119
表 5-3	各类出行服务的购买成本	120
表 5-4	调查问卷样本社会经济属性的统计分布	121
表 5-5	态度陈述的响应统计结果	123
表 5-6	态度潜变量验证性因子分析结果	125
表 5-7	单次出行情境下的结构模型估计结果	129
表 5-8	单次出行情境下的测量模型估计结果（括号内为 t 值）	130
表 5-9	单次出行情境下不同类别数模型的拟合优度对比	130
表 5-10	单次出行情境下的选择模型估计结果（括号内为 t 值）	131
表 5-11	套餐订阅模型潜变量识别的 EFA 因子载荷	139
表 5-12	CFA 验证后潜变量与态度指标的对应关系	140
表 5-13	套餐订阅情境下的结构模型估计结果（括号内为 t 值）	144
表 5-14	套餐订阅情境下的测量模型估计结果（括号内为 t 值）	145
表 5-15	不同类别数模型的拟合优度对比	146
表 5-16	套餐订阅情境下的选择模型估计结果（括号内为 t 值）	147

表 6-1	MIMIC 模型总体拟合优度	165
表 6-2	MIMIC 结构模型估计结果（括号内为稳健 t 值）	166
表 6-3	MIMIC 测量模型估计结果（括号内为稳健 t 值）	167
表 6-4	HMM 模型估计结果（括号内为稳健 t 值）	169
表 7-1	智能体的动态状态变量	188
表 7-2	推广策略决策变量	189
表 7-3	小规模算例仿真预算设置	233
表 7-4	小规模算例仿真模型主要参数设置	234
表 7-5	小规模算例深度学习代理训练、反向求解与优化参数设置	234
表 7-6	多种实验设置下混合 ReLU 数量统计	236
表 7-7	中心冻结模型相对原深度学习代理的逐目标 NMAE (%)	237
表 7-8	MIP 问题构建与求解结果（中位数）	237
表 7-9	三类代理模型的城市级目标预测精度（NMAE, %）	238
表 7-10	纯解析代理与深度学习代理仿真过程目标预测精度（NMAE, %）	238
表 7-11	统一无量纲目标空间和固定参考点下的精确超体积增长	239
表 7-12	两类代理模型所得 Pareto 近似集的单目标最优策略	242
表 7-13	三种代表方案的独立实验稳定性结果	243
表 7-14	三种代表性推广策略效果	253

1 绪论

1.1 研究背景及意义

出行即服务（Mobility as a Service, MaaS）是近十余年来兴起的一种新型出行服务组织范式。该理念由 Hietanen 于 2014 年首次系统提出^[1]，并在同年于赫尔辛基举办的智能交通系统（Intelligent Transport Systems, ITS）欧洲大会上引起广泛关注；2015 年，MaaS 联盟（MaaS Alliance）在 ITS 世界大会期间宣告成立，标志着这一理念开始由北欧走向全球。按照 MaaS 联盟的界定，MaaS 是指将多种交通方式的出行服务整合为按需响应的一体化出行服务。具体而言，MaaS 以用户出行需求为中心，依托一站式数字平台整合城市轨道交通、地面公交、共享单车、网约车、汽车租赁等多模式出行资源，为用户提供覆盖行前规划、预约、支付与行中引导的全流程无缝出行服务，并以按次付费（Pay-As-You-Go, PAYG）、订阅制套餐等灵活形式重构出行服务的供给与消费方式^[2,3]。就其内核而言，MaaS 倡导的是出行消费从拥有交通工具向按需购买出行服务的范式转变，因而被广泛视为数字时代重塑城市出行体系的代表性方向。对用户而言，一站式服务显著降低了多模式出行中信息搜寻、换乘衔接与支付交易的成本，提供了可与私家车相竞争的出行便利性；对运营者而言，多方式客流的汇聚与出行数据的融合为精细化运营和增值服务创造了条件；对城市与社会而言，MaaS 通过提升公共交通与共享出行在出行链中的地位，有望降低私家车依赖与保有水平，被视为有望缓解交通拥堵、推动城市交通系统低碳化与共享化转型的解决方案^[4,5]。

在我国，发展 MaaS 既有迫切的现实需求，也具备坚实的实践基础。从现实需求看，伴随城镇化与机动化进程的持续推进，截至 2025 年底全国机动车保有量已达 4.69 亿辆、机动车驾驶人达 5.59 亿人，特大城市普遍面临交通拥堵、停车资源紧张与污染排放等治理难题；交通运输亦是我国碳排放的重要来源领域，在“双碳”战略目标下，引导小汽车出行向集约绿色出行方式转移、提升绿色出行比例，已成为城市交通治理的核心命题之一。从实践基础看，我国建成了世界上规模最大的城市公共交通与轨道交通网络，共享单车、网约车等新业态发展活跃，移动互联网与移动支付高度普及，为 MaaS 的落地提供了丰厚的服务供给与技术土壤。

正因如此，国家顶层设计对发展 MaaS 作出了持续而明确的部署。2019 年 9 月，中共中央、国务院印发《交通强国建设纲要》，提出构建安全、便捷、高效、绿色、经济的现代化综合交通体系，推进出行服务快速化、便捷化，开展绿色出行行动；同年，交通运输部印发《数字交通发展规划纲要》，明确提出“倡导‘出行即服

务(MaaS)’理念,以数据衔接出行需求与服务资源,使出行成为一种按需获取的即时服务”,交通运输部等十二部门和单位联合印发《绿色出行行动计划(2019—2022年)》,将完善绿色出行服务体系落实为专项行动。进入“十四五”时期,《数字交通“十四五”发展规划》进一步要求“倡导‘出行即服务’理念,鼓励企业整合多种方式出行信息资源,为旅客提供全链条、多方式、一站式出行服务”;国务院印发的《“十四五”现代综合交通运输体系发展规划》亦部署“支持市场主体整合资源,提供‘一站式’出行服务”。可以看出,大力发展出行即服务已成为我国推进交通强国建设、实现交通运输绿色低碳转型的明确政策导向,为MaaS在我国的探索实践营造了良好的政策环境。

在理念倡导与政策推动的双重作用下,北京市交通委员会于2019年11月依托高德地图、百度地图等互联网平台启动建设全国首个城市级MaaS平台——北京交通绿色出行一体化服务平台,聚合公交、轨道、骑行、步行等多种方式出行服务,并于2020年9月率先推出绿色出行碳普惠激励机制,截至2024年注册用户已超过3000万;上海于2022年10月正式上线城市级MaaS应用“随申行”,广州、深圳、成都等城市亦结合本地特点开展了政企协同的多样化试点探索。除此之外,MaaS试点平台近十年间在全球范围内也呈现百花齐放的态势。瑞典哥德堡于2013—2014年开展的UbiGo现场试验以家庭订阅套餐整合公共交通、汽车共享、租车与出租车等服务,被视为MaaS最早的完整实践之一^[6,7];芬兰MaaS Global公司于2016年在赫尔辛基推出全球首个商业化运营的3级MaaS平台Whim,以月度订阅套餐覆盖公共交通、出租车、共享汽车等多种方式,并先后拓展至伯明翰、安特卫普、维也纳、东京等城市^[8,9];此后,维也纳WienMobil、柏林Jelbi、日本my route等由公共交通运营商或产业联盟主导的平台相继上线,澳大利亚悉尼亦依托Tripi应用开展了面向订阅套餐的MaaS现场试验^[10]。至此,MaaS已完成从理念到产品的初步落地,进入以试点检验模式、以模式支撑推广的关键阶段。

然而,与政策期待和舆论热度形成鲜明反差的是,MaaS的市场化推广远未取得预期成效,全球试点普遍陷入理念叫好、市场遇冷的发展困境。作为诞生于MaaS理念发源地的全球标杆项目,Whim的订阅用户规模与出行分担率长期低于预期,平台持续依赖外部融资维持运营,在累计融资超过1.6亿欧元后仍未能建立可持续的盈利模式,其运营方MaaS Global最终于2024年3月宣告破产^[9],为全球MaaS实践敲响了警钟。除此之外,UbiGo试验虽然获得了较高的用户满意度与继续使用意愿,但试验结束后服务因商业模式与制度障碍未能延续^[7];悉尼MaaS试验发现,多数用户仅愿意接受按次付费形式,对月度订阅套餐的支付意愿有限^[10,11];新加坡Zipster等一批平台亦相继收缩或终止服务。

国内实践同样面临瓶颈。现有试点大多由政府主导,以信息集成与支付集成

为主要形态，全国范围内尚未形成实现深度服务集成、以套餐订阅为特征的成熟 MaaS 平台；平台功能与既有地图导航、公交查询类应用同质化明显，用户黏性不足，活跃用户规模相对于城市全量出行需求仍然有限；碳普惠等激励机制虽在引导绿色出行方面初见成效，但平台运营高度依赖财政投入与企业让利，自我造血的商业模式尚未形成。总体而言，我国 MaaS 发展仍处于渗透率很低的起步阶段，潜在用户对 MaaS 的认知与体验有限，深度集成、主体协同与可持续运营等关键问题尚待破解。

面对接连受挫的实践，学术界和业界开始形成对 MaaS 的又一认识：以订阅套餐为核心的第一代 MaaS 商业模式，可能系统性地高估了用户从既有出行习惯向 MaaS 迁移的意愿^[12,13]。在大量 MaaS 试点相继失败的现实挑战下，如何推广 MaaS 愈发受到重视。然而，MaaS 推广绝非搭建平台、接入服务的简单技术集成问题，而是一项涉及用户行为转变、多主体利益协调与长周期市场培育的复杂工程，其关键在于能否以科学的方法识别用户、构建策略、优化运营。具体而言，MaaS 推广当前阶段面临的难题可归结为以下三个方面。

其一，推广策略的现实试错成本高昂。MaaS 推广涉及套餐设计、定价补贴、营销投放、服务配置等多维策略，其效果须投放真实市场并历经足够长的运营周期方能显现；一旦策略设计偏离用户偏好，纠错的代价便是持续的资金消耗、用户流失乃至平台倒闭。同时，真实市场中常用的上线—观察—调整的试错模式周期漫长，策略带来的效益与外部环境因素相互交织，难以从推广效果中剥离单一策略的直接贡献。因此，在推广策略投放现实市场之前，亟需在计算环境中构建能够刻画大规模异质用户采纳行为的高保真仿真系统，作为策略预评估的试验场，以低成本、可重复、可控的方式对候选策略进行先行检验。

其二，用户对 MaaS 的多阶段采纳机理复杂。用户采纳 MaaS 并非一蹴而就的单点决策，而是历经“初次认知—单次出行尝试—长期套餐订阅”的渐进过程：各阶段的决策情境、影响因素与心理机制存在系统性差异，前序阶段形成的体验与初始印象又会显著影响后续阶段的决策倾向。在我国 MaaS 渗透率很低的背景下，潜在用户对 MaaS 的认知有限，单次出行场景下的初次体验对于培育长期订阅需求尤为关键。

其三，面向多元目标的推广策略制定困难。即便具备了仿真评估手段与行为机理认知，如何从策略空间中科学制定优质的推广策略仍是难题。推广策略由多阶段、多维度的决策变量组合而成，策略空间随维度增长呈指数级膨胀。在应用仿真手段模拟推广策略的实际效果时，仿真计算运行成本高昂，穷举式或大规模随机搜索在计算上不可行。更为重要的是，MaaS 推广同时承载用户采纳、平台收益、环境效益等多元目标，各目标之间存在此消彼长的权衡关系，面向单一目标的

优化往往顾此失彼。

然而，既有研究在推广策略仿真、行为机理与策略制定三个层面仍存在不足。首先，在仿真数据供给层面，既有研究多采用小规模样本开展分析，难以兼顾全市范围内的潜在采纳者与背景出行者，不足以支撑对 MaaS 采纳决策及新型服务传播过程的刻画。同时，小规模样本难以反映用户逐步采纳和 MaaS 使用所引致的交通系统拥堵、等待时间延长及车内拥挤等服务水平变化，也无法揭示服务水平下降对后续用户选择行为的反馈作用。其次，在行为机理层面，既有研究多聚焦于套餐订阅等单一阶段的意愿建模，对阶段间需求的继承、迟滞与流失等迁移机制缺乏体系化解析，导致 MaaS 推广过程中差异化服务设计缺乏坚实的行为机理依据。最后，在策略制定层面，既有研究与实践尚缺乏面向 MaaS 大规模推广的多目标策略优化方法，难以在有限计算资源下有效探索高维策略空间，亦难以协调用户采纳、平台收益与环境效益等目标之间的权衡关系，因而无法充分支撑推广策略的精细化设计与科学决策。

综上所述，破解 MaaS 推广应用困境，亟需打通“仿真基础构建—采纳机理解析—推广策略优化”的完整方法链条：以高保真的合成人口与出行计划夯实仿真基础，以 MaaS 多阶段采纳意愿建模揭示行为机理，进而提出面向大规模仿真的推广策略优化方法，实现推广策略的高效寻优。这正是本文选题的出发点与研究主线。

1.1.1 研究意义

面对出行即服务在政策大力支持背景下仍面临的用户订阅率低迷、运营持续亏损、规模化运营受阻等发展困境，以及国际典型 MaaS 项目相继运营失败、国内 MaaS 试点用户黏性不足等严峻挑战，亟需从构建支撑推广策略科学制定的微观行为仿真基础设施出发，深入剖析用户多阶段采纳决策机理与跨阶段迁移规律，进而研究面向多元价值诉求的 MaaS 推广策略优化方法，通过精准识别采纳障碍、优化推广策略组合，推动 MaaS 突破发展瓶颈、实现可持续运营。本研究围绕上述需求展开，具有重要的理论价值和实践价值。

理论价值方面，本研究将生成式人工智能、离散选择分析与仿真优化方法深度融合 MaaS 推广研究，构建了“仿真基础构建—行为机理解析—推广策略优化”的完整研究链条。所提出的面向出行分析的超大城市家庭级人口合成方法与考虑家庭联合活动的家庭级出行计划生成方法，将人口合成与活动出行建模的对象由相互独立的个体拓展至具有内在关联结构的家庭，丰富了活动分析法在大数据与人工智能时代的方法体系；所构建的 MaaS 多阶段采纳意愿的分阶段与一体化双建模方法，突破了现有研究聚焦单一阶段、单一集成水平的局限，为刻画“单次出

行尝试—套餐订阅”全周期采纳行为及跨阶段需求迁移规律提供了系统化的分析框架；所提出的深度学习代理模型与多目标贝叶斯优化协同的推广策略优化方法，为大规模多智能体仿真与策略寻优的高效耦合提供了新的方法范式。上述成果共同拓展了出行行为建模与交通系统仿真优化的理论边界，可为交通行为科学、智能交通系统等相关领域研究提供方法借鉴。

实践价值方面，研究成果可为城市交通管理部门与 MaaS 平台运营者提供直接的技术支撑与决策依据。对城市交通管理部门而言，所构建的高保真合成人口与家庭出行计划仿真基础设施，可支撑 MaaS 推广乃至更广泛交通政策对城市交通运行、社会公平与环境效益综合影响的事前评估，辅助相关政策的科学制定；对 MaaS 平台运营者而言，多阶段采纳意愿模型揭示了用户在单次出行尝试与套餐订阅等不同决策环节的差异化偏好与关键障碍，可支撑差异化服务方案与套餐组合的精准设计，融合多智能体仿真与多目标优化的策略优化框架可在定价、补贴、营销、服务覆盖等多维策略空间中高效识别协同最优方案，为平台以有限资源实现可持续运营提供量化决策工具。从更宏观的视角看，研究成果有助于引导小汽车出行向绿色集约出行方式转移、降低交通能耗与碳排放，可为交通强国建设与“双碳”战略下城市交通绿色低碳转型提供有力支撑。

1.2 研究目标及范围界定

1.2.1 研究目标

本研究以破解 MaaS 推广现实困境、推动城市交通系统绿色化与智能化转型的现实需求为牵引，围绕超大城市 MaaS 推广策略科学制定这一核心问题，旨在构建“仿真基础构建—行为机理解析—推广策略优化”的一体化研究框架，提出面向 MaaS 推广的高保真出行需求生成、多阶段采纳意愿建模与多目标推广策略优化方法，以促进 MaaS 推广策略仿真评估能力、用户采纳机理解析能力与推广决策科学化水平提升等目标的实现。具体研究目标如下：

（1）突破现有人口合成研究中对家庭一个人多层级关联结构刻画不足、属性联合分布拟合精度较低的难题，针对现有人口合成方法难以为大规模 MaaS 推广策略仿真提供高保真微观人口输入的瓶颈，围绕家庭级属性、个人级属性与家庭结构的联合生成，提出家庭级大规模人口合成方法，实现超大城市家庭级别合成人口的高保真、大规模生成。

（2）克服现有出行计划生成研究对家庭联合活动刻画不足，以及对家庭成员间、活动计划各属性间耦合关系考虑不深入的问题，考虑家庭成员间的活动协同与资源共享机制，提出考虑家庭联合活动的家庭级出行计划生成方法，实现合成

人口个体与家庭全日活动出行计划的精细化生成。

(3) 针对现有 MaaS 采纳研究多聚焦单一阶段或单一集成水平、对全周期采纳意愿与跨阶段需求迁移机制解析不足的问题，从分阶段与一体化建模两种视角出发，提出 MaaS 多阶段采纳意愿建模方法，量化态度潜变量、出行习惯等因素对采纳决策的异质作用机理，揭示“单次出行尝试一套餐订阅”过程中的行为状态转移与需求迁移规律，实现 MaaS 全周期采纳行为的体系化精细刻画。

(4) 针对现有 MaaS 推广研究多局限于单一策略或少量预设情景，且城市级规模推广策略寻优困难的问题，构建融合认知扩散、多阶段采纳与留存机制的 MaaS 多智能体仿真模型，设计高精度、可辅助寻优的代理模型，进而提出基于信赖域机制的多目标优化算法，实现套餐设计、套餐定价、营销投放与服务水平等推广策略优化，并高效获取用户采纳率、平台净收入与碳减排等目标之间的 Pareto 前沿。

1.2.2 研究范围界定

MaaS 及其推广策略的内涵较为宽泛，为明确研究边界，本文从以下四个方面对研究范围加以界定。

集成水平界定。按照集成程度，Sochor 等提出的经典框架依据集成深度将 MaaS 划分为五个层级：0 级为无集成，各类出行服务彼此孤立；1 级为信息集成，提供多方式出行信息查询与行程规划；2 级为预约与支付集成，实现跨方式服务的统一预约与支付；3 级为服务集成，通过订阅套餐等形式将多种出行服务捆绑为整体性服务承诺；4 级为社会目标集成，通过政策协同使 MaaS 服务于减碳、拥堵治理等城市公共目标^[8]。集成水平的逐级跃升，意味着资源整合深度、商业模式复杂度与多主体协同难度的同步提高。本文所研究的 MaaS 涉及 2 至 3 级集成水平的服务形态，即经由一站式平台提供多模式出行的规划、预订与统一支付，并同时提供按次付费与套餐订阅两种使用方式，并涉及部分 4 级社会目标集成，即通过制定 MaaS 推广策略在提高 MaaS 接受度的同时降低交通碳排放。

研究对象界定。本文以我国超大城市为研究场景，以北京市为算例城市。仿真与策略优化的作用对象为全市居民；行为建模的对象则聚焦于 MaaS 渗透率较低阶段的潜在用户。考虑到居民出行决策的家庭关联性，人口合成与活动计划生成均以家庭为基本单元。

MaaS 采纳阶段划分界定。本文将用户对 MaaS 的采纳过程界定为两个先后衔接的阶段：其一为单次出行场景下由既有出行方式向 MaaS 多模式服务的转移（试用）阶段，其二为在初步体验基础上的套餐订阅阶段。

优化策略变量界定。本文的推广策略限定于需求侧，包括套餐定价、补贴机制、广告投放与服务覆盖等维度；策略评价目标涵盖用户采纳率、平台净收入与

碳减排三个方面。多模式交通网络的供给侧优化，如线网设计、时刻表编制与运力调度等，不在本文研究范围之内。

1.3 研究内容

为实现上述研究目标，本文凝练出贯穿全文的四个关键研究内容，对各研究内容的分析与陈述如下。

(1) 支撑大规模推广策略仿真的高保真虚拟人口合成

城市级 MaaS 推广策略仿真的作用对象为全市居民，对策略响应异质性的刻画要求人口输入微观到个体、覆盖到全市，并尽量保留与真实人口分布一致的属性联合分布与空间边际分布。然而，居民出行调查虽粒度精细却抽样率有限，人口普查与统计年鉴虽覆盖全域却仅提供边际分布，单一数据源均无法直接满足 MaaS 推广策略大规模仿真的数据需求，须以人口合成技术弥合微观样本与宏观约束之间的缺口。进一步地，居民的出行决策在一定程度上受家庭层面协调的影响，人口合成的基本单元须由个体提升至家庭，这带来了以下难点：

i. 家庭-个人层级间的“一对多”映射：家庭级属性与成员级属性之间不存在确定的对应关系，若缺乏额外的条件约束，下层成员属性的生成空间过大，难以收敛到与上层家庭属性协调一致的组合，夫妻、亲子等成员关系亦须作为显式对象建模；

ii. 高维联合分布拟合与可变家庭结构表征：基于统计推断的方法在家庭级合成中遭遇维度诅咒，列联表高度稀疏而难以估计，既有深度生成模型则多以定长向量表征单个个体，难以容纳成员数可变的家庭结构；

iii. 多尺度边际约束与不合理组合甄别：城市级别的合成人口须在市、区、交通小区等多个地理尺度上与宏观边际分布吻合，且须区分调查中恰好未出现的样本零与现实中不可能存在的结构零，避免生成逻辑矛盾的属性组合。

为此，本文以小规模居民出行调查样本为种子、以多源宏观统计信息为约束，研究家庭画像条件下的分层扩散生成方法与异构图家庭结构表征，设计能量引导的多尺度边际对齐机制与样本零、结构零控制策略，合成属性联合分布真实、家庭结构合理、规模覆盖全市的家庭级虚拟人口。

(2) 考虑家庭联合活动的城市级家庭活动计划生成

活动计划是以活动链的形式记录每位居民一日之内于何时出行、前往何处、出于何种目的以及采用何种方式，既定义了居民既有的出行模式，更界定了其向 MaaS 转移的具体出行情境，是仿真中智能体判断是否采用 MaaS 以及如何采用 MaaS 的直接输入。然而，既有研究多以个人为生成对象，忽略家庭成员间的活动协同与资源共享机制，导致生成的活动计划难以满足家庭层面的可行性。具体而

言,生成家庭级活动计划,存在以下难点:

i. 异质家庭的统一表征:家庭成员数可变、角色各异,成员之间的交互结构随家庭构成而变化,须以统一的方式嵌入异质化的家庭与成员属性。

ii. 家庭联合活动与成员间协调:接送、陪伴与家庭出游等联合活动在居民日常出行中普遍存在,家庭车辆等资源在成员间的分配构成硬性约束,个体独立生成的活动计划难以满足家庭层面的可行性;

iii. 大规模家庭级别活动计划生成的可行性:超大城市往往具有超千万户家庭,既有的基于优化的方法虽能通过显式约束较为完整地刻画家庭资源限制等条件,但在大规模生成时计算开销过高,难以满足城市级别仿真对活动计划输入的需求。

为此,本文研究集合表征与多任务学习相结合的家庭-成员统一表征方法,设计跨角色注意力自回归解码架构与空间感知目的地选择层,并引入基于纳什议价的可微协调层,在车辆可用性等家庭约束下协调各成员的活动安排,构建可重现家庭联合活动模式的活动计划生成方法。

(3) MaaS 多阶段采纳意愿的建模解析

用户对 MaaS 的采纳是由单次出行尝试到套餐订阅的渐进过程:前者决定 MaaS 能否成功吸引用户“试用”,是采纳的起点;后者决定 MaaS 能否将“试用者”转化为“长期用户”,是可持续运营的关键。然而,既有研究虽广泛研究了潜在用户对 MaaS 的采纳意愿,但大多关注套餐订阅阶段,忽视了用户首次使用 MaaS 的单次出行尝试阶段,且对阶段间需求迁移机制缺乏系统化解析。然而,解析这一多阶段采纳意愿,存在以下难点:

i. 不同阶段偏好及其异质性的刻画:在单次出行与套餐订阅等多个阶段,用户采纳 MaaS 的偏好形成机理不同。例如,在单次出行阶段,用户的选择偏好主要受出行便利性、价格敏感性等因素驱动;而在套餐订阅阶段,用户的选择偏好则更多受长期使用成本、套餐灵活性与服务覆盖等因素影响。此外,用户偏好具有异质性,其受到态度变量、社会经济属性变量、出行习惯变量等多维因素的影响。因此,在多阶段采纳意愿建模中,须充分刻画不同阶段的偏好机理及其异质性。

ii. 采纳意愿跨阶段传播机理的刻画:既有研究虽广泛研究了 MaaS 采纳单一阶段的用户选择行为,但对不同阶段之间的耦合关系缺乏刻画。实际上,在已有的 MaaS 试点中,出现了用户针对不同阶段的选择偏好差异显著的现象。具体而言,用户在单次出行阶段选择是否使用 MaaS 服务后,受到 MaaS 服务带来的出行费用节省、出行时间改善、服务便利性等体验的影响,会形成对 MaaS 的初始印象,这一印象会显著影响其后续的套餐订阅决策。构建采纳意愿的跨阶段传播机理模型,有助于揭示用户在不同阶段的选择偏好差异及其形成机制。

为此,本文首先设计两步式 SP 调查采集 MaaS 多阶段选择数据,并进一步设计了分阶段建模与一体化建模两种建模范式,以捕捉多阶段采纳意愿的异质性与跨阶段传播机理。在分阶段建模视角下,构建潜在类别选择模型刻画单次转移意愿,进而以转移意愿指数度量初始印象,进而构建潜在类别潜变量模型刻画套餐订阅行为;在一体化建模视角下,构建结合多指标多原因模型的隐马尔可夫建模框架,联合刻画初始状态形成、单次出行选择、跨阶段状态转移与套餐订阅选择的全过程。最终,通过对比两种建模范式的适用边界,为 MaaS 多阶段采纳意愿的解析提供方法论指导。

(4) 基于城市级仿真的 MaaS 推广策略优化

在构建了支撑城市级 MaaS 采纳仿真的数据基础并解析了用户多阶段采纳机理之后,最后一部分研究内容聚焦于城市级 MaaS 推广策略优化。面向用户采纳率、平台净收入与碳减排等多重目标,高效搜索套餐设计、套餐定价、营销投放与服务水平等推广策略的时空配置,以科学回答何种推广策略能够在多重目标之间实现有效权衡。然而,推广策略的时空动态性、仿真评估的高昂成本与多目标之间的冲突相互耦合,其实现存在以下难点:

i. 用户采纳过程的可信仿真:在现实推广过程中,用户会经历认知、试用、订阅、套餐选择、续订、流失等多种环节^[4],多样的策略变量通过差异化机制作用于用户各阶段决策。因此,须将前文估计的多阶段采纳行为模型与用户的认知扩散、试用与采纳、续订与流失等选择有机结合,以在个体层面刻画可信的推广策略作用下的采纳演化过程;

ii. 城市级仿真模型难以用于策略寻优:城市级多智能体仿真单次运行需大量计算开销,有限的仿真样本难以覆盖完整策略空间,不足以直接用于推广策略寻优。因此,须构建能够在小样本条件下准确近似推广策略与仿真模型多目标输出之间的映射的代理模型,同时兼顾对未评估策略的预测能力与优质候选策略的生成能力;

iii. 高维多目标策略空间的高效搜索:涵盖套餐设计、套餐定价、服务水平、营销投入的 MaaS 推广策略空间较大,且用户采纳率、平台净收入与碳减排等多个推广目标之间存在冲突,须设计有效的推广策略寻优算法,结合代理模型与仿真评估结果动态调整搜索范围,在局部开发与全局探索之间取得平衡,从而在尽可能少的仿真预算下逐步逼近 Pareto 前沿。

为此,本文首先融合 Bass 扩散与空间网络效应刻画营销影响,以获得的多阶段采纳行为模型驱动智能体决策,设计用户采纳率、平台净收入与碳减排三目标评估方法,因而形成能够刻画用户采纳过程与推广策略效果的基于多智能体仿真的推广策略评估模型。其次,推导以状态概率递推为核心的平均场解析代理模型,

在其上叠加高斯过程残差校正形成混合解析代理，并设计具有小样本学习与持续学习能力的深度学习代理模型。设计两类代理模型的反向求解算法，以辅助进行策略寻优。最后，提出基于信赖域机制的多目标优化算法，结合提出的代理模型反向求解方法生成候选策略，并结合仿真模型评估、信赖域更新、代理更新等算法流程，在有限仿真预算下高效形成 Pareto 近似解集，为 MaaS 推广策略的制定提供参考。

1.4 技术路线与结构安排

本文共包含八章，整体技术路线如图1-1所示。全文遵循“问题剖析—仿真基础构建—行为机理解析—推广策略优化”的研究主线：以多源数据为基础，首先合成家庭级虚拟人口并生成活动计划，构建城市级仿真的微观底座；继而从分阶段与一体化两种视角解析 MaaS 多阶段采纳机理，提炼智能体的多阶段采纳行为参数；最终以多智能体仿真为推广策略评估方法，通过构建两类代理模型辅助寻优，结合基于信赖域的多目标优化算法完成推广策略的多目标协同优化。




图 1-1 论文技术路线

Figure 1-1 Flow chart of the dissertation.

其余各章的主要内容总结如下。

第2章是文献综述部分，主要梳理人口合成方法、活动计划生成、MaaS 采纳意愿与 MaaS 推广策略四个方面研究的发展脉络，探讨已有文献的研究不足，并分析有待进一步完善之处。

第3章主要研究面向出行分析的超大城市家庭级人口合成问题，提出了一种家庭画像条件下的分层扩散生成模型。模型以异构图表征家庭内部的成员关系，实现家庭属性、家庭结构与成员属性的联合生成，并设计了能量引导的多尺度边际对齐机制与样本零、结构零正则化策略。此章内容为后续研究提供了覆盖全市的微观决策主体，是整个仿真链条的源头环节。

第4章主要研究家庭级活动计划生成问题，提出了一种考虑家庭联合活动的家庭级活动计划生成模型。模型以集合表征与共享-专属编码统一嵌入异质化的家庭与成员属性，经跨角色注意力自回归解码与空间感知目的地选择生成各成员的活动计划，并引入基于纳什议价的可微协调层保障家庭层面的可行性。此章内容与第3章相结合，构成了城市级 MaaS 推广策略仿真的完整微观底座。

第5章主要研究 MaaS 多阶段采纳意愿的分阶段建模，设计了两步式陈述偏好调查，针对单次出行场景下的 MaaS 转移意愿构建基于混合潜在分类模型的 MaaS 转移行为选择模型，针对套餐订阅决策构建基于初始印象的考虑属性无视的混合潜在分类模型，识别异质用户类别及各阶段采纳的驱动与障碍因素。此章内容精细刻画了各阶段内的偏好异质性，为推广策略仿真提供了各阶段专用的行为模型。

第6章仍研究 MaaS 多阶段采纳意愿，从一体化建模视角构建了融合多指标多原因（MIMIC）模型与隐马尔可夫模型的建模框架，联合刻画初始行为状态隶属、单次出行阶段选择、跨阶段行为状态转移与套餐订阅阶段选择的全过程，并对比分析了分阶段与一体化两种建模范式的适用边界。此章内容与第5章相互补充，为第7章提供了跨阶段行为状态转移机理与行为参数选用依据。

第7章主要研究城市级 MaaS 多目标推广策略优化问题。构建 MaaS 采纳多智能体仿真模型，量化推广策略的实施效果。其次，分别构建由平均场解析模型与高斯过程残差校正组成的混合解析代理模型，以及具有小样本学习和持续学习能力的深度学习代理模型，并设计与两类代理结构相适配的反向求解方法。最后，提出基于信赖域机制的多目标代理辅助优化算法，利用代理模型的反向求解算法生成候选策略，并结合仿真模型评估结果进行信赖域调整和代理模型更新，在有限仿真预算下逐步逼近推广策略的 Pareto 前沿，并以居民出行调查数据以及生成的全市虚拟人口为算例分析代表性推广策略。此章将前述家庭级虚拟人口、活动计划与 MaaS 多阶段采纳行为模型应用于推广策略仿真与优化，并提出了面向大规模多智能体仿真与多目标优化的推广策略优化方法，为 MaaS 推广策略的科学制

定提供了技术支撑。

第8章是结论部分，在总结全文研究内容的基础上，进一步梳理了研究工作的创新点，并对未来可以继续完善和补充的研究方向进行展望。

1.5 本章小结

本章首先介绍了 MaaS 发展的政策背景与国内外实践现状，分析了 MaaS 推广过程中用户规模不足、平台盈利困难等现实问题，并阐明了开展相关研究的理论意义与实践价值。结合城市级 MaaS 推广决策需求，提出了本文需要解决的四个关键问题：如何构建高保真的家庭级虚拟人口，如何生成考虑家庭联合活动的活动计划，如何刻画 MaaS 多阶段采纳意愿及其跨阶段迁移机理，以及如何在昂贵仿真约束下实现多目标推广策略优化。基于上述问题，确定了本文的研究目标与研究范围，形成了“仿真基础构建—行为机理解析—推广策略优化”的研究内容与技术路线，为后续各章研究奠定了基础。

2 国内外研究现状

围绕第1章凝练的四部分研究内容，本章从四个方面对国内外研究现状进行综述：首先综述支撑仿真微观底座的人口合成方法，其次综述活动计划生成研究，再次综述 MaaS 采纳意愿研究，最后综述 MaaS 运营与推广策略研究。在此基础上，对国内外既有研究主要存在的不足和有待进一步研究的内容进行评述，为本文后续各章的研究提供理论基础与方法借鉴。

2.1 人口合成方法研究

人口合成旨在基于有限的微观样本与宏观统计数据，生成能够准确复现研究区域人口社会经济属性联合分布及其空间分布的虚拟人口，是基于活动的出行需求模型（Activity-Based Model, ABM）的第一步，也是城市级交通仿真的微观数据基础^[15-17]。既有的人口合成方法大多基于两类数据开展研究：一类为集计数据，又称边际数据，指研究区域内人口特征的汇总计数或多维属性的占比，多来源于人口普查与统计年鉴；另一类为非集计数据，又称种子数据或样本数据，指涵盖个体多维社会经济属性的微观样本，多来源于居民出行调查等抽样调查^[18]。围绕如何从种子数据中学习属性联合分布并使合成的人口满足宏观边际分布约束，既有方法大体可分为基于统计推断的重加权方法与基于统计学习的方法（以深度生成模型为代表）两大类^[18]，代表性研究如表 2-1所示。值得注意的是，居民的出行决策在相当程度上是家庭层面协调的产物，以家庭为单元的虚拟人口是活动仿真的理想输入^[18]；然而，同一家庭内成员的属性之间存在复杂的依赖关系，如户主与配偶的年龄、受教育程度往往显著相关，子女的存在又会影响家庭的车辆拥有与居住选址^[19]，这使得家庭级合成远比个体级合成困难。考虑到本文以家庭为基本合成单元，且家庭级合成并非独立的方法类别，而是上述两类方法在合成对象上由个体向家庭的延伸，下面从基于统计推断的人口合成方法与基于统计学习的人口合成方法两个方面分别进行综述，并在各方法路线中一并考察以家庭为对象的合成研究。

表 2-1 代表性人口合成方法研究汇总

Table 2-1 Summary of representative studies on population synthesis methods.

类别	代表研究	方法	主要特点
基于统计推断的重加权方法			
	Deming 和 Stephan (1940) ^[20]	迭代比例拟合 (IPF)	提出列联表迭代比例调整思想, 为 IPF 方法的雏形
	Beckman 等 (1996) ^[15]	IPF	首次将 IPF 用于 TRANSIMS 虚拟人口生成, 确立“拟合—分配”两阶段流程
	Voas 和 Williamson (2000) ^[21]	组合优化	以随机替换最小化拟合误差, 缓解 IPF 的整数化偏差
	Ye 等 (2009) ^[22]	迭代比例更新 (IPU)	实现家庭级与个人级属性分布的同时匹配
	Pritchard 和 Miller (2012) ^[23]	稀疏列表 IPF	以稀疏数据结构降低高维合成的内存开销
	Barthelemy 和 Toint (2013) ^[24]	无样本合成	以熵最大化与禁忌搜索摆脱对种子样本的依赖
	Konduri 等 (2016) ^[25]	增强 IPU	支持多空间分辨率级别的边际控制
	Khachman 等 (2024) ^[26]	多分辨率集成框架	实现由区域到建筑级的空间化人口分配
基于统计学习的方法			
	Farooq 等 (2013) ^[27]	马尔可夫链蒙特卡罗	首个基于统计学习的合成方法, 经条件分布抽样缓解样本零问题
	Sun 和 Erath (2015) ^[28]	贝叶斯网络	编码属性依赖结构, 小样本情形下优于 IPF
	Saadi 等 (2016) ^[29]	隐马尔可夫模型	灵活融合多源不一致数据
	Sun 等 (2018) ^[19]	层次混合模型	以多层潜变量刻画家庭成员间属性依赖
	Borysov 等 (2019) ^[30]	变分自编码器	开启深度生成人口合成方向, 经隐空间采样提升多样性
	Garrido 等 (2020) ^[31]	生成对抗网络	高维稀疏组合下的复现能力优于变分自编码器
	Kim 和 Bansal (2023) ^[32]	正则化深度生成模型	恢复样本零的同时抑制结构零
	Kang 等 (2023) ^[33]	扩散模型	以去噪重构生成高异质性人口
	Jutras-Dubé 等 (2024) ^[34]	Copula 可迁移模型	解耦依赖结构与边际分布, 支持跨区域迁移
	Kukic 等 (2024) ^[35]	一步 Gibbs 采样	去除“户主”假设的单步家庭生成
	Lim 等 (2025) ^[36]	大语言模型	以贝叶斯网络引导大语言模型自回归生成, 兼顾多样性与可行性

2.1.1 基于统计推断的人口合成方法

基于统计推断的人口合成方法以重加权为核心思想, 通过调整种子样本的权重或选取样本的组合, 使合成人口在给定地理尺度上与已知的边际分布相匹配, 主要包括迭代比例拟合 (Iterative Proportional Fitting, IPF) 与组合优化两条技术路线。

就合成对象而言, 此类方法早期以个体为对象, 随着基于活动的模型对家庭决策单元的需求日益凸显, 逐步发展出家庭级与个人级属性联合匹配的改进技术。

IPF 的思想最早可追溯至 Deming 和 Stephan^[20] 对列联表的迭代比例调整。Beckman 等^[15] 首次将其应用于 TRANSIMS 系统的虚拟人口生成, 确立了“拟合—分配”两阶段的经典流程: 拟合阶段结合种子数据与边际分布估计多维列联表中各属性组合的期望频数; 分配阶段按该频数从种子数据中抽取家庭, 构成合成人口。围绕 IPF 的固有局限, 后续研究开展了大量改进。Guo 和 Bhat^[37] 改进 IPF 算法以缓解“样本零”问题, 即真实人口中存在而种子样本中恰好未被观测到的属性组合(如农村独居老人)无法被复现的现象; Ye 等^[22] 提出迭代比例更新(Iterative Proportional Updating, IPU)算法, 使合成人口的家庭级与个人级特征分布得以同时匹配边际约束; Pritchard 和 Miller^[23] 引入稀疏列表数据结构, 显著降低了高维属性合成的内存需求; Konduri 等^[25] 进一步提出增强 IPU 算法, 可在多个空间分辨率级别上同时施加控制变量; Lovelace 和 Ballas^[38] 针对 IPF 结果整数化过程中的拟合损失, 提出截断—复制—采样方法; Khachman 等^[26] 则构建了多分辨率集成框架, 实现由区域到建筑级的精细空间分配。此外, 为克服 IPF 难以处理多元变量高维联合分布的局限, 有学者将人口合成转化为熵优化问题, 如 Barthelemy 和 Toint^[24] 仅依托汇总统计信息, 以熵最大化与禁忌搜索实现了无样本的人口重构。

组合优化是另一条经典的重加权路线, 其将研究区域划分为边际分布已知且相互排斥的子区域, 进而从种子数据中选择最优的样本组合, 以最大化各子区域的适应度指标^[21]。与结果确定的 IPF 不同, 组合优化方法通常是非确定性的, 每次运行的结果不尽相同, 可靠性存在争议, 且在属性维度增多时同样面临维度灾难。国内方面, 人口合成技术已被应用于城市微观仿真研究, 如诸葛承祥^[39] 在基于自组织理论的城市交通与土地利用动态演化研究中, 以合成的微观个体作为仿真系统的输入。

总体来看, 重加权方法计算高效、边际一致性好, 在实践中应用最为广泛。然而, 此类方法本质上是对种子样本的复制与加权, 无法生成种子样本之外的属性组合, 难以刻画真实人口的异质性; 就家庭级合成而言, IPU 类改进虽实现了家庭级与个人级边际的同时匹配, 其合成结果仍局限于复制种子样本中既有的家庭结构, 无法生成样本之外的成员组合; “零单元”问题与高维联合分布拟合中的维度诅咒, 也制约了其在属性丰富的大规模合成场景中的应用^[18]。

2.1.2 基于统计学习的人口合成方法

为突破重加权方法对种子样本的强依赖, 基于统计学习的方法从概率建模的角度直接学习属性间的依赖关系, 进而以采样方式生成合成人口。Farooq 等^[27] 率

先提出基于马尔可夫链蒙特卡罗 (Markov Chain Monte Carlo, MCMC) 模拟的人口合成方法, 通过条件分布抽样有效缓解了样本零问题, 为统计学习技术在该领域的应用指明了方向; Sun 和 Erath^[28] 利用贝叶斯网络编码属性间的依赖结构, 证明其在小样本情形下对人口结构的复现优于传统 IPF, 并尝试以之直接生成家庭级人口; Saadi 等^[29] 则基于隐马尔可夫模型实现了对多源数据的灵活融合。面向家庭这一合成对象, Sun 等^[19] 构建层次混合模型, 以多层潜变量刻画夫妻、亲子等成员间的属性依赖, 是家庭内在关系显式建模的代表性工作; Kukic 等^[35] 则去除传统两步模拟中的“户主”假设, 以按年龄降序的单步 Gibbs 采样提升家庭生成的逻辑一致性与效率。然而, 此类方法通常须人为设定模型结构或依赖较强的独立性假设, 在处理高维特征空间或生成种子数据中未观测到的特征组合时面临可拓展性瓶颈^[18]。

随着深度学习技术的发展, 深度生成模型凭借对复杂数据分布的强大拟合能力, 逐渐成为人口合成领域的研究热点。Borysov 等^[30] 率先将变分自编码器 (Variational Autoencoder, VAE) 引入人口合成, 通过隐空间采样生成高维属性组合, 开启了深度生成人口合成的研究方向; Badu-Marfo 等^[40] 构建复合生成对抗网络 (Generative Adversarial Network, GAN), 联合生成表格型社会经济属性与序列型出行轨迹; Aemmer 和 MacKenzie^[41] 将生成对象由个体拓展至家庭, 联合生成家庭与个体两级属性; Garrido 等^[31] 的对比实验表明, WGAN 在高维稀疏特征组合的复现上优于 VAE; Kim 和 Bansal^[32] 在 VAE 与 GAN 中引入边界距离正则化, 在恢复样本零的同时显著抑制了结构零的生成; Kang 等^[33] 将扩散模型引入人口合成, 在人口异质性的复现上优于 VAE 类方法; Jutras-Dubé 等^[34] 借助 Copula 理论解耦属性依赖结构与边际分布, 实现了合成模型的跨区域迁移。近年来, 大语言模型也被引入该领域, 如 Borisov 等^[42] 利用预训练语言模型的语义知识直接生成表格数据, Lim 等^[36] 以贝叶斯网络引导大语言模型的自回归生成过程, 将合成人口的可行率提升至约 95%。国内方面, 唐嘉^[43] 融合深度生成模型与多源数据开展了高空间分辨率的人口合成研究, 提升了国内合成人口研究的空间粒度与属性丰富度。

尽管深度生成模型在刻画高维联合分布方面优势突出, 其在人口合成中的应用仍面临两方面突出挑战^[18,32]。其一为边际对齐问题: 深度生成模型以微观样本的似然最大化为训练目标, 并不内生地保证合成结果与宏观边际分布一致。既有研究多采用“先生成、后重加权”的两步式处理, 然而该处理会扭曲模型已学得联合分布, 破坏属性间的复杂依赖关系。其二为零单元甄别问题: 模型难以区分“样本中恰好未出现”的样本零与“现实中不可能存在”的结构零 (如高收入的婴儿), 从而在生成多样性与逻辑有效性之间顾此失彼。虽然已有研究提出定制化损失函数^[32]、与贝叶斯网络相结合^[44] 等正则化策略, 但更具普适性的处理方式仍有

待探索^[18]。当合成对象由个体转向家庭时，上述挑战被进一步放大，并叠加了家庭级合成特有的困难：家庭-个人层级间存在“一对多”映射，同一家庭级属性组合可对应成员数量与成员构成各异的多种个体级属性组合^[19]；既有深度生成模型多以定长向量表征单个个体，并将个体视为独立同分布的样本，难以容纳成员数可变的家庭结构，夫妻、亲子等成员关系也未被作为显式对象建模；同时，合成人口须在市、区、交通小区等多个地理尺度上同时与宏观边际吻合，且须避免生成逻辑矛盾的家庭属性组合。总体而言，面向城市级 MaaS 推广策略仿真所需的全市家庭级虚拟人口，尚缺乏属性联合分布真实、家庭结构合理且多尺度边际一致的系统性生成方法。

2.2 活动计划生成研究

活动计划以活动链的形式记录居民一日之内于何时出行、前往何处、出于何种目的以及采用何种方式^[45,46]，是 ABM 的核心输入，也是本文 MaaS 推广策略仿真中智能体既有出行模式的直接来源。基于活动的模型以“出行是活动的派生性需求而非本源性需求”为基本假设^[47]，通常涵盖长期选择（居住地、工作地与车辆拥有等）、中期选择（交通卡订阅与停车许可等）与短期选择（全天活动安排、出行链生成与出行具化等）三个层次的建模^[45]，其中全天活动计划的生成属于短期选择建模，是其区别于传统四阶段法最本质的部分。就建模方法而言，既有活动计划生成研究可分为基于效用最大化的微观经济学方法、基于优化建模的方法等机理模型与基于深度学习等的的数据驱动模型两大类，代表性研究如表 2-2 所示。值得注意的是，本文关注的家庭联合活动与成员间协调普遍存在于居民的日常出行之中，如家长接送子女上下学、家庭成员共同外出就餐与游憩，以及家庭车辆在持照成员间的分配等，深刻塑造着每位成员的活动计划形态，对此类行为的建模研究在上述两类方法之中也有提及，但仍然相对有限。下面从机理模型与数据驱动模型两个方面分别进行综述，并在各方法类别中一并考察面向家庭联合活动与成员协调的建模研究。

表 2-2 代表性活动计划生成方法研究汇总

Table 2-2 Summary of representative studies on activity chain generation methods.

类别	代表研究	方法	主要特点
微观经济学方法			
	Bowman 和 Ben-Akiva (2001) ^[48]	日活动计划系统	先确定全天活动模式，再进行方式与目的地选择的嵌套选择体系
	Bradley 和 Vovsha (2005) ^[49]	家庭联合日活动模式模型	联合建模全体家庭成员的日活动模式，以交互项刻画联合参与的附加效用
	Miller 等 (2005) ^[50]	基于出行链的微观仿真	将小汽车乘客方式视为驾驶员与乘客的联合决策，按家庭效用最大化分配车辆
	Bhat (2008) ^[51]	多重离散-连续极值模型	刻画时间预算在多种活动间的同时配置
优化建模方法			
	Fu 和 Lam (2018) ^[52]	网络均衡模型	多模式网络中双人联合活动调度的均衡建模
	Khan 和 Habib (2023) ^[53]	微观仿真系统	耦合活动生成、活动调度与共享出行选择
	Pougala 等 (2023) ^[54]	OASIS 框架	以混合整数优化同时处理全部活动调度维度
	Rezvanly 等 (2023) ^[55]	OASIS 家庭扩展	显式刻画车辆分配、接送、联合参与等家庭内交互
深度学习方法			
	Borysov 等 (2019) ^[30]	变分自编码器	学习智能体属性的高维联合分布
	Badu-Marfo 等 (2022) ^[40]	复合生成对抗网络	联合生成社会经济属性与出行序列
	Kim 和 Bansal (2023) ^[32]	正则化生成模型	恢复稀有可行组合并抑制不可行组合
	Liao 等 (2024) ^[46]	Transformer 生成器	以社会人口属性为条件生成活动-地点链，支持跨区域迁移
	Lee 等 (2025) ^[56]	协同生成对抗网络	融合居民出行调查与智能卡数据生成时空异质的活动计划

2.2.1 机理模型

机理模型以明确的行为机理假设为基础刻画活动计划的形成过程：其将居民的活动安排视为特定决策机制作用下的结果，通过效用最大化、约束满足等显式数学结构表达活动参与、目的地、方式与时间等多维选择的产生机理，模型参数具有清晰的行为学含义^[45,47]。相较于将每次出行视为孤立事件、以交通小区为基本分析单元的传统四阶段法，机理模型以个体完整的日程安排为基本分析单元，能够刻画活动之间的关联性以及个体间社会交互对出行决策的影响^[45,57]，近年来在大规模应用中持续受到学术界与业界的关注^[17,58]。按决策机制的表达方式，机理模型主要包括两条技术路线：微观经济学方法以随机效用最大化理论为基础，借助多项 Logit、嵌套 Logit 与多重离散-连续极值等离散选择模型族，按层次结构组织活动模式、目的地、方式与时间等各选择环节；优化建模方法则将全天活动调度表述为带显式约束的数学规划问题，以优化求解的方式生成活动计划。

在微观经济学方法方面，Bowman 和 Ben-Akiva^[48] 提出日活动计划系统，在方式与目的地选择之前先行确定由主要活动、主要出行链与次要出行链构成的全天活动模式，形成层次嵌套的离散选择体系；Bradley 和 Vovsha^[49] 对全体家庭成员的日活动模式类型进行联合建模，以交互项刻画成员联合参与活动的附加效用；Miller 等^[50] 在基于出行链的微观仿真中，将小汽车乘客方式处理为驾驶员与乘客之间的联合决策，并按家庭整体效用最大化分配家庭车辆；Bhat^[51] 提出多重离散-连续极值（Multiple Discrete-Continuous Extreme Value, MDCEV）模型，刻画时间预算在多种活动备选间的同时配置；Timmermans 和 Zhang^[59] 系统总结了家庭活动行为建模在群体决策、任务分工与资源分配机制方面的进展；Ghader 等^[60] 构建基于 Copula 的连续交叉嵌套 Logit 模型以刻画出行链的时刻安排；Hasnine 和 Habib^[61] 将基于出行链的方式选择作为活动型需求建模框架的核心；Jin 等^[62] 进一步将社交网络关系引入联合休闲活动的安排建模。

在优化建模方法方面，Fu 和 Lam^[52,63] 在多模式交通网络中构建活动调度的网络均衡模型，刻画双人联合活动模式的形成及其时空可达性；Pougala 等^[54] 提出 OASIS 框架，以基于效用的混合整数优化同时处理活动参与、时序、时长与方式等全部选择维度；Rezvani 等^[55] 进一步将 OASIS 框架拓展至家庭内部交互，统一刻画车辆分配、家务分工、接送、联合参与与顺路搭载等协调行为，是对家庭协调处理的较为全面的一项研究；Toaza 和 Esztergár-Kiss^[64] 将活动链优化表述为带时间窗的旅行商问题并以遗传算法与分支定界求解；Khan 和 Habib^[53] 则在活动型需求建模框架内耦合活动生成、活动调度与共享出行选择的微观仿真。在应用层面，上述模型已支撑 MATSim 等大规模多智能体仿真平台的需求生成^[65]；国内如诸葛承祥等^[66] 针对 MATSim 在大规模场景下的计算性能开展了改进研究。

总体来看,机理模型行为机理透明、解释性强,且在家庭联合活动与成员协调方面已积累了由效用交互项到显式约束的系统性处理。然而,此类方法的效用函数或约束结构依赖研究者的先验设定,可处理的选择维度有限;微观经济学方法的各选择环节多按序贯结构组织,误差沿链条传递,难以复现完整活动链的高维联合分布^[47,59];优化建模方法虽可借助显式约束同时处理多个选择维度,但推断阶段须逐家庭求解优化问题,计算代价高昂。因此,机理模型的行为刻画粒度与计算可扩展性难以兼得,难以直接支撑城市级全人口的家庭活动计划生成。

2.2.2 数据驱动模型

与机理模型相对,数据驱动模型不预设效用结构或决策规则,其核心思想是将活动计划视为可学习的结构化数据,直接从居民出行调查、智能卡等大规模真实数据中学习活动多维属性的联合分布或活动序列的生成规律,进而以端到端的方式生成活动计划。就采用方法而言,早期研究多借助传统机器学习方法开展活动模式的识别与预测^[67,68];随着深度学习技术的发展,以变分自编码器、生成对抗网络与扩散模型为代表的深度生成模型,以及以 Transformer 为代表的序列生成模型逐渐成为该方向的主流,近年来兴起的大语言模型也开始进入研究视野。

在深度生成模型方面,Borysov 等^[30]以 VAE 学习智能体属性的高维联合分布,开启了深度生成方法在出行需求建模中的应用;Badu-Marfo 等^[40]以复合 GAN 联合生成社会经济属性与出行序列;Kim 等^[69]利用条件生成对抗网络为智能卡数据提取的出行链补全定性属性;Lee 等^[56]提出协同 GAN,融合居民出行调查与智能卡两类数据生成时空异质的活动计划。在序列生成模型方面,Liao 等^[46]提出基于 Transformer 的深度活动模型,以社会人口属性为条件生成活动-地点链并实现跨区域迁移;Tan 等^[70]进一步将混合专家结构引入 Transformer 以刻画出行行为的模式差异;Hong 等^[71]则以上下文感知的多头自注意力网络建模个体的下一位置选择。近年来,大语言模型也被初步用于个体移动行为的理解与生成^[72,73],展现出利用语义知识刻画出行偏好的潜力。

与机理模型相比,数据驱动模型可端到端训练、分布拟合能力强,且在推理阶段的生成效率高,适于大规模人口的活动计划生成^[17]。然而,此类方法在面向家庭对象时仍存在明显不足。首先,既有模型几乎均以个体为基本生成单元,将个体视为相互独立的样本,家庭级活动计划生成任务本身仍近乎空白^[55]。其次,活动目的、时间、方式与目的地等多任务在各成员的活动计划中强耦合,若割裂建模则生成的活动链内部易出现逻辑失真。再次,诸如“同时驾车人数不得超过家庭车辆数”的车辆可用性硬性约束难以仅通过软损失或条件输入得到满足,生成结果在家庭层面的可行性缺乏保证。最后,目的地选择涉及大规模候选集,受活

动目的、出行阻抗与地块吸引力等多因素共同影响，是活动链生成中空间精度最难保障的环节^[56,71]。因此，如何以统一的方式表征异质家庭及其成员，在保证家庭层面可行性的前提下协调地生成全体成员的活动计划，是活动计划生成研究亟待解决的问题。

2.3 MaaS 采纳意愿研究

MaaS 通过统一的数字化平台整合公共交通、共享单车、出租车与共享汽车等多种出行服务，为用户提供涵盖行程规划、预订与支付的一站式多模式出行体验^[74]。Sochor 等^[8]按服务集成深度将 MaaS 划分为信息集成、预订与支付集成、服务捆绑集成以及社会目标集成等层级；参照该划分，单次出行场景下的多模式服务选择与套餐订阅分别对应集成的不同等级^[75]。自瑞典 UbiGo 与澳大利亚悉尼试点以来，全球范围内已开展了多轮 MaaS 试验^[2,7,76]，积累了宝贵的观测数据，也表明用户对 MaaS 的采纳是由初次接触到长期订阅的渐进过程^[77]。围绕这一过程，下面从单次出行场景下的选择行为、套餐订阅行为以及多阶段采纳与跨阶段关联三个方面进行综述。

2.3.1 单次出行场景下 MaaS 选择行为研究

澳大利亚 MaaS 试点平台的相关数据表明按次付费往往是用户接触 MaaS 的第一步^[77]，单次出行场景正是用户与 MaaS 初次相遇、形成初始印象的典型情境。在此情景下，用户尚未与 MaaS 平台建立稳定的订阅关系，而是以单次出行为决策单元，在既有出行方式与 MaaS 提供的多模式组合选项之间进行权衡。围绕“谁更可能采纳 MaaS”与“用户为何以及如何单次出行情境下转向 MaaS”两个基本问题，该方向研究大体沿两条线索展开：一是潜在用户识别与画像刻画，从社会经济属性、出行习惯与态度偏好出发划分潜在用户群体；二是情境化的选择行为建模，在具体出行情境下解析 MaaS 多模式服务相对既有方式的效用权衡与转移机制。研究数据以陈述偏好（Stated Preference, SP）调查与态度量表为主，探索性因子分析、潜在类别聚类、结构方程模型以及融合潜变量的离散选择模型等方法得到广泛应用^[78]。

在潜在用户识别与画像刻画方面，Alonso-González 等^[79]基于荷兰的态度量表调查，以探索性因子分析与潜在类别聚类识别出五类人群，发现多模式出行者对 MaaS 的采纳倾向最高、单一小汽车用户最为消极，并指出高车辆拥有需求与低技术接受度是采纳的主要障碍；López-Carreiro 等^[80]面向马德里的调查表明，采纳倾向随多模式性、对新型出行方式的开放度与技术能力的提升而增强；Zijlstra 等^[81]

刻画了 MaaS 早期采纳者的人群画像；van 't Veer 等^[82] 则识别出对 MaaS 较为排斥的私家车拥有者群体；Vij 等^[83] 基于澳大利亚全国样本发现，消费者平均而言更偏好按次付费而非固定套餐。在形成机理层面，Fioreze 等^[84] 发现态度对 MaaS 使用意向的影响远大于社会经济属性；Schikofsky 等^[85] 以结构方程模型解析了采纳意向背后的动机机制；Kim 等^[86] 通过层次潜变量与潜类别结构证实心理生活方式在订阅决策中的关键作用。Kriswardhana 和 Esztergár-Kiss^[78] 的系统综述进一步将影响因素归纳为社会经济属性、出行模式、心理因素与建成环境四类。

相比于研究 MaaS 潜在用户的画像，直接针对单次出行场景下 MaaS 选择行为的研究明显偏少。Kim 等^[87] 基于首尔通勤情境的 SP 实验构建整合选择与潜变量模型，发现私家车用户与公共交通用户对 MaaS 多模式选项的偏好存在显著差异，且换乘阻抗对 MaaS 多模式服务的采纳具有负向作用；Matowicki 等^[88] 基于捷克的调查解析了态度因素对 MaaS 潜在使用的影响；Krauss 等^[89] 以混合 Logit 模型识别共享出行方式效用的驱动因素。然而，既有的人群分类研究本质上是静态刻画，难以回答用户由既有出行方式转向 MaaS 多模式服务的转移机制；MaaS 多模式选项相对既有方式的额外效用及其在不同人群间的差异，也缺乏系统的定量解析。

2.3.2 MaaS 套餐订阅行为研究

套餐订阅对应 MaaS 服务集成的更高层级，是 MaaS 区别于单一方式出行服务的核心形态，也是运营商获取稳定收入、培育用户黏性的主要途径。具体而言，运营商将公共交通、共享出行与出租车等多种服务按一定用量与期限打包为订阅套餐，用户则以周期性付费换取组合化的出行权益。作为既有研究关注最多、成果最丰富的方向，围绕“设计什么样的套餐”“谁愿意订阅、愿意支付多少”以及“不同人群的偏好有何差异”三个基本问题，既有研究大体沿套餐设计、订阅意愿与支付意愿、偏好异质性三条线索展开，数据来源也由早期的陈述选择实验逐步拓展至真实试点的揭示偏好（Revealed Preference, RP）观测，混合 Logit 与潜在类别模型等离散选择方法在其中得到广泛应用^[77,90]。

在套餐设计层面，Matyas 和 Kamargianni^[91] 设计了刻画套餐购买决策的陈述偏好实验，在方式额度、方式专属权益、额度可转移性与专属优惠等属性之外设置固定套餐与自选菜单的对照，以测度用户对灵活性的支付意愿，为套餐设计研究提供了实验范式；Reck 等^[90] 系统归纳了 MaaS 套餐设计的基础维度，用以厘清既有实验结论差异的来源；Caiati 等^[92] 以序贯组合选择实验与混合 Logit 模型刻画用户对套餐构成与定价机制的异质偏好；Guidon 等^[93] 探讨了出行服务捆绑对不同人群的价值创造；Esztergár-Kiss 和 Kerényi^[94] 则指出城市间前提条件的差异会显

著影响套餐的适配构成；Krauss 等^[95] 基于德国 83 个城市的陈述偏好实验进一步证实，本地公共交通与共享出行的供给水平是套餐被接纳的重要前提，既有共享出行使用经历正向、而小汽车使用负向地影响套餐采纳。随着悉尼等真实试点的开展，套餐设计亦由假想实验走向落地验证，Ho 等^[14] 即以共创式、数据驱动的方式设计五档套餐，采用在按次付费熟悉期后逐月引入的渐进策略，考察各档套餐吸引用户脱离按次付费的成效及其对私家车减排目标的意义。

在订阅意愿与支付意愿层面，Ho 等^[96] 较早通过陈述选择实验探讨了用户由传统出行服务转向 MaaS 订阅套餐的可能性；在此基础上，Ho 等^[11] 基于悉尼的陈述选择调查发现约半数受访者愿意采纳 MaaS，并量化了各服务组件的支付意愿；其后续研究在泰恩赛德开展了跨城市的复制比较^[97]；Liljamo 等^[98] 将芬兰受访者的支付意愿与其当前出行成本相关联；Tsouros 等^[99] 刻画了潜在用户画像及其支付意愿；Polydoropoulou 等^[100] 基于大曼彻斯特的菜单式陈述偏好数据构建混合选择模型，估计了支付意愿的分布，并发现多模式倾向越强的个体愿意为套餐支付越高的费用；Mulley 等^[101] 则面向社区交通这一特殊服务群体，以陈述选择实验估计了用户对 MaaS 套餐的支付意愿，发现其支付意愿明显低于运营商的服务提供成本，凸显了套餐定价在成本覆盖上的现实约束。值得注意的是，套餐订阅意愿与私家车拥有之间存在替代关系：Bahamonde-Birke 等^[102] 以混合选择框架联合刻画荷兰居民的 MaaS 采纳意愿、套餐选择及其与私家车拥有的权衡，发现用户对套餐内各服务的支付意愿普遍低于其单独购买时的价格，且个体间差异显著；Cisterna 等^[103] 则以基于智能体的仿真刻画订阅费对采纳的影响，揭示套餐费用与购车养车成本之间的权衡，并指出补贴套餐或提高私家车拥有成本可在抑制私家车拥有的同时增加运营商收入。

围绕偏好异质性，Matyas 和 Kamargianni^[104] 以潜在类别模型识别出套餐回避者等差异化群体；Matyas^[105] 发现相当比例的订阅者愿意尝试套餐中此前未使用过的方式，表明套餐可作为出行管理工具；Wang 等^[106] 分析了个性化套餐的异质选择及其对出行的影响；Chen 等^[107] 将潜类别选择模型应用于游客群体。在偏好的刻画机理上，Liu 等^[108] 将前景理论等风险选择框架引入套餐与方式选择建模，发现出行计划的不确定性会明显削弱用户的订阅意愿，且用户对出行时间与费用的估值呈现风险规避与敏感性递减的非线性特征；Chen 和 Chen^[109] 则基于高雄 MeNGo 真实平台既有用户的调查，论证平台与出行服务的感知价值经满意度传导至持续使用意向，且方式可达性收益较价格折扣更能驱动用户黏性。近期研究进一步向特定人群与态度机制拓展，包括跨模式性与环保意识的混合选择建模^[110]、大学社区的订阅行为^[111,112]、基于满意度的异质性分群^[113] 以及代际差异^[114]。除问卷研究外，真实试点提供了珍贵的 RP 证据：基于悉尼试点，Ho 等^[77] 以混合 Logit

模型刻画参与者在按次付费与逐步引入的多档套餐间的真实选择, Hensher 等^[76]联合建模套餐选择与私家车使用, 其后续研究量化了 MaaS 对出行行为及共享方式收入的影响^[115], Ali 等^[116]则以纵向双重差分设计评估了行为改变。总体而言, 该方向已就套餐设计与偏好异质性的的重要性形成共识, 但对低渗透率下用户从初次接触到愿意订阅的转化路径关注不足。

2.3.3 MaaS 多阶段采纳行为研究

与前两小节聚焦单一决策场景不同, 多阶段采纳研究将 MaaS 采纳理解为由初次接触、试用体验到套餐订阅乃至持续使用的渐进演化过程, 重点关注两类问题: 一是各阶段决策之间如何相互关联, 即早期接触形成的体验与印象以何种机制影响后续的订阅决策; 二是用户行为状态如何随推广进程在阶段间动态转移。多个真实试点的追踪观测为这一视角提供了经验基础: UbiGo 试点的追踪研究表明, 试用体验会促使参与者重新审视既有出行习惯并向更可持续的模式转变^[7,117]; 悉尼试点中, 按次付费被设置为参与者加入试验的默认起点, 参与者在体验的基础上才逐步转向各类套餐^[76,77]。这些证据共同表明, MaaS 采纳呈现由“初次接触”到“套餐订阅”的多阶段特征。近年来, 多阶段视角开始受到重视: Liu 等^[118]基于台湾的 SP 调查构建混合 Logit 模型, 考察套餐订阅对方式选择的影响, 揭示了订阅决策与出行选择间的联动; Yu 等^[119]基于大规模激励实验发现, 处于不同行为状态的用户在激励撤除后表现出显著差异的留存与流失模式, 提示行为状态的动态转移是理解采纳可持续性的关键; Ali 等^[116]的纵向评估同样表明用户行为随试点推进而演化。

然而, 从建模方法看, 既有研究以静态离散选择模型为主, 潜变量与潜类别结构虽可刻画阶段内的偏好异质性, 但难以表达行为状态在阶段间的动态转移。隐马尔可夫模型等潜在状态方法已被用于刻画出行行为的动态演化^[119,120]。但在 MaaS 采纳情境下, 初始行为状态的形成、单次出行选择、跨阶段状态转移与套餐订阅选择等多阶段的行为偏好和决策机制尚未在统一的框架内展开研究。

2.4 MaaS 运营与推广策略研究

随着 MaaS 概念验证项目和小规模试点在全球范围内接连受挫, MaaS 运营与推广策略研究逐渐成为学术界与业界关注的焦点, 如何协调多主体利益、形成可持续商业模式并扩大稳定用户基础, 已成为决定 MaaS 能否实现规模化发展的关键问题。MaaS 生态系统的运行由平台运营商、公共交通与共享出行等交通服务提供商、政府管理部门及出行者共同参与, 其落地与可持续运营并非单纯的出行产

品销售问题。一方面,平台需要确定自身在多主体体系中的组织角色,并通过套餐设计、价格制定、服务采购和收益分配维持系统运行;另一方面,作为仍处于市场培育阶段的新型出行服务, **MaaS** 还需要借助广告宣传、价格优惠、绿色奖励、服务推荐和体验改善等手段扩大用户规模并增强使用意愿。前者主要解决服务如何供给以及各参与主体如何形成可持续价值,属于 **MaaS** 运营策略;后者主要考察不同推广工具对用户采纳、持续使用及出行行为的影响,属于 **MaaS** 推广策略。两类策略相互关联,但所面向的决策对象与研究问题并不相同。下面分别从运营策略和推广策略两个方面进行综述。

2.4.1 MaaS 运营策略研究

MaaS 运营策略以多种出行服务能够持续、稳定地通过同一平台提供为基本目标。与第2.3.2节从用户选择角度讨论套餐偏好不同,本节关注平台及交通服务提供商的供给侧决策。相关研究主要围绕三个相互衔接的层面展开:首先是运营主体与商业架构,即由公共部门、私人平台或交通服务提供商中的哪一方承担整合者角色;其次是产品与资源配置,即平台如何设计套餐和价格、采购不同方式的服务容量并将其分配给用户;最后是价值创造与分配,即平台收入、服务成本、运营商收益、用户福利与公共利益如何在多主体间协调。

在运营主体与商业架构方面, **Polydoropoulou** 等^[121] 基于布达佩斯、大曼彻斯特和卢森堡的访谈与研讨资料,构建了 **MaaS** 原型商业模式,指出公共交通管理部门、交通服务提供商与区域政府是 **MaaS** 生态中的关键主体,监管制度、接口开放程度以及主体间信任会直接影响服务整合。**Berg** 等^[122] 进一步将 **MaaS** 概括为整合者、平台和中介三类典型运营模式,并从价格、企业利润、消费者剩余与社会福利等方面比较其市场结果,发现不同运营架构会改变平台与交通服务提供商的定价关系,因而产生明显不同的用户价格和福利水平。**Vij** 和 **Dühr**^[123] 从既有交通运营商的视角分析 **MaaS** 的商业可行性,指出互补型服务的整合能够扩大客源并提高资产利用率,而替代型服务的接入也可能损害既有运营商收益。若完全依赖市场自发协调,服务整合可能呈现碎片化特征,政府仍需在平台建设、准入和监管中发挥作用。

在运营收益可持续性方面, **Kraus** 等^[124] 将订阅收入、交通服务采购折扣、广告与数据收入,以及支付、保险、客户支持和平台建设成本统一核算,比较了公共与私人主体主导下的 **MaaS** 能够产生的经济价值。研究发现,扩大用户规模并不必然改善盈利能力,较高折扣虽然能够增加用户,却可能因服务采购与平台运营成本同步增长而导致成本提高,因此需要通过公共补贴、增值服务和新的收益来源弥补基础出行服务的有限利润。**Xiao** 和 **Kang**^[125] 则进一步将套餐额度与价格、弹

性需求和车队运营成本联合建模,表明套餐定价不能脱离实际服务供给成本。同时,用户需求增加所带来的运营负担需要纳入到平台运营收益的核算中。

近年来,除 MaaS 商业模式的研究外,MaaS 平台多模式交通服务定价与运力资源配置也逐渐成为运营研究的重点。Xi 等^[126]将 MaaS 表示为涵盖出行者与交通服务提供商的双边市场,以单领导者-多跟随者博弈刻画平台价格和资源配置对市场两边参与程度的影响;其后续研究通过在线拍卖机制,根据用户支付意愿、服务时间和不便成本实时配置运力资源,并从激励相容、个体理性和预算平衡等方面检验提出的机制的有效性^[127]。Liu 和 Chow^[128]进一步将固定线路公共交通和按需出行运营商纳入多对多分配博弈,研究拥挤条件下 MaaS 平台、运营商与用户之间的匹配方法,并以平台补贴维持运营主体参与。Yao 等^[129]则构建多领导者-多跟随者博弈,同时刻画平台定价、交通服务提供商运力供给和出行者方式-路径选择之间的博弈关系,指出合理的运输服务价格可能使平台盈利、运营商收益和用户福利同步改善。总体而言,MaaS 运营策略研究已由定性识别商业模式逐步拓展至价格、运力、成本和收益的协同决策,但多数研究仍基于单期均衡或简化需求函数,对用户状态随长期运营变化以及空间异质需求如何反作用于运营策略的研究相对有限。

2.4.2 MaaS 推广策略研究

除运营策略以外,MaaS 推广策略研究关注如何通过广告宣传、价格优惠、绿色奖励、服务推荐和体验改善等手段扩大用户规模并增强使用意愿,是在当前 MaaS 渗透率较低、规模化实施困难的背景下亟需考虑的问题。从现有文献看,MaaS 推广研究涉及广告强度、价格折扣与套餐设置^[130],绿色奖励和多模式出行推荐^[131],以及服务体验改善^[132]等多种手段。相关研究对象既包括潜在采纳者和通过激励获得的新用户,也包括真实平台中的既有订阅者^[103,119,133]。相应的评价指标包括采纳率与套餐购买、持续使用与用户留存等用户侧结果,也包括平台收入、私家车与公共交通使用变化以及碳排放等运营和社会效果^[77,116,119,131]。就研究方法而言,已有研究分别采用陈述偏好调查估计用户对套餐和价格的潜在选择^[11],利用真实试点和运营数据检验实际订阅、激励留存与出行行为变化^[77,116,119],并借助多智能体仿真比较折扣、广告、订阅费和绿色激励等情景的中长期影响^[103,130,131]。沿着上述研究路径,既有文献首先考察价格、套餐和广告等推广手段对用户采纳 MaaS 的影响,随后逐步拓展至既有用户保持以及交通与环境效果评价。

围绕价格、套餐与广告等推广手段,Tang 等^[130]面向北京市构建了基于智能体的仿真模型,模拟按次付费、月度、季度和年度四类 MaaS 套餐在不同折扣与广告强度下的推广效果。结果表明,用户更倾向于选择月度套餐和按次付费方案。此

外,增加广告投放能够促进推广初期的用户采纳,但对长期采纳与扩散的提升作用较为有限。**Cisterna**等^[103]采用基于智能体的仿真模型分析用户在套餐订阅价格与拥车成本之间的权衡,发现具有高频出行和有长距离出行特征的出行者能够接受较高的订阅费用,而套餐补贴或提高拥车成本可在促进 **MaaS** 采纳的同时改善出行服务提供商收入。以上研究表明, **MaaS** 推广的效果会受到用户出行需求、套餐构成和实施时间等因素的共同影响。

随着真实运营数据逐渐积累,一些研究进一步考察推广激励结束后的使用变化以及既有用户的订阅保持。**Yu**等^[119]基于上海一万名用户的大规模社会实验发现,优惠周票能够显著吸引新用户,但激励撤除后各类用户的流失率均有所上升,且增加折扣幅度并未显著改善用户留存情况。**Chen**等^[133]利用布里斯班 **MaaS** 试点的纵向订阅记录识别出七类订阅演化模式,发现长期订阅者更偏好包含无限公共交通权益的套餐,且社会经济属性、订阅动机、居住地建成环境和实际出行频率均会影响订阅持续时间与套餐选择。**Chen**和**Tsai**^[132]则基于实际 **MaaS** 用户的使用记录分析 **MaaS** 使用便捷性与服务无缝性对其订阅的影响,发现服务体验会通过感知价值和满意度进一步作用于用户忠诚度与依附程度。以上研究表明,价格激励、套餐权益与服务体验会显著影响用户的采纳和留存行为,评价推广策略时需要区分短期参与和长期订阅两类结果。

除用户规模与留存外,部分研究进一步考察 **MaaS** 的大规模推广能否产生预期的交通与环境效果。**Ali**等^[116]利用 **MaaS** 试点的纵向数据和双重差分方法发现,相较于不使用 **MaaS** 的出行者, **MaaS** 用户的私家车使用下降、公共交通使用增加,说明持续使用 **MaaS** 能够带来可观测的方式转移。**Zhang**和**Xu**^[131]基于北京 **MaaS** 平台构建了多智能体碳排放评估模型,并分析多模式出行推荐方案与绿色奖励水平对碳排放的影响。结果表明,降低组合出行方案中的网约车比例能够减少系统碳排放,但增加碳减排激励并不一定产生更高的减排量。因此,用户采纳规模、持续使用情况与低碳出行转移效果可能存在差异,评价 **MaaS** 推广效果时需要对各类结果分别进行考察。

总体来看,既有研究已从价格折扣、套餐设置、广告投放、绿色激励和服务体验等方面分析了 **MaaS** 推广策略的作用,并分别考察了 **MaaS** 大规模应用下的用户采纳与留存、平台收入、出行方式转移和碳排放等指标。然而,多数研究仅比较某一种推广手段的不同取值,或对少量预先设定的推广情景进行评估,尚未回答营销、定价、套餐额度和服务水平等策略应当如何联合配置,缺乏针对性的面向 **MaaS** 大规模应用的推广策略制定方法。

2.5 既有研究评述

从上述文献综述可以看出,既有研究在人口合成、活动计划生成、MaaS 采纳意愿与推广策略优化等方面已取得较为丰富的成果,为本文提供了坚实的理论基础,但在支撑本文关注的城市级 MaaS 推广策略仿真优化研究上,主要存在以下不足和有待进一步研究的内容:

(1) 家庭级人口合成方法难以兼顾属性联合分布真实性、家庭结构合理性与多尺度空间分布边际一致性。既有重加权方法本质上是对种子样本的复制与加权,无法生成样本之外的属性组合。深度生成模型虽能灵活刻画高维联合分布,却多以定长向量表征单个个体并视其为独立同分布样本,难以容纳成员数可变的家庭结构,家庭-个人层级间的映射关系以及夫妻、亲子等成员关系亦未被显式建模。同时,深度学习模型先生成、后采样的两步式边际对齐会偏离已学得联合分布,制约了合成人口在多地理尺度约束下的有效性,也难以从样本中有效甄别样本零与结构零等零单元样本。

(2) 活动计划生成研究对家庭联合活动与成员间协调的刻画不足。微观经济学与优化建模方法虽可通过效用结构与显式约束刻画家庭协调,但效用形式依赖人工设定,且推断须逐家庭求解优化问题,难以扩展至城市级人口。深度学习方法虽可端到端高效生成活动计划,却大多数以个体为基本生成单元,联合出行、接送与车辆分配等家庭级耦合不在生成目标之内,活动目的、时间、方式与目的地等多属性在家庭成员间的强耦合性难以复现,车辆可用性等家庭资源硬性约束难以保证。此外,针对城市级别大规模的目的地选择的空间精度也缺乏保障。

(3) MaaS 采纳研究偏重套餐订阅的单阶段刻画,多阶段采纳机理与跨阶段关联尚不明晰。既有研究多聚焦套餐订阅意愿与潜在用户识别两个主要方向,对单次出行场景下用户由既有方式向 MaaS 多模式服务转移这一初次接触 MaaS 的环节关注不足。此外,针对初次接触形成的对 MaaS 的初始印象如何影响后续订阅决策,缺乏可量化跨阶段效应的选择模型。用户行为状态的形成及其跨阶段转移虽已有少量研究涉及,但多关注单一阶段的行为状态(如 MaaS 套餐订阅),缺乏对初次接触、试用体验与套餐订阅等多阶段行为状态的联合建模,难以刻画用户行为随推广进程的动态演化。

(4) MaaS 运营与推广策略研究缺乏多类策略的联合设计。既有运营研究主要围绕商业模式、平台定价、运力配置和主体间利益协调展开,多在单期均衡或给定需求条件下分析运营决策,较少考虑用户规模、采纳状态及空间需求随推广过程发生的变化。此外,推广策略相关研究虽然考察了广告宣传、价格优惠、套餐设置、绿色奖励和服务体验改善等多种手段,但多数研究仅分析单一推广策略,或比较少量预先设定的策略情景,尚未系统回答营销、定价、套餐额度与服务水平等

策略应当如何在不同阶段和地区联合配置。因此，如何结合用户采纳的动态演化和空间差异，制定兼顾多重目标的 MaaS 推广策略，仍有待进一步研究。

2.6 本章小结

本章从人口合成方法、活动计划生成、MaaS 采纳意愿与 MaaS 运营和推广策略四个方面，对国内外既有研究进行了归纳总结。

人口合成方法方面，梳理了基于统计推断的重加权方法与以深度生成模型为代表的统计学习方法两大类，并重点考察了家庭-个人多层级联合合成的研究进展，明确了家庭级合成在“一对多”映射、可变家庭结构表征与多尺度空间分布边界对齐方面的方法缺口，为本文第3章的研究奠定了基础。

活动计划生成方面，从微观经济学方法、优化建模方法与深度学习方法三个类别总结了活动计划生成的研究现状，并重点考察了家庭联合活动与成员协调的建模进展，指出数据驱动的家庭级协调生成尚近乎空白，为第4章的研究指明了方向。

MaaS 采纳意愿方面，按单次出行场景选择—套餐订阅—多阶段采纳与跨阶段关联的脉络梳理了既有研究，归纳了影响采纳意愿的主要因素与常用建模方法，明确了初次接触环节研究不足、跨阶段关联缺乏联合建模的现状，为第5章与第6章的行为建模提供了依据。

MaaS 运营与推广策略方面，首先从商业架构、平台定价、运力配置和利益协调等方面梳理了 MaaS 运营策略研究，随后归纳了广告宣传、价格优惠、套餐设置、绿色激励、服务推荐和体验改善等推广手段及其对用户采纳、持续使用、平台收入、出行方式转移和碳排放的影响。既有研究表明，不同运营与推广策略均会影响 MaaS 的发展效果，但对多类策略在不同阶段和地区的联合配置关注不足，构成了第7章开展 MaaS 多目标推广策略优化研究的现实依据。

最后，对既有研究存在的四方面不足进行了归纳评述，为后续各章研究的展开提供了理论支撑。

3 面向出行分析的超大城市家庭级人口合成

3.1 本章引论

本章聚焦研究内容(1):支撑大规模推广策略仿真的高保真虚拟人口合成。本文研究城市范围内的 MaaS 推广策略制定与优化,其作用对象为全市居民,策略效果的评估以多智能体仿真为手段,而对推广策略效果精准评估的前提是获得有代表性的全市居民的微观人口。本章合成的虚拟人口是第4章家庭出行计划生成的直接输入,二者进一步结合第5章与第6章的 MaaS 采纳意愿建模,共同构成第7章推广策略仿真的基础。由于人口合成阶段的偏差会沿后续研究内容依次传播,因此本章工作的质量从源头决定了仿真的可信度。下面从仿真需求与数据供给两个方面进行分析。

首先,从仿真需求上看,既有研究表明居民的个人属性、家庭特征、空间分布均会影响其 MaaS 采纳决策。在个体层面,年龄、职业、收入与受教育程度等社会经济属性决定了用户对定价、补贴等推广策略的敏感程度;在家庭层面,用户对 MaaS 的试用、订阅与套餐选择并非孤立的个体行为,家庭车辆的可用性、成员间的接送与联合出行安排、家庭收入的预算约束,共同塑造了个体对既有出行模式的依赖程度;在空间层面,居住区位决定了用户可获得的交通服务供给,进而影响 MaaS 各组成方式对其的吸引力。若以同质化的代表性个体刻画全市居民,上述差异化的策略响应便无从体现,仿真所得的推广效果评估将出现系统性偏差。因此,推广策略仿真所需的人口输入须微观到个体并覆盖到全市,并尽量保留不同属性的联合分布与空间分布。

其次,从数据供给上看,尽管现有数据中居民出行调查能够提供较为详尽的人口属性与出行信息,但其在覆盖率上仍有不足。以北京市为例,2023 年居民出行调查完整记录了受访家庭的社会经济属性、成员构成及各成员的活动出行安排,是粒度最细、信息最全的微观数据来源,然而其抽样率仅约 0.40%,若直接以调查样本作为仿真输入,规模上远不能代表全市居民,空间上亦存在大量未被覆盖的区域。与之相对,人口普查与统计年鉴等宏观数据虽然覆盖城市全域以及各行政区划,却仅能提供各属性的边际分布,不包含个体层面的属性联合信息,更无家庭内部的成员结构。换言之,居民出行调查数据或统计年鉴等单一数据源均无法直接满足本文 MaaS 推广策略高保真仿真的数据需求。

人口合成正是弥合上述需求与供给之间缺口的技术。作为基于活动的出行需求模型(Activity-Based Model, ABM)的第一步,人口合成以小规模调查样本为样

本、以宏观统计信息为约束,将样本扩展为覆盖全域的虚拟人口,在保持属性联合分布真实性的同时满足宏观边际的吻合性,从而为 ABM 内后续的活动计划生成与运行仿真提供决策主体^[18]。然而,既有人口合成研究大多以居民个体为合成单元,仅追求个体属性联合分布的还原,家庭或被简化为个体的一个属性字段,或被完全忽略。然而,此类设定存在一定缺陷:一方面,缺乏家庭结构约束的个体集合在重组成家庭后,成员属性间往往出现逻辑矛盾,如夫妻与亲子的年龄关系失真、持照人数与车辆配置失调等;另一方面,居民的出行决策在相当程度上是家庭层面协调的产物,车辆在成员间的分配、对儿童与老人的接送、联合出行的安排均以家庭为决策单元展开,以个体为单元的人口无法重现此类家庭决策行为。因此,仅以个人为合成单元得到的虚拟人口,难以作为第4章家庭出行计划生成的可信输入。

然而,若将合成单元由个体提升至家庭,对方法本身提出了更高的要求,既有方法均难以应对。基于统计推断的方法以列联表为载体,家庭级合成须同时刻画家庭属性与多个成员属性的联合分布,联合状态空间随属性维数与成员数呈指数增长,导致列联表高度稀疏,联合估计不再可行。基于深度生成模型的方法虽然缓解了高维联合分布的拟合难题,但其对高阶属性组合(多维边际)的拟合能力随组合维数增长迅速衰减,且多以定长向量表征单个个体,难以容纳成员数可变的家庭结构与成员间关系,生成过程中亦缺乏对齐多空间尺度的边际分布、甄别样本零与结构零的有效手段。

综上,本章的研究目标确定为:以小规模出行调查数据为样本,融合多源宏观统计信息,合成属性联合分布真实、家庭结构合理、多空间尺度边际吻合且规模覆盖全市的家庭级虚拟人口,并使方法对不同城市的人口分布特征具备可迁移性。剖析该问题的内在特性,实现上述目标需解决以下问题。

(1) 家庭-个人层级间的“一对多”映射。家庭级属性与成员级属性之间不存在确定的对应关系,家庭规模、收入与车辆拥有水平相同的家庭,其成员的年龄结构、职业构成与角色关系可能差异显著。生成模型若不引入额外的条件约束,下层成员属性的生成空间过大,难以收敛到与上层家庭属性协调一致的组合。同时,保障成员间关系(夫妻、亲子等)的合理性也是一大难点。

(2) 多地理尺度边际分布的同时对齐。为保障合成人口能够最大程度还原目标城市的人口分布特征,合成人口须在微观(如栅格)、中观(如行政区)、宏观(如城市)等不同地理尺度上同时逼近来自不同数据源的边际分布。各尺度约束并非彼此独立,仅满足单一尺度的对齐方式会以牺牲其他尺度的吻合度为代价。

(3) 样本零与结构零的甄别处置。受抽样规模限制,样本中未出现的属性组合包含真实存在但未被抽中的“样本零”与逻辑上不可能成立的“结构零”两类。生

成模型若简单复刻样本分布，合成人口缺乏多样性；若放任模型自由外推，则可能产出无效组合。如何在生成过程中甄别两类零值组合，并以不同方式加以处置，是保证合成人口既具多样性又符合逻辑约束的关键。

（4）生成模型对人口分布差异的适配。由于基于深度学习的生成模型高度依赖输入数据以及超参数、损失权重等模型结构数据，模型的最优参数往往随目标城市的人口分布特征而变化。若每个城市都需通过人工经验进行超参数调优，计算代价高昂且结果缺乏稳定性，制约方法的推广应用。

针对上述问题，本章提出基于分层扩散 Transformer (Hierarchical Diffusion-Transformer, HiDiT) 模型的家庭级人口合成方法，其总体框架如图 3-1 所示。针对问题（1），构建基于 HDBSCAN 的家庭画像机制，以画像标签作为条件信息压缩下层生成空间，并在分层扩散 Transformer 中融合图生成模块，显式表征家庭结构与成员关系；针对问题（2），设计基于能量引导的多地理尺度边际对齐机制，在扩散采样过程中注入来自于多源宏观统计信息多尺度引导梯度，并通过求解二次规划问题协调不同空间尺度间的梯度冲突；针对问题（3），设计基于变分自编码器与贝叶斯网络的零单元控制策略，在采样阶段识别并区分两类零单元，对结构零样本予以重生成；针对问题（4），设计两阶段超参数调优策略，先基于属性间互信息构建超参数先验分布，再以融合冲突感知的 Hyperband 算法完成高效搜索。本章章节安排如下：3.2 节至 3.6 节依次阐述家庭画像机制、分层扩散 Transformer 模型、多地理尺度边际对齐机制、零单元控制策略与超参数调优策略；3.7 节以北京市为算例验证方法的有效性；最后总结本章工作。




图 3-1 面向出行分析的超大城市家庭级人口合成方法总体框架

Figure 3-1 Overall framework of the household-level population synthesis method for travel analysis in megacities.

3.2 基于层次密度聚类的家庭画像生成

本章引论所述的“一对多”映射在生成建模领域亦被称为不适定逆问题 (Ill-posed inverse problem)^[134]。处理此类问题的有效途径之一是引入额外的条件信息约束生成过程^[135]。受此启发,本节构建家庭画像机制,综合家庭级与成员级两类属性将样本家庭划分为若干群组,并将家庭画像标签作为条件信息输入后续的分层生成过程,从而压缩下层成员属性的生成空间。

家庭画像的划分通过基于密度的聚类实现,具体采用层次密度聚类算法 (Hierarchical Density-Based Spatial Clustering of Applications with Noise, HDBSCAN)^[136]。相比 K-means 等传统聚类方法, HDBSCAN 具有三方面优势。一是无需预先指定簇数,避免了主观设定对划分结果的影响;二是借助簇层级树可识别密度不一、形状任意的簇;三是依托密度层级能够更准确地甄别噪声样本。家庭画像生成的实施分为两步,首先构建并筛选用于刻画家庭的画像特征,然后执行聚类并对噪声样本进行处理,下面分别阐述。

3.2.1 家庭特征构建

画像特征从原始家庭级属性、成员级属性聚合统计与家庭复合指标三个方面构建。其中,原始家庭级属性来源于调查数据,体现家庭的基本社会经济特征;成

员级属性聚合统计通过对家庭内成员属性进行统计计算，反映家庭成员构成的特征；家庭复合指标则参照既有研究选取反映家庭复杂特征的指标，综合刻画家庭的结构复杂性与角色多样性。

在原始家庭级属性方面，记 $\mathbf{X}^{\text{hh}} \in \mathbb{R}^{N \times d_1}$ 为家庭级属性矩阵，其中 N 为样本家庭数， d_1 为家庭级属性维数。家庭级属性包括家庭规模、就业人数、车辆保有量（机动车、自行车、电动自行车、摩托车与老年代步车）、是否有在校学生与家庭年收入。其中，是否有在校学生与家庭年收入为分类变量，其余均为数值变量。

在成员级属性聚合统计方面，记 $\mathbf{X}^{\text{agg}} \in \mathbb{R}^{N \times d_2}$ 为由家庭内各成员属性聚合得到的统计特征矩阵。参与聚合的成员级属性为年龄、性别、驾照持有情况、受教育程度、与户主关系及职业。对于其中的高维分类变量，即受教育程度、与户主关系与职业，先做 one-hot 编码，再按家庭计算各类别的成员占比，得到家庭级的类别比例矩阵；考虑到此类比例矩阵维数较高且存在冗余，进一步采用主成分分析（Principal Component Analysis, PCA）降维，主成分个数按累计方差贡献率首次超过预设阈值 θ （如 95%）自适应确定，由此得到降维后的受教育程度特征 $\mathbf{X}^{\text{edu}} \in \mathbb{R}^{N \times d_e}$ 、关系特征 $\mathbf{X}^{\text{rel}} \in \mathbb{R}^{N \times d_r}$ 与职业特征 $\mathbf{X}^{\text{occ}} \in \mathbb{R}^{N \times d_o}$ 。

对于数值型的成员级属性，则按家庭计算统计量。记 $\mathbf{X}^{\text{ind}} \in \mathbb{R}^{N \times d_{\text{ind}}}$ 为相应的统计特征矩阵，对成员年龄集合为 $\mathbf{a}_i = \{a_{i1}, a_{i2}, \dots, a_{im_i}\}$ 的家庭 i （ m_i 为其成员数），计算：

$$\mathbf{X}_i^{\text{ind}} = [\mu(\mathbf{a}_i), \sigma(\mathbf{a}_i), \min(\mathbf{a}_i), \max(\mathbf{a}_i), \bar{g}_i, \bar{l}_i, n_i^{\text{child}}, \rho_i^{\text{child}}, n_i^{\text{elder}}, \rho_i^{\text{elder}}, n_i^{\text{work}}, \rho_i^{\text{work}}] \quad (3-1)$$

式中， $\mu(\cdot)$ 、 $\sigma(\cdot)$ 、 $\min(\cdot)$ 与 $\max(\cdot)$ 分别为均值、标准差、最小值与最大值算子； $\bar{g}_i$ 与 $\bar{l}_i$ 分别为家庭 i 的性别比例与驾照持有率； n_i^{child} 、 n_i^{elder} 与 n_i^{work} 分别为儿童（年龄 < 18 岁）、老年（年龄 ≥ 60 岁）与家庭内就业（ $18 \leq \text{年龄} < 60$ 岁）成员数； ρ_i^{child} 、 ρ_i^{elder} 与 ρ_i^{work} 为对应的成员占比。

将上述各部分横向拼接，得到成员级属性聚合统计特征矩阵：

$$\mathbf{X}^{\text{agg}} = [\mathbf{X}^{\text{edu}} \parallel \mathbf{X}^{\text{rel}} \parallel \mathbf{X}^{\text{occ}} \parallel \mathbf{X}^{\text{ind}}] \in \mathbb{R}^{N \times d_2} \quad (3-2)$$

式中， $\parallel$ 表示矩阵的横向拼接； $d_2 = d_e + d_r + d_o + d_{\text{ind}}$ 为聚合统计特征的总维数。

在家庭复合指标方面，记 $\mathbf{X}^{\text{comp}} \in \mathbb{R}^{N \times d_3}$ 为复合特征矩阵。参照既有家庭画像研究^[137-140]，选取人均就业比例、人均机动车保有量、人均自行车保有量、抚养比与年龄差异指数五项反映家庭复杂特征的指标，对家庭 i 计算：

$$\mathbf{X}_i^{\text{comp}} = \left[\frac{n_i^{\text{work}}}{m_i}, \frac{n_i^{\text{veh}}}{m_i}, \frac{n_i^{\text{bike}}}{m_i}, \frac{n_i^{\text{child}} + n_i^{\text{elder}}}{n_i^{\text{work}} + \delta}, \frac{\sigma(\mathbf{a}_i)}{\mu(\mathbf{a}_i) + \delta} \right] \quad (3-3)$$

式中, n_i^{veh} 与 n_i^{bike} 分别为家庭 i 的机动车数与自行车数 (含电动自行车); m_i 为家庭 i 的成员数, δ 为防止除零的小正常数。

最终的家庭画像特征矩阵由三类特征拼接而成:

$$\mathbf{X} = [\mathbf{X}^{\text{hh}} \parallel \mathbf{X}^{\text{agg}} \parallel \mathbf{X}^{\text{comp}}] \in \mathbb{R}^{N \times D} \quad (3-4)$$

式中, $D = d_1 + d_2 + d_3$ 为特征总维数。

在特征筛选方面, 聚类前依次执行三步处理。首先采用方差阈值法剔除方差接近于零的特征, 此类特征在样本间几乎不变, 对聚类无贡献。然后计算特征间的 Pearson 相关系数矩阵, 剔除高度相关的冗余特征, 避免相关特征在距离度量中被重复计入。最后, 对保留特征做 z-score 标准化, 使各特征在聚类的距离计算中贡献均衡。

3.2.2 家庭画像聚类生成

基于筛选后的特征矩阵, HDBSCAN 依据互达距离构建簇的层级结构。对样本 $\mathbf{x}_i$, 定义其核心距离 $d_{\text{core}}(\mathbf{x}_i)$ 为该样本到其第 k 近邻的距离, 其中 k 为最小邻域样本数; 在此基础上, 任意两样本 $\mathbf{x}_i$ 与 $\mathbf{x}_j$ 之间的互达距离定义为:

$$d_{\text{mreach}}(\mathbf{x}_i, \mathbf{x}_j) = \max \{d_{\text{core}}(\mathbf{x}_i), d_{\text{core}}(\mathbf{x}_j), d(\mathbf{x}_i, \mathbf{x}_j)\} \quad (3-5)$$

式中, $d(\mathbf{x}_i, \mathbf{x}_j)$ 为两样本间的欧氏距离。互达距离将低密度区域的样本间距离适度放大, 使簇层级的构建对密度差异更加稳健。算法在互达距离图上构建最小生成树并凝聚为簇层级树, 依据簇的稳定性自层级树中提取最终的簇划分, 密度过低、无法归入任何稳定簇的样本则被标记为噪声点。算法的完整细节可参阅相关文献^[136]。

聚类中需确定两个超参数: 最小簇规模 m_{clst} , 决定可被视作一个簇的最小样本数; 簇选择阈值 ϵ , 影响自层级树提取簇时的粒度。本节以轮廓系数为评价指标, 通过网格搜索确定二者的最优组合。对样本 $\mathbf{x}_i$, 其轮廓系数定义为:

$$s_i = \frac{b_i - a_i}{\max \{a_i, b_i\}} \quad (3-6)$$

式中, a_i 为样本 $\mathbf{x}_i$ 到同簇其余样本的平均距离; b_i 为其到最近异簇样本的平均距离。全体样本轮廓系数的均值越大, 表明簇内越紧致、簇间越分离, 对应的超参数组合越优。

HDBSCAN 将部分低密度样本判为噪声点, 而后续的条件生成要求每个家庭均要有画像标签, 因此需对噪声点进行类别指派。本节采用加权 K 近邻 (K-Nearest Neighbors, KNN) 方法, 对每个噪声样本 $\mathbf{x}_i$, 在已获得簇标签的样本中检索其 K 个

最近邻 $\mathcal{N}_K(\mathbf{x}_i)$ ，按距离倒数加权确定其归属：

$$c_i = \arg \max_{c \in \mathcal{C}} \sum_{j \in \mathcal{N}_K(\mathbf{x}_i)} \frac{\mathbb{I}[c_j = c]}{d(\mathbf{x}_i, \mathbf{x}_j) + \delta} \quad (3-7)$$

式中, $\mathcal{C}$ 为簇标签集合; c_j 为近邻样本 j 的簇标签; $\mathbb{I}[\cdot]$ 为指示函数。距离越近的近邻权重越大。上述各超参数 (含近邻数 K) 均通过基于轮廓系数的网格搜索确定。

经特征构建、聚类与噪声归并, 每个样本家庭均被赋予唯一的画像标签 $c_i \in \{1, 2, \dots, C\}$, 其中 C 为画像类别总数。画像标签将作为条件信息输入3.3节的分层扩散 Transformer 模型, 约束成员级属性的条件生成过程。

3.3 分层扩散 Transformer 模型

在家庭画像机制提供条件信息的基础上, 本节构建分层扩散 Transformer 模型, 用于从加噪的家庭级属性与个人级属性中逐步还原真实的家庭属性与结构。本节首先定义模型的输入数据结构与总体结构, 然后给出分层扩散过程的数学定义, 进而依次阐述家庭级扩散 Transformer、家庭结构表征与个人级扩散 Transformer 三个核心模块, 最后给出损失函数与模型训练方式。

3.3.1 模型总体结构

考虑到数据的层级特性, 模型须有效刻画家庭级与个人级属性间的依赖关系。为此, 首先定义模型的输入数据结构。记 $\mathbf{h}_i \in \mathbb{R}^{d_h}$ 为家庭 i 的家庭级属性向量, $\mathbf{P}_i = [\mathbf{p}_{i1}, \mathbf{p}_{i2}, \dots, \mathbf{p}_{iM}]^\top \in \mathbb{R}^{M \times d_p}$ 为其个人级属性矩阵, 其中 M 为成员数上限, d_p 为个人级属性维度。由于各家庭成员数不等, 本节采用定长表征, 即 M 依据样本中的最大家庭规模设定, 成员数不足 M 的家庭以零向量填充个人级属性矩阵, 并引入成员存在标记指示各成员是否真实存在, 非真实存在的成员标记值为零。就本文数据而言 (详见3.7.1节), 家庭级包含 8 种数值变量与 1 种类别变量, one-hot 编码后 $d_h = 10$; 个人级包含年龄数值变量与性别、驾照持有情况、与户主关系、受教育程度、职业 5 项类别变量, one-hot 编码后 $d_p = 50$, 成员数上限 $M = 8$ 。为便于生成模型训练, 所有数值属性均做 z-score 标准化。

基于输入数据, 为刻画家庭结构, 进一步构建家庭结构图。记 $\mathcal{G}_i = (\mathcal{V}_i, \mathcal{E}_i, \mathbf{A}_i)$ 为家庭 i 的结构图, 其中节点集 $\mathcal{V}_i$ 表示家庭成员, 边集 $\mathcal{E}_i$ 表示成员间的两两关系, $\mathbf{A}_i \in \{0, 1\}^{M \times M}$ 为邻接矩阵。在节点类型方面, 按性别与年龄组的组合将成员划分为 6 类 (节点类型集 $\mathcal{T}_v$ 的规模 $|\mathcal{T}_v| = 6$), 即年龄组分为儿童 (年龄 < 18 岁)、成人 ($18 \leq$ 年龄 < 60 岁) 与老人 (年龄 ≥ 60 岁), 性别分为男与女, 基本覆盖调查

数据中的全部成员类型。节点特征 $\mathbf{f}_{ij} \in \{0, 1\}^{|\mathcal{T}_v|}$ 为第 j 名成员节点类型的 one-hot 编码。在边类型方面, 定义配偶、亲子、祖孙、兄弟姐妹与其他亲属 5 类家庭关系 (边类型集 $\mathcal{T}_e$ 的规模 $|\mathcal{T}_e| = 5$), 边特征 $\mathbf{e}_{ijk} \in \{0, 1\}^{|\mathcal{T}_e|}$ 为成员 j 与成员 k 间关系类型的 one-hot 编码。邻接矩阵在实际存在的成员间构造全连接。成员数不足 M 的家庭, 其非真实存在成员对应的节点特征、邻接矩阵与边特征均以零填充。

基于上述定义, 分层扩散 Transformer 模型的目标是: 在画像标签 c_i 的条件下, 还原家庭级属性 $\mathbf{h}_i$ 、个人级属性 $\mathbf{P}_i$ 与家庭结构图 $\mathcal{G}_i$ 的联合分布。围绕该目标, 模型主体由四个模块构成: (1) 家庭级扩散 Transformer, 在画像条件下生成家庭级属性; (2) 图变分自编码器 (Graph Variational Autoencoder, GraphVAE) 解码器, 由生成的家庭属性预测家庭结构图; (3) 异质图 Transformer (Heterogeneous Graph Transformer, HGT), 从预测的结构图中提取成员结构特征; (4) 个人级扩散 Transformer, 在家庭属性、画像信息与结构特征的共同条件下生成个人级属性。模型总体结构如图 3-2 所示。




图 3-2 分层扩散 Transformer 模型总体结构

Figure 3-2 Overall architecture of the Hierarchical Diffusion-Transformer model.

3.3.2 分层扩散过程

在阐述分层扩散 Transformer 模型各模块之前, 先给出扩散模型扩散过程的定义。本模型以去噪扩散概率模型 (Denoising Diffusion Probabilistic Model, DDPM)^[141]

为基础，其建模思想是构造前向加噪-反向去噪的双向过程。前向过程将数据逐步破坏为纯噪声，反向过程学习逆转这一破坏，从而能够由噪声生成服从数据分布的新样本。记 $\mathbf{x}_0$ 为一个原始数据样本，表示未加噪的原始状态。在本章中， $\mathbf{x}$ 统一指代待生成的属性数据，即家庭级属性向量 $\mathbf{h}$ 或个人级属性矩阵 $\mathbf{P}$ ，两个层级共享同一扩散过程定义。前向扩散过程按预设的方差序列 $\{\beta_t\}_{t=1}^T$ 在 T 个时间步内逐步注入高斯噪声：

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I}) \quad (3-8)$$

式中， $\mathbf{x}_t$ 为经 t 步加噪后的样本； $q(\cdot | \cdot)$ 表示前向过程的条件转移分布； $\beta_t \in (0, 1)$ 为第 t 步注入噪声的方差，通常设置为随 t 递增的序列，使噪声注入由弱到强； $\mathcal{N}(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma})$ 表示均值为 $\boldsymbol{\mu}$ 、协方差矩阵为 $\boldsymbol{\Sigma}$ 的高斯分布； $\mathbf{I}$ 为单位矩阵。

令 $\alpha_t = 1 - \beta_t$ ， $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ ，则任意时间步的加噪样本可由 $\mathbf{x}_0$ 直接采样得到：

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I}) \quad (3-9)$$

式中， α_t 为第 t 步的信号保留系数； $\bar{\alpha}_t$ 为其自第 1 步至第 t 步的累积乘积，刻画第 t 步样本中原始信号的留存比例，随 t 增大而趋近于 0，故 $\mathbf{x}_T$ 趋近于标准高斯噪声， T 为扩散过程的总步数。式 (3-9) 经重参数化可写为 $\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}$ ，其中 $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 为标准高斯噪声，该形式避免了逐步采样，可一步构造任意时间步的训练样本。

值得注意的是，若对家庭级属性与个人级属性独立加噪，家庭属性与个人属性在扩散过程中的层级关联将被噪声切断。为在扩散过程中保留层级间依赖，本节为家庭属性与个人属性构造相关噪声。记 $\boldsymbol{\epsilon}^h$ 与 $\boldsymbol{\epsilon}^p$ 分别为家庭级与个人级的独立标准高斯噪声，个人级实际注入的噪声构造为：

$$\tilde{\boldsymbol{\epsilon}}^p = \rho \cdot \text{expand}(\boldsymbol{\epsilon}^h) + \sqrt{1 - \rho^2} \cdot \boldsymbol{\epsilon}^p \quad (3-10)$$

式中， $\rho \in [0, 1]$ 为控制层级依赖强度的相关系数； $\text{expand}(\cdot)$ 将家庭级噪声广播至个人级维度。该相关噪声设计使同一家庭的成员在扩散过程中共享共性的潜在成分，同时保留成员各自的随机变异。

3.3.3 家庭级扩散 Transformer 模块

家庭级扩散 Transformer 以加噪的家庭属性 $\mathbf{h}_t^h$ 为输入，在画像标签 c 与画像特征中心 $\mathbf{z}_c$ （画像 c 内样本画像特征的质心）的条件下预测原始家庭属性，以保证生成的家庭属性符合所属画像群组的特征。首先，将加噪家庭属性线性投影至隐藏维度：

$$\mathbf{h}^{(0)} = \text{Linear}(\mathbf{h}_t^h) \in \mathbb{R}^{1 \times d} \quad (3-11)$$

式中, d 为隐藏维度, $\text{Linear}(\cdot)$ 为线性变换层。

随后, 将噪声时间步 t 、画像标签 c 与画像特征中心 $\mathbf{z}_c$ 分别嵌入并融合, 构成作用于家庭属性生成的条件向量 $\mathbf{c}^h$:

$$\mathbf{c}^h = \text{TimeEmbed}(t) + \text{LayerNorm}(\text{LabelEmbed}(c) + \text{ProfileProj}(\mathbf{z}_c)) \quad (3-12)$$

式中, $\text{TimeEmbed}(\cdot)$ 为正弦位置编码接多层感知机的时间嵌入模块; $\text{LabelEmbed}(\cdot)$ 为可学习的标签嵌入表; $\text{ProfileProj}(\cdot)$ 为将画像特征中心线性投影至隐藏维度的投影层; LayerNorm 层归一化用于稳定条件向量的数值尺度。

在模块主体方面, 本节采用扩散 Transformer (Diffusion Transformer, DiT) 架构^[142], 由 L 个堆叠的 DiT 块构成, 每个 DiT 块以自注意力机制与多层感知机捕捉属性间的长程依赖与复杂模式, 并通过零初始化的自适应层归一化 (adaptive Layer Normalization, adaLN-Zero) 机制注入条件信息。各 DiT 块执行:

$$\begin{aligned} \mathbf{h}^{(\ell)} &= \mathbf{h}^{(\ell-1)} + g_1^{(\ell)} \cdot \text{Attention} \left(\text{modulate} \left(\text{LN}(\mathbf{h}^{(\ell-1)}), \beta_1^{(\ell)}, \gamma_1^{(\ell)} \right) \right) \\ \mathbf{h}^{(\ell)} &= \mathbf{h}^{(\ell)} + g_2^{(\ell)} \cdot \text{MLP} \left(\text{modulate} \left(\text{LN}(\mathbf{h}^{(\ell)}), \beta_2^{(\ell)}, \gamma_2^{(\ell)} \right) \right) \end{aligned} \quad (3-13)$$

式中, $\ell = 1, 2, \dots, L$ 为 DiT 块的层数; $\text{Attention}(\cdot)$ 与 $\text{MLP}(\cdot)$ 分别为自注意力模块与多层感知机模块; $\text{modulate}(\mathbf{x}, \beta, \gamma) = \gamma \odot \mathbf{x} + \beta$ 为调制运算, $\odot$ 表示逐元素相乘; 平移向量、缩放向量与门控权重 $(\beta_1^{(\ell)}, \gamma_1^{(\ell)}, g_1^{(\ell)}, \beta_2^{(\ell)}, \gamma_2^{(\ell)}, g_2^{(\ell)})$ 均由条件向量 $\mathbf{c}^h$ 经线性层预测得到; $\text{LN}(\cdot)$ 为层归一化。借助堆叠的 DiT 块, 模块在画像信息的引导下有效刻画家庭属性间的复杂关联。

经最后一个 DiT 块后, 先对输出表征进行自适应层归一化运算, 再经带层归一化与 GELU 激活的两层多层感知机, 得到去噪后的家庭属性预测 $\hat{\mathbf{h}}_0$ 。

3.3.4 基于图处理模块的家庭结构表征

本文提出的方法与既有方法主要区别在于可还原家庭结构, 因此, 在获得家庭属性预测 $\hat{\mathbf{h}}_0$ 后, 本小节先以 GraphVAE 解码器由家庭属性预测家庭结构图, 再以异质图 Transformer 从家庭结构图中提取各成员的结构特征。

在结构图预测方面, 采用 GraphVAE 解码器^[143] 对预测的家庭属性解码。解码器 GraphDecoder 由带 BatchNorm 与 ReLU 激活的四层多层感知机构成, 逐层细化潜在表征并输出软化的图结构:

$$(\tilde{\mathbf{V}}, \tilde{\mathbf{E}}, \tilde{\mathbf{A}}) = \text{GraphDecoder}(\hat{\mathbf{h}}_0) \quad (3-14)$$

式中, $\tilde{\mathbf{V}} \in \mathbb{R}^{M \times |\mathcal{T}_v|}$ 为预测的节点类型概率分布; $\tilde{\mathbf{E}} \in \mathbb{R}^{M \times M \times |\mathcal{T}_e|}$ 为预测的边类型概率分布; $\tilde{\mathbf{A}} \in \mathbb{R}^{M \times M}$ 为预测的邻接矩阵。为在保持离散结构语义的同时支持端到端训

练，对节点类型和边类型预测施加 Gumbel-Softmax 松弛^[144]：

$$\tilde{\mathbf{V}} = \text{GumbelSoftmax}(\tilde{\mathbf{V}}; \kappa), \quad \tilde{\mathbf{E}} = \text{GumbelSoftmax}(\tilde{\mathbf{E}}; \kappa) \quad (3-15)$$

式中， κ 为控制松弛平滑程度的温度参数。对邻接矩阵则施加 Sigmoid 激活，使其取值落于 (0,1) 区间：

$$\tilde{\mathbf{A}} = \text{Sigmoid}(\tilde{\mathbf{A}}) \quad (3-16)$$

在结构特征提取方面，考虑到家庭结构图具有多样的成员类型与关系类型，属于标准的异构图，因此采用异质图 Transformer (Heterogeneous Graph Transformer, HGT)^[145] 处理预测的结构图。HGT 由特征投影层与多层基于注意力的消息传递模块构成，消息传递在聚合邻居信息时显式区分节点与边的类型。特征投影层将节点类型概率分布投影为初始节点特征：

$$\mathbf{U}^{(0)} = \mathbf{W}^{\text{proj}} \tilde{\mathbf{V}} \in \mathbb{R}^{M \times |\mathcal{T}_v|} \quad (3-17)$$

式中， $\mathbf{W}^{\text{proj}}$ 为可学习的投影矩阵； $\mathbf{U}^{(0)}$ 为初始节点特征矩阵。

每个 HGT 层执行带类型特定变换的异质消息传递，其计算流程可概括为四步：先按节点类型做特定投影，再按关系类型变换键与值，继而以预测的图结构为掩码加权聚合消息，最后按节点类型做输出变换。下面依次阐述。

在节点类型特定投影方面，为每种节点类型定义独立的查询、键与值投影，以捕捉户主、配偶、子女等不同家庭角色的独有特征：

$$\mathbf{Q}^{(\tau)} = \mathbf{U}^{(0)} \mathbf{W}_Q^{(\tau)} + \mathbf{b}_Q^{(\tau)}, \quad \mathbf{K}^{(\tau)} = \mathbf{U}^{(0)} \mathbf{W}_K^{(\tau)} + \mathbf{b}_K^{(\tau)}, \quad \mathbf{V}^{(\tau)} = \mathbf{U}^{(0)} \mathbf{W}_V^{(\tau)} + \mathbf{b}_V^{(\tau)} \quad (3-18)$$

式中， $\tau \in \mathcal{T}_v$ 为节点类型索引； $\mathbf{Q}^{(\tau)}$ 、 $\mathbf{K}^{(\tau)}$ 与 $\mathbf{V}^{(\tau)} \in \mathbb{R}^{M \times d}$ 分别为假定全部节点属于类型 τ 时的查询、键与值表征矩阵； $\mathbf{W}_Q^{(\tau)}$ 、 $\mathbf{W}_K^{(\tau)}$ 、 $\mathbf{W}_V^{(\tau)} \in \mathbb{R}^{d \times d}$ 与 $\mathbf{b}_Q^{(\tau)}$ 、 $\mathbf{b}_K^{(\tau)}$ 、 $\mathbf{b}_V^{(\tau)} \in \mathbb{R}^d$ 为类型 τ 专属的可学习投影矩阵与偏置。随后，将各表征沿特征维等分为 H 个注意力头，记第 h 头的子表征为 $\mathbf{Q}^{(\tau,h)}$ 、 $\mathbf{K}^{(\tau,h)}$ 、 $\mathbf{V}^{(\tau,h)} \in \mathbb{R}^{M \times d_k}$ ，其中 H 为注意力头数， $d_k = d/H$ 为每头的特征维度。

在关系类型特定变换方面，按关系类型对键与值表征进行变换，以刻画不同关系类型对消息传递的差异化影响。对每种关系类型 $r \in \mathcal{T}_e$ 与注意力头 h ：

$$\tilde{\mathbf{K}}^{(\tau,r,h)} = \mathbf{K}^{(\tau,h)} \mathbf{W}_{\text{ATT}}^{(r,h)}, \quad \tilde{\mathbf{V}}^{(\tau,r,h)} = \mathbf{V}^{(\tau,h)} \mathbf{W}_{\text{MSG}}^{(r,h)} \quad (3-19)$$

式中， $\tilde{\mathbf{K}}^{(\tau,r,h)}$ 与 $\tilde{\mathbf{V}}^{(\tau,r,h)} \in \mathbb{R}^{M \times d_k}$ 分别为类型 τ 节点的键与值经关系 r 变换后的表征； $\mathbf{W}_{\text{ATT}}^{(r,h)}$ 、 $\mathbf{W}_{\text{MSG}}^{(r,h)} \in \mathbb{R}^{d_k \times d_k}$ 分别为关系 r 在头 h 上专属的可学习注意力变换矩阵与消息变换矩阵。在此基础上，对类型为 τ_t 的目标节点 i ，类型为 τ_s 的源节点 j 经关系 r 在头 h 上传递的注意力得分为：

$$\alpha_{ij}^{(\tau_s, \tau_t, r, h)} = \frac{\mathbf{Q}_i^{(\tau_t, h)} \cdot \left(\tilde{\mathbf{K}}_j^{(\tau_s, r, h)} \right)^\top}{\sqrt{d_k}} \cdot \mu^{(r, h)} \quad (3-20)$$

式中, $\mathbf{Q}_i^{(\tau_i, h)}$ 为矩阵 $\mathbf{Q}^{(\tau_i, h)}$ 的第 i 行, 即目标节点 i 的查询向量; $\tilde{\mathbf{K}}_j^{(\tau_s, r, h)}$ 为矩阵 $\tilde{\mathbf{K}}^{(\tau_s, r, h)}$ 的第 j 行, 即源节点 j 经关系 r 变换后的键向量; 查询由目标节点生成、键由源节点生成, 以刻画关系的方向性; $(\cdot)^\top$ 表示转置, 分母 $\sqrt{d_k}$ 为防止内积随维度增大而过大的缩放项; $\mu^{(r, h)}$ 为关系 r 在头 h 上的可学习缩放因子, 用于调节不同关系类型的整体重要性。

在消息聚合环节, 注意到上述注意力得分是在“节点属于某类型、边属于某关系”的假定下计算的, 而预测图中节点类型、边类型与边的存在性均为预测概率, 因此构造组合掩码以加权各假定情形:

$$m_{ij}^{(r, \tau_s, \tau_t)} = \tilde{v}_{j, \tau_s} \cdot \tilde{v}_{i, \tau_t} \cdot \tilde{\epsilon}_{ij, r} \cdot \tilde{A}_{ij} \quad (3-21)$$

式中, $\tilde{v}_{j, \tau_s}$ 与 $\tilde{v}_{i, \tau_t}$ 分别为源节点 j 属于类型 τ_s 、目标节点 i 属于类型 τ_t 的预测概率; $\tilde{\epsilon}_{ij, r}$ 为边 (j, i) 属于关系 r 的预测概率; $\tilde{A}_{ij}$ 为该边存在的预测概率; $m_{ij}^{(r, \tau_s, \tau_t)}$ 即类型-关系组合 (τ_s, τ_t, r) 下消息路径 $j \rightarrow i$ 成立的联合置信权重, 当图结构退化为硬指派时其取值为 0 或 1, 组合掩码随之退化为常规的硬掩码。

以组合掩码加权, 将注意力得分与消息在全部类型-关系组合上累加, 得到源节点 j 对目标节点 i 在头 h 上的聚合注意力与聚合消息:

$$\bar{\alpha}_{ij}^{(h)} = \sum_{r \in \mathcal{T}_e} \sum_{\tau_s, \tau_t \in \mathcal{T}_v} m_{ij}^{(r, \tau_s, \tau_t)} \cdot \alpha_{ij}^{(\tau_s, \tau_t, r, h)} \quad (3-22)$$

$$\bar{\mathbf{M}}_{ij}^{(h)} = \sum_{r \in \mathcal{T}_e} \sum_{\tau_s, \tau_t \in \mathcal{T}_v} m_{ij}^{(r, \tau_s, \tau_t)} \cdot \alpha_{ij}^{(\tau_s, \tau_t, r, h)} \cdot \tilde{\mathbf{V}}_j^{(\tau_s, r, h)} \quad (3-23)$$

式中, $\bar{\alpha}_{ij}^{(h)}$ 为消息路径 $j \rightarrow i$ 在头 h 上的聚合注意力得分; $\tilde{\mathbf{V}}_j^{(\tau_s, r, h)}$ 为矩阵 $\tilde{\mathbf{V}}^{(\tau_s, r, h)}$ 的第 j 行, 即源节点 j 的变换值向量; $\bar{\mathbf{M}}_{ij}^{(h)} \in \mathbb{R}^{d_k}$ 为节点 j 向节点 i 传递的注意力加权消息。为衡量各源节点对目标节点的相对影响, 将聚合注意力在源节点维度上归一化, 并据此聚合得到目标节点的消息表征:

$$\hat{\alpha}_{ij}^{(h)} = \frac{\bar{\alpha}_{ij}^{(h)}}{\sum_k \bar{\alpha}_{ik}^{(h)} + \delta}, \quad \mathbf{m}_i^{(h)} = \sum_j \hat{\alpha}_{ij}^{(h)} \cdot \bar{\mathbf{M}}_{ij}^{(h)} \quad (3-24)$$

式中, $\hat{\alpha}_{ij}^{(h)}$ 为归一化后的注意力权重, 分母中 k 遍历全部源节点; δ 为保证数值稳定的小正常数; $\mathbf{m}_i^{(h)} \in \mathbb{R}^{d_k}$ 为目标节点 i 在头 h 上自全部源节点聚合的消息。

在类型特定输出方面, 记 $\mathbf{m}^{(h)} = [\mathbf{m}_1^{(h)}, \dots, \mathbf{m}_M^{(h)}]^\top \in \mathbb{R}^{M \times d_k}$ 为头 h 上全部节点的消息矩阵, 拼接多头输出后施加类型特定的输出变换, 并辅以可学习的残差连接与层归一化:

$$\mathbf{O}^{(\tau)} = \text{Dropout} \left(\text{GELU} \left(\text{Concat}(\mathbf{m}^{(1)}, \dots, \mathbf{m}^{(H)}) \mathbf{W}_o^{(\tau)} + \mathbf{b}_o^{(\tau)} \right) \right) \quad (3-25)$$

$$\mathbf{U}^{(\tau)} = \text{LayerNorm}(\text{Sigmoid}(\lambda_\tau) \cdot \mathbf{O}^{(\tau)} + (1 - \text{Sigmoid}(\lambda_\tau)) \cdot \mathbf{U}^{(\tau)}) \quad (3-26)$$

式中, $\text{Concat}(\cdot)$ 表示将 H 个头的消息矩阵沿特征维拼接, 拼接后维度恢复为 $\mathbb{R}^{M \times d}$; $\text{GELU}(\cdot)$ 为激活函数; $\text{Dropout}(\cdot)$ 为随机失活操作; $\mathbf{O}^{(\tau)} \in \mathbb{R}^{M \times d}$ 为类型 τ 分支的输出变换结果; $\mathbf{W}_O^{(\tau)}$ 与 $\mathbf{b}_O^{(\tau)}$ 为该类型的输出投影矩阵与偏置, 将聚合消息映射回该类型节点的特征空间; λ_τ 为类型 τ 的可学习跳连权重, 经 Sigmoid 压缩至 $(0, 1)$ 区间后实现消息支路与残差支路的自适应加权; $\mathbf{U}^{(\tau)}$ 为残差支路输入, 取初始投影特征 $\mathbf{U}^{(0)}$ 在类型 τ 分支上的对应部分; $\mathbf{U}'^{(\tau)} \in \mathbb{R}^{M \times d}$ 为类型 τ 分支更新后的节点特征。

各类型的输出分支并行计算后, 节点 i 的最终表征按其软类型分布加权合成:

$$\mathbf{u}'_i = \sum_{\tau \in \mathcal{J}_v} \tilde{v}_{i,\tau} \cdot \mathbf{U}'^{(\tau)}_i \quad (3-27)$$

式中, $\tilde{v}_{i,\tau}$ 为节点 i 属于类型 τ 的预测概率; $\mathbf{U}'^{(\tau)}_i$ 为矩阵 $\mathbf{U}'^{(\tau)}$ 的第 i 行, 即类型 τ 分支下节点 i 的更新特征; $\mathbf{u}'_i \in \mathbb{R}^d$ 为节点 i 融合全部类型分支后的最终表征。

3.3.5 个人级扩散 Transformer 模块

作为最后一个模块, 在生成的家庭属性、画像信息与 HGT 提取的成员结构特征的共同条件下, 个人级扩散 Transformer 生成全部家庭成员的个人属性。

首先, 对加噪的个人级属性做隐藏维度投影。记 $\mathbf{P}_t \in \mathbb{R}^{M \times d_p}$ 为加噪的个人级属性矩阵, $\mathcal{M} \subseteq \{1, \dots, M\}$ 为成员掩码, 即成员是否存在的标记的集合。对真实存在的有效成员逐一投影:

$$\mathbf{p}_j^{(0)} = \text{Linear}(\mathbf{P}_{t,j}) \in \mathbb{R}^d, \quad \forall j \in \{1, \dots, M\} \quad (3-28)$$

式中, $\mathbf{P}_{t,j}$ 为矩阵 $\mathbf{P}_t$ 的第 j 行, 即成员 j 的加噪属性向量; $\text{Linear}(\cdot)$ 为线性投影层; $\mathbf{p}_j^{(0)}$ 为成员 j 的初始隐藏表征。将各成员表征按行堆叠, 记 $\mathbf{p}^{(0)} = [\mathbf{p}_1^{(0)}, \dots, \mathbf{p}_M^{(0)}]^\top \in \mathbb{R}^{M \times d}$ 为初始成员表征矩阵, 后续 DiT 块在该矩阵上逐层更新。

为整合各类条件信息, 构造分别服务于交叉注意力机制与自适应层归一化机制的两个条件向量。前者融合 HGT 提取的图结构特征、家庭级模块输出的家庭属性预测与时间步嵌入。其中, 图结构特征由 HGT 末层节点表征展平后投影得到, 以承载家庭内部关系与成员构成信息:

$$\boldsymbol{\psi} = \text{Linear}(\text{Flatten}(\mathbf{U}^{(L_g)})) \in \mathbb{R}^d \quad (3-29)$$

式中, L_g 为 HGT 的层数; $\mathbf{U}^{(L_g)} = [\mathbf{u}'_1, \dots, \mathbf{u}'_M]^\top \in \mathbb{R}^{M \times d}$ 为经 L_g 层消息传递后由各节点最终表征堆叠而成的末层节点表征矩阵; $\text{Flatten}(\cdot)$ 将矩阵按行展平为 Md 维向量; $\boldsymbol{\psi}$ 为图结构特征向量。交叉注意力条件向量构造为:

$$\mathbf{c}^{\text{cross}} = \text{LayerNorm}(\boldsymbol{\psi} + \text{FamilyProj}(\hat{\mathbf{h}}_0) + \text{TimeEmbed}(t)) \in \mathbb{R}^d \quad (3-30)$$

式中, $\hat{\mathbf{h}}_0$ 为3.3.3小节家庭级模块输出的去噪家庭属性预测; $\text{FamilyProj}(\cdot)$ 为将家庭属性线性投影至隐藏维度的投影层; $\text{TimeEmbed}(\cdot)$ 为与式 (3-12)相同的时间嵌入模块。

自适应层归一化条件向量则与家庭级模块一致, 由画像标签 c 、画像特征中心 $\mathbf{z}_c$ 与时间步 t 构成:

$$\mathbf{c}^{\text{ada}} = \text{LayerNorm}(\text{LabelEmbed}(c) + \text{ProfileProj}(\mathbf{z}_c)) + \text{TimeEmbed}(t) \in \mathbb{R}^d \quad (3-31)$$

式中, $\text{LabelEmbed}(\cdot)$ 与 $\text{ProfileProj}(\cdot)$ 为与式 (3-12)相同的标签嵌入与画像中心投影模块。两个条件向量分工明确: $\mathbf{c}^{\text{ada}}$ 承载家庭画像类别信息, 经自适应层归一化作用于全体成员; $\mathbf{c}^{\text{cross}}$ 承载本家庭特有的属性与结构信息, 经交叉注意力供各成员按需读取。

基于上述条件信息, 个人级扩散 Transformer 由 L 个堆叠的、以交叉注意力增强的 adaLN-Zero 式 DiT 块构成, 在家庭属性与家庭结构信息的引导下刻画成员属性间的依赖。每个 DiT 块分两个阶段执行。第一阶段遵循标准 DiT 结构:

$$\begin{aligned} \tilde{\mathbf{p}}^{(\ell)} &= \mathbf{p}^{(\ell-1)} + g_1^{(\ell)} \cdot \text{MaskedMHA} \left(\text{modulate} \left(\text{LN}(\mathbf{p}^{(\ell-1)}), \beta_1^{(\ell)}, \gamma_1^{(\ell)} \right) \right) \\ \tilde{\mathbf{p}}^{(\ell)} &= \tilde{\mathbf{p}}^{(\ell)} + g_2^{(\ell)} \cdot \text{MLP} \left(\text{modulate} \left(\text{LN}(\tilde{\mathbf{p}}^{(\ell)}), \beta_2^{(\ell)}, \gamma_2^{(\ell)} \right) \right) \end{aligned} \quad (3-32)$$

式中, $\ell \in \{1, \dots, L\}$ 为 DiT 块索引; $\mathbf{p}^{(\ell-1)}$ 为第 $\ell-1$ 块输出的成员表征矩阵; $\tilde{\mathbf{p}}^{(\ell)}$ 为第一阶段的中间表征; $\text{MaskedMHA}(\cdot)$ 为带键端填充掩码的多头自注意力, 掩码按 $\mathcal{M}$ 屏蔽无效成员, 使注意力仅在有效成员间计算; $\text{modulate}(\cdot)$ 与 $\text{LN}(\cdot)$ 与式 (3-13)相同; 调制参数 $(\beta_1^{(\ell)}, \gamma_1^{(\ell)}, g_1^{(\ell)}, \beta_2^{(\ell)}, \gamma_2^{(\ell)}, g_2^{(\ell)})$ 由条件向量 $\mathbf{c}^{\text{ada}}$ 经带 SiLU 激活的线性层预测, 使成员特征的归一化随画像信息自适应调整。

第二阶段引入交叉注意力以吸收家庭属性与图结构条件, 并辅以前馈层。该阶段各运算对每个有效成员并行执行:

$$\begin{aligned} \mathbf{a}^{(\ell)} &= \text{CrossMHA}(\text{LN}(\tilde{\mathbf{p}}^{(\ell)}), \mathbf{c}^{\text{cross}}, \mathbf{c}^{\text{cross}}) \\ \mathbf{g}^{(\ell)} &= \text{Sigmoid}(\mathbf{W}_g [\tilde{\mathbf{p}}^{(\ell)}; \mathbf{a}^{(\ell)}]) \\ \hat{\mathbf{p}}^{(\ell)} &= \tilde{\mathbf{p}}^{(\ell)} + \mathbf{g}^{(\ell)} \odot \text{Dropout}(\mathbf{a}^{(\ell)}) \\ \mathbf{p}^{(\ell)} &= \hat{\mathbf{p}}^{(\ell)} + \text{Dropout}(\text{MLP}(\text{LN}(\hat{\mathbf{p}}^{(\ell)}))) \end{aligned} \quad (3-33)$$

式中, $\text{CrossMHA}(\cdot)$ 为多头交叉注意力, 即以成员表征为查询、以条件向量 $\mathbf{c}^{\text{cross}}$ 为键与值; $\mathbf{a}^{(\ell)}$ 为交叉注意力输出, 承载各成员自家庭条件中读取的信息; $[\cdot; \cdot]$ 表示将每个成员的两个 d 维表征沿特征维拼接为 $2d$ 维向量; $\mathbf{W}_g \in \mathbb{R}^{d \times 2d}$ 为可学习投影矩阵; $\mathbf{g}^{(\ell)}$ 为逐成员、逐维度取值于 0 与 1 之间的门控向量, 自适应控制交叉注意力的信息流入, 使模型依据成员特征的当前状态选择性吸收家庭级与结构信息; $\odot$ 表示逐元素相乘; $\hat{\mathbf{p}}^{(\ell)}$ 为门控融合后的表征; $\mathbf{p}^{(\ell)}$ 为该 DiT 块的最终输出。

经最后一个 DiT 块后, 输出表征送入与家庭级模块 DiT 相同的末端输出层, 得到全部成员的去噪个人属性预测 $\hat{\mathbf{P}}_0$ 。其中, 数值属性 (年龄) 由线性输出直接预测; 分类属性 (性别、驾照持有情况、与户主关系、受教育程度与职业) 经 softmax 激活输出类别概率分布; 成员存在标志位经 Sigmoid 激活输出存在概率。

3.3.6 损失函数与模型训练

模型的输出包括家庭属性预测 $\hat{\mathbf{h}}_0$ 、全部成员的个人属性预测 $\hat{\mathbf{P}}_0$ 与家庭结构图预测 $(\tilde{\mathbf{V}}, \tilde{\mathbf{E}}, \tilde{\mathbf{A}})$ 。为对各输出分量施加监督, 总损失构造为:

$$\mathcal{L} = \mathcal{L}_{\text{family}} + \mathcal{L}_{\text{person}} + \mathcal{L}_{\text{graph}} \quad (3-34)$$

式中, $\mathcal{L}_{\text{family}}$ 、 $\mathcal{L}_{\text{person}}$ 与 $\mathcal{L}_{\text{graph}}$ 分别为家庭级损失、个人级损失与图结构损失。

在家庭级损失方面, 按属性类型分为数值与分类两个分量:

$$\mathcal{L}_{\text{family}} = w_{\text{cont}}^h \mathcal{L}_{\text{cont}}^h + w_{\text{cat}}^h \mathcal{L}_{\text{cat}}^h \quad (3-35)$$

式中, $\mathcal{L}_{\text{cont}}^h$ 与 $\mathcal{L}_{\text{cat}}^h$ 分别为数值属性分量与分类属性分量; w_{cont}^h 与 w_{cat}^h 为对应的权重。对数值属性 (家庭规模、就业人数、各类车辆保有量等) 采用均方误差损失:

$$\mathcal{L}_{\text{cont}}^h = \sum_{k=1}^{d_{\text{cont}}} (\hat{h}_k - h_k)^2 \quad (3-36)$$

式中, d_{cont} 为数值属性个数; $\hat{h}_k$ 与 h_k 分别为家庭属性预测 $\hat{\mathbf{h}}_0$ 与真实家庭属性 $\mathbf{h}$ 中第 k 个数值属性的取值。对分类属性 (是否有在校学生) 采用焦点损失^[146] 以处理类别不平衡:

$$\mathcal{L}_{\text{cat}}^h = -\alpha_f (1 - p_y)^{\gamma_f} \log(p_y) \quad (3-37)$$

式中, y 为该分类属性的真实类别; p_y 为模型对真实类别 y 的预测概率; α_f 为类别平衡因子; γ_f 为聚焦参数, p_y 越接近 1 (样本越易分类), 损失被压低得越多, 从而使训练聚焦于难分类样本。

在个人级损失方面, 针对全部有效成员计算。先逐成员计算各属性损失, 再按家庭聚合, 从而与家庭级损失保持同一口径。个人级损失由属性损失与两项辅助损失构成:

$$\mathcal{L}_{\text{person}} = \sum_{a \in \mathcal{A}_p} w_a \mathcal{L}_a^p + w_{\text{mask}} \mathcal{L}_{\text{mask}} + w_{\text{total}} \mathcal{L}_{\text{total}} \quad (3-38)$$

式中, $\mathcal{A}_p = \{\text{年龄, 性别, 驾照, 关系, 受教育程度, 职业}\}$ 为个人属性集合; $\mathcal{L}_a^p$ 为属性 a 在全部有效成员上的损失, 其中数值属性 (年龄) 采用均方误差, 分类属性采用形如式 (3-37) 的焦点损失; $\mathcal{L}_{\text{mask}}$ 与 $\mathcal{L}_{\text{total}}$ 为掩码损失与成员总数损失; w_a 、 w_{mask} 与 w_{total} 为对应的权重。

两项辅助损失用于保证成员存在标志与家庭规模的一致性。掩码损失对各有效成员的存在标志施加二元交叉熵监督：

$$\mathcal{L}_{\text{mask}} = \frac{1}{M} \sum_{j=1}^M \text{BCE}(\hat{f}_j, f_j) \quad (3-39)$$

式中， $\hat{f}_j \in (0, 1)$ 为成员 j 的存在概率预测值； $f_j \in \{0, 1\}$ 为该成员的真实存在标志； $\text{BCE}(\cdot, \cdot)$ 为二元交叉熵损失。成员总数损失则约束存在概率之和与预测家庭规模的一致性：

$$\mathcal{L}_{\text{total}} = \left(\sum_{j \in \mathcal{M}} \hat{f}_j - \hat{n} \right)^2 \quad (3-40)$$

式中， $\hat{n}$ 为家庭级输出中的家庭规模分量经反标准化（逆 z-score 变换）得到的家庭规模预测值。

在图结构损失方面，以3.3.1小节定义的真实家庭结构图 $(\mathcal{V}, \mathcal{E}, \mathbf{A})$ 为标签，对预测结构图的三个组成部分分别监督：

$$\mathcal{L}_{\text{graph}} = w_{\text{adj}} \mathcal{L}_{\text{adj}} + w_{\text{node}} \mathcal{L}_{\text{node}} + w_{\text{edge}} \mathcal{L}_{\text{edge}} \quad (3-41)$$

式中， $\mathcal{L}_{\text{adj}}$ 为邻接矩阵损失，对预测邻接矩阵 $\tilde{\mathbf{A}}$ 以真实邻接矩阵 $\mathbf{A}$ 为标签施加二元交叉熵，监督边的存在性； $\mathcal{L}_{\text{node}}$ 与 $\mathcal{L}_{\text{edge}}$ 分别为节点类型损失与边类型损失，对预测的节点类型概率分布 $\tilde{\mathcal{V}}$ 与预测的边类型概率分布 $\tilde{\mathcal{E}}$ 以真实类型为标签施加形如式 (3-37) 的焦点损失； w_{adj} 、 w_{node} 与 w_{edge} 为三个分量的权重。

在模型训练方面，训练时对每个样本随机抽取时间步 t ，按式 (3-9) 与式 (3-10) 对家庭与个人属性施加相关噪声，模型预测原始属性与结构图，并按总损失 $\mathcal{L}$ 反向传播更新参数。值得注意的是，上述损失函数中的各分量权重共同决定了模型对不同输出分量的关注程度，其最优取值随数据分布特征而变化，是3.6节超参数调优策略的调优对象；具体训练超参数设置见3.7节。

3.4 生成数据边际分布对齐方法

训练完成的分层扩散 Transformer 模型刻画的是训练数据的联合分布，然而，合成人口还须在微观、中观、宏观等多个地理尺度上对齐已知的属性边际分布。本节将其转化为去噪采样过程中的均值调整问题，即在每个去噪步，以能量函数度量当前生成结果与来自宏观统计信息的目标边际分布的偏离程度，并以其梯度修正去噪分布的均值，使生成方向持续对齐目标边际分布。进一步，为平衡不同地理尺度对齐目标之间的矛盾，在每个去噪步求解一个优化问题以确定最优的调整方向。边际对齐机制的整体流程如图 3-3 所示，下面依次阐述反向去噪采样过程、采

样过程中用到的多地理尺度能量函数、引导梯度计算以及地理尺度间梯度冲突协调策略。




图 3-3 基于能量引导的多地理尺度边际分布对齐流程

Figure 3-3 Energy-guided marginal distribution alignment across multiple geographic scales.

3.4.1 反向采样过程

去噪采样遵循 DDPM 的标准流程^[141]，即自纯高斯噪声 $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 出发，由训练好的模型在 T 个时间步内逐步去噪，最终得到服从数据分布的生成样本。在每个时间步 t ，给定加噪输入 $\mathbf{x}_t$ ，模型先直接预测去噪后的数据：

$$\hat{\mathbf{x}}_0 = f_{\theta}(\mathbf{x}_t, t, c, \mathbf{z}_c) \quad (3-42)$$

式中， $f_{\theta}(\cdot)$ 为参数为 θ 、训练完成的分层扩散 Transformer 模型； c 与 $\mathbf{z}_c$ 为画像标签与画像特征中心； $\hat{\mathbf{x}}_0$ 为模型在第 t 步对原始数据的预测。基于 $\hat{\mathbf{x}}_0$ ，可导出反向转移分布的后验均值：

$$\mu_{\theta}(\mathbf{x}_t, t) = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t}\hat{\mathbf{x}}_0 + \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}\mathbf{x}_t \quad (3-43)$$

式中， $\mu_{\theta}(\mathbf{x}_t, t)$ 为反向转移分布 $q(\mathbf{x}_{t-1} | \mathbf{x}_t, \hat{\mathbf{x}}_0)$ 的均值； β_t 、 $\alpha_t = 1 - \beta_t$ 与 $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ 均与3.3.2小节的前向过程定义一致， $\bar{\alpha}_{t-1}$ 为截至第 $t-1$ 步的累积信号保留系数。后验均值是预测数据 $\hat{\mathbf{x}}_0$ 与当前样本 $\mathbf{x}_t$ 的加权组合，权重由方差序列决定。随后执行反向采样步：

$$\mathbf{x}_{t-1} = \mu_{\theta}(\mathbf{x}_t, t) + \sigma_t \xi, \quad \xi \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad (3-44)$$

式中, ξ 为反向采样的随机噪声项; σ_t 为后验标准差, $\sigma_t^2 = \frac{(1 - \bar{\alpha}_{t-1})\beta_t}{1 - \bar{\alpha}_t}$ 为对应的后验方差。如此自 $t = T$ 迭代至 $t = 1$, 即得最终的合成样本 $\mathbf{x}_0$ 。

针对分层人口合成, 采样过程同时对家庭级属性 $\mathbf{x}^h$ 与个人级属性 $\mathbf{x}^p$ 进行去噪。每步先由家庭级模块去噪得到家庭属性并预测家庭结构, 再以其为条件去噪个人属性。为保持训练阶段建立的层级依赖, 初始噪声 $\mathbf{x}_T^h$ 与 $\mathbf{x}_T^p$ 按式 (3-10) 的方式构造。

3.4.2 采样过程引导梯度计算

为对齐多地理尺度、多属性的目标边际, 本节引入基于能量的引导机制^[147]。以能量函数 $J(\mathbf{x}_t)$ 度量当前生成结果与目标边际分布之间的偏离程度, 并以其关于 $\mathbf{x}_t$ 的梯度修正后验均值, 将生成方向持续向目标边际分布对齐, 调整后的均值为:

$$\hat{\mu}_t = \mu_\theta(\mathbf{x}_t, t) - \eta \nabla_{\mathbf{x}_t} J(\mathbf{x}_t) \quad (3-45)$$

式中, $\hat{\mu}_t$ 为调整后的均值, 替代式 (3-44) 中的 $\mu_\theta(\mathbf{x}_t, t)$ 参与采样; $\eta > 0$ 为控制引导强度的系数; $\nabla_{\mathbf{x}_t} J(\mathbf{x}_t)$ 为能量函数关于当前样本的梯度, 经由 $\hat{\mathbf{x}}_0$ 对 $\mathbf{x}_t$ 的依赖链式求导获得。

边际分布对齐的目标是全体合成人口, 因此当前分布的估计须将当前批次与此前已生成的累积人口合并。生成过程按地理单元分批进行, 对地理尺度 g 上的某一属性类别 a , 其分布占比为:

$$\hat{q}_{g,a} = \frac{\sum_{i=1}^B \mathbb{I}[\hat{a}_i = a] + N_g^{\text{prev}} \cdot q_{g,a}^{\text{prev}}}{B + N_g^{\text{prev}}} \quad (3-46)$$

式中, B 为当前批次的样本数; $\hat{a}_i$ 为当前批次第 i 个样本由预测 $\hat{\mathbf{x}}_0$ 解码得到的该属性取值; $\mathbb{I}[\cdot]$ 为指示函数; N_g^{prev} 与 $q_{g,a}^{\text{prev}}$ 分别为尺度 g 内此前已生成人口的累计样本数与类别 a 的累计比例。

总能量函数由各地理尺度的能量分量构成:

$$J(\mathbf{x}_t) = \sum_{g=1}^G J_g \quad (3-47)$$

式中, g 为地理尺度索引; G 为地理尺度总数; J_g 为尺度 g 的能量分量。每个尺度分量又可进一步分解为家庭级与个人级两部分:

$$J_g = J_g^h + J_g^p, \quad g = 1, \dots, G \quad (3-48)$$

式中, 上标 h 与 p 分别标记家庭级与个人级属性对应的能量。尺度 g 的家庭级能量为当前分布与目标分布的加权平方误差:

$$J_g^h = \sum_{a \in \mathcal{A}_g^h} w_{g,a} \cdot (\hat{q}_{g,a} - q_{g,a}^*)^2 \quad (3-49)$$

$$w_{g,a} = w_g^{\text{base}} + \zeta \cdot |\hat{q}_{g,a} - q_{g,a}^*| \quad (3-50)$$

式中, $\mathcal{A}_g^h$ 为尺度 g 上的家庭级属性类别集合; $\hat{q}_{g,a}$ 为按式 (3-46) 估计的分布; $q_{g,a}^*$ 为尺度 g 上类别 a 的目标边际分布; $w_{g,a}$ 为类别 a 在尺度 g 上的能量权重; w_g^{base} 为尺度 g 的基础权重, 体现不同尺度约束的相对优先级; $\zeta > 0$ 为自适应调节强度, 使当前偏差越大的类别获得越高的权重, 从而将引导强度动态集中于对齐成都欠佳的分布。个人级能量 J_g^p 将式 (3-49) 中的属性类别集合替换为相应的个人级集合 $\mathcal{A}_g^p$ 后按同样方式计算。

综上, 能量函数涉及多个地理尺度、多个属性的对齐目标, 各目标对应的梯度方向未必一致, 简单求和可能引发目标间此消彼长的“跷跷板”效应。为此, 下面引入梯度冲突协调策略。

3.4.3 梯度间冲突协调方法

为消解去噪过程中不同引导目标梯度间的冲突, 本节采用冲突规避梯度下降 (Conflict-Averse Gradient descent, CAGrad) 算法^[148] 协调各目标的引导方向。考虑到家庭级与个人级属性的维度不同, 分别对两个层级分别消解冲突。

对某一层级, 记各引导目标的梯度集合为 $\{\mathbf{g}_1, \mathbf{g}_2, \dots, \mathbf{g}_K\}$, 其中 K 为该层级下引导目标的个数, 本文中引导目标按尺度划分, 故 $K = G$ 。算法首先计算平均梯度:

$$\bar{\mathbf{g}} = \frac{1}{K} \sum_{k=1}^K \mathbf{g}_k \quad (3-51)$$

式中, $\mathbf{g}_k$ 为第 k 个引导目标的单位化梯度; $\bar{\mathbf{g}}$ 为平均梯度。若全部梯度与平均梯度的内积均非负, 即 $\mathbf{g}_k^\top \bar{\mathbf{g}} \geq 0$ 对所有 k 成立, 则目标间不存在冲突, 直接以 $\bar{\mathbf{g}}$ 作为最终引导梯度; 否则, 求解如下二次规划问题以寻找冲突规避的调整权重:

$$\begin{aligned} \min_{\mathbf{w}} \quad & \left\| \bar{\mathbf{g}} + \sum_{k=1}^K w_k (\mathbf{g}_k - \bar{\mathbf{g}}) \right\|_2^2 \\ \text{s.t.} \quad & \sum_{k=1}^K w_k \leq \phi, \quad w_k \geq 0, \quad k = 1, \dots, K \end{aligned} \quad (3-52)$$

式中, $\mathbf{w} = [w_1, \dots, w_K]^\top$ 为待求的调整权重向量, w_k 越大表示融合方向越向目标 k 倾斜; $\|\cdot\|_2$ 为向量的 ℓ_2 范数; $\phi \in (0, 1]$ 为控制冲突规避强度的超参数, ϕ 越大允许融合方向偏离平均梯度的幅度越大。该问题规模仅为目标个数 K , 采用 Frank-Wolfe 算法即可高效求解。记最优解为 $\mathbf{w}^*$, 融合梯度取为:

$$\mathbf{g}^* = \bar{\mathbf{g}} + \sum_{k=1}^K w_k^* (\mathbf{g}_k - \bar{\mathbf{g}}) \quad (3-53)$$

式中, $\mathbf{g}^*$ 为冲突协调后的融合梯度, 替代式 (3-45) 中的原始梯度 $\nabla_{\mathbf{x}_i} J(\mathbf{x}_i)$ 参与均值调整。

借助上述带冲突协调的多尺度引导机制, 合成人口能够同时逼近不同地理尺度的边际约束。

3.5 样本零与结构零控制策略

针对引论中的 (3), 生成模型可能产出真实存在但未被调查抽中的“样本零”以及逻辑上不可能成立的“结构零”。前者是合成人口多样性的正规来源, 应予保留; 后者属无效组合, 理应剔除。然而二者在训练数据中均表现为零频次, 模型自身无从区分。为此, 本节设计一种事后控制策略, 以变分自编码器 (Variational Autoencoder, VAE)^[149] 构建统一的低维潜空间, 以贝叶斯网络 (Bayesian Network, BN)^[150] 刻画生成样本属于合法属性组合的可能性, 进而以 BN 对数概率与潜空间距离两种判据将生成样本划分为有效样本、样本零与结构零三类, 并对结构零予以重生成。策略包含训练与判别两个阶段, 下面依次阐述。

在训练阶段, 首先训练 VAE 以建立潜空间。VAE 的训练数据为 $\mathcal{D}_{\text{aug}} = \mathcal{D}_{\text{hts}} \cup \mathcal{D}_{\text{gen}}$, 其中 $\mathcal{D}_{\text{hts}}$ 为调查样本集, $\mathcal{D}_{\text{gen}}$ 为 HiDiT 模型的生成样本集。采用该数据集的原因在于, 潜空间须同时覆盖真实数据分布与生成样本的分布, 否则无法确定生成样本在潜空间中的位置。对任一家庭样本, 将其家庭级与个人级属性拼接为联合向量 $\mathbf{x} = [\mathbf{h}; \text{Flatten}(\mathbf{P})]$, 经 VAE 编码器将其映射为低维潜表征:

$$\boldsymbol{\omega} = \text{Enc}(\mathbf{x}) \in \mathbb{R}^{d_{\omega}} \quad (3-54)$$

式中, $\text{Flatten}(\cdot)$ 将个人级属性矩阵按行展平; $[\cdot; \cdot]$ 表示向量拼接; $\text{Enc}(\cdot)$ 为训练完成的 VAE 编码器; $\boldsymbol{\omega}$ 为该样本的潜表征; d_{ω} 为潜空间维度。

随后, 在潜空间上训练 BN 以刻画给定数据的合法概率。与 VAE 不同, BN 仅以调查样本的潜表征为训练数据, 从而习得真实人口属性的联合分布。考虑到 BN 以离散变量为对象, 先对潜表征逐维做分位数分箱, 将每一维离散化为 n_b 个箱, 记离散化后的潜向量为 $\check{\boldsymbol{\omega}}$; 再以爬山算法在赤池信息准则 (Akaike Information Criterion, AIC) 评分下学习 BN 网络结构^[28]。训练完成后, BN 给出任一离散化潜向量的对数概率:

$$\log p_{\text{BN}}(\check{\boldsymbol{\omega}}) = \sum_{j=1}^{d_{\omega}} \log p(\check{\omega}_j | \text{Pa}(\check{\omega}_j)) \quad (3-55)$$

式中, $\check{\omega}_j$ 为离散化潜向量的第 j 维分量; $\text{Pa}(\check{\omega}_j)$ 为网络结构中该分量的父节点集合; $p(\check{\omega}_j | \text{Pa}(\check{\omega}_j))$ 为习得的条件概率; $\log p_{\text{BN}}(\check{\boldsymbol{\omega}})$ 度量该潜表征与真实人口数据的相符程度, 值越高表明越相符。

为判别生成样本类别，对每个生成样本 $\tilde{\mathbf{x}}$ ，先经式 (3-54) 编码得潜表征 $\tilde{\omega}$ ，再计算两项指标。其一为 BN 对数概率 $\log p_{\text{BN}}(\tilde{\omega})$ ，按式 (3-55) 计算；其二为潜空间距离，定义为生成样本潜表征到全体调查样本潜表征的平均欧氏距离：

$$d_{\text{lat}}(\tilde{\omega}) = \frac{1}{N} \sum_{i=1}^N \|\tilde{\omega} - \omega_i\|_2 \quad (3-56)$$

式中， ω_i 为第 i 个调查样本的潜表征； N 为调查样本家庭数； $\|\cdot\|_2$ 为向量的 ℓ_2 范数。该距离等价于将生成样本视作单点分布时，其与调查样本潜表征经验分布 μ_{hts} 之间 p 阶 Wasserstein 距离的经验形式 $(\mathbb{E}_{\omega \sim \mu_{\text{hts}}} \|\tilde{\omega} - \omega\|_2^p)^{1/p}$ 在 $p = 1$ 时的取值，从分布层面度量生成样本对调查数据整体的偏离程度。

以上指标的阈值均依据调查样本自身的分布设定。对数概率阈值 ϑ_{bn} 取全体调查样本 BN 对数概率的下 10% 分位数，含义是生成样本的对数概率只要不低于 90% 调查样本，即视为符合真实人口分布。距离阈值 ϑ_d 取全体调查样本潜空间距离的上 99% 分位数，含义是超出该界的生成样本比几乎全部调查样本都更远离数据整体。基于上述阈值，生成样本可划分为三类：

$$\text{label}(\tilde{\mathbf{x}}) = \begin{cases} \text{有效样本,} & \log p_{\text{BN}}(\tilde{\omega}) \geq \vartheta_{\text{bn}} \\ \text{样本零,} & \log p_{\text{BN}}(\tilde{\omega}) < \vartheta_{\text{bn}} \text{ 且 } d_{\text{lat}}(\tilde{\omega}) \leq \vartheta_d \\ \text{结构零,} & \log p_{\text{BN}}(\tilde{\omega}) < \vartheta_{\text{bn}} \text{ 且 } d_{\text{lat}}(\tilde{\omega}) > \vartheta_d \end{cases} \quad (3-57)$$

式中， ϑ_{bn} 与 ϑ_d 分别为按上述分位数规则设定的对数概率阈值与距离阈值。该划分的直观解释为，BN 对数概率高的样本符合自调查数据习得的人口模式，因此判为有效；对数概率低但潜表征邻近整体数据的样本，视为稀有合法组合，即样本零；对数概率低且远离整体数据的样本，视为不应存在的属性组合，即结构零。

在处理方式上，有效样本与样本零均予保留，以保证合成人口的多样性，判为结构零的样本则交回 HiDiT 模型重新生成。

3.6 两阶段超参数调优策略

针对引论中的 (4)，HiDiT 模型包含多个与人口数据特征耦合的超参数，即各损失分量权重 w_{cont}^h 、 w_{cat}^h 、 w_a 、 w_{mask} 、 w_{total} 、 w_{adj} 、 w_{node} 、 w_{edge} 以及式 (3-10) 中的层级噪声相关系数 ρ 。受地理区位、经济发展水平等因素影响，不同城市的人口属性分布与依赖结构差异显著，依赖人工经验逐一试错既不经济也难以保证稳定。为此，本节设计两阶段调优策略：第一阶段利用训练数据中属性间的依赖性构建超参数的先验分布，使搜索过程能够较快地聚焦于合理的参数空间区域；第二阶段在超参数搜索算法——Hyperband 算法框架^[151]内引入冲突感知机制，对超参数空

间进行高效搜索。需要说明的是，本策略针对的是上述与数据特征耦合的超参数；网络层数、隐藏维度等架构类超参数与学习率等常规训练超参数按领域惯例设定或根据交叉验证确定，不在本策略的调优范围内。

3.6.1 超参数先验分布构建

第一阶段基于如下贪心假设：针对相互依赖性越强的属性或变量，模型需投入越多的注意力，故其对应的损失权重应取较高的初值。为度量属性间的依赖强度，本节采用互信息刻画属性间的非线性依赖性，为先验分布的构建提供量化依据。首先以归一化互信息（Normalized Mutual Information, NMI）度量任意两属性间的依赖强度，对任意一对属性 (X_a, X_b) ：

$$\text{NMI}(X_a, X_b) = \frac{2I(X_a; X_b)}{H(X_a) + H(X_b)} \quad (3-58)$$

式中， X_a 与 X_b 为视作随机变量的两个属性； $I(X_a; X_b) = \sum_{x_a} \sum_{x_b} p(x_a, x_b) \log \frac{p(x_a, x_b)}{p(x_a)p(x_b)}$ 为二者的互信息， $p(x_a, x_b)$ 为联合概率分布， $p(x_a)$ 与 $p(x_b)$ 为各自的边缘分布； $H(\cdot)$ 为香农熵。NMI 取值介于 $[0, 1]$ ，1 表示完全依赖，0 表示相互独立。对全部属性两两计算，即得属性间 NMI 矩阵。

基于 NMI 矩阵，将属性按层级划分为家庭级属性组 $\mathcal{A}_h$ 与个人级属性组 $\mathcal{A}_p$ ，并对每个属性组 $\mathcal{A}_k$ 计算组内平均互信息度量同组属性间的平均依赖强度：

$$\bar{v}_k^w = \frac{2}{|\mathcal{A}_k|(|\mathcal{A}_k| - 1)} \sum_{\substack{a, b \in \mathcal{A}_k \\ a < b}} \text{NMI}(X_a, X_b) \quad (3-59)$$

式中， k 为属性组索引， $\mathcal{K}$ 为属性组集合， $k \in \mathcal{K}$ ； $|\mathcal{A}_k|$ 为组 k 的属性个数；求和遍历组内全部无序属性对。跨组平均互信息度量组 k 属性与组外全部属性间的平均依赖强度：

$$\bar{v}_k^c = \frac{1}{|\mathcal{A}_k| \cdot |\bar{\mathcal{A}}_k|} \sum_{a \in \mathcal{A}_k} \sum_{b \in \bar{\mathcal{A}}_k} \text{NMI}(X_a, X_b) \quad (3-60)$$

式中， $\bar{\mathcal{A}}_k = \bigcup_{j \neq k} \mathcal{A}_j$ 为组 k 以外全部属性的集合。基于以上两类统计量，按超参数类别构造先验分布。

对家庭级与个人级损失权重，综合组内与跨组依赖构造重要性得分并跨组归一化，得先验均值：

$$\mu_{w_k}^{(0)} = w_0 \cdot \left(1 + \frac{\bar{v}_k^w + \bar{v}_k^c}{\sum_{j \in \mathcal{K}} (\bar{v}_j^w + \bar{v}_j^c)} \right) \quad (3-61)$$

式中， $\mu_{w_k}^{(0)}$ 为组 k 对应损失权重的先验均值； w_0 为基准权重。对刻画层级间交互的超参数（如层级噪声相关系数 ρ ），其先验均值基于跨组依赖构造：

$$\mu_{w_{\text{inter}}}^{(0)} = w_0 \cdot (1 + 2 \bar{v}_{\text{avg}}^c) \quad (3-62)$$

式中, $\bar{v}_{\text{avg}}^c = \frac{1}{|\mathcal{K}|} \sum_{k \in \mathcal{K}} \bar{v}_k^c$ 为全部属性组跨组平均互信息的均值; 跨组依赖越强, 表明层级间关联越紧密, 相应超参数的初值越高。

先验标准差则依据属性组依赖结构的复杂程度设定, 以组内 NMI 子矩阵的谱熵度量:

$$H_k^{\text{sp}} = - \sum_i \tilde{\lambda}_{k,i} \log \tilde{\lambda}_{k,i} \quad (3-63)$$

$$\sigma_{w_k}^{(0)} = \sigma_0 \cdot (1 + \chi_s \cdot \tilde{H}_k^{\text{sp}}) \quad (3-64)$$

式中, $\tilde{\lambda}_{k,i}$ 为组 k 组内 NMI 子矩阵的第 i 个归一化特征值 (各特征值除以特征值之和); H_k^{sp} 为组 k 的谱熵; $\tilde{H}_k^{\text{sp}} = H_k^{\text{sp}} / \max_j H_j^{\text{sp}}$ 为跨组归一化后的谱熵; $\sigma_{w_k}^{(0)}$ 为先验标准差; σ_0 为基准标准差; $\chi_s > 0$ 为谱熵敏感系数。谱熵越高表明组内依赖结构越复杂、权重最优值的不确定性越大, 相应先验越宽, 以保留更大的探索空间。最终, 初始超参数配置自截断高斯分布 $w_k \sim \mathcal{N}(\mu_{w_k}^{(0)}, (\sigma_{w_k}^{(0)})^2)$ 采样, 以保证权重取值非负。

3.6.2 超参数寻优算法

第二阶段以第一阶段的先验为起点, 在 Hyperband 算法^[151] 框架内进行搜索。Hyperband 将逐次减半思想与计算资源的多档分配相结合, 先以少量计算资源评估大量配置, 逐轮淘汰表现落后的配置, 并向保留下来的配置追加计算资源, 从而在固定计算预算内快速搜索有效参数配置。在该框架内, 考虑到梯度冲突暴露度高的配置, 其各目标间的平衡尚未充分显现, 应给予其更多的存活机会与探索空间, 有助于发现更优的配置。因此, 本节做两点基于冲突感知的改进。其一, 在逐轮的存活选择环节引入考虑冲突感知的最优计算预算分配 (Conflict-Aware Optimal Computing Budget Allocation, CA-OCBA) 规则, 使存活决策同时考虑验证损失与梯度冲突暴露度。其二, 设计冲突感知的分布更新机制, 依据观测到的损失分量间梯度冲突调整后续采样分布。

在梯度冲突检测方面, 训练过程中持续监测损失分量间的梯度冲突。对任意一对损失分量 $\mathcal{L}_i$ 与 $\mathcal{L}_j$, 成对冲突分数定义为:

$$\Lambda_{ij} = \max(0, -\cos\langle \nabla_{\theta} \mathcal{L}_i, \nabla_{\theta} \mathcal{L}_j \rangle) \quad (3-65)$$

式中, $\nabla_{\theta} \mathcal{L}_i$ 为损失分量 $\mathcal{L}_i$ 关于模型参数 θ 的梯度; $\cos\langle \cdot, \cdot \rangle$ 为两向量的余弦相似度; $\Lambda_{ij} > 0$ 表明两个目标将参数推向相反的方向, 取值越大冲突越剧烈。在此基

基础上，损失分量 k 的冲突暴露度定义为：

$$E_k = \sum_{j \neq k} w_j \cdot \Lambda_{kj} \quad (3-66)$$

式中， w_j 为当前配置下损失分量 j 的权重； E_k 越大，表明在当前权重方案下分量 k 受其他目标的压制越严重。

在 CA-OCBA 过程中的存活配置选择方面，借鉴最优计算预算分配（OCBA）将计算预算优先投向“最可能改变性能排序”的候选配置的思想^[152]，设计如下筛选规则。记 n_s 为本轮应保留的配置数，预留 $m_e = \max(1, \lfloor n_s/3 \rfloor)$ 个探索名额，直接保留损失最低的 $n_s - m_e$ 个配置，其余 m_e 个名额按冲突感知得分竞争。具体而言，将全部配置按验证损失升序排列后，计算第 n_s 名与第 $n_s + 1$ 名之间的边界：

$$\vartheta_b = \frac{\mathcal{L}_{(n_s)}^{\text{val}} + \mathcal{L}_{(n_s+1)}^{\text{val}}}{2} \quad (3-67)$$

式中， $\mathcal{L}_{(n_s)}^{\text{val}}$ 与 $\mathcal{L}_{(n_s+1)}^{\text{val}}$ 分别为升序排列下第 n_s 名与第 $n_s + 1$ 名配置的验证损失。对每个未被保留的配置 i ，其到边界的距离为：

$$\tilde{\Delta}_i = \frac{|\mathcal{L}_i^{\text{val}} - \vartheta_b|}{1 + \chi_c \cdot \bar{E}_i} \quad (3-68)$$

式中， $\mathcal{L}_i^{\text{val}}$ 为配置 i 的验证损失； $\bar{E}_i$ 为配置 i 在全部损失分量上的平均冲突暴露度； $\chi_c > 0$ 为冲突敏感度系数。暴露度越高，有效距离被压缩得越短，高冲突配置由此获得更大的存活机会。配置 i 的选择得分为：

$$\varsigma_i = \left(\frac{\sigma_{cs}}{\tilde{\Delta}_i} \right)^2 \quad (3-69)$$

式中， σ_{cs} 起尺度作用，不改变得分的相对排序。未被保留配置中得分最高的 m_e 个保留至下一轮。

在系数分布更新方面，每个 Hyperband 计算流程结束后，依据冲突暴露度与存活配置更新采样分布。方差侧，高冲突暴露触发膨胀以鼓励探索：

$$\sigma_k^{(\text{new})} = \sigma_k^{(\text{old})} \cdot (1 + \chi_\sigma \cdot \hat{E}_k) \quad (3-70)$$

式中， $\sigma_k^{(\text{old})}$ 与 $\sigma_k^{(\text{new})}$ 分别为超参数 w_k 采样分布更新前后的标准差； $\hat{E}_k$ 为分量 k 的归一化冲突暴露度； $\chi_\sigma > 0$ 为方差膨胀率。均值侧，向表现优良的存活配置迁移：

$$\mu_k^{(\text{new})} = (1 - \chi_\mu) \cdot \mu_k^{(\text{old})} + \chi_\mu \cdot \bar{w}_k \quad (3-71)$$

式中， $\mu_k^{(\text{old})}$ 与 $\mu_k^{(\text{new})}$ 分别为更新前后的均值； $\chi_\mu \in (0, 1)$ 为均值迁移率； $\bar{w}_k = \sum_{k'} \pi_{k'} \cdot w_{k,k'} / \sum_{k'} \pi_{k'}$ 为超参数 w_k 在存活配置上的加权均值，其中 k' 为存活配置索引， $w_{k,k'}$

为配置 k' 中超参数 w_k 的取值, 权重 $\pi_{k'} = \exp(-\mathcal{L}_{k'}^{\text{val}}/\bar{\mathcal{L}}^{\text{val}})$ 使验证损失越低的配置获得越高的权重, $\bar{\mathcal{L}}^{\text{val}}$ 为存活配置验证损失的均值。该更新规则在梯度冲突较大时放宽搜索范围, 在配置平稳收敛时收窄搜索范围。

综上, 第一阶段以数据自身的依赖结构为先验提供搜索起点, 第二阶段以冲突感知机制在预算约束下高效逼近最优配置, 二者协同使 HiDiT 模型能够自适应不同城市的人口分布特征。

3.7 算例实验

为验证本文所构建的 HiDiT 模型及其多地理尺度边际分布对齐和零单元处理机制的有效性, 本节以北京市为研究区域设计实验算例。具体而言, 本节将基于多源人口数据开展实验, 依次从实验设置与评价指标、基准模型对比、消融实验、家庭结构图生成质量、多地理尺度边际分布对齐效果以及样本零与结构零处理效果等方面, 对所提出模型进行系统评估。

3.7.1 算例数据描述

北京市人口规模大、行政区类型多样, 不同区域在家庭规模、年龄结构、受教育水平和交通工具拥有情况等方面均存在明显差异, 能够为检验模型在复杂人口结构下的生成能力提供较为充分的应用场景。本文所用基础数据包括人口样本数据、人口特征边际分布数据和人口分布数据三类。其中, 人口样本数据用于学习家庭与个人属性之间的联合分布及家庭内部成员关系; 人口特征边际分布数据用于使合成人口分布对齐不同地理尺度上的属性边际分布; 人口分布数据用于确定最小空间单元内的合成人口规模。

(1) 人口样本数据

人口样本数据采用 2023 年北京市居民出行调查数据。该调查覆盖北京市全部 16 个行政区, 记录了受访家庭及其成员的社会经济属性与成员构成等信息。经数据清洗后, 本章共使用 33169 个家庭样本和 79695 个个人样本, 抽样率约为 0.40%。

结合上述数据, 本章在家庭层级选取家庭规模、就业人数、机动车保有量、自行车保有量、电动自行车保有量、摩托车保有量、老年代步车保有量、家庭年收入和是否有在校学生共 9 项属性, 在个人层级选取年龄、性别、驾照持有情况、受教育程度、与户主关系和职业共 6 项属性。上述属性既能够反映家庭资源约束和人口构成特征, 也能够刻画个人活动参与能力、出行方式选择条件和家庭内部角色关系, 是后续合成人口生成的核心变量。

(2) 人口特征边际分布数据

为实现合成人口在不同空间层级上的宏观分布一致性，本章将人口特征边际分布约束划分为栅格、行政区和城市三个空间尺度。栅格尺度选取 $1\text{km} \times 1\text{km}$ 空间栅格，用于刻画城市内部细粒度人口属性差异。行政区尺度选取北京市 16 个行政区，用于约束不同区之间的人口结构差异。城市尺度则为以北京市全域，用于保证合成人口总体属性分布与全市统计特征一致。为获取上述三个尺度的边际分布数据，本章主要依赖两类数据源：手机应用数据和统计年鉴数据。

手机应用数据取自百度地图匿名化居民画像数据，覆盖北京市 16 个行政区，共包含 15022 个空间分辨率为 $1\text{km} \times 1\text{km}$ 的栅格。每个栅格中仅记录年龄组、性别、收入水平、职业和车辆拥有情况等属性的比例分布。需要说明的是，手机应用数据采集于 2021 年 5 月，而居民出行调查数据为 2023 年。两类数据之间存在一定时间差异，但考虑到北京市人口结构在短期内整体相对稳定，且本章重点在于验证模型在多尺度边际约束下进行家庭级人口合成的能力，因此认为该时间差异不会对实验目标产生实质性影响。

统计年鉴数据提供行政区尺度和城市尺度的人口边际分布信息。在行政区尺度，本章提取北京市 16 个行政区的户均家庭规模、年龄组占比和性别占比。在城市尺度，提取家庭规模占比、家庭户均就业人数、年龄组占比和受教育程度占比等统计信息。北京市行政区尺度边际属性统计如表 3-1 所示，城市尺度边际属性统计如表 3-2 所示。

表 3-1 北京市行政区尺度人口边际属性统计

Table 3-1 Statistics of population marginals at the administrative-district scale in Beijing.

行政区	户均家庭规模	0-14 岁占比 (%)	15-64 岁占比 (%)	65 岁及以上占比 (%)	男性占比 (%)
东城区	2.87	13.8	65.6	20.6	48.6
西城区	3.08	14.8	63.4	21.7	49.1
朝阳区	2.54	11.3	71.9	16.8	49.2
丰台区	2.39	11.2	70.5	18.3	49.7
石景山区	2.52	11.5	71.5	17.0	50.1
海淀区	3.21	11.9	72.6	15.5	49.8
门头沟区	2.05	11.3	69.5	19.1	50.0
房山区	2.12	13.3	72.9	14.8	49.8
通州区	2.06	12.5	73.8	13.7	49.3
顺义区	2.34	11.7	74.3	14.0	49.3
昌平区	2.26	11.0	78.6	10.4	49.8
大兴区	2.52	12.3	72.9	14.8	49.5
怀柔区	2.08	11.8	69.3	18.9	49.5

续下页

(续表 3-1)

行政区	户均家庭规模	0-14 岁占比 (%)	15-64 岁占比 (%)	65 岁及以上占比 (%)	男性占比 (%)
平谷区	2.31	12.9	67.1	20.0	50.2
密云区	2.13	12.4	69.8	17.7	49.5
延庆区	1.95	11.7	70.8	17.5	50.2

表 3-2 北京市城市尺度人口边际属性统计

Table 3-2 Statistics of population marginals at the city scale in Beijing.

属性	类别	数值	属性	类别	数值
家庭规模	1 人	26.8%	年龄结构	45-49 岁	6.5%
家庭规模	2 人	34.2%	年龄结构	50-54 岁	7.8%
家庭规模	3 人	22.3%	年龄结构	55-59 岁	7.1%
家庭规模	4 人	9.7%	年龄结构	60-64 岁	6.8%
家庭规模	5 人及以上	7.0%	年龄结构	65-69 岁	6.3%
户均就业人数	全体家庭	1.1	年龄结构	70-74 岁	4.2%
年龄结构	0-4 岁	3.4%	年龄结构	75-79 岁	2.2%
年龄结构	5-9 岁	4.9%	年龄结构	80-84 岁	1.5%
年龄结构	10-14 岁	3.7%	年龄结构	85 岁及以上	1.6%
年龄结构	15-19 岁	2.6%	受教育程度	小学及以下	5.3%
年龄结构	20-24 岁	4.8%	受教育程度	初中	19.3%
年龄结构	25-29 岁	7.5%	受教育程度	高中	17.2%
年龄结构	30-34 岁	10.1%	受教育程度	中专/职高	20.8%
年龄结构	35-39 岁	10.4%	受教育程度	大专	27.6%
年龄结构	40-44 岁	8.6%	受教育程度	本科及以上	8.1%

(3) 人口分布数据

人口分布数据用于确定最小空间单元（栅格）内需要生成的人口规模。本章采用美国橡树岭国家实验室发布的全球人口分布数据，其空间分辨率约为 1km × 1km。该数据能够提供北京市范围内较细粒度的人口分布，因此可作为生成真实城市规模的虚拟人口的数量依据。北京市人口分布如图 3-4所示。




图 3-4 北京市人口分布

Figure 3-4 Population distribution in Beijing.

(4) 多源数据融合与统一口径处理

由于上述三类数据在空间粒度和属性口径上并不完全一致，实验前需要进行统一的数据融合处理。在空间维度上，为保证不同数据源能够共同作用于模型生成过程，本章建立栅格-行政区-城市的层级空间隶属关系，从而形成多尺度边际对齐所需的地理层级结构。

在属性维度上，不同数据源对同一社会经济属性的取值划分存在一定差异。例如，年龄、收入和受教育程度等变量在居民出行调查数据、手机应用数据和统计年鉴数据中的分组标准并不完全相同。对此，本章以居民出行调查数据中的属性划分为基准，对其他数据源中的属性类别进行归并和映射，使各类边际约束能够与模型训练样本保持可比。

3.7.2 实验设置与评价指标

本章基于 Python 与 PyTorch 框架实现 HiDiT 模型及各类对比模型。所有实验均在配备 Intel(R) Core(TM) i9-13950HX CPU、64 GB 内存和 NVIDIA RTX 4090 GPU（24 GB 显存）的计算环境下完成。为保证模型对比的公平性，所有模型均使用相同的训练样本，且模型参数规模处于相近量级。HiDiT 模型中的超参数由3.6节所提出的两阶段超参数调优策略及十折交叉验证确定，具体取值如表 3-3所示。

表 3-3 HiDiT 模型主要超参数设置

Table 3-3 Main hyperparameter settings of the HiDiT model.

类别	超参数	取值
模型结构		
	隐层维度	320
	Transformer 层数	30
	注意力头数	16
	图结构投影维度	24
	HGT 层数	2
	HGT 注意力头数	4
扩散过程		
	加噪时间步数	200
	噪声调度起始值 β_{start}	0.0001
	噪声调度终止值 β_{end}	0.02
	噪声相关系数 ρ	0.66
训练设置		
	训练轮数	500
	批量大小	1024
	学习率	1×10^{-4}
损失权重		
	家庭级连续属性权重 w_{cont}^h	1.82
	家庭级类别属性权重 w_{cat}^h	1.82
	个人级属性权重 w_a	0.1
	成员掩码与成员总数权重 $w_{\text{mask}}, w_{\text{total}}$	0.1
	图结构权重 $w_{\text{adj}}, w_{\text{node}}, w_{\text{edge}}$	0.97

为评价合成人口与真实样本在属性联合分布上的一致性，采用人口合成研究中常用的标准化均方根误差（Standardized Root Mean Square Error, SRMSE）作为主要评价指标^[16,19,35,40]。对于给定属性组合，SRMSE 定义为：

$$\text{SRMSE} = \frac{\sqrt{\sum_{i=1}^{N_c} (n_i^{\text{synth}} - n_i^{\text{real}})^2 / N_c}}{\sum_{i=1}^{N_c} n_i^{\text{real}} / N_c} \quad (3-72)$$

式中， N_c 为该组属性下所有可能属性组合的数量； n_i^{synth} 和 n_i^{real} 分别表示合成人口和真实样本在第 i 类属性组合中的样本频数。SRMSE 越小，表明合成人口与真实样本在该属性组合下的联合分布越接近。

考虑到本文关注的是家庭级别人口合成，故评价指标从三个层面展开。家庭级属性层面，直接计算家庭规模、就业人数、车辆拥有、家庭收入等家庭属性组合

的 SRMSE。个人级属性层面，计算年龄、性别、职业、受教育程度等个人属性组合的 SRMSE。为进一步检验模型是否真正学习到家庭内部成员属性之间的协调关系，提出扩展家庭级属性层面，将个人属性聚合至家庭层级，构造是否有老年人、驾照持有成员占比、男性成员占比、本科及以上学历成员占比、就业成员占比等扩展变量，并计算其与家庭属性组合后的 SRMSE。对于上述三个层面，均分别计算 1 维至 6 维属性组合下的平均 SRMSE，以刻画模型在低维边际分布和高维联合分布上的生成质量。

3.7.3 基准模型对比分析

选取人口合成领域中具有代表性的深度生成模型作为基准模型进行对比,具体包括: WGAN 模型^[32]、VAE 模型^[30,32]、条件 WGAN (Conditional WGAN, CWGAN) 模型^[69] 和条件 VAE (Conditional VAE, CVAE) 模型^[41]。上述模型均已被应用于人口合成任务,能够学习高维人口属性的复杂联合分布。其中, WGAN 和 VAE 为非条件生成模型, CWGAN 和 CVAE 则通过引入条件信息增强生成过程的可控性。

表 3-4 展示了不同模型在家庭级、个人级和扩展家庭级三个层面下的平均 SRMSE 结果。结果表明, HiDiT 模型在全部评价层面和全部属性组合维度下均取得最小的 SRMSE, 说明其在家庭级别人口合成任务中整体优于各类基准生成模型。

表 3-4 不同模型的平均 SRMSE 对比结果

Table 3-4 Comparison of average SRMSE values across different models.

层面	模型	1 维	2 维	3 维	4 维	5 维	6 维
家庭级	WGAN	0.390	0.978	1.750	2.659	3.635	4.599
	VAE	0.851	2.252	4.207	6.710	9.709	13.070
	CWGAN	0.439	1.121	2.060	3.221	4.547	5.950
	CVAE	0.896	2.381	4.493	7.257	10.651	14.562
	HiDiT	0.045	0.104	0.171	0.242	0.315	0.389
个人级	WGAN	0.603	1.615	3.028	4.662	6.260	7.571
	VAE	0.506	1.268	2.275	3.384	4.421	5.261
	CWGAN	0.522	1.372	2.572	4.048	5.612	7.061
	CVAE	0.660	1.553	2.651	3.790	4.802	5.616
	HiDiT	0.089	0.231	0.431	0.668	0.923	1.188

续下页

(续表 3-4)

层面	模型	1 维	2 维	3 维	4 维	5 维	6 维
扩展家庭级							
	WGAN	0.393	0.886	1.510	2.260	3.086	3.912
	VAE	0.622	1.504	2.688	4.195	5.983	7.925
	CWGAN	0.371	0.884	1.590	2.491	3.542	4.665
	CVAE	0.720	1.751	3.181	5.049	7.305	9.799
	HiDiT	0.093	0.258	0.503	0.830	1.219	1.633

在家庭级属性层面，HiDiT 模型的优势最为明显。随着属性组合维度由 1 维增加至 6 维，各基准模型的 SRMSE 均快速增大，表明基准模型在高维联合分布还原方面存在明显误差累积。相比之下，HiDiT 模型即使在 6 维属性组合下 SRMSE 仍仅为 0.389，远低于表现相对较好的 WGAN 模型，表现出了良好的生成合理的家庭级属性的能力。

在个人级属性层面，HiDiT 模型同样保持最优表现。基准模型虽然能够在一定程度上学习个人属性的边际分布，但随着属性组合维度升高，其误差显著增大。例如，在 6 维属性组合下，VAE 模型的 SRMSE 为 5.261，WGAN 模型为 7.571，而 HiDiT 模型仅为 1.188。该结果表明，HiDiT 模型通过上层家庭属性、家庭画像条件和结构图信息对个人级生成过程进行引导，能够有效缩小个人属性生成空间，从而更准确地还原个体属性联合分布。

在扩展家庭级属性层面，HiDiT 模型在 6 维属性组合下 SRMSE 为 1.633，而 WGAN、VAE、CWGAN 和 CVAE 分别为 3.912、7.925、4.665 和 9.799，说明本文所提出的家庭画像机制与图处理模块能够有效捕捉家庭成员间的协同关系以及家庭内的复杂的高维依赖关系。

值得注意的是，CWGAN 和 CVAE 并未稳定优于其非条件版本，部分情形下甚至表现更差。这说明对于家庭级人口合成任务，简单加入条件变量并不必然能够改善生成质量。

3.7.4 消融实验分析

为进一步识别 HiDiT 模型中关键模块的贡献，本文设置两组消融模型进行对比：（1）移除 GraphVAE 解码器和 HGT 模块，不再显式生成和利用家庭结构图，即 HiDiT（无图处理模块）；（2）移除家庭画像标签条件，在训练和生成过程中不使用 HDBSCAN 聚类得到的家庭画像信息，即 HiDiT（无画像条件）。通过与完整 HiDiT 模型对比，可以分别检验图处理模块和家庭画像条件信息对人口合成质量

的影响。

表 3-5 展示了消融实验结果。结果表明，完整 HiDiT 模型在家庭级、个人级和扩展家庭级三个层面均取得最小 SRMSE，说明本文设计的图处理模块和画像条件模块均对提升生成质量具有重要作用。

表 3-5 HiDiT 模型不同模块的消融实验结果

Table 3-5 Results of ablation experiments on different modules of the HiDiT model.

层面	模型	1 维	2 维	3 维	4 维	5 维	6 维
家庭级							
	HiDiT（无图处理模块）	0.055	0.134	0.225	0.317	0.405	0.486
	HiDiT（无画像条件）	0.064	0.161	0.279	0.408	0.536	0.659
	HiDiT	0.045	0.104	0.171	0.242	0.315	0.389
个人级							
	HiDiT（无图处理模块）	0.667	1.676	2.896	4.158	5.352	6.465
	HiDiT（无画像条件）	0.995	2.621	4.972	7.981	11.546	15.562
	HiDiT	0.089	0.231	0.431	0.668	0.923	1.188
扩展家庭级							
	HiDiT（无图处理模块）	0.411	1.092	2.002	3.068	4.180	5.216
	HiDiT（无画像条件）	0.440	1.174	2.173	3.375	4.681	5.978
	HiDiT	0.093	0.258	0.503	0.830	1.219	1.633

移除图处理模块后，家庭级属性 SRMSE 仅出现小幅上升。例如，6 维家庭级属性组合下 SRMSE 由 0.389 增加至 0.486，说明家庭级总体属性分布主要由上层扩散模型决定，受图处理模块影响相对有限。然而，在个人级和扩展家庭级层面，误差增幅较大。6 维个人级属性组合下以及扩展家庭级属性组合下 SRMSE 分别由 1.188 和 1.633 增至增至 6.465 和 5.216，表明 GraphVAE 和 HGT 模块的作用主要体现在刻画家庭内部成员依赖关系上。若不显式建模家庭结构，模型更容易将家庭成员视作相对独立的个体，从而破坏成员年龄、性别、职业、驾照持有情况等属性之间的协调关系。

移除家庭画像条件后，模型性能在所有层面均明显下降，且个人级层面下降幅度最大。6 维个人级属性组合下 SRMSE 由 1.188 上升至 15.562，说明家庭画像

条件是解决家庭-个人层级“一对多”映射问题的重要信息来源。缺少家庭画像约束时，同一家庭级属性可能对应过多成员组合，个人级扩散过程的生成空间显著扩大，模型难以稳定生成与家庭背景相匹配的成员属性。扩展家庭级属性层面的误差也由 1.633 上升至 5.978，进一步说明家庭画像信息对于维持家庭成员组合合理性具有重要作用。

为更直观地比较不同模型变体的生成效果，图 3-5和图 3-6分别展示了家庭级属性和个人级属性的分布对比。可以看出，完整 HiDiT 模型生成结果与真实居民出行调查样本的分布最为接近。移除图处理模块后，部分个人属性与家庭成员聚合特征出现偏差。移除家庭画像条件后，多个属性的分布偏离真实样本更为明显。上述可视化结果与 SRMSE 定量评价结果相互印证，说明完整模型结构能够更好地保证家庭属性、个人属性和家庭内部结构的一致性。




图 3-5 消融实验中家庭级属性分布对比

Figure 3-5 Comparison of household-level attribute distributions in ablation experiments.




图 3-6 消融实验中个人级属性分布对比

Figure 3-6 Comparison of individual-level attribute distributions in ablation experiments.

3.7.5 家庭结构图生成质量分析

为进一步验证 GraphVAE 与 HGT 等模块对家庭内部关系的刻画能力, 本节从邻接关系预测、边类型预测和节点类型预测三个方面分析家庭结构图生成质量。具体而言, 将模型预测得到的家庭结构图与真实样本中的家庭结构图进行对比, 评价其是否能够还原家庭成员之间的连接关系和关系类型。

关于预测邻接矩阵与真实邻接矩阵之间的相似性。图 3-7 展示了节点级相似度矩阵、邻接矩阵余弦相似度分布和 Jaccard 相似度分布。其中, 节点级相似度矩阵中的每个元素 (i, j) 表示所有家庭中预测邻接值与真实邻接值之间的平均元素级相似度 $1 - |A_{ij}^{\text{pred}} - A_{ij}^{\text{true}}|$ 。从图中可以看出, 节点相似度整体较高, 说明模型能够较好地判断家庭成员之间是否存在关系。

进一步地, 本文计算每个家庭预测邻接矩阵与真实邻接矩阵之间的余弦相似度和 Jaccard 相似度。其中, 余弦相似度用于衡量邻接矩阵整体结构的一致性, 定

义为：

$$\text{Cosine} = \frac{\text{vec}(\mathbf{A}^{\text{pred}})^{\top} \text{vec}(\mathbf{A}^{\text{true}})}{|\text{vec}(\mathbf{A}^{\text{pred}})|_2 |\text{vec}(\mathbf{A}^{\text{true}})|_2} \quad (3-73)$$

Jaccard 相似度用于衡量预测边集合与真实边集合之间的重合程度，定义为：

$$\text{Jaccard} = \frac{|(i, j) : A_{ij}^{\text{pred}} > 0 \wedge A_{ij}^{\text{true}} > 0|}{|(i, j) : A_{ij}^{\text{pred}} > 0 \vee A_{ij}^{\text{true}} > 0|} \quad (3-74)$$

结果显示，预测邻接矩阵与真实邻接矩阵的余弦相似度均值为 0.839，Jaccard 相似度均值为 0.805，且多数样本集中在较高相似度区间。这说明模型不仅能够还原家庭成员数量，也能够较准确地判断成员之间的连接关系。




图 3-7 家庭结构图邻接矩阵相似度分析

Figure 3-7 Similarity of adjacency matrices for household structure graphs.

进一步分析边类型和节点类型预测准确率，如图 3-8所示。




图 3-8 家庭结构图边类型与节点类型预测准确率分布

Figure 3-8 Distributions of edge-type and node-type prediction accuracy for household structure graphs.

结果表明,边类型预测准确率均值为 0.889,说明模型能够正确识别 80% 以上的家庭成员关系类型,如配偶、亲子、祖孙和兄弟姐妹等,表明模型能够有效地还原家庭成员之间的关系结构。节点类型预测准确率均值为 0.841,表明模型能够较好地还原家庭成员构成,例如户主、配偶、子女和老人等角色组合。上述结果说明,本文提出的 GraphVAE 解码器能够有效生成家庭结构图,HGT 模块也能够进一步将家庭结构信息传递至个人属性生成过程,为高质量家庭级人口合成提供支撑。

3.7.6 多地理尺度边际分布对齐效果评估

为验证3.4节所提出的能量引导机制在多地理尺度边际分布对齐中的作用,本节分别在栅格、行政区和城市三个地理尺度上比较加入能量引导前后的合成人口边际分布误差。考虑到手机应用数据可能受用户群体结构影响,在部分人口属性上存在一定抽样偏差^[153],本文在栅格尺度上选取未同时纳入行政区和城市尺度约束的属性进行引导,以减少不同数据源之间潜在口径差异造成的冲突。具体而言,栅格尺度选择机动车拥有比例作为示例属性。行政区尺度使用户均家庭规模、0-14岁占比、15-64岁占比、65岁及以上占比和男性占比共5项边际约束。城市尺度使用家庭规模、户均就业人数、年龄结构和受教育程度等共31项边际约束。图3-9展示了栅格尺度上机动车拥有比例的边际对齐误差空间分布。




图 3-9 栅格尺度机动车拥有比例边际对齐误差空间分布

Figure 3-9 Spatial distribution of marginal alignment errors for the motor vehicle ownership share at the grid scale.

结果表明,未加入能量引导时,栅格尺度机动车拥有比例的平均绝对误差为 0.2952;加入能量引导后,平均绝对误差降低至 0.2145,误差下降幅度为 27.34%。

该结果说明，能量引导机制能够在扩散采样过程中有效利用栅格尺度边际信息，引导生成结果更接近局部空间单元的真实属性分布。

图 3-10 进一步展示了行政区尺度上不同属性的边际分布绝对误差。可以看出，在北京市 16 个行政区中，加入能量引导后大部分属性的绝对误差均明显降低。未加入引导时，模型生成结果难以完全匹配行政区尺度的宏观统计特征，尤其在户均家庭规模和年龄结构方面存在一定偏差。加入能量引导后，户均家庭规模、15-64 岁人口占比、65 岁及以上人口占比以及男性占比等属性的误差均得到较明显改善。虽然引导机制对于 0-14 岁人口占比，部分行政区改善幅度相对有限，但整体上未造成误差恶化，说明该机制能够在多项边际约束之间保持较好的平衡。




图 3-10 行政区尺度人口边际分布绝对误差对比

Figure 3-10 Comparison of absolute errors in population marginal distributions at the administrative-district scale.

图 3-11 展示了城市尺度 31 项边际属性的绝对误差对比。结果表明，加入能量引导后，几乎所有城市尺度边际属性的误差均有所下降。未加入引导时，生成数据在家庭规模分布和受教育程度分布等属性上与全市统计年鉴数据存在一定差异；加入城市尺度边际分布引导后，上述偏差得到明显修正，尤其是受教育程度相关属性的改善较为显著。




图 3-11 城市尺度人口边际分布绝对误差对比

Figure 3-11 Comparison of absolute errors in population marginal distributions at the city scale.

综合三个地理尺度的实验结果可以看出，本文提出的能量引导机制能够有效提升合成人口与目标边际分布在三个地理尺度上的一致性，同时避免过度优化某一尺度而牺牲其他尺度的边际吻合度，能够为大规模城市人口合成提供更具可控性的宏观分布对齐能力。

3.7.7 样本零与结构零处理效果评估

为验证提出的 VAE-BN 控制策略对样本零与结构零的处理效果，本节比较加入控制策略前后生成样本的分类结果，如表 3-6所示。

表 3-6 合成样本中有效样本、潜在样本零与潜在结构零分类结果

Table 3-6 Classification results for valid samples, potential sampling zeros, and potential structural zeros in the synthetic data.

方法	有效样本 (%)	潜在样本零 (%)	潜在结构零 (%)
未加入控制策略	27.57	65.57	6.86
加入 VAE-BN 控制策略	30.10	69.90	≈ 0

未加入控制策略时，有效样本占比为 27.57%，潜在样本零占比为 65.57%，但潜在结构零占比达到 6.86%，说明若完全依赖生成模型外推，虽然能够生成较多训练样本外组合，但其中会混入一定比例的逻辑不合理组合。加入 VAE-BN 控制策略后，有效样本占比提高至 30.10%，潜在样本零占比为 69.90%，而潜在结构零占比降至近似为 0。该结果表明，本文所提出的控制策略策略能够在保留稀有合法组合的同时有效剔除结构零。

进一步地，为分析控制策略对生成样本潜空间分布的影响，计算生成样本与居民出行调查样本在 VAE 潜空间中的 Wasserstein 距离。图 3-12展示了加入控制策

略前后 Wasserstein 距离的分布。未加入控制策略时,生成样本与真实样本之间的平均 Wasserstein 距离为 2.579。加入 VAE-BN 控制策略后,平均 Wasserstein 距离下降至 2.564,更接近真实调查样本内部的平均距离水平 2.556。这说明控制策略能够引导生成样本向真实样本潜空间中的合理区域靠近,从而减少远离真实人口结构的异常组合。




图 3-12 生成样本与居民出行调查样本在 VAE 潜空间中的 Wasserstein 距离分布

Figure 3-12 Distribution of Wasserstein distances between synthetic samples and household travel survey samples in the VAE latent space.

上述结果说明,本文提出的 VAE-BN 控制策略能够有效区分样本零与结构零,从而维持合成人口的多样性和外推能力。

3.8 本章小结

本章针对 MaaS 推广策略仿真所需的微观人口输入,研究了面向出行分析的超大城市家庭级人口合成问题。围绕家庭-个人层级间的“一对多”映射、多地理尺度边际分布的同时对齐、样本零与结构零的甄别处置以及超参数对人口分布差异的适配四个方面,本章提出了以分层扩散 Transformer 模型为主体的人口合成方法,并以北京市为算例进行了验证。本章的主要工作与结论如下。

其一,针对家庭与个人属性间的“一对多”映射,构建了基于 HDBSCAN 的家庭画像机制与分层扩散 Transformer 模型。家庭画像机制以画像标签作为条件信息压缩下层成员属性的生成空间,分层扩散 Transformer 以 GraphVAE 解码器与异质

图 Transformer 显式表征家庭结构与成员关系。算例表明, 所提模型在家庭级、个人级与扩展家庭级三个层面、全部属性组合维度下均取得最小的 SRMSE, 6 维属性组合下家庭级与个人级 SRMSE 分别低至 0.389 与 1.188, 显著优于各类生成模型基准。消融实验进一步表明, 图处理模块与画像条件模块分别在刻画成员依赖关系与约束成员生成空间上发挥关键作用, 移除后个人级 SRMSE 分别升至 6.465 与 15.562。在家庭结构图的生成质量上, 预测邻接矩阵与真实邻接矩阵的余弦相似度与 Jaccard 相似度均值分别达 0.839 与 0.805, 边类型与节点类型预测准确率均值分别为 0.889 与 0.841, 表明模型能够准确还原家庭成员的构成与关系。

其二, 针对多地理尺度边际分布的同时对齐, 设计了基于能量引导的多地理尺度边际对齐机制。该机制在去噪采样过程中注入多地理尺度引导梯度, 将宏观统计信息以边际约束的形式融入生成过程, 并通过求解二次规划问题协调尺度间的梯度冲突。算例表明, 引入能量引导后, 合成人口在栅格、行政区与城市三个尺度上与目标边际的吻合度均得到提升, 其中栅格尺度机动车拥有比例的平均绝对误差下降 27.34%, 且冲突协调策略保证了多尺度约束间的平衡, 避免过度优化单一尺度。

其三, 针对样本零与结构零的处理, 设计了基于变分自编码器与贝叶斯网络的零单元控制策略。该策略以 BN 对数概率与潜空间距离双判据将生成样本划分为有效样本、样本零与结构零, 保留前两类以维持多样性、剔除并重生成结构零以保证合法性。算例表明, 引入控制策略后结构零占比由 6.86% 降至近似为零, 同时样本零得以保留。生成样本与调查样本在潜空间中的平均 Wasserstein 距离由 2.579 降至 2.564, 趋近真实样本内部水平, 表明该策略在剔除无效组合的同时维持了合成人口的合理外推能力。

其四, 针对超参数对不同城市人口分布的适配, 设计了两阶段超参数调优策略。第一阶段基于属性间互信息构建超参数的先验分布, 为搜索提供起点; 第二阶段在 Hyperband 框架内引入冲突感知机制, 依据梯度冲突暴露度调整存活选择与采样分布, 实现预算约束下的高效搜索, 使方法能够自适应不同城市的人口分布特征。

综上, 本章提出的方法能够由小规模调查样本合成属性联合分布真实、家庭结构合理且多尺度边际吻合的家庭级虚拟人口。所合成的虚拟人口为下一章家庭活动计划的生成提供了具备完整家庭结构与成员属性的决策主体, 是后续 MaaS 推广策略仿真的微观基础。

4 考虑家庭联合活动的家庭级活动计划生成

4.1 本章引论

本章聚焦研究内容(2):考虑家庭联合活动的城市级别家庭级别活动计划生成。活动计划以活动链的形式表征,记录每位居民一日之内于何时出行、前往何处、出于何种目的以及采用何种方式,描述了居民完整的活动-出行序列,是刻画居民日常生活与出行行为的核心。对于 MaaS 推广策略仿真而言,活动计划不仅定义了每位居民既有的出行模式,更界定了其向 MaaS 转移的具体情境,是智能体判断是否采用 MaaS、以及如何采用 MaaS 的直接输入。因此,为智能体生成合理的活动计划是仿真可信度的关键所在。下面对活动计划生成问题的特性进行简要分析。

首先,居民活动计划的生成受到多种因素的共同影响,既包括年龄、职业、居住地与工作地点位置等个体层面的属性,也包括家庭构成、车辆拥有与收入水平等家庭层面的属性。既有研究多以个体为基本生成单元,着重刻画个体属性对活动与出行选择的影响,而对家庭层面的协调因素考虑不足。然而,家庭层面的活动计划制定在现实中十分普遍。在亲子出行中,父母常陪同子女上学、参加课外活动或就医。此外,家庭持照人数通常多于其所拥有的车辆数,车辆的实际使用是家庭内部分配的结果,而非各成员相互独立的决策。因此,家庭成员的活动计划彼此并非独立,而是在联合活动、车辆共享与时序安排上相互协调的产物。若忽略这种协调、以个体为单位独立地生成各成员的活动链,所生成的计划在联合出行、接送与车辆分配等家庭级统计上则会产生偏差。因此,本章进一步以第3章获得的家庭级虚拟人口为输入,获取家庭级别的协调式活动计划,以便生成的人口根据自身活动计划做出 MaaS 采纳决策。

然而,将活动计划的生成单元由个体提升至家庭对生成方法本身提出了更高的要求。如第2章所述,基于优化的方法虽能以显式约束较为完整地刻画车辆分配、接送与联合参与等家庭协调,但其效用函数依赖人工设定、参数由极大似然估计,且计算代价高昂、难以扩展至大规模人口。基于深度生成模型的方法虽能端到端地学习活动计划属性的联合分布,但既有研究始终将居民视作彼此独立的样本,缺乏对家庭内部协调的显式建模,难以生成家庭级的多成员协调的活动计划。具体而言,面向家庭的协调式活动计划生成面临的难点主要体现在以下三个方面。

(1) 家庭与成员多层级信息的统一感知。每位成员的活动计划由家庭层面的共享特征(如家庭构成、车辆拥有与收入水平)与成员层面的个体属性(如年龄、

职业与持照状态)共同塑造,二者粒度不同、视角互补,须在生成之前整合为统一的成员表征。同时,家庭中的成员构成的集合具有无序且规模不定的特点,这要求生成方法需具有处理无序集合的能力、对成员顺序保持置换等变、并能适应不同规模的家庭。

(2) 多成员活动计划的协调生成。在家庭层面,成员的活动计划经由联合活动、接送义务与车辆共享相互耦合,其中部分耦合是不可违反的硬约束,例如同时驾驶私家车的成员数不能超过家庭拥有的车辆数,联合出行的成员须共享一致的出发到达时间与出行方式。因此,生成过程须对全体成员同时推理、并保证家庭内部协调,而非逐一独立生成。

(3) 城市级目的地选择建模。目的地选择是活动计划生成中最具挑战的环节。一方面,城市尺度下候选目的地集合规模庞大;另一方面,目的地受个人偏好、活动目的、出行阻抗与目的地吸引力等多重因素共同支配,呈现情境依赖、空间异质的特征。如何在城市尺度下的大候选集上刻画居民对目的地的选择机制,并保证所生成目的地的空间精度,是活动计划生成需攻克的难点。

针对上述问题,本章提出协调式家庭活动链生成框架(Coordinated Household ACTivity-chain generator, CoHACT),其总体框架如图 4-1所示。该框架由四个相互关联的模块构成:针对(1),构建融合家庭-成员特征的多任务编码器,以渐进分层提取结构与集合注意力专家整合家庭共享特征与成员专属属性,并将其融合为协调成员特征。同时,推断家庭与个人层级的活动模式先验,以缓解由家庭属性到活动链的“一对多”映射;针对(2),设计家庭协调式活动计划解码器与基于纳什议价的家庭活动计划协调层——前者经跨角色注意力使各成员在生成活动计划时相互感知,后者将家庭活动计划生成建模为合作博弈问题,确保解码器输出的活动计划严格满足家庭资源等硬约束的同时最大化家庭效用;针对(3),设计考虑空间异质性的目的地注意力层,利用地理阻抗、目的地吸引力与用地语义对候选目的地打分,刻画目的地选择的时空异质性,提升生成目的地的空间精度。

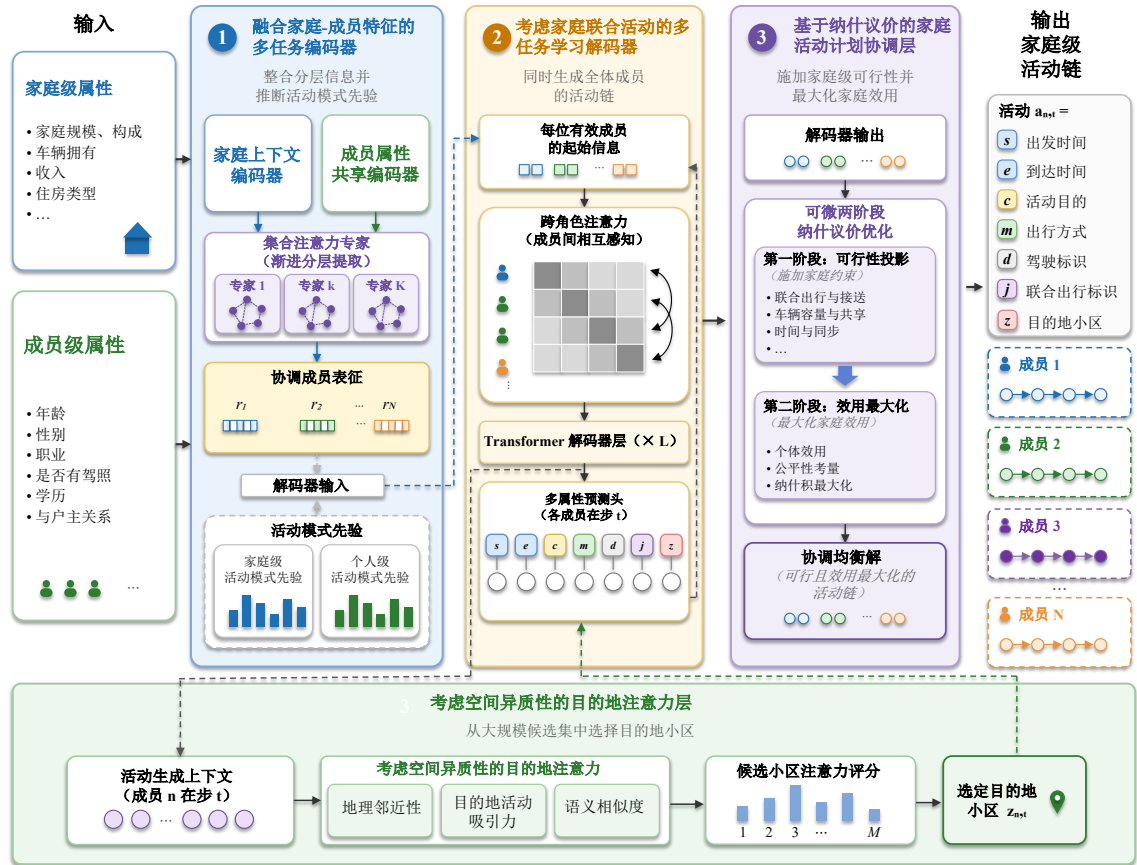


图 4-1 考虑家庭联合活动的家庭级活动计划生成方法总体框架

Figure 4-1 Overall framework of the household-level activity chain generation method with intra-household joint activities.

4.2 融合家庭-成员特征的多任务编码器

承接4.1节的问题描述，本章将家庭级活动计划生成构建为一个条件生成任务：以家庭级属性向量 $\mathbf{h} \in \mathbb{R}^{d_h}$ 与各成员的属性向量 $\{\mathbf{P}_i \in \mathbb{R}^{d_p}\}_{i=1}^N$ 为条件，为家庭中每位有效成员生成完整的活动链，其中 N 为家庭成员数。家庭级属性刻画家庭的共享特征，如家庭规模与构成、车辆拥有与收入水平；成员级属性刻画成员的个体特征，如年龄、性别、职业与持照状态；二者共同构成生成所依赖的条件信息。本节聚焦模型的输入侧，即如何将上述异质条件信息编码为指导后续家庭及活动计划生成的融合表征。编码器的整体结构如图 4-2所示。




图 4-2 融合家庭-成员特征的多任务编码器示意图

Figure 4-2 Schematic diagram of the multi-task encoder integrating household and member features.

由4.1所述，每位家庭成员的活动链同时受到家庭共享特征与成员个体属性的影响，二者粒度不同、视角互补，须在生成之前整合为统一的成员表征。为此，本节设计融合家庭-成员特征的多任务编码器，将家庭级与成员级属性映射为一组相互协调的成员表征以及一个家庭级表征，作为后续解码器的条件信息。编码器的设计出于两点考虑。一方面，家庭中的成员天然构成无序且规模可变的集合，编码器须对成员顺序保持置换等变、并能处理不同规模的家庭，同时应有效融合每位成员的特征与成员间共享的家庭级特征。另一方面，条件信息中家庭层面与成员层面的属性粒度不同：家庭规模、车辆拥有与收入水平等家庭属性对全体成员取值相同，刻画家庭的共享背景；年龄、职业与持照状态等成员属性则因人而异，刻画成员的个体差异。二者视角互补，编码器须在一定程度上将其解耦，方能在提取家庭共享特征的同时保留成员专属特征。基于上述两点考虑，本节首先设计融合家庭-成员特征的编码层，将家庭属性与成员属性融合为统一的成员表征；随后设计渐进分层提取（Progressive Layered Extraction, PLE）^[154] 编码器，将家庭-成员特征融合问题建模为一个包含家庭表征与成员表征两项主任务的多任务学习问题，显式分离共享参数与任务专属参数，从而协调地学习家庭表征与成员表征；此外，为处理由属性到活动链的“一对多”问题，本节还构建家庭与个人级的活动模式先验，为后续生成提供模式层面的引导。设计的融合家庭-成员特征的多任务编码器的结构示意图如图 4-2所示。

4.2.1 家庭-成员特征融合

首先，构建家庭-成员特征融合层，将家庭级属性向量 $\mathbf{h}$ 与成员级属性矩阵 $\mathbf{P} = [\mathbf{P}_1, \dots, \mathbf{P}_N]^\top$ 整合为统一的成员表征。为使每位成员的信息向量有效融合成员共享的家庭属性与自身属性，首先将家庭属性向量广播至全体成员，并与各成员属性拼接，再经一个共享的线性层映射为维度为 d_{model} 的融合表征：

$$\mathbf{x}_n^{(0)} = \text{Linear}(\mathbf{h} \parallel \mathbf{P}_n) \in \mathbb{R}^{d_{\text{model}}}, \quad n = 1, \dots, N, \quad (4-1)$$

式中， $\parallel$ 表示向量拼接。将各成员的线性变换结果按行堆叠，即得融合表征矩阵 $\mathbf{X}^{(0)} = [\mathbf{x}_1^{(0)}, \dots, \mathbf{x}_N^{(0)}]^\top \in \mathbb{R}^{N \times d_{\text{model}}}$ ，作为后续 PLE 编码器的输入。

4.2.2 活动模式先验构建

除式 (4-1) 获取的融合表征外，编码器还须为后续生成提供活动模式先验，以缓解由属性到活动链的“一对多”映射，压缩解码器生成家庭级活动计划的生成空间。为此，本章在 C_h 个家庭级与 C_p 个个人级活动模式簇上分别构建家庭级活动模式分布 $\pi^h \in \Delta^{C_h}$ 与各成员的个人级活动模式分布 $\{\pi_n^{\text{ind}} \in \Delta^{C_p}\}_{n=1}^N$ ，其中 Δ^C 表示 C 维概率单纯形。活动模式簇通过对训练集中的活动链施加高斯混合模型聚类离线获得，簇数由贝叶斯信息准则确定。活动模式分布并非由编码器主干预测，而是由一个独立训练、并经蒸馏得到的活动模式识别模型 g_ϕ 根据家庭与成员属性给出，且在 CoHACT 训练过程中冻结权重，以获取稳定的活动模式输出。以上模式条件生成与 CoHACT 相对分离的设计的优势在于：在训练早期编码器表征尚不稳定时，冻结的 g_ϕ 仍能提供稳定且具有信息量的模式先验，从而更可靠地引导生成。所得家庭与个人级活动模式分布将在4.3节经自适应层归一化注入解码过程。

4.2.3 渐进分层提取编码器

经式 (4-1) 的特征融合，家庭属性与家庭成员属性被整合为融合表征矩阵 $\mathbf{X}^{(0)}$ ，其每一行对应一名成员，表示该成员的个体信息及其所属家庭的共享信息。在此基础上，编码器须进一步处理该表征矩阵以获取供解码器使用的两类特征：逐成员刻画的成员特征 $\mathbf{R}$ ，与刻画家庭整体的家庭特征 $\mathbf{r}^h$ 。须强调的是，家庭特征与成员特征与原始输入数据不同，应涵盖蕴含家庭层面的完整信息。具体而言，成员的活动计划制定受家庭情境制约——其他成员的属性、家庭共享的资源以及联合开展的活动均会影响单个成员的活动安排；家庭特征 $\mathbf{r}^h$ 则在此之上对全体成员作进一步汇聚，用以给解码器统筹家庭层面的整体安排。

正因两类特征高度共享信息而又各有侧重,若以单一共享网络学习,家庭特征与成员特征提取两项任务在训练过程中的梯度易相互干扰,引发模型输出效果在两类特征间此消彼长的“跷跷板”效应(多任务学习中经典的负迁移问题)。为此,本节将编码过程建模为一个包含成员特征提取与家庭特征提取两项主任务的多任务学习问题,并采用渐进分层提取(Progressive Layered Extraction, PLE)^[154]结构作为编码器主体,显式分离两项任务的共享参数与专属参数,从而在充分共享公共信息的同时协调地提取两类特征。

PLE 结构堆叠 L 个定制门控(Customized Gate Control, CGC)层。每个 CGC 层为两项特征提取任务设置 m_s 个对全体任务可见的共享专家,并为每项任务各配置 m_k 个任务专属专家:共享专家提取家庭与成员中的融合信息,任务专属专家保留各自任务的特性,使每项任务既能利用共享专家提取的融合信息、又能借助专属专家维持自身特性,从而缓解任务间的负迁移现象。

每个专家的输入为按成员排布的特征矩阵,首层取融合表征矩阵 $\mathbf{X}^{(0)}$ 。由于家庭内成员本无固定次序、且家庭规模随家庭而异,专家须对成员的排列保持置换等变,并适应可变的成员数目。为此,本章将每个专家建模为诱导集合注意力块(Induced Set-Attention Block, ISAB)^[155],使各成员的提取后的特征均由全体成员的特征聚合而来,既不依赖成员次序与家庭规模,又使各成员的提取后特征蕴含家庭层面的信息。ISAB 的基本组件为多头注意力块(Multi-head Attention Block, MAB)。给定查询矩阵 $\mathbf{Q}$ 与键矩阵 $\mathbf{K}$, MAB 定义为

$$\text{MAB}(\mathbf{Q}, \mathbf{K}) = \text{LN}(\mathbf{A} + \text{FFN}(\mathbf{A})), \quad \mathbf{A} = \text{LN}(\mathbf{Q} + \text{MHA}(\mathbf{Q}, \mathbf{K}, \mathbf{K})), \quad (4-2)$$

式中, $\text{MHA}(\cdot)$ 为多头注意力, $\text{FFN}(\cdot)$ 为逐位置前馈网络, $\text{LN}(\cdot)$ 为层归一化。直接对 N 个成员的特征施加自注意力的复杂度为 $O(N^2 d_{\text{model}})$, 且不显式产生家庭层面的聚合特征,不利于每个成员获取家庭层面的信息。为此, ISAB 引入一组数量为 n_l 的可学习诱导点 $\mathbf{I} \in \mathbb{R}^{n_l \times d_{\text{model}}}$, 经两个堆叠的 MAB 计算各成员的提取后特征:

$$\mathbf{S} = \text{MAB}(\mathbf{I}, \mathbf{X}) \in \mathbb{R}^{n_l \times d_{\text{model}}}, \quad \text{ISAB}(\mathbf{X}) = \text{MAB}(\mathbf{X}, \mathbf{S}) \in \mathbb{R}^{N \times d_{\text{model}}}, \quad (4-3)$$

即诱导点先对成员集合施加注意力,形成紧凑的家庭级聚合特征 $\mathbf{S}$; 各成员再以自身为查询对象、对该家庭级聚合特征施加注意力,得到各自的提取后特征。如此,计算复杂度由 $O(N^2 d_{\text{model}})$ 降至 $O(N n_l d_{\text{model}})$, 且各成员的提取后特征均经由对家庭级聚合特征的注意力计算得到,故蕴含家庭层面的信息。

基于 ISAB 专家, CGC 层以门控机制耦合两项特征提取任务,使每项任务按各自的组合权重读取其专属专家与全部共享专家的提取后特征。对第 ℓ 层的任务 k , 记其自上一层得到的提取后特征矩阵为 $\mathbf{U}_k^{(\ell-1)} \in \mathbb{R}^{N \times d_{\text{model}}}$, 并以 $\mathbf{U}_k^{(0)} = \mathbf{X}^{(0)}$ 初始

化。门控网络依据掩码均值 $\bar{\mathbf{u}}_k^{(\ell-1)}$ 计算任务 k 在其候选专家集上的组合权重，其中有效成员掩码 μ_n^{mem} 用于屏蔽为对齐最大家庭规模而填充的无效成员位：

$$\mathbf{w}_k^{(\ell)} = \text{Softmax}\left(\mathbf{W}_k^{(\ell)} \bar{\mathbf{u}}_k^{(\ell-1)}\right), \quad \bar{\mathbf{u}}_k^{(\ell-1)} = \frac{\sum_{n=1}^N \mu_n^{\text{mem}} \mathbf{u}_{k,n}^{(\ell-1)}}{\sum_{n=1}^N \mu_n^{\text{mem}}}, \quad (4-4)$$

式中， $\mathbf{u}_{k,n}^{(\ell-1)}$ 为矩阵 $\mathbf{U}_k^{(\ell-1)}$ 的第 n 行，即成员 n 的提取后特征向量， $\text{Softmax}(\cdot)$ 沿候选专家维度归一化， $\mathbf{W}_k^{(\ell)}$ 为任务 k 在第 ℓ 层的可学习门控矩阵。任务 k 在第 ℓ 层的提取后特征为其全部候选专家输出的加权组合：

$$\mathbf{U}_k^{(\ell)} = \sum_{e=1}^{m_s+m_k} w_{k,e}^{(\ell)} \mathbf{E}_{k,e}^{(\ell)}\left(\mathbf{U}_k^{(\ell-1)}\right), \quad (4-5)$$

式中， $\mathbf{E}_{k,e}^{(\ell)}(\cdot)$ 为任务 k 可用的第 e 个专家的特征提取函数，即式 (4-3) 的 ISAB 计算流程，专家候选集涵盖 m_s 个共享专家与 m_k 个任务专属专家， $w_{k,e}^{(\ell)}$ 为式 (4-4) 所得的相应门控权重。如此，两项主任务依据各自门控权重对共享专家与专属专家作加权计算，并随 CGC 层的堆叠逐层细化各自的提取后特征。

经 L 个 CGC 层后，成员特征提取任务以其末层提取后特征作为成员特征矩阵 $\mathbf{R} = [\mathbf{r}_1, \dots, \mathbf{r}_N]^\top \in \mathbb{R}^{N \times d_{\text{model}}}$ ，家庭特征提取任务则对其末层提取后特征在各有效成员位置上施加掩码均值池化，得到家庭表征 $\mathbf{r}^h \in \mathbb{R}^{d_{\text{model}}}$ 。所得成员表征与家庭表征连同前文构建的活动模式先验一并传输给解码器，用于生成家庭中各成员的活动链。

4.3 考虑家庭联合活动的多任务学习解码器

承接4.2节的编码器，本节设计考虑家庭联合活动的活动计划解码器，以编码器输出的成员表征 $\{\mathbf{r}_n\}_{n=1}^N$ 、家庭表征 $\mathbf{r}^h$ 与家庭、个人级活动模式先验为条件，为家庭中每位有效成员生成完整的活动计划。记成员 n 的活动计划为按时序排列的活动序列 $\{a_{n,t}\}_{t=1}^T$ ， T 为最大链长；每个活动 $a_{n,t}$ 由刻画其时间、空间与行为特征的七个属性构成：

$$a_{n,t} = (s_{n,t}, e_{n,t}, c_{n,t}, m_{n,t}, d_{n,t}, j_{n,t}, z_{n,t}), \quad (4-6)$$

式中， $s_{n,t}, e_{n,t} \in \mathbb{R}$ 为归一化的出发与到达时间； $c_{n,t}$ 为活动目的； $m_{n,t}$ 为出行方式； $d_{n,t}$ 与 $j_{n,t}$ 为驾驶与联合出行的二元标识； $z_{n,t}$ 为目的地小区。值得注意的是，生成的目标是家庭而非个体，即同时生成全体成员的活动计划，并显式建模与满足家庭的联合出行需求。

现实中，居民的活动决策同时受自身属性与家庭情境的约束，且须确定活动的多个属性——参与何种活动、于何时何地展开、以及如何在活动间出行。因此，

家庭级活动计划生成既须同时考虑全体成员、又须兼顾活动的全部属性，可自然地建模为一个多任务序列生成问题。为此，本节将解码器设计为以每个活动属性为一项任务的多任务注意力网络，即由一个任务特定注意力与一组专属预测头共同构成 MTAN 式解码器^[156]。生成过程分两个阶段组织：第一阶段，由成员表征与家庭表征构建家庭级特征，并经跨角色注意力使成员间相互交互，获得家庭成员的协调特征，表示家庭成员在认知家庭情境与其他成员的基础上形成的协调表征；第二阶段，以该成员特征、成员表征与活动模式先验为条件，由共享的 Transformer 解码器自回归地生成各成员的活动序列，再由专属预测头给出各活动属性。

上述设计针对4.1节的难点（2）与（3）。其中，难点（2）的协调生成由解码器经跨角色注意力使各成员相互感知、并同时生成全体成员的活动计划解决，而车辆可用性等不可违反的硬约束则由后续基于纳什议价的家庭活动计划协调层控制；难点（3）的目的地选择由考虑空间异质性的目的地与出行方式联合预测方法处理，在城市尺度的大候选集上联合预测目的地与出行方式。

据此，本节分两部分展开：首先，构建家庭成员特征协调层以获取相互作用的家庭成员特征（4.3.1小节）；随后，设计自回归活动计划生成器（4.3.2小节。家庭协调式活动链解码器的总体结构如图 4-3 所示。




图 4-3 家庭协调式活动链解码器示意图

Figure 4-3 Schematic diagram of the household-coordinated activity-chain decoder.

4.3.1 家庭成员特征协调层

经编码器得到的成员特征 $\mathbf{R} = [\mathbf{r}_1, \dots, \mathbf{r}_N]^\top$ 已由编码器中的共享专家与任务专属专家输出的特征聚合得到，每位成员的特征均隐含家庭整体与其余成员的信息；家庭特征 $\mathbf{r}^h$ 则是面向家庭特征任务的整体概括。为使各成员在自回归生成活动时据考虑到车辆共享与接送时序等联合活动，本节在自回归生成前设置特征协调层，依次使用任务特定注意力与跨角色注意力对成员特征作两步增强：前者将家庭特征 $\mathbf{r}^h$ 显式注入各成员特征，后者在成员间显式交互，二者共同输出供解码器使用的协调成员特征 $\{\tilde{\mathbf{r}}_n\}$ ，表示家庭成员在认知家庭情境与其他成员的基础上形成的协调表征。

首先，任务特定注意力使每位成员从编码器输出的家庭特征中提取与自身相关的家庭共享特征。该注意力以成员特征 $\mathbf{r}_n$ 为查询向量、以家庭表征 $\mathbf{r}^h$ 为键向量与值向量，二者分别取自编码器的成员表征任务与家庭表征任务，故称任务特定：

$$\tilde{\mathbf{r}}_n = \text{LN}(\mathbf{r}_n + \text{MHA}(\mathbf{r}_n, \mathbf{r}^h, \mathbf{r}^h)), \quad (4-7)$$

式中， $\text{MHA}(\cdot)$ 为多头注意力； $\text{LN}(\cdot)$ 为层归一化； $\tilde{\mathbf{r}}_n$ 为提取家庭共享特征后的成员表征。

随后，跨角色注意力在有效成员集合上采用多头自注意力，使各成员相互交互，以捕捉家庭内部的活动计划协调关系：

$$\tilde{\mathbf{r}}_n = \text{LN}(\tilde{\mathbf{r}}_n + \text{MHA}(\tilde{\mathbf{r}}_n, \tilde{\mathbf{R}}, \tilde{\mathbf{R}})), \quad (4-8)$$

式中， $\tilde{\mathbf{R}} = [\tilde{\mathbf{r}}_1, \dots, \tilde{\mathbf{r}}_N]^\top$ 为全体成员提取家庭共享特征后的成员表征，注意力由有效成员掩码 μ_n^{mem} 屏蔽，使填充的无效成员不参与计算； $\tilde{\mathbf{r}}_n$ 为最终得到的每个成员的协调成员特征。

经上述两步，协调成员特征 $\{\tilde{\mathbf{r}}_n\}_{n=1}^N$ 中的每位成员同时感知家庭信息与其余成员的信息，蕴含家庭层面的整体情境与成员间的协调关系，是后续自回归生成活动计划的输入。

4.3.2 自回归活动计划生成器

活动计划中的各活动相互关联，后一活动以先前已生成的活动为条件，天然契合自回归生成范式。为此，解码器以 L_d 层堆叠的 Transformer 解码器逐步生成每位成员的活动序列。在步 t ，对每个位置 $\tau \leq t$ ，输入由上一次活动的嵌入、位置编码与协调成员特征，获取每位成员的活动表征 $\mathbf{u}_n^{(\tau)}$ ：

$$\mathbf{u}_n^{(\tau)} = \text{Embed}(a_{n,\tau-1}) + \text{PosEmbed}(\tau) + \tilde{\mathbf{r}}_n, \quad (4-9)$$

式中, $\text{Embed}(\cdot)$ 将上一次活动的属性嵌入, 其中类别属性经嵌入表映射、连续属性经线性投影; $\text{PosEmbed}(\tau)$ 为位置编码; $a_{n,0}$ 为可学习的起始向量; $\tilde{\mathbf{r}}_n$ 为成员 n 的协调成员特征。

记输入序列 $\mathbf{H}^{(0)} = [\mathbf{u}_n^{(1)}, \dots, \mathbf{u}_n^{(t)}]$ (为简洁略去成员下标), 第 ℓ 层 Transformer 解码器依次执行四个模块:

其一, 因果自注意力沿活动序列捕捉时序依赖, 并以下三角因果掩码 $\mathbf{M}$ 使每个位置的活动生成仅注意其之前的活动, 保持自回归性:

$$\mathbf{H}' = \text{LN}(\mathbf{H}^{(\ell-1)} + \text{MHA}(\mathbf{H}^{(\ell-1)}, \mathbf{H}^{(\ell-1)}, \mathbf{H}^{(\ell-1)}; \mathbf{M})), \quad (4-10)$$

式中, $\mathbf{M}$ 为下三角因果掩码, 阻止该位置的活动生成受到未来活动的影响, $\mathbf{H}'$ 为因果自注意力后的活动表征。

其二, 面向成员特征的交叉注意力以活动表征 $\mathbf{H}'$ 为查询向量、以编码器输出的成员特征 $\mathbf{r}_n$ 为键向量与值向量, 使生成在每一步均锚定于该成员的静态画像、避免长序列上发生漂移; 家庭特征与其余成员的信息已由式 (4-9) 中的协调成员特征 $\tilde{\mathbf{r}}_n$ 注入输入:

$$\mathbf{H}'' = \text{LN}(\mathbf{H}' + \text{MHA}(\mathbf{H}', \mathbf{r}_n, \mathbf{r}_n)). \quad (4-11)$$

式中, $\mathbf{H}''$ 为交叉注意力后的活动表征。

其三, 自适应层归一化以家庭级与个人级活动模式分布为条件, 对生成过程进行调制。两分布分别经投影、拼接后作为条件向量, 再由一个轻量网络据此预测缩放与平移参数, 用于调制层归一化:

$$(\gamma_n, \beta_n) = \text{MLP}_{\text{ada}}(\text{SiLU}([\mathbf{W}^h \boldsymbol{\pi}^h \parallel \mathbf{W}^{\text{ind}} \boldsymbol{\pi}_n^{\text{ind}}])), \quad (4-12)$$

$$\mathbf{H}''' = (1 + \gamma_n) \odot \text{LN}(\mathbf{H}'') + \beta_n, \quad (4-13)$$

式中, $\mathbf{W}^h$ 与 $\mathbf{W}^{\text{ind}}$ 将家庭级与个人级活动模式分布 $\boldsymbol{\pi}^h, \boldsymbol{\pi}_n^{\text{ind}}$ 投影至隐藏层维度; $\odot$ 为逐元素相乘; MLP_{ada} 的末层参数初始化为零, 使训练初期 γ_n 与 β_n 均为零、调制退化为恒等映射 (此时 $\mathbf{H}''' = \text{LN}(\mathbf{H}'')$), 其后随训练逐步学到有效的调制, 从而稳定训练。借助这一条件调制, 同一套解码器即可依据活动模式条件适配不同类型的家庭 (如通勤主导与接送主导的家庭), 而无需为每类家庭单独设置子网络。最终, $\mathbf{H}'''$ 为自适应层归一化后的活动表征。

其四, 逐位置前馈网络精炼各活动表征:

$$\mathbf{H}^{(\ell)} = \text{LN}(\mathbf{H}''' + \text{FFN}(\mathbf{H}''')). \quad (4-14)$$

式中, $\mathbf{H}^{(\ell)}$ 为第 ℓ 层的活动表征。

经 L_d 层后, 末位置的隐状态 $\mathbf{g}_n^{(t)} = \mathbf{H}^{(L_d)}[t]$ 送入一组专属预测头, 预测得到步 t 活动的各属性:

$$\begin{aligned} (\hat{s}_{n,t}, \hat{e}_{n,t}) &= \text{MLP}_{\text{time}}(\mathbf{g}_n^{(t)}), \\ \hat{\mathbf{c}}_{n,t} &= \text{Softmax}(\mathbf{W}_c \mathbf{g}_n^{(t)}), \\ \hat{\mathbf{d}}_{n,t} &= \text{Softmax}(\mathbf{W}_d \mathbf{g}_n^{(t)}), \\ \hat{\mathbf{j}}_{n,t} &= \text{Softmax}(\mathbf{W}_j \mathbf{g}_n^{(t)}). \end{aligned} \quad (4-15)$$

式中, $\text{MLP}_{\text{time}}(\cdot)$ 为预测出发与到达时间 $(\hat{s}_{n,t}, \hat{e}_{n,t})$ 的连续时间头; $\mathbf{W}_c$ 、 $\mathbf{W}_d$ 、 $\mathbf{W}_j$ 分别为活动目的、驾驶与联合出行分类头的投影矩阵, $\hat{\mathbf{c}}_{n,t}$ 为活动目的类别分布, $\hat{\mathbf{d}}_{n,t}$ 、 $\hat{\mathbf{j}}_{n,t}$ 为驾驶与联合出行二元标识的分布。目的地 $z_{n,t}$ 与出行方式 $m_{n,t}$ 预测, 均以解码隐状态 $\mathbf{g}_n^{(t)}$ 为输入, 二者在空间维度上高度相关, 即活动目的地的选择直接影响出行方式的选择, 反之亦然。

为此, 将目的地与出行方式的预测耦合建模, 进一步设计考虑空间异质性的目的地与出行方式联合预测方法, 以在城市尺度的大候选集上联合预测目的地与出行方式。

首先, 为异质地表征候选目的地, 每个候选目的地 $z \in \mathcal{Z}$ 由三组特征刻画: 可学习的目的地嵌入 $\mathbf{e}_z$, 以数据驱动方式捕捉每个目的地的潜在特性; 预计算的 LDA 主题向量 ℓ_z , 由目的地内兴趣点 (Point Of Interest, POI) 分布概括其用地构成; 预计算的吸引力向量 $\mathbf{a}_z \in \mathbb{R}^P$, 其各分量为各候选目的地内与各活动目的相关的设施数量。三组特征拼接后投影至隐藏层维度, 得到各候选目的地的键向量:

$$\mathbf{k}_z = \mathbf{W}_k \text{LN}(\text{MLP}([\mathbf{e}_z \parallel \ell_z \parallel \mathbf{a}_z])) \in \mathbb{R}^{d_{\text{model}}}, \quad (4-16)$$

式中, $\text{MLP}(\cdot)$ 为带层归一化的两层网络; $\mathbf{W}_k$ 为键投影矩阵; $\parallel$ 表示拼接; P 为活动目的数。全部候选目的地键 $\mathbf{K} = [\mathbf{k}_1, \dots, \mathbf{k}_{|\mathcal{Z}|}]^\top$ 每次前向只计算一次, 并在全体成员与活动步间共享。

随后, 以当前活动的生成隐状态 $\mathbf{g}_n^{(t)}$ 与目的意图为查询向量, 对候选目的地评分。对成员 n 的第 t 次活动, 查询由解码隐状态、出发地嵌入与所预测的活动目的融合而成:

$$\mathbf{q}_{n,t} = \text{MLP}_q([\mathbf{g}_n^{(t)} \parallel \mathbf{o}_{n,t} \parallel \hat{\mathbf{c}}_{n,t}]) \in \mathbb{R}^{d_{\text{model}}}, \quad (4-17)$$

式中, $\mathbf{o}_{n,t}$ 为出发地小区的嵌入, 即上一活动的目的地 (首个活动则为当前位置); $\hat{\mathbf{c}}_{n,t}$ 为所预测的活动目的分布。继而对每个候选目的地评分, 并以地理阻抗惩罚与目的吸引力加成增强注意力:

$$\text{logit}_{n,t,z} = \frac{\mathbf{q}_{n,t}^\top \mathbf{k}_z}{\sqrt{d_{\text{model}}}} - \lambda_{\text{imp}} \delta_{o_{n,t}, z} + \lambda_{\text{aff}} \mathbf{a}_z^\top \hat{\mathbf{c}}_{n,t}, \quad (4-18)$$

式中, $\frac{\mathbf{q}_{n,t}^\top \mathbf{k}_z}{\sqrt{d_{\text{model}}}}$ 为查询向量与候选目的地键向量的相似度; $\delta_{o_{n,t},z}$ 为由出发地 $o_{n,t}$ 至候选目的地 z 的预计算阻抗, 惩罚项 $-\lambda_{\text{imp}} \delta_{o_{n,t},z}$ 实现类似引力模型的距离衰减; $\mathbf{a}_z^\top \hat{\mathbf{c}}_{n,t}$ 为候选目的地 z 在所预测目的下的期望的吸引力, 奖励对该目的更具吸引力的小区; 权衡系数 $\lambda_{\text{imp}}, \lambda_{\text{aff}} > 0$ 均可学习。最终对全候选目的地上的评分 $\text{logit}_{n,t,z}$ 进行 Softmax 运算得到目的地预测的概率分布:

$$P(z_{n,t} = z) = \frac{\exp(\text{logit}_{n,t,z})}{\sum_{z' \in \mathcal{Z}} \exp(\text{logit}_{n,t,z'})}. \quad (4-19)$$

考虑到出行方式与出行距离密切相关, 而出行距离取决于所选目的地。为此, 以距离感知的出行方式预测头显式耦合方式预测与目的地选择。先由目的地分布与阻抗矩阵计算活动的期望出行距离:

$$\bar{\delta}_{n,t} = \sum_{z \in \mathcal{Z}} P(z_{n,t} = z) \delta_{o_{n,t},z}, \quad (4-20)$$

随后, 以解码隐状态 $\mathbf{g}_n^{(t)}$ 与期望距离为输入给出对出行方式的基础预测, 再叠加距离-方式先验偏置 $\mathbf{b}(\bar{\delta}_{n,t})$, 得到出行方式分布:

$$\hat{\mathbf{m}}_{n,t} = \text{Softmax}(\text{MLP}_m([\mathbf{g}_n^{(t)} \parallel \bar{\delta}_{n,t}]) + \mathbf{b}(\bar{\delta}_{n,t})). \quad (4-21)$$

式中, $\bar{\delta}_{n,t}$ 为按目的地分布加权的期望出行距离; $\text{MLP}_m(\cdot)$ 为出行方式分类头; $\mathbf{b}(\bar{\delta}_{n,t})$ 为由训练集距离-方式经验分布初始化的先验偏置。

4.4 基于纳什议价的家庭活动计划协调层

4.3节的解码器虽借助跨角色注意力等机制使各成员生成的活动计划相互呼应, 但其输出仍为概率分布与连续值等“软”形式, 并未在成员之间显式施加家庭层面的硬约束, 易导致生成的活动计划在家庭层面不可行, 对应生成任务中的“结构零”问题。实际上, 家庭的一日活动计划本质上是家庭成员共享有限资源、并在部分冲突的活动计划间相互妥协的集体决策: 一方面, 成员日程受不可违反的硬约束限制, 如同时驾车的成员数不能超过家庭车辆数、联合出行的成员须共享一致的出发到达时间与出行方式; 另一方面, 满足这些耦合还需在成员间权衡, 如谁占用有限车辆、谁接送孩子等受抚养成员、谁的活动时间被调整, 故协调后的日程是协商折中而非任一成员的最优。因此, 解码器的输出至多在统计上促成协调, 却既不能严格保证上述家庭层面硬性约束成立, 也难以化解成员间的资源冲突(难点(2)的可行性)。

为此, 在解码器生成家庭级别的活动计划后, 本节将家庭活动计划协调任务建模为一个纳什议价(Nash Bargaining)问题, 提出基于纳什议价的家庭活动计划

协调层，将解码器输出的活动计划投影到家庭层面可行的均衡解。具体而言，以解码器输出的各家庭成员的活动计划为参考活动计划，求解一个帕累托有效、个体理性（任一成员协商后的效用不劣于其单独行动获得的效用）且在成员间均衡分配效用增益的可行解，使家庭活动计划协调结果在严格满足家庭资源约束与联合活动约束的同时，能够最大程度地提升家庭整体效用。为保证提出的纳什议价协调层可与编码器与解码器端到端联合训练，本节进一步设计两阶段的可微优化算法，即先求解纳什议价问题以获得协调解、再经优化过程反向传播梯度，从而既施加家庭级可行性、又将协调信号回传以引导编码器与解码器的学习。

4.4.1 问题构建

（1）纳什议价模型

纳什议价模型源于合作博弈论^[157]，刻画多个参与者就一组可行结果进行协商、并在无法达成一致时各自退守至某一分歧点（disagreement point）的情形。设有 N 个参与者，其可达成的效用向量构成可行集 $S \subseteq \mathbb{R}^N$ ，分歧点 $\mathbf{u}^0 = (u_1^0, \dots, u_N^0)$ 为协商破裂时各参与者所得的效用。纳什证明，在帕累托有效、对称、仿射变换不变与无关方案独立四条公理下，存在唯一的议价解，其最大化各参与者相对分歧点的效用增益之积：

$$\mathbf{u}^* = \arg \max_{\mathbf{u} \in S, \mathbf{u} \geq \mathbf{u}^0} \prod_{n=1}^N (u_n - u_n^0). \quad (4-22)$$

式中， $\mathbf{u}^*$ 为纳什议价解，兼具个体理性（任一参与者协商后的效用不劣于其单独行动获得的效用）与帕累托有效性，并在参与者间均衡分配增益、而非简单最大化效用之和，因而广泛用于刻画资源分配与利益协调问题。

（2）家庭活动计划协调问题建模

本节将家庭活动计划的协调建模为一个纳什议价问题：家庭成员即参与者，各成员未经协调的解码器生成的活动计划构成其分歧点，可行集为满足家庭资源约束与联合活动约束的协调活动计划。具体而言，设有 N 个家庭成员，其可达成的效用向量构成可行集 $\mathcal{F} \subseteq \mathbb{R}^N$ ，分歧点 $\mathbf{U}^0 = (U_1^0, \dots, U_N^0)$ 为各成员从解码器生成的活动计划中获得的效用。基于纳什议价的家庭活动计划协调模型的目标是求解一个帕累托有效、个体理性且在成员间均衡分配效用增益的可行解，使家庭活动计划协调结果在严格满足家庭资源约束与联合活动约束的同时，能够最大程度地提升家庭整体效用。

若将活动的全部属性均作为决策变量，家庭活动计划协调问题的解空间将极为庞大，因此，本节聚焦直接决定活动链可行性与协调性的关键属性，即时间、出行方式、联合出行与驾驶（接送）决策；活动目的固定，目的地已由4.3.2小节确

定，二者不参与本节的协调优化。记决策向量 $\mathbf{x}$ 汇集每位成员 n 每个活动 t 的出发与到达时间 $(s_{n,t}, e_{n,t})$ 、出行方式分布 $\mathbf{m}_{n,t} = (m_{n,t,1}, \dots, m_{n,t,K})$ 、联合出行概率 $j_{n,t}$ 与驾驶概率 $d_{n,t}$ ，并记 $\mathbf{x}^d$ 为相应的解码器生成结果。参照已有的基于优化的家庭活动计划生成研究^[55]，定义成员 n 在候选解 $\mathbf{x}$ 下的效用为：

$$U_n(\mathbf{x}) = \sum_t \mu_{n,t}^{\text{act}} \left[\alpha_{n,t}^{\text{soc}} q_{n,t}^{\text{out}} + \alpha_{n,t}^{\text{joint}} j_{n,t} + \theta_{n,t}^{\text{esc}} \mathbb{I}_n^{\text{adult}} d_{n,t} (e_{n,t} - s_{n,t}) + q_{n,t}^{\text{out}} \sum_k m_{n,t,k} \theta_k^{\text{tr}} \tau_{n,t,k} - \theta^{\text{jc}} j_{n,t}^2 \right], \quad (4-23)$$

式中， $q_{n,t}^{\text{out}}$ 为外出活动的概率（由固定的活动目的决定）； $\mathbb{I}_n^{\text{adult}}$ 为成年指示； $\tau_{n,t,k}$ 为方式 k 的期望出行时间（由4.3.2小节所选目的地决定）； $\mu_{n,t}^{\text{act}}$ 为活动有效性掩码。方括号内五项依次表示外出的社会效用、联合出行效用、成年人驾车接送他人的接送效用、所选方式的出行负效用，以及产生内点最优的二次联合出行成本。参数中，方式出行系数 θ_k^{tr} 与联合出行成本 θ^{jc} 为可学习标量，用于捕捉不同方式的出行负效用与联合出行的内点最优；与家庭内部决策更为相关的社会、联合与接送系数 $\alpha_{n,t}^{\text{soc}}, \alpha_{n,t}^{\text{joint}}, \theta_{n,t}^{\text{esc}}$ 则由一个可学习网络根据家庭属性、成员属性与所预测的活动目的给出，以捕捉家庭内部的个体差异与成员间的相互影响。最终，家庭活动计划协调问题可建模为一个带约束的纳什议价问题。

依纳什议价原则，协调解（Bargaining Solution）最大化各成员相对其分歧点的效用增益之积：

$$\mathbf{x}^* = \arg \max_{\mathbf{x} \in \mathcal{F}} \prod_{n=1}^N (U_n(\mathbf{x}) - U_n^0)^{\mu_n^{\text{mem}}} = \arg \max_{\mathbf{x} \in \mathcal{F}} \sum_{n=1}^N \mu_n^{\text{mem}} \log(U_n(\mathbf{x}) - U_n^0), \quad (4-24)$$

式中， μ_n^{mem} 为成员有效性掩码； $U_n^0 = U_n(\mathbf{x}^d)$ 为分歧点，即成员 n 从解码器生成的活动计划 $\mathbf{x}^d$ 中获得的效用，代表未达成家庭协调时的结果。最大化该纳什积保证协调解的个体理性——任一成员在协商后获得的最终效用一定高于其协商前获得的初始效用，并在成员间均衡分配效用增益。记 k_{car} 为私家车方式的索引， $\mathcal{P}$ 汇集解码器识别的联合出行成员对，即 $\mathcal{P} = \{(n_1, n_2, t) \mid n_1 < n_2, j_{n_1,t}^d j_{n_2,t}^d > \kappa\}$ ，其中 $j_{n,t}^d$ 为解码器输出 $\mathbf{x}^d$ 中的联合出行概率， κ 为激活阈值。汇集家庭级车辆资源约束与联合出行约束等的可行集 $\mathcal{F}$ 为：

$$\mathcal{F} = \left\{ \mathbf{x} \left| \begin{array}{ll} e_{n,t} \geq s_{n,t}, & s_{n,t+1} \geq e_{n,t}, & \forall (n,t); \\ \sum_k m_{n,t,k} = 1, & m_{n,t,k} \geq 0, & j_{n,t}, d_{n,t} \in [0, 1], & \forall (n,t); \\ s_{n,t}, e_{n,t} \in [\tau_{\min}, \tau_{\max}], & & \forall (n,t); \\ \sum_n \sum_t \mu_{n,t}^{\text{act}} \mathbb{I}_n^{\text{adult}} m_{n,t,k_{\text{car}}} d_{n,t} \leq V; & & \\ s_{n_1,t} = s_{n_2,t}, & e_{n_1,t} = e_{n_2,t}, & \mathbf{m}_{n_1,t} = \mathbf{m}_{n_2,t}, & j_{n_1,t} = j_{n_2,t}, & \forall (n_1, n_2, t) \in \mathcal{P}, \end{array} \right. \right\}, \quad (4-25)$$

该可行集包含刻画家庭内时间、方式与资源耦合的四组约束。

第一组约束强制每位成员活动计划的时序排序，即到达事件不早于出发时间、下一次活动的出发时间不早于本次活动的到达时间；

第二组约束使各活动的各项属性均落于可行域，即方式分布位于概率单纯形、联合出行与驾驶概率位于 $[0, 1]$ 、出发与到达时间位于标准化的每日时间窗的上下界 $[\tau_{\min}, \tau_{\max}]$ ；

第三组约束为家庭内车辆可用性约束，即，所有成年成员在某活动中使用私家车且充当驾驶员的求和总数不得超过家庭车辆数 V 。

第四组约束强制联合出行一致性，即对解码器生成的联合出行的每对成员，其出发时间、到达时间、方式分布与联合出行概率被绑定为相同值。

上述约束中，时序排序、属性可行与联合一致性为线性约束，车辆可用性则在方式与驾驶变量上为双线性，使得可行集 $\mathcal{F}$ 一般非凸，且难以直接求解。为此，本节设计一个两阶段的启发式求解流程，将可行性求解与梯度计算解耦，以提升求解的可处理性与稳定性。

4.4.2 两阶段优化算法

式 (4-24) 所表达的优化问题为带约束且一般非凸的优化问题，难以通过闭式求解。然而，为使家庭活动计划协调层能够与编码器与解码器端到端联合训练，进而以家庭活动计划协调的结果指导编码器与解码器的学习，又须将其作为可微优化层、使梯度能穿过该基于纳什议价的家庭活动计划协调层进行反向传播。为此，本节设计一个两阶段的启发式求解流程，将该纳什议价问题的求解与梯度计算解耦，在保障家庭活动协调可行性的同时，使梯度计算可微且稳定。

第一阶段，采用序列二次规划 (Sequential Quadratic Programming, SQP)^[158] 算法在该非凸问题中求一个可行解，但不追踪求解过程中的梯度。每次迭代以拟牛顿法 (Broyden-Fletcher-Goldfarb-Shanno, BFGS) 近似的海森矩阵与线性化约束构造二次规划子问题、给出步进方向，再经 Armijo 线搜索与对 $\mathcal{F}$ 的投影加以修正。该阶段可稳健地给出可行收敛点 $\mathbf{x}^{\text{conv}}$ ，但因在无梯度下运行而不可微。

第二阶段，将第一阶段的收敛点 $\mathbf{x}^{\text{conv}}$ 包裹于一个小型凸二次规划 (Quadratic Programming, QP)，作为可微优化层^[159] 求解，即在 $\mathbf{x}^{\text{conv}}$ 附近求一个调整量 $\mathbf{y}$ ：

$$\mathbf{y}^* = \arg \min_{\mathbf{y}} \frac{1}{2} \mathbf{y}^\top \mathbf{Q} \mathbf{y} + \mathbf{p}^\top \mathbf{y} \quad \text{s.t.} \quad \mathbf{G} \mathbf{y} \leq \mathbf{h}, \quad \mathbf{A} \mathbf{y} = \mathbf{b}, \quad (4-26)$$

式中， $\mathbf{y} \in \mathbb{R}^D$ 为相对收敛点 $\mathbf{x}^{\text{conv}}$ 的调整量， D 为决策向量 $\mathbf{x}$ 的维数。该二次规划是对“负纳什目标与一个近端正则项之和”在 $\mathbf{x}^{\text{conv}}$ 处的局部二次近似：近端正则项 $\frac{\rho}{2} \|\mathbf{x} - \mathbf{x}^{\text{d}}\|^2$ 以系数 $\rho > 0$ 惩罚解偏离解码器输出 $\mathbf{x}^{\text{d}}$ ，使协调解在改善纳什目标

的同时不过度偏离解码器生成的原始的活动计划； ρ 即近端权重，其值越大，协调解越贴近 $\mathbf{x}^d$ 、所作调整越保守。将 $\frac{\rho}{2}\|\mathbf{x} - \mathbf{x}^d\|^2$ 代入 $\mathbf{x} = \mathbf{x}^{\text{conv}} + \mathbf{y}$ 并展开后，将与 $\mathbf{y}$ 有关的线性部分和二次部分分别并入 $\mathbf{p}$ 和 $\mathbf{Q}$ ，线性项 $\mathbf{p} = \rho(\mathbf{x}^{\text{conv}} - \mathbf{x}^d)$ 为该近端项在 $\mathbf{x}^{\text{conv}}$ 处的梯度，将修正量系于 $\mathbf{x}^d$ 。曲率 $\mathbf{Q}$ 为负纳什目标的局部海森与近端项之和，并构造为对角阵 $\mathbf{Q} = \text{diag}(q_1, \dots, q_D)$ ，其第 i 项元素 $q_i = 1/(U_{n(i)} - U_{n(i)}^0)^2 + \rho$ 将对数效用的二阶曲率 $\partial^2[-\log(U_n - U_n^0)]/\partial U_n^2 = 1/(U_n - U_n^0)^2$ 与近端权重相加，其中 $n(i)$ 将第 i 个决策变量映射到其所属成员。该曲率含义有二：成员的效用增益 $U_n - U_n^0$ 越小（越接近分歧点），其曲率越大、对应变量的调整越被收紧，从而优先保护增益微薄的成员，契合纳什议价均衡分配增益的本意；而 $+\rho$ 项确保 $\mathbf{Q} \succ \mathbf{0}$ ，使二次规划严格凸、求解稳定。矩阵 $\mathbf{G}, \mathbf{h}, \mathbf{A}, \mathbf{b}$ 则为可行集 $\mathcal{F}$ 在 $\mathbf{x}^{\text{conv}}$ 处对激活（取等）约束的线性化，分别给出不等式约束 $\mathbf{G}\mathbf{y} \leq \mathbf{h}$ 与等式约束 $\mathbf{A}\mathbf{y} = \mathbf{b}$ 。

为使协调解 $\mathbf{x}^* = \mathbf{x}^{\text{conv}} + \mathbf{y}^*$ 的梯度能回传至编码器与解码器，本节进而对式 (4-26) 的卡罗需-库恩-塔克 (Karush-Kuhn-Tucker, KKT) 条件求微分。在最优点 $(\mathbf{y}^*, \boldsymbol{\lambda}^*, \boldsymbol{\nu}^*)$ ($\boldsymbol{\lambda}^*, \boldsymbol{\nu}^*$ 分别为不等式与等式约束的乘子)，KKT 系统为：

$$\begin{aligned} \mathbf{Q}\mathbf{y}^* + \mathbf{p} + \mathbf{G}^\top \boldsymbol{\lambda}^* + \mathbf{A}^\top \boldsymbol{\nu}^* &= \mathbf{0}, \\ \text{diag}(\boldsymbol{\lambda}^*)(\mathbf{G}\mathbf{y}^* - \mathbf{h}) &= \mathbf{0}, \quad \mathbf{A}\mathbf{y}^* = \mathbf{b}. \end{aligned} \quad (4-27)$$

下述命题在一般情形下确立 QP 解关于数据 $(\mathbf{Q}, \mathbf{p})$ 的可微性，并给出雅可比的求解式。

定理 4.1 (QP 解的可微性)： 设 $\mathbf{Q} \succ \mathbf{0}$ ， $\mathbf{A}$ 的行与激活不等式约束的梯度线性无关，且在 $(\mathbf{y}^*, \boldsymbol{\lambda}^*, \boldsymbol{\nu}^*)$ 处严格互补成立。则解映射 $(\mathbf{Q}, \mathbf{p}) \mapsto \mathbf{y}^*$ 在当前数据邻域内连续可微，其微分满足线性系统

$$\begin{bmatrix} \mathbf{Q} & \mathbf{G}^\top & \mathbf{A}^\top \\ \text{diag}(\boldsymbol{\lambda}^*)\mathbf{G} & \text{diag}(\mathbf{G}\mathbf{y}^* - \mathbf{h}) & \mathbf{0} \\ \mathbf{A} & \mathbf{0} & \mathbf{0} \end{bmatrix} \begin{bmatrix} d\mathbf{y}^* \\ d\boldsymbol{\lambda}^* \\ d\boldsymbol{\nu}^* \end{bmatrix} = \begin{bmatrix} -d\mathbf{Q}\mathbf{y}^* - d\mathbf{p} \\ \mathbf{0} \\ \mathbf{0} \end{bmatrix}, \quad (4-28)$$

从而 $\mathbf{y}^*$ 关于 $\mathbf{p}$ 与 $\mathbf{Q}$ 的雅可比可由以相应右端项求解式 (4-28) 得到。

证明. 对式 (4-27) 三个 KKT 等式关于数据 $(\mathbf{Q}, \mathbf{p})$ 与解 $(\mathbf{y}^*, \boldsymbol{\lambda}^*, \boldsymbol{\nu}^*)$ 取全微分、并固定 $(\mathbf{G}, \mathbf{h}, \mathbf{A}, \mathbf{b})$ ：平稳性条件给出 $d\mathbf{Q}\mathbf{y}^* + \mathbf{Q}d\mathbf{y}^* + d\mathbf{p} + \mathbf{G}^\top d\boldsymbol{\lambda}^* + \mathbf{A}^\top d\boldsymbol{\nu}^* = \mathbf{0}$ ，互补松弛给出 $\text{diag}(\boldsymbol{\lambda}^*)\mathbf{G}d\mathbf{y}^* + \text{diag}(\mathbf{G}\mathbf{y}^* - \mathbf{h})d\boldsymbol{\lambda}^* = \mathbf{0}$ ，原始可行性给出 $\mathbf{A}d\mathbf{y}^* = \mathbf{0}$ ，恰为式 (4-28)。在所设约束规范与严格互补下，左端 KKT 矩阵非奇异^[160]，由隐函数定理即得结论。 [证毕]

求解式 (4-28) 需对完整 KKT 矩阵作因式分解，其运算过程涉及激活约束的所有决策变量。本文构造的对角形式的 $\mathbf{Q}$ 允许一个更简单的特例，也是本文用于计算反向传播梯度的方法，具体如下：

定理 4.2 (对角特例): 进一步设 $\mathbf{Q} = \text{diag}(q_1, \dots, q_D)$ 且 $q_i > 0$, 并设最优点无激活约束, 即 $\lambda^* = \mathbf{0}$ 且局部模型中不含等式约束。则解具有闭式 $\mathbf{y}^* = -\mathbf{Q}^{-1}\mathbf{p}$, 即 $y_i^* = -p_i/q_i$, 且雅可比化简为

$$\frac{\partial \mathbf{y}^*}{\partial \mathbf{p}} = -\mathbf{Q}^{-1}, \quad \frac{\partial y_i^*}{\partial q_j} = -\delta_{ij} \frac{y_i^*}{q_i}, \quad (4-29)$$

式中, δ_{ij} 为克罗内克记号。

证明. 当 $\lambda^* = \mathbf{0}$ 且无等式约束时, 式 (4-27) 的 KKT 系统化为平稳性条件 $\mathbf{Q}\mathbf{y}^* + \mathbf{p} = \mathbf{0}$, 按坐标解耦为 $q_i y_i^* + p_i = 0$, 即 $y_i^* = -p_i/q_i$ 。直接求导得 $\partial y_i^*/\partial p_j = -\delta_{ij}/q_i$, 即 $\partial \mathbf{y}^*/\partial \mathbf{p} = -\mathbf{Q}^{-1}$; 又 $\partial y_i^*/\partial q_j = \delta_{ij} p_i / q_i^2 = -\delta_{ij} y_i^* / q_i$ 。 [证毕]

本文反向传播以命题4.2作为命题4.1的对角近似: 忽略式 (4-28) 中由激活约束导致的变量耦合。前向解不受该近似影响, 其可行性由 SQP 阶段与带约束 QP 求解确定。给定来自损失的梯度 $\partial \mathcal{L} / \partial \mathbf{y}^*$, 式 (4-29) 的闭式经链式法则将其传播至 QP 数据:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{p}} = -\mathbf{Q}^{-1} \frac{\partial \mathcal{L}}{\partial \mathbf{y}^*}, \quad \frac{\partial \mathcal{L}}{\partial q_i} = -\frac{y_i^*}{q_i} \frac{\partial \mathcal{L}}{\partial y_i^*}. \quad (4-30)$$

由于线性项 $\mathbf{p} = \rho(\mathbf{x}^{\text{conv}} - \mathbf{x}^{\text{d}})$ 依赖解码器输出 $\mathbf{x}^{\text{d}}$ ($\partial \mathbf{p} / \partial \mathbf{x}^{\text{d}} = -\rho \mathbf{I}$), 对角曲率 q_i 经成员效用增益 $U_n - U_n^0$ 依赖可学习的效用参数, 故第一式将梯度回传至解码器 (进而编码器), 第二式更新效用参数。如此既避免展开求解的不稳定, 又免去对完整 KKT 系统的因式分解。

综上, 基于纳什议价的家庭活动计划协调层的最终输出如下:

$$\mathbf{x}^* = \mathbf{x}^{\text{d}} + (\mathbf{x}^{\text{conv}} - \mathbf{x}^{\text{d}})_{\text{detach}} + \mathbf{y}^*(\mathbf{x}^{\text{d}}), \quad (4-31)$$

式中, $(\cdot)_{\text{detach}}$ 表示在反向传播时截断该项的梯度, 即前向保留其数值、反向将其视为常数。该式以直通 (straight-through) 方式结合两个阶段的结果。

前向时, 三项相加为 $\mathbf{x}^{\text{d}} + (\mathbf{x}^{\text{conv}} - \mathbf{x}^{\text{d}}) + \mathbf{y}^* = \mathbf{x}^{\text{conv}} + \mathbf{y}^*$, 即该层的输出恰为第一阶段的可行解 $\mathbf{x}^{\text{conv}}$ 经第二阶段调整 $\mathbf{y}^*$ 修正后的结果, 从而严格保持可行性。

反向时, 因 $(\mathbf{x}^{\text{conv}} - \mathbf{x}^{\text{d}})_{\text{detach}}$ 不传梯度, 对解码器输出求导得 $\partial \mathbf{x}^* / \partial \mathbf{x}^{\text{d}} = \mathbf{I} + \partial \mathbf{y}^* / \partial \mathbf{x}^{\text{d}}$ 。其中, 单位阵 $\mathbf{I}$ 来自直通项 $\mathbf{x}^{\text{d}}$, 将上游梯度直接回传至解码器、绕开不可微的收敛点 $\mathbf{x}^{\text{conv}}$; $\partial \mathbf{y}^* / \partial \mathbf{x}^{\text{d}}$ 则由式 (4-30) 经线性项 $\mathbf{p} = \rho(\mathbf{x}^{\text{conv}} - \mathbf{x}^{\text{d}})$ 给出。此外, $\mathbf{y}^*$ 还经对角曲率 q_i 依赖可学习的效用参数, 故梯度同时回传至效用参数。

该设计的关键在于: 第一阶段为求可行性而在无梯度下运行, $\mathbf{x}^{\text{conv}}$ 本身不可微; 直通构造使前向输出仍取该可行解, 又借 $\mathbf{x}^{\text{d}}$ 与 $\mathbf{y}^*$ 两条可微路径将可行性与协调信号回传。由此, 纳什议价层整体保持可微, 可与编码器、解码器端到端联合训练。

4.5 损失函数与模型训练策略

综合以上，本文提出的 CoHACT 模型由编码器、解码器与家庭活动计划协调层组成。编码器与解码器负责生成每位成员的活动链，家庭活动计划协调层则在家庭内部施加约束、协调成员间的活动计划。本节设计损失函数以监督各成员的活动计划预测，并给出训练策略。

记 $\mu_{n,t} = \mu_n^{\text{mem}} \cdot \mu_{n,t}^{\text{act}}$ 标识成员 n 的第 t 个活动是否有效， $N_v = \sum_{n,t} \mu_{n,t}$ 为一个家庭内有效的成员-活动位置数。下述各属性损失均按 $\mu_{n,t}$ 掩码、并对 N_v 归一，使填充的无效活动不参与损失计算。

针对出发时间与到达时间两个连续属性，采用 Smooth L_1 损失—其在误差较小时为平方误差、较大时退化为线性，以降低大偏差样本的影响：

$$\mathcal{L}_{\text{time}} = \frac{1}{N_v} \sum_{n,t} \mu_{n,t} [\text{SL}_1(\hat{s}_{n,t} - s_{n,t}) + \text{SL}_1(\hat{e}_{n,t} - e_{n,t})], \quad (4-32)$$

其中逐元素的 Smooth L_1 函数定义为

$$\text{SL}_1(x) = \begin{cases} \frac{1}{2}x^2, & |x| < 1, \\ |x| - \frac{1}{2}, & |x| \geq 1. \end{cases} \quad (4-33)$$

式中， $\hat{s}_{n,t}, \hat{e}_{n,t}$ 与 $s_{n,t}, e_{n,t}$ 分别为预测与真实的出发、到达时间，均在标准化空间中度量； x 表示预测误差。Smooth L_1 对预测误差分段取值：当误差较小 ($|x| < 1$) 时取平方形式 $\frac{1}{2}x^2$ ，在零点附近平滑可导、且梯度与误差成正比，利于对小误差的精细拟合；当误差较大 ($|x| \geq 1$) 时退化为线性形式 $|x| - \frac{1}{2}$ ，使其梯度有界（恒为 ± 1 ），从而抑制少数大偏差样本对训练的过度主导。

针对活动目的、出行方式、驾驶与联合出行四个离散属性，考虑到其类别高度不平衡（如多数活动非联合、多数出行者非驾驶员），故采用焦点损失（Focal Loss）^[146]，以降低易分类多数类的权重、聚焦于难分类的少数类：

$$\text{FL}(p) = -\alpha(1-p)^\gamma \log p, \quad (4-34)$$

式中， p 为模型赋予真实类别的预测概率， α 与 γ 分别为焦点损失的平衡参数与聚焦参数。记 $\hat{\mathbf{x}}_{n,t}[x_{n,t}]$ 为真实类别 $x_{n,t}$ 的预测概率，四个离散属性共享如下形式，分别得到 $\mathcal{L}_{\text{purpose}}$ 、 $\mathcal{L}_{\text{mode}}$ 、 $\mathcal{L}_{\text{driver}}$ 与 $\mathcal{L}_{\text{joint}}$ ：

$$\mathcal{L}_x = \frac{1}{N_v} \sum_{n,t} \mu_{n,t} \text{FL}(\hat{\mathbf{x}}_{n,t}[x_{n,t}]), \quad x \in \{c, m, d, j\}. \quad (4-35)$$

针对目的地预测，考虑到其为在大规模候选小区集上的分类，采用预测目的地的分布（式（4-19））与真实小区之间的交叉熵损失监督：

$$\mathcal{L}_{\text{dest}} = -\frac{1}{N_v} \sum_{n,t} \mu_{n,t} \log P(z_{n,t}), \quad (4-36)$$

式中, $z_{n,t}$ 为真实目的地小区。

总训练目标为上述各项损失的加权和:

$$\mathcal{L} = \omega_{\text{time}}\mathcal{L}_{\text{time}} + \omega_c\mathcal{L}_{\text{purpose}} + \omega_m\mathcal{L}_{\text{mode}} + \omega_d\mathcal{L}_{\text{driver}} + \omega_j\mathcal{L}_{\text{joint}} + \omega_z\mathcal{L}_{\text{dest}}, \quad (4-37)$$

式中, $\omega_{\text{time}}, \omega_c, \omega_m, \omega_d, \omega_j, \omega_z$ 为权衡各项任务重要度的权重。

在训练策略方面, 本节采用以下两项训练措施。

其一, 自回归生成中, 每个活动以其先前活动为条件; 若训练时一律以真实的历史活动作为条件、而推断时只能以模型自身的预测作为条件, 二者分布不一致, 会导致推理阶段一旦出现偏差便沿活动计划逐步累积、放大的情况。为此, 解码器采用计划采样与自回归滚动预测: 随训练进程逐步以模型自身的预测替换真实历史活动, 使模型在训练中接触并适应自身(含误差)的预测, 从而缩小训练与推理的差距、提升在较长活动计划上的生成质量。

其二, 纳什议价协调层以解码器输出为分歧点, 并经两阶段优化求解与梯度回传; 在训练初期解码器输出尚不合理, 此时若启用该层, 协调求解将建立在无意义的预测之上、徒增计算开销, 其回传的梯度也会扰动编码器与解码器的早期学习。为此, 纳什议价层仅在前若干个编码器与解码器的迭代训练之后才启用, 以在较为合理的预测基础上进行家庭活动计划协调, 并将协调信号回传至编码器与解码器。

4.6 小规模算例实验

为系统评价本章提出的 CoHACT 框架的有效性, 本节以北京市为研究区域、基于 2023 年北京市居民出行调查数据设计小规模算例实验, 在测试集上对模型作全面检验。与第3章以静态社会经济属性为输出的人口合成不同, 活动计划生成的效果评价须同时回答三个问题:

其一, 生成的活动计划在个体层面是否真实, 即每位成员的出发与到达时间、活动目的、出行方式与目的地等属性的分布能否还原真实的活动计划;

其二, 考虑到本文旨在解决家庭级活动计划生成问题, 因此, 生成的活动计划在家庭层面是否协调, 即在不违反车辆可用性等家庭层面的约束的前提下, 车辆共享、联合出行与接送等家庭内部耦合关系能否被正确再现;

其三, 为验证本文提出的空间感知目的地注意力层的有效性, 生成的目的地在城市尺度上是否具有足够的空间精度, 即能否在数千个候选小区构成的大候选集上还原真实的目的地选择分布。

上述三个问题中, 后两个问题对应4.1节所述难点(2)的家庭协调生成与难点(3)的城市级目的地选择, 也是本章方法区别于既有个体级活动生成方法的核心

所在；因此，本节的评价不仅考察生成分布的整体保真度，也需要检验家庭协调与空间精度这两项本章方法相比既有方法的改进。

为此，本节依次从以下方面展开评估。首先，描述算例所需的家庭出行调查数据与小区级空间数据（4.6.1小节），并给出数据划分、基准模型、评价指标与消融设计等实验设置（4.6.2小节）。随后，通过多维度 SRMSE 指标与代表性基线的性能对比评估 CoHACT 的总体生成性能（4.6.3小节），并通过逐步消融实验评估提出的纳什议价协调层与空间感知目的地注意力层的贡献（4.6.4小节）。在此基础上，进一步从家庭级活动计划内部协调性（4.6.5小节）、个体级活动计划属性分布（4.6.6小节）以及目的地空间分布（4.6.7小节）三个角度，对生成活动计划的真实性、协调性与空间精度展开分析。

4.6.1 算例数据描述

本章算例所需数据包括家庭出行调查数据与交通小区（Traffic Analysis Zone, TAZ）级空间数据两类。前者提供家庭与成员的社会经济属性及其完整的活动-出行序列，是学习家庭级活动计划联合分布、训练与评价生成模型的基础；后者提供候选目的地集合及其用地构成、吸引力与地理阻抗等空间信息，支撑城市尺度上的目的地选择。下面分别说明两类数据及其预处理。

（1）家庭出行调查数据

家庭出行调查数据采用 2023 年北京市居民出行调查，调查期为 2023 年 4 月 7 日至 6 月 30 日，覆盖北京市全域，抽样率约 0.4%，共含 33169 户家庭与 79695 名个体。该调查与第3章人口合成所用数据相同，但本章关注的不再是家庭与成员的静态社会经济属性，而是家庭内每个成员的活动-出行记录。具体而言，调查数据可组织为家庭级、成员级与活动级三个层次：家庭级记录家庭规模、成员构成、收入水平与车辆拥有，刻画家庭的共享背景与资源约束；成员级记录年龄、性别、职业、持照状态、受教育程度与与户主关系，刻画成员的个体特征（家庭与成员的社会经济属性与第3章共用数据，此处不再赘述）；活动级则将每位成员活动链中的每个活动描述为出发时间、到达时间、活动目的（10 类）、出行方式（11 类）、驾驶标识、联合出行标识与目的地小区共七个属性，对应4.3节式（4-6）所定义的活动元组。其中，驾驶标识与联合出行标识直接记录了家庭内部的车辆使用与联合活动，为评价家庭协调性提供了真实参照。预处理时，连续变量（出发与到达时间）经 z-score 标准化，类别变量通过 one-hot 编码处理，以适配模型输入。

（2）交通小区级空间数据

为支撑城市尺度的目的地选择建模与评价，本章采用划分北京市域的 2006 个交通分析小区（Traffic Analysis Zone, TAZ）作为活动计划生成的候选目的地集。以

上交通小区依行政边界与用地特征划定，在中心城区更密更小、在郊区更疏更大，其疏密本身也侧面反映了活动与出行需求的空间分布。在此基础上，进一步采集两类空间特征以异质地刻画各交通小区的特征：（1）通过高德地图 API 采集的全市兴趣点（Point of Interest, POI）数据，共 1116297 个、归为 23 个大类，据以计算各小区的用地构成，支撑式（4-16）中的用地主题向量与目的吸引力向量；（2）交通小区两两间的出行阻抗（本章选取交通小区质心间的出行距离）构成的阻抗矩阵，为式（4-18）的地理阻抗惩罚提供数据支撑。上述空间数据使提出的 CoHACT 模型能够在数千个候选交通小区上区分各目的地的地理临近性与活动吸引力，是目的地注意力层的数据基础。北京市交通小区与兴趣点的空间分布如图 4-4 所示。




图 4-4 北京市交通分析小区与兴趣点空间分布

Figure 4-4 Spatial distribution of traffic analysis zones and points of interest in Beijing.

4.6.2 实验设置与评价指标

数据划分方面，对预处理后的 32174 户合格家庭，在各行政区内按 9:1 的比例随机划分为训练集与测试集。按行政区分层划分是为使训练集与测试集在空间分布上保持一致，避免因区域人口与出行特征的不均衡而高估或低估模型性能。最终测试集含 3219 户家庭，其 16288 条有效出行作为评价 CoHACT 模型以及基线模型的测试集。为避免信息泄漏，4.2 节中由高斯混合模型聚类得到的活动模式簇以及经蒸馏得到的活动模式预测模型 g_ϕ 均仅在训练集上拟合，随后在训练与推理过程中冻结模型权重，从而确保活动模式先验不携带测试集的信息。

实验环境方面，全部实验基于 PyTorch 实现，运行于配备 13th Gen Intel Xeon i9-13950HX CPU、64 GB 内存与 24 GB 显存 NVIDIA RTX 4090 GPU 的个人电脑。

CoHACT 的超参数由训练集上的五折交叉验证选取，主要取值见表 4-1。训练过程通过模型在验证集上的表现确定最优迭代轮数，并保存对应的模型权重，以避免过拟合。为保证提出的 CoHACT 模型与其他模型的可比性，后续各基准模型与消融变体均在同一训练集上、以相同的数据预处理与评价指标训练和测试。

表 4-1 CoHACT 模型超参数设置
Table 4-1 Hyperparameter settings of the CoHACT model.

超参数类型	超参数	取值
模型结构		
	模型维度 d_{model}	256
	属性嵌入维度	256
	注意力头数	16
	编码器 CGC 层数 L	2
	共享专家数 m_s	2
	任务专属专家数 m_k	2
	诱导点数 n_l	16
	解码器 Transformer 层数 L_d	16
	dropout 比率	0.3
活动模式与目的地		
	家庭级簇数 C_h	20
	个人级簇数 C_p	40
	LDA 主题数	12
损失函数		
	焦点损失平衡参数 α	0.25
	焦点损失聚焦参数 γ	2.0
训练参数		
	优化器	AdamW
	权重衰减	1×10^{-4}
	初始学习率	5×10^{-5}
	学习率调度	余弦退火
	训练轮数	500
	批规模	100
	梯度裁剪范数	1.0

评价指标方面，采用合成人口与活动生成研究中广泛使用的标准化均方根误差（Standardized Root Mean Square Error, SRMSE）度量生成分布与真实分布的差异。SRMSE 通过对真实频率作归一，使不同维度、不同稀疏程度的属性组合上的

误差具有可比性，其定义为：

$$\text{SRMSE} = \frac{\sqrt{\frac{1}{B} \sum_{b=1}^B (f_b^{\text{gen}} - f_b^{\text{real}})^2}}{\frac{1}{B} \sum_{b=1}^B f_b^{\text{real}}}, \quad (4-38)$$

式中， f_b^{gen} 与 f_b^{real} 分别为生成活动计划与真实活动计划落入交叉分类属性空间第 b 个区间的相对频率， B 为区间总数；SRMSE 越小，表示生成分布与真实分布越接近，取零时说明生成分布与真实分布完全一致。

由于本章关注的是家庭级活动计划生成，单一维度的 SRMSE 不足以全面刻画家庭级活动计划的生成质量，故从个体与家庭两个层面，由简到繁地计算多维度的 SRMSE。在个体层面，构造四个逐步纳入更多属性的维度子集：4D 子集涵盖出发时间、到达时间、出发地与目的地四项时空属性，刻画活动的时空属性；5D-purpose 与 5D-mode 子集在 4D 子集的基础上分别加入活动目的与出行方式，考察模型对行为属性的还原能力；8D-full 子集进一步纳入联合出行与驾驶标识，构成包含全部属性的最严格联合分布。随属性维度增加，交叉分类下的属性组合数迅速膨胀、对联合分布还原能力的要求也随之提高，因而由 4D 至 8D-full 的 SRMSE 变化可反映模型在高维联合分布上的稳健性。此外，单独计算剔除出发地与目的地的 6D 子集（即 8D-full 去除出发地与目的地属性），以评估非空间属性的拟合质量，从而间接评估目的地注意力层对空间维度的生成质量。

在家庭层面，为检验模型是否真正再现了家庭内部活动计划的协调结构，将活动计划按家庭聚合为五项家庭活动计划统计量，即家庭总出行数、联合出行比例、主导出行方式、主导活动目的与不同目的地数，并计算其交叉分布的 Household-SRMSE。该指标从家庭整体视角度量生成结果与真实调查的差异，与个体级 SRMSE 互补，共同构成对家庭级活动计划生成质量的多维度评价体系。

4.6.3 基准模型对比分析

由于目前尚无专为家庭级活动计划生成而设计的深度生成模型，本小节选取合成人口与活动生成研究中广泛采用的六个代表性深度生成模型作为基准。其中，生成对抗网络（Generative Adversarial Network, GAN）、Wasserstein GAN（WGAN）与变分自编码器（Variational Autoencoder, VAE）为非条件生成模型，直接学习活动-出行属性的联合分布；在此基础上，进一步引入它们以家庭与成员属性为条件输入的条件版本（CGAN、CWGAN、CVAE），以考察显式条件信息对生成质量的影响。

上述基准模型涵盖对抗式与变分式两大类主流生成范式及其条件化变体，能够较为全面地代表既有方法在该任务上的水平。为使性能差异归因于模型设计而

非模型参数规模，所有基准模型均在同一训练集上以相同的优化器设置与学习率训练，并配置与 CoHACT 相近的参数量。需要指出的是，这些基准均沿用既有研究将居民视作彼此独立样本的建模方式，缺乏对家庭内部活动计划协调的显式刻画，因而与本章方法的对比可直接反映家庭级活动计划协调建模所带来的价值。

表 4-2 给出 CoHACT 与六个基准模型在五个 SRMSE 子集及家庭层面 SRMSE 的多维度对比。总体来看，CoHACT 在全部子集、个体与家庭两个层面均显著优于全部六个基准模型，且其性能优势远超基准模型之间的性能差异，表明该性能提升来自模型本身的改进而非参数微调。

表 4-2 CoHACT 与基准模型的多维度 SRMSE 对比（值越小越优，最优模型以加粗标出）

Table 4-2 Comparison of multidimensional SRMSE values between CoHACT and the baseline models (lower values indicate better performance; the best-performing model is shown in bold).

模型	SRMSE (4D)	SRMSE (5D- purpose)	SRMSE (5D-mode)	SRMSE (8D)	SRMSE (6D)	Household- SRMSE
GAN	52.21	53.54	53.19	54.52	15.46	3.71
WGAN	55.08	56.57	56.18	57.67	17.40	3.88
VAE	52.80	54.17	53.80	55.17	13.95	4.30
CGAN	28.91	29.57	29.41	30.06	8.27	4.63
CWGAN	31.55	32.27	32.11	32.83	9.46	4.32
CVAE	31.66	32.41	32.22	32.95	8.31	4.17
CoHACT	1.69	1.82	1.86	1.95	4.31	1.48

具体到个体层面，CoHACT 将最严格的 8D-full 子集的 SRMSE 降至 1.95，约为最优基准模型（CGAN，30.06）的 1/15、最差基准模型（WGAN，57.67）的近 1/30；在 4D、5D-purpose 与 5D-mode 子集上同样保持 1.69~1.86 的较好性能，超越各基准模型一个数量级以上。值得关注的是，生成误差随属性维度呈现出逐渐增长的趋势，即，各基准模型的 SRMSE 由 4D 到 8D-full 持续上升（如 WGAN 由 55.08 升至 57.67、CGAN 由 28.91 升至 30.06），反映出在逐步纳入活动目的、出行方式、联合与驾驶标识后，问题的复杂度增加导致模型联合分布还原能力的下降；相比之下，CoHACT 由 4D 到 8D-full 仅由 1.69 微增至 1.95，几乎不随维度恶化。这一稳健性源于本章解码器以多任务注意力网络逐属性建模、并以自回归方式沿活动计划联合生成全部属性，使高维属性间的依赖得以保持。

进一步讨论个体层面 CoHACT 模型的优势，在移除出发地与目的地预测的 6D 子集上，CoHACT（4.31）虽仍最优，但其相对基准模型（8.27~17.40）的差距明显小于含空间预测的子集。与之相对，一旦将出发地与目的地纳入评价维度，基准

模型的误差便急剧上升——以 GAN 为例，其 SRMSE 由 6D 子集的 15.46 陡增至 8D-full 的 54.52，VAE、WGAN 等模型也呈现出相同的模式。这一模式说明，城市尺度下的目的地选择是基准模型误差的主要来源，也正是 CoHACT 优势最为显著的环节。在数千个候选交通小区构成的大规模候选集上，基准模型因缺乏有效的空间建模机制而损失大量精度，CoHACT 则凭借目的地注意力层将空间预测误差控制在较低水平，从而间接验证了该层的有效性（其贡献将在 4.6.4 小节的消融实验中进一步讨论）。

在家庭层面，CoHACT 的 Household-SRMSE 为 1.48，仍全面优于基准模型，约为最优基准（GAN，3.71）的 40%、最差基准（CGAN，4.63）的 1/3。值得注意的是，家庭层面 CoHACT 性能优势小于个体层面，其原因在于 Household-SRMSE 所聚合的五项家庭统计量（总出行数、联合出行比例、主导出行方式、主导活动目的与不同目的地数）中，多数特征可由个体级别边际分布近似还原，基准模型在这些维度上本已能取得尚可的匹配，故 CoHACT 的提升空间相对受限。即便如此，1.48 的 Household-SRMSE 仍较各基准降低逾一半，说明本章的家庭协调式解码器与纳什议价协调层不仅保证了个体属性的真实，也使家庭整体统计更贴近真实的家庭级活动计划。

此外，条件生成模型和非条件生成模型在个人和家庭层面上表现出的性能差异也值得关注。在个体层面的性能评估中，三个条件基准模型（CGAN、CWGAN、CVAE）的 SRMSE 显著优于其对应的非条件版本（如 8D-full 子集上 CGAN 的 30.06 远低于 GAN 的 54.52），说明以家庭与成员属性为条件输入确实能压缩生成空间、改善个体边际分布的匹配。然而，这一性能改善并未出现在家庭层面的评估中。三个条件模型的 Household-SRMSE 介于 4.17~4.63，略差于非条件模型的 3.71~4.30。上述个人层面与家庭层面性能的差异表明，仅将家庭属性作为条件输入，本身并不足以诱导生成合理的家庭级活动计划。究其原因，条件基准模型虽共享了家庭背景信息，但仍在各成员之间相互独立地采样，缺乏对成员间车辆共享、联合出行与接送等耦合关系的显式建模，故条件信息带来的改善仅停留在个体边际层面，甚至可能因强化独立采样下的个体最优而加剧家庭层面的不一致。这恰从反面印证了本章在解码器中引入跨角色注意力、并以纳什议价协调层显式建模家庭内部耦合的必要性。

4.6.4 消融实验分析

为进一步识别 CoHACT 中关键组件的贡献，考虑到编码器与解码器是活动链生成的主干，移除任一者都将使模型无法产出完整的活动计划，故本小节仅对基于纳什议价的**家庭活动计划协调层**与考虑空间异质性的目的地注意力层进行消融

实验分析。考虑到计算开销与消融的可解释性，每次消融实验从完整模型中移除一个组件，共计形成三种模型结构：CoHACT（完整模型）、CoHACT w/o Nash（移除基于纳什议价的家庭活动计划协调层）与 CoHACT w/o spatial（移除考虑空间异质性的目的地注意力层）。

表 4-3 给出三种模型配置在五个个人级属性子集上的 SRMSE 与 Household-SRMSE。总体而言，完整 CoHACT 在多数子集与家庭层面均取得最优，而两个组件的移除分别在不同维度上引起性能退化。

表 4-3 消融实验结果（最优模型以加粗标出）

Table 4-3 Results of ablation experiments (the best-performing model is shown in bold).

配置	SRMSE (4D)	SRMSE (5D- purpose)	SRMSE (5D-mode)	SRMSE (8D)	SRMSE (6D)	Household- SRMSE
CoHACT	1.69	1.82	1.86	1.95	4.31	1.48
CoHACT w/o Nash	1.67	2.02	2.00	2.14	5.62	2.18
CoHACT w/o spatial	1.98	2.10	2.12	2.22	3.81	1.70

首先，移除基于纳什议价的家庭活动计划协调层后，模型在 4D 子集上的性能基本不变（1.67 对 1.69），甚至性能表现略有提升，但在其余子集上的性能均明显变差，尤其是不预测出发地与目的地的 6D 子集（由 4.31 升至 5.62）与家庭层面的 Household-SRMSE（由 1.48 升至 2.18）。移除基于纳什议价的家庭活动计划协调层后的性能变化与该层的作用机理高度吻合。针对 4D 子集，纳什议价层经近端正则项使协调解整体贴近解码器输出，且纳什议价协调层要求的联合活动的时间与空间异质性仅针对小部分联合出行成员，对 4D 整体分布的净扰动较小。正因纳什议价协调层以极小的边际拟合代价换取成员间的时间一致，移除该层后时间的边际拟合反而回到解码器的最优，使 4D 略有改善。与之相对，性能退化集中于 6D 子集与 Household-SRMSE，原因分析如下：6D 子集相较 4D 子集额外纳入出行方式、联合出行与驾驶等行为属性，正是纳什议价层经车辆可用性约束与联合一致性约束（耦合成员间的方式与联合出行）最直接重塑的对象，而 Household-SRMSE 所聚合的指标也是家庭层面的协调结果，是纳什议价层主要施加约束的对象。因此，去掉纳什议价协调层后，家庭内部的行为协调与可行性显著下降，导致 6D 子集与 Household-SRMSE 的性能恶化。换句话说，纳什议价层以个体边际拟合的微小让步，换取了家庭内部行为协调与可行性的显著改善。

另外，移除考虑空间异质性的目的地注意力层后，模型的性能变化呈现出与

移除纳什议价层近乎相反的模式：所有含出发地和目的地预测的子集均显著变差（如 4D 由 1.69 升至 1.98、8D-full 由 1.95 升至 2.22、Household-SRMSE 由 1.48 升至 1.70），而无出发地和目的地预测的 6D 子集反而略有改善（由 4.31 降至 3.81）。这一“跷跷板”的现象源于多任务学习中任务间的梯度竞争。当解码器须同时承担目的地选择与其余属性预测时，规模庞大的目的地任务会主导模型的梯度更新，使模型在空间属性上拟合更优；一旦移除该任务，模型得以将训练重点集中于非空间属性，故 6D 子集的拟合反而更优，但损失了对城市尺度目的地预测的能力，使所有含出发地与目的地预测的空间精度明显下降。

综合来看，上述消融结果一方面验证了两个组件的贡献，另一方面也解释了 CoHACT 能在各维度上取得良好表现的原因。纳什议价层与目的地注意力层分别补足了基准模型在家庭活动计划协调与空间精度这两方面的短板，且二者作用维度近乎正交、互不干扰，故同时保留时，模型既能维持较好的空间预测精度、又能保证家庭级活动计划的协调与可行性。需要补充的是，本小节以 SRMSE 度量的是分布层面的模型性能，而纳什议价层对车辆可用性等硬约束的严格保障难以由分布指标完全体现，这一点将在 4.6.5 小节通过家庭级活动计划内部协调性的分析进一步检验。

4.6.5 家庭级活动计划内部协调性

与基准模型的多维度 SRMSE 对比实验已表明 CoHACT 在个体活动计划与家庭活动计划两个层面均取得远优于基准模型的性能，但 SRMSE 主要刻画生成的属性分布与实际分布的吻合程度，不能直接回答“生成的家庭级活动计划是否真正合理”这一问题。为此，本小节从车辆共享、联合出行、接送行为等角度选取六项刻画生成的家庭级活动出行计划特征的指标，主要分为两类：一类关注家庭活动计划的可行性，即驾驶人数与家庭车辆数的匹配；另一类关注家庭成员在活动安排上的相互配合程度，包括联合出行与接送等协调行为以及亲子在外时间的重叠。将 CoHACT 生成的家庭级活动计划与实际的家庭级活动计划逐一比较，对比结果如图 4-5 所示。




图 4-5 CoHACT 生成家庭级活动计划与实际分布对比

Figure 4-5 Comparison of household-level activity chain between CoHACT-generated and observed data.

在家庭级活动计划的可行性方面，选取统一家庭中同时驾车出行的成员数是否超过家庭车辆数作为指标（即是否存在车辆超配），刻画家庭车辆资源分配的可行性。如图 4-5(a) 所示，全部 3219 户生成的家庭活动计划均不存在车辆超配情况，与实际的家庭级活动计划完全一致，符合家庭车辆资源约束的硬性要求。上述生成的家庭级活动计划并无车辆超配的结果证明了基于纳什议价的家庭活动计划协调层的有效性。具体而言，作为对照，CoHACT 模型在移除纳什议价层后，存在车辆超配的家庭活动计划的占比升高至 17.3%。因此，基于纳什议价的家庭活动计划协调层是 CoHACT 保证家庭级活动计划可行性的关键所在，其通过满足家庭级的资源约束，确保了生成的家庭级活动计划的合理性。

在联合出行与接送行为方面，相应指标整体拟合情况良好，但存在一定程度

的不匹配。如图 4-5(b)~(e) 所示,相较于实际的家庭活动计划,CoHACT 模型生成了较多的具有少量联合出行与接送的家庭,低估了联合出行与接送较频繁的家庭数量。与之相反,图 4-5(f) 中,CoHACT 生成了较多的亲子在外时间重叠度较高的家庭。以上指标的不匹配的成因与联合出行行为本身的稀疏性有关。在实际的居民出行调查中,频繁开展联合出行与接送的家庭本属少数,4.5 节的焦点损失虽已在一定程度上缓解了类别不平衡,但自回归生成与纳什议价协调层仍倾向于产生较为保守的联合出行与接送水平,从而在生成的家庭级活动计划中略低估了联合出行与接送行为的强度。尽管如此,模型再现了各项指标分布的整体形态,说明 CoHACT 已能以合理精度刻画家庭的联合出行与接送行为。

综上,家庭级活动计划内部协调性的分析从具体的家庭联合活动层面印证了 SRMSE 所反映的家庭级优势:一方面,CoHACT 生成的家庭级活动计划严格遵守车辆共享这一家庭资源约束,与实际的家庭活动出行计划完全一致,凸显了纳什议价协调层在保证可行性上的有效性;另一方面,虽略有保守,但 CoHACT 模型可以较好地再现联合出行与接送等行为。这表明 CoHACT 生成的家庭活动计划不仅在分布统计上贴近真实调查的结果,也在家庭联合活动协调的行为机制上具备一定的可信度。

4.6.6 个体级活动计划属性分布

在确认 CoHACT 模型能够生成较为可信的家庭级活动计划的基础上,进一步考察生成的样本是否同时保持了个体级活动计划的属性分布。为此,将生成的个体活动计划与实际的个体活动计划在六个属性(出发地与目的地除外)的一维边际分布上逐一比较(图 4-6),并进一步比较以上属性衍生的出行距离分布(图 4-7)和活动时长分布(图 4-8),以检验生成样本在个体级活动计划属性分布上的真实性。




图 4-6 CoHACT 生成的活动计划与实际活动计划的一维边际分布对比

Figure 4-6 Comparison of one-dimensional marginal distributions between activity chains generated by CoHACT and observed activity chains.

图 4-6 的六个子图表明，生成活动计划与实际的活动在在这六个属性的边际分布上高度吻合。在时间属性上，出发时间与到达时间子图显示 CoHACT 准确再现了居民的一日的出行节律，尤其是早高峰与晚高峰构成的双峰形态。在活动目的、出行方式、是否为驾驶员与是否为联合出行四个类别属性上，CoHACT 模型生成的活动计划能够复现实际活动计划的主要类别分布。以活动目的为例，最为频繁出现的类别分布匹配情况良好，第二频繁出现类别的计数完全一致，但在部分少数类别上的拟合效果欠佳。其成因同样在于数据分布的不平衡，即，主导类别样本数量更多，模型在优化总体损失时更侧重对其拟合，尽管 4.5 节已引入焦点损失以提升出现频次较低的类别的权重，但稀有活动类型、出行方式等稀疏类

别的再现仍是活动生成中的公认难题。总体而言，尽管 CoHACT 生成的样本在部分稀有属性上的拟合效果欠佳，但仍能较好地再现个体级活动计划的属性的整体分布。

在出行距离与活动时长方面，生成的活动计划与实际活动计划的分布拟合情况也比较良好。图 4-7 显示生成的活动计划再现了真实出行距离分布的右偏形态与长尾特征，二者整体贴合，说明模型能够刻画出行距离短途为主、长途偶发的一般规律。两分布的主要差异在于极短距离处模型将过多出行集中于 1 km 以下，这与目的地选择中地理阻抗惩罚有关，即，阻抗惩罚在抑制不合理的长距离出行的同时，也使生成的目的地略向出发地的邻近区域集中，从而导致模型在一定程度上倾向于生成极短距离的出行。




图 4-7 真实调查与 CoHACT 生成样本的出行距离分布

Figure 4-7 Comparison of trip-distance distributions between household travel survey data and samples generated by CoHACT.

在活动时长方面，图 4-8 显示 CoHACT 生成的活动计划再现了真实分布的总体形态，如约 1 小时左右的较短的活动时长峰值、接近工作时长的较长活动时长峰值。需要注意的是，生成分布的长活动峰约后移 1 小时且更为集中，即，模型峰值约在 11 小时，而真实分布峰值约在 9~10 小时。这一偏移与出发时间、到达时间子图中略微右偏的晚高峰相互呼应。较晚的返回时刻意味着更长的在外活动时长，二者在逻辑上自洽，说明该偏差并非随机噪声，而是源于时间属性生成上的轻微后移。除这一偏移外，两个分布在活动时长分布上整体贴合良好。




图 4-8 真实调查与 CoHACT 生成样本的活动时长分布

Figure 4-8 Comparison of activity-duration distributions between household travel survey data and samples generated by CoHACT.

综合图 4-6、图 4-7 与图 4-8 的对比可见，CoHACT 在保证家庭级活动计划合理性的同时并未牺牲生成的活动计划在个体属性与真实分布的拟合度，说明模型在家庭级与个体级两个层面均能生成较为真实的活动计划。

4.6.7 目的地空间分布

基准模型的效果对比侧面说明了 CoHACT 模型在目的地选择上具有显著优势，但并未直接验证 CoHACT 生成的目的地分布到底是否与实际的目的地分布相符。为检验 CoHACT 中目的地注意力层的有效性，进一步检验生成目的地的空间精度。为此，在全市的 2006 个交通小区上将生成样本的目的地分布与真实数据的目的地分布进行比较。首先，绘制两者的空间分布图，并计算二者的频率之差，结果如图 4-9 所示。




图 4-9 目的地空间分布对比

Figure 4-9 Comparison of destination spatial distributions.

并从两个互补的角度加以评估：一是整体空间格局是否吻合，借助图 4-9 的空间分布与两分布间的 Jensen-Shannon (JS) 散度量；二是区域覆盖是否完整，借助图 4-10 的长尾覆盖加以检验。

图 4-9 表明，在总体空间格局方面，CoHACT 生成的目的地分布在全市尺度上与真实数据的目的地分布高度相似，二者均反映了城市中心处的高密度核心与外围的热点分布，且二者的频率之差几乎为零。计算两分布间的 Jensen-Shannon (JS) 散度结果表明，两分布见的 JS 散度仅为 0.0132，极接近于零，说明生成的目的地分布与真实的目的地分布在全市尺度上几乎相同。这一高空间保真度得益于本文提出的考虑空间异质性的目的地注意力层，该层将可学习的目的地嵌入、用地主题与目的吸引力（式 (4-16)）同地理阻抗惩罚（式 (4-18)）相结合，使模型在为各候选小区评分时既考虑其对特定活动目的的吸引力、又顾及由出发地到该小区的出行阻抗，从而在城市尺度的大候选集上准确还原目的地需求的分布。

然而，生成样本中仍存在少量缺失小区。如图 4-10 所示，生成样本再现了真实数据中被访问的 1370 个目的地小区中的 1230 个，覆盖率为 89.8%；而 140 个未被覆盖的小区均为真实数据中至多被访问十次的小区，合计仅占真实出行总量的极小部分。换句话说，被访问次数较多的目的地小区均被生成样本覆盖，模型仅在访问极其稀疏的长尾小区上存在遗漏。这一现象与前文类别属性中稀有类别被低估的机理一致。在以 Softmax 对全候选集评分的目的地预测中，访问次数极少的小区难以积累足够的训练信号，加之地理阻抗与吸引力机制本就倾向于将选择概率集中于地理邻近且具吸引力的小区。考虑到被遗漏的小区被访问次数极少，其缺失对全市目的地分布的整体保真度影响较小。




图 4-10 目的地区域覆盖的长尾验证

Figure 4-10 Long-tail validation of destination-zone coverage.

综上，针对目的地空间分布的分析表明，CoHACT 能够在城市尺度的大候选集上高保真地再现真实的目的地选择结果，仅在极少数被访问次数较低的小区上存在遗漏，验证了本章提出的考虑空间异质性的目的地注意力层在城市级目的地选择上的有效性。

4.7 大规模算例实验

4.6节的小规模算例实验已在测试集上验证了 CoHACT 的生成精度、家庭协调性与目的地空间保真度。虽然各项实验表明 CoHACT 在个体级与家庭级均能生成较为真实的活动计划，但其验证尺度（3219 户测试家庭）过小，难以为 MaaS 推广策略仿真优化提供覆盖全市人口的微观行为基础。因此，本节与第3章合成的城市级别虚拟人口相衔接，进一步开展大规模算例实验。通过该实验可检验 CoHACT 在城市尺度下的计算可扩展性、个体级属性分布的真实性以及目的地空间分布的合理性，从而为 MaaS 推广策略仿真优化提供可靠的微观行为基础。

考虑到 CoHACT 模型的效果已通过测试集进行了全面的检验，本节仅将其应用于第3章合成的全市家庭级虚拟人口，随后依次从生成规模与计算效率（4.7.2小节）、个体级活动计划合理性（4.7.3小节）与目的地空间分布合理性（4.7.4小节）三个方面展开验证。

4.7.1 算例设置

(1) 虚拟人口输入

大规模算例的生成对象为第3章 HiDiT 模型合成的家庭级虚拟人口，覆盖北京

市 16 个辖区、约 1400 万户家庭共 31582283 名虚拟居民，其家庭级与个人级社会经济属性的类别均与本章训练数据相同。与小规模算例的 3219 户测试家庭相比，本算例的生成对象在规模上扩大了三个数量级以上，且虚拟人口不携带任何真实的活动-出行记录，因而对 CoHACT 的工程可扩展性与泛化能力构成双重检验。

（2）工作地与上学地指派

CoHACT 的生成过程除家庭与成员的社会经济属性外，还须以每位成员的居住小区及其工作地或上学地锚点小区作为空间条件输入；而第3章的虚拟人口仅具有 1 km 栅格粒度的居住位置，且不含就业地与就学地信息。其中，居住地小区可通过栅格质心和交通小区的空间包含关系直接指派，但工作地与上学地的锚点小区则需通过目的地选择模型进行推断。基于 2023 年北京市居民出行调查，分别为就业者与学生标定工作地选择与上学地选择两个多项 Logit 目的地选择模型，再据两模型输出的选择概率为每位虚拟就业者与虚拟学生抽样锚点所在的交通小区。

两模型的备选集均为全市 2006 个交通小区，效用函数由四类核心变量构成，即居住小区与备选小区间的质心直线距离、备选小区的就业/上学吸引度（基于特征价格模型与地理加权回归度量的就业与学校设施价值）、小区规模与本区虚拟变量，并将收入、车辆拥有情况、年龄、学历与教育阶段等属性同小区间距离及就业/上学吸引度作交互，以刻画目的地选择的群体异质性。模型以居民出行调查中有效的 45047 名就业者与 6546 名学生为样本标定。

从标定与验证结果看，两模型核心系数的符号均与出行行为直觉一致（距离项显著为负，就业/就学吸引度、小区规模与在本区就业/就学哑元变量显著为正），交互项亦揭示出收入越高的就业者对长距离通勤容忍度越强、学段越高通学范围越大等合理的群体异质性。测试集验证结果表明，模型预测的期望通勤/通学距离与实测均值基本一致（预测期望通勤距离 5.63 km 对实际平均通勤距离 5.57 km，预测期望通学距离 4.65 km 对实际平均通学距离 4.38 km），具备为虚拟人口指派工作地/就学地的精度基础。据此将两模型应用于全体虚拟人口（其中就业者 2458.3 万人、学生 105.6 万人）。

（3）验证方式

与小规模算例不同，第3章生成的虚拟居民不存在真实的活动计划，故无法采用将生成的活动计划与真实活动计划对比的方式进行验证。因此，本节转而在分布层面将全市生成结果与居民出行调查数据的全体活动计划进行比较。

4.7.2 生成规模与计算效率

首先对生成城市级活动计划的可行性进行分析。表 4-4 汇总了北京市 16 个行政区的活动计划生成规模与耗时。CoHACT 共为 31582283 名虚拟居民生成 65190504

次出行，人均出行 2.064 次，较训练数据的 2.133 次仅低约 3.2%；分区来看，各辖区人均出行介于 2.028~2.099 次之间，未随辖区人口规模出现系统性漂移。计算效率方面，在单机单卡环境下生成全市虚拟人口的活动计划累计耗时 37.3 小时，平均每小时产出约 85 万名居民的完整活动计划。上述结果表明，CoHACT 的生成流程具备扩展至城市级人口的可行性。

表 4-4 大规模算例的分区生成规模与耗时

Table 4-4 Generation scale and runtime by district in the large-scale case study.

行政区	虚拟人口（人）	出行数（次）	人均出行（次）	耗时（小时）
朝阳区	5623754	11712852	2.083	5.2
海淀区	5333017	10972250	2.057	4.8
丰台区	3632221	7498486	2.064	7.3
昌平区	2709519	5573239	2.057	2.5
西城区	2302741	4762294	2.068	2.1
大兴区	2085396	4377605	2.099	3.8
通州区	1684398	3435647	2.040	1.8
东城区	1650724	3348462	2.028	3.2
顺义区	1493523	3059621	2.049	1.5
房山区	1400939	2916978	2.082	1.5
石景山区	1079065	2189187	2.029	0.9
密云区	666405	1372204	2.059	0.7
平谷区	617825	1260286	2.040	0.6
怀柔区	515737	1081304	2.097	0.6
延庆区	419452	872465	2.080	0.5
门头沟区	367567	757624	2.061	0.4
合计	31582283	65190504	2.064	37.3

4.7.3 个体级活动计划属性分布

考虑到4.6节已对 CoHACT 模型展开了较为全面的验证，本节仅在分布层面对大规模生成的活动计划进行验证。沿用4.6.6小节的验证方式，将大规模生成的活动计划与居民出行调查数据在六个属性（出发地与目的地除外）的一维边际分布上逐一比较（图 4-11）。须说明的是，因对比两侧的样本量相差悬殊（生成侧 65190504 次出行、居民出行调查侧 147322 条出行），各图纵轴以设定为对数坐标下的频率。




图 4-11 大规模生成活动计划与居民出行调查数据的一维边际分布对比

Figure 4-11 Comparison of one-dimensional marginal distributions between activity generated in the large-scale case study and household travel survey data.

图 4-11 表明，大规模生成的活动计划在六个属性的边际分布上均保持了与居民出行调查中的活动计划较为一致的整体形态。在时间属性上，出发时间与到达时间子图显示 CoHACT 在全市尺度上较为完整地复现了居民一日出行的双峰节律：两侧早高峰均位于 8 时、晚高峰均位于 18~19 时。在活动目的与出行方式两个类别属性上，主导类别及其排序均与居民出行调查一致：回家与工作居活动目的的前两位，步行、电动自行车与小汽车为份额最高的三种出行方式，地铁份额与居民出行调查数据几乎持平。偏差的方向则与小规模算例中已识别的生成精度特征一致，即高估电动自行车与小汽车所占份额，低估步行、自行车与公交的所占份额。在两个家庭协调相关属性上，驾驶标识的边际分布与参照接近；联合出行标

识则被部分低估。

以上对比结果表明，在城市级居民活动计划任务中，CoHACT 在个体级活动计划属性分布上仍保持了与居民出行调查数据的整体一致性，且偏差的方向与小规模算例中量化的生成精度特征一致。换言之，CoHACT 无需任何重新训练，即可在城市级人口上保持其在小规模算例中已验证的生成精度特征。

4.7.4 目的地空间分布

上一节针对 CoHACT 模型在个体级活动计划属性分布上的真实性进行了验证，本节进一步考察大规模生成的活动计划在目的地空间分布上的合理性。沿用4.6.7小节的验证方式，在全市 2006 个交通小区上将大规模生成样本的目的地分布与居民出行调查的目的地分布进行比较：绘制两者的空间分布并计算频率之差（图 4-12），进而计算两分布间的 JS 散度与热点小区重叠情况。




图 4-12 目的地空间分布对比

Figure 4-12 Comparison of destination spatial distributions.

图 4-12表明，在总体空间格局上，大规模生成的目的地分布与居民出行调查高度相似，即二者的目的地分布均集中于中心城区与外围部分交通小区，二者的空间分布在对数尺度下也呈现出一致空间分布模式（JS 散度为 0.0730）。具体而言，绝大多数小区目的地分布的频率之差接近零（差值绝对值不超过 5.2×10^{-3} ）。CoHACT 生成的样本共覆盖 1808 个目的地小区（占全部 2006 个小区的 90.1%），与居民出行调查包含的 1808 个小区几乎重合（共同的交通小区有 1802 个），未被覆盖的小区仍集中于访问极稀疏的长尾低吸引小区。

综上，CoHACT 在城市级人口上生成的活动计划在目的地空间分布上仍保持了与居民出行调查数据的整体一致性。

4.8 本章小结

本章针对 MaaS 推广策略仿真所需的高保真活动计划输入,研究了考虑家庭联合活动的家庭级活动计划生成问题。既有研究多以个体为基本生成单元,将居民视作彼此独立的样本,难以再现联合出行、车辆共享与接送等家庭联合活动行为,致使生成的活动计划在联合出行、接送与车辆分配等家庭级统计上产生偏差。围绕家庭与成员多层级信息的统一感知、多成员活动计划的协调生成以及城市级目的地选择的建模三方面困难,本章以第3章合成的家庭级虚拟人口为输入,提出了协调式家庭活动计划生成框架 (CoHACT),并以北京市为算例,依次开展了基于居民出行调查数据的小规模算例实验与面向全市虚拟人口的大规模算例实验。本章的主要工作与结论如下。

其一,针对家庭与成员多层级信息的统一感知,构建了融合家庭-成员特征的多任务编码器。该编码器以渐进分层提取结构为主体,将家庭表征与成员表征的提取建模为多任务学习问题,通过定制化门控机制显式分离共享专家与任务专属专家,缓解两类特征间的负迁移;其专家以诱导集合注意力块实现,使家庭成员表征对家庭内成员的次序保持置换等变、适应可变的家庭规模,并在聚合中令各成员蕴含家庭层面的共享信息。在此基础上,进一步由独立训练并冻结权重的活动模式识别模型构建家庭级与个人级活动模式先验,缓解由属性到活动链的“一对多”映射、压缩生成空间。

其二,针对家庭内多成员活动计划的协调生成,设计了考虑家庭联合活动的多任务学习解码器。该解码器先经任务特定注意力与跨角色注意力使各成员在生成前相互感知、形成蕴含家庭情境的协调成员特征,再以多任务注意力网络逐属性、自回归地同时生成全体成员的活动计划,并经自适应层归一化将活动模式先验注入生成过程。算例表明,CoHACT 在个体与家庭两个层面、全部属性组合维度下均显著优于 GAN、VAE 及其条件版本等六个基准模型:最严格的 8 维联合分布下 SRMSE 低至 1.95,约为最优基准 (CGAN, 30.06) 的 1/15;且生成误差几乎不随属性维度恶化 (由 4 维的 1.69 仅微增至 8 维的 1.95),表明逐属性、自回归的联合建模有效保持了高维属性间的依赖。

其三,针对家庭内部车辆共享、联合出行与接送等耦合关系硬约束的限制,提出了基于纳什议价的家庭活动计划协调层。该层将家庭活动计划协调建模为纳什议价问题,以解码器输出为分歧点,求解一个帕累托有效、个体理性且在成员间均衡分配效用增益的可行解,并经“序列二次规划求可行解、可微二次规划回传梯度”的两阶段算法实现与编码器、解码器的端到端联合训练,在严格满足车辆可用性等硬约束的同时最大化家庭整体效用。消融实验表明,移除该层后家庭层面的 Household-SRMSE 由 1.48 升至 2.18、6 维子集的 SRMSE 由 4.31 升至 5.62;家

庭级协调性分析进一步表明, CoHACT 生成的全部 3219 户家庭活动计划均不存在车辆超配, 与真实调查完全一致, 而移除该层后车辆超配家庭占比升至 17.3%, 凸显了该层在保证家庭级可行性上的关键作用。

其四, 针对城市级目的地选择的建模, 设计了考虑空间异质性的目的地注意力层。该层以可学习的目的地嵌入、用地主题向量与目的吸引力向量异质地表征候选小区, 并在注意力评分中融入地理阻抗惩罚与目的吸引力加成, 在数千个候选交通小区构成的大候选集上刻画情境依赖、空间异质的目的地选择, 同时以距离感知的出行方式预测头耦合目的地与出行方式预测。算例表明, CoHACT 生成的目的地分布与真实分布的 JS 散度仅为 0.0132、二者在全市尺度上几乎一致, 并完整覆盖了被访问次数较多的交通小区 (覆盖率 89.8%, 仅遗漏了至多被访问十次的长尾低访问需求小区); 消融实验中移除该层将导致所有含出发地与目的地预测的子集精度显著变差, 从正反两方面验证了该层在城市级目的地选择上的有效性。

其五, 为检验方法在城市级应用中的可扩展性与泛化能力, 开展了面向全市虚拟人口的大规模算例实验。经居住小区匹配与基于新标定目的地选择模型的工作地/就学地指派等前期数据处理工作, 将训练完成的 CoHACT 不经任何重新训练直接应用于第3章合成的约 1400 万户虚拟家庭, 在单机环境下以 37.3 小时为 31582283 名虚拟居民生成了由 65190504 次出行构成的活动计划, 人均出行次数 (2.064 次) 与居民出行调查基本一致。分布层面的对比验证表明, 生成结果在时间节律、类别构成、目的地空间分布上均保持了与真实出行行为一致的总体结构, 偏差方向与机理均与小规模算例一致。

综上, 本章提出的 CoHACT 框架能够在严格满足家庭资源约束与联合活动约束的前提下, 生成个体属性真实、家庭内部活动协调且目的地空间精度高的家庭级活动计划。所生成的活动计划完整刻画了每位居民一日之内的活动-出行序列及其家庭协调关系。大规模算例产出的覆盖全市的活动计划可直接作为第7章推广策略仿真优化中智能体现有的出行模式, 为 MaaS 推广策略仿真界定了各智能体向 MaaS 转移的具体情境, 与3章合成的虚拟人口共同构成了仿真的微观行为基础。

5 MaaS 多阶段采纳意愿的分阶段建模

5.1 本章引论

第3章与第4章分别从“人”与“出行”两个维度为 MaaS 推广策略仿真奠定了城市级别仿真的微观数据基础。然而,上述虚拟人口及其活动计划所刻画的,是尚未引入 MaaS 时居民的出行现状,无法回答推广策略仿真的核心问题——当 MaaS 进入这些居民既有的活动-出行情境时,他们是否愿意、又在多大程度上愿意由既有方式转向 MaaS。换言之,活动计划虽界定了每位居民向 MaaS 转移的具体情境,却未给出其在该情境下采纳 MaaS 的行为规则。因此,在开展第7章的推广策略仿真之前,须进一步了解这些居民在其既有活动-出行模式下对 MaaS 的采纳意愿。这一行为基础由本章与第6章共同刻画,二者分别从“分阶段建模”与“一体化建模”两种视角对 MaaS 的多阶段采纳意愿加以建模,本章采用前者。

综上,本章聚焦研究内容(3): MaaS 多阶段采纳意愿的建模解析。既有研究表明,用户对 MaaS 的采纳并非一蹴而就的单次决策,而是一个循序渐进的过程。在尚未接触 MaaS 的初始阶段,用户往往先在某次出行中以按次付费(Pay-As-You-Go, PAYG)的方式尝试 MaaS 提供的多模式出行服务,从而形成对 MaaS 的初始印象^[77];在此基础上,结合初次使用 MaaS 获得的体验,用户才会进一步考虑是否订阅月度 MaaS 套餐^[104],以在更长的时间尺度上享受 MaaS 带来的便利与优惠^[104]。前者决定 MaaS 能否成功吸引用户“试用”,是用户 MaaS 采纳的起点;后者决定 MaaS 能否将“试用者”转化为“长期用户”,是 MaaS 可持续运营的关键。因此,刻画用户由既有出行方式向 MaaS 提供的多模式服务转移,以及由单次出行中的转移向 MaaS 套餐长期订阅的多阶段采纳意愿,是制定精准的 MaaS 推广策略、推动 MaaS 持续发展的行为基础,也是后续第7章所述 MaaS 推广策略仿真刻画智能体采纳决策的微观行为依据。下面对 MaaS 多阶段采纳意愿建模问题的特性进行简要分析。

首先,根据上述分析,用户对 MaaS 的采纳行为具有阶段性特征,且前一阶段的采纳意愿会影响后一阶段的采纳意愿。具体而言,用户在单次出行场景下对 MaaS 多模式出行服务的转移意愿,构成其对 MaaS 的“初始印象”;这一初始印象既反映了 MaaS 多模式出行服务相对于既有单一出行方式的额外效用,又会进一步影响用户在套餐订阅阶段的决策^[118]。若独立地看待两个阶段,难以解释为何同一用户会在不同 MaaS 使用阶段中表现出截然不同的行为模式,也无法回答“如何通过改善单次出行体验来撬动套餐订阅”这一对 MaaS 运营至关重要的问题。因此,

理解用户对 MaaS 的多阶段采纳意愿须显式地刻画“单次转移”与“套餐订阅”两阶段之间的内在联系。

其次,用户的 MaaS 采纳意愿在不同群体间存在显著的异质性。一方面,采纳意愿受年龄、性别、收入、受教育程度等社会经济属性,以及主要出行方式、出行频率、出行距离等出行模式属性的共同影响^[78,79];另一方面,用户对出行的内在态度(如对性价比、新技术、计划性与环保的偏好)亦深刻地塑造其对 MaaS 的接受程度^[86]。这种由可观测属性与不可观测态度共同驱动的异质性,意味着在刻画用户对 MaaS 的多阶段采纳意愿时,须考虑不同群体的差异化偏好,以为制定人群差异化的 MaaS 推广策略提供依据。

最后,由于目前国内尚无成熟的 MaaS 平台,难以获得真实的揭示偏好(Revealed Preference, RP)数据,须借助陈述偏好(Stated Preference, SP)实验获取用户在假想的 MaaS 情境下的选择行为^[86,88]。如何设计能够同时捕捉用户的单次转移意愿、套餐订阅意愿及二者关联的 SP 实验,是开展多阶段采纳意愿建模的前提。

尽管近年来有大量研究关注 MaaS 的采纳意愿,但仍存在不足。既有研究多集中于 MaaS 套餐订阅或潜在用户识别^[79,81,104],对单次出行场景下用户的 MaaS 转移意愿关注不足,更鲜有研究刻画“单次转移”与“套餐订阅”两阶段间的内在联系。为此,本章提出 MaaS 多阶段采纳意愿的分阶段建模框架,其总体思路如图 5-1 所示。该框架由相互衔接的三部分构成,与上述三方面特性逐一对应。

(1) 针对 SP 实验设计这一前提,设计两步式 SP 调查。在单次出行场景中,先后向受访者呈现无 MaaS 与含 MaaS 两个出行情境,使其聚焦于 MaaS 多模式出行服务与既有方式的差异;继而在受访者形成初始印象后,继续向其呈现具有不同特色的 MaaS 套餐选项,调查其 MaaS 套餐订阅行为。该设计既可分别获取单次出行情景与套餐订阅两阶段的选择数据,又可将受访者在单次出行场景下形成的转移意愿作为关联变量,刻画两阶段间的内在联系。

(2) 针对用户在单次出行场景下对 MaaS 转移意愿及其偏好异质性,以混合选择模型(Hybrid Choice Model, HCM)为框架,将态度潜变量、出行惯性变量与偏好延续变量变量纳入潜在分类 Logit(Latent Class Logit, LCL)模型,识别具有差异化转移偏好的潜在用户类别,并据此构建 MaaS 转移意愿指数以量化用户的转移意愿,作为用户在单次出行场景下对 MaaS 的初始印象的度量。

(3) 针对在单次出行场景后的用户的 MaaS 套餐订阅意愿及其偏好异质性,构建基于初始印象的融合潜变量的潜在分类(Latent Class with Latent Variable, LCLV)模型。具体而言,以单次出行场景下估计的转移意愿作为初始印象的度量,并将其作为划分潜在类别的关键变量,以进一步刻画不同群体在套餐订阅上的异质偏好,并据此辨识促进或阻碍 MaaS 套餐订阅的关键因素,为制定精准的 MaaS

推广策略提供依据。




图 5-1 MaaS 多阶段采纳意愿的分阶段建模总体框架

Figure 5-1 Overall framework for stage-wise modeling of multi-stage MaaS adoption intention.

5.2 MaaS 多阶段采纳意愿调查与特征分析

为获取用户在 MaaS 情境下的多阶段采纳行为数据，本节设计并实施了一项两步式的 SP 调查。本节首先介绍调查问卷的总体结构与 SP 实验的设计思路，随后阐述调查的实施过程与样本的统计特征，最后对多阶段选择行为的总体特征加以分析，为后续两阶段 MaaS 采纳意愿建模奠定数据基础。本次调查所采用的完整问卷（含个人及家庭信息、出行模式、出行意愿与出行态度各部分题项，以及单次出行情景与订阅服务情景两类 SP 实验的情境示例）参见附录 A。

5.2.1 两步式陈述偏好实验设计

鉴于本文研究的目标城市为北京，而北京尚无成熟运营的 MaaS 平台、难以获取 RP 数据，本节设计 SP 实验以采集所需信息^[86,88]。问卷共由六个部分构成，其总体结构如图 5-2 所示。问卷开篇介绍了调查机构、调查目的与数据用途；第一部分采集受访者的社会经济属性，包括年龄、性别、受教育程度、职业与收入；第二部分采集受访者的出行模式，包括主要出行方式、平均出行距离与各方式的出行频率；第三、四部分分别调查单次出行场景下的用户对 MaaS 多模式出行服务的选择行为与 MaaS 套餐订阅行为，是问卷的核心；第五部分采用 5 级李克特量表采集受访者对出行的态度，共含 25 条态度陈述。考虑到 MaaS 目前市场渗透率较低的

现状，问卷在进入 SP 实验前，先以图文方式介绍 MaaS 的概念与功能，以帮助受访者代入 MaaS 情境、提升受访者回答的可信度^[91,161]。




图 5-2 调查问卷总体设计框架

Figure 5-2 Overall framework for questionnaire design.

接下来,详细介绍第三、四部分的 SP 实验设计。在第三部分中,首先构建一个不含 MaaS 出行服务的出行情境,要求受访者从既有方式中选择其偏好的出行方式;随后在保持情境与服务水平变量不变的前提下,向该情境额外加入四种 MaaS 多模式出行服务选项,并要求受访者再次从既有的出行方式与新增的 MaaS 选项中进行选择。如此,受访者面对的并非将既有方式与 MaaS 选项并列的单一情境^[87],而是两个先后呈现、仅在是否含 MaaS 上存在差异的情境,从而更易于思考 MaaS 所带来的额外效用。两步式 SP 实验的界面示例如图 5-3 所示。受访者在两个情境中的选择结果经组合即可判定其是否发生转移:若两次选择相同,则记为“不转移”;若第二次选择了某一 MaaS 选项,则记为转移至相应选项。受访者在无 MaaS 情境中的首次选择结果,亦可作为刻画其出行习惯的变量纳入后续模型。




图 5-3 第三部分单次出行情境 SP 实验界面示例

Figure 5-3 Example of the one-trip SP experiment in Part III.

在情境设计上，为使假想情境尽可能贴近现实，综合考虑了出行距离、出发时间与出行目的三类情境变量。结合北京居民的常见出行场景^[162]，设置了 5 个出行距离情景（<10、10-20、20-30、30-40、>40 km）、4 个出发时间情景（8:00-10:00、17:00-19:00、10:00-17:00、晚于 23:00）与 2 个出行目的情景（通勤与非通勤）。与 5 个出行距离情景相对应，选取了 5 对起讫点（Origin and Destination, OD），并隐去其真实位置，以避免受访者基于既有出行经验作答。在备选方案方面，无 MaaS 服务的情境参考高德地图的推荐，选取北京最具代表性的三种既有方式：私家车、

出租/网约车与公共交通（地铁/公交）；其依据有二：其一，依据 MaaS 集成度的分级，无集成的单一方式服务对应于 MaaS 的 0 级、可视为“无 MaaS”服务^[8,75]；其二，上述三种方式在北京的客运量与满意度均较高，是最具代表性的既有方式。含 MaaS 情境则在上述既有方式之外，加入四种以“公共交通 + 共享出行”为主的门到门 MaaS 多模式服务^[163]：地铁 + 公交（M1）、地铁 + 共享单车（M2）、地铁 + 出租/网约车（M3）与拼车合乘（M4）^[7,87,164]。各方案的服务水平（Level of Service, LOS）变量经高德地图 API 提取，部分属性的水平则在预设水平中选取。单次出行场景下各方案的属性水平如表 5-1 所示。

表 5-1 单次出行场景 SP 实验的属性水平设置
Table 5-1 Attribute levels in the one-trip SP experiment.

方案	属性	属性水平
两个选择情境中均纳入的既有方式		
私家车	停车与油耗费用	0、15、25 元
	出行时间	由高德 API 获取
出租/网约车	等待时间	3、5、10 min
	车内时间	由高德 API 获取
	出行费用	由高德 API 获取
地铁/公交	等待时间	5、10、15 min
	车内时间	由高德 API 获取
	出行费用	由高德 API 获取
	步行距离	由高德 API 获取
仅在含 MaaS 情境中纳入的 MaaS 多模式出行服务		
地铁 + 公交（M1）	等待时间	由各方式等待时间求和
	车内时间	高德 API 车内时间的 0.8、1、1.1 倍
	出行费用	高德 API 费用的 0.8、1、1.1 倍
地铁 + 共享单车（M2）	等待时间	由各方式等待时间求和
	车内时间	高德 API 车内时间的 0.8、1、1.1 倍
	出行费用	高德 API 费用的 0.8、1、1.1 倍
地铁 + 出租/网约车（M3）	等待时间	由各方式等待时间求和
	车内时间	高德 API 车内时间的 0.8、1、1.1 倍
	出行费用	高德 API 费用的 0.8、1、1.1 倍
合乘（M4）	车内时间	出租车出行时间的 1、1.1、1.2 倍
	出行费用	出租车出行费用的 0.4、0.6、0.8 倍

注：换乘时间已计入等待时间；出发时间晚于 23:00 的情境中，与公共交通相关的方式不可用。

在受访者完成第三部分、对 MaaS 形成初步认识后，第四部分收集其 MaaS 套

餐订阅行为。考虑到 MaaS 套餐（尤其是高服务水平套餐）价格较高、受访者作答时易产生困难，在呈现套餐之前先要求受访者回顾自身的出行需求。即，先回顾上一周公交、地铁、自行车、电动自行车与出租/网约车五种方式的出行次数，以辅助其估计月度各方式的出行需求；再据此估计上一月的出行花费。在此基础上，参照 MaaS 套餐应当各具特色的设计原则^[76,104,105]，设计了四种 MaaS 套餐：公交优先、地铁畅行、优惠出租与全能畅行。其中，公交优先以不限次的公交与共享单车为核心，辅以有限的地铁、共享电动自行车与合乘服务；地铁畅行较公交优先提供更高的地铁权益；优惠出租则提供更多的出租/网约车服务；全能畅行则提供最多的多模式出行服务、价格亦最高。各套餐的属性水平设置如表 5-2 所示，套餐中各类出行服务的购买成本依据北京的实际情况确定，如表 5-3 所示。

表 5-2 MaaS 套餐的属性水平设置
Table 5-2 Attribute levels of the MaaS bundles.

套餐	属性	属性水平
公交优先	不限次公交	包含
	不限次共享单车	包含
	月度地铁次数	10
	月度共享电动自行车次数	[0, 4, 8, 12]
	月度出租/网约车里程 (km)	[0, 70, 140, 175]
	价格系数	[0.8, 0.9, 1, 1.1, 1.2]
地铁畅行	不限次公交	包含
	不限次共享单车	包含
	月度地铁次数	60
	月度共享电动自行车次数	[0, 4, 8, 12]
	月度出租/网约车里程 (km)	[0, 70, 140, 175]
	价格系数	[0.8, 0.9, 1, 1.1, 1.2]
优惠出租	不限次公交	包含
	不限次共享单车	包含
	月度地铁次数	30
	月度共享电动自行车次数	[12, 16, 20, 24]
	月度出租/网约车里程 (km)	[350, 420, 490, 560]
	价格系数	[0.8, 0.9, 1, 1.1, 1.2]

续下页

(续表 5-2)

套餐	属性	属性水平
全能畅行	不限次公交	包含
	不限次共享单车	包含
	月度地铁次数	90
	月度共享电动自行车次数	[24, 28, 32, 36]
	月度出租/网约车里程 (km)	[520, 625, 695, 765]
	价格系数	[0.8, 0.9, 1, 1.1, 1.2]

注：价格系数为套餐总成本的缩放因子，套餐价格由套餐内各出行服务的购买成本之和乘以价格系数得到。

表 5-3 各类出行服务的购买成本

Table 5-3 Purchase costs of different travel services.

出行服务	购买成本
月度不限次公交	30 元
地铁	3 元/次
月度不限次共享单车	20 元
共享电动自行车	3 元/次
出租/网约车	2.24 元/km

考虑到各部分的属性水平组合数量庞大，且可能会生成支配方案。因此，为获取代表性情境，采用 D-最优设计^[165]加以筛选。最终，第三、四部分各生成 40 个情境组合：第三部分依出行距离分为 5 组、每组 8 个情境，每位受访者从每个出行距离情境中随机作答 1 题，共 5 题；第四部分同理，受访者从另外 40 个组合中随机作答 5 题。

5.2.2 调查实施与样本统计分析

本次调查于 2022 年 1 月至 2 月在北京实施，受访者经专业调查公司（问卷星）在线招募，完成问卷后获得一定的报酬。考虑到调查目标人群为 MaaS 的潜在用户，要求调查平台参照高德地图的用户画像招募受访者（考虑到高德已经实现了通过整合多种交通方式的出行规划服务，符合 MaaS 的第一级集成水平的概念^[8,75]）；同时，鉴于 SP 实验的设计以北京的实际情况为前提，要求受访者为北京居民，以排除不同城市因交通基础设施、土地利用等不同而产生的偏好差异^[94]。为保证数据质量，依据以下规则剔除存在逻辑问题的问卷，主要针对第三部分的选择结果：

其一，剔除在无 MaaS 情境中选择私家车但实际不拥有私家车的受访者；

其二，若受访者在含 MaaS 情境中未选择 MaaS 选项，则其在含 MaaS 情境中的选择应与无 MaaS 情境一致，否则视为无效（因除新增 MaaS 选项外，情境变量与既有交通方式的 LOS 变量均未改变）。

最终获得 1242 份有效问卷；其中，单次出行阶段经一致性检验后保留 5472 个有效选择观测，套餐订阅阶段共 6210 个观测样本。样本的社会经济属性分布如表 5-4 所示。

表 5-4 调查问卷样本社会经济属性的统计分布

Table 5-4 Distribution of socioeconomic characteristics in the survey sample.

变量	类别	样本占比 (%)	北京常住人口占比 (%)
性别	男	43.64	51.07
	女	56.36	49.93
年龄	<18	6.12	13.60
	18–24	23.35	6.80
	25–34	37.28	19.40
	35–44	21.50	17.60
	45–54	8.45	14.60
	55–60	2.17	9.30
	>60	1.13	18.70
受教育程度	研究生	13.69	—
	本科	57.57	—
	中专	14.41	—
	高中	6.92	—
	高中以下	7.41	—
	专业技术人员	3.30	—
职业	商业与服务业	12.32	—
	公司职员	52.01	—
	学生	15.86	—
	其他	16.51	—
	<6000	44.76	—
月收入（元）	6001–20000	49.60	—
	>20000	5.64	—
是否拥有私家车	是	47.67	—
	否	52.33	—
是否持有驾照	是	70.13	—
	否	29.87	—

续下页

(续表 5-4)

变量	类别	样本占比 (%)	北京常住人口占比 (%)
是否拥有自行车/电动自行车	是	66.43	—
	否	33.57	—
是否听说过 MaaS	是	57.97	—
	否	42.03	—

须指出的是,虽然收集到的样本与北京常住人口的统计分布存在一些差异,但考虑到北京常住人口的统计分布并不等同于 MaaS 潜在用户的分布,样本的代表性仍可在一定程度上得到保证。就性别而言,样本中女性多于男性,与台湾 MenGo、悉尼 Tripi 等真实 MaaS 试点的用户分布一致^[77,109];就年龄而言,由于要求按高德地图用户画像招募,样本以 20-30 岁为主(超过 50%)、其次为 30-40 岁,与高德地图在北京的用户年龄分布一致,也与 MenGo、Tripi 等试点中潜在 MaaS 用户偏年轻的特征相符,在一定程度上佐证了样本的代表性。“是否听说过 MaaS”的分布则表明 MaaS 在北京的普及度尚低,恰适合本研究聚焦于尚未接触 MaaS 的群体。

样本的出行模式特征如图 5-4 所示。就主要出行方式而言,公共交通最为普遍(占 72.22%),其次为出租/网约车(占比超过 30%),私家车、共享单车与步行的占比也超过 30%。就各方式的出行频率而言,多数受访者采用特定交通方式的出行次数少于 7 次;就平均出行距离而言,工作日与周末的分布相近,多数受访者的日均出行距离集中在 40 km 以内。




图 5-4 样本出行模式特征分布（选择“主要出行方式”时允许多选）

Figure 5-4 Distribution of travel-pattern characteristics in the sample (multiple responses were allowed for “main travel modes”).

受访者的潜在态度经 25 条态度陈述问题采集，各问题回答的统计结果如表 5-5 所示。其中， I_{17} 、 I_{18} 、 I_{24} 、 I_{25} 为负向陈述，其回答的取值为“非常同意”时对应的态度最不利于 MaaS 采纳。因此，其取值已作正向化处理以与其余陈述对齐。表 5-5 中态度陈述将在后续两阶段建模中经探索性与验证性因子分析识别为态度潜变量。

表 5-5 态度陈述的响应统计结果

Table 5-5 Response statistics for the attitudinal statements.

指标	态度陈述	均值	标准差
I_1	出行便捷对我很重要	4.35	0.85
I_2	出行经济对我很重要	4.17	0.94
I_3	出行舒适对我很重要	3.95	0.94
I_4	出行可靠对我很重要	4.27	0.87
I_5	我偏好等待时间更短的出行	4.21	0.95
I_6	我偏好出行时间更短的出行	4.17	0.96
I_7	我乐于享受出行优惠	4.22	0.97

续下页

(续表 5-5)

指标	态度陈述	均值	标准差
I_8	我愿意尝试新鲜事物	3.98	1.01
I_9	我希望在单一平台上规划出行	4.12	0.99
I_{10}	我认为新型出行方式会提升我的出行品质	3.91	1.02
I_{11}	我认为 MaaS 能让我的出行更高效	3.98	1.00
I_{12}	我认为 MaaS 能降低我的出行成本	3.89	1.07
I_{13}	我不希望我的出行计划被打乱	4.06	1.02
I_{14}	我认为做计划很重要	4.00	1.01
I_{15}	以低碳方式出行对我很重要	3.78	1.10
I_{16}	以环保方式出行对我很重要	3.86	1.07
I_{17}	在线出行规划可能侵犯我的隐私	3.15	1.23
I_{18}	目前可获得的出行信息不够充分	3.29	1.12
I_{19}	我对出行的安全性感到满意	4.05	0.93
I_{20}	我认为当前的共享出行性价比高	3.85	1.09
I_{21}	目前获得的出行信息是准确的	3.73	0.95
I_{22}	我愿意用手机提前规划出行	4.17	0.99
I_{23}	出行安全对我很重要	4.49	0.85
I_{24}	我认为开车出行更舒适	3.97	1.06
I_{25}	我不愿改变惯常的出行方式	3.40	1.18

5.3 单次出行场景下 MaaS 转移意愿建模

结合5.2的调查结果,本节聚焦于 MaaS 多阶段采纳的第一阶段,即单次出行场景下用户由既有方式向 MaaS 多模式出行服务的转移意愿建模。本节以混合选择模型(HCM)为框架,先由态度陈述问题识别态度潜变量,再构建混合潜在分类模型,以识别具有异质转移偏好的潜在用户类别以及不同用户类别的转移意愿差异;在估计结果分析的基础上,进一步构建 MaaS 转移意愿指数以量化用户的转移意愿;最后开展灵敏度分析,考察 MaaS 选项服务水平对转移意愿的影响。

5.3.1 态度潜变量识别

既有交通行为学研究表明,出行者的行为决策不仅受社会经济属性、出行模式变量等可观测属性的影响,也受其内在态度的影响^[86,166-170]。为引入态度变量对单次出行场景下的转移行为的影响,本节首先借助态度陈述加以间接度量^[166,167]。考虑到模型估计的复杂性与收敛性,在单次出行场景下,以出行的性价比权衡为核心态度潜变量,对出行品质和成本相关的态度陈述(I_1 - I_6)开展潜变量识别。

首先,采用探索性因子分析(Exploratory Factor Analysis, EFA)识别态度陈述背后潜在的因子结构。为获得更为合理的结构,要求各指标的因子载荷大于 0.4。分析结果表明, I_1 - I_6 可归并为单一潜变量,将其命名为“性价比偏好”,表征用户以相对较低的成本获取高品质出行服务的意愿。随后,采用验证性因子分析(Confirmatory Factor Analysis, CFA)检验该潜变量的有效性。潜变量的有效性以因子载荷与组合信度(Construct Reliability, CR)两项指标衡量:因子载荷大于 0.4 的指标视为有效,CR 则须大于 0.6 以保证潜在结构的有效性。CFA 结果如表 5-6所示。结果表明,所识别的潜在结构有效。

表 5-6 态度潜变量验证性因子分析结果

Table 5-6 Confirmatory factor analysis results for the attitudinal latent variables.

潜变量	态度陈述	因子载荷
性价比偏好 CR: 0.74	I_1	0.58
	I_2	0.58
	I_3	0.52
	I_4	0.60
	I_5	0.61
	I_6	0.53

5.3.2 基于混合潜在分类模型的 MaaS 转移行为建模

本小节结合混合选择模型与潜在分类模型刻画用户在单次出行情境下对 MaaS 的转移意愿。混合选择模型由结构模型、测量模型与选择模型三部分构成:结构模型刻画社会经济属性与潜变量之间的关系,测量模型建立潜变量与态度陈述之间的联系,选择模型则解释用户在单次出行情境下的转向使用 MaaS 的行为。其中,为捕捉用户在是否转移 MaaS 上的异质偏好,选择模型采用潜在分类模型。构建的 HCM 模型的总体结构如图 5-5所示。




图 5-5 单次出行场景下 MaaS 转移行为建模框架

Figure 5-5 Framework for modeling shifts to MaaS under one-trip scenarios.

(1) 结构模型

结构模型刻画社会经济与出行模式属性等个人相关的可观测变量对潜变量的影响。对受访者 n ，潜变量“性价比偏好”的取值 a^n 由如下结构方程度量：

$$a^n = \gamma Z^n + \varphi^n, \quad \varphi^n \sim N(0, \sigma_\varphi), \quad (5-1)$$

式中， a^n 为受访者 n 的“性价比偏好”度量值； Z^n 为受访者 n 的社会经济与出行模式属性向量； γ 为待估系数向量； φ^n 为服从零均值、标准差为 σ_φ 的正态分布的随机误差项。

(2) 测量模型

测量模型建立潜变量与态度陈述之间的联系。考虑到受访者遵循 5 级李克特量表对态度陈述作答，采用有序 Probit 模型刻画潜变量 a^n 对各态度陈述响应的影响。对第 s 条态度陈述，其测量方程为：

$$I_s^{n*} = \gamma_s + \gamma'_s a^n + \eta_s^n, \quad \eta_s^n \sim N(0, \sigma_s), \quad (5-2)$$

$$I_s^n = \begin{cases} v_s^1, & I_s^{n*} < \tau_s^1 \\ v_s^2, & \tau_s^1 \leq I_s^{n*} < \tau_s^2 \\ \vdots & \vdots \\ v_s^M, & \tau_s^{M-1} \leq I_s^{n*} < \tau_s^M \end{cases} \quad (5-3)$$

式中, I_s^{n*} 为受访者 n 对第 s 条陈述的连续潜在响应; γ_s 与 γ'_s 分别为待估的截距与潜变量系数; η_s^n 为服从零均值、标准差为 σ_s 的正态分布的随机误差项; I_s^n 为受访者 n 对第 s 条陈述的实际响应; v_s^i 为第 s 条陈述的第 i 个等级; τ_s^i 为 v_s^i 对应的阈值, 且满足 $\tau_s^i > \tau_s^{i-1}$ 。设 $\tau_s^0 = 0$, 则针对 5 级量表须估计 3 个阈值差以确定 4 个阈值, 即 $\tau_s^i = \tau_s^{i-1} + \delta_s^i$ 。据此, 受访者 n 对第 s 条陈述响应 v_s^i 的概率为:

$$P_s^n(I_s^n = v_s^i) = \Phi\left(\frac{\tau_s^i - \gamma_s - \gamma'_s a^n}{\sigma_s}\right) - \Phi\left(\frac{\tau_s^{i-1} - \gamma_s - \gamma'_s a^n}{\sigma_s}\right), \quad (5-4)$$

式中, $\Phi(\cdot)$ 为标准正态分布的累积分布函数。

(3) 基于潜在分类的选择模型

在构建选择模型之前, 须先依据“无 MaaS”与“含 MaaS”两情境的选择结果界定备选方案。为直观刻画受访者在两情境下的选择差异, 备选方案由“无 MaaS”与“含 MaaS”两情境的选择结果组合判定。具体而言, 先记录无 MaaS 情境的选择结果, 再将含 MaaS 情境的选择结果与之比较; 若两次选择相同则记为不转移, 若受访者在含 MaaS 情境中改选某一 MaaS 选项则记为转移至相应方案, 包含转移至 M1、M2、M3、M4 四类。备选方案的确定过程如图 5-6 所示。



图 5-6 单次出行场景下备选方案示意图

Figure 5-6 Schematic illustration of the alternatives under one-trip scenarios.

为刻画潜在 MaaS 用户的异质性^[79,86,104]，本小节采用潜在分类模型描述用户在是否转移 MaaS 上的异质偏好。潜在分类模型由类别隶属模型与离散选择模型两部分构成。在类别隶属模型中，受访者 n 隶属类别 q 的概率 P_q^n 为：

$$P_q^n = \frac{\exp(\delta_q + \gamma_q Z^n + \lambda_q a^n)}{\sum_{i \in Q} \exp(\delta_i + \gamma_i Z^n + \lambda_i a^n)} \quad (5-5)$$

式中， δ_q 为类别特定常数； γ_q 为待估系数向量，表征个体相关变量对隶属类别 q 的影响； λ_q 为类别 q 中潜变量（性价比偏好）对应的待估参数； Q 为类别集合。在类别 q 中，基于多项 Logit 模型，受访者 n 选择方案 i 的概率 $P_{i|q}^n$ 为：

$$P_{i|q}^n = \frac{\exp(V_i^{nq})}{\sum_{j \in R_q} \exp(V_j^{nq})} \quad (5-6)$$

式中， V_i^{nq} 为类别 q 中受访者 n 选择方案 i 的效用， R_q 为受访者 n 的备选方案集合。

在效用函数的设定上，经反复试验、剔除显著性较低的变量后，效用函数由五部分构成：方案特定常数（Alternative-Specific Constant, ASC）、出行惯性变量、偏好延续变量、情境属性与 LOS 变量，并以不转移作为参考方案。其中，出行惯性变量与跨场景变量根据受访者在无 MaaS 与含 MaaS 情境下的选择结果进行界定。出行惯性变量源自“第二次选择与第一次相同”的选择结果，纳入不转移方案，用以刻画受访者维持既有方式的偏好；偏好延续变量源自“第二次选择不同于第一次”的选择结果，用以考察 MaaS 选项与既有方式之间的替代关系。例如，在无 MaaS 情境中选择公共交通的受访者，可能更倾向于选择含公共交通的 MaaS 选项，故将无 MaaS 情境下选择公共交通这一结果纳入转移至 M1、M2 的效用函数。情境属性包含出行距离与出发时间；LOS 变量则包含出行时间（作用于转移至 M1-M4）与地铁内时间（作用于转移至 M1-M3）。综合式（5-5）与式（5-6），受访者 n 选择方案 i 的概率 P_i^n 为：

$$P_i^n = \sum_{q \in Q} P_q^n \cdot P_{i|q}^n \quad (5-7)$$

5.3.3 模型估计结果

本节基于极大似然估计思想，借助 Python 开源工具包 Biogeme^[171] 对构建的基于混合潜在分类的选择模型进行估计。下面依次分析结构模型、测量模型与选择模型的估计结果。

结构模型估计结果如表 5-7 所示。就社会经济属性而言，女性较男性更可能关注出行中的性价比，受教育程度在本科及以上的受访者更倾向于追求出行中的性价比。从年龄的影响来看，相较于 60 岁以上老人以及月收入在 2 万以上的受访者，

其余年龄段与收入水平的受访者均偏好高品质、低成本的出行服务，其中 24 岁以下、月收入低于 20000 元者尤为突出。就出行模式属性而言，每周出行频率、工作日出行距离与每周地铁出行频率对“性价比偏好”均有显著正向影响，表明出行越频繁者越倾向于追求性价比。

表 5-7 单次出行情境下的结构模型估计结果

Table 5-7 Estimation results of the structural model for one-trip scenarios.

观测变量	估计值	t 值
社会经济属性		
性别：女	0.11	2.75
年龄：<24	2.85	24.40
年龄：25-44	2.69	24.90
年龄：45-60	2.76	23.60
职业：学生	0.02	0.33
月收入：<6k 元	0.72	8.69
月收入：6k-20k 元	0.73	8.89
受教育程度：本科及以上	0.31	6.87
出行模式属性		
每周出行频率：>10 次	0.21	5.22
工作日出行距离：>10 km	0.17	4.10
主要出行方式：共享汽车	-0.26	-3.76
主要出行方式：私人自行车/电动自行车	-0.08	-1.87
主要出行方式：共享单车	-0.14	-3.29
主要出行方式：步行	0.22	5.19
是否拥有私家车：是	0.07	1.63
每周地铁出行频率：>12 次	0.18	3.76
每周电动自行车出行频率：>12 次	-0.09	-1.27

注：|t| > 1.96（1.65）时变量在 95%（90%）置信水平下显著。

测量模型估计结果如表 5-8 所示，“性价比偏好”与全部指标均显著正相关，即随着“性价比偏好”度量值的增大，受访者选择“非常同意”的概率随之上升。

表 5-8 单次出行情境下的测量模型估计结果（括号内为 t 值）

Table 5-8 Estimation results of the measurement model for one-trip scenarios (t -values in parentheses).

对应指标	系数	截距	标准差
性价比偏好			
I_1	1（固定）	0（固定）	1（固定）
I_2	0.838 (32.50)	0.321 (3.35)	1.180 (35.00)
I_3	0.704 (33.30)	0.383 (4.75)	1.070 (37.70)
I_4	0.876 (34.10)	0.363 (3.85)	1.090 (34.40)
I_5	0.883 (33.40)	0.157 (1.61)	1.190 (35.30)
I_6	0.867 (29.30)	0.428 (3.88)	1.420 (34.80)

注： $|t| > 1.96$ （1.65）时变量在 95%（90%）置信水平下显著；阈值差估计为 $\delta_1^1=1.140$ (30.00)、 $\delta_1^2=1.260$ (40.20)、 $\delta_1^3=1.360$ (45.30)。

在分析选择模型的结果之前，需首先阐述类别数选择的合理性。为确定潜在分类类别数，分别估计了类别数为 2-5 的模型，结果如表 5-9所示。结合对数似然（LL）、赤池信息准则（AIC）与贝叶斯信息准则（BIC）选择最优类别数，四个模型的 AIC 相差不大，本研究选取 BIC 最低且估计结果合理的 2 类别模型作为最优模型^[104,107]。

表 5-9 单次出行情境下不同类别数模型的拟合优度对比

Table 5-9 Comparison of goodness-of-fit measures for models with different numbers of classes under one-trip scenarios.

模型	参数个数	LL	AIC	BIC
2 类别 LC	68	-41213.14	82562.28	83011.58
3 类别 LC	88	-41130.91	82437.82	83019.28
4 类别 LC	108	-41087.02	82390.04	83103.64
5 类别 LC	128	-41060.89	82377.78	83223.53

2 类别潜在分类模型估计结果如表 5-10所示。就整体拟合度而言，模型的 AIC 与 BIC 分别为 82562.28 与 83011.58，调整后 McFadden ρ^2 为 0.345，表明模型拟合良好。

表 5-10 单次出行情境下的选择模型估计结果（括号内为 t 值）Table 5-10 Estimation results of the choice model for one-trip scenarios (t -values in parentheses).

变量	类别 1	类别 2
类别隶属模型		
ASC: 类别 1	-3.64 (-4.90)	
是否熟悉 MaaS: 是	0.45 (3.11)	
潜变量: 性价比偏好	0.11 (1.59)	
主要出行方式: 公共交通	1.78 (3.73)	
主要出行方式: 出租/网约车	1.19 (5.88)	
主要出行方式: 私人自行车/电动自行车	0.50 (3.17)	
是否拥有私家车: 是	-0.33 (-1.79)	
工作日出行距离: >10 km	0.28 (1.85)	
离散选择模型		
方案特定常数		
ASC: 转移至 M1	3.57 (2.11)	-1.86 (-3.32)
ASC: 转移至 M2	3.67 (2.11)	-2.19 (-3.84)
ASC: 转移至 M3	2.93 (1.77)	-2.39 (-5.21)
ASC: 转移至 M4	1.85 (1.15)	-2.62 (-7.19)
出行惯性变量		
维持无 MaaS 情境选择: 私家车	2.93 (2.01)	0.75 (2.67)
维持无 MaaS 情境选择: 出租/网约车	3.95 (2.53)	-0.02 (-0.04)
偏好延续变量		
无 MaaS 情境选择: 公共交通	-0.13 (-0.36)	1.84 (3.86)
无 MaaS 情境选择: 出租/网约车	1.76 (4.52)	-0.61 (-1.07)
情境属性		
出行时间 (min)	-0.013 (-1.86)	0.004 (0.77)
地铁内时间 (min)	-0.015 (-1.04)	-0.018 (-2.53)
出发时间: 平峰时段	0.61 (2.48)	-0.18 (-1.43)
出行距离: >40 km	1.27 (2.19)	0.49 (0.77)
模型汇总		
样本量	5472	
初始对数似然	-63068.59	
最终对数似然	-41213.14	
估计参数个数	68	
似然比检验	43710.9	
调整后 McFadden ρ^2	0.345	
AIC	82562.28	
BIC	83011.58	

注: $|t| > 1.96$ (1.65) 时变量在 95% (90%) 置信水平下显著。

就类别隶属模型而言,类别 1 的 ASC 估计为-3.64,表明受访者初始属于隶属类别 1 的效用较低。是否拥有私家车对隶属类别 1 有负向影响,意味着拥有私家车者更可能隶属类别 2、其出行主要由私家车完成。除此之外,其余变量对隶属类别 1 均有正向影响:熟悉 MaaS、追求高性价比出行,以及以公共交通、出租/网约车或私人自行车/电动自醒着为主要方式的受访者,更可能隶属类别 1。综合来看,类别 1 受访者期望通过 MaaS 获得更高品质的出行、其主要方式为公共交通、出租车或私人自行车;类别 2 受访者则偏好私家车出行,故“性价比偏好”水平较低。须说明的是,尽管“性价比偏好”的 t 统计量未达常规显著性水平,但保留该变量有助于获得更多关于在单次出行情境下向 MaaS 转移行为的行为启示。根据模型结果进一步计算,受访者隶属类别 1 与类别 2 的概率分别为 28.89% 与 71.11%;这一差异主要源于类别 1 中 ASC 的绝对值最大。

就离散选择模型而言,ASC 的估计结果表明:类别 1 的全部 ASC 对相应 MaaS 选项均为正向影响,类别 2 则全部为负向影响。具体地,类别 1 受访者在转移至 M2 (3.67) 上感知到最高效用、其次为 M1 (3.57);类别 2 受访者则在转移至 M4 (-2.62) 上感知到最低效用、其次为 M3 (-2.39)。就出行惯性变量而言,两类别受访者在无 MaaS 情境中选择私家车时均表现出维持原选择的意愿(类别 1、2 分别为 2.93 与 0.75);类别 1 受访者在选择出租车时也表现出维持原选择的意愿(3.95)。值得注意的是,类别 1 中维持私家车的系数低于维持出租/网约车,意味着相较出租车,这些受访者的私家车出行更易被 MaaS 替代,有助于推广共享出行方式。就偏好延续变量而言,对类别 1 受访者,在无 MaaS 情境中选择出租/网约车对其在含 MaaS 情境中选择 M3、M4 有显著正向影响(1.76);对类别 2 受访者,选择公共交通对其选择 M1、M2 有显著正向影响(1.84)。前者反映出类别 1 受访者希望通过含出租/网约车的 MaaS 选项降低出行成本,后者则印证了既有研究中 MaaS 的早期用户可能是以私家车为主的出行者这一判断^[97]。就情境属性而言,类别 1 的出行时间系数(-0.013)与类别 2 的地铁内时间系数(-0.018)均显著为负,表明类别 1 受访者期望出行时间更短,类别 2 受访者则更关注更短的地铁内时间;此外,类别 1 受访者更倾向于在平峰时段(0.61)转移至 M1-M3,而在出行距离大于 40 km 的情境下倾向于维持原选择,后者可能源于长距离情境下 MaaS 选项较高的换乘成本。

综合类别隶属模型与离散选择模型的估计结果,可对两类受访者的用户画像作如下归纳。类别 1 可概括为“高品质出行追求者”:该类受访者多熟悉 MaaS、追求高性价比与高品质出行,主要出行方式为公共交通、出租/网约车或私人自行车/电动自行车,对各 MaaS 选项普遍感知到正向效用,尤为青睐以公共交通衔接共享单车、常规公交的 M2、M1 等门到门方案,且对出行时间较为敏感。尽管其

样本隶属概率仅为 28.89%，但其私家车出行更易被 MaaS 替代，是 MaaS 起步阶段最具转化潜力的目标人群。类别 2 则可概括为“私家车依赖者”：该类受访者为以私家车为主要出行方式，“性价比偏好”水平较低，对全部 MaaS 选项均感知到负向效用，出行惯性强、既有习惯难以改变，且构成样本的多数（71.11%），意味着样本中倾向于维持既有方式者居多。值得注意的是，类别 2 受访者在无 MaaS 情境中选择公共交通的经历会显著提升其转移至含公共交通的 M1、M2 的概率，表明以公共交通为锚点的 MaaS 套餐是撬动这一庞大而保守群体的潜在切入口。

5.3.4 MaaS 转移意愿指标构建

结合混合潜在分类模型的估计结果，可进一步量化受访者在单次出行情境下的转移意愿，以为后续分析单次出行情境下的关键因素和套餐订阅情境下的偏好异质性提供基础。

考虑到受访者面对的出行情境多样，为量化其在单次出行情境下转移意愿，须综合不同情境加以度量。为此，先计算受访者在不同情境下选择 MaaS 选项的概率，再依各情境的占比计算其在单次出行场景下选择 MaaS 选项的加权平均概率；该概率在一定程度上计入了受访者社会经济属性与出行模式的异质性，为便于理解，称之为“MaaS 转移意愿指数”。对受访者 n ，其 MaaS 转移意愿指数 S^n 为：

$$S^n = \frac{\sum_{k \in K} \theta_k^n \sum_{m \in M} P_{km}^n}{K}, \quad (5-8)$$

式中， S^n 为受访者 n 的 MaaS 转移意愿指数； K 为受访者 n 所面对的情境数； M 为 MaaS 选项集合； P_{km}^n 为受访者 n 在情境 k 下选择 MaaS 选项 m 的概率； θ_k^n 为受访者 n 第 k 类情境的出行占比，因缺乏相关数据，假定为 0.2。

依据式 (5-7) - 式 (5-8) 计算全体受访者的转移意愿指数，其核密度如图 5-7 所示。整体转移意愿指数的核密度估计在 0.43 的转移意愿附近达到峰值，表明相当一部分受访者的转移意愿集中在 0.4 左右、对转移 MaaS 持较为中性的态度；同时，核密度曲线左侧的密度值高于右侧，表明倾向于维持既有出行习惯的受访者多于倾向于转移 MaaS 的受访者。




图 5-7 MaaS 转移意愿指数的核密度估计图

Figure 5-7 Kernel density estimate of the index of willingness to shift to MaaS.

考虑到不同类别受访者对 MaaS 多模式出行服务的偏好存在显著差异，进一步分别估计两类别受访者的转移意愿指数核密度。在此，为直观对比两类别受访者的转移意愿差异，假定两类情况。情况 1 假定全体受访者均隶属类别 1，情况 2 假定全体受访者均隶属类别 2。计算 MaaS 转移意愿指数核密度估计结果如图 5-8 所示。




图 5-8 两类别受访者 MaaS 转移意愿指数的核密度估计图

Figure 5-8 Kernel density estimates of the index of willingness to shift to MaaS for the two respondent classes.

对比可见，类别 1 受访者的核密度估计的峰值（0.75）对应的转移意愿远高于类别 2 受访者（0.31）。进一步地，类别 1 的曲线右偏、表明其转移意愿更强，类别 2 的曲线左偏、表明其更倾向于维持既有方式。两曲线的差异提供了一个有益的政策启示：受访者间本身的异质性对转移意愿影响显著。

5.3.5 转移人数灵敏度分析

在计算受访者的转移意愿指数后，进一步分析影响受访者转移至 MaaS 的关键因素。为此，本文以出行时间为例，结合转移意愿的计算结果，开展转移人数的灵敏度分析。考虑情况 1（全部受访者均隶属类别 1）、情况 2（全部受访者均隶属类别 2）以及情况 3（正常计算的隶属情况），三种情况下的转移人数对出行时间的灵敏度分析结果如图 5-9 所示，其中横轴表示 MaaS 多模式出行服务出行时间变化的比例。




图 5-9 MaaS 多模式出行服务出行时间变化下转移至 MaaS 的人数

Figure 5-9 Number of respondents shifting to MaaS as the travel time of MaaS multimodal travel services changes.

图 5-9表明, 情况 1 下, 转移至 MaaS 的人数多于情况 2, 与 5.3.4 小节的结论一致。此外, 情况 1 下, 转向 MaaS 的人数对 MaaS 多模式出行服务出行时间的敏感度高于情况 2, 表明类别 1 受访者对 MaaS 提供的较短出行时间有更强的偏好, 更愿意通过 MaaS 来改善出行体验。

由于本文计算的转移意愿指数是基于不同距离情境下的转移概率加权平均而得, 故进一步就不同出行距离情境开展转移人数的灵敏度分析, 结果如图 5-10 所示。就情况 1 而言, 出行时间比例为 0 时, 20-30 km 出行距离情境下转移人数最多; 出行时间比值为 1.0 时, 0-10 km 出行距离情境转移人数最多。就转移人数的变化幅度而言, 30-40 km 情境下出行时间比例从 0 增至 1.0 时转移人数下降最多, 共下降 12.64%; 而大于 40 km 出行距离情境下情况 1 转移人数远少于其他情境。就情况 2 而言, 出行时间比例为 0 时同样是 20-30 km 出行距离情境转移人数最多, 比值为 1.0 时 10-20 km 出行距离情境转移人数最多。此外, 情况 2 下各情境转移人数变化幅度均较小, 其中 30-40 km 情境降幅最大 (15.35%), 与情况 1 相似。




图 5-10 不同出行距离情境下转移人数随出行时间变化

Figure 5-10 Number of respondents shifting to MaaS as travel time varies across travel-distance scenarios.

上述结果表明，可在公众关注的特定情境中改善 MaaS 服务水平：对 20-30 km 及 30-40 km 等转移意愿较强、敏感度较高的情境，MaaS 供应商可经多模式班次优化使各方式无缝衔接，或经合乘等门到门服务缩短步行距离、降低出行时间；而对 0-10 km（情况 1）与 10-20 km（情况 2）等在不改善 MaaS 多模式出行服务服务水平时转移意愿已较高的情境，则可在不增加服务投入的前提下针对相应用户

加强 MaaS 推广。

5.4 基于转移意愿的 MaaS 套餐订阅建模

承接5.3节的单次出行转移意愿建模，本节继续分析用户对 MaaS 多阶段采纳的第二阶段，即套餐订阅阶段的选择行为。为此，首先阐述单次出行偏好向套餐订阅决策的偏好传导机制，明确两阶段之间的联系；继而构建考虑属性无视的混合潜在分类模型，刻画在单次出行情境下具有不同转移意愿的受访者在套餐订阅阶段的异质偏好；随后基于模型估计结果，分析影响受访者订阅 MaaS 套餐的关键因素，并对不同类别受访者的订阅偏好进行比较；最后开展灵敏度与弹性分析，考察套餐价格及非价格变量对套餐订阅意愿的影响。

5.4.1 单次出行意愿向套餐订阅决策的偏好传导

为刻画用户在单次出行阶段的转移意愿如何影响其在套餐订阅阶段的选择行为，本小节阐明由单次出行的转移意愿向套餐订阅决策的偏好传导机制，作为关联单次出行 MaaS 多模式服务使用行为与套餐订阅选择的桥梁。具体而言，设计了两种方式将单次出行阶段的转移意愿传导至套餐订阅阶段：

其一，是以转移意愿指数度量的“总体印象”。如5.3.4小节所述，受访者在五个单次出行情境下选择 MaaS 选项的平均概率构成其 MaaS 转移意愿指数；该指数综合反映了受访者首次接触 MaaS 时对其多模式出行服务的整体接受程度，可视为一种“总体印象”。初始印象积极者，有可能在套餐订阅阶段持更开放的态度；初始印象消极者，则可能更倾向于维持自身原有的出行习惯，拒绝订阅相对昂贵的 MaaS 套餐。因此，本节以转移意愿指数作为划分受访者潜在类别的关键变量，并进一步探究不同类别受访者在套餐订阅阶段的异质偏好。

其二，是通过受访者在单次出行阶段最偏好的 MaaS 选项刻画的对不同多模式出行服务的“具体偏好”。受访者在单次出行场景下最愿意采纳的 MaaS 多模式出行服务，反映了其在出行过程中使用 MaaS 时的具体方式偏好，进而可能影响其套餐订阅。为此，依据5.3节估计的单次出行阶段对各 MaaS 出行服务（M1-M4）的选择概率，取各距离情境下平均选择概率最大的 MaaS 出行服务作为受访者最偏好的 MaaS 选项，并对其作类别编码（如最偏好 M1 则相应变量取 1、否则取 0），纳入套餐订阅模型的效用函数中。

结合上述两种将单次出行阶段的转移意愿传导至套餐订阅阶段的方式，本文可以在套餐订阅选择模型中刻画受访者在单次出行阶段中形成的对 MaaS 的“初始印象”对其在套餐订阅阶段的选择行为的影响，从而能够较为系统地分析受访

者在 MaaS 多阶段采纳过程中的异质偏好。

5.4.2 态度潜变量识别

与单次出行场景下的 MaaS 转移意愿建模类似，套餐订阅决策同样受到受访者态度潜变量的影响^[85,86,107]。为此，本节同样首先采用 EFA 与 CFA 识别潜变量，用于指导后续混合潜在分类模型的构建。

参考既有研究中关于态度变量对 MaaS 套餐订阅的影响^[85,86,107]，本节使用 25 条态度陈述来刻画受访者在套餐订阅阶段的态度偏好，涵盖出行成本、技术接受度、计划性、环保意识与现状满意等多个方面。

首先采用 EFA 识别潜变量与态度陈述之间的对应关系，在此之前，采用 Bartlett 球形检验与 Kaiser-Meyer-Olkin 检验对数据适用性进行检验。结果表明，Bartlett 球形检验的 p 值 $0.00 < 0.05$ ，并且 Kaiser-Meyer-Olkin 检验结果为 0.92，大于 0.60 的标准阈值，表明态度陈述间存在足够的相关性，适于因子分析。随后提取特征值大于 1 的 5 个因子，采用方差最大正交旋转，并以普通最小二乘求最小残差解。在此过程中，参照既有研究^[172]剔除载荷较差 (< 0.40) 或存在交叉载荷的陈述。最终得到 5 个潜变量：性价比偏好 (Cronbach's $\alpha = 0.82$)、技术接受度 (Cronbach's $\alpha = 0.77$)、计划性偏好 (Cronbach's $\alpha = 0.83$)、环保意识 (Cronbach's $\alpha = 0.76$) 与现状满意度 (Cronbach's $\alpha = 0.75$)，共涉及 20 条态度陈述，因子载荷如表 5-11 所示。

表 5-11 套餐订阅模型潜变量识别的 EFA 因子载荷

Table 5-11 EFA factor loadings for identifying latent variables in the bundle subscription model.

指标	性价比偏好	技术接受度	计划性偏好	环保意识	现状满意度
I_1	0.63				
I_2	0.52				
I_3	0.43				
I_4	0.59				
I_5	0.60				
I_6	0.60				
I_7	0.47				
I_8		0.48			
I_9		0.55			
I_{10}		0.59			
I_{11}		0.72			
I_{12}		0.68			
I_{13}			0.80		
I_{14}			0.73		

续下页

(续表 5-11)

指标	性价比偏好	技术接受度	计划性偏好	环保意识	现状满意度
I_{15}				0.55	
I_{16}				0.58	
I_{19}					0.43
I_{20}					0.53
I_{21}					0.54
I_{22}	0.45				

为检验所识别潜变量的合理性,进一步采用 CFA 考察识别到的潜变量与对应态度陈述之间的关系。经若干试验,将指标 I_{22} 自性价比偏好中剔除可改善整体潜变量结构的拟合优度,拟合指标卡方自由度比 ($2.960 < 3.000$)、拟合优度指数 ($0.933 > 0.900$)、比较拟合指数 ($0.962 > 0.900$)、近似误差均方根 ($0.056 < 0.100$)、残差均方根 ($0.030 < 0.050$) 与标准化残差均方根 ($0.039 < 0.050$) 等指标均表明模型有效。经 CFA 验证后,潜变量与态度指标的最终对应关系如表 5-12 所示。

表 5-12 CFA 验证后潜变量与态度指标的对应关系

Table 5-12 Correspondence between latent variables and attitudinal indicators after CFA validation.

潜变量	指标	态度陈述
性价比偏好	I_1	出行便捷对我很重要
	I_2	出行经济对我很重要
	I_3	出行舒适对我很重要
	I_4	出行可靠对我很重要
	I_5	我偏好等待时间更短的出行
	I_6	我偏好出行时间更短的出行
	I_7	我乐于享受出行优惠
技术接受度	I_8	我愿意尝试新鲜事物
	I_9	我希望在单一综合平台上规划出行
	I_{10}	我认为新型出行方式会提升我的出行品质
	I_{11}	我认为 MaaS 能让我的出行更高效
计划性偏好	I_{12}	我认为 MaaS 能降低我的出行成本
	I_{13}	我不希望我的出行计划被打乱
	I_{14}	我认为做计划很重要
环保意识	I_{15}	以低碳方式出行对我很重要
	I_{16}	以环保方式出行对我很重要
现状满意度	I_{19}	我对出行的安全性感到满意
	I_{20}	我认为当前的共享出行性价比高
	I_{21}	目前获得的出行信息是准确的

结合表 5-12 的潜变量与态度指标对应关系,可对潜变量进行解释。性价比偏好潜变量代表受访者在出行中对服务品质与经济性的双重重视,其对应指标既涵盖对出行便捷、舒适、可靠以及更短等待与出行时间的偏好,也包含对出行经济与优惠的关注,表明关注性价比偏好的受访者倾向于以较低成本获取高品质的出行服务。技术接受度潜变量刻画受访者对新型出行方式及 MaaS 的接纳与认同程度,具有较高技术接受度的受访者乐于尝试新鲜事物,期望在单一综合平台上完成出行规划,并认同新型出行方式与 MaaS 能够提升出行品质与效率、降低出行成本。计划性偏好潜变量表征受访者对出行计划稳定性的重视,即注重事先规划、不愿既定出行安排被打乱。环保意识潜变量反映受访者对出行环境影响的关切,倾向于以低碳、环保的方式完成出行。现状满意度潜变量则度量受访者对当前出行状况的满意程度,涵盖其对出行安全性、共享出行性价比与出行信息准确性的评价。

5.4.3 考虑属性无视的混合潜在分类模型

结合 5.4.1 小节中设计的两种偏好传导方式及 5.4.2 小节中识别的潜变量,本小节构建考虑属性无视的混合潜在分类模型刻画受访者在套餐订阅阶段的异质偏好。与 5.3 节构建的混合选择模型框架类似,本节分别构建结构模型、测量模型与选择模型,其总体框架如图 5-11 所示。值得注意的是,经对比具有不同类别的潜在分类模型后,本章最终选取区分两类受访者(MaaS 乐观者和 MaaS 存疑者)的潜在分类模型,其不仅具有最好的拟合优度指标,而且在解释上也更为合理。




图 5-11 基于单次出行转移意愿的 MaaS 套餐订阅选择模型框架

Figure 5-11 Framework for the MaaS bundle subscription choice model based on willingness to shift in one-trip scenarios.

(1) 结构模型

结构模型考察与个体有关的社会经济属性、出行模式等与个体有关的变量对所识别潜变量的影响。对受访者 n ，第 l 个潜变量的取值 a_l^n 为：

$$a_l^n = \gamma_l^n Z^n + \phi_l^n, \quad \phi_l^n \sim N(0, \sigma_{\phi_l}), \quad (5-9)$$

式中， γ_l^n 为待估系数， Z^n 为受访者 n 的个体相关属性向量， ϕ_l^n 为服从零均值、标准差为 σ_{ϕ_l} 的正态分布的随机误差项。

(2) 测量模型

测量模型刻画潜变量与对应态度陈述之间的关系。本小节继续采用有序 Probit 模型刻画态度指标 I_{ls}^n 与对应潜变量 a_l^n 之间的关系：

$$I_{ls}^{n*} = \gamma_s + \gamma'_{ls} a_l^n + \eta_{ls}^n, \quad \eta_{ls}^n \sim N(0, \sigma_s), \quad (5-10)$$

$$P_s^n(I_{ls}^n = v_{ls}^i) = \Phi\left(\frac{\tau_{ls}^i - \gamma_s - \gamma'_{ls} a_l^n}{\sigma_s}\right) - \Phi\left(\frac{\tau_{ls}^{i-1} - \gamma_s - \gamma'_{ls} a_l^n}{\sigma_s}\right), \quad (5-11)$$

式中各符号含义与式 (5-2) -- 式 (5-4) 类似，其中 γ_s 与 γ'_{ls} 分别为第 l 个潜变量第 s 条陈述的截距与系数，阈值同样满足 $\tau_{ls}^i = \tau_{ls}^{i-1} + \delta_{ls}^i$ ， $\Phi(\cdot)$ 为标准正态分布的累积分布函数。

(3) 考虑属性无视的潜在分类选择模型

考虑到在单次出行阶段表现出不同转移意愿的受访者在套餐订阅阶段可能存在异质偏好，本节继续构建潜在分类选择模型刻画受访者在套餐订阅阶段的异质

选择行为。首先，类别隶属模型中，受访者 n 隶属类别 q 的概率为：

$$P_q^n = \frac{\exp(\delta_q + \gamma_q Z^n)}{\sum_{i \in Q} \exp(\delta_i + \gamma_i Z^n)}, \quad (5-12)$$

式中， δ_q 为类别特定常数， γ_q 为待估系数向量， Q 为类别集合。

针对选择模型，考虑到公交优先与地铁畅行两套餐均以公共交通为主导，受访者在选择套餐时可能存在对两套餐的相关性，故本节在离散选择模型中采用两层 NL 结构刻画受访者在套餐订阅阶段的选择行为。具体而言，将公交优先与地铁畅行两套餐置于同一“公交导向巢”。因此，在类别 q 中，受访者 n 选择巢 m 内方案 r 的概率为条件概率与边际概率之积：

$$P_{(rm|q)}^n = P_{(r|m,q)}^n P_{(m|q)}^n, \quad r \in R_m^n, m \in M^n, \quad (5-13)$$

$$P_{(r|m,q)}^n = \frac{\exp(\mu_{(m|q)} V_{(r|m,q)}^n)}{\sum_{r' \in R_m^n} \exp(\mu_{(m|q)} V_{(r'|m,q)}^n)}, \quad (5-14)$$

$$P_{(m|q)}^n = \frac{\exp[\lambda_q (V_{(m|q)}^n + V_{(m|q)}^{n*})]}{\sum_{m' \in M^n} \exp[\lambda_q (V_{(m'|q)}^n + V_{(m'|q)}^{n*})]}, \quad V_{(m|q)}^{n*} = \frac{1}{\mu_{(m|q)}} \ln \sum_{r' \in R_m^n} \exp(V_{(r'|m,q)}^n), \quad (5-15)$$

式中， $V_{(r|m,q)}^n$ 为类别 q 中受访者 n 选择巢 m 内方案 r 的下层效用； $\mu_{(m|q)}$ 为类别 q 中巢 m 的下层尺度参数，须介于 0 与 1 之间以保证巢结构假设成立； λ_q 为上层尺度参数，为简化估计设为 1^[173]； $V_{(m|q)}^n$ 为类别 q 中受访者 n 选择巢 m 的上层效用； $V_{(m|q)}^{n*}$ 为对数和项，表示集合 R_m^n 内的期望最大效用。综合式 (5-12) 与式 (5-13)，受访者 n 选择巢 m 内方案 r 的概率为：

$$P_{rm}^n = \sum_{q \in Q} P_q^n \cdot P_{(rm|q)}^n. \quad (5-16)$$

关于效用函数的组成，在大量实验的基础上，基于属性无视理论，允许不同类别受访者的效用函数采用不同的变量设定^[166,174]，即对某类别受访者，在模型估计中剔除显著性较差（ t 值 < 1 ）且剔除后不致模型不收敛的变量。

效用函数共考虑六类变量：尺度参数、方案特定常数（ASC）、套餐属性、单次出行场景下偏好的 MaaS 选项、潜变量与个体有关变量。结合识别得到的 MaaS 乐观者和 MaaS 存疑者两类受访者的两种类别，各类变量的具体设定如下。

尺度参数与 ASC：下层尺度参数用以检验巢结构的合理性；关于 ASC 设定，经试验，MaaS 存疑者仅对公交优先套餐设 ASC，MaaS 乐观者则对优惠出租与全能畅行两套餐设 ASC。

套餐属性：考虑套餐价格与套餐内可用的出租/网约车两项套餐属性。价格变量进入存疑者与乐观者除 PAYG 外所有套餐的效用函数；可用出租/网约车变量进入乐观者公交优先与地铁畅行套餐的效用函数，以考察出租/网约车服务对公交导

向套餐订阅的影响。两变量均未作类别编码，以考察套餐中每单位出租/网约车服务或每单位增价的边际影响。

偏好的 MaaS 选项：依5.4.1小节所述，将单次出行场景下受访者最偏好的 MaaS 选项作类别编码后纳入效用函数，以刻画初始印象中的具体偏好对套餐订阅的影响。存疑者与乐观者的具体设定依显著性试验而定（详见5.4.4小节）。

潜变量：将 5 个态度潜变量分别纳入相应套餐的效用函数。例如，对存疑者，将性价比偏好纳入 PAYG 效用以考察性价比意识的影响，将技术接受度纳入全能畅行，将计划性偏好纳入公交优先，将环保意识纳入优惠出租，将现状满意度纳入全能畅行；对乐观者，潜变量依类似逻辑纳入。

个体相关变量：包含社会经济属性与出行模式属性，同时进入结构模型与选择模型。

5.4.4 模型估计结果

鉴于混合潜在分类模型中纳入了 5 个潜变量，直接计算数值积分的方式在计算上不切实际，故采用蒙特卡洛积分（500 次 MHLS 抽样）借助 Python 开源工具包 Biogeme 进行模型估计^[171,175]。下面依次分析结构、测量与选择模型的估计结果，并据此辨识在考虑单次出行转移意愿的前提下，影响受访者在套餐订阅阶段选择行为的关键因素。

结构模型估计结果如表 5-13 所示。性别方面，相较男性，女性更具环保意识^[176]，但对新技术的接受度和计划性的偏好更低^[86]。年龄方面，以 60 岁以上为参照，其余各年龄段对全部潜变量均有正向影响。除此之外，受访者社会经济属性和出行模式对态度潜变量的影响也给出了部分值得关注的结果。以现状满意度为例，以公共交通或出租/网约车为主要方式的受访者对当前出行状况更为满意，这可能得益于北京公共交通系统较为发达、出租/网约车出行体验良好。此外，每周公交出行超过 10 次的受访者环保意识更强，而每周乘坐出租/网约车超过 10 次者则可能具有较低的环保意识，表明常乘公交者更关注出行的环境影响。

表 5-13 套餐订阅情境下的结构模型估计结果（括号内为 t 值）

Table 5-13 Estimation results of the structural model for bundle subscription scenarios (*t*-values in parentheses).

观测变量	性价比偏好	技术接受度	计划性偏好	环保意识	现状满意度
性别：女	——	-0.027 (-1.75)	-0.169 (-7.79)	0.121 (5.80)	-0.016 (-0.84)
年龄：≤24	3.250 (52.70)	2.450 (53.20)	2.32 (45.10)	1.85 (40.20)	2.47 (48.70)
年龄：25-44	3.080 (54.80)	2.230 (57.80)	2.25 (52.20)	1.85 (47.80)	2.39 (54.40)

续下页

(续表 5-13)

观测变量	性价比偏好	技术接受度	计划性偏好	环保意识	现状满意度
年龄: 45-60	3.110 (43.30)	2.190 (41.80)	2.40 (40.50)	1.97 (36.90)	2.40 (40.80)
职业: 学生	——	-0.099 (-4.78)	0.030 (1.04)	0.139 (4.94)	-0.039 (-1.52)
主要出行方式: 步行	0.110 (5.54)	——	0.077 (3.42)	——	0.103 (4.85)
每周出行频率: ≥ 7	0.259 (8.00)	0.190 (7.40)	0.146 (5.13)	0.041 (1.53)	0.254 (9.11)
主要出行目的: 非通勤	0.022 (0.88)	0.049 (2.50)	0.145 (5.25)	——	——
每周公交出行频率:	——	0.075 (3.76)	——	0.106 (3.92)	0.144 (5.31)
>10					
每周地铁出行频率:	0.168 (5.82)	0.161 (6.66)	0.132 (4.67)	——	0.134 (4.53)
>10					
每周出租/网约车出行频率: >10	——	——	——	-0.117 (-4.04)	0.263 (9.23)
每周电动自行车出行频率: >10	-0.185 (-5.09)	0.083 (2.67)	——	——	——
潜变量标准差	1.210 (45.50)	0.927 (45.30)	0.843 (38.10)	0.796 (38.90)	0.857 (41.60)

注: $|t| > 1.96$ (1.65) 时变量在 95% (90%) 置信水平下显著; “——” 表示该变量未纳入相应潜变量的结构方程。

测量模型估计结果如表 5-14 所示。结果表明, 全部潜变量与对应态度陈述在 99% 置信水平下均显著相关, 即随着潜变量估计值的增大, 受访者越倾向于对相应陈述作“非常同意”的响应。

表 5-14 套餐订阅情境下的测量模型估计结果 (括号内为 t 值)

Table 5-14 Estimation results of the measurement model for bundle subscription scenarios (t -values in parentheses).

相关指标	系数	截距	标准差
性价比偏好 (阈值差: $\delta_1^1=0.925$ (37.10)、 $\delta_1^2=1.090$ (50.30)、 $\delta_1^3=1.190$ (57.60))			
I_1	1 (固定)	0 (固定)	1 (固定)
I_2	0.797 (34.00)	0.383 (5.17)	1.110 (45.10)
I_3	0.698 (35.80)	0.323 (5.11)	0.971 (47.40)
I_4	0.905 (37.70)	0.183 (2.48)	0.980 (43.60)
I_5	0.863 (35.20)	0.246 (3.21)	1.110 (44.40)
I_6	0.952 (38.10)	-0.112 (-1.44)	1.030 (44.50)
I_7	0.945 (34.70)	0.066 (0.78)	1.180 (43.50)

续下页

(续表 5-14)

相关指标	系数	截距	标准差
技术接受度 (阈值差: $\delta_2^1=0.731$ (39.90)、 $\delta_2^2=1.030$ (59.40)、 $\delta_2^3=1.120$ (67.60))			
I_8	1 (固定)	0 (固定)	1 (固定)
I_9	1.130 (35.90)	-0.107 (-1.44)	1.000 (50.10)
I_{10}	1.070 (38.40)	-0.277 (-4.17)	0.921 (52.70)
I_{11}	1.020 (36.50)	-0.078 (-1.16)	0.956 (52.30)
I_{12}	0.980 (34.10)	-0.074 (-1.07)	1.070 (53.20)
计划性偏好 (阈值差: $\delta_3^1=0.694$ (27.90)、 $\delta_3^2=0.901$ (46.70)、 $\delta_3^3=0.954$ (57.50))			
I_{13}	1 (固定)	0 (固定)	1 (固定)
I_{14}	0.994 (32.30)	-0.093 (-1.35)	0.878 (51.00)
环保意识 (阈值差: $\delta_4^1=0.793$ (34.70)、 $\delta_4^2=0.899$ (52.60)、 $\delta_4^3=0.949$ (59.30))			
I_{15}	1 (固定)	0 (固定)	1 (固定)
I_{16}	1.010 (32.30)	0.062 (0.97)	0.949 (55.60)
现状满意度 (阈值差: $\delta_5^1=0.815$ (34.50)、 $\delta_5^2=1.040$ (53.60)、 $\delta_5^3=1.240$ (67.80))			
I_{19}	1 (固定)	0 (固定)	1 (固定)
I_{20}	0.960 (30.30)	-0.086 (-1.03)	1.220 (54.00)
I_{21}	0.781 (33.00)	0.143 (2.25)	0.939 (56.20)

注: $|t| > 1.96$ (1.65) 时变量在 95% (90%) 置信水平下显著。

为确定潜在分类选择模型类别数, 分别估计类别数为 2-5 的模型, 并结合 LL、AIC 与 BIC 等指标选择最有类别数, 结果如表 5-15 所示。类别数为 2-5 的模型的 AIC 随类别数增加而下降, BIC 则随之上升; 本研究选取 BIC 最低且估计结果合理的 2 类别模型作为最优模型^[104,107]。2 类别模型的调整后 McFadden ρ^2 为 0.316, 表明模型对存疑者与乐观者套餐订阅行为的刻画有效。

表 5-15 不同类别数模型的拟合优度对比

Table 5-15 Comparison of goodness-of-fit measures for models with different numbers of classes.

模型	参数个数	LL	AIC	BIC
2 类别模型	192	-145399.40	291182.90	292475.80
3 类别模型	241	-145220.43	290922.86	292545.73
4 类别模型	290	-145149.56	290879.12	292831.95
5 类别模型	339	-145024.71	290727.42	293010.22

2 类别选择模型 (含类别隶属模型与离散选择模型) 的估计结果如表 5-16 所示。

表 5-16 套餐订阅情境下的选择模型估计结果（括号内为 t 值）

Table 5-16 Estimation results of the choice model for bundle subscription scenarios (*t*-values in parentheses).

变量	所属备选项（存疑者）	估计值（存疑者）	所属备选项（乐观者）	估计值（乐观者）
类别隶属模型				
ASC: MaaS 存疑者		1.75 (3.39)	——	
MaaS 转移意愿		-3.04 (-5.89)	——	
离散选择模型				
尺度参数				
μ_1	公交导向巢	0.323 (2.11)	公交导向巢	0.119 (1.93)
方案特定常数				
ASC1	公交优先	0.288 (1.79)	——	——
ASC3	——	——	优惠出租	2.32 (1.67)
ASC4	——	——	全能畅行	3.367 (2.67)
套餐属性变量				
可用出租/网约车	——	——	公交优先、地铁畅行	-1.130 (-5.17)
套餐价格（百元）	除 PAYG 外所有套餐	-0.036 (-1.95)	除 PAYG 外所有套餐	-0.051 (-1.70)
单次出行场景下偏好的 MaaS 选项				
地铁 + 公交（M1）	公交优先、地铁畅行、全能畅行	0.324 (2.57)	公交优先、地铁畅行	2.34 (5.99)
地铁 + 共享单车（M2）	地铁畅行	0.233 (1.56)	公交优先、地铁畅行	3.77 (5.23)
地铁 + 网约车（M3）	地铁畅行	0.069 (1.22)	PAYG	-3.080 (-5.50)
地铁 + 网约车（M3）	优惠出租	0.534 (3.41)	——	——
合乘（M4）	公交优先	0.301 (1.40)	PAYG	-0.895 (-1.77)
合乘（M4）	地铁畅行	0.349 (1.65)	——	——
潜变量				
性价比偏好	PAYG	0.215 (3.08)	PAYG	-0.064 (-0.09)
技术接受度	全能畅行	4.440 (3.01)	全能畅行	-1.990 (-1.35)
计划性偏好	公交优先	-0.051 (-1.33)	PAYG	-0.477 (-0.50)

续下页

(续表 5-16)

变量	所属备选项（存疑者）	估计值（存疑者）	所属备选项（乐观者）	估计值（乐观者）
潜变量（续）				
环保意识	优惠出租	0.176 (1.28)	优惠出租	-2.780 (-3.29)
现状满意度	全能畅行	-4.310 (-2.97)	全能畅行	-0.175 (-0.11)
个体相关变量				
性别：女	——	——	公交优先	-0.340 (-1.47)
性别：女	——	——	地铁畅行	-0.387 (-1.69)
年龄：24-44	地铁畅行	0.172 (2.00)	——	——
年龄：45-60	优惠出租	0.536 (3.30)	——	——
年龄：45-60	全能畅行	1.370 (3.91)	——	——
年龄：>60	PAYG	0.848 (1.83)	——	——
月收入：<6k 元	公交优先、地铁畅行	0.275 (2.60)	——	——
月收入：6k-20k 元	优惠出租	0.287 (2.36)	——	——
月收入：>20k 元	除 PAYG 外所有套餐	0.424 (2.18)	优惠出租、全能畅行	0.799 (1.40)
受教育程度：本科及以上	PAYG	0.058 (1.24)	PAYG	1.560 (4.34)
拥有自行车/电动自行车：是	公交优先、地铁畅行	0.234 (1.89)	公交优先、地铁畅行	0.641 (2.90)
持有驾照：是	PAYG	0.297 (2.58)	优惠出租	-0.965 (-3.06)
工作日出行距离：<5 km	——	——	地铁畅行	0.044 (1.36)
工作日出行距离：20-40 km	地铁畅行	0.122 (1.47)	——	——
工作日出行距离：40-60 km	地铁畅行	0.386 (2.27)	——	——
工作日出行距离：>60 km	地铁畅行	0.224 (1.84)	——	——
周末出行距离：<5 km	——	——	PAYG	0.745 (3.24)
周末出行距离：5-10 km	PAYG	0.463 (3.38)	PAYG	0.248 (0.85)
周末出行距离：20-40 km	PAYG	0.249 (1.88)	地铁畅行、优惠出租	0.051 (1.34)
周末出行距离：40-60 km	地铁畅行	-0.270 (-1.79)	——	——
周末出行距离：>60 km	PAYG	0.477 (2.40)	——	——
月出行花费：>1000 元	全能畅行	0.248 (1.22)	全能畅行	0.510 (1.84)

续下页

(续表 5-16)

变量	所属备选项（存疑者）	估计值（存疑者）	所属备选项（乐观者）	估计值（乐观者）
个体相关变量（续）				
月出行花费：>1000 元	PAYG	0.074 (0.74)	PAYG	0.102 (1.91)
主要方式：公共交通	公交优先、地铁畅行	0.903 (6.88)	——	——
主要方式：自行车/电动自行车	公交优先	0.658 (4.59)	公交优先	-1.850 (-4.00)
主要方式：自行车/电动自行车	地铁畅行	0.677 (4.57)	地铁畅行	-1.870 (-4.05)
主要方式：共享单车	公交优先、地铁畅行	-0.324 (-2.90)	——	——
主要方式：出租/网约车	优惠出租、全能畅行	0.332 (2.86)	——	——
主要方式：私家车	全能畅行	0.421 (2.37)	除 PAYG 外所有套餐	0.552 (2.19)
主要方式：步行	PAYG	0.468 (4.44)	公交优先	0.076 (1.65)
主要组合出行：公交 + 共享单车	——	——	地铁畅行	0.094 (1.80)
主要组合出行：公交 + 出租/网约车	PAYG	0.164 (1.78)	地铁畅行	0.075 (1.69)
主要组合出行：出租/网约车 + 共享单车	优惠出租	0.394 (3.03)	——	——
每周公交频率：>10 次	公交优先	0.129 (1.58)	公交优先	0.293 (2.00)
每周地铁频率：>10 次	公交优先	0.467 (3.23)	地铁畅行	0.355 (1.97)
每周地铁频率：>10 次	公交优先	0.682 (4.90)	——	——
每周出租/网约车频率	优惠出租	-0.614 (-1.33)	优惠出租	8.100 (5.28)
每周出租/网约车频率	全能畅行	-1.740 (-0.42)	全能畅行	6.310 (3.96)
模型汇总				
观测样本数		6210		
初始对数似然		-212897.80		
最终对数似然		-145399.40		
估计参数个数		192		
似然比检验		134996.70		
调整后 McFadden ρ^2		0.316		
AIC		291182.90		
BIC		292475.80		

注：|t| > 1.96（1.65）时变量在 95%（90%）置信水平下显著；“——”表示该变量未纳入相应类别的效用函数。

类别隶属模型。类别隶属模型中, ASC 与 MaaS 转移意愿指数的估计系数分别显著为正与显著为负, 表明受访者初始隶属 MaaS 存疑者的效用较高, 而单次出行场景下转移意愿越高者越可能成为 MaaS 乐观者。ASC (1.75) 与转移意愿系数 (-3.04) 的估计意味着, 转移意愿大于 0.576 的受访者隶属 MaaS 乐观者的概率更高。这一结果直接印证了 5.4.1 小节所述的偏好传导机制: 单次出行阶段形成的初始印象, 确实显著地划分了套餐订阅阶段的用户群体。

尺度参数与 ASC。就离散选择模型而言, 存疑者与乐观者公交导向巢的下层尺度参数分别为 0.323 与 0.119, 既验证了巢结构的合理性, 又表明对乐观者而言公交优先与地铁畅行两套餐更为相似。就 ASC 而言, 公交优先套餐对 MaaS 存疑者具显著吸引力, 体现了公交服务在 MaaS 套餐中的受欢迎程度^[99,105]; 优惠出租与全能畅行套餐则对乐观者具吸引力。这表明, 价格较低的公交优先套餐即使对单次出行转移意愿不高的存疑者亦具吸引力, 而乐观者则更倾向于订阅价格较高的套餐, 意味着其在单次出行中已感知到较高的 MaaS 使用效用。

套餐属性。就套餐自身的吸引力而言, 存疑者与乐观者均偏好订阅费较低的套餐, 这一结果直观且与既有研究一致^[92,105,118]。值得注意的是, 乐观者对在公交导向套餐中加入出租/网约车服务的估计为负, 为 MaaS 套餐制定提供了有益的启示, 即应尽量保持公交导向套餐的公交主导特征。

单次出行情境下偏好的 MaaS 选项。单次出行场景下偏好的 MaaS 选项对套餐订阅的影响呈现异质性的结果。首先, MaaS 乐观者相应估计系数的量级显著大于存疑者, 表明单次出行场景下的初始印象对乐观者的套餐订阅影响更大。另外, 偏好地铁 + 公交选项可吸引存疑者与乐观者订阅公交优先与地铁畅行套餐。然而, 偏好地铁 + 公交选项的 MaaS 存疑者也倾向于订阅全能畅行套餐, 结合其不愿在单次出行中转向使用 MaaS 的特征, 这可能反映出其套餐选择中的非理性。此外, 偏好地铁 + 共享单车选项对两类受访者订阅地铁畅行套餐均有显著正向影响。偏好地铁 + 网约车选项的乐观者倾向于订阅各类套餐, 而存疑者则倾向于订阅地铁畅行与优惠出租套餐。

态度潜变量。就潜变量而言, 存疑者“性价比偏好”对 PAYG 的正向估计意味着追求性价比对套餐订阅有负向影响, 这可能是因为当前阶段 MaaS 渗透率低、套餐收益不明确^[118]。存疑者“技术接受度”的正向估计表明追求新技术对套餐订阅有正向影响, 与既有研究一致^[86]。就“环保意识”而言, 乐观者中环保主义对订阅优惠出租有显著负向影响; 然而对存疑者, 环保主义对其选择优惠出租反有显著正向影响, 意味着在被套餐吸引后, 具环保意识的存疑者反而可能作出不够可持续的选择。就“现状满意度”而言, 存疑者对全能畅行套餐持负向态度, 结合其多为私家车用户的特征, 对既有出行方式的满意降低了其订阅服务最全面的全

能畅行套餐的意愿。

受访者社会经济属性。关于受访者社会经济属性变量，最直观的结果是存疑者的套餐订阅受更为多元的因素的影响。对乐观者而言，女性对订阅公交优先与地铁畅行套餐有负向影响。对存疑者，年龄的影响显著，即 24-44 岁者更倾向于订阅地铁畅行，45-60 岁者更倾向于订阅优惠出租与全能畅行，而 60 岁以上者更倾向于选择 PAYG。就月收入而言，月收入高于 20000 元的存疑者更倾向于订阅各类套餐，低于 6000 元者倾向于订阅公交优先与地铁畅行，6000-20000 元者则倾向于订阅优惠出租，体现出低收入者订阅低价套餐、中等收入者订阅高品质套餐的现象。受教育程度的正向估计表明，高学历者更倾向于在订阅前收集更多套餐信息、因而更可能选择 PAYG。就拥车情况而言，两类受访者模式相近：拥有自行车/电动自行车对其订阅公交优先与地铁畅行有正向影响（可能用于接驳），而持有驾照则对其不订阅套餐有正向影响，与既有研究一致^[79,177]。

出行模式变量。就出行模式而言，MaaS 存疑者方面，工作日出行距离大于 20 km、周末大于 5 km 分别对其订阅地铁畅行套餐与 PAYG 有正向影响；月出行花费对存疑者的影响略不显著，这可能因其虽月出行花费较高，但较低的转移意愿使其在订阅套餐时更为谨慎。相较乐观者，以自行车/电动自行车为主要方式的存疑者更倾向于订阅公交导向套餐，以步行为主要方式者则倾向于选择 PAYG^[92]。乐观者方面，工作日出行距离的影响不显著，但周末平均出行距离小于 5 km 时其倾向于选择 PAYG；月出行花费高于 1000 元对其订阅全能畅行套餐与 PAYG 有正向影响，前者可能因全能畅行可覆盖其出行需求、后者则可能因部分受访者未能找到合适套餐。此外，主要方式与各方式的高使用强度对其订阅相应套餐有正向影响，而以私人自行车/电动自行车为主要方式者则不倾向于订阅套餐，可能因其主要以该方式出行、无需购买套餐。

综合来看，可对两类群体加以画像。MaaS 存疑者尽管在单次出行场景下转移意愿较低，却仍对 MaaS 套餐抱有兴趣，但其订阅行为未必是最优选择，体现在其套餐选择与单次出行偏好之间的不一致，以及高收入群体对各类套餐的积极态度上；此外，其订阅行为受更为多元的社会经济属性影响，而出行模式变量的影响有限，显得较为冲动。相反，MaaS 乐观者的套餐订阅行为相对理性：依据单次出行场景下偏好的 MaaS 选项与对自身出行模式的了解，善于基于首次 MaaS 体验、兼顾 MaaS 的实际收益与自身出行习惯来选择套餐，且较少受月收入与年龄的影响。

5.4.5 灵敏度与弹性分析

在估计得到的模型基础上，进一步开展灵敏度与弹性分析，以考察价格系数、单次出行场景下偏好的 MaaS 选项、潜变量等因素对套餐订阅的影响，以挖掘 MaaS

存疑者与乐观者订阅套餐的差异化决定因素。

首先，标定结果表明，价格是套餐订阅最直观的阻碍因素。为考察套餐价格对存疑者与乐观者订阅意愿的异质影响，以价格系数为横轴开展灵敏度分析，即同步提高所有套餐的价格系数（假定 MaaS 供应商对各套餐采用相同的定价方案），计算各价格系数下套餐与 PAYG 的订阅意愿，结果如图 5-12 所示。




图 5-12 MaaS 存疑者与 MaaS 乐观者的价格灵敏度

Figure 5-12 Price sensitivity of MaaS Skeptics and MaaS Optimists.

当价格系数为 0.5 时，即套餐价格设为各出行服务购买成本之和的一半时，乐观者的 MaaS 采纳意愿高于存疑者（差值 0.068），符合预期；这表明设计良好的套餐对初始印象较差的群体亦具吸引力。随价格系数上升，两类受访者对套餐的订阅意愿均逐步下降，但存疑者的订阅意愿降幅大于乐观者，且其套餐与 PAYG 订阅意愿曲线交点对应的价格系数小于乐观者，表明乐观者对涨价的容忍度更高——这可能因乐观者依出行需求订阅套餐，而存疑者为套餐的性价比所吸引、故对价格更敏感。然而，两类受访者对每类套餐价格的敏感度均较低，表明价格未必是 MaaS 采纳最重要的阻碍因素。就各套餐的订阅比例而言，价格系数为 0.5 时乐观者更倾向于订阅地铁畅行，存疑者则在各价格系数下均更倾向于 PAYG，体现出两

类别受访者对套餐的异质偏好。

为进一步考察套餐价格的影响，计算各套餐订阅比例关于价格系数的集计直接点弹性^[171]，结果如图 5-13 所示。结果表明，订阅套餐的整体的价格弹性量级远高于单一套餐。就变化趋势而言，存疑者的集计直接点弹性在价格系数达 8.15 的转折点之前均低于乐观者，印证了存疑者对套餐价格较乐观者更为敏感。各套餐的弹性结果表明，当价格系数分别低于 6.18（存疑者）与 7.34（乐观者）时，公交优先套餐的集计直接点弹性大于 0，即其订阅比例随价格系数上升而增加，其原因为，随着其他套餐价格上涨过快，公交优先套餐的性价比凸显，因而吸引了更多受访者订阅。借助这一规律，MaaS 供应商可经调整套餐价格鼓励用户经由公交出行。





图 5-13 MaaS 存疑者与 MaaS 乐观者订阅意愿对套餐价格的集计直接点弹性


Figure 5-13 Aggregate direct point elasticities of bundle subscription intention with respect to bundle prices for MaaS Skeptics and MaaS Optimists.

除价格外，模型标定结果表明，非价格变量对套餐订阅同样有重要影响。为此，在价格系数分别为 0.5、0.8、1.0、1.2 四种情境下计算非价格变量的集计直接点弹性（以 0.5 为基准），结果如图 5-14 所示。就乐观者而言，价格系数为 0.5 时，单次出行场景下偏好的 MaaS 选项、性价比偏好与计划性偏好对套餐订阅有正向影响，其中偏好地铁 + 公交选项与计划性偏好影响最大；而公交导向套餐中可用的出租/网约车、技术接受度、环保意识与现状满意度的弹性为负，其中出租/网约车资源与技术接受度影响最大。就存疑者而言，偏好的 MaaS 选项、性价比偏好与


技术接受度对套餐订阅有正向影响，其中技术接受度影响最大；性价比偏好与现状满意度的弹性为负且影响较大。此外，随价格系数上升，几乎所有变量的影响均增大，而技术接受度与现状满意度的影响则减小，表明套餐价格较高时受访者更为谨慎、上述变量的影响更为显著。




(a) 价格系数为0.50时的集计直接点弹性



(b) 价格系数为0.80时相对0.50的弹性差异



(c) 价格系数为1.00时相对0.50的弹性差异



(d) 价格系数为1.20时相对0.50的弹性差异

图 5-14 MaaS 存疑者与 MaaS 乐观者套餐订阅对非价格变量的集计直接点弹性

Figure 5-14 Aggregate direct point elasticities of MaaS bundle subscriptions with respect to non-price variables for MaaS Skeptics and MaaS Optimists.

5.5 本章小结

本章研究了 MaaS 渗透率较低阶段下用户的多阶段采纳意愿建模问题。针对用户由既有方式向 MaaS 多模式出行服务的单次转移、以及由单次转移进一步向 MaaS 套餐长期订阅的两阶段采纳行为，本章提出了 MaaS 多阶段采纳意愿的分阶段建模框架，并经一项在北京实施的两步式 SP 调查（1242 份有效样本）加以标定与验证。主要工作与结论如下。

其一，设计并实施了两步式 SP 调查，以同时获取两阶段的采纳行为数据并刻画其内在联系。在单次出行场景中先后呈现无 MaaS 与含 MaaS 两个情境，使受访者聚焦于 MaaS 多模式服务相对既有方式的额外效用；在其形成初始印象后，再呈现公交优先、地铁畅行、优惠出租与全能畅行四类各具特色的 MaaS 套餐，调查其

订阅行为。该设计既分别获取了单次转移（5472 个观测）与套餐订阅（6210 个观测）两阶段的选择数据，又以单次出行阶段形成的转移意愿作为关联变量，将两阶段统一于同一建模框架之内。

其二，构建了基于混合潜在分类的选择模型以刻画单次出行场景下用户的 MaaS 转移意愿。模型以混合选择模型为框架，识别出“性价比偏好”态度潜变量与两类具有差异化转移偏好的潜在用户——期望经 MaaS 获得高品质出行的类别 1 与偏好私家车出行的类别 2，样本隶属概率分别为 28.89% 与 71.11%。在此基础上构建了 MaaS 转移意愿指数以量化用户的初始印象；服务水平灵敏度分析进一步表明，缩短 MaaS 选项的出行时间可有效提升转移意愿，且类别 1 较类别 2 更为敏感，提示可在转移意愿较强、敏感度较高的特定情境中优先改善服务水平。

其三，构建了基于初始印象的混合潜在分类模型，刻画套餐订阅阶段的异质偏好。模型以单次出行阶段估计的转移意愿作为划分潜在类别的关键变量，将用户区分为 MaaS 存疑者与 MaaS 乐观者（转移意愿大于 0.576 者更可能为乐观者），并借助五个态度潜变量与嵌套 Logit 结构辨识了两类用户对套餐订阅的异质偏好。乐观者倾向于依自身出行需求理性订阅套餐，存疑者的订阅行为则较受社会经济属性驱动而略显冲动。价格灵敏度与弹性分析表明，乐观者对套餐涨价的容忍度高于存疑者，但两类用户对套餐价格均不甚敏感，表明服务品质等非价格因素对套餐订阅同样关键。

上述两阶段模型及其标定结果，为第 7 章 MaaS 推广策略仿真刻画智能体的多阶段采纳决策提供了微观行为依据。

6 MaaS 多阶段采纳意愿的一体化建模

6.1 本章引论

第5章已从“分阶段建模”的视角研究了 MaaS 多阶段采纳意愿。首先构建单次出行场景下的混合潜在分类模型刻画用户的转移意愿，进而计算转移意愿指数作为用户对 MaaS“初始印象”的度量，并纳入下一套餐订阅阶段的混合潜在分类模型中捕捉用户对 MaaS 套餐的异质偏好，从而将两阶段相衔接。该框架可分别精细刻画两阶段的偏好异质性，有效辨识各阶段内的 MaaS 采纳的关键因素。然而，分阶段建模将两阶段先后、独立地进行模型估计，虽通过构建转移意愿指数将两阶段相衔接，但对两阶段间动态联系的刻画仍不充分。因此，本章仍聚焦研究内容(3)，拟从“一体化建模”的视角对 MaaS 多阶段采纳意愿进行研究，旨在刻画两阶段间的动态联系，并在全周期视角下识别 MaaS 采纳的关键驱动因素。为此，首先简要分析分阶段建模框架的不足。

首先，分阶段建模以单向传递的“转移意愿指数”衔接两阶段，这意味着单次出行体验对套餐订阅的影响只能以一个事先计算、外生给定的标量传入，既无法回收两阶段参数间的相关性，也难以保证估计的一致性^[178]，缺乏统一的似然函数进行联合估计，难以在全周期视角下刻画 MaaS 采纳的关键驱动因素。

其次，分阶段建模隐含地假设用户的偏好类型在两阶段间保持不变，即无论是单次出行阶段的潜在类别，还是套餐订阅阶段的潜在类别，均在各自阶段内固定。然而，用户的行为状态可能在初次体验 MaaS 后发生改变。例如，对 MaaS 持谨慎态度、在单次出行阶段不愿转移的用户，可能因体验到显著的 MaaS 便利性而转向对 MaaS 更为积极的态度。这种跨阶段的行为状态转移是连接“初次体验”与“后续订阅”的关键环节，而既有文献(含第5章)尚未对其建模，致使两阶段间的动态联系无法被定量刻画。

为弥补上述不足，本章提出 MaaS 多阶段采纳意愿的一体化建模框架，其核心思想为，通过设计 MaaS 多阶段订阅隐马尔可夫模型(Hidden Markov Model, HMM)，将受访者的行为状态贯穿于单次出行与套餐订阅两阶段，从而允许同一受访者的行为状态在两阶段间转变，进而在统一框架内同时刻画初始状态形成、跨阶段状态转移与两阶段的选择行为。具体而言，本章的研究思路可概括为三点：

(1) 针对联合估计中态度潜变量的识别与度量，沿用第5章经探索性因子分析(EFA)与验证性因子分析(CFA)检验的五因子态度结构，构建 MIMIC 模型。以社会经济与出行模式属性为自变量解释各潜变量(结构模型)，以有序 Probit 刻画

潜变量与态度陈述的关系（测量模型），经极大似然估计后计算每位受访者的潜变量因子得分，作为 HMM 中刻画行为状态的潜变量。

（2）针对多阶段采纳决策与跨阶段行为状态转移，构建贯穿两阶段的 HMM，包含四个相互衔接的子模型：初始行为状态隶属模型刻画用户在单次出行阶段所处的初始状态，单次出行选择模型刻画各状态下用户是否转移至 MaaS，跨阶段状态转移模型刻画用户在体验单次出行后向套餐订阅阶段的状态转移，套餐订阅选择模型刻画各状态下用户的套餐选择。四个子模型在统一的联合似然下同时估计，从而显式刻画两阶段间的动态联系。

（3）针对一体化建模视角下与分阶段建模视角下的结果对比，分析两种建模范式在刻画 MaaS 采纳行为异质性与识别关键驱动因素上的差异。通过一体化建模可通过 HMM 模型构建的多阶段行为链条，识别 MaaS 多阶段全周期的采纳驱动因素，并给出面向全体用户的采纳驱动因素排序。此外，通过对比一体化建模与分阶段建模的估计结果，可厘清两种范式的适用边界，为第7章 MaaS 推广策略仿真中智能体多阶段采纳行为参数的选用提供依据。

在数据基础方面，本章与第5章采用同一份两步式 SP 调查数据，其调查设计、样本特征与态度量表已于第5章及附录 D 中详细阐述，故本章不再赘述数据采集过程，而将重点置于一体化模型的构建与估计结果分析。

6.2 多指标多原因模型构建

为纳入潜变量刻画用户的态度异质性，本节沿用5.4.2节中识别到的性价比偏好、技术接受度、计划性偏好、环保意识与现状满意度五个潜变量。由于 HMM 模型的标定过程计算复杂性过高，难以应用混合选择模型框架将结构模型与测量模型引入到 HMM 模型中同步估计，故本节采用两步法对模型进行估计。首先，构建多指标多原因（Multiple Indicators Multiple Causes, MIMIC）模型，同时刻画潜变量的形成机制与潜变量对态度陈述的影响^[179]，为后续 HMM 中刻画行为状态提供潜变量因子得分。

MIMIC 模型由结构方程与测量方程两部分构成^[179]：结构方程以可观测的个体相关变量为原因解释各潜变量，测量方程则以有序 Probit 刻画潜变量与其对应态度陈述（指标）之间的关系。MIMIC 模型的结构如图 6-1所示。下面依次介绍结构方程、测量方程，以及似然函数与因子得分的计算。




图 6-1 MIMIC 模型结构

Figure 6-1 Structure of the MIMIC model.

6.2.1 结构方程构建

结构方程以可观测的受访者自身相关的变量解释各潜变量，以刻画社会经济与出行模式属性对态度的塑造。对潜变量 f 与受访者 n ，结构方程为：

$$a_{n,f} = \sum_{k=1}^K \beta_{k,f} Z_{n,k} + \sigma_f \varepsilon_{n,f}, \quad \varepsilon_{n,f} \sim \mathcal{N}(0,1), \quad (6-1)$$

式中， $a_{n,f}$ 为受访者 n 在潜变量 f 上的取值； $Z_{n,k}$ 为 K 个观测变量中的第 k 个； $\beta_{k,f}$ 为 $Z_{n,k}$ 对潜变量 f 的系数； σ_f 为潜变量 f 的尺度参数； $\varepsilon_{n,f}$ 为服从标准正态分布的随机扰动项。与第5章类似，本章从两类属性中选取观测变量。一是社会经济属性（年龄、收入与职业），二是出行模式属性（每周出行频率、每周出行距离、主

要出行目的与各方式的出行频率)。值得注意的是, 结构方程的主要目的在于计算潜变量因子得分, 因此本章尽可能纳入更多的观测变量以解释潜变量的异质性。

6.2.2 测量方程构建

测量方程刻画潜变量与其对应态度指标之间的关系, 与5.4.2节类似, 本章仍沿用有序 Probit 模型^[169]。设 $I_{n,j} \in \{1, 2, 3, 4, 5\}$ 为受访者 n 对指标 j 的响应, $f(j)$ 为指标 j 所载荷的潜变量, 则观测到响应为 c 的概率为:

$$P(I_{n,j} = c | a_{n,f(j)}) = \Phi\left(\frac{\tau_c^{(f(j))} - \alpha_j - \lambda_j a_{n,f(j)}}{\sigma_j}\right) - \Phi\left(\frac{\tau_{c-1}^{(f(j))} - \alpha_j - \lambda_j a_{n,f(j)}}{\sigma_j}\right), \quad (6-2)$$

式中, $\Phi(\cdot)$ 为标准正态分布的累积分布函数; α_j 为指标 j 的截距; λ_j 为潜变量 $f(j)$ 对指标 j 的载荷, 为待估参数; σ_j 为指标层面的尺度参数; $\tau_c^{(f)}$ 为潜变量 f 的第 c 个阈值。为识别模型, 设 $\tau_0^{(f)} = -\infty$ 、 $\tau_5^{(f)} = +\infty$ 、 $\tau_1^{(f)} = 0$, 并将其余阈值参数化为累积增量 $\tau_c^{(f)} = \tau_{c-1}^{(f)} + \delta_c^{(f)}$, 其中 $\delta_c^{(f)} > 0$ ($c \in \{2, 3, 4\}$); 同时, 对每个潜变量, 将其首个载荷指标锚定为 $\lambda = 1$ 、 $\alpha = 0$ 、 $\sigma = 1$ 。

6.2.3 似然函数与潜变量计算

综合结构方程与测量方程, MIMIC 模型中受访者 n 的似然贡献为全部观测指标在五维潜变量向量 $\mathbf{a}_n$ 上的联合概率密度积分:

$$L_n = \int_{\mathbf{a}_n} f_I(\mathbf{I}_n | \mathbf{a}_n; \boldsymbol{\alpha}, \boldsymbol{\lambda}, \boldsymbol{\sigma}_I, \boldsymbol{\tau}) \cdot f_a(\mathbf{a}_n | \mathbf{Z}_n; \boldsymbol{\beta}, \boldsymbol{\sigma}_a) d\mathbf{a}_n, \quad (6-3)$$

$$f_I(\mathbf{I}_n | \mathbf{a}_n) = \prod_{f \in F} \prod_{j \in J_f} \prod_{c \in C} P(I_{n,j} = c | a_{n,f})^{\delta(I_{n,j}=c)}, \quad (6-4)$$

$$f_a(\mathbf{a}_n | \mathbf{Z}_n) = \prod_{f \in F} \frac{1}{\sigma_f} \phi\left(\frac{a_{n,f} - \sum_{k=1}^K \beta_k^{(f)} Z_{n,k}}{\sigma_f}\right), \quad (6-5)$$

式中, $f_I(\cdot)$ 为全部测量方程的联合似然函数, $f_a(\cdot)$ 为全部结构方程的联合概率密度; F 为潜变量集合, J_f 为潜变量 f 对应的态度陈述集合, $C = \{1, 2, 3, 4, 5\}$ 为李克特量表的有序取值集合; $\delta(I_{n,j} = c)$ 为指示函数, 当受访者 n 对态度陈述 j 选取测量值 c 时取 1、否则取 0; $\phi(\cdot)$ 为一元标准正态密度函数。

由于式(6-3)中的积分无解析解, 本节基于模拟极大似然估计思想, 借助 Python 开源工具包 Biogeme 3.3.2^[180], 以 500 次模拟极大似然抽样 (Maximum Simulated Likelihood Sampling, MSLS) 最大化对数似然之和 $\sum_n \ln L_n$ 对模型进行估计。估计完成后, 即可根据受访者的社会经济及出行模式属性, 计算其五个潜变量的取值 $\bar{a}_{n,f}$, 并将其作为态度属性纳入6.3节的 HMM, 从而在不引入内生性的前提下刻画受访者态度对行为状态的影响。

6.3 基于隐马尔可夫模型的多阶段采纳意愿建模

在计算得到每位受访者的潜变量取值后, 本节进一步介绍基于隐马尔可夫模型 (Hidden Markov Model, HMM) 的 MaaS 多阶段采纳意愿建模框架, 以刻画受访者在单次出行与套餐订阅两阶段的使用意愿偏好及阶段间的行为状态转移。HMM 被广泛用于刻画出行行为中的状态转移^[120,181], 适用于本章所关注的 MaaS 多阶段采纳问题, 其由不可观测的潜在状态序列与观测到的行为选择序列构成, 潜在状态序列刻画受访者在不同阶段作出 MaaS 采纳选择时所处的、不可观测的潜在行为状态, 而观测到的行为选择序列则为受访者在特定状态各阶段下作出的选择, 对应不同的偏好结构。

具体而言, HMM 在统一的建模框架内刻画四个相互衔接的过程: (1) 受访者在单次出行阶段所处的初始行为状态 (6.3.1小节); (2) 确定的初始行为状态如何影响其单次出行选择 (6.3.2小节); (3) 单次出行的选择后, 行为状态是否发生转变 (6.3.3小节); (4) 转移后的 (可能为新的) 行为状态如何决定其套餐订阅选择 (6.3.4小节)。四个子模型在单一联合似然下同时估计 (6.3.5小节)。本章将 HMM 设定为含 K 个潜在行为状态, 状态集合记为 $S = \{1, 2, \dots, K\}$ 。图 6-2 为 HMM 的总体结构。




图 6-2 MaaS 多阶段采纳意愿的一体化建模框架

Figure 6-2 Overall framework for integrated modeling of multi-stage MaaS adoption intention.

值得注意的是, 关于四个子模型效用函数的具体形式, 采用迭代式的设定流

程,即先估计仅含状态特定 ASC 的基准模型,再向四个子模型的效用函数中逐步加入其他变量。在此过程中,将显著性较低的变量剔除并在其他子模型中试验。最终,依据调整后 R^2 、AIC、BIC 等指标及变量显著性,确定四个子模型的效用函数的具体设定。下面依次介绍各子模型。

6.3.1 初始行为状态隶属模型

受访者在初次接触 MaaS 并进行对应的采纳决策(即单次出行情境下的 MaaS 多模式出行服务采用决策)前处于某一不可观测的初始状态,该状态影响其首个行为阶段的行为偏好,并可能展现出不同的采纳意愿与行为选择。为此,构建初始行为状态隶属模型以刻画受访者初始状态的形成机制,帮助理解单次出行阶段的偏好异质性及后续的行为状态转移过程。采用以状态 $s = 1$ 为参照的多项 Logit 设定,受访者 n 处于状态 s 的概率为:

$$P(S_n^{st} = s) = \frac{\exp(V_n^{\text{init},s})}{\sum_{s' \in \mathcal{S}} \exp(V_n^{\text{init},s'})}, \quad s \in \mathcal{S}, \quad (6-6)$$

式中, $P(S_n^{st} = s)$ 为受访者 n 在作单次出行选择时处于状态 s 的概率, $V_n^{\text{init},s}$ 为处于状态 s 的效用,设定为:

$$V_n^{\text{init},s} = \alpha_0^s + \sum_{k=1}^{K_{\text{ind}}} \alpha_k^s X_{n,k} + \sum_{f \in F} \alpha_f^s \bar{a}_{n,f} \quad (6-7)$$

式中, $X_{n,k}$ 为第 k 个受访者自身的社会经济与出行模式变量,用以刻画由个体自身特征塑造的异质偏好, K_{ind} 为受访者自身有关的变量的总数。 $\bar{a}_{n,f}$ 为受访者 n 的潜变量 f 的计算值,刻画潜在态度对行为状态的影响; α_0^s 为状态特定常数; α_k^s 与 α_f^s 为待估的状态特定系数。

6.3.2 单次出行阶段选择模型

在识别受访者的初始状态后,进一步刻画不同行为状态下受访者如何作出初次接触 MaaS,即单次出行阶段的 MaaS 多模式出行服务采纳选择。本章将单次出行选择建模为二元决策,即在提供 MaaS 多模式服务的情境下,受访者是否从原有的出行方案转移到使用 MaaS。为此,采用二元 Logit 模型,处于状态 s 下的受访者 n 在单次出行情境下转移至 MaaS 的概率为:

$$P(Y_n^{st} = 1 | S_n^{st} = s) = \frac{\exp(V_n^{st,s})}{\exp(V_n^{st,s}) + 1}, \quad s \in \mathcal{S}, \quad (6-8)$$

式中，在状态 s 下受访者 n 转移至 MaaS 的效用为：

$$V_n^{st,s} = ASC^{st,s} + \sum_k \beta_k^{st,s} X_{n,k}^{st} \quad (6-9)$$

式中， X_n^{st} 为单次出行情境层面的属性，包括单次出行情境下选择的 MaaS 多模式出行服务带来的费用节省与时间节省、轨道车内时间，以及无 MaaS 多模式出行服务情境下的选择结果等变量； $ASC^{st,s}$ 为状态特定的方案常数； $\beta_k^{st,s}$ 为状态 s 下属性 $X_{n,k}^{st}$ 的系数，用以刻画不同状态下受访者对单次出行情境属性的异质偏好。

6.3.3 跨阶段行为状态转移模型

在单次出行阶段做出是否使用 MaaS 的多模式出行服务决策后，受访者形成了对 MaaS 的初始态度与偏好，因此其之后针对 MaaS 的行为状态可能在单次出行选择后发生改变，进而影响其套餐订阅选择。例如，一名持谨慎态度的受访者在单次出行阶段可能处于不愿采纳 MaaS 新兴出行服务的状态，但在体验 MaaS 后，可能因感受到费用节省与便捷而转向更积极的状态，从而提高其订阅 MaaS 套餐的可能性。为此，本小节对由单次出行阶段向套餐订阅阶段的行为状态转移加以建模，以理解受访者跨阶段的 MaaS 采纳行为变化。

具体而言，在行为状态转移过程中，受访者的行为状态可能由单次出行阶段的状态 S_n^{st} 转移至套餐订阅阶段的状态（可能不同） S_n^{bs} ，其转移受受访者偏好、单次出行阶段所体验到的 MaaS 多模式出行服务质量，以及套餐订阅阶段的套餐属性共同影响。因此，将状态转移过程构建为条件于单次出行阶段状态 S_n^{st} 的多项 Logit 模型，进而确定转移向套餐订阅阶段状态 S_n^{bs} 的概率如下：

$$P(S_n^{bs} = s' | S_n^{st} = s) = \frac{\exp(V_n^{\text{trans},s \rightarrow s'})}{\sum_{s'' \in \mathcal{S}} \exp(V_n^{\text{trans},s \rightarrow s''})}, \quad s, s' \in \mathcal{S}, \quad (6-10)$$

式中， $P(S_n^{bs} = s' | S_n^{st} = s)$ 为受访者 n 由单次出行阶段的状态 s 转移至套餐订阅阶段的状态 s' 的概率， $V_n^{\text{trans},s \rightarrow s'}$ 为该转移的效用，设定为：

$$V_n^{\text{trans},s \rightarrow s'} = G_0^{s \rightarrow s'} + \sum_{k=1}^{K_{\text{trans}}} G_k W_{n,k}^{\text{trans}}, \quad (6-11)$$

式中， $G_0^{s \rightarrow s'}$ 为单次出行和套餐订阅两阶段状态间特定的转移截距，刻画由状态 s 向状态 s' 转移的基准倾向； $W_{n,k}^{\text{trans}}$ 为受访者 n 的第 k 个转移变量； G_k 为相应系数。重点考虑三类转移变量：其一，单次出行阶段所体验到的 MaaS 多模式出行服务质量（如 MaaS 选项相对原方式在受访者层面平均的费用节省与时间节省），刻画单次出行阶段的体验如何影响状态转移；其二，套餐属性与受访者出行模式的匹配

程度，包括套餐所含方式的服务水平与受访者主要出行方式频次的匹配程度、套餐价格与受访者当前月度出行花费的匹配程度等，刻画套餐与出行模式的匹配程度如何影响状态转移；其三，套餐的平均价格系数，刻画套餐的性价比如何影响状态转移。

6.3.4 套餐订阅阶段选择模型

在经历单次出行选择并转移至（可能新的）行为状态后，受访者在转移后的行为状态下做出第二阶段的 MaaS 套餐订阅选择。与 6.3.2 小节的单次出行选择模型相对应，套餐订阅选择模型刻画各状态下受访者的套餐选择。关于模型形式，考虑到嵌套 Logit 在本章的联合估计中无法收敛，故采用多项 Logit。以 PAYG 为参照方案，处于状态 s 的受访者 n 选择套餐 b 的概率为：

$$P(Y_n^{bs} = b | S_n^{bs} = s) = \frac{\exp(V_{n,b}^{bs,s})}{\sum_{b' \in \mathcal{A}^{bs}} \exp(V_{n,b'}^{bs,s})}, \quad b \in \mathcal{A}^{bs}, s \in \mathcal{S}, \quad (6-12)$$

式中， Y_n^{bs} 为受访者 n 的套餐订阅选择， $V_{n,b}^{bs,s}$ 为在行为状态 s 下受访者 n 选择套餐 b 的效用，设定为：

$$V_{n,b}^{bs,s} = \text{ASC}_b^{bs,s} + \sum_k \gamma_{b,k}^{bs,s} X_{n,b,k}^{bs} \quad (6-13)$$

式中， $\text{ASC}_b^{bs,s}$ 为状态与套餐特定的常数； $\gamma_{b,k}^{bs,s}$ 为状态 s 下套餐属性 $X_{n,b,k}^{bs}$ 的系数； $X_{n,b,k}^{bs}$ 为影响受访者 n 选择套餐 b 的第 k 个属性。

在效用函数设定上，主要考虑两方面：一是套餐属性，包括套餐价格与所含方式；二是受访者本身属性，包括社会经济与出行模式属性。其中，套餐价格变量加入到全部四种 MaaS 套餐的效用函数中，以刻画不同状态的受访者对套餐价格的差异化权衡；套餐中可用的出租/网约车变量加入到公交优先与地铁畅行两套餐的效用函数，以考察补充性出租/网约车服务对这两种公交导向套餐吸引力的影响。个体相关变量（性别、年龄、收入、受教育程度、职业、是否持照、是否拥车，以及各方式的每周出行频率）则加入到全部四种 MaaS 套餐的效用函数，刻画不同特征与出行模式的受访者在套餐订阅上的差异化偏好。

6.3.5 联合似然函数与模型标定

(1) 联合似然函数

若将 MIMIC 模型与 HMM 模型进行联合估计，则完整似然为受访者的选择对 (Y_n^s, Y_n^{bs}) 的联合概率与其潜变量因子得分 $\mathbf{a}_n$ 的联合概率密度在五维潜变量向量上

积分、并对所有可能的状态路径求和，其计算负担在当前条件下不可行，故本章不对 MIMIC 与 HMM 作完全联合估计，而采用两阶段标定策略。因此，HMM 的似然仅包含 6.3.1 至 6.3.4 小节所述的四个子模型。由于单次出行阶段状态 S_n^{st} 与套餐订阅阶段状态 S_n^{bs} 均不可观测，受访者 n 在某一情境下观测到的选择对 (Y_n^{st}, Y_n^{bs}) 的联合概率，须对全部 K^2 条可能的状态路径 $(s, s') \in \mathcal{S} \times \mathcal{S}$ 求和，即：

$$P(Y_n^{st}, Y_n^{bs}) = \sum_{s \in \mathcal{S}} \sum_{s' \in \mathcal{S}} P(S_n^{st} = s) \cdot P(Y_n^{st} | S_n^{st} = s) \cdot P(S_n^{bs} = s' | S_n^{st} = s) \cdot P(Y_n^{bs} | S_n^{bs} = s'), \quad (6-14)$$

式中，四个条件概率分别由式（6-6）、式（6-8）、式（6-10）与式（6-12）给出。HMM 的完整对数似然为全部“受访者 $\times$ 情境”观测上 $\log P(Y_{n,t}^{st}, Y_{n,t}^{bs})$ 之和，其中下标 t 标识受访者 n 所贡献的情境：

$$\mathcal{LL}_{\text{HMM}} = \sum_{n=1}^N \sum_{t=1}^{T_n} \log P(Y_{n,t}^{st}, Y_{n,t}^{bs}), \quad (6-15)$$

式中， N 为受访者数， T_n 为受访者 n 的情境对数。

（2）模型标定设置

MIMIC 模型与 HMM 模型均借助 Python 开源工具包 Biogeme 3.3.2^[180] 估计。MIMIC 模型以 500 次 MHLS 抽样最大化模拟对数似然；HMM 模型则最大化式（6-15）的对数似然。在数据组织上，因两模型的似然结构不同，其数据组织也不同：对 MIMIC 模型，每位受访者仅贡献 1 条观测（25 条态度陈述在 SP 实验中仅作答一次），共得 1242 条个体层面观测；对 HMM 模型，须将每位受访者的单次出行选择与其对应的套餐订阅选择两两配对，以完整观测两阶段间的行为转移，故共得 27360 条观测。由于每位受访者贡献多条情境对，本章报告在受访者层面聚类的稳健标准误，以校正同一受访者跨情境的决策的相关性。

6.4 模型结果分析

本节报告并分析一体化建模框架下 MIMIC 模型的估计结果（6.4.1 小节）、HMM 模型的估计结果（6.4.2）。其中，HMM 模型的结果分为从初始行为状态形成到套餐订阅选择建模等 4 个子模型的估计结果。

6.4.1 MIMIC 模型估计结果

在分析具体的参数估计结果之前，简要分析 MIMIC 模型的总体拟合情况，结果如表 6-1 所示。

MIMIC 模型共估计 132 个参数，最终对数似然值为 -28239.92 ，模型初始对数似然值为 -44012.50 ，McFadden ρ^2 为 0.358、调整后 McFadden ρ^2 为 0.355，AIC 与 BIC 分别为 56743.85 与 57420.28。表明模型能够较好地拟合受访者潜变量形成以及潜变量对态度陈述的影响。结构模型与测量模型的估计结果分别如下。

表 6-1 MIMIC 模型总体拟合优度

Table 6-1 Overall goodness-of-fit statistics for the MIMIC model.

统计量	数值
观测数	1242
估计参数个数	132
零模型对数似然	-44012.50
最终对数似然	-28239.92
似然比检验	31545.16
McFadden ρ^2	0.358
调整后 McFadden ρ^2	0.355
AIC	56743.85
BIC	57420.28

(1) 结构模型估计结果

结构模型估计结果如表 6-2 所示。就年龄而言，以 60 岁以上为参照，其余三个年龄段的受访者对五个潜变量的系数均显著为正，介于 1.06 与 2.46 之间，说明 60 岁以下受访者在五个态度维度上的态度得分均高于老年参照组。就收入而言，以高收入组（>20000 元/月）为参照，中低收入受访者在除计划性偏好外的潜变量上得分更高。关于出行模式变量对潜变量的影响，结果显示每周出行频率超过 7 次的受访者在性价比偏好、技术接受度、计划性偏好和现状满意度上均显著为正，每周公交出行频率超过 10 次的受访者在环保意识和现状满意度上显著为正，说明依赖公交出行的受访者更关注环境保护，并对现有出行状况更为满意。每周出行频率超过 7 次（0.155）与每周公交出行频率超过 10 次（0.063）的受访者对当前出行状况更为满意，这可能得益于北京公共交通系统较为发达，出行频繁、依赖公交者往往拥有较满意的出行体验。总体而言，受访者社会经济属性和出行模式变量对五个潜变量的影响略有差异，但大多显著影响均符合预期。

更多细节见表 6-2。

表 6-2 MIMIC 结构模型估计结果（括号内为稳健 t 值）
Table 6-2 Estimation results of the MIMIC structural model (robust *t*-values in parentheses).

观测变量	性价比偏好	技术接受度	计划性偏好	环保意识	现状满意度
社会经济属性					
年龄：≤24	2.458 (7.60)***	1.521 (6.32)***	1.685 (6.27)***	1.056 (3.20)***	1.493 (6.42)***
年龄：25–44	2.203 (7.06)***	1.368 (6.17)***	1.621 (6.28)***	1.154 (3.56)***	1.360 (6.20)***
年龄：45–60	2.108 (6.85)***	1.226 (5.01)***	1.747 (6.25)***	1.314 (3.69)***	1.385 (5.60)***
职业：学生	−0.140 (−0.81)	−0.172 (−1.27)	0.009 (0.08)	0.181 (1.22)	0.014 (0.13)
收入：<6000 元/月	0.692 (3.11)***	0.398 (2.10)**	0.252 (1.49)	0.759 (2.78)***	0.274 (1.66)*
收入：6001–20000 元/月	0.638 (3.02)***	0.390 (2.10)**	0.204 (1.36)	0.657 (2.47)**	0.345 (2.16)**
出行模式属性					
每周出行频率：≥7	0.142 (2.75)***	0.119 (3.20)***	0.090 (2.65)***	0.049 (1.03)	0.155 (4.54)***
每周出行距离：≥20km	0.075 (1.68)*	0.018 (0.57)	0.050 (1.64)	0.076 (1.87)*	0.040 (1.35)
出行目的：通勤	0.098 (0.62)	0.119 (1.23)	0.201 (2.06)**	0.212 (1.58)	0.052 (0.56)
每周公交频率：≥10	−0.005 (−0.11)	0.046 (1.40)	0.005 (0.18)	0.093 (2.16)**	0.063 (2.23)**
每周地铁频率：≥10	0.072 (1.57)	0.039 (1.20)	0.007 (0.25)	−0.005 (−0.12)	0.023 (0.81)
每周出租/网约车频率：≥10	−0.002 (−0.06)	−0.018 (−0.45)	−0.027 (−0.87)	0.060 (1.30)	0.037 (1.30)
每周电单车频率：≥10	−0.132 (−2.50)**	0.068 (1.77)*	−0.058 (−1.61)	0.007 (0.14)	−0.012 (−0.33)
每周自行车频率：≥10	0.021 (0.44)	−0.010 (−0.31)	0.001 (0.03)	0.044 (0.99)	0.049 (1.59)
潜变量标准差 σ_f	1.189 (13.22)***	0.860 (15.63)***	0.523 (2.10)**	1.198 (11.72)***	0.700 (7.22)***

注：***、**、* 分别表示在 1%、5%、10% 水平下显著；年龄、收入的参照组分别为 60 岁以上、20000 元/月以上。

(2) 测量模型估计结果

测量模型估计结果如表 6-3 所示。估计结果从三个方面证实了潜变量结构的有效性：其一，全部载荷系数均为正且在 1% 水平下显著，量级介于 0.621 与 1.132 之间；其二，每个潜变量的三个响应阈值增量均为正且高度显著，确保有序 Probit 的阈值单调递增、满足识别要求；其三，指标层尺度参数因指标而异且均高度显著，反映 19 条指标响应离散程度的异质性。综上，测量模型验证了从结构模型中识别的潜变量对受访者态度陈述的影响，进一步说明潜变量结构的有效性。

表 6-3 MIMIC 测量模型估计结果（括号内为稳健 t 值）

Table 6-3 Estimation results of the MIMIC measurement model (robust t -values in parentheses).

相关指标	系数	截距	标准差
性价比偏好 （阈值增量：0.883 (11.39)***、1.105 (17.50)***、1.252 (20.80)***）			
I_1	1（固定）	0（固定）	1（固定）
I_2	0.778 (14.08)***	0.432 (2.43)**	1.114 (17.22)***
I_3	0.621 (14.48)***	0.557 (4.02)***	1.017 (18.74)***
I_4	0.789 (12.53)***	0.555 (2.78)***	1.053 (15.95)***
I_5	0.864 (15.76)***	0.229 (1.33)	1.091 (17.04)***
I_6	0.909 (16.46)***	0.011 (0.06)	1.037 (16.70)***
I_7	0.837 (12.96)***	0.423 (2.04)**	1.263 (15.45)***
技术接受度 （阈值增量：0.682 (13.90)***、0.981 (23.47)***、1.082 (26.68)***）			
I_8	1（固定）	0（固定）	1（固定）
I_9	0.958 (13.20)***	0.320 (1.92)*	0.998 (21.25)***
I_{10}	0.999 (15.12)***	-0.100 (-0.64)	0.847 (20.64)***
I_{11}	1.132 (14.58)***	-0.322 (-1.78)*	0.751 (16.81)***
I_{12}	1.108 (13.98)***	-0.363 (-1.99)**	0.872 (18.24)***
计划性偏好 （阈值增量：0.625 (8.62)***、0.830 (10.00)***、0.887 (10.14)***）			
I_{13}	1（固定）	0（固定）	1（固定）
I_{14}	0.691 (5.14)***	0.561 (2.25)**	0.938 (24.24)***
环保意识 （阈值增量：0.961 (12.15)***、1.167 (16.05)***、1.238 (18.25)***）			
I_{15}	1（固定）	0（固定）	1（固定）
I_{16}	0.945 (22.32)***	0.265 (2.47)**	0.983 (19.53)***
现状满意度 （阈值增量：0.744 (12.09)***、1.006 (17.88)***、1.234 (20.49)***）			
I_{19}	1（固定）	0（固定）	1（固定）
I_{20}	0.981 (11.33)***	-0.136 (-0.62)	1.187 (22.17)***
I_{21}	0.677 (9.57)***	0.396 (2.21)**	0.958 (23.49)***

注：***、**、* 分别表示在 1%、5%、10% 水平下显著。

6.4.2 隐马尔可夫模型估计结果

结合 MIMIC 模型的模型标定结果,进一步计算每一受访者的潜变量得分,进一步将其纳入到 HMM 模型的标定过程。本小节分析 HMM 模型的估计结果。四个子模型的完整估计结果如表 6-4 所示,括号内为稳健 t 值。下文将从总体拟合、初始行为状态识别、单次出行选择、跨阶段行为状态转移以及套餐订阅选择五个方面对 HMM 模型的估计结果进行分析。

(1) 状态数选择与总体拟合

关于行为状态数量的选取,针对行为状态数量 $K = 2 - 4$ 的模型分别进行标定。然而,行为状态数量 $K = 3$ 与 $K = 4$ 的模型均无法收敛,且在 $K = 2$ 的模型中,模型的整体拟合程度较好,且具有较好的可解释性。综上,选取 $K = 2$ 作为 HMM 模型的最优状态数。 $K = 2$ HMM 模型的最终对数似然值为 -51639.19 ,初始模型对数似然值为 -64662.29 ,调整后 McFadden $\bar{\rho}^2$ 为 0.200 ,表明模型能够较好地解释受访者从初始行为状态形成到套餐订阅选择的联合决策过程。AIC 与 BIC 分别为 103456.40 与 104187.70 。关于模型识别出的两个行为状态,根据受访者处于两行为状态在四个子模型中的决策偏好将其命名:第一个状态(表 6-4 第二列)受访者在单次出行与套餐订阅决策中对费用更为敏感,故命名为“费用敏感型”;第二个状态(表 6-4 第三列)受访者在单次出行阶段决策以及跨阶段行为状态转移中展现出对时间更为敏感的倾向,故命名为“时间敏感型”。后对这两种状态的形成过程、单次出行选择、跨阶段行为状态转移以及套餐订阅选择进行分析。

表 6-4 HMM 模型估计结果 (括号内为稳健 t 值)Table 6-4 Estimation results of the HMM (robust t -values in parentheses).

变量	费用敏感型	时间敏感型
初始行为状态隶属模型		
ASC	——	-3.880 (-14.40)***
女性	——	0.697 (12.40)***
年龄: 25-44	——	-0.009 (-0.15)
年龄: >60	——	-5.000 (-8.28)***
收入: <6000 元/月	——	0.167 (1.27)
收入: 6001-20000 元/月	——	0.775 (6.35)***
受教育程度: 本科及以上	——	0.608 (9.51)***
职业: 学生	——	-0.166 (-2.30)**
拥车	——	0.221 (3.64)***
每周公交频率: ≥ 10	——	-0.240 (-10.70)***
每周地铁频率: ≥ 10	——	0.436 (17.60)***
每周出租/网约车频率: ≥ 10	——	-0.168 (-5.51)***
每周电单车频率: ≥ 10	——	0.272 (10.50)***
主要出行方式: 租赁汽车	——	0.424 (5.19)***
主要出行方式: 共享单车	——	0.826 (11.20)***
性价比偏好	——	-0.066 (-2.14)**
技术接受度	——	0.466 (10.10)***
计划性偏好	——	0.301 (3.25)***
环保意识	——	-0.378 (-9.47)***
现状满意度	——	0.150 (2.58)***
单次出行选择模型		
ASC: MaaS	-2.050 (-9.74)***	1.920 (10.20)***
无 MaaS 时的选择: 公共交通	2.920 (14.90)***	3.590 (1.60)
无 MaaS 时的选择: 出租/网约车	-0.009 (-0.05)	1.030 (3.47)***
出发时间: 非高峰	-0.257 (-3.47)***	-0.074 (-0.35)
出行距离: >40km	-6.210 (-9.20)***	0.328 (0.99)
平均轨道交通车内时间	-0.020 (-7.16)***	-0.037 (-4.93)***
平均费用节省 (相对无 MaaS 选择, 元)	0.459 (4.45)***	0.050 (0.74)
平均时间节省 (相对无 MaaS 选择, min)	-0.017 (-0.29)	0.143 (0.19)

续下页

(续表 6-4)

变量	费用敏感型	时间敏感型
状态转移模型		
转移截距 (→ 时间敏感型)	-0.419 (-1.76)*	0.027 (0.13)
体验到的费用节省 (元)	-0.006 (-5.47)***	
体验到的时间节省 (min)	0.005 (4.03)***	
所含方式与公交频率之差	-0.294 (-5.74)***	
所含方式与地铁频率之差	-0.186 (-2.51)**	
所含方式与自行车频率之差	0.220 (3.66)***	
所含方式与出租车频率之差	-0.181 (-4.22)***	
套餐价格与月度出行花费之差	0.018 (7.22)***	
平均价格系数	0.318 (2.12)**	
套餐订阅选择模型		
方案特定常数		
ASC: 公交优先	1.320 (7.69)***	-0.271 (-2.05)**
ASC: 地铁畅行	1.160 (5.31)***	-0.967 (-6.03)***
套餐属性		
价格 (公交优先、地铁畅行, 百元)	-0.235 (-3.14)***	0.015 (0.84)
价格 (优惠出租、全能畅行, 百元)	-0.024 (-2.23)**	0.015 (0.84)
出租/网约车里程 (公交优先、地铁畅行, 百公里)	-0.067 (-0.39)	-0.213 (-3.42)***
公交优先		
女性	0.075 (0.85)	-0.323 (-7.06)***
年龄: >60	0.349 (1.34)	1.490 (7.38)***
收入: <6000 元/月	0.159 (1.33)	-0.063 (-1.01)
职业: 学生	0.294 (2.75)***	-0.121 (-2.05)**
自行车/电单车拥有	0.232 (2.68)***	0.273 (5.02)***
每周公交频率: ≥10	0.863 (15.50)***	0.120 (4.41)***
地铁畅行		
收入: 6001-20000 元/月	0.387 (5.98)***	-3.790 (-1.84)*
每周出行距离: ≥20km	0.069 (2.14)**	0.060 (2.58)***
每周地铁频率: ≥10	1.010 (16.70)***	0.333 (14.30)***
主要多模式出行: 公交 + 共享单车	0.371 (4.10)***	0.015 (0.22)
优惠出租		
年龄: 45-60	0.784 (6.74)***	-4.970 (-7.98)***
周末出行距离: ≥20km	0.036 (1.76)*	-0.253 (-2.29)**
每周出租/网约车频率: ≥10	1.380 (8.39)***	-2.260 (-6.15)***

续下页

(续表 6-4)

变量	费用敏感型	时间敏感型
套餐订阅选择模型 (续)		
套餐属性 (续)		
全能畅行		
月度出行花费: >1000 元	-0.044 (-0.63)	0.102 (2.14)**
主要出行方式: 私家车	0.402 (6.01)***	0.560 (2.60)***
PAYG		
受教育程度: 本科及以上	2.270 (4.36)***	0.412 (6.18)***
持驾照	-4.820 (-2.09)**	0.488 (8.02)***
月度出行花费: >1000 元	-0.044 (-0.63)	0.102 (2.14)**
模型概况		
样本数	27360	
初始对数似然值	-64662.29	
最终对数似然值	-51639.19	
估计参数个数	89	
似然比检验	26046.20	
调整后 McFadden ρ^2	0.200	
AIC	103456.40	
BIC	104187.70	

注: **、*、* 分别表示在 1%、5%、10% 水平下显著; “——” 表示以费用敏感型为参照、相应系数归一化为 0; 状态转移模型仅设定转移至时间敏感型的效用、转移至费用敏感型的效用归一化为 0。

(2) 初始行为状态及其决定因素

就受访者作单次出行选择前的初始状态而言, 以费用敏感型为参照状态, ASC 显著为负 (-3.880) 表明受访者更可能起始于费用敏感型, 这与 MaaS 文献的既有结论一致: 货币成本是 MaaS 采纳最常见的障碍^[87,114]。就社会经济属性而言, 女性 (0.697)、收入 6001-20000 元/月的中等收入者 (0.775) 与本科及以上受教育者 (0.608) 更可能初始为时间敏感型状态, 这可能因上述群体的时间压力相对更大, 故在出行决策中对时间比对费用更为敏感; 相反, 60 岁以上者 (-5.000) 与学生 (-0.166) 更可能为费用敏感型, 这可能是由于其时间压力相对较小、对费用更为敏感。

就出行模式属性而言, 公交与地铁的对比尤为鲜明: 每周公交频率 ≥ 10 的受访者 (-0.240) 初始更不可能处于时间敏感型, 而每周地铁频率 ≥ 10 的受访者 (0.436) 则相反。值得注意的是, 出行模式变量对初始状态形成的影响可能源于两个方面: 一方面是正向的影响, 即地铁通常被视为较公交更省时的方式, 其高效性促使使用者形成看重时间的决策取向; 另一方面则源于样本自身的出行习惯, 即

习惯乘坐公交的出行者本身在出行选择中更为在意出行费用。这种两方面的影响同样适用于其余出行模式变量,例如每周电动自行车频率 ≥ 10 的受访者(0.272)、以共享单车为主要出行方式的受访者(0.826)与拥有私人小汽车的受访者(0.221)均更可能形成时间敏感型的初始状态,不仅反映了这些灵活、按需出行方式的在节省出行时间上的吸引力,也反映了选择这些出行者本身偏重时间的生活方式。

就 MIMIC 模型测算的态度潜变量而言,技术接受度(0.466)对初始状态为时间敏感型的影响最大,计划性偏好(0.301)与现状满意度(0.150)同样正向促进出行者初始形成时间敏感型的行为状态,这可能因为针对以上态度潜变量获得较高的分的受访者乐于组织并优化其出行体验,从而更倾向于看重时间的决策风格;相反,性价比偏好(-0.066)与环保意识(-0.378)的系数为负,即具有较高性价比偏好和环保意识的受访者更倾向于进入费用敏感型的初始行为状态。就初始状态分布而言,模型估计表明 63.4% 的受访者起始于费用敏感型、36.6% 起始于时间敏感型,说明多数受访者在决策中以费用为先,而仍有一部分受访者以时间为先。

(3) 单次出行阶段的偏好异质性

本部分总结两状态在单次出行阶段的异质行为模式。首先,两种行为状态下受访者的决策偏好最直观的差异体现在针对转向 MaaS 多模式出行服务的常数(ASC)上,即费用敏感型 ASC 为 -2.050、时间敏感型 ASC 为 1.920,说明在其他属性相同时,费用敏感型受访者倾向于拒绝在单次出行阶段使用 MaaS 多模式出行服务,而时间敏感型受访者倾向于采纳 MaaS。从选择结果的概率分布来看,有 21.7% 的费用敏感型受访者在单次出行阶段选择转向 MaaS 多模式出行服务,然而,却有 80.9% 的时间敏感型受访者选择转向 MaaS 多模式出行服务,进一步说明两状态在单次出行阶段的决策偏好存在显著差异。MaaS 多模式出行服务带来的费用节省与时间节省系数的标定结果进一步揭示了这一行为差异背后的机理。针对费用敏感型行为状态,平均费用节省系数显著为正(0.459),说明对出行费用的考量主导该状态的决策,即 MaaS 出行服务节省的出行费用越多,费用敏感型受访者越可能选择 MaaS;而时间敏感型状态下,费用节省的标定系数不显著,表明费用节省在其决策中作用并不显著。与此相对,平均轨道交通车内时间的系数在时间敏感型(-0.037)中较费用敏感型(-0.020)更强地为负,表明时间敏感型受访者对 MaaS 多模式出行服务的出行时间更为敏感。

就无 MaaS 情境下受访者选择的既有出行方式的影响而言,估计结果呈现出明显的状态异质性。在费用敏感型状态下,无 MaaS 时本会选择公共交通的受访者更可能转移至采用 MaaS 多模式出行服务(2.920),说明在 MaaS 多模式无缝集成下,MaaS 以公交为导向且能够帮助出行者节省出行成本的定位可吸引这部分用

户；在时间敏感型中，无 MaaS 时本会选择出租/网约车的受访者显著更可能转移至 MaaS (1.030)，这可能是因为 MaaS 提供了地铁 + 出租/网约车、合乘等更省时的 MaaS 选项，对本会选择出租/网约车的时间敏感型受访者更具吸引力。就情境变量而言，费用敏感型下非高峰出发时间 (-0.257) 与长出行距离 (-6.210) 的系数显著为负，说明费用敏感型受访者在这些情境下更不愿转向 MaaS 多模式出行服务。

(4) 跨阶段行为状态转移机理

状态转移模型刻画受访者的行为状态如何在单次出行与套餐订阅两阶段之间发生改变，须说明的是，本子模型仅设定转移至时间敏感型的效用，转移至费用敏感型的效用归一化为 0。就转移截距而言，费用敏感型受访者的系数为负 (-0.419)，说明在其他属性不变时，处于费用敏感型的受访者倾向于保持费用敏感型状态，而非转向时间敏感型状态。接下来分别对影响状态转移的因素进行分析。

就单次出行阶段所体验到的 MaaS 多模式出行服务带来的费用与时间节省变量而言，二者对状态转移的影响效果相反。受访者在单次出行阶段因采用 MaaS 出行服务而节省的出行费用的估计系数显著为负 (-0.006)，说明在单次出行中获得更高费用节省的受访者更可能保持或转入费用敏感型；因采用 MaaS 出行服务而节省的出行时间估计系数显著为正 (0.005)，说明获得更高时间节省的受访者更可能转入时间敏感型。上述费用节省和时间节省的结果表明，受访者在单次出行阶段的实际体验会强化其相应的决策取向，即体验到费用节省的受访者更趋于转向费用敏感型状态，体验到时间节省的受访者更趋于转向时间敏感型状态。

就套餐订阅带来的预期节省的出行费用而言，套餐价格与受访者当前月度出行花费之差对转入时间敏感型有显著正向影响 (0.018)，说明套餐定价偏离受访者当前支出的套餐会将其推离费用敏感型；套餐的平均价格系数同样显著为正 (0.318)，说明价格系数较高的套餐也会将受访者推离费用敏感型。上述结果表明，费用敏感型受访者不仅对套餐的价格水平较为敏感，并当套餐定价与其既有支出预期不符时更易转向时间敏感型状态。

就受访者主要出行方式与套餐所含方式的匹配程度而言，首先计算受访者主要方式频率与四种套餐所含的各种方式的服务水平的最小差的绝对值，代表 MaaS 套餐与受访者主要方式的匹配程度，再估计其对状态转移的影响。估计结果表明，四种方式的匹配程度的系数估计结果对受访者的状态转移影响不尽相同。公交 (-0.294)、地铁 (-0.186) 与出租/网约车 (-0.181) 的系数均显著为负，表明套餐中这些方式的服务水平与受访者主要的出行方式使用频次越匹配，越会导致其转向费用敏感型状态。这可能是套餐内出行方式服务水平的匹配强化了受访者对套餐经济性的评估。例如，对公共交通服务而言，出行者通常对其月度支出与

使用频率有相对稳定的预期,当所供服务大幅超出或不足于实际出行需求时,便会感知到更高的闲置或额外支出风险,从而降低对套餐经济性的评价。与之相反,针对自行车的匹配程度的估计系数显著为正(0.220),表明套餐内自行车可用的次数与受访者的使用自行车的出行频次越匹配,越会使受访者转向时间敏感型状态。这可能是因为北京的自行车/共享单车出行高度灵活、且常与其他方式组合,对上述分析中初始状态更可能为时间敏感型的自行车用户而言,套餐中的自行车服务可作为其熟悉的方式,使其更易接受套餐的省时与多模式集成收益。

(5) 套餐订阅阶段的偏好异质性

在上述分析完初始状态形成、单次出行选择以及跨阶段状态转移后,本小节分析两行为状态针对套餐订阅阶段的偏好异质性。

针对费用敏感型,公交优先(ASC为1.320)与地铁畅行(ASC为1.160)两套餐显著较PAYG更具吸引力,说明费用敏感的受访者在其他变量相同时更偏好价格较低、以公交为导向的套餐;而针对时间敏感型,这两种公交导向套餐则不具显著的吸引力(ASC分别为-0.271与-0.967)。从套餐选择分布来看,公交优先与地铁畅行分别被24.3%与32.4%的费用敏感型受访者选择,也分别被21.8%与23.3%的时间敏感型受访者选择。此外,优惠出租与全能畅行在费用敏感型受访者中的订阅比例分别为23.4%与17.6%,而在时间敏感型受访者中几乎被拒绝(仅0.5%与1.8%)。与之相对,PAYG最受时间敏感型受访者青睐(52.6%),在费用敏感型中却最不受偏好(2.4%)。综合而言,受访者处于费用敏感型时偏好公交导向的套餐,处于时间敏感型时则可能偏好PAYG的灵活性。

就套餐自身的属性而言,套餐价格对费用敏感型受访者在公交导向套餐(-0.235)与其余两种套餐(-0.024)上均显著为负,体现出费用敏感型受访者固有的高价格敏感性;而在时间敏感型中,两个套餐价格系数均不显著(0.015)。公交导向套餐中可用的出租/网约车对费用敏感型受访者不显著(-0.067),而对时间敏感型受访者影响显著且为负(-0.213),说明向公交导向套餐中加入出租/网约车服务不能吸引处于任一行为状态的受访者。

就社会经济与出行模式属性的影响而言,状态异质性同样明显。总体上,费用敏感型受访者更倾向于依自身特征订阅套餐,时间敏感型受访者则更倾向于拒绝订阅套餐、但可被与其出行模式匹配的套餐所吸引。以优惠出租套餐为例,常乘出租车(每周不少于10次)的受访者处于费用敏感型时强烈倾向于订阅优惠出租(1.380),处于时间敏感型时则强烈拒绝订阅(-2.260);45-60岁受访者(0.784对-4.970,均显著)与周末长距离出行者(0.036对-0.253,均显著)也呈现类似的结果。以上结果说明,当这些群体处于费用敏感型时,会将优惠出租视为其既有出租车出行习惯的成本控制策略;而处于时间敏感型时则倾向于拒绝优惠出租,可

能是因为其省时收益相对 PAYG 的灵活性不够有吸引力。不过, 时间敏感型受访者仍可被与其出行模式匹配的套餐吸引, 这体现于常乘公交的受访者对公交优先 (0.120)、常乘地铁的受访者对地铁畅行 (0.333) 以及高月度出行花费的受访者对全能畅行 (0.102) 的显著正向的订阅倾向。

综合上述估计结果, 可对两类行为状态的受访者作如下归纳: 费用敏感型受访者以费用为决策核心, 初始占比更高, 在单次出行阶段对 MaaS 较为谨慎、仅在 MaaS 多模式出行服务可带来可观的费用节省时才愿意转向 MaaS, 在套餐订阅阶段则偏好价格较低的公交导向套餐并对价格高度敏感; 时间敏感型受访者以时间与灵活性为决策核心, 在单次出行阶段倾向于采纳 MaaS, 在套餐订阅阶段却更偏好保留 PAYG 的灵活性、对套餐价格不敏感。

6.5 弹性分析与讨论

6.4节的估计结果已识别出费用敏感型与时间敏感型两种行为状态, 并刻画了二者在两阶段的偏好异质性与跨阶段转移时两者互相切换的行为机理。然而, 估计系数仅反映影响因素的边际贡献, 难以捕捉影响因素从初始状态形成到套餐订阅全生命周期下对提升受访者 MaaS 采纳意愿的作用。为此, 本节首先计算两种行为状态下 MaaS 多阶段的服务水平对 MaaS 采纳 (转向 MaaS 多模式出行服务或 MaaS 套餐订阅) 的弹性 (状态条件弹性, 6.5.1小节), 继而面向两种行为状态, 沿初始状态 → 单次出行 → 状态转移 → 套餐订阅的行为链条, 给出面向全体用户的 MaaS 采纳聚合弹性 (6.5.2小节), 最后将本章的一体化建模结果与第5章的分阶段建模加以对比, 厘清两种范式的适用边界并为第7章提供依据 (6.5.3小节)。

6.5.1 行为状态的条件弹性分析

为量化各行为状态 MaaS 采纳意愿 (单次出行阶段或套餐订阅阶段) 对相关属性变化的敏感程度, 本小节计算两种行为状态下单次出行 MaaS 采纳概率与套餐订阅概率的状态条件点弹性。考虑到 MaaS 服务水平相关的属性更具政策与运营干预意义, 因此本节聚焦 MaaS 服务水平类属性 (如费用节省、时间节省、轨道车内时间、套餐价格与公交导向套餐中可用的出租车里程) 的弹性。两状态的状态条件弹性如图 6-3所示。




图 6-3 服务水平相关属性对 MaaS 多阶段采纳意愿的状态条件弹性

Figure 6-3 State-conditional elasticities of multi-stage MaaS adoption intention with respect to level-of-service attributes.

对于费用敏感型受访者，其决策主要取决于费用。在单次出行阶段，其转向 MaaS 多模式出行服务的意愿关于平均费用节省的弹性为 -0.024 ，而关于平均时间节省的弹性仅为 -0.001 ，即费用节省每改善 1% 对费用敏感型采纳的提升约为时间节省的 24 倍；其关于 MaaS 选项平均轨道交通车内时间的弹性也较大 (-0.658)。考虑到费用敏感型受访者在单次出行阶段中转向 MaaS 多模式出行服务的概率较低 (21.7%)，因此，轨道服务水平的改善或许是针对此类受访者提高单次出行阶段 MaaS 采纳意愿的有效手段。在套餐订阅阶段，费用敏感型下四个价格弹性均为负且较大：公交优先 -0.524 、地铁畅行 -0.709 、优惠出租 -0.217 、全能畅行 -0.364 ，其中两个公交导向套餐的价格敏感性更高，这可能因其更易被视为具有公交习惯的受访者的高性价比策略，价格变动对其性价比评估的影响更强。与之相对，公交导向套餐中可用的出租/网约车里程在该状态下的弹性几乎为零（公交优先与地铁畅行均为 -0.028 ）。

对于时间敏感型受访者，其决策主要取决于时间。在单次出行阶段，其时间节省弹性为 -0.006 ，约为费用敏感型的 6 倍，而费用节省弹性仅为 -0.001 。此外，轨道车内时间弹性为 -0.472 ，量级小于费用敏感型，原因在于时间敏感型受访者的 MaaS 采纳概率很高 (80.9%)，相同的影响系数所产生的采纳意愿的百分比变化更小。在套餐订阅阶段，时间敏感型的四个价格弹性均为正值（公交优先 0.035、地铁畅行 0.052、优惠出租 0.181、全能畅行 0.277）。究其原因，套餐价格并未进入

时间敏感型受访者的决策考量,即该状态下套餐价格系数不显著(0.015)。故上述价格弹性应解读为零值附近的小幅响应,而非真实的行为结果。相比之下,价格系数的聚合弹性更能说明其对此类受访者的行为影响。套餐价格的整体上浮会使优惠出租与全能畅行的订阅份额分别下降 0.167 与 0.121,同时使 PAYG 的订阅份额上升 0.112。此外,公交导向套餐中可用的出租/网约车里程对时间敏感型受访者的弹性为 -0.105 (两套餐相同),量级约为费用敏感型的 4 倍,说明向公交导向套餐中加入出租车里程同样会抑制时间敏感型受访者的订阅。

综合以上两行为状态下的条件弹性结果,费用敏感型与时间敏感型不仅在行为偏好上不同,同一服务水平属性对采纳意愿的边际改善也呈现不同的特征,即费用敏感型受访者对费用类属性高度敏感、时间敏感型受访者对时间类属性高度敏感。然而,本节的状态条件弹性仅刻画了各状态对 MaaS 服务水平变化的响应,难以回答考虑全体用户的“哪些因素最能提升 MaaS 采纳”的问题,这正是下一小节的关注点。

6.5.2 考虑全体用户的 MaaS 服务水平弹性

在理解不同行为状态下的受访者采纳 MaaS 的条件弹性后,MaaS 运营方还需全面了解哪些因素最能提升全体潜在用户对 MaaS 的采纳意愿。为此,本节构建了从初始状态形成到套餐订阅的完整行为链条,并沿链条计算各因素对全体用户 MaaS 套餐订阅的聚合弹性,以作为 MaaS 长期发展的政策与运营干预的依据。具体而言,首先使用两种行为状态的初始分布与跨阶段转移概率,对状态条件弹性进行加权聚合,最终得到面向全体用户的聚合弹性。后续从 MaaS 套餐整体订阅弹性与分套餐的 MaaS 套餐订阅弹性两个角度进行分析。

(1) MaaS 套餐整体订阅弹性

关于 MaaS 套餐整体订阅的聚合弹性如图 6-4 所示。结果表明,MaaS 多模式出行服务中的平均轨道交通车内时间的聚合弹性最大,为 -0.521 ;平均费用节省与平均时间节省的聚合弹性分别约为 -0.014 与 -0.006 。状态转移过程中的套餐价格与受访者参照月度出行支出之间差异的聚合弹性为 -0.055 ,公交导向套餐中可用的出租车/网约车里程为 -0.046 ,各套餐价格的弹性则均低,均小于 0.005。这说明 MaaS 多模式出行服务的平均轨道交通车内时间可能是提升潜在用户 MaaS 采纳意愿最有效的干预手段。




图 6-4 MaaS 套餐整体订阅弹性

Figure 6-4 Aggregate elasticities of overall MaaS bundle subscription.

(2) 分套餐的订阅弹性

除 MaaS 套餐整体的订阅弹性外, 对各套餐订阅概率的聚合弹性如图 6-5 所示。四个套餐的平均轨道交通车内时间、平均费用节省与平均时间节省弹性的规律近似, 即关于平均轨道交通车内时间的弹性均为负且量级接近 (公交优先 -0.519 、地铁畅行 -0.520 、优惠出租 -0.524 、全能畅行 -0.523), 关于费用节省与时间节省的弹性同样相似但量级较小 (分别约 -0.014 与 -0.006)。

在价格敏感性上, 公交导向套餐和其他两类套餐的弹性计算结果呈现出两种不同的模式。对公交导向套餐, 其对自身价格的聚合弹性较小 (公交优先 -0.106 、地铁畅行 -0.183), 套餐所含的出租车/网约车里程会降低其订阅概率 (公交优先 -0.081 、地铁畅行 -0.077)。价格比例系数则弹性较小 (公交优先 0.013 、地铁畅行 -0.005), 原因在于, 公交导向套餐在两种行为状态下的订阅比例相近 (公交优先为 24.3% 对 21.8% , 地铁畅行为 32.4% 对 23.3%), 价格比例系数变动所诱发的行为状态转移并不会导致套餐订阅结果的过多改变。此外, 公交优先与地铁畅行二者之间的交叉价格弹性均为正 (公交优先关于地铁畅行价格为 0.087 , 反向为 0.050), 二者互为替代。与之相对, 优惠出租与全能畅行对价格比例系数 (分别 -0.167 与 -0.121) 与自身价格 (分别 -0.178 与 -0.203) 均更为敏感。这一差异源于两状态下对这两种套餐的订阅份额分布, 即费用敏感型状态下对优惠出租与全能畅行订阅意愿较大 (集计后的订阅比例分别为 23.4% 与 17.6%), 而时间敏感型状态下的受访者几乎拒绝订阅这两类套餐 (集计后的订阅比例分别为 0.5% 与

1.8%)。此外,当价格比例系数上升时,受访者趋于转向时间敏感型,而时间敏感型状态下对这两类套餐的订阅意愿很低,其订阅比例随之下降。然而,优惠出租与全能畅行两类套餐可从公交导向套餐的价格变动中获得可观的替代需求,其关于公交优先套餐价格的交叉弹性分别为 0.129 与 0.097,关于地铁畅行价格的交叉弹性分别为 0.277 与 0.202,说明其会吸收费用敏感型受访者因公交导向套餐涨价而释放的套餐订阅需求。




图 6-5 分套餐的订阅弹性

Figure 6-5 Bundle-specific aggregate subscription elasticities.

综上,单次出行阶段服务水平对最终套餐订阅的聚合弹性较大,尤其是 MaaS 多模式出行服务的平均轨道交通车内时间。在套餐订阅阶段,套餐内各属性的整体订阅弹性较小,因套餐内属性的调整主要导致受访者在四个套餐之间重新分配订阅需求,而非扩大套餐订阅总量。

6.5.3 分阶段与一体化建模结果对比

在全面分析一体化建模视角下得到的结果后,本小节进一步针对第5章的分阶段建模结果与本章的一体化建模结果进行对比,有助于厘清两种建模方法的适用边界,并为第7章的行为参数选用奠定基础。

(1) 共同发现

就实质结论而言,两种建模视角相互印证了若干结论:其一,受访者的 MaaS 偏好高度异质;其二,货币成本是核心决策驱动;其三,公共交通用户较私家车用户更易接受 MaaS。此外,既有研究中关于社会经济属性的规律性结论,即女性、较高收入者、高受教育程度者与技术热衷者更易接受 MaaS,在本章估计中同样得到确认。在此之上,一体化建模还揭示了分阶段建模难以呈现的细节。例如,经常乘坐地铁的受访者倾向于初始归属于时间敏感型状态,而经常乘坐公交的受访者则倾向于初始归属于费用敏感型状态,即“公交用户更易接受 MaaS”这一结论存在公交用户与地铁用户的分化,有助于运营方区分应优先瞄准的公交细分人群。

(2) 方法论差异

两种建模方法的差异主要体现在两方面。

其一是异质性的处理方式。分阶段建模通过潜在分类刻画行为异质性,受访者的潜在类型在各阶段内固定不变;一体化建模则通过 HMM 允许行为状态在单次出行与套餐订阅两阶段间转移,从而观测到分阶段建模设定无法捕捉的状态转移机理,例如,在单次出行阶段体验到的 MaaS 多模式出行服务节省的费用将使受访者更倾向于转入费用敏感型状态,节省的时间将使其更倾向于转向时间敏感型状态。

其二是跨阶段的衔接方式。分阶段建模以单次出行阶段计算得到的转移意愿指数衔接两阶段,并先后独立估计两阶段的选择模型;一体化建模则在单一联合似然下、经 K^2 条状态路径求和同时估计两阶段行为选择。正是凭借这一联合结构,本章得以量化单次出行阶段属性对最终套餐订阅的整体影响。

(3) 适用边界

综合而言,两种建模视角各有其适用情境。分阶段建模的优势在于,可在各阶段内引入更丰富的模型结构(如套餐订阅阶段的属性无视、嵌套 Logit 巢结构与精细的潜在类别画像),从而分别精细刻画两阶段的偏好异质性,各阶段的行为可解释性更强,适于面向单一阶段、需要精细划分人群画像的运行需求。一体化建模的优势则在于,在统一似然函数下联合刻画初始状态形成、跨阶段状态转移与两阶段选择,能够直接捕捉单次出行获取到的出行体验对套餐偏好的影响,并在全周期视角下给出 MaaS 采纳的关键因素,适于理解跨阶段的动态联系与全生命周期的 MaaS 采纳意愿。

6.6 本章小结

本章在第5章分阶段建模的基础上,研究了 MaaS 多阶段采纳意愿的一体化建模问题。针对分阶段建模无法捕捉受访者从单次出行到套餐订阅阶段的行为状态转移、难以通过统一的建模方式刻画受访者全过程采纳意愿的局限性,本章提出了结合 MIMIC 模型的 HMM 建模框架,完整地刻画了受访者从初始状态形成、单次出行选择、跨阶段状态转移到套餐订阅选择的全过程,并经与第5章相同的两步式 SP 调查数据(1242 份有效样本)加以标定与验证。主要工作与结论如下。

其一,构建了 MIMIC-HMM 建模框架。该框架通过 MIMIC 模型从态度陈述中计算五个态度潜变量的态度得分,并将其纳入初始行为状态的形成过程。进一步,构建 HMM 模型在联合刻画初始行为状态形成、单次出行选择、跨阶段状态转移与套餐订阅选择四个相互衔接的过程,并构建统一的似然函数。Biogeme 标定结果表明,调整后 McFadden ρ^2 达 0.200,表明 HMM 模型对受访者 MaaS 多阶段采纳意愿的拟合良好。

其二,识别出两种具有显著偏好异质性的行为状态。通过对受访者多阶段 MaaS 采纳行为的一体化估计,HMM 识别出贯穿受访者决策行为全周期的费用敏感型与时间敏感型两个状态,分别占初始状态分布的 63.4% 与 36.6%,反映受访者以费用或以时间为先的两类决策偏好。在单次出行阶段,费用敏感型受访者对 MaaS 多模式出行服务带来的费用节省敏感,而时间敏感型受访者则更关注单次出行中 MaaS 多模式出行服务的时间成本;在套餐订阅阶段,费用敏感型受访者偏好公交导向套餐且对价格高度敏感,时间敏感型受访者则偏好 PAYG(占其订阅的 52.6%),但对能满足其出行需求的套餐仍有一定的订阅意愿。

其三,揭示了跨阶段行为状态转移机理。在单次出行阶段体验到更高 MaaS 多模式出行服务带来的费用节省的受访者更可能转入或保持费用敏感型状态,体验到更高 MaaS 多模式出行服务带来的时间节省的受访者则更可能转入时间敏感型状态;套餐价格偏离当前每月的出行成本、套餐的价格比例系数偏高均会使受访者不再保持费用敏感型状态。这一机理刻画了既有文献与第5章所未能捕捉的、连接“初次体验”与“长期订阅”的动态行为状态转换。

其四,给出了从单次出行到套餐订阅全周期的 MaaS 采纳关键因素。沿“初始状态 → 单次出行 → 状态转移 → 套餐订阅”的行为链条的聚合弹性表明,单次出行阶段 MaaS 多模式出行服务的平均轨道交通车内时间聚合弹性最大,为 -0.521,比所有套餐内服务水平属性的聚合弹性均高出一个数量级。此外,单次出行阶段的 MaaS 多模式出行服务的平均费用节省与时间节省也具有较高的聚合弹性,而套餐内的价格与出租/网约车里程的聚合弹性均较小。以上针对全体用户的聚合弹性分析为 MaaS 全生命周期推广策略提供了行为依据。

上述分阶段建模与一体化建模的结果各有侧重、相互补充：第5章分阶段建模可获得各阶段的选择模型与各阶段内精细的人群画像，有助于理解各阶段的行为偏好与异质性；本章一体化建模则可刻画跨阶段的行为状态转移机理，所得的全周期 MaaS 采纳关键因素的聚合弹性分析，则为推广策略着力点提供了行为层面的依据。

7 基于仿真优化的 MaaS 推广策略优化

7.1 本章引论

前述各章依次完成了城市级 MaaS 推广策略仿真所需虚拟人口和活动计划的构建与 MaaS 多阶段采纳机理的解析。在此基础上,本章聚焦研究内容(4):基于城市级仿真的 MaaS 推广策略优化。具体而言,以第3章的合成人口与第4章生成的活动计划作为全市居民的初始状态,构建城市级仿真智能体集合,进而结合第5章的多阶段采纳行为模型,构建居民采纳 MaaS 的多阶段决策机理,形成城市级 MaaS 推广策略优化问题的多智能体仿真评估框架。考虑到仿真模型对计算资源的高消耗以及推广策略空间的高维特性,提出能够在有限的仿真计算资源的前提下能够准确复现仿真系统输入(推广策略)-输出(采纳率、平台净收入、碳减排等多目标)映射关系的代理模型,进而提出能够有效利用代理模型进行高效搜索的多目标优化方法,以支撑城市级 MaaS 推广策略的科学制定。下面对该问题的特性进行简要分析。

首先,推广策略的效果评估须建立在可信的采纳决策仿真之上。推广策略包含套餐设计、套餐定价、营销投放、多模式出行服务质量等多维度内容,其各维度对居民采纳决策的影响机制有所不同。具体而言,多模式出行服务质量、套餐设计、套餐定价等策略维度通过影响居民对 MaaS 的感知价值与感知成本作用于个体的采纳决策;另一方面,营销投放等策略维度通过影响居民对 MaaS 的认知程度与认知速度作用于个体的采纳决策。此外,在新技术接受相关研究中,个体的采纳决策不仅受自身感知价值、感知成本与认知程度的影响,还受到同伴影响的作用。例如,个体的采纳又经由口碑传播与空间集聚效应反过来影响其他个体的认知进程,形成复杂的社会扩散过程。除个体的采纳行为外,个体采纳 MaaS 带来的诸如运营商收入、碳减排等社会效益也是推广策略效果评估的关键指标。因此,如何构建上述推广策略对个体的采纳决策的影响机制,以及个体采纳决策对其他个体认知进程的传播机制,进而准确模拟推广策略带来的实际效果,是开展推广策略优化的前提条件。

其次,需设计兼顾探索和利用的代理模型以辅助大规模策略空间下的寻优过程。推广策略并非一组静态参数,其包含的套餐设计、套餐定价、营销投放及多模式出行服务质量均可分时间、分区域动态调整,由此形成的决策空间维度较高。考虑到本文需构建的推广策略仿真系统是涉及超大城市内海量智能体在多区域、多时段下的多阶段采纳决策的复杂系统,具有非线性、非凸、非平稳的特性,难以获

取仿真系统输出结果对输入推广策略的精确梯度信息, 导致无法利用仿真系统对策略空间进行高效搜索。然而, 由于策略空间的高维特征, 直接以仿真评估在策略空间进行枚举在计算上不可行。因此, 需构建能够准确近似仿真输出的代理模型, 以支撑大规模策略空间下的高效搜索, 这对代理模型的探索与利用能力提出了较高的要求。

针对以上难点, 本章的研究目标确定为: 设计能够精准模拟推广策略效果的多智能体仿真模型, 构建兼顾探索与利用的代理模型, 并提出能够在有限仿真预算下高效搜索策略空间的多目标优化方法, 以支撑城市级 MaaS 推广策略的科学制定。具体而言, 本章的研究内容设置如下:

(1) 超大城市 MaaS 多阶段采纳多智能体仿真模型。

以第3章的合成人口与第4章生成的活动计划模拟全市居民的社会经济属性与日常出行行为, 设计融合扩散传播与空间网络效应的社交网络影响机制以模拟居民对 MaaS 的认知状态。进而, 在给定推广策略的前提下, 结合第5章的多阶段采纳行为模型, 模拟居民单次出行阶段及长期采纳阶段的多阶段采纳决策过程, 对全市居民采用 MaaS 的采纳率、平台净收入及碳减排等多目标指标进行仿真评估。

(2) 面向 MaaS 推广策略评估的代理模型设计。

针对多智能体仿真模型的高计算消耗特性, 设计能够在有限仿真预算下兼顾探索与利用的代理模型, 以支撑大规模策略空间下的高效搜索。具体而言, 首先推导多智能体仿真模型的平均场解析代理, 以毫秒级的确定性递推提供廉价物理先验, 并在其上叠加高斯过程残差校正构成混合解析代理模型; 其次设计融合分区时序卷积、跨区注意力与基于观测样本的条件推断的深度学习代理模型, 以解析先验预训练缓解仿真样本稀缺, 以盒稳定训练改善其可反求解性, 进而在信赖域中心构造可精确求解的混合整数规划模型, 通过求解生成在该信赖域内具有全局最优性保证的候选策略。

(3) 面向推广策略寻优的多目标优化算法设计。

针对推广策略空间高维、用户采纳率、平台净收入与碳减排三项目标相互冲突以及单次仿真评估成本高昂的问题, 提出基于信赖域机制的多目标优化算法。具体而言, 首先将三项目标按不同偏好进行标量化, 构建分别偏好用户采纳率、平台净收入与碳减排且共享仿真样本与 Pareto 解集的三个信赖域; 在各信赖域内调用与代理模型相匹配的反向求解方法生成候选策略, 并将候选策略输入至多智能体仿真模型获得实际目标值, 根据代理预测改善与仿真实际改善的一致性动态调整信赖域中心与范围; 同时利用新增仿真样本在线更新代理模型, 进而在有限仿真预算下获得覆盖不同目标偏好方向的 Pareto 近似解集。

针对上述特性, 本章提出基于仿真优化的 MaaS 推广策略优化框架, 总体思

路如图 7-1所示，其由环环相扣的四部分构成。(1) 融合扩散传播与空间网络效应刻画认知过程，以第5章的行为模型驱动智能体决策，构建涵盖认知、试用、订阅、留存等决策机制的 MaaS 采纳多智能体仿真模型，作为策略评估的基础；(2) 推导仿真模型的平均场解析代理，并在其基础上叠加高斯过程残差校正构成混合解析代理模型；(3) 设计融合分区时序卷积、跨区注意力与基于观测样本的条件推断的深度学习代理模型，以解析先验预训练缓解仿真样本稀缺问题，提出盒稳定损失以改善其可反求解性，并在信赖域中心将其表达为混合整数规划模型，通过求解该模型生成在该信赖域内具有全局最优性保证的候选策略；(4) 提出基于信赖域机制的多目标优化算法，以与代理模型相匹配的反向求解方法生成候选策略，通过仿真模型对候选策略的评估结果管理三个目标偏好信赖域，进而在线更新代理模型，在有限仿真预算下形成覆盖不同目标偏好方向的非支配候选策略。




图 7-1 基于仿真优化的 MaaS 推广策略优化框架

Figure 7-1 Framework for simulation-based optimization of MaaS promotion strategies.

本章其余部分安排如下：7.2节构建基于多智能体仿真的推广策略评估模型；7.3节构建仿真优化问题，设计混合解析代理与深度学习代理两类代理模型及其反向求解方法；7.4节提出基于信赖域机制的多目标优化算法；7.5节与7.6节分别开展基于居民出行调查数据的小规模算例实验与基于合成人口的大规模算例实验；7.7节总结本章。

7.2 基于多智能体仿真的推广策略评估模型

相较于以聚合需求曲线刻画用户响应的优化建模路线，多智能体仿真能够在个体层面保留用户策略响应的异质性，并刻画采纳行为经由社会网络相互影响的扩散过程，是既有研究已采用的评估 MaaS 大规模推广潜力的新范式^[130,182]。为此，本节在第3章合成人口与第4章活动计划构成的仿真微观底座之上，以第5章估计的多阶段采纳行为模型驱动智能体决策，构建基于多智能体仿真的 MaaS 推广策略评估模型。模型自下而上地模拟给定推广策略作用下全市居民对 MaaS 由认知、试用、订阅到留存或流失的全生命周期采纳过程，并输出用户采纳率、平台净收入与碳减排三项评价指标，仿真模型的总体框架如图 7-2 所示。




图 7-2 推广策略仿真评估模型框架图

Figure 7-2 Framework of the simulation model for evaluating MaaS promotion strategies.

本节首先介绍仿真模型的基本设定，随后依次介绍模型的四个模块：7.2.2 小节构建刻画认知扩散与营销推广效果的 MaaS 认知扩散模块；7.2.3 小节构建包括单次试用、是否订阅、套餐选择三层决策机制的多阶段采纳意愿决策模块；7.2.4 小节构建基于月度续订决策的用户留存与流失模块；7.2.5 小节为推广策略效果评估模块，定义多目标评价指标体系以及核算方法。

7.2.1 仿真模型基本设定

首先明确仿真模型的基本设定，包括仿真区域与时间设定、智能体设定以及推广策略设定。然后，基于上述设定，给出仿真模型的总体流程。

(1) 仿真区域与时间设定

仿真区域为北京市，其空间组织划为三个粒度。最小的空间粒度为交通小区，考虑到其最能体现居民的邻里接触特性和小区内部交通设施的均质性，将其作为 MaaS 口碑传播的主要空间载体与营销预算投放的基本单元。中间粒度为行政区，仅作为推广策略评估中用户采纳率的统计单元；最大的空间粒度为推广策略分区，考虑到逐行政区独立设置策略会使决策空间过度膨胀，且部分行政区在人口结构、经济水平、交通设施等方面的特征具有相似性，故将全市行政区按收入构成、小汽车拥有率、公共交通与出租/网约车使用强度等人口结构特征聚合为 Z 个策略分区，统一策略分区内的所有行政区共享一套推广策略，分区的具体构造见 7.5.1 小节。

时间设定上，考虑到推广过程中居民对 MaaS 的认知状态、试用积累与订阅续订等动态状态变量的时变性，以及推广过程中可能会涉及用户的流失与再次采纳等跨期行为，本章将仿真规划期设置为 3 年，以充分捕捉 MaaS 推广策略在较长评估期下的效果。针对 3 年仿真评估期下的策略调整，将 3 年均分为 $K = 6$ 个连续的半年阶段，推广策略在各阶段初更新，与真实运营中按季度、半年度滚动调整策略的实践相符。针对仿真步长的设定，考虑到居民出行行为的周期性以及仿真模型的计算成本，仿真以 1 周为步长推进。在每个仿真步长内，智能体根据其当前的状态、账期进度以及推广策略等信息，做出是否试用、是否订阅、选择何种套餐以及是否续订的决策，并更新其动态状态变量。

(2) 智能体设定

根据算例的不同，智能体构建有两种方法：其一，7.5 节小规模算例中，智能体直接以居民出行调查数据中的个体构建；其二，7.6 节的大规模算例中，以第 3 章合成人口构建，出行特征来源于第 4 章生成的家庭活动计划。两种方法除个体数据的来源外无任何不同，其多阶段采纳行为均由第 5 章的行为模型驱动。每个智能体 i 携带三类静态特征与一组动态状态变量。

静态特征包括：社会经济与家庭属性（年龄、性别、职业、收入、受教育程度、驾照持有情况与家庭车辆保有等）；出行特征（各方式周使用频次、日均出行次数、通勤距离与私家车月度驾驶里程等）；月度出行费用，即按现行票制价格核算的既有方式月度出行支出。其中，社会经济与家庭属性变量可由居民出行调查数据或人口合成结果直接获取。假设个体的出行行为在短期内相对稳定，为从个体的出行记录中获取出行特征变量，设计相应规则进行构造。具体而言，日均出行次数取当日出行总次数，月度出行数按每月 22 个工作日折算；各方式周使用频次参考当日使用次数，若当日使用某方式不少于 2 次，则将其定义为对应方式“每周 10 次及以上”的高频使用者；出行距离变量按第 5 章实验设计的距离分档编码；主要出行方式按当日机动化出行的主导方式作类别编码，作为行为模型中出行惯性与偏好延续变量的输入；私家车月度驾驶里程仅累加个体作为驾驶员的小汽车出行

距离，并按工作日折算至月度。月度出行费用同理由逐次出行记录构造，按现行票制对各程出行逐一计价后加总折算。上述构造规则与第5章行为模型估计时的变量含义对齐，模型估计参数因此可直接应用于仿真模型的个体决策中。

动态状态变量刻画智能体在 MaaS 推广过程中过去的行为决策及所处状态，如表 7-1 所示。其中，所处状态是核心状态变量，代表智能体现在是否认知 MaaS、是否在使用 MaaS 以及是否流失，取“未认知、已认知、试用中、已订阅、已流失”五种取值之一，其五种状态之间的转移规则如图 7-2 所示。具体而言，未认知过 MaaS 的智能体经由其他智能体扩散传播与投入的营销宣传可转为已认知 MaaS 状态；已认知 MaaS 的智能体经单次出行下的 MaaS 服务试用积累使用经验，在满足相关条件后决定是否订阅 MaaS 以及选择何种套餐，转为试用中或已订阅状态；已订阅的智能体按在套餐有效期末对当前套餐作续订与否的决策，未续订者转入已流失状态；已流失的智能体保留对 MaaS 的认知与使用记忆，自次周起即可重新试用，但须重新积累试用经验。关于表 7-1 中其他状态变量，曾订阅指示 $e_{i,t}$ 标识智能体是否订阅过 MaaS 套餐，标识为是的智能体将被计数在 MaaS 认知扩散模块中的累计采纳份额中；累计试用次数 $n_{i,t}^{tr}$ 记录智能体在试用阶段使用 MaaS 单次出行服务的次数，用以评估智能体是否具备由试用状态转化为订阅状态的资格，未续订时清零；当前套餐 k_i 记录智能体已订阅的套餐类型，若未订阅则为空；续订基准效用差 v_i 记录智能体订阅时刻所选套餐相对按次付费的效用差，作为其后续续订决策的基准；账期进度变量记录当前账期已经历的周数，用以判定续订结算节点；累计流失次数记录智能体经历的退订事件数。

表 7-1 智能体的动态状态变量

Table 7-1 Dynamic state variables of the agents.

状态变量	符号	初始值	含义
所处状态	—	未认知	智能体在推广进程中的行为状态见图 7-2
曾订阅指示	$e_{i,t}$	0	是否曾订阅过 MaaS 套餐（置位后不复位）
累计试用次数	$n_{i,t}^{tr}$	0	累计使用 MaaS 单次出行服务的次数
当前套餐	k_i	—	已订阅时为所选套餐，未订阅时为空
续订基准效用差	v_i	0	订阅时刻所选套餐相对按次付费的感知效用差
账期进度	—	0	当前账期已经历的周数及账期序号
累计流失次数	—	0	经历的退订事件数

（3）推广策略设定

本章主要考虑推广策略的两方面作用。其一，通过营销投放的空间分布，改变智能体及其周边其他智能体对 MaaS 的认知程度，从而影响智能体的认知进程；其

二，通过套餐设计、套餐定价与 MaaS 出行服务水平的调整，改变智能体对 MaaS 的感知效用与试用意愿，从而影响智能体的采纳决策。因此，本章设计的推广策略涵盖套餐设计、套餐定价、营销投放与服务水平四类共 11 维策略，其含义与取值范围如表 7-2 所示。

表 7-2 推广策略决策变量

Table 7-2 Decision variables for MaaS promotion strategies.

类别	变量	含义	取值范围
套餐设计	x_{PT}	公交优先套餐、地铁畅行套餐中的出租/网约车额度 (km/月)	[0, 350]
	x_{VT}	优惠出租套餐中的出租/网约车额度 (km/月)	[0, 520]
套餐定价	s_{BF}	公交优先套餐价格比例系数	[0.70, 1.30]
	s_{MA}	地铁畅行套餐价格比例系数	[0.70, 1.30]
	s_{VT}	优惠出租套餐价格比例系数	[0.70, 1.30]
	s_{UA}	全能畅行套餐价格比例系数	[0.70, 1.30]
营销投放	B	营销预算 (万元/月)	[50, 500]
	γ_{pot}	高潜力区域倾斜系数	[0.30, 0.90]
	γ_{gap}	认知缺口区域倾斜系数	[0.10, 0.70]
	c	营销空间集中度参数	[0.10, 0.90]
服务水平	τ	MaaS 按次出行时间改善比例	[0, 0.30]

套餐设计与套餐定价维度沿用第5章陈述偏好实验的套餐体系。具体而言，公交优先与地铁畅行两套餐在实验设计中共享同一出租/网约车额度，故以单一策略变量 x_{PT} 确定；优惠出租套餐的出租/网约车额度由 x_{VT} 确定。此外，第5章套餐订阅选择模型效用函数中不包含的变量均设置为实验设计水平的中点值，以保持套餐间的差异化定位。套餐额度与定价缩放系数的取值范围在相应实验设计水平的基础上适度外扩（如定价缩放由 [0.80, 1.20] 外扩至 [0.70, 1.30]），以覆盖更大力度的策略组合。

营销投放维度控制 MaaS 推广所用的营销预算总量及其空间分配规则，包括总营销预算以及高潜力区域倾斜系数、认知缺口区域倾斜系数和营销空间集中度参数等影响预算空间分布的 3 类系数。总营销预算为每月投入的营销预算总量，单位为万元；高潜力区域倾斜系数与认知缺口区域倾斜系数分别控制高潜力区域与认知缺口区域的预算倾斜程度，取值越大则倾斜程度越高；营销空间集中度参数控制预算在空间上的集中程度，取值越大则预算越集中于少数交通小区。上述营销预算的分配规则在 7.2.2 小节中详细说明。

服务水平维度刻画 MaaS 集成运营带来的出行时间改善，主要影响用户在单次出行阶段采用 MaaS 多模式出行服务获取的出行体验。出行时间改善比例 τ 刻画 MaaS 集成运营带来的出行时间改善程度，取值越大则出行时间改善越明显；其取值范围采用 0–0.30 的较小幅度，主要考虑到 MaaS 集成运营的出行时间在现实中难以大幅度调整。

上述 11 维决策变量以半年（6 个月）为一个阶段动态调整，并针对不同的分区采用差异化的推广策略，因此，完整的动态推广策略为张量：

$$\theta = \{\theta_{k,z} \in \mathbb{R}^{11} : k = 1, \dots, K; z = 1, \dots, Z\}, \quad (7-1)$$

式中 θ 为仿真周期针对每个分区的完整推广策略， $\theta_{k,z}$ 为第 k 阶段针对第 z 分区的 11 维推广策略。考虑到本章的仿真周期为 3 年，分为 $K = 6$ 个阶段，且将北京市划分为 $Z = 5$ 个策略分区，则完整的动态推广策略 θ 在该设定下共 330 维。

(4) 仿真整体流程

首先阐述仿真模型采用的行为学假设。

(1) 智能体的偏好由估计得到的离散选择模型给定，在策略不变的同一段内（本章设定为 6 个月）对 MaaS 多阶段决策的偏好保持不变；

(2) 智能体对 MaaS 的认知状态、试用次数、套餐有效期等动态状态变量会随仿真步长的步进变化，并影响其多阶段采纳决策。

以上两种假设避免了在每个周步长上重复调用离散选择模型的计算开销。接下来详细介绍仿真的整体流程，如图 7-2 所示。仿真进程的推进由策略阶段循环与周循环两层嵌套构成。每进入一个策略阶段 k ，模型首先计算每个分区的各套餐价格，随后根据当期策略调用第 5 章的行为模型，一次性计算各智能体的周试用概率、订阅基础概率、最优套餐及其续订基准效用差等行为参数，并根据营销预算总量与空间分布规则计算各交通小区的营销预算分配。随后，模型进入 26 周的周循环，每周保持上述行为参数不变，依次执行认知抽样、试用抽样与试用次数累积、订阅决策与套餐选择、套餐续订四个步骤，并在每周末记录各区订阅的用户规模。策略阶段结束时输出订阅率、平台净收入与碳减排三项目标的阶段结果，进入下一阶段后重复上述流程重新计算。

7.2.2 MaaS 认知扩散模块

作为一种新兴出行服务，MaaS 在推广初期首先面临的是“如何让居民知道”的问题。在本章采用的仿真模型的设定中，居民对 MaaS 的认知程度与认知速度既受运营商营销投放的驱动，又受已采纳用户口碑传播的影响，因此具有呈现典型的

社会扩散特征。本模块采用创新扩散理论的巴斯扩散模型（Bass Diffusion Model, Bass）刻画智能体由未认知转为已认知的过程^[183]。Bass 模型将新产品的认知扩散分解为独立于既有用户的创新效应与源于既有用户口碑的模仿效应，是新兴服务扩散预测中应用最广的模型。考虑到本章设计的推广策略空间含有营销投入项，故采用考虑广告宣传投入的 Bass 模型^[184]，其一般形式如式（7-2）所示。

$$h(t) = [\alpha + \beta \ln A(t)] + qF(t) \quad (7-2)$$

式中， $h(t)$ 为个体在时刻 t 的条件采纳率，表示在到 t 时刻尚未采纳的条件下下一瞬间采纳的瞬时概率率； $\alpha + \beta \ln A(t)$ 为时变创新系数（外部影响），其中 α 为创新系数的基线常数，表征无广告投入（或广告基准水平）时的固有外部影响强度； β 为广告有效性系数，表征广告对创新系数的边际贡献； $A(t)$ 为第 t 期的广告投入（支出或强度）； q 为模仿系数（内部影响），刻画已采纳者对未采纳者的口碑传染强度，且不受广告影响； $F(t)$ 为累计采纳分布函数，表示到时刻 t 累计采纳者占最终市场潜力 m 的比例。

在本章构建的 MaaS 推广策略效果仿真模型中，针对式（7-2）包含的创新效应与模仿效应分别进行建模。

（1）创新效应建模

式（7-2）中的创新效应 $\alpha + \beta \ln A(t)$ 刻画了营销投放对认知扩散的贡献，包含创新系数的基线常数与营销投入影响两部分。

创新系数的基线常数取自既有文献，即以年为评估单位下， $\alpha = 0.03$ ^[185]，并按生存函数一致原则折算为周度：

$$\alpha_w = 1 - (1 - \alpha)^{\tau_w^y} \quad (7-3)$$

式中， α_w 为周度创新系数， τ_w^y 为从年度到周度的时间转换系数，通过转换保证一年内未被创新效应影响认知到 MaaS 的概率在两种时间粒度下相等。

营销投入影响建模的重点在于如何将分配给分区 z 当期的营销预算精准投放到分区 z 中各交通小区，以达到最大化认知扩散的效果。为此，本章设计了兼顾人口潜力（居民数量）与认知缺口（未认知 MaaS 的个体数量）的营销预算分配规则。具体而言，设分区 z 当期的营销预算为 $B_{k,z}$ （万元/月），其在该分区内有居民分布的交通小区间的分配规则如下：

$$A_{l,t} = B_{k,z(l)} \cdot \frac{\gamma_{\text{pot}}(\rho_l)^c + \gamma_{\text{gap}} g_{l,t}}{\sum_{l' \in \mathcal{L}_{z(l)}} [\gamma_{\text{pot}}(\rho_{l'})^c + \gamma_{\text{gap}} g_{l',t}]} \quad (7-4)$$

式中， $A_{l,t}$ 为分配至小区 l 的营销强度，对应标准 Bass 模型中的 $A(t)$ ； $z(l)$ 为小区 l 所属的策略分区， $\mathcal{L}_{z(l)}$ 为执行该分配的空间单元（行政区）内有居民分布的交通

小区集合； ρ_l 为小区 l 的居民份额（小区智能体数占该执行单元的比例）； $g_{l,t}$ 为小区未认知 MaaS 的智能体比例，即认知缺口； γ_{pot} 、 γ_{gap} 与集中度参数 c 均为分区 z 的策略变量，前两者分别控制向高人口潜力区域与高认知缺口区域倾斜的力度，后者调节投放的空间集中程度—— c 越小，居民份额的幂变换越平缓，预算在小区间越趋平均分布。

（2）模仿效应建模

式（7-2）中的模仿效应 $qF(t)$ 刻画了已认知 MaaS 的智能体的口碑传播对认知扩散的贡献，包含模仿系数与累计采纳份额两部分。与创新效应近似，模仿系数采用以年为评估单位下的常用参数，即 $q = 0.38^{[185]}$ ，并按生存函数一致原则折算为周度：

$$q_w = 1 - (1 - q)^{\tau_w^y} \quad (7-5)$$

式中， q_w 为周度模仿系数。关于累计采纳份额，考虑到 MaaS 的口碑传播具有邻里传播与城市级信息传播两种渠道，本模块在标准 Bass 风险率的基础上引入空间网络效应，以量化两种传播渠道的影响。具体而言，累计采纳份额计算如式（7-6）与式（7-7）所示。

$$F_t = \beta_{\text{loc}} F_{l,t} + \beta_{\text{city}} F_{c,t} \quad (7-6)$$

$$F_{c,t} = \frac{1}{N} \sum_{i=1}^N e_{i,t}, \quad F_{l,t} = \frac{1}{N_l} \sum_{i: l(i)=l} e_{i,t}, \quad (7-7)$$

式中， $F_{c,t}$ 为全市范围截至第 t 周的累计采纳份额， $F_{l,t}$ 为小区 l 截至第 t 周的累计采纳份额； N 为仿真中的智能体总数， N_l 为小区 l 内的智能体数； β_{loc} 与 β_{city} 分别为本地与全城口碑影响权重。其中，本地权重占主导，体现口碑传播的空间集聚性； $e_{i,t}$ 为曾订阅指示变量。值得强调的是，考虑到口碑影响源于使用经历，不因退订而消失， F 统计的是曾订阅者而非当前订阅者，已流失用户仍计入其中，以保证 F_t 单调不减，与 Bass 模型中累计采纳份额的原始定义一致。

（3）采纳概率计算

综上，智能体 i 在第 t 周的认知概率 $\lambda_{i,t}$ 可由式（7-2）实例化为

$$\lambda_{i,t} = \alpha_w + b \ln(1 + A_{l(i),t}) + q_w F_t \quad (7-8)$$

式中， $l(i)$ 为智能体 i 所在的交通小区； b 为广告有效性系数。

每周对全体未认知 MaaS 的智能体按概率 $\lambda_{i,t}$ 作独立伯努利抽样，命中的智能体转为已认知状态，并参与后续的 MaaS 多阶段采纳意愿决策。

7.2.3 多阶段采纳意愿决策模块

在认知扩散模块的作用下，智能体逐步知晓 MaaS 的存在，并在认知后进入多阶段采纳意愿决策模块。根据第5章的相关分析，智能体认知 MaaS 后的采纳决策是循序渐进的过程，即智能体先在若干次单次出行中以按次付费方式尝试 MaaS 的多模式服务，待累积足够的使用体验后，再考虑是否订阅套餐并在多种套餐间作出选择。这一分阶段推进、多次试用、意愿逐渐形成的过程，要求为每一决策阶段配置结构完整、可独立调用的行为模型。根据6.5.3小节所讨论的分阶段建模与一体化建模的适用边界，智能体多阶段采纳 MaaS 的决策过程更契合分阶段建模的决策范式。据此，本模块以第5章估计的行为模型构成试用、订阅、套餐选择三层决策机制。为行文简洁，此处及后文省略策略变量的阶段与分区下标，其取值均按智能体所在分区与当期阶段确定。

(1) 试用层

试用层针对处于已认知状态的智能体（以及已流失后重新进入决策流程的智能体，见7.2.4小节），计算其在每周尝试 MaaS 单次出行的概率。具体而言，该概率由第5章5.3节的单次出行转移意愿模型给出，针对智能体的逐次出行事件开展计算。其中，为获取每一次出行事件 j 的多模式出行时间，利用 2023 年北京市居民出行调查的逐次出行记录，对四类 MaaS 多模式方案分别标定对数形式的出行时间估计模型：

$$\ln(1 + t_{j,m}^0) = \alpha_m + \beta_m \ln(1 + d_j) + \gamma_m^\top \mathbf{x}_j^{\text{tod}} + \zeta_m^\top \mathbf{x}_j^{\text{pur}}, \quad m \in \{M1, \dots, M4\}, \quad (7-9)$$

式中， $t_{j,m}^0$ 为出行事件 j 下采用方案 m 的出行时间（min）； d_j 为该出行事件的出行距离（km）； $\mathbf{x}_j^{\text{tod}}$ 与 $\mathbf{x}_j^{\text{pur}}$ 分别为出发时段与出行目的的哑变量向量，用以刻画高峰拥挤、服务频率与出行链构成对出行时间的系统性影响； α_m 为方案 m 的基础时间常数， β_m 为距离弹性系数， γ_m 、 ζ_m 为相应哑变量的系数向量，各方案的参数以稳健回归在调查样本上分别估计，以抑制少数异常时耗记录的影响。双对数形式既保证还原的出行时间恒为正，又压缩长距离出行的残差长尾，使短途与长途出行事件在拟合中获得相当的权重。

此外，转移意愿模型的效用函数中具有轨道段在车时间与全程出行时间两类变量（5.3节）。全程出行时间采用 $t_{j,m}^0$ ；含轨道段的方案（M1–M3）的轨道段在车时间，通过居民出行调查中总时耗扣除步行、候车与换乘时耗后得到经验轨道时间占比后，对全程出行时间进行折算。在此基础上，推广策略中的出行时间改善比例 τ 作用于各出行事件的出行时间，具体如下：

$$t_{j,m} \leftarrow (1 - \tau) t_{j,m}^0, \quad m \in \{M1, \dots, M4\}, \quad (7-10)$$

式中, τ 为 MaaS 单次出行下出行时间改善比例, 同时作用于出行时间与轨道段在车时间, 取值越大则 MaaS 多模式方案的出行时间越短、相对既有方式越具吸引力。由于各出行事件的出行距离与出行情境均有不同, 同一 τ 在不同个体、不同出行事件上带来的效用变化也会产生差异, 从而引入推广策略对不同个体的异质性影响。

将以上所述智能体社会经济属性、出行习惯、出行情境变量与推广策略下的出行时间改善代入转移意愿模型, 得到智能体在每次出行事件 j 上转向任一 MaaS 方案的转移概率 q_j 。考虑到后续智能体订阅的持续时间和满意度计算以月为单位, 在此, 首先将逐事件的转移概率折算为月度试用概率, 后将月度试用概率折算为与仿真步长一致的周度试用概率。假设一个月内智能体的全部出行事件为相互独立的试用机会, 月度试用概率即逐事件的加权独立重复, 再按等生存概率折算为周度:

$$P_{\text{try},i}^m = 1 - \prod_{j \in \mathcal{E}_i} (1 - q_j), \quad (7-11)$$

$$p_i^w = 1 - (1 - P_{\text{try},i}^m)^{\tau_w^m}, \quad (7-12)$$

式中, $P_{\text{try},i}^m$ 为月度试用概率; $\mathcal{E}_i$ 为智能体 i 的出行事件集合; p_i^w 为周试用概率; τ_w^m 为月度向周度的时间折算系数。

在计算出周试用概率 p_i^w 后, 已认知 MaaS 的智能体以该概率进入试用状态。进入试用状态的当周及其后各周, 智能体均以概率 p_i^w 继续使用 MaaS 单次出行服务, 在此过程中, 记录累计试用次数 $n_{i,t}^{\text{ty}}$ 以刻画试用期内的持续使用行为。当试用发生时, 记录该出行时间下智能体转移概率最大的 MaaS 方案, 作为其“最偏好的 MaaS 选项”, 用以进入套餐订阅模型的效用函数, 同时作为 7.2.5 节中碳减排核算的依据。

(2) 订阅层

与试用层的单次出行决策不同, 订阅是 MaaS 采纳中具有承诺性质的决策, 其套餐订阅会在一定时间内有效, 且订阅后智能体的行为会受到套餐约束。因此, 智能体在订阅套餐前需要对 MaaS 的价值进行评估。为此, 设计两项限制条件以确保智能体订阅的合理性。

其一, 智能体在订阅套餐前, 应具有较为充分的单次出行体验。该项限制要求智能体应具有较为丰富的单次出行体验, 以便在订阅前对 MaaS 的价值形成稳定的认知。为此, 设定智能体在订阅前必须经历至少 $n_{i,t}^{\text{ty}} \geq 2$ 试用, 这一限制避免因单次体验不足而导致的冲动订阅行为。

其二, 智能体在订阅套餐前, 应感知到 MaaS 套餐的价值优于按次付费的方案。该项限制要求智能体在订阅前应对 MaaS 套餐的价值有明确的认知, 即其最偏

好套餐的感知效用应优于按次付费的方案。为此，设定智能体在订阅前必须存在最偏好 MaaS 套餐的感知效用增量 $V_i^{\max} > 0$ ，即其感知效用优于按次付费的方案。这一限制确保了智能体在做出订阅决策时，已经有足够的认知来评估 MaaS 套餐的实际价值，从而避免因感知效用不足而导致的冲动订阅行为。其中：

$$V_i^{\max} = \sum_{q \in \{\text{opt}, \text{dis}\}} \pi_{q,i} \left(\max_{k \in \mathcal{K}} V_{i,k}^{(q)} - V_{i,\text{PAYG}}^{(q)} \right), \quad (7-13)$$

式中， $\mathcal{K}$ 为公交优先、地铁畅行、优惠出租与全能畅行四种套餐的集合； $V_{i,k}^{(q)}$ 与 $V_{i,\text{PAYG}}^{(q)}$ 分别为类别 q 下智能体 i 对套餐 k 与按次付费（PAYG）的感知效用； $\pi_{q,i}$ 为5.4.4节中混合潜在分类模型给出的智能体 i 对类别 q 的类别隶属概率。 $V_i^{\max} \leq 0$ 意味着无任何套餐的感知效用优于按次付费，此时订阅不会发生。

若智能体满足了以上两项限制条件，则其在当周以概率 P_i^{sub} 作订阅 MaaS 套餐与否的伯努利抽样：

$$P_i^{\text{sub}} = (1 - P_{i,\text{PAYG}}) \cdot \mathbb{I}\{V_i^{\max} > 0\} \quad (7-14)$$

式中， $P_{i,\text{PAYG}}$ 为套餐选择模型中智能体 i 选择 PAYG 的概率； $\mathbb{I}\{\cdot\}$ 为指示函数，当括号内条件成立时取 1，否则取 0。

(3) 套餐选择层

若订阅层中式 (7-14) 命中，则智能体进一步在四种套餐间作出订阅选择。选择行为由第5章5.4节考虑属性无视的混合潜在分类模型刻画，即智能体以概率 $\pi_{\text{dis},i}$ 隶属 MaaS 存疑者、以概率 $\pi_{\text{opt},i} = 1 - \pi_{\text{dis},i}$ 隶属 MaaS 乐观者：

$$\pi_{\text{dis},i} = \frac{1}{1 + \exp[-(c_0 + c_1(1 - \tilde{p}_i))]}, \quad (7-15)$$

式中， $\tilde{p}_i$ 为试用层模型给出的智能体 i 单次出行向 MaaS 转移的概率， $1 - \tilde{p}_i$ 即其维持既有方式的不转移倾向； c_0 、 c_1 ($c_1 > 0$) 为第5章估计的类别隶属模型的常数项及转移概率的参数。

在每一类别内部，依据第5章5.4节构建的混合潜在分类模型，套餐订阅选择服从嵌套 Logit 结构，公交优先与地铁畅行两个公共交通主导的套餐构成公交导向巢，其余选项相互独立。综上，以隶属概率加权的智能体选择套餐 k 的概率为：

$$P_i(k) = \pi_{\text{opt},i} P_i^{(\text{opt})}(k) + \pi_{\text{dis},i} P_i^{(\text{dis})}(k), \quad (7-16)$$

式中， $P_i^{(\text{opt})}(k)$ 和 $P_i^{(\text{dis})}(k)$ 分别为第 i 个智能体在类别 opt 和类别 dis 下选择套餐 k 的概率，其效用函数结构与参数取值均沿用第5章的估计结果，其中“最偏好的 MaaS 选项”变量由试用层的输出给定。

做出订阅选择的智能体选定式 (7-16) 中概率最大的套餐, 其套餐价格由式 (7-17) 给出:

$$p_k = c_k \cdot s_k, \quad c_k = b_k + \kappa_{\text{taxi}} x_k + \kappa_e n_k, \quad (7-17)$$

式中, c_k 为套餐 k 的出行服务购买成本; b_k 为套餐内不限次公交、不限次共享单车与月度地铁次数等基础服务的成本; x_k 为套餐包含的出租/网约车里程额度 (km/月), 由策略变量 x_{PT} 、 x_{VT} 给定; n_k 为共享电动自行车次数; κ_{taxi} (2.24 元/km) 与 κ_e (3 元/次) 为对应服务的单位供给成本, 与第5章表 5-3 的购买成本一致。

当智能体做出订阅选择后, 其状态发生系列更新。首先, 若智能体为首次订阅套餐, 其订阅指示变量 $e_{i,t}$ 由 0 置为 1, 并确定其所选套餐 k_i 。此外, 记录其所选套餐相对 PAYG 的感知效用差 v_i , 并将其作为续订的基准效用差, 并将智能体套餐的可用时间重置为 1 个月, 在套餐到期后将进一步进行智能体的续订决策。

7.2.4 用户留存与流失模块

考虑到现实中的 MaaS 套餐按月计费, 用户在每个套餐有效期 (后简称账期) 末决定是否继续付费^[77], 本节进一步建模套餐到期时用户的续订决策。为此, 本模块通过月度续订决策刻画订阅者的留存与流失行为。账期届满时, 智能体对“继续订阅当前套餐”与“退回按次付费”作二元选择, 续订概率为:

$$P_i^{\text{renew}} = \frac{1}{1 + \exp(-z_i)}, \quad z_i = v_i + \beta_{k_i}^{\text{save}} s_i, \quad (7-18)$$

式中, v_i 为智能体 i 所订阅套餐与 PAYG 的效用差; β_k^{save} 为智能体 i 订阅套餐 k 带来的月度出行费用节省敏感系数, 具体值取自悉尼 MaaS 试点中真实的用户续订选择数据^[77]; s_i 为智能体 i 在订阅期内获得的月度费用节省, 即

$$s_i = \chi (C_i^0 - p_{k_i} - U_{i,k_i}), \quad (7-19)$$

式中, C_i^0 为智能体 i 按次付费情形下的月度出行费用; p_{k_i} 为所订套餐的月度价格; U_{i,k_i} 为套餐额度未能覆盖, 仍须用户自行支付的月度出行支出 (下称超额部分); χ 为币值换算系数。式 (7-19) 的物理意义在于, 智能体以套餐月费替代原有出行支出, 但套餐的服务额度是有限的, 额度之外与套餐覆盖之外的出行支出仍由智能体承担。因此, 当计算结果为正时, 智能体订阅套餐“物有所值”, 对续订概率同时产生正向影响; 计算结果为负时订阅实际抬高了出行支出, 对续订概率产生负向影响。下面依次说明 C_i^0 与 $U_{i,k}$ 的核算方式, 以及系数 β_k^{save} 与 χ 的取值。

按次付费月度出行费用 C_i^0 根据智能体的每月的出行记录, 按照北京市实际的各出行方式的出行计价规则计算。针对驾车出行, 对其出行成本按照燃油费加停

车费（假设 10 元/日）的方式计算；针对步行、私人自行车与电动自行车、单位班车、摩托车等出行方式，将其出行成本记为 0。

在计算超额部分 $U_{i,k}$ 前，需说明两点假设。

其一，仅机动化出行参与计算出行成本，考虑到在计算月度出行费用 C_i^0 时，步行、私人自行车与电动自行车、单位班车、摩托车等出行方式的出行成本记为 0，因此在计算超额部分 $U_{i,k}$ 时也不考虑这些方式的出行支出。

其二，出行方式选择由行为模型计算的转移概率决定，与所订套餐无关。即智能体在订阅套餐后，其出行方式选择仍由试用层的行为模型决定。

在以上假设的基础上，超额部分 $U_{i,k}$ 同样由智能体每月的出行核算。首先，结合智能体 i 每月的出行记录，结合试用层的计算规则，对智能体 i 的每次出行 $j \in \mathcal{E}_i$ ，计算其转向 MaaS 方案 m ($m = 1, \dots, 4$) 的概率 $q_{j,m}$ 以及其维持既有方式的概率 $q_{j,0} = 1 - \sum_m q_{j,m}$ 。随后，计算智能体 i 在当月对各出行方式的期望需求，即每种出行方式的期望出行距离与票费：

$$X_i^\ell = \sum_{j \in \mathcal{E}_i} \sum_{a=0}^4 C_{j,a}^\ell q_{j,a}, \quad \ell \in \{\text{mn}, \text{mf}, \text{td}, \text{tf}, \text{out}\}, \quad (7-20)$$

式中， X_i^ℓ 为智能体 i 在第 ℓ 项上的月度期望需求；五个通道 ℓ 分别为地铁月乘次 (mn)、地铁票费 (mf)、出租/网约车里程 (td)、出租/网约车票费 (tf) 与其他支出 (out)； $C_{j,a}^\ell$ 为出行 j 在选择 a 下对通道 ℓ 的贡献系数。

具体而言，单次出行选择模型给出每次出行的选择分布，即以概率 $q_{j,0}$ 维持既有方式、以概率 $q_{j,m}$ 转向四类 MaaS 方案之一。因此，在计算月度期望出行需求时，把每次出行按以上选择分布加权到各选择上，逐项记录其对五个通道的期望贡献， X_i^ℓ 即全部出行累加后的月度合计。所有票费均按与 C_i^0 相同的定价规则计价。

在计算各智能体每月的出行需求后，结合其所订套餐的额度，计算超额部分 $U_{i,k}$ 。其中，套餐额度根据智能体订阅的套餐而定，月度需求超出套餐额度的比例为：

$$\varphi(D, A) = \frac{\max\{0, D - A\}}{D} \quad (D > 0), \quad \varphi(0, A) = 0, \quad (7-21)$$

式中， D 为月度方式出行需求量， A 为套餐内对应额度。智能体 i 订阅套餐 k 时的月度超额部分的费用为

$$U_{i,k} = X_i^{\text{out}} + \varphi(X_i^{\text{mn}}, N_k) X_i^{\text{mf}} + \varphi(X_i^{\text{td}}, x_k) X_i^{\text{tf}}, \quad (7-22)$$

式(7-22)的意义为，智能体需为超额部分支付的费用包括三部分：其一，套餐覆盖不到的其他支出 X_i^{out} ；其二，地铁超额部分的票费 X_i^{mf} 按超额比例 $\varphi(X_i^{\text{mn}}, N_k)$ 计算；其三，出租/网约车超额部分的票费 X_i^{tf} 按超额比例 $\varphi(X_i^{\text{td}}, x_k)$ 计算。

最后说明续订决策中两项系数的取值依据。月度节省敏感系数 β_k^{save} 按套餐特征对应悉尼 MaaS 试点中用户续订四类套餐的偏好估计值。公交优先与优惠出租套餐取 6.57×10^{-2} 、地铁畅行套餐取 6.80×10^{-2} 、全能畅行套餐取 1.08×10^{-1} [77]。由于悉尼 MaaS 试点中估计值以 2019 年澳元计价，而本章费用变量为 2023 年人民币，根据中国 CPI 与居民消费购买力，取 $\chi = 3.66 \times 10^{-1}$ 。

综上，在确定各参数计算方法后，智能体 i 通过(7-18)计算续订概率 P_i^{renew} ，并以该概率作伯努利抽样决定是否续订。若续订，则套餐可用时间重置为 1 个月；若不续订，则智能体转入已流失状态。流失后，清除智能体订阅套餐并清零累计试用次数，智能体自次周起即可重新试用。

7.2.5 推广策略效果评估模块

在上述7.2.2-7.2.4小节的仿真流程中，智能体受推广策略的影响下在认知、试用、订阅、续订或流失等多个阶段做出行为决策，产生了 MaaS 试用、订阅与续订的动态演化过程。通过对智能体行为的追踪，能够进一步估计推广策略的实际效果。

考虑到本文研究旨在促进 MaaS 的采纳与使用，并最大限度发挥 MaaS 在改善城市交通系统运行状态的作用，因此，本小节聚焦 MaaS 推广效果和 MaaS 发挥的作用两方面设计评估指标。首先，针对 MaaS 推广效果，从用户和平台两个层面考虑，分别设计用户采纳率和平台净收入两种指标。其中，用户采纳率对应 MaaS 推广策略的作用下，智能体愿意长期使用 MaaS 的程度，代表 MaaS 能够可持续运营的用户基础；平台净收入对应 MaaS 运营平台在推广策略作用下的经济收益，代表 MaaS 能够可持续运营的经济基础。其次，从更高层面的 MaaS 发展社会目标出发，设计碳减排指标，衡量 MaaS 推广策略在促进智能体转向多模式出行服务后，减少私家车使用、降低交通系统碳排放的效果。现对每项指标的设计如下。

(1) 用户采纳率

用户采纳率取 3 年仿真结束时，订阅套餐的智能体比例，作为推广策略在促进智能体采纳 MaaS 上的指标：

$$F_1(\theta) = -\frac{1}{N} \sum_{i=1}^N \sigma_{i,T}, \quad (7-23)$$

式中， F_1 为用户采纳率指标； N 为仿真中的智能体总数； $\sigma_{i,T}$ 为智能体 i 第 T 周（仿真过程的最后一周， $T = 156$ 为仿真总周数）的订阅状态指示变量。

(2) 平台净收入

平台净收入为经过 3 年的推广策略实施期，用户的套餐订阅产生的收入扣除营销支出与套餐成本后的净收入，其计算方式如下：

$$F_2(\theta) = - \left[\sum_{i=1}^N \sum_{t \in \mathcal{T}_i} \left(s_{k_i}^{\kappa(t)} - 1 \right) c_{k_i}^{\kappa(t)} - \sum_{k=1}^K \sum_{z=1}^Z B_{k,z} \right], \quad (7-24)$$

式中, F_2 为平台净收入指标; K 为策略阶段数量; Z 为分区数量; $\mathcal{T}_i$ 为智能体 i 的订阅事件集合, 涵盖该智能体首次订阅和后续续订等事件; $s_{k_i}^{\kappa(t)}$ 与 $c_{k_i}^{\kappa(t)}$ 分别为智能体 i 订阅套餐 k_i 时所在策略阶段 $\kappa(t)$ 的套餐价格比例系数与套餐成本; $B_{k,z}$ 为在策略阶段 k 向分区 z 投入的营销支出预算。其中, $\sum_{i=1}^N \sum_{t \in \mathcal{T}_i} \left(s_{k_i}^{\kappa(t)} - 1 \right) c_{k_i}^{\kappa(t)}$ 代表 MaaS 运营平台通过智能体的套餐订阅获取到的收益; $\sum_{k=1}^K \sum_{z=1}^Z B_{k,z}$ 为 MaaS 推广过程支出的营销成本。

(3) 碳减排

与平台净收入相似, 碳减排指标为经过 3 年的推广策略实施期, 智能体转向使用 MaaS 多模式出行服务带来的碳减排量。值得注意的是, 结合 MaaS 旨在通过多模式交通服务替代小汽车出行, 在计算碳减排指标时, 本小节仅考虑智能体既有私家车出行转向 MaaS 出行服务的情况, 计算方法如下:

$$F_3(\theta) = - \sum_{t=1}^T \sum_{i=1}^N \phi_i^{\kappa(t)} \tau_w^m, \quad (7-25)$$

式中, F_3 为在推广策略 θ 下得到的碳减排量, T 为仿真总周数; τ_w^m 为月度向周度的时间折算系数; $\phi_i^{\kappa(t)}$ 为智能体 i 在策略阶段 $\kappa(t)$ 下的期望月度减排率 (kg/月), 计算如下:

$$\phi_i^{\kappa(t)} = \sum_{j \in \mathcal{E}_i} d_j \mathbb{I}\{\text{drv}_j\} \sum_{m=1}^4 q_{j,m} (e_{\text{car}} - e_m), \quad (7-26)$$

式中, $\mathbb{I}\{\text{drv}_j\}$ 为智能体乘坐私家车出行的指示函数; d_j 为出行 j 的出行距离; $q_{j,m}$ 为出行 j 转向 MaaS 多模式出行服务 m 的转移概率; e_{car} 与 e_m 分别为私家车与方案 m 中多方式的运行阶段排放因子, 其中, 私家车与出租/网约车为 $1.82 \times 10^{-1} \text{ kg/km}^{[186]}$ 、公交车为 $3.50 \times 10^{-2} \text{ kg/(人} \cdot \text{km)}^{[187]}$ 、城市轨道为 $1.07 \times 10^{-2} \text{ kg/(人} \cdot \text{km)}^{[187]}$ 、步行与自行车等交通方式为零。

综上, 通过对上述用户采纳率、平台净收入与碳减排三项指标的计算, 能够在 3 年推广策略实施期结束时, 评估任一候选策略的推广效果。除此之外, 仿真模型在每个策略阶段末均输出一组推广策略评估指标状态 $\mathbf{y}_k \in \mathbb{R}^3$, 以刻画动态策略作用下推广策略效果指标的演化轨迹, 同时也作为 7.3.3 小节深度学习代理模型的逐阶段监督信号。

7.3 仿真优化代理模型

7.2 节的仿真模型为候选推广策略提供了效果评估的手段, 但将其直接用于推广策略寻优存在以下问题: 其一, 推广策略维度较高, 策略空间较大, 直接采用仿

真模型在策略空间寻优需大量仿真计算，在城市尺度下计算开销高昂，计算成本不可接受；其二，仿真是含离散抽样的黑箱系统，无法直接向数学优化算法提供闭式表达与梯度等信息。为解决以上基于仿真的优化问题，既有研究提出了仿真优化（Simulation-Based Optimization, SO）^[188] 的概念，即在较少的计算预算下，通过构建计算快速的代理模型（元模型）近似仿真系统对输入的响应，并进一步辅助选取候选策略。

上述问题是仿真优化^[188] 框架的标准形式，其旨在通过较少的计算预算，高效地搜索优质的推广策略。为此，基于7.2节建立的城市尺度下的 MaaS 推广策略效果评估模型，本节将城市尺度下 MaaS 推广策略寻优问题构建为仿真优化问题。首先，将推广策略优化问题形式化并剖析其求解难点（7.3.1小节），进一步在7.3.2小节，采用已有研究常用的机理模型的形式，推导仿真模型的平均场解析代理形式，并进一步叠加高斯过程以校正解析代理模型的计算误差，并设计解析代理模型的反向求解算法，以得到在给定搜索域内的最优策略，进而在7.3.3小节，结合解析代理模型的先验知识，基于小样本学习思想，设计一种高精度、可持续学习的深度学习代理模型，提出针对该深度学习代理模型的求解算法，以在推广策略空间中高效搜索优质策略。

7.3.1 仿真优化问题构建

首先给出仿真优化问题的一般形式，仿真优化问题可表述为^[188]：

$$\min_{\mathbf{x} \in \Omega} f(\mathbf{x}; \mathbf{p}) = \mathbb{E}[F(\mathbf{x}, \boldsymbol{\omega}; \mathbf{p})], \quad (7-27)$$

式中， $\mathbf{x}$ 为确定性决策向量； $\mathbf{p}$ 为外生确定性参数，承载决策者不可控的场景要素； $\boldsymbol{\omega}$ 为一次仿真运行所消耗的全部随机因素； F 为随机性能测度，其概率分布由 $\mathbf{x}$ 与 $\mathbf{p}$ 共同决定，每次仿真运行仅给出 F 的一次随机实现；目标函数 f 为随机性能测度的期望；可行域 Ω 由一组联系 $\mathbf{x}$ 与 $\mathbf{p}$ 的一般约束（可为非凸）构成，且各约束均具有闭式可微的表达。上述优化问题刻画了仿真优化问题的本质特征，即可行域是解析且可微的，目标函数却不存在任何闭式，只能以有限次独立仿真重复的样本均值近似。

考虑到本章采用仿真模型作为推广策略评估的手段，故将推广策略寻优问题构建为仿真优化问题，其与一般形式 (7-27) 各构成要素的对应关系如下：决策向量为7.2.1小节定义的推广策略 $\boldsymbol{\theta}$ ；外生参数 $\mathbf{p}$ 涵盖仿真模型中智能体属性、行为模型参数、排放因子等场景要素；随机因素 $\boldsymbol{\omega}$ 对应智能体认知、试用、订阅与续订的逐周伯努利抽样，单次仿真给出的 $F_j(\boldsymbol{\theta}, \boldsymbol{\omega}; \mathbf{p})$ 因此只是针对推广策略的一次随机实现，优化的对象是其期望 f_j 。

与一般仿真优化问题的单目标设定不同, 本章同时优化用户采纳率、平台净收入与碳减排三项指标, 推广策略优化问题因此为一般形式在多目标设定下的扩展, 即:

$$\begin{aligned} \min_{\boldsymbol{\theta} \in \Theta} \quad & \mathbf{f}(\boldsymbol{\theta}; \mathbf{p}) = (f_1, f_2, f_3), \\ \text{s.t.} \quad & f_j(\boldsymbol{\theta}; \mathbf{p}) = \mathbb{E}[F_j(\boldsymbol{\theta}, \boldsymbol{\omega}; \mathbf{p})], \\ & \Theta = \prod_{k=1}^K \prod_{z=1}^Z [\boldsymbol{\theta}^{\text{lo}}, \boldsymbol{\theta}^{\text{up}}]. \end{aligned} \quad (7-28)$$

式中, Θ 为由表 7-2 中 11 维决策变量的取值范围在 K 个策略阶段与 Z 个分区上构成的 330 维盒约束策略空间, 对应仿真优化一般形式中的可行域 Ω 。目标函数 f_j 不存在任何闭式, 其取值只能通过有限次独立仿真进行均值估计:

$$f_j(\boldsymbol{\theta}; \mathbf{p}) = \bar{F}_j(\boldsymbol{\theta}; \mathbf{p}) = \frac{1}{r} \sum_{i=1}^r F_j(\boldsymbol{\theta}, \boldsymbol{\omega}_i; \mathbf{p}), \quad (7-29)$$

式中, r 为独立重复仿真的次数, 每一次仿真计算得到的 $F_j(\boldsymbol{\theta}, \boldsymbol{\omega}_i; \mathbf{p})$ 都对应一次完整的仿真运行。

考虑到用户采纳、平台净收入与碳减排三项指标的目标相互冲突 (如套餐价格降低导致平台净收入减少, 但会带来用户采纳率和碳减排的提高), 式(7-28)表述的问题一般不存在使三者同时最优的单一解, 求解目标是刻画目标间的最优权衡结构, 即 Pareto 最优解集。决策者可在前沿上依据实际偏好在采纳规模、平台盈利与减排效益间权衡取舍。

为高效求解仿真优化问题, 既有研究常通过构建代理模型 (又称元模型) 近似仿真系统对输入的响应, 以计算廉价的解析计算近似替代计算昂贵的仿真评估^[188]。在代理模型的辅助下, 仿真优化问题的求解流程主要分为以既有仿真观测拟合代理模型、在代理模型上寻优生成候选策略、仿真模型评估候选策略并更新代理模型三步, 其仿真优化问题的解的质量取决于代理模型能否在极少观测下较好地拟合策略空间的目标函数响应^[188]。

因此, 针对建立的仿真优化问题, 设计具有良好性质的代理模型, 以在较小的仿真预算下高效搜索优质推广策略。具体而言, 本章设计了两类代理模型。

1. 混合解析代理模型。参考既有研究^[188], 设计了物理型代理模型与函数型代理模型的混合结构。物理型代理模型通过构建一组反映 MaaS 推广策略效果评估仿真系统内部运行机理的函数, 在不依赖仿真样本的情况下, 给出推广策略对目标函数的全局趋势预测; 函数型代理模型通过高斯过程对物理型代理模型的残差进行局部校正, 以提高代理模型在局部搜索域内的精度。在此基础上, 进一步设计混合解析代理模型的反向求解算法, 以获取在给定搜索域内的最优候选策略。此类代理模型能够为后续的基于深度学习的代理模型提供先验知识, 并作为对比基线。

2. 基于深度学习的代理模型。代理模型的本质是构建一个函数映射, 将推广策略映射到目标函数的响应, 正是深度学习模型的优势。因此, 受到深度学习模型的启发, 针对高维策略空间下的既有研究采用的代理模型在小样本下拟合能力不足的问题, 设计了基于深度神经网络的代理模型。通过引入混合解析代理模型的物理先验知识, 结合小样本学习与持续学习技巧, 利用深度神经网络的强大拟合能力, 在小样本下实现对目标函数的高精度拟合。进一步, 本章提出了一种将深度神经网络转化为混合整数规划问题的算法, 并通过求解转化后的混合整数规划问题, 在可行空间内求解最优候选策略。

综上, 本小节介绍了仿真优化问题的一般形式以及其在本章推广策略寻优问题的适用性, 进一步分析了推广策略寻优仿真优化问题求解的难点, 并提出了两类代理模型的设计思路。后续两节分别介绍两种代理模型的设计细节。

7.3.2 混合解析代理模型设计

解析代理模型的关键, 在于以一组便于计算的函数构建仿真系统的近似形式, 即以推广策略与智能体属性等要素为自变量, 以计算方便、结果确定的函数求值直接逼近仿真模型输出的期望, 从而在优化循环中替代昂贵的仿真模型评估。为此, 本章结合平均场近似 (mean-field approximation) 的思想构建解析代理模型, 在模拟仿真模型整体运行流程的前提下, 大幅简化计算流程。

平均场近似源于统计物理对多体系统的研究, 其基本思想是放弃对个体间随机关联的刻画, 将系统的联合分布近似分解为各个体边缘分布之积, 使任一个体仅通过一个由全体个体共同生成的聚合量——平均场——感受其余个体的影响。如此一来, 聚合量由各个体的边缘分布汇总得到, 各个体的演化又只以该聚合量为输入, 二者逐步交替更新即可推进整个系统的演化, 无需再对个体的随机实现反复抽样。

就本节模型而言, 智能体间的耦合主要在 MaaS 认知决策模块, 即任一智能体的周认知概率不仅直接受到其余智能体订阅状态的影响, 也间接受到智能体认知整体情况导致的营销投放的影响。平均场近似不再追踪每个智能体的订阅结果, 转而计算全体智能体曾订阅概率的算术平均, 作为全市累计采纳份额的期望与全体智能体订阅结果的平均场。配合个体相互独立的乘积分解假设, 每个智能体的状态演化封闭为对其自身边缘分布的确定性递推, 得到自身订阅概率后进一步更新平均场, 实现单一智能体与全部智能体状态交替更新。值得注意的是, 经典的平均场处理通常假定全体个体同质。本章不作此假定, 即每个智能体保留各自的属性与行为参数、逐一递推, 平均场替代仅发生在个体受总体影响的 MaaS 认知决策上, 从而保留了个体对 MaaS 采纳决策的异质性。

结合上述思想, 本节设计的混合解析代理模型不再对个体决策随机抽样, 而以确定性递推计算每个智能体在各决策阶段的选择概率, 单次求值即给出无抽样噪声的概率预测结果。然而, 通过平均场近似的方法因舍弃了部分智能体间的交互关系, 因此会导致计算结果带有偏差, 进一步导致模型计算精度较低等现象。为此, 本节在解析代理模型的基础上, 进一步叠加高斯过程对解析代理模型的残差进行局部校正, 以提高代理模型在局部搜索域内的精度。在此基础上, 设计混合解析代理模型的反向求解算法, 以获取在给定搜索域内的最优候选策略。混合解析代理模型框架如图 7-3 所示。




图 7-3 混合解析代理模型框架

Figure 7-3 Framework of the hybrid analytical surrogate model.

(1) 解析代理模型前向递推

结合上述平均场理论, 首先建立针对仿真模型的解析代理模型。解析代理模型不再通过抽样模拟每个智能体的实际状态, 而是为每个智能体维护一组处于某个状态的概率, 即六维状态概率向量:

$$\mathbf{P}_{i,t} = (P^U, P^A, P^{T_1}, P^{T_2}, P^S, P^C), \quad (7-30)$$

式中, $\mathbf{P}_{i,t}$ 为智能体 i 在第 t 周的状态概率向量, 代表智能体目前处于何种状态的完整概率分布, 其各分量之和为 1; P^U 、 P^A 、 P^{T_1} 、 P^{T_2} 、 P^S 与 P^C 依次为该智能体处于未认知、已认知、已试用 1 次、已试用 $n_{i,t}^{\text{try}}$ 次及以上、已订阅与已流失六种状

态的概率。相对仿真模型中的五种状态，考虑到仿真模型中试用次数的作用是判定智能体是否具有足够的经验以决定是否订阅，此处将“试用中”状态按累计试用次数拆分为 T_1 （已试用 1 次）与 T_2 （已试用 $n_{i,t}^{ty} = 2$ ）两种。以上六种状态分别代表智能体在 MaaS 推广策略作用下的不同采纳阶段，任一时刻智能体必定属于以上六种状态之一。简洁起见，各分量及下文的流量符号均省略下标 i 与 t ，均指智能体 i 第 t 周的取值。

状态概率向量的逐周递推按仿真模型中认知—试用—订阅—流失—再试用的仿真流程设计，针对每一分量的概率更新，对其计算其发生改变的条件概率，即处于该状态的概率乘发生该转移的概率，得到智能体状态间的期望转移率。针对所有类别的期望转移率计算完毕后，结合流量守恒的思想，更新智能体的状态概率向量，并重新计算下一时刻的平均场。对每个状态的期望转移率计算如下。

首先是认知环节。处于未认知态的智能体本周经由营销投放、口碑传播等渠道转入已认知态，其期望转移率为

$$f^{UA} = P^U \bar{\lambda}_t, \quad (7-31)$$

式中， f^{UA} 为本周由未认知态转入已认知态的期望转移率； $\bar{\lambda}_t$ 为第 t 周的平均场认知概率，即把认知概率公式 (7-8) 中随机的全市累计采纳份额替换为其确定性期望（由本段末尾的式 (7-38) 对全体智能体取算术平均得到）后的取值。

其次是试用环节。已认知的智能体每周以周试用概率 p^w 发生试用。按仿真设定，智能体进入试用状态后的当周，依然通过周试用概率 p^w 决定是否发生试用。因此从已认知态出发，同一周内有三种状态转移结果，即累计试用达 2 次的智能体，进入 T_2 状态；累计试用 1 次的智能体，者进入 T_1 状态；未产生试用的智能体，保持其已认知状态。此外，之前已在 T_1 状态的智能体本周再试用一次则进入 T_2 状态。三种期望转移率依次为

$$f^{AT_2} = P^A (p^w)^2, \quad f^{AT_1} = P^A p^w (1 - p^w), \quad f^{T_1 T_2} = P^{T_1} p^w, \quad (7-32)$$

式中， f^{AT_2} 与 f^{AT_1} 分别为由已认知状态进入 T_2 状态与 T_1 状态的期望转移率； $f^{T_1 T_2}$ 为由 T_1 状态进入 T_2 状态的期望转移率。

未续订套餐的已流失智能体同样参与试用环节，其累计试用次数已在退订时清零，故其在已流失状态下的期望转移率与已认知环节相同：

$$f^{CT_2} = P^C (p^w)^2, \quad f^{CT_1} = P^C p^w (1 - p^w), \quad (7-33)$$

式中， f^{CT_2} 与 f^{CT_1} 分别为已流失状态下经重新试用进入 T_2 状态、 T_1 状态的期望转移率。

然后是订阅环节。订阅决策仅对累计试用满 $n_{i,t}^{\text{try}} = 2$ 次的智能体开放。故本周具备订阅资格的智能体既包括周初已在 T_2 状态智能体, 也包括新转移向 T_2 状态的智能体两种。订阅状态期望转移率计算如下:

$$e_t = P^{T_2} + f^{T_1 T_2} + f^{A T_2} + f^{C T_2}, \quad f^{TS} = e_t q, \quad (7-34)$$

式中, e_t 为第 t 周具备订阅资格的概率; f^{TS} 为本周发生订阅、进入已订阅状态的期望转移率; q 为订阅概率 (式 (7-14))。

最后是续订环节。在订的智能体每周以恒定的风险率退出订阅:

$$f^{SC} = P^S h, \quad (7-35)$$

$$h = 1 - \eta, \quad \eta = (P^{\text{renew}})^{\tau_w^y}, \quad (7-36)$$

式中, f^{SC} 为本周由已订阅状态转入已流失状态的期望转移率; h 为非续订率, 由月度续订概率折算得到。具体而言, 仿真中, 订阅者按各自账期以月为单位决策是否续订, 续订概率为以月为单位下的 P^{renew} (式 (7-18))。然而, 解析代理模型不逐一跟踪智能体决策行为, 仅通过每周恒定的流失概率刻画智能体是否续订。因此, 以年续订率相等为折算原则, 令按周续订率 η 连续续订 1 年的概率等于连续 12 个月均续订的概率, 即 $\eta = (P^{\text{renew}})^{\tau_w^y}$; h 为其退订概率。

各分量的期望转移概率计算完成后, 六个状态概率分量按流量守恒更新如下:

$$\begin{aligned} P_{t+1}^U &= P^U - f^{UA}, & P_{t+1}^A &= P^A + f^{UA} - f^{AT_1} - f^{AT_2}, \\ P_{t+1}^{T_1} &= P^{T_1} + f^{AT_1} + f^{CT_1} - f^{T_1 T_2}, & P_{t+1}^{T_2} &= e_t - f^{TS}, \\ P_{t+1}^S &= P^S + f^{TS} - f^{SC}, & P_{t+1}^C &= P^C + f^{SC} - f^{CT_1} - f^{CT_2}, \end{aligned} \quad (7-37)$$

式中, 带下标 $t+1$ 的变量为下一周的状态概率, 等号右侧各项均取第 t 周的值。每种期望转移率都从一种状态分量扣除, 又进入另一种状态分量, 实现流量守恒。

状态概率向量更新后, 结合全部智能体的订阅概率, 对平均场进行更新。根据式 (7-31), 认知概率 $\bar{\lambda}_t$ 需要输入全市智能体的累计采纳概率, 即曾订阅过 MaaS 套餐的智能体期望概率。因此, 须为每个智能体记录一个曾经订阅过的概率, 其递推公式为:

$$\bar{e}_{i,t+1} = 1 - (1 - \bar{e}_{i,t}) (1 - f_{i,t}^{TS}), \quad (7-38)$$

式中, $\bar{e}_{i,t}$ 为智能体 i 截至第 t 周曾经订阅过的概率; $1 - \bar{e}_{i,t}$ 为其从未订阅过的概率; $f_{i,t}^{TS}$ 为其第 t 周的订阅流量 (式 (7-34))。因此, $(1 - \bar{e}_{i,t}) (1 - f_{i,t}^{TS})$ 表示到本周为止从未订阅过且本周也未发生订阅的概率, 取补即为智能体 i 截至第 $t+1$ 周曾经订

阅过的概率。将全体智能体的曾订阅概率取算术平均，便得到下一周认知概率所需的全市累计采纳份额。

至此，已完成对解析代理模型前向递推流程介绍，后续介绍在前向递推过程中的针对推广策略的效果评估。

(2) 目标函数计算

结合前向递推得到的各智能体状态占据概率与期望转移流量，下面依次给出用户采纳率、平台净收入与碳减排三项目标的计算方法。

针对用户采纳率。与式 (7-23) 相同，采纳率取仿真期末在订人口的比例。差别在于，解析代理模型中智能体在仿真期末的订阅状态不再是 0-1 哑元变量，而是该智能体的订阅概率，故直接对全体智能体订阅概率取算术平均如下：

$$\hat{F}_1 = -\frac{1}{N} \sum_{i=1}^N P_{i,T}^S, \quad (7-39)$$

式中， $\hat{F}_1$ 为解析代理模型计算的采纳率目标； $P_{i,T}^S$ 为智能体 i 在仿真期末（ $T = 156$ 周）处于已订阅状态的概率。

针对平台净收入，解析代理模型将订阅行为带来的收入替换为期望收入，考虑首次订阅和续订两种情况，并在此基础上扣除营销成本，计算方式如下：

$$\hat{F}_2 = -\left[\sum_{t=1}^T \sum_{i=1}^N [f_{i,t}^{TS} + (P_{i,t}^S - f_{i,t}^{SC}) r_i^{\text{pay}}] (s_{k_i} - 1) c_{k_i} - C^{\text{mkt}} \right], \quad (7-40)$$

式中， $\hat{F}_2$ 为解析代理模型计算的平台净收入目标； $f_{i,t}^{TS}$ 、 $f_{i,t}^{SC}$ 与 $P_{i,t}^S$ 沿用式 (7-34)、式 (7-35) 与式 (7-30) 的定义； k_i 为智能体 i 的偏好套餐，通过将其社会经济属性、出行特征与当期策略下的各套餐价格代入第5章的套餐选择模型计算每个套餐的感知效用，并取其感知效用最高的套餐； s_{k_i} 与 c_{k_i} 分别为该套餐的定价缩放系数与月度服务成本； C^{mkt} 为逐阶段累计的营销支出。其中， $P_{i,t}^S - f_{i,t}^{SC}$ 为智能体的处于续订状态的概率，乘以周续订支付率 r_i^{pay} 后得到续订概率的期望值。

式(7-40)中， r_i^{pay} 为周续订支付率，用以反映智能体每周续订的期望次数。在此，仅考虑具有续订资格的智能体，即已订阅状态的智能体，将其续订决策是为套餐订阅期满时的独立重复决策，其在每个账期末以月度续订概率 P^{renew} 决定是否续订。因此，其期望续订次数经简单推导后可得 $P^{\text{renew}} / (1 - P^{\text{renew}})$ ，即首次流失前续订次数的期望。此外，解析代理模型中，订阅者订阅后第 t 周仍在订的概率为 η^t ，因此其期望在订周数为 $\sum_{t \geq 1} \eta^t = \eta / (1 - \eta)$ 。将期望续订的次数平均到这些在订周上，即得周续订支付率：

$$r^{\text{pay}} = \frac{P^{\text{renew}} / (1 - P^{\text{renew}})}{\eta / (1 - \eta)} = \frac{P^{\text{renew}} (1 - \eta)}{\eta (1 - P^{\text{renew}})}, \quad (7-41)$$

式中, P^{renew} 为月度续订概率(式(7-18)); η 为式(7-36)的周续订率; 分子 $P^{\text{renew}}/(1 - P^{\text{renew}})$ 为期望续费期数, 分母 $\eta/(1 - \eta)$ 即期望在订周数, 二者之比为每在订一周的期望续费期数。

针对碳减排, 与式(7-25)近似, 逐周计算并汇总全体智能体的期望减排量, 得到解析代理模型计算的碳减排目标:

$$\hat{F}_3 = - \sum_{t=1}^T \sum_{i=1}^N (P_{i,t}^S + f_{i,t}^{\text{TS}}) \phi_i \cdot \tau_w^m, \quad (7-42)$$

式中, $\hat{F}_3$ 为解析代理计算的碳减排目标; $P_{i,t}^S + f_{i,t}^{\text{TS}}$ 为表征智能体在订阅状态的概率; ϕ_i 为由式(7-26)计算得到的智能体 i 的月度减排量 (kg/月); τ_w^m 为月到周的折算系数。

除以上三项目标外, 解析代理模型还可对全体智能体或各行政分区进行集计统计, 同步计算得到认知率、周试用概率、订阅概率、感知效用增量、套餐差价、减排率与采纳率等 9 项中间量 (即对目标计算有直接或间接影响的指标), 以作为物理先验辅助深度学习模型的训练 (7.3.3 小节)。

(3) 高斯过程残差校正

如本小节开头所述, 平均场近似舍弃了智能体间的部分交互关系, 导致预测值与仿真评估值之间存在偏差。然而, 该偏差来源于计算流程简化而非随机抽样, 因而可由少量仿真样本辨识并校正。为此, 采用常用的函数型代理模型, 高斯过程 (Gaussian Process, GP) 回归, 对解析代理模型的残差进行建模^[189]。首先, 将残差定义为同一策略下仿真评估值与解析预测值之差:

$$r_j(\theta) = \bar{F}_j(\theta) - \hat{F}_j(\theta), \quad j = 1, 2, 3, \quad (7-43)$$

式中, $r_j(\theta)$ 为推广策略 θ 处目标 j 的残差; $\bar{F}_j(\theta)$ 为仿真模型的评估值 (式(7-29)); $\hat{F}_j(\theta)$ 为解析代理模型的预测值 (式(7-39)至式(7-42))。

残差建模的目的, 是从少量样本中学出残差随推广策略变化的规律, 从而在未评估的推广策略处预测并修补这一偏差。对每一项目标, 设置零均值的 GP 先验:

$$r_j(\theta) \sim \mathcal{GP}(0, k_{5/2}(\theta, \theta')), \quad j = 1, 2, 3, \quad (7-44)$$

式中, $k_{5/2}(\theta, \theta')$ 为 Matern-5/2 核函数, 以完整的推广策略向量为输入, 旨在刻画任意两个策略处残差的相关程度, 其表达式为

$$k_{5/2}(\theta, \theta') = \sigma_f^2 \left(1 + \sqrt{5}\Delta + \frac{5}{3}\Delta^2 \right) \exp(-\sqrt{5}\Delta), \quad \Delta = \sqrt{\sum_{d=1}^D \frac{(\theta_d - \theta'_d)^2}{\ell_d^2}}, \quad (7-45)$$

式中, σ_f^2 为信号方差, 控制残差的整体波动幅度; Δ 为两个策略间以长度尺度加权的距离; D 为策略向量的维度数; θ_d 与 θ'_d 分别为两个策略向量的第 d 维分量; ℓ_d

为第 d 维的长度尺度。各维长度尺度独立取值，通过自动相关性判定（Automatic Relevance Determination, ARD）计算，即残差对某一策略维度越敏感，估计出的该维长度尺度越小、其在距离中的权重越大；反之，影响微弱的维度长度尺度趋大，在距离中权重被削弱。选用 Matern-5/2 核的依据如下。

其一，其光滑度假定与本章仿真优化问题残差的性质相符。Matern-5/2 核对应的随机函数二次可微，足以支撑后续对 GP 后验均值求梯度并作拟牛顿修正。

其二，Matern-5/2 核配合 ARD 是构建高斯过程代理模型的常用选择^[190,191]，能够在保持后验均值可微的同时，根据各策略维度对残差变化的贡献自适应调整相关距离。

假定 GP 在给定的 N 个仿真样本上拟合，记样本策略为 $\theta^{(1)}, \dots, \theta^{(N)}$ ，按式 (7-43) 计算各样本策略的残差。进而，针对三项目标分别通过边际似然最大化估计信号方差、各维长度尺度与观测噪声方差等参数。拟合完成后，任一策略 θ 处残差的后验均值为

$$\mu_j(\theta) = \mathbf{k}_j(\theta)^\top (\mathbf{K}_j + \sigma_{n,j}^2 \mathbf{I})^{-1} \mathbf{r}_j, \quad (7-46)$$

式中， $\mu_j(\theta)$ 为目标 j 残差的后验均值，即 GP 对策略 θ 偏差的估计值； $\mathbf{k}_j(\theta) = [k_{5/2}(\theta, \theta^{(1)}), \dots, k_{5/2}(\theta, \theta^{(N)})]^\top$ 为待预测策略与各样本策略间的核向量； $\mathbf{K}_j$ 为 $N \times N$ 的样本核矩阵，其第 (n, n') 个元素为 $k_{5/2}(\theta^{(n)}, \theta^{(n')})$ ； $\mathbf{r}_j = [r_j(\theta^{(1)}), \dots, r_j(\theta^{(N)})]^\top$ 为残差观测向量； $\sigma_{n,j}^2$ 为观测噪声方差，用于拟合仿真样本均值 $\bar{F}_j$ 中残留的抽样噪声； $\mathbf{I}$ 为 N 阶单位阵。

结合残差后验均值对解析预测进行修正，即得混合解析代理模型的最终形式：

$$\tilde{F}_j(\theta) = \hat{F}_j(\theta) + \mu_j(\theta), \quad j = 1, 2, 3, \quad (7-47)$$

式中， $\tilde{F}_j(\theta)$ 为混合解析代理模型对目标 j 的预测值。解析部分 $\hat{F}_j(\theta)$ 为物理型代理模型的预测结果；GP 部分 $\mu_j(\theta)$ 为函数型代理模型给出的残差校正结果。

（4）混合解析代理模型反向求解

如 7.3.1 小节所述，代理模型除正向预测推广策略的效果外，还须在给定搜索域内求出针对特定目标的最优候选策略，即代理模型的反向求解过程。在得到式 (7-47) 的混合解析代理模型后，其反向求解问题可写为以下形式：

$$\theta^* = \arg \min_{\theta \in \mathcal{B}} \Phi(\theta), \quad \Phi(\theta) = g(\tilde{F}_1(\theta), \tilde{F}_2(\theta), \tilde{F}_3(\theta)), \quad (7-48)$$

式中， $\mathcal{B} \subset \Theta$ 为给定的搜索域，在 7.4 节优化算法中进一步阐述； $g(\cdot)$ 为将三项目标统一为单一目标的标量化函数，其具体构造见 7.4.1 小节； $\Phi(\theta)$ 为策略 θ 在混合解析代理模型预测下的目标值； θ^* 为反向求解输出的最优策略。

式 (7-48) 中的目标函数由前向逐周递推与 GP 残差后验均值共同构成，其包含 Logit 形式套餐订阅的概率计算以及 Matern-5/2 核等非全局凸函数部分，因此该目

标函数在 $\mathcal{B}$ 内一般非凸，单初始点搜索可能收敛于较差的局部最优解。为此，反向求解采用搜索域内候选点筛选及多初始点拟牛顿优化的两阶段启发式方法。第一阶段搜索域内候选点筛选利用混合代理的批量前向计算筛选若干目标值较优的初始策略，第二阶段多初始点拟牛顿优化分别计算解析项与 GP 项关于策略变量的梯度，并由各初始策略出发作局部优化。下面先分别给出两个组成部分的反向推理计算方法，即基于两个组成部分得到目标值关于推广策略的梯度，再进一步说明两阶段搜索流程。

解析递推项的反向计算。首先将原前向递推过程写为易于求梯度的形式，将第 t 周全体智能体的状态概率向量汇总记为 $\mathbf{P}_t$ ，则解析代理的逐周演化可统一表示为

$$\mathbf{P}_{t+1} = \mathcal{T}_t(\mathbf{P}_t, \boldsymbol{\theta}_{\kappa(t)}), \quad t = 1, \dots, T, \quad (7-49)$$

式中， $\mathcal{T}_t(\cdot)$ 为由认知、试用、订阅、续订和流失等状态转移共同构成的第 t 周递推映射； $\kappa(t)$ 为第 t 周对应的策略阶段； $\boldsymbol{\theta}_{\kappa(t)}$ 为该阶段各分区推广策略的集合。解析代理的三项目标也可统一写为以下形式：

$$\hat{F}_j(\boldsymbol{\theta}) = \varphi_j(\mathbf{P}_{T+1}) + \sum_{t=1}^T \ell_{j,t}(\mathbf{P}_t, \boldsymbol{\theta}_{\kappa(t)}), \quad j = 1, 2, 3, \quad (7-50)$$

式中， $\varphi_j(\cdot)$ 为仿真结束时统计的目标项，对应最终用户采纳率； $\ell_{j,t}(\cdot)$ 为第 t 周产生的目标，用于累计订阅收入、营销支出与碳减排等指标。

式 (7-49) 与式 (7-50) 共同描述了推广策略影响目标函数的完整计算顺序。为计算目标 $\hat{F}_j$ 关于推广策略的梯度，引入伴随变量计算目标针对状态概率的梯度，即第 t 周状态概率发生微小变化后，目标 j 将发生多大变化：

$$\boldsymbol{\lambda}_{j,t} \equiv \nabla_{\mathbf{P}_t} \hat{F}_j = \left[\frac{\partial \hat{F}_j}{\partial \mathbf{P}_{1,t}}, \frac{\partial \hat{F}_j}{\partial \mathbf{P}_{2,t}}, \dots \right]^\top, \quad (7-51)$$

式中， $\boldsymbol{\lambda}_{j,t}$ 与状态概率向量 $\mathbf{P}_t$ 具有相同维度，其每个分量表示，在其他条件保持不变时，第 t 周某一状态概率增加一个单位将引起目标 j 变化的数量。

伴随变量从仿真最后一个时间步开始计算，该时刻下状态向量对目标 j 的影响仅来自目标 φ_j ：

$$\boldsymbol{\lambda}_{j,T+1} = \nabla_{\mathbf{P}_{T+1}} \varphi_j(\mathbf{P}_{T+1}). \quad (7-52)$$

随后按照 $t = T, T-1, \dots, 1$ 的顺序逐步长向前回溯：

$$\boldsymbol{\lambda}_{j,t} = \nabla_{\mathbf{P}_t} \ell_{j,t}(\mathbf{P}_t, \boldsymbol{\theta}_{\kappa(t)}) + \left[\frac{\partial \mathcal{T}_t}{\partial \mathbf{P}_t} \right]^\top \boldsymbol{\lambda}_{j,t+1} \quad (7-53)$$

式中， $\nabla_{\mathbf{P}_t} \ell_{j,t}(\mathbf{P}_t, \boldsymbol{\theta}_{\kappa(t)})$ 表示第 t 周状态变化对当周目标的直接影响； $\partial \mathcal{T}_t / \partial \mathbf{P}_t$ 为第 t 周状态转移关于当前状态的 Jacobian 矩阵，用于刻画当前各状态概率变化对下一

周各状态概率的影响；进而， $\left[\frac{\partial \mathcal{T}_t}{\partial \mathbf{P}_t}\right]^\top \boldsymbol{\lambda}_{j,t+1}$ 表示第 t 周状态对下一周状态 $\mathbf{P}_{t+1}$ 的影响，以及后续每周的状态对目标影响的间接作用。伴随变量 $\boldsymbol{\lambda}_{j,t}$ 将上述当周直接影响和全部未来间接影响合并为一个总敏感度。按照式 (7-53) 从第 $T+1$ 周递推至第 1 周，便可获得各周状态对目标的完整影响。

上述递推完成了目标函数到状态变量的反向传递，即得到了 $\nabla_{\mathbf{P}_t} \hat{F}_j = \boldsymbol{\lambda}_{j,t}$ ；反向求解实际需要的是目标函数关于推广策略的梯度 $\nabla_{\boldsymbol{\theta}_{k,z}} \hat{F}_j$ 。结合式 (7-50)，对于满足 $\kappa(t) = k$ 的第 t 周，分区 z 的推广策略 $\boldsymbol{\theta}_{k,z}$ ，其对目标的影响分为直接影响 $\nabla_{\boldsymbol{\theta}_{k,z}} \ell_{j,t}(\mathbf{P}_t, \boldsymbol{\theta}_{\kappa(t)})$ ，以及通过影响状态转移映射 $\mathcal{T}_t$ 改变下一周状态 $\mathbf{P}_{t+1}$ ，并进一步影响目标的间接影响。针对间接影响，结合链式法则，定义第 t 周状态转移关于该策略的 Jacobian 矩阵 $\mathbf{B}_{t,k,z}$ 为

$$\mathbf{B}_{t,k,z} \equiv \frac{\partial \mathbf{P}_{t+1}}{\partial \boldsymbol{\theta}_{k,z}} = \frac{\partial \mathcal{T}_t(\mathbf{P}_t, \boldsymbol{\theta}_{\kappa(t)})}{\partial \boldsymbol{\theta}_{k,z}}, \quad \kappa(t) = k. \quad (7-54)$$

若状态向量与单阶段分区策略向量的维度分别为 n_P 和 d_θ ，则 $\mathbf{B}_{t,k,z} \in \mathbb{R}^{n_P \times d_\theta}$ 。当策略发生微小变化 $d\boldsymbol{\theta}_{k,z}$ 时，有 $d\mathbf{P}_{t+1} = \mathbf{B}_{t,k,z} d\boldsymbol{\theta}_{k,z}$ 。由于 $\boldsymbol{\lambda}_{j,t+1}$ 已经汇总了第 $t+1$ 周状态对当周及其后全部目标的影响，故策略经状态递推引起的目标变化为

$$\begin{aligned} d\hat{F}_j|_{\mathbf{P}_{t+1}} &= \boldsymbol{\lambda}_{j,t+1}^\top d\mathbf{P}_{t+1} \\ &= \boldsymbol{\lambda}_{j,t+1}^\top \mathbf{B}_{t,k,z} d\boldsymbol{\theta}_{k,z} \\ &= (\mathbf{B}_{t,k,z}^\top \boldsymbol{\lambda}_{j,t+1})^\top d\boldsymbol{\theta}_{k,z} \\ &= \left(\left[\frac{\partial \mathcal{T}_t}{\partial \boldsymbol{\theta}_{k,z}} \right]^\top \boldsymbol{\lambda}_{j,t+1} \right)^\top d\boldsymbol{\theta}_{k,z}. \end{aligned} \quad (7-55)$$

因此，由状态传递产生的间接梯度为

$$\nabla_{\boldsymbol{\theta}_{k,z}} \hat{F}_j|_{\mathbf{P}_{t+1}} = \left[\frac{\partial \mathcal{T}_t}{\partial \boldsymbol{\theta}_{k,z}} \right]^\top \boldsymbol{\lambda}_{j,t+1}. \quad (7-56)$$

综上，将策略对目标流量的直接影响与间接影响按周求和，可得

$$\nabla_{\boldsymbol{\theta}_{k,z}} \hat{F}_j = \sum_{\{t: \kappa(t)=k\}} \left\{ \nabla_{\boldsymbol{\theta}_{k,z}} \ell_{j,t}(\mathbf{P}_t, \boldsymbol{\theta}_{\kappa(t)}) + \left[\frac{\partial \mathcal{T}_t}{\partial \boldsymbol{\theta}_{k,z}} \right]^\top \boldsymbol{\lambda}_{j,t+1} \right\}. \quad (7-57)$$

式中采用 $\boldsymbol{\lambda}_{j,t+1}$ 是因为第 t 周策略通过 $\mathcal{T}_t$ 直接改变的是下一周状态 $\mathbf{P}_{t+1}$ 。由于同一阶段的策略在该阶段内保持不变，其梯度需累加所有满足 $\kappa(t) = k$ 的贡献。至此，式 (7-57) 给出了目标函数关于推广策略的梯度计算方法，完成了解析递推项的反向求解。

GP 项的反向计算。 GP 拟合完成后，残差观测、核超参数与核矩阵在反向求解过程中均保持固定，反向计算仅针对待求策略 $\boldsymbol{\theta}$ 更新核向量及残差后验均值。首

先, 将式 (7-46) 中与待求策略无关的部分预先合并为系数向量:

$$\xi_j = (K_j + \sigma_{n,j}^2 \mathbf{I})^{-1} \mathbf{r}_j, \quad \mu_j(\boldsymbol{\theta}) = \mathbf{k}_j(\boldsymbol{\theta})^\top \xi_j, \quad j = 1, 2, 3, \quad (7-58)$$

式中, $\xi_j \in \mathbb{R}^N$ 为目标 j 的预计算系数, 在 GP 拟合完成后保持不变; $\mathbf{k}_j(\boldsymbol{\theta})$ 为待求策略与 N 个训练策略之间的核向量。因此, GP 后验均值关于策略的梯度在理论上为 $\nabla_{\boldsymbol{\theta}} \mu_j(\boldsymbol{\theta}) = [\nabla_{\boldsymbol{\theta}} \mathbf{k}_j(\boldsymbol{\theta})]^\top \xi_j$ 。以批量前向差分计算上述梯度。对当前迭代策略, 将其各维正向扰动组成设计矩阵:

$$\mathbf{X}_\varepsilon(\boldsymbol{\theta}) = \begin{bmatrix} \boldsymbol{\theta}^\top \\ (\boldsymbol{\theta} + \varepsilon \mathbf{e}_1)^\top \\ \vdots \\ (\boldsymbol{\theta} + \varepsilon \mathbf{e}_D)^\top \end{bmatrix} \in \mathbb{R}^{(D+1) \times D}, \quad (7-59)$$

式中, D 为推广策略向量的维度; $\mathbf{e}_d$ 为第 d 维单位向量; ε 为差分步长。将式 (7-59) 的 $D+1$ 个策略输入三个目标已拟合的 GP 模型, 得到

$$\begin{aligned} \mathbf{m}_j(\boldsymbol{\theta}) &= [m_{j,0}, m_{j,1}, \dots, m_{j,D}]^\top, \\ m_{j,0} &= \mu_j(\boldsymbol{\theta}), \quad m_{j,d} = \mu_j(\boldsymbol{\theta} + \varepsilon \mathbf{e}_d), \\ \left[\widehat{\nabla_{\boldsymbol{\theta}} \mu_j(\boldsymbol{\theta})} \right]_d &= \frac{m_{j,d} - m_{j,0}}{\varepsilon}, \quad d = 1, \dots, D, \end{aligned} \quad (7-60)$$

式中, $j = 1, 2, 3$ 分别对应用户采纳率、平台净收入与碳减排三项目标; $\mu_j(\boldsymbol{\theta})$ 为目标 j 的 GP 残差模型在策略 $\boldsymbol{\theta}$ 处给出的后验均值; $\mathbf{m}_j(\boldsymbol{\theta}) \in \mathbb{R}^{D+1}$ 为该 GP 对式 (7-59) 中全部扰动策略进行批量预测得到的后验均值向量。其中, $m_{j,0}$ 为未扰动策略 $\boldsymbol{\theta}$ 处的残差后验均值, 作为差分计算的基准值; $m_{j,d}$ 为仅将策略第 d 维增加 ε 后得到的残差后验均值; $\widehat{\nabla_{\boldsymbol{\theta}} \mu_j(\boldsymbol{\theta})} \in \mathbb{R}^D$ 为通过前向差分近似得到的目标 j 的 GP 残差梯度, 符号 $\left[\widehat{\nabla_{\boldsymbol{\theta}} \mu_j(\boldsymbol{\theta})} \right]_d$ 表示该梯度的第 d 个分量。

在得到混合解析代理模型两部分的梯度后, 便可结合梯度信息进行反向求解。为避免单初始点搜索陷入局部最优, 采用两阶段启发式方法: 第一阶段在搜索域内筛选若干目标值较优的初始策略, 第二阶段以这些初始策略为起点作多初始点拟牛顿优化。

第一阶段: 搜索域内候选点筛选。除搜索域中心外, 在 $\mathcal{B}$ 内以拉丁超立方采样生成 S 个策略样本, 共同构成候选集, 再按目标值筛选策略起点:

$$\mathcal{S}_0 = \{\boldsymbol{\theta}_c\} \cup \{\boldsymbol{\theta}^{(1)}, \dots, \boldsymbol{\theta}^{(S)}\}, \quad \mathcal{S}_1 = \underset{\substack{\mathcal{S} \subseteq \mathcal{S}_0 \\ |\mathcal{S}|=n_0}}{\operatorname{argmin}} \sum_{\boldsymbol{\theta} \in \mathcal{S}} \Phi(\boldsymbol{\theta}), \quad (7-61)$$

式中, $\boldsymbol{\theta}_c$ 为搜索域 $\mathcal{B}$ 的中心; $\boldsymbol{\theta}^{(1)}, \dots, \boldsymbol{\theta}^{(S)}$ 为拉丁超立方采样生成的 S 个策略样本; $\mathcal{S}_0$ 为候选集; $\mathcal{S}_1$ 为 $\mathcal{S}_0$ 中目标值最小的 n_0 个策略构成的策略起点集。本阶段的作用是在非凸目标下为第二阶段提供分散于 $\mathcal{B}$ 内不同区域的优质初始点。

第二阶段：多初始点拟牛顿优化。对 $\mathcal{S}_1$ 中的每个初始点，以有限内存拟牛顿法（L-BFGS-B）在盒约束 $\mathcal{B}$ 内迭代优化。迭代所需的目标梯度由解析项与 GP 项按链式法则合成：

$$\nabla_{\theta} \tilde{F}_j(\theta) = \nabla_{\theta} \hat{F}_j(\theta) + \widehat{\nabla_{\theta} \mu_j(\theta)}, \quad \nabla_{\theta} \Phi(\theta) = \sum_{j=1}^3 \frac{\partial g}{\partial \tilde{F}_j} \nabla_{\theta} \tilde{F}_j(\theta), \quad (7-62)$$

式中， $\nabla_{\theta} \hat{F}_j(\theta)$ 为解析递推项的梯度； $\widehat{\nabla_{\theta} \mu_j(\theta)}$ 为式 (7-60) 得到的 GP 残差梯度； $\partial g / \partial \tilde{F}_j$ 为目标函数对目标 j 的偏导数或次梯度。基于上述联合梯度，自各策略初始点出发的迭代优化可概括为

$$\theta^{(m+1)} = \Pi_{\mathcal{B}} [\theta^{(m)} - \alpha^{(m)} \mathbf{H}^{(m)} \nabla_{\theta} \Phi(\theta^{(m)})], \quad (7-63)$$

式中， $\theta^{(m)}$ 为第 m 步的迭代点； $\mathbf{H}^{(m)}$ 为 L-BFGS-B 由最近若干步的策略增量与梯度增量递推得到的逆 Hessian 近似矩阵； $\alpha^{(m)}$ 为线搜索确定的步长； $\Pi_{\mathcal{B}}[\cdot]$ 为向盒约束 $\mathcal{B}$ 的投影算子。各起点独立迭代至收敛后，取全部收敛解中目标值最小的策略作为问题 (7-48) 的解 θ^* ，即本轮反向求解输出的候选策略。

上述候选点筛选与多初始点拟牛顿优化的完整执行过程见算法 1。

算法 1：混合解析代理模型的两阶段反向求解流程

Require: 搜索域 $\mathcal{B}$, 解析代理 $\{\hat{F}_j\}_{j=1}^3$, 已拟合的 GP 残差模型 $\{\mu_j\}_{j=1}^3$, 标量化函数 g , 拉丁超立方样本数 S , 策略起点数 n_0 , 最大迭代次数 $M_{\max}$, 差分步长 ε

Ensure: 反向求解得到的候选策略 θ^*

- 1: 按式 (7-58) 预计算并缓存各目标的 GP 系数 $\{\xi_j\}_{j=1}^3$
- 2: **第一阶段：搜索域内候选点筛选**
- 3: 计算搜索域中心 $\theta_c \leftarrow \text{center}(\mathcal{B})$
- 4: 在 $\mathcal{B}$ 内生成拉丁超立方样本 $\{\theta^{(s)}\}_{s=1}^S$
- 5: 构造候选集 $\mathcal{S}_0 \leftarrow \{\theta_c\} \cup \{\theta^{(1)}, \dots, \theta^{(S)}\}$
- 6: 对 $\mathcal{S}_0$ 批量执行逐周解析递推, 得到 $\{\hat{F}_j(\theta)\}_{j=1}^3$
- 7: 对 $\mathcal{S}_0$ 批量计算 GP 残差后验均值, 得到 $\{\mu_j(\theta)\}_{j=1}^3$
- 8: 计算 $\tilde{F}_j(\theta) \leftarrow \hat{F}_j(\theta) + \mu_j(\theta)$ 及 $\Phi(\theta) \leftarrow g(\tilde{F}_1, \tilde{F}_2, \tilde{F}_3)$
- 9: 按 $\Phi(\theta)$ 从小到大排序, 取前 n_0 个策略构成 $\mathcal{S}_1 = \{\theta_r^{(0)}\}_{r=1}^{n_0}$
- 10: **第二阶段：多初始点拟牛顿优化**
- 11: 初始化局部收敛解集 $\mathcal{C} \leftarrow \emptyset$
- 12: **for** $r = 1, \dots, n_0$ **do**
- 13: 令 $m \leftarrow 0$, 初始化 L-BFGS-B 校正向量
- 14: **while** $m < M_{\max}$ 且尚未满足收敛条件 **do**
- 15: 前向计算 $\{\hat{F}_j(\theta_r^{(m)})\}_{j=1}^3$, 并按式 (7-57) 反向计算其梯度
- 16: 按式 (7-59) 构造扰动批次, 并按式 (7-60) 计算 GP 残差及其梯度
- 17: 按式 (7-62) 合成 $\Phi(\theta_r^{(m)})$ 与 $\nabla_{\theta} \Phi(\theta_r^{(m)})$
- 18: 由校正向量更新 $H^{(m)}$, 经线搜索确定 $\alpha^{(m)}$, 并按式 (7-63) 更新 $\theta_r^{(m+1)}$
- 19: $m \leftarrow m + 1$
- 20: **end while**
- 21: 将局部收敛解加入 $\mathcal{C} \leftarrow \mathcal{C} \cup \{\theta_r^{(m)}\}$
- 22: **end for**
- 23: $\theta^* \leftarrow \arg \min_{\theta \in \mathcal{C}} \Phi(\theta)$
- 24: **return** θ^*

7.3.3 基于深度学习的代理模型设计

混合解析代理模型虽能在较少仿真样本下给出相对稳定的预测, 但仍存在不足。一方面, 平均场近似所舍弃的个体异质性、离散选择决策与跨区交互会带来目标预测的偏差, 且因 GP 模型只对最终目标预测残差, 难以获取较为精准的中间状态信息。另一方面, GP 的核表示由既有样本确定, 新增样本需要重新拟合各目标对应的 GP 模型, 当样本数量提升时, 训练成本将显著增加, 且 GP 模型的表达

能力在高维策略空间中有限,难以捕捉复杂的非线性作用关系。因此,在混合解析代理模型基础上继续设计深度学习代理模型,以充分利用深度学习网络对高维映射的学习能力。

然而,针对本章推广策略寻优问题,基于深度学习的代理模型需满足以下条件。首先,城市级推广策略仿真计算开销较大,可获得的仿真样本远少于深度网络的训练需求,因此模型须具备小样本学习能力。其次,优化过程中仿真样本按轮次持续增加,模型既要即时利用新增样本,又要避免少量增量数据破坏已经形成的全局表征。再次,未经训练的随机网络不具备可信的策略响应关系,其在寻优过程输出的最优策略不具有物理意义。因此,需结合物理先验知识对深度学习模型进行约束,使其能够在进行少量训练的基础上具有可用于策略寻优的能力。围绕上述要求,本小节依次介绍基于深度学习代理模型的模型架构、训练策略与反向求解方法,其整体架构如图 7-4 所示。




图 7-4 基于深度学习代理模型总体架构

Figure 7-4 Overall architecture of the deep-learning surrogate model.

(1) 模型架构

为有效的利用仿真模型的运行特征并处理训练信息稀疏问题,结合仿真模型的运行特性,本章设计由五个模块构成的深度学习代理模型: i. 分区时序策略编码器用于处理推广策略的时序依赖关系,即提取同一分区内策略的跨阶段关联与累积效应; ii. 外生情境编码器用于提取全局和分区情境的特征,即对各分区的社会经济结构、既有出行行为等外生变量进行编码,以辅助捕捉各分区对推广策略的

响应差异；iii. 跨区交互编码器用于学习分区之间的依赖关系；iv. 基于已评估策略的条件推断模块旨在解决训练信息稀疏问题，即结合小样本学习的思想，将已过去评估仿真样本作为推断条件，对预测策略进行条件预测，并在策略寻优过程中通过持续新增样本提高预测表现；v. 基于物理先验的目标解码器则将上述四模块输出的联合表征映射为仿真模型输出中间量与逐策略阶段的目标，通过混合解析代理模型输出的仿真中间量对网络进行约束，进一步降低小样本条件下的训练难度。五个模块的总体连接关系如图 7-4 所示。对五个模块的详细介绍如下：

分区时序策略编码器。各分区前一阶段的推广策略会对后续阶段产生影响，且各阶段策略的作用在时间上具有延续性。为此，针对每个分区沿策略阶段这一时间维度执行一维卷积，以提取各阶段间策略的时序依赖关系。记分区 z 策略的时间序列为 $\Theta_z \in \mathbb{R}^{K \times P_m}$ ，则第 ℓ 层卷积表示为

$$\begin{aligned} Z_z^{(0)} &= \Theta_z^\top, \\ Z_z^{(\ell)}[:, t] &= \rho \left(\sum_{\tau=-r_\ell}^{r_\ell} W_\tau^{(\ell)} Z_z^{(\ell-1)}[:, t+\tau] + b^{(\ell)} \right), \quad \ell = 1, \dots, L_c, \end{aligned} \quad (7-64)$$

式中， $\rho(x) = \max\{0, x\}$ 为 ReLU 激活函数； L_c 为卷积层数； $Z_z^{(\ell)}[:, t] \in \mathbb{R}^{C_\ell}$ 为第 ℓ 层在阶段 t 处的通道向量； C_ℓ 为该层通道数； $W_\tau^{(\ell)}$ 与 $b^{(\ell)}$ 分别为相对位置 τ 处的卷积权重与偏置； r_ℓ 为第 ℓ 层卷积核的半宽，相应卷积核宽度为 $2r_\ell + 1$ 。序列两端采用等长零填充，使各层的阶段长度保持为 K 。在卷积最后一层，将得到的特征展平并投影为各分区的策略表征：

$$h_z = \rho [W_p \text{vec}(Z_z^{(L_c)}) + b_p] \in \mathbb{R}^{D_h}, \quad (7-65)$$

式中， $h_z \in \mathbb{R}^{D_h}$ 为分区 z 的策略表征； $Z_z^{(L_c)} \in \mathbb{R}^{C_{L_c} \times K}$ 为最后一次卷积输出的特征； $\text{vec}(\cdot)$ 表示按照阶段顺序将该特征图展开为 $K C_{L_c}$ 维列向量； $W_p \in \mathbb{R}^{D_h \times K C_{L_c}}$ 和 $b_p \in \mathbb{R}^{D_h}$ 分别为特征投影层的权重矩阵和偏置向量； D_h 为分区策略表征的维度。该投影层将包含各阶段局部策略模式的卷积特征压缩为固定维度的分区级策略表征，供后续跨区交互编码使用。值得注意的是，卷积编码器在各分区间共享参数，使相同位置的策略变量具有一致的含义，分区差异则由外生情境编码器提取。

外生变量编码器。考虑地区人口社会经济结构和居民出行模式对策略效果的影响，本模块将各地区的社会经济与出行特征汇总为外生变量向量 $s \in \mathbb{R}^{D_s}$ (D_s 为分区外生变量向量维度)，并通过多层感知机提取城市级的外生变量特征嵌入：

$$\begin{aligned} c_g^{(0)} &= s, \\ c_g^{(\ell)} &= \rho (W_g^{(\ell)} c_g^{(\ell-1)} + b_g^{(\ell)}), \quad \ell = 1, \dots, L_g, \\ c_g &= c_g^{(L_g)} \in \mathbb{R}^{D_c}, \quad c_z = S_z s \in \mathbb{R}^{D_{c,z}}, \end{aligned} \quad (7-66)$$

式中, D_c 为城市级外生变量向量嵌入维度; L_g 为城市级外生变量编码器层数; $\mathbf{W}_g^{(\ell)}$ 与 $\mathbf{b}_g^{(\ell)}$ 为第 ℓ 层的可学习权重和偏置; $\mathbf{S}_z$ 为从城市级外生变量向量中筛选分区 z 外生变量的矩阵; $\mathbf{c}_z$ 为分区 z 的外生变量。其中, 城市级外生变量嵌入融合至全部样本表征, 用以辅助捕捉各分区对推广策略的响应差异, 各分区的外生变量则之后进入相应分区的目标解码过程, 以便在预测分区目标时考虑其分区本身特征。

跨区交互编码器。推广策略虽按分区设置, 但不同分区的策略在仿真模型中并非相互独立。一方面, 用户的认知与口碑扩散的空间传播, 使分区 z 的认知、试用、订阅及相应目标不仅受到本区策略 Θ_z 的影响, 还会受到其他分区采纳用户的间接作用。另一方面, 城市级采纳率、平台净收入与碳减排需要由各分区结果按照相应指标口径集计获得, 取决于各分区策略的效果。因此, 在将策略的特征向量输入进目标解码器之前, 需使每个分区的策略表征能够获取其他分区策略的信息。为此, 将 Z 个分区策略表征作为序列元素施加多头自注意力。对第 m 个注意力头, 分区 z 对分区 z' 的注意力权重及该头的输出为

$$\alpha_{zz'}^{(m)} = \frac{\exp\left(\left\langle \mathbf{W}_Q^{(m)} \mathbf{h}_z, \mathbf{W}_K^{(m)} \mathbf{h}_{z'} \right\rangle / \sqrt{d_a}\right)}{\sum_{z''=1}^Z \exp\left(\left\langle \mathbf{W}_Q^{(m)} \mathbf{h}_z, \mathbf{W}_K^{(m)} \mathbf{h}_{z''} \right\rangle / \sqrt{d_a}\right)}, \quad \mathbf{u}_z^{(m)} = \sum_{z'=1}^Z \alpha_{zz'}^{(m)} \mathbf{W}_V^{(m)} \mathbf{h}_{z'}, \quad (7-67)$$

式中, $\alpha_{zz'}^{(m)}$ 为第 m 个注意力头中分区 z 分配给分区 z' 的归一化注意力权重, 满足 $\alpha_{zz'}^{(m)} \geq 0$ 且 $\sum_{z'=1}^Z \alpha_{zz'}^{(m)} = 1$; $\mathbf{W}_Q^{(m)}, \mathbf{W}_K^{(m)}, \mathbf{W}_V^{(m)} \in \mathbb{R}^{d_a \times D_h}$ 分别为第 m 个注意力头的查询、键和值投影矩阵; $\langle \cdot, \cdot \rangle$ 表示向量内积; d_a 为单个注意力头的维度。 $\mathbf{u}_z^{(m)} \in \mathbb{R}^{d_a}$ 为分区 z 在该注意力头上汇聚其他分区特征后得到的输出。各头输出经拼接和输出投影后, 与原分区表征作残差连接和层归一化:

$$\begin{aligned} \tilde{\mathbf{h}}_z &= \text{LN}\left(\mathbf{h}_z + \mathbf{W}_O \left[\mathbf{u}_z^{(1)}; \dots; \mathbf{u}_z^{(H_a)}\right]\right), \\ \text{LN}(\mathbf{x}) &= \gamma \odot \frac{\mathbf{x} - \bar{\mathbf{x}}\mathbf{1}}{\sqrt{v(\mathbf{x}) + \epsilon_{\text{LN}}}} + \beta, \end{aligned} \quad (7-68)$$

式中, $\mathbf{W}_O \in \mathbb{R}^{D_h \times H_a d_a}$ 为多头注意力的输出投影矩阵; $\tilde{\mathbf{h}}_z \in \mathbb{R}^{D_h}$ 为融合其他分区策略特征后的策略表征; $\text{LN}(\cdot)$ 为层归一化算子。对于 $\mathbf{x} \in \mathbb{R}^{D_h}$, $\bar{\mathbf{x}} = D_h^{-1} \sum_{r=1}^{D_h} x_r$ 与 $v(\mathbf{x}) = D_h^{-1} \sum_{r=1}^{D_h} (x_r - \bar{\mathbf{x}})^2$ 分别为其分量均值与方差; $\mathbf{1} \in \mathbb{R}^{D_h}$ 为全一向量; $\epsilon_{\text{LN}} > 0$ 为保证数值稳定的常数; $\gamma, \beta \in \mathbb{R}^{D_h}$ 分别为可学习的逐维缩放参数和平移参数; $\odot$ 表示逐元素相乘。

基于已评估策略的条件推断模块。深度学习代理既面临初始仿真样本数量有限的问题, 也面临寻优过程中已评估样本持续增加的问题。因此, 基于深度学习的代理模型需具有的小样本学习和持续学习的能力, 以适应仿真优化问题的特性。

为此, 借鉴注意神经过程根据已观测输入—输出集合构造条件预测分布的思想^[192], 将已评估策略及其效果组成已评估策略集合 $\mathcal{D}_{\text{ctx}} = \{(\Theta^{(n)}, \mathbf{Y}^{(n)})\}_{n=1}^{M_c}$ (其中,

$\mathbf{Y}^{(n)} \in \mathbb{R}^{Z \times D_y}$ 为样本 n 的分区输出； D_y 为每个分区输出的维度； M_c 为当前已评估样本数），并以该集合为条件推断目标策略 Θ_* 的推广效果。具体而言，结合构建的已评估策略集合，基于已评估策略的条件推断模块针对待评估策略提取相关策略输出特征及已评估策略集合整体特征，前者从局部视角提取与待评估策略较为相近的策略的推广效果特征，后者则从全局视角提取已评估策略集合的整体特征，以辅助预测待评估策略的推广效果。

首先，对每个已评估样本，将其跨区交互后的分区策略表征汇聚为样本级策略表征，同时将对应分区的目标输出进行嵌入，进而构建推广策略—目标输出对的已评估策略表征：

$$\begin{aligned} \mathbf{p}^{(n)} &= \rho \left(\mathbf{W}_p \frac{1}{Z} \sum_{z=1}^Z \tilde{\mathbf{h}}_z^{(n)} + \mathbf{b}_p \right), & \mathbf{e}_y^{(n)} &= \rho [\mathbf{W}_y \text{vec}(\mathbf{Y}^{(n)}) + \mathbf{b}_y], \\ \mathbf{r}_n &= \text{Enc}_r([\mathbf{p}^{(n)}; \mathbf{e}_y^{(n)}; \mathbf{c}_g]), & n &= 1, \dots, M_c. \end{aligned} \quad (7-69)$$

式中， $\tilde{\mathbf{h}}_z^{(n)} \in \mathbb{R}^{D_h}$ 为已评估策略 n 在分区 z 的跨区交互表征； $\mathbf{p}^{(n)} \in \mathbb{R}^{D_p}$ 为对全部分区表征取均值并投影后得到的策略表征； $\mathbf{W}_p \in \mathbb{R}^{D_p \times D_h}$ 与 $\mathbf{b}_p \in \mathbb{R}^{D_p}$ 为相应投影参数； $\text{vec}(\mathbf{Y}^{(n)})$ 表示将样本 n 的全部分区输出展开为向量； $\mathbf{W}_y \in \mathbb{R}^{D_e \times ZD_y}$ 与 $\mathbf{b}_y \in \mathbb{R}^{D_e}$ 为输出嵌入层参数； $\mathbf{e}_y^{(n)} \in \mathbb{R}^{D_e}$ 为输出嵌入向量； $\text{Enc}_r(\cdot)$ 为已评估策略编码器； $\mathbf{r}_n \in \mathbb{R}^{D_r}$ 为同时包含推广策略、输出和城市级外生变量信息的第 n 个已评估策略的表征。这里将策略及其对应输出联合编码，是为了使后续待评估策略注意力检索的对象不只是哪些策略与目标策略相关，还包括这些策略曾产生何种效果。

在已评估策略表征的基础上，将待预测策略 Θ_* 编码为查询向量，并通过交叉注意力衡量该策略与已评估策略之间的表征相关性：

$$\begin{aligned} \mathbf{p}_* &= \rho \left(\mathbf{W}_p \frac{1}{Z} \sum_{z=1}^Z \tilde{\mathbf{h}}_z^{(*)} + \mathbf{b}_p \right), & \mathbf{q}_* &= \text{Enc}_q([\mathbf{p}_*; \mathbf{c}_g]), \\ \mathbf{k}_n &= \mathbf{W}_k \mathbf{r}_n + \mathbf{b}_k, & \mathbf{v}_n &= \mathbf{W}_v \mathbf{r}_n + \mathbf{b}_v, \\ \omega_{n*} &= \frac{\exp(\langle \mathbf{q}_*, \mathbf{k}_n \rangle / \sqrt{D_r})}{\sum_{i=1}^{M_c} \exp(\langle \mathbf{q}_*, \mathbf{k}_i \rangle / \sqrt{D_r})}, & \mathbf{r}_* &= \sum_{n=1}^{M_c} \omega_{n*} \mathbf{v}_n. \end{aligned} \quad (7-70)$$

式中， $\tilde{\mathbf{h}}_z^{(*)}$ 为待预测策略在分区 z 的跨区交互表征； $\mathbf{p}_* \in \mathbb{R}^{D_p}$ 为该策略的表征； $\text{Enc}_q(\cdot)$ 为目标查询编码器； $\mathbf{q}_* \in \mathbb{R}^{D_r}$ 为目标查询向量； $\mathbf{W}_k, \mathbf{W}_v \in \mathbb{R}^{D_r \times D_r}$ 与 $\mathbf{b}_k, \mathbf{b}_v \in \mathbb{R}^{D_r}$ 分别为键、值投影的权重和偏置； $\mathbf{k}_n, \mathbf{v}_n \in \mathbb{R}^{D_r}$ 分别为已评估策略表征 $\mathbf{r}_n$ 经键投影和值投影得到的向量； ω_{n*} 为目标策略分配给样本 n 的归一化注意力权重，满足 $\omega_{n*} \geq 0$ 且 $\sum_{n=1}^{M_c} \omega_{n*} = 1$ ； $\mathbf{r}_*$ 为交叉注意力机制得到的已评估策略经验表征。由式 (7-70) 可知，不同待评估策略会形成不同的注意力权重，从而有选择地利用与当前查询相

关的已评估策略。值得注意的是，式 (7-70) 中给出单个注意力头的表达形式，多头注意力对各头的结果进行拼接和输出投影。

以上交叉注意力侧重提取与待评估策略相关的已评估策略的表征，但仅依赖少数策略可能忽略全体已评估策略集合反映的目标分布。为此，对全部已评估策略表征集计处理，再由该处理结果构造已评估策略目标输出的条件后验分布：

$$\begin{aligned}\bar{\mathbf{r}}_{\mathcal{D}} &= \frac{1}{|\mathcal{D}|} \sum_{(\Theta, \mathbf{Y}) \in \mathcal{D}} \mathbf{r}(\Theta, \mathbf{Y}), \\ q_{\psi}(\boldsymbol{\xi} | \mathcal{D}) &= \mathcal{N}[\boldsymbol{\mu}_{\xi}(\bar{\mathbf{r}}_{\mathcal{D}}), \text{diag} \boldsymbol{\sigma}_{\xi}^2(\bar{\mathbf{r}}_{\mathcal{D}})], \\ \boldsymbol{\xi} &= \begin{cases} \boldsymbol{\mu}_{\xi}(\bar{\mathbf{r}}_{\mathcal{D}_{\text{ctx}} \cup \mathcal{B}_t}) + \boldsymbol{\sigma}_{\xi}(\bar{\mathbf{r}}_{\mathcal{D}_{\text{ctx}} \cup \mathcal{B}_t}) \odot \boldsymbol{\varepsilon}_{\xi}, & \text{训练阶段,} \\ \boldsymbol{\mu}_{\xi}(\bar{\mathbf{r}}_{\mathcal{D}_{\text{ctx}}}), & \text{推理阶段,} \end{cases} \quad \boldsymbol{\varepsilon}_{\xi} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).\end{aligned}\tag{7-71}$$

式中， $\mathcal{D}$ 表示已评估策略集计处理的策略集合， $|\mathcal{D}|$ 为其样本数； $\mathbf{r}(\Theta, \mathbf{Y})$ 为按式 (7-69) 得到的已评估策略表征； $\bar{\mathbf{r}}_{\mathcal{D}}$ 为集合 $\mathcal{D}$ 的整体表征； $\boldsymbol{\xi} \in \mathbb{R}^{D_{\xi}}$ 为表征已评估策略整体目标输出及其不确定性的潜变量； $q_{\psi}(\cdot)$ 为参数为 ψ 的条件后验分布； $\boldsymbol{\mu}_{\xi}(\cdot), \boldsymbol{\sigma}_{\xi}(\cdot) \in \mathbb{R}^{D_{\xi}}$ 分别输出潜变量后验均值和标准差， D_{ξ} 为潜变量维度； $\boldsymbol{\varepsilon}_{\xi} \in \mathbb{R}^{D_{\xi}}$ 为标准高斯噪声， $\mathbf{I}$ 为 D_{ξ} 阶单位矩阵； $\mathcal{B}_t$ 为训练阶段能够获得真实输出的待评估策略集合。训练阶段从已评估策略和待评估策略的后验中重参数化采样，并通过后续 KL 损失使其接近仅由已评估策略集合形成的后验；推理阶段无法获得待评估策略的真实输出，因而只使用 $\mathcal{D}_{\text{ctx}}$ 形成的后验均值。

由此， $\mathbf{r}_{*}$ 与 $\boldsymbol{\xi}$ 分别提供待评估策略相关的局部特征和全局特征，并与待评估策略的分区表征共同输入后续目标解码器。新增仿真样本加入 $\mathcal{D}_{\text{ctx}}$ 后，会立即改变注意力权重、确定性经验表征和潜变量后验，因而无需先更新全部网络参数即可修正待评估策略的预测结果，进而保障基于深度学习代理模型的小样本学习和持续学习能力。

基于物理先验的目标解码器。在上述四个模块输出的联合表征基础上，目标解码器旨在准确复现给定策略下的仿真模型输出，包括最终目标和用来理解仿真模型的运行机制与目标形成过程的过程量和逐阶段目标。

在解码器输出的组织方式上，对每个分区分别预测 Q 项中间过程量以及 K 个策略阶段的 J 项目标。其中，中间过程量用于描述各分区智能体认知、试用和订阅等状态，属于辅助预测；逐阶段目标则保留用户采纳率、平台净收入和碳减排等三目标随策略实施的演化过程。得到各分区的目标预测值后，再将各分区指标集计为城市级目标。该结构使预测误差能够沿分区和策略阶段两个向网络传播，辅助模型学习目标的空间来源与时间累积过程。

其次，为这些中间量预测提供与仿真过程相对应的监督手段。为此，以解析代

理计算的认知率、试用概率、订阅概率、感知价值和价格差等 Q 项中间量作为辅助标签, 通过设计损失项以引导网络训练过程, 使网络在学习最终推广效果的同时, 也学习各指标之间的交互关系。

最后, 考虑到认知扩散、试用和订阅等作用机制在不同分区之间具有共同的作用机制, 令全部分区共用同一套解码器参数, 使各分区样本能够共同识别仿真模型的作用机制。综合上述设计, 分区 z 的预测为

$$\begin{aligned} (\boldsymbol{\mu}_z, \boldsymbol{\eta}_z) &= \text{Dec}([\tilde{\mathbf{h}}_z; \mathbf{e}_z; \mathbf{c}_z; \mathbf{r}_*; \boldsymbol{\xi}]), \\ \boldsymbol{\sigma}_z &= \boldsymbol{\varepsilon}_\sigma + \text{softplus}(\boldsymbol{\eta}_z), \quad \boldsymbol{\mu}_z, \boldsymbol{\sigma}_z \in \mathbb{R}^{D_y}, \quad D_y = Q + KJ, \end{aligned} \quad (7-72)$$

式中, $\text{Dec}(\cdot)$ 为全部分区共享参数的多层感知机解码器; $\tilde{\mathbf{h}}_z$ 为融合跨区信息后的分区策略表征; $\mathbf{e}_z$ 为分区嵌入; $\mathbf{c}_z$ 为分区外生变量; $\mathbf{r}_*$ 与 $\boldsymbol{\xi}$ 分别为待评估策略相关的局部特征和全局特征; $\boldsymbol{\mu}_z \in \mathbb{R}^{D_y}$ 为分区 z 各输出维度的预测均值; $\boldsymbol{\eta}_z \in \mathbb{R}^{D_y}$ 为解码器输出的无约束尺度参数; $\text{softplus}(x) = \ln(1 + \exp x)$ 用于将其转换为正值; $\boldsymbol{\sigma}_z \in \mathbb{R}^{D_y}$ 为预测标准差, 仅用于训练阶段刻画不同分区和输出维度的噪声; $\boldsymbol{\varepsilon}_\sigma > 0$ 为标准差下限。每个分区的输出维度为 $D_y = Q + KJ$, 其中 $\boldsymbol{\mu}_z$ 的前 Q 个分量对应中间过程量, 其余 KJ 个分量对应 K 个策略阶段的 $J = 3$ 项目标。城市级阶段目标由分区输出按指标口径聚合:

$$F_{k,1}^{\text{DL}} = \frac{\sum_{z=1}^Z N_z \mu_{z,k,1}^{\text{obj}}}{\sum_{z=1}^Z N_z}, \quad F_{k,j}^{\text{DL}} = \sum_{z=1}^Z \mu_{z,k,j}^{\text{obj}}, \quad j = 2, \dots, J, \quad (7-73)$$

式中, N_z 为分区 z 的人口规模; $\mu_{z,k,j}^{\text{obj}}$ 为解码器对分区 z 、阶段 k 、目标 j 的预测均值。预测城市级采纳率目标按人口加权聚合, 平台净收入与碳减排目标按分区求和。

(2) 损失函数与训练策略

损失函数。深度学习代理模型的损失函数由三部分构成, 分别对应输出拟合精度、条件推断一致性和反向求解可行性。

针对输出拟合精度, 解码器输出的 Q 项中间量和 KJ 项阶段目标均为连续变量, 但其形成机理与数值波动程度并不相同。因此, 采用异方差高斯负对数似然^[193,194], 使解码器同时预测输出均值与条件方差, 并依据各指标的预测难度自适应调整残差权重。记目标批次为 $\mathcal{B}_t$, 样本数为 $N_t = |\mathcal{B}_t|$ 。对于其中的样本 n , 分区 z 、输出维度 d 对应的负对数似然为

$$\ell_{z,d}^{(n)} = \frac{1}{2} \ln \left[\left(\sigma_{z,d}^{(n)} \right)^2 + \varepsilon_y \right] + \frac{\left(Y_{z,d}^{(n)} - \mu_{z,d}^{(n)} \right)^2}{2 \left[\left(\sigma_{z,d}^{(n)} \right)^2 + \varepsilon_y \right]}, \quad d = 1, \dots, D_y. \quad (7-74)$$

式中, $Y_{z,d}^{(n)}$ 、 $\mu_{z,d}^{(n)}$ 和 $\sigma_{z,d}^{(n)}$ 分别为真实值、预测均值和预测标准差; ε_y 为保证数值稳定的正常数。式 (7-74) 的第二项根据预测方差对损失值进行调整, 使较难预测的目

标不会过度主导参数更新；第一项则对预测方差本身进行约束，防止网络仅通过增大方差降低残差项。

式 (7-74) 计算中间过程量和阶段目标两类预测的损失，其在维度数量和重要性上不同，因此在两类预测内取均值后再加权，得到输出拟合损失

$$\begin{aligned} \mathcal{L}_{\text{data}} = & \frac{w_{\text{pro}}}{N_t Z Q} \sum_{n=1}^{N_t} \sum_{z=1}^Z \sum_{d=1}^Q \ell_{z,d}^{(n)} \\ & + \frac{w_{\text{obj}}}{N_t Z K J} \sum_{n=1}^{N_t} \sum_{z=1}^Z \sum_{d=Q+1}^{D_y} \ell_{z,d}^{(n)}. \end{aligned} \quad (7-75)$$

式中， w_{pro} 和 w_{obj} 分别为中间过程量和阶段目标的损失权重。式 (7-75) 先对两类预测的损失分别取均值，以消除维度数对损失量级的影响，再通过两个权重参数调节其相对重要性调节其对网络参数更新的影响。

针对条件推断一致性，采用 KL 散度约束训练阶段潜变量分布与推理阶段潜变量分布的一致性。以 $\mathcal{D}_{\text{all}}$ 表示由已评估策略和待评估策略共同形成的联合条件信息，潜变量的 KL 约束写为：

$$\mathcal{L}_{\text{KL}} = D_{\text{KL}}[q_{\psi}(\boldsymbol{\xi} | \mathcal{D}_{\text{all}}) \| q_{\psi}(\boldsymbol{\xi} | \mathcal{D}_{\text{ctx}})]. \quad (7-76)$$

式中， $D_{\text{KL}}[\cdot \| \cdot]$ 为衡量两个概率分布差异的 KL 散度； $q_{\psi}(\boldsymbol{\xi} | \mathcal{D}_{\text{all}})$ 为训练阶段同时利用已评估策略和待评估策略信息形成的潜变量后验， $q_{\psi}(\boldsymbol{\xi} | \mathcal{D}_{\text{ctx}})$ 为仅由已评估策略形成的潜变量后验。式 (7-76) 旨在使信息较充分的训练阶段后验接近实际推理时能够获得的已评估策略后验，从而减小训练与推理之间的条件信息差异。

针对反向求解可行性，基于深度学习代理模型的反向求解需要将训练完成的网络逐层写成优化模型中的约束，其中 ReLU 函数可表示为 $y = \max\{0, x\}$ 。式中的 x 称为预激活值。由于反向求解在各策略变量上、下界构成的策略盒内搜索候选策略，同一神经元的 x 会随候选策略变化。将策略盒内所有可能策略输入网络后，该神经元可能取得的最小值和最大值分别记为 l 和 u ，由此形成预激活区间 $[l, u]$ 。若 $l \geq 0$ ，说明该神经元对策略盒内的所有候选策略均有 $x \geq 0$ ，ReLU 计算结果始终为正，因此可直接写成线性关系 $y = x$ ；若 $u \leq 0$ ，说明所有候选策略均有 $x \leq 0$ ，ReLU 计算结果始终为 0，因而可直接令 $y = 0$ 。只有当 $l < 0 < u$ 时，预激活区间才跨越 0，反向求解前无法确定应采用 $y = 0$ 还是 $y = x$ 。此时需要引入二元变量表示该 ReLU 函数^[195]，具有该特征的 ReLU 称为混合 ReLU。混合 ReLU 越多，反向求解需要同时判断的二元变量越多，计算规模也越大。因此，针对分区时序策略编码器中需要进入反向求解的 ReLU 单元设置盒稳定惩罚，促使更多预激活区间满足 $l \geq 0$ 或 $u \leq 0$ ，以减少混合 ReLU 数量。借鉴既有研究^[195–197]，首先计算各 ReLU 单元在策略区间内的预激活上下界，再根据区间与零点的相对位置构造盒稳定惩罚。

对批内第 n 个归一化策略 $\Theta^{(n)}$, 在各策略维度上构造半宽为 δ_{box} 的训练盒 $\mathcal{B}_\delta(\Theta^{(n)}) = [\Theta^{(n)} - \delta_{\text{box}}, \Theta^{(n)} + \delta_{\text{box}}] \cap [0, 1]$, 用于描述当前策略邻域内允许的策略变化。随后采用区间边界传播 (Interval Bound Propagation, IBP) 方法^[197], 从该策略盒出发逐层传播上下界, 得到全部策略所对应预激活值区间。具体而言, 设第 ℓ 层的线性变换为 $\hat{\mathbf{x}}^{(\ell)} = \mathbf{W}^{(\ell)} \mathbf{x}^{(\ell-1)} + \mathbf{b}^{(\ell)}$, 上一层输出的区间为 $[\mathbf{l}^{(\ell-1)}, \mathbf{u}^{(\ell-1)}]$, 则

$$\begin{aligned}\hat{\mathbf{l}}^{(\ell)} &= \mathbf{W}_+^{(\ell)} \mathbf{l}^{(\ell-1)} + \mathbf{W}_-^{(\ell)} \mathbf{u}^{(\ell-1)} + \mathbf{b}^{(\ell)}, \\ \hat{\mathbf{u}}^{(\ell)} &= \mathbf{W}_+^{(\ell)} \mathbf{u}^{(\ell-1)} + \mathbf{W}_-^{(\ell)} \mathbf{l}^{(\ell-1)} + \mathbf{b}^{(\ell)}.\end{aligned}\quad (7-77)$$

式中, $\mathbf{W}_+^{(\ell)} = \max\{\mathbf{W}^{(\ell)}, 0\}$ 与 $\mathbf{W}_-^{(\ell)} = \min\{\mathbf{W}^{(\ell)}, 0\}$ 分别为网络权重矩阵的非负部分和非正部分; $\hat{\mathbf{l}}^{(\ell)}$ 与 $\hat{\mathbf{u}}^{(\ell)}$ 为第 ℓ 层预激活的下界与上界。正权重与输入下界组合、负权重与输入上界组合得到输出下界 $\hat{\mathbf{l}}^{(\ell)}$, 反向组合得到输出上界 $\hat{\mathbf{u}}^{(\ell)}$, 从而保证式 (7-77) 覆盖局部策略盒内的全部可能取值。经过 $\rho(x) = \max\{0, x\}$ (ReLU 函数) 后, 输入给下一层的区间为 $\mathbf{l}^{(\ell)} = \rho(\hat{\mathbf{l}}^{(\ell)})$ 和 $\mathbf{u}^{(\ell)} = \rho(\hat{\mathbf{u}}^{(\ell)})$ 。

得到各层的预激活区间后, 为降低混合 ReLU 数量, 需将跨越零点的区间尽量移动至零点同侧。为此, 对目标批次中的各个训练盒构造盒稳定惩罚。同时, 为消除不同网络层预激活区间宽度的影响, 进一步以区间宽度进行归一化, 构造如下无量纲盒稳定惩罚:

$$\mathcal{P}_{\text{box}} = \frac{1}{N_t} \sum_{n=1}^{N_t} \frac{1}{|\mathcal{G}_\theta|} \sum_{g \in \mathcal{G}_\theta} \frac{1}{|\mathcal{V}_g|} \sum_{v \in \mathcal{V}_g} \frac{\min\{\rho(-\hat{l}_{n,g,v}), \rho(\hat{u}_{n,g,v})\}}{\max\{\hat{u}_{n,g,v} - \hat{l}_{n,g,v}, \epsilon_b\}}, \quad (7-78)$$

式中, $\mathcal{G}_\theta$ 为时序策略编码器中施加盒稳定惩罚的 ReLU 层集合; $\mathcal{V}_g$ 为层 g 的单元集合; $\hat{l}_{n,g,v}$ 和 $\hat{u}_{n,g,v}$ 分别为单元 v 中样本 n 的预激活下界与上界; ϵ_b 为防止区间宽度过小导致数值不稳定的正常数。式 (7-78) 中, $\min\{\rho(-\hat{l}_{n,g,v}), \rho(\hat{u}_{n,g,v})\}$ 仅在 $\hat{l}_{n,g,v} < 0 < \hat{u}_{n,g,v}$ 时为正, 表示将距离零点较近的区间端点移动至零点所需的位移。当预激活区间已经位于零点同侧时, 分子为零。

以上盒稳定惩罚仅施加于时序策略编码器的卷积层及其投影层, 因其直接接收策略输入, IBP 边界相对紧致。后续跨区交互编码器和共享分区解码器等模块的输入在经过多层特征混合后, 变量相关性较强, IBP 易产生过宽区间, 直接进行训练已导致模型表达能力损失较大。因此, 后两模块的预激活区间边界收紧在深度学习代理模型反向求解阶段处理。

综合式 (7-75)、式 (7-76) 和式 (7-78), 全模型的训练损失为

$$\mathcal{L} = \mathcal{L}_{\text{data}} + w_{\text{KL}} \mathcal{L}_{\text{KL}} + \lambda_{\text{box}}(e) \mathcal{P}_{\text{box}}, \quad (7-79)$$

式中, w_{KL} 为潜变量 KL 约束的权重; $\lambda_{\text{box}}(e)$ 为盒稳定惩罚在第 e 轮训练中的权重。

训练策略。一般而言, 深度学习模型需要大量样本进行拟合, 而仿真模型运行计算成本较高导致样本数量有限。若直接使用少量仿真样本进行训练, 网络难以

充分学习推广策略的跨阶段和跨分区关系。为此,针对深度学习代理模型的训练过程设计了三阶段策略,即首先利用解析代理生成的大量样本进行预训练,使网络学习基本的策略作用规律,其次利用高保真仿真样本进行微调,修正解析代理与仿真模型之间的偏差,最后利用策略寻优过程中新增的仿真样本持续更新模型。

首先,在策略空间内生成 N_{pre} 个具有代表性的策略样本,由7.3.2小节的解析代理批量计算分区中间量和逐阶段目标,构成

$$\mathcal{D}_{\text{pre}} = \{(\Theta^{(n)}, \mathbf{Y}_{\text{ana}}^{(n)})\}_{n=1}^{N_{\text{pre}}}, \quad \mathbf{Y}_{\text{ana},z}^{(n)} = [\mathbf{v}_{\text{ana},z}^{(n)}; \text{vec}(\mathbf{F}_{\text{ana},z,1:K}^{(n)})], \quad (7-80)$$

式中, $\mathbf{v}_{\text{ana},z}^{(n)} \in \mathbb{R}^Q$ 为解析代理给出的分区中间量; $\mathbf{F}_{\text{ana},z,1:K}^{(n)} \in \mathbb{R}^{K \times J}$ 为分区逐阶段目标。利用式(7-80)中得到的 $\mathcal{D}_{\text{pre}}$ 作为训练集对深度学习模型进行预训练,使网络在使用高成本仿真样本训练前,先学习不同策略变量的基本作用和预测目标的关联关系等,进而为后续微调和策略寻优建立具有机理意义的初始映射。

其次,利用少量仿真模型输出的结果对模型进行校正。对 N_{sim} 个已评估策略,计算中间量作为辅助标签与逐阶段目标,得到

$$\mathbf{Y}_{\text{ft},z}^{(n)} = [\mathbf{v}_{\text{ABM},z}^{(n)}; \text{vec}(\mathbf{F}_{\text{ABM},z,1:K}^{(n)})], \quad n = 1, \dots, N_{\text{sim}}. \quad (7-81)$$

式中, $\mathbf{v}_{\text{ABM},z}^{(n)} \in \mathbb{R}^Q$ 为仿真模型给出的分区中间量; $\mathbf{F}_{\text{ABM},z,1:K}^{(n)} \in \mathbb{R}^{K \times J}$ 为分区逐阶段目标。将式(7-81)中得到的 $\mathcal{D}_{\text{ft}} = \{(\Theta^{(n)}, \mathbf{Y}_{\text{ft}}^{(n)})\}_{n=1}^{N_{\text{sim}}}$ 作为微调集对深度学习模型进行微调,使网络输出适应仿真模型的量级和偏差。

最后,进入优化循环后,第 r 轮新增仿真样本按 $\mathcal{D}_{\text{ctx}}^{(r+1)} = \mathcal{D}_{\text{ctx}}^{(r)} \cup \{(\Theta^{(r+1)}, \mathbf{Y}^{(r+1)})\}$ 并入已评估策略集合。随后,利用已有的仿真样本对共享分区解码器进行微调,使网络逐步学习多轮仿真中反复出现的预测偏差。

(3) 反向求解。推广策略寻优需要对深度学习代理模型进行反向求解,即将推广策略作为决策变量,在给定可行域 $\mathcal{B}$ 内寻找目标最优的策略。受 ReLU 神经网络既有研究的启发^[195,198],本节在待评估策略处构造深度学习代理模型的分段线性形式,并将其重新表示为混合整数规划(Mixed-Integer Programming, MIP)问题,以求解可行域内的最优候选策略。

既有研究中的标准 MIP 编码主要处理深度学习网络中线性变换层与 ReLU 函数之间的组合,而本章设计的深度学习代理模型还包含一维卷积、外生变量输入、基于已评估策略的条件推断、softmax 注意力、层归一化、潜变量、Dropout 及异方差输出等组成部分。因此,将其转化为 MIP 还需事先区分随候选策略变化的外生变量与固定信息,将卷积运算和目标计算等改写为线性变换约束,以及对 softmax 注意力与层归一化作局部近似处理。在完成以上处理后,再对保留下来的 ReLU 函数进行精确编码。

在介绍针对深度学习代理模型的相关处理前, 首先定义 $\mathcal{B}_n$ 为策略盒 $\mathcal{B}$ 经逐维归一化后在网络输入空间中的对应区域, Θ_c 为策略盒中心 θ_c 的归一化输入。后续 MIP 均以 $\Theta \in \mathcal{B}_n$ 作为决策变量。

策略变量与固定信息的区分。 反向求解仅改变待预测策略 Θ , 网络权重在整个求解过程中保持不变。此外, 一轮策略寻优所采用的外生变量和已评估样本集 $\mathcal{D}_{\text{ctx}}$ 同样保持不变。因此, 外生变量编码器输出 $\mathbf{c}_g$ 与 $\{\mathbf{c}_z\}_{z=1}^Z$ 、分区嵌入 $\{\mathbf{e}_z\}_{z=1}^Z$ 、已评估策略表征 $\{\mathbf{r}_n\}_{n=1}^{M_c}$ 以及潜变量后验均值, 均可在求解前通过一次前向计算确定。

线性变换运算的等价表示。 分区时序策略编码器中的一维卷积、网络中的输入归一化、全连接层、残差相加和城市级目标聚合均为线性变换运算, 可直接写成线性等式约束。将分区、分阶段的策略展平后, 第 ℓ 层卷积的预激活可写为

$$\text{vec}(\hat{\mathbf{Z}}_z^{(\ell)}) = \bar{\mathbf{W}}_c^{(\ell)} \text{vec}(\mathbf{Z}_z^{(\ell-1)}) + \bar{\mathbf{b}}_c^{(\ell)}, \quad (7-82)$$

式中, $\hat{\mathbf{Z}}_z^{(\ell)}$ 为分区 z 在第 ℓ 层卷积后、进入 ReLU 函数前的预激活张量; $\bar{\mathbf{W}}_c^{(\ell)}$ 为展开后得到的卷积矩阵; $\bar{\mathbf{b}}_c^{(\ell)}$ 为对应的偏置向量。

共享分区解码器的输入包含随策略变化的分区策略表征 $\tilde{\mathbf{h}}_z$ 和模型中的固定信息。以解码器第一层为例, 可将其写为

$$\hat{\mathbf{x}}_z^{(1)} = \mathbf{W}_h \tilde{\mathbf{h}}_z + \mathbf{W}_e \mathbf{e}_z + \mathbf{W}_c \mathbf{c}_z + \mathbf{W}_r \mathbf{r}_* + \mathbf{W}_\xi \boldsymbol{\xi} + \mathbf{b}, \quad (7-83)$$

式中, $\mathbf{W}_h$ 、 $\mathbf{W}_e$ 、 $\mathbf{W}_c$ 、 $\mathbf{W}_r$ 和 $\mathbf{W}_\xi$ 分别为第一层权重矩阵中与各输入对应的权重。由此, 仅 $\tilde{\mathbf{h}}_z$ 会在反向寻优过程中随策略变化, 需进行计算。此外, 式 (7-73) 中的人口加权和分区求和也均为线性组合, 可在解码器输出后原样加入 MIP。

注意力与层归一化的局部处理。 跨区交互编码器的注意力权重由查询向量与键向量的内积经过 softmax 后计算得到。此外, 层归一化也包含均值、方差、平方根和除法。以上运算既不是线性函数, 也不是有限段的分段线性函数, 若将其随策略变化的完整关系直接保留, 所得模型将不再是标准 MIP。考虑到后续优化在以 Θ_c 为中心的信赖域内进行, 因此在中心策略处计算式 (7-67) 的注意力权重 $\alpha_{zz'}^{(m)}(\Theta_c)$, 并固定式 (7-68) 中各分区的层归一化均值与方差。冻结注意力权重后, 值向量仍随 $\mathbf{h}_z$ 作线性变化。综上, 跨区注意力、残差连接和层归一化可合并为

$$\tilde{\mathbf{h}}_{\text{flat}} = \mathbf{A}_c \mathbf{h}_{\text{flat}} + \mathbf{b}_c, \quad \mathbf{h}_{\text{flat}} = [\mathbf{h}_1; \dots; \mathbf{h}_Z], \quad \mathbf{A}_c \in \mathbb{R}^{ZD_h \times ZD_h}, \quad (7-84)$$

式中, $\mathbf{h}_{\text{flat}}$ 和 $\tilde{\mathbf{h}}_{\text{flat}}$ 分别为跨区交互前后全部分区表征的拼接向量; $\mathbf{A}_c$ 和 $\mathbf{b}_c$ 由中心注意力权重、值投影、输出投影、残差项及冻结后的层归一化共同合成。式 (7-84) 在中心 Θ_c 处与原跨区交互编码器完全一致, 在信赖域内则构成其线性变换近似。因此, 需对信赖域大小进行限制, 以保证所构建 MIP 问题求解策略的准确性。

基于观测样本的条件推断模块包含待评估策略对已评估策略的交叉注意力。该模块的键和值仅由固定的 $\mathcal{D}_{\text{ctx}}$ 产生，将交叉注意力的 softmax 权重固定为其在 Θ_c 处的取值后，式 (7-70) 中的已评估策略表征 $\mathbf{r}_*$ 也成为常量，因此不影响 MIP 问题的构建。

ReLU 函数及其激活边界处理。按照前文盒稳定惩罚部分的定义，前文所述的混合 ReLU，需要引入二元变量 $\zeta \in \{0, 1\}$ ，并采用三角 big-M 约束进行精确编码^[195]：

$$y \geq 0, \quad y \geq x, \quad y \leq x - l(1 - \zeta), \quad y \leq u\zeta. \quad (7-85)$$

式中， x 为 ReLU 的预激活值， y 为 ReLU 输出值， $[l, u]$ 为预激活区间。当 $\zeta = 0$ 时，式 (7-85) 要求 $y = 0$ 且 $x \leq 0$ ；当 $\zeta = 1$ 时，要求 $y = x$ 且 $x \geq 0$ 。因此，只要 l 和 u 确实覆盖可行域内的全部预激活取值，该组约束便与原 ReLU 函数等价。

预激活边界既用于判断是否需要二元变量，也直接决定式 (7-85) 的松弛程度。若计算得到的 $[l, u]$ 相对真实区间过宽，原本始终为正或始终为负的单元也可能被误判为混合 ReLU，从而引入不必要的二元变量。对于确实跨越零点的单元，过大的 $|l|$ 与 u 还会削弱 MIP 的线性松弛，使分支定界过程变慢。因此，MIP 编码时仍需针对实际可行域 $\mathcal{B}_n$ 重新计算并收紧每个 ReLU 单元的有效边界。为此，本章依次采用区间边界传播 (Interval Bound Propagation, IBP)^[197]、基于线性规划的渐进式边界收紧 (Linear Programming-based Progressive Bounds Tightening, LP-PBT)^[195] 和 CROWN 框架下的反向线性界传播 (Backward CROWN Linear Bound Propagation, 反向 CROWN)^[199] 三种方法，收紧 ReLU 单元的预激活区间。

首先采用 IBP 计算全部 ReLU 单元的初始边界，该过程可较快得到覆盖全部候选策略的有效区间，但所得上下界是对真实最小值和最大值的保守估计，其原因可以通过区间宽度说明。记第 $\ell - 1$ 层输出区间的宽度为 $\mathbf{w}^{(\ell-1)} = \mathbf{u}^{(\ell-1)} - \mathbf{l}^{(\ell-1)}$ ，可得第 ℓ 层预激活区间的宽度：

$$\hat{\mathbf{w}}^{(\ell)} = \left(\mathbf{W}_+^{(\ell)} - \mathbf{W}_-^{(\ell)} \right) \mathbf{w}^{(\ell-1)} = |\mathbf{W}^{(\ell)}| \mathbf{w}^{(\ell-1)}. \quad (7-86)$$

式中， $\hat{\mathbf{w}}^{(\ell)} = \hat{\mathbf{u}}^{(\ell)} - \hat{\mathbf{l}}^{(\ell)}$ 为第 ℓ 层预激活区间的宽度； $|\mathbf{W}^{(\ell)}|$ 表示对权重矩阵逐元素取绝对值。式 (7-86) 表明，IBP 会把上一层各单元视为独立单元，允许这些单元同时取得各自最不利的端点。然而，多个特征往往由同一组策略变量共同决定，通常不能彼此独立地同时达到各自的上界或下界。因此，IBP 计算的区间可能宽于各单元的真实取值范围。

对 IBP 判定为混合的 ReLU 单元，采用 LP-PBT 将策略输入、各层线性变换以及 ReLU 输入与输出之间的关系同时纳入线性规划，从而进一步收紧其预激活区间边界。

设上游混合 ReLU 单元 p 的预激活值为 $\hat{x}_p$, 经过 ReLU 后的输出为 $x_p = \rho(\hat{x}_p)$, 其当前边界满足 $l_p < 0 < u_p$ 。该 ReLU 的真实输入—输出关系由 $x_p = 0$ 和 $x_p = \hat{x}_p$ 两段线段构成。若对其进行精确表示, 需要像式 (7-85) 一样引入二元变量。为了在边界计算阶段避免增加整数变量, LP-PBT 采用以下三条线性不等式构造包围 ReLU 真实输出范围的三角形区域:

$$\begin{aligned} x_p &\geq 0, \\ x_p &\geq \hat{x}_p, \\ x_p &\leq \frac{u_p(\hat{x}_p - l_p)}{u_p - l_p}. \end{aligned} \quad (7-87)$$

式中, 第一条不等式表示 ReLU 输出不小于 0; 第二条表示 ReLU 输出不小于其输入; 第三条对应连接 $(l_p, 0)$ 与 (u_p, u_p) 的直线, 用于限定输出的上界。三条不等式共同构成 ReLU 在区间 $[l_p, u_p]$ 上的三角形外包区域。该区域包含全部可能的 ReLU 输入—输出组合, 同时也允许少量不满足 $x_p = \rho(\hat{x}_p)$ 的附加组合, 因此能够在不使用二元变量的情况下将 ReLU 近似为线性约束。

在此基础上, 将策略盒、由输入层至第 ℓ 层的线性变换等式以及全部上游混合 ReLU 的三角形约束共同组成线性规划, 并分别最小化和最大化待收紧单元 v 的预激活值:

$$\begin{aligned} l_v^{\text{LP}} &= \min_{\Theta, \mathbf{x}} \hat{x}_v^{(\ell)}, \\ u_v^{\text{LP}} &= \max_{\Theta, \mathbf{x}} \hat{x}_v^{(\ell)}, \\ \text{s.t. } x_p &\geq 0, \quad x_p \geq \hat{x}_p, \quad x_p \leq \frac{u_p(\hat{x}_p - l_p)}{u_p - l_p}, \quad l_p < 0 < u_p, \\ &\text{第 } 1, \dots, \ell \text{ 层的线性变换约束,} \\ &\Theta \in \mathcal{B}_n. \end{aligned} \quad (7-88)$$

式中, $\hat{x}_v^{(\ell)}$ 为第 ℓ 层待收紧单元 v 的预激活值; l_v^{LP} 和 u_v^{LP} 分别为线性规划得到的预激活下界和上界; $\mathbf{x}$ 表示由输入层至第 ℓ 层涉及的全部中间变量。由于三角形区域完整包含 ReLU 的全部输出范围, 原网络在策略盒内产生的所有取值均满足上述线性规划约束。因此, l_v^{LP} 不会高于真实最小值, u_v^{LP} 不会低于真实最大值, 二者仍然构成覆盖真实取值范围的有效边界。当前层获得的新边界继续用于构造下一层的 ReLU 三角形约束, 故称为渐进式边界收紧。此外, 由于线性规划保留了不同神经元之间的连接关系, 能够排除 IBP 中部分不可能同时出现的上下界组合, 因而所得区间通常更紧。

对于跨区交互编码器之后的解码器单元, 采用 LP-PBT 对这些深层单元逐一收紧又会带来较大的计算开销。为此, 采用反向 CROWN 计算解码器 ReLU 的预激活边界, 是从待收紧单元出发, 依次反向穿过解码器、跨区交互编码器及上游混

合 ReLU，最终将目标单元的预激活表示为原始策略输入的线性上下界。

$$\mathbf{a}_L^\top \text{vec}(\Theta) + c_L \leq \hat{x}_v(\Theta) \leq \mathbf{a}_U^\top \text{vec}(\Theta) + c_U, \quad \forall \Theta \in \mathcal{B}_n. \quad (7-89)$$

式中， $\hat{x}_v(\Theta)$ 为待收紧单元 v 在策略盒 $\mathcal{B}_n$ 下的预激活值； $\mathbf{a}_L$ 与 c_L 为线性下界的系数向量和常数项， $\mathbf{a}_U$ 与 c_U 为线性上界的系数向量和常数项。反向 CROWN 体现在，从待收紧的目标 ReLU 单元出发，将其线性界逐层代回前一层，直至最终写成原始策略输入的函数。若当前线性界为 $\mathbf{a}_\ell^\top \mathbf{x}^{(\ell)} + c_\ell$ ，将线性变换层 $\mathbf{x}^{(\ell)} = \mathbf{W}^{(\ell)} \mathbf{x}^{(\ell-1)} + \mathbf{b}^{(\ell)}$ 代入后，有

$$\mathbf{a}_{\ell-1} = (\mathbf{W}^{(\ell)})^\top \mathbf{a}_\ell, \quad c_{\ell-1} = c_\ell + \mathbf{a}_\ell^\top \mathbf{b}^{(\ell)}. \quad (7-90)$$

式中， $\mathbf{a}_{\ell-1}$ 为回代至第 $\ell-1$ 层后得到的系数向量； $c_{\ell-1}$ 为相应的常数项。

当反向代入过程遇到混合 ReLU 时，无法继续使用一个精确的线性等式。为此，在其有效区间 $[l_p, u_p]$ 上分别构造一条线性下界和一条线性上界：

$$\beta_p \hat{x}_p \leq \rho(\hat{x}_p) \leq \frac{u_p}{u_p - l_p} (\hat{x}_p - l_p), \quad \beta_p \in [0, 1], \quad (7-91)$$

式中，右侧直线连接 $(l_p, 0)$ 与 (u_p, u_p) ，在整个区间内位于 ReLU 输出的上方；左侧直线的斜率 $\beta_p \in [0, 1]$ ，在整个区间内位于 ReLU 图像下方。记反向代入至该层时，混合 ReLU 单元 p 的输出在当前目标线性界中的对应项为 $a_p \rho(\hat{x}_p)$ ，其中 a_p 为反向传播至该单元时得到的系数。若构造目标上界，当 $a_p \geq 0$ 时，由 $a_p \rho(\hat{x}_p) \leq a_p U_p(\hat{x}_p)$ 可知应代入上界 $\frac{u_p}{u_p - l_p} (\hat{x}_p - l_p)$ 构造目标上界；当 $a_p < 0$ 时，不等号方向随负系数相乘而改变，由 $a_p \rho(\hat{x}_p) \leq a_p L_p(\hat{x}_p)$ 可知应代入下界 $\beta_p \hat{x}_p$ 构造目标上界。构造目标下界时采用相反的选择，即正系数对应 ReLU 下界，负系数对应 ReLU 上界。按照上述规则逐层代回，便可在始终保持上下界有效性的条件下，将目标单元的预激活最终表示为式 (7-89) 所示的原始策略输入的线性函数。

在线性界已经写成 Θ 的函数后，其在可行域内的最大值可以直接计算。系数为正的策略维度取上界，系数为负的策略维度取下界。因此，目标单元的 CROWN 上界为

$$u_v^{\text{CROWN}} = \mathbf{a}_{U+}^\top \text{vec}(\bar{\Theta}_{\mathcal{B}_n}) + \mathbf{a}_{U-}^\top \text{vec}(\underline{\Theta}_{\mathcal{B}_n}) + c_U, \quad (7-92)$$

式中， $\underline{\Theta}_{\mathcal{B}_n}$ 和 $\bar{\Theta}_{\mathcal{B}_n}$ 分别为归一化策略盒的下界和上界； $\mathbf{a}_{U+} = \max\{\mathbf{a}_U, 0\}$ 与 $\mathbf{a}_{U-} = \min\{\mathbf{a}_U, 0\}$ 分别为上界系数向量的非负部分和非正部分。目标单元的 CROWN 下界同理，只需使正系数对应策略下界、负系数对应策略上界。

以上，三种方法得到多种有效边界，可对其取交集：

$$\begin{aligned} l_v &\leftarrow \max\{l_v^{\text{IBP}}, l_v^{\text{LP}}, l_v^{\text{CROWN}}\}, \\ u_v &\leftarrow \min\{u_v^{\text{IBP}}, u_v^{\text{LP}}, u_v^{\text{CROWN}}\}. \end{aligned} \quad (7-93)$$

式中, 未用于单元 v 的边界方法不参与相应的最大值或最小值计算。所得区间一方面用于判断 ReLU 始终为正、始终为负或为混合 ReLU, 另一方面作为式 (7-85) 中的 l 和 u 。

完成上述处理后, 对给定的目标标量化系数 $\mathbf{a}$, 深度学习代理的局部反向求解可统一写为

$$\begin{aligned}
 \min_{\Theta, \mathbf{x}, \zeta} \quad & \mathbf{a}^\top \boldsymbol{\mu}^{\text{obj}} \\
 \text{s.t.} \quad & \hat{\mathbf{x}}^{(\ell)} = \mathbf{W}^{(\ell)} \mathbf{x}^{(\ell-1)} + \mathbf{b}^{(\ell)}, \quad \ell = 1, \dots, L, \\
 & x_v^{(\ell)} = \hat{x}_v^{(\ell)} \quad (l_v \geq 0), \quad x_v^{(\ell)} = 0 \quad (u_v \leq 0), \\
 & x_v^{(\ell)} \text{ 按式 (7-85) 编码} \quad (l_v < 0 < u_v), \\
 & \boldsymbol{\mu}^{\text{obj}} = \mathbf{W}^{\text{out}} \mathbf{x}^{(L)} + \mathbf{b}^{\text{out}}, \\
 & \mathbf{x}^{(0)} = \text{vec}(\Theta), \quad \Theta \in \mathcal{B}_n, \quad \zeta \in \{0, 1\}^{n_{\text{mix}}}.
 \end{aligned} \tag{7-94}$$

式中, $\mathbf{x}$ 和 $\hat{\mathbf{x}}$ 分别表示各层 ReLU 输出与预激活变量; $\{(\mathbf{W}^{(\ell)}, \mathbf{b}^{(\ell)})\}_{\ell=1}^L$ 包含卷积展开、跨区线性映射及共享解码器中的线性层; $\mathbf{W}^{\text{out}}$ 与 $\mathbf{b}^{\text{out}}$ 合并表示解码器均值输出层和式 (7-73) 中的城市级线性聚合; $\boldsymbol{\mu}^{\text{obj}}$ 为进入优化目标的城市级预测均值; $\mathbf{a}$ 由目标权重和尺度系数组成; ζ 为全部混合 ReLU 对应的二元变量, n_{mix} 为其数量。由式 (7-94) 可见, 反向求解的整数规模主要由混合 ReLU 数量决定, 而不是由网络全部参数的数量决定。

7.4 基于信赖域机制的多目标优化算法

为在有限仿真预算下利用代理模型的预测与评估能力, 本节构建基于信赖域机制的多目标优化算法。

7.4.1 算法设定

本章提出的基于信赖域机制的多目标优化算法源于无导数信赖域方法。经典无导数信赖域方法在当前迭代点 $\mathbf{x}_r$ 附近构建局部模型 m_r , 在半径为 Δ_r 的邻域内求解局部模型得到试探步 $\mathbf{s}_r$, 再以计算昂贵目标函数的实际改善与局部模型的预测改善之比判断模型在该邻域内是否可信, 求解过程可表示为:

$$\begin{aligned}
 \mathbf{s}_r & \in \arg \min_{\mathbf{s}} m_r(\mathbf{x}_r + \mathbf{s}), \\
 \text{s.t.} \quad & \|\mathbf{s}\|_p \leq \Delta_r, \quad \mathbf{x}_r + \mathbf{s} \in \Omega, \\
 & \mathbf{x}_r^{\text{trial}} = \mathbf{x}_r + \mathbf{s}_r,
 \end{aligned} \tag{7-95}$$

式中, $\mathbf{x}_r$ 为第 r 轮开始时的当前可行解; $\mathbf{s}$ 为相对于当前解 $\mathbf{x}_r$ 的任一候选步; Δ_r 为第 r 轮的信赖域半径; Ω 为决策向量的可行域; $\|\cdot\|_p$ 表示相应的 p 范数; $\mathbf{s}_r$ 为使局部模型取值最小的候选步; $\mathbf{x}_r^{\text{trial}}$ 为沿 $\mathbf{s}_r$ 移动后得到的试探点。由于直接在邻域内反复计算目标函数 $f(\mathbf{x})$ 的成本较高, 无导数信赖域方法以局部模型 $m_r(\mathbf{x})$ 近似 $f(\mathbf{x})$ 在 $\mathbf{x}_r$ 附近的变化。

得到 $\mathbf{x}_r^{\text{trial}}$ 后, 再分别由局部模型计算预测改善, 并调用一次昂贵目标函数计算实际改善; 当 $\Delta_r^{\text{pred}} > 0$ 时, 信赖域改善比定义为

$$\Delta_r^{\text{pred}} = m_r(\mathbf{x}_r) - m_r(\mathbf{x}_r^{\text{trial}}), \quad \Delta_r^{\text{act}} = f(\mathbf{x}_r) - f(\mathbf{x}_r^{\text{trial}}), \quad \rho_r = \frac{\Delta_r^{\text{act}}}{\Delta_r^{\text{pred}}}, \quad (7-96)$$

式中, Δ_r^{pred} 为局部模型预测的目标下降量; Δ_r^{act} 为实际调用 $f(\mathbf{x})$ 后观测到的目标下降量; ρ_r 为二者之比, 称为信赖域改善比, 用于衡量局部模型对目标变化方向 and 变化幅度的预测与实际评估结果是否一致。当 ρ_r 接近 1 时, 说明局部模型对目标改善幅度的预测较为准确; 当 ρ_r 接近 0 或小于 0 时, 说明实际改善明显低于预测改善, 甚至出现预测改善符号相反的情况。结合信赖域改善比, 典型的试探点接受与半径更新规则可写为:

$$\begin{aligned} \mathbf{x}_{r+1} &= \begin{cases} \mathbf{x}_r^{\text{trial}}, & \rho_r \geq \eta_1, \\ \mathbf{x}_r, & \rho_r < \eta_1, \end{cases} \\ \Delta_{r+1} &= \begin{cases} \gamma_{\text{dec}}\Delta_r, & \rho_r < \eta_1, \\ \min\{\gamma_{\text{inc}}\Delta_r, \Delta_{\text{max}}\}, & \rho_r > \eta_2, \|\mathbf{s}_r\|_p \geq \tau\Delta_r, \\ \Delta_r, & \text{其他情形,} \end{cases} \end{aligned} \quad (7-97)$$

式中, $0 \leq \eta_1 < \eta_2 < 1$ 分别为试探点接受阈值和信赖域扩张阈值; $0 < \gamma_{\text{dec}} < 1$ 与 $\gamma_{\text{inc}} > 1$ 分别为半径收缩系数和扩张系数; Δ_{max} 为允许的最大信赖域半径; $\tau \in (0, 1]$ 用于判断试探步是否接近当前信赖域边界。由此, 当实际改善与预测改善不一致时, 算法拒绝试探点并缩小信赖域; 当二者较为一致且最优试探步已接近信赖域边界时, 算法接受试探点并扩大下一轮的搜索范围; 其余情形则接受试探点或维持当前中心, 并保持信赖域半径不变。

本文保留了标准无导数信赖域算法的基本逻辑, 但针对 MaaS 推广策略优化问题进行了扩展。首先, 标准形式针对单个标量目标维护一个信赖域, 本文同时优化用户采纳率、平台净收入与碳减排, 因此将三项目标按不同偏好标量化, 并设置三个共享仿真样本和 Pareto 解集的信赖域。具体而言, 针对本章提出的两种代理模型, 记 $q \in \{\text{H}, \text{DL}\}$ 为代理模型类型, 其中 H 表示式 (7-47) 所示的混合解析代理, DL 表示 7.3.3 小节所示的深度学习代理。代理模型 q 在第 r 轮利用已有仿真样

本得到的三目标预测统一记为

$$\hat{\mathbf{F}}_r^{(q)}(\boldsymbol{\theta}) = \left[\hat{F}_{r,1}^{(q)}(\boldsymbol{\theta}), \hat{F}_{r,2}^{(q)}(\boldsymbol{\theta}), \hat{F}_{r,3}^{(q)}(\boldsymbol{\theta}) \right]^\top. \quad (7-98)$$

针对第 m 个目标偏好方向, 定义归一化加权和标量化函数为

$$\begin{aligned} g_m(\mathbf{y}) &= \sum_{j=1}^3 w_j^{(m)} \frac{y_j}{s_j}, \quad m = 1, 2, 3, \\ \hat{g}_{r,m}^{(q)}(\boldsymbol{\theta}) &= g_m\left(\hat{\mathbf{F}}_r^{(q)}(\boldsymbol{\theta})\right), \quad \bar{g}_m(\boldsymbol{\theta}) = g_m(\bar{\mathbf{F}}(\boldsymbol{\theta})), \end{aligned} \quad (7-99)$$

式中, $\mathbf{y}$ 为任一最小化形式的三目标向量; s_j 为目标 j 的标准差, 用以消去不同目标量纲的影响; $\hat{g}_{r,m}^{(q)}$ 为代理模型给出的标量化目标; $\bar{g}_m$ 为仿真模型给出的标量化目标。三个信赖域采用的权重矩阵为

$$\mathbf{W} = \begin{bmatrix} 0.98 & 0.01 & 0.01 \\ 0.01 & 0.98 & 0.01 \\ 0.01 & 0.01 & 0.98 \end{bmatrix}, \quad \mathbf{w}^{(m)} = \mathbf{W}[m, :]. \quad (7-100)$$

式中, 三行权重分别偏好用户采纳率、平台净收入与碳减排。需要说明的是, 三个固定权重也只代表三个主要偏好方向, 在实际应用中, 可根据偏好调整权重矩阵 $\mathbf{W}$, 以获得不同的 Pareto 解集。

针对信赖域设置, 第 r 轮第 m 个信赖域以中心 $\mathbf{c}_{r,m}$ 和归一化边长 $\ell_{r,m}$ 表示。将推广策略按展平为 D 维向量后, 该信赖域定义为

$$\begin{aligned} \mathcal{B}_{r,m} &= \left\{ \boldsymbol{\theta} \in \Theta : \left| \frac{\theta_d - c_{r,m,d}}{\theta_d^{\text{up}} - \theta_d^{\text{lo}}} \right| \leq \frac{\ell_{r,m}}{2}, \quad d = 1, \dots, D \right\}, \\ \underline{\theta}_{r,m,d} &= \max \left\{ \theta_d^{\text{lo}}, c_{r,m,d} - \frac{\ell_{r,m}}{2} (\theta_d^{\text{up}} - \theta_d^{\text{lo}}) \right\}, \\ \bar{\theta}_{r,m,d} &= \min \left\{ \theta_d^{\text{up}}, c_{r,m,d} + \frac{\ell_{r,m}}{2} (\theta_d^{\text{up}} - \theta_d^{\text{lo}}) \right\}. \end{aligned} \quad (7-101)$$

式中, θ_d^{lo} 与 θ_d^{up} 为第 d 维策略的全局下界与上界; $\underline{\theta}_{r,m,d}$ 与 $\bar{\theta}_{r,m,d}$ 为该信赖域经全局策略空间 Θ 截断后的实际边界。由式 (7-101) 可知, 将各维策略按其全局范围归一化后, $\mathcal{B}_{r,m}$ 是以 $\mathbf{c}_{r,m}$ 为中心、边长为 $\ell_{r,m}$ 的轴对齐超立方体, 又称 L_∞ 盒。此外, 采用的盒形区域可直接转化为 L-BFGS-B 的变量边界或式 (7-94) 中策略变量的上下界, 有利于反向求解计算。

式 (7-101) 表示的各信赖域分别维护中心、边长等参数, 三个信赖域在每轮内依次运行, 使先执行信赖域产生的新仿真样本能够进入后续的数据更新过程。信赖域边长限制在 $\ell_{\min}$ 与 $\ell_{\max}$ 之间, 两类代理对比时采用相同的边长设置, 以保持搜索范围一致。

7.4.2 算法运行流程

算法分为初始化与信赖域迭代两个阶段。初始化阶段在全局策略空间 Θ 内生成 N_A 个拉丁超立方样本，并逐一调用仿真模型获得三项目标及分区、阶段过程量，形成初始已评估策略集：

$$\mathcal{D}_0 = \{(\theta^{(n)}, \bar{F}(\theta^{(n)}))\}_{n=1}^{N_A}, \quad \mathcal{P}_0 = \text{ND}(\mathcal{D}_0), \quad (7-102)$$

式中， $\text{ND}(\cdot)$ 表示从已评估样本中提取非支配解； $\mathcal{P}_0$ 为初始 Pareto 解集。随后，根据 $\mathcal{D}_0$ 中城市级三项目标的样本标准差确定尺度向量 $\mathbf{s} = [s_1, s_2, s_3]^\top$ ，并将其代入式 (7-99)；同时，以初始化仿真样本中目标 m 取值最优的策略作为第 m 个信赖域的初始中心。若采用混合解析代理，则以仿真输出与解析递推输出之差拟合三项目标的 GP 残差模型；若采用深度学习代理，则利用解析先验完成预训练，再以初始仿真样本训练模型并构造条件推断模块的已评估策略集合。

信赖域迭代阶段包含候选策略生成、仿真模型评估、信赖域更新、和代理更新四个相互衔接的环节。候选策略生成环节，在第 r 轮第 m 个信赖域内调用与代理类型 q 对应的反向求解算法 $\mathcal{R}_q$ ，求解

$$\theta_{r,m}^{\text{cand}} = \mathcal{R}_q(\hat{\mathbf{F}}_r^{(q)}, \mathcal{B}_{r,m}, \mathbf{w}^{(m)}, \mathbf{s}) \quad (7-103)$$

式中， $\theta_{r,m}^{\text{cand}}$ 为候选策略。得到候选策略后，调用仿真模型计算其实际目标 $\bar{\mathbf{F}}_{r,m}^{\text{cand}}$ ，并将其加入已评估样本集与 Pareto 解集。结合当前信赖域中心 $\mathbf{c}_{r,m}$ 和候选策略 $\theta_{r,m}^{\text{cand}}$ ，计算代理预测改善与仿真实际改善幅度：

$$\begin{aligned} \Delta_{r,m}^{\text{pred}} &= \hat{g}_{r,m}^{(q)}(\mathbf{c}_{r,m}) - \hat{g}_{r,m}^{(q)}(\theta_{r,m}^{\text{cand}}), \\ \Delta_{r,m}^{\text{act}} &= \bar{g}_m(\mathbf{c}_{r,m}) - \bar{g}_m(\theta_{r,m}^{\text{cand}}). \end{aligned} \quad (7-104)$$

式中， $\hat{g}_{r,m}^{(q)}(\mathbf{c}_{r,m})$ 与 $\bar{g}_m(\mathbf{c}_{r,m})$ 分别为代理模型对当前中心的标量化目标的预测值和仿真模型对该中心的标量化评估值。 $\Delta_{r,m}^{\text{pred}}$ 表示代理模型预测的信赖域中心至候选策略的目标下降量， $\Delta_{r,m}^{\text{act}}$ 表示仿真模型在同一对策略之间给出的实际下降量。

在计算代理模型和仿真模型分别给出的改善幅度后，下一步是计算信赖域改善比 $\rho_{r,m}$ 。按照标准信赖域方法的试探点接受原则，改善比不低于接受阈值 η_1 时，接受候选策略并将信赖域中心移动至该点；改善比低于 η_1 或处于不可判状态时，保留原中心。当某一信赖域已收缩至 $\ell_{\min}$ ，且连续 N_{stall} 轮未接受新的中心时，算法判定其在当前区域停滞，则从全部已评估样本中选择新的中心。中心选择首先按该信赖域的标量化目标从优到劣检查历史策略，取第一个与当前中心的归一化 L_∞ 距离超过 $0.50\ell_{\min}$ 、且不位于其他信赖域当前策略盒内的策略；若不存在满足条件

的历史策略，则从 Pareto 档案中选择到全部信赖域中心的最小距离最大的策略：

$$\mathbf{c}_{r,m}^{\text{restart}} = \arg \max_{\boldsymbol{\theta} \in \mathcal{P}_r} \min_{m'=1,2,3} \left\| \tilde{\boldsymbol{\theta}} - \tilde{\mathbf{c}}_{r,m'} \right\|_{\infty}, \quad (7-105)$$

式中， $\tilde{\boldsymbol{\theta}}$ 与 $\tilde{\mathbf{c}}_{r,m'}$ 表示按全局策略上下界归一化后的策略与信赖域中心。重启后，将边长恢复至 $\ell_{\max}$ 。该机制优先利用寻优过程中效果较好的策略，同时在必要时将信赖域迁移至距离现有搜索区域较远的 Pareto 解附近，以避免三个信赖域长期重叠或停留在同一局部区域。

每轮获得的新仿真样本均用于更新代理，但两类代理的更新方式不同。对于混合解析代理，重新计算新样本相对于解析递推的三项目标残差，并利用截至当前轮次的已评估样本更新三个 GP 残差模型；对于深度学习代理，新样本首先直接加入条件推断模块的已评估策略集合，使后续候选预测能够立即利用新增信息，随后在每轮开始时以较小学习率仅微调共享解码器，并混入离线训练样本以减轻对信赖域局部样本的过拟合。卷积编码器与跨区注意力参数保持冻结，以维持 ReLU 边界缓存和局部混合整数规划编码的有效性。三个信赖域在同一轮内依次执行，并在轮末以更新后的共享 Pareto 解集计算超体积，从而记录有限仿真预算下非支配解集的改进过程。

上述两阶段流程汇总于算法 2。

算法 2：基于信赖域机制的多目标优化算法流程

Require: 全局策略空间 Θ , 仿真模型, 代理类型 $q \in \{H, DL\}$, 初始化样本数 N_A , 迭代轮数 R , 权重矩阵 $\mathbf{W}$, 停滞重启阈值 N_{stall} , 信赖域参数

Ensure: 已评估样本集 $\mathcal{D}$ 与 Pareto 解集 $\mathcal{P}$

- 1: 在 Θ 内生成 N_A 个拉丁超立方策略, 并逐一执行仿真评估, 构造 $\mathcal{D}_0$ 与 $\mathcal{P}_0$
- 2: 根据 $\mathcal{D}_0$ 中三项目标的样本标准差确定尺度向量 $\mathbf{s}$, 并代入式 (7-99); 以三项目标各自的初始化最优策略设置三个信赖域中心
- 3: 利用 $\mathcal{D}_0$ 训练代理 q , 并令 $\mathcal{D} \leftarrow \mathcal{D}_0$, $\mathcal{P} \leftarrow \mathcal{P}_0$
- 4: **for** $r = 1, \dots, R$ **do**
- 5: 利用截至第 $r-1$ 轮的全部新增样本更新代理 q
- 6: **for** $m = 1, 2, 3$ **do**
- 7: 按式 (7-101)构造当前信赖域 $\mathcal{B}_{r,m}$
- 8: 调用 $\mathcal{R}_q$ 求解式 (7-103), 生成候选策略 $\theta_{r,m}^{\text{cand}}$
- 9: **if** 反向求解在允许的收缩重试后仍未成功 **then**
- 10: 增加该信赖域的停滞轮数, 按条件执行重启, 并跳过本次仿真评估
- 11: **else**
- 12: 调用仿真模型评估 $\theta_{r,m}^{\text{cand}}$, 并将新样本加入 $\mathcal{D}$ 与 $\mathcal{P}$
- 13: 以当前信赖域中心为共同基准, 按式 (7-104)计算 $\Delta_{r,m}^{\text{pred}}$ 与 $\Delta_{r,m}^{\text{act}}$
- 14: 计算改善比
- 15: 按改善比与接受阈值判断是否更新策略中心, 并依据改善比和连续失败计数更新信赖域边长
- 16: 按候选策略是否被接受更新停滞轮数, 并按式 (7-105)所述规则判断是否重启
- 17: **end if**
- 18: **end for**
- 19: 更新代理的样本条件信息, 计算并记录共享 Pareto 解集的超体积
- 20: **end for**
- 21: **return** $\mathcal{D}, \mathcal{P}$

7.5 小规模算例实验

本节利用居民出行调查构建小规模仿真算例, 检验前述代理模型及多目标优化方法的有效性。首先说明算例数据与实验设置, 随后检验本章提出的深度学习代理模型能否有效转化为便于反向求解的混合整数规划问题; 在此基础上, 分别从预测误差和超体积增长两个角度比较深度学习代理模型与混合解析代理模型; 最后, 比较两类方法各自得到的 Pareto 近似集, 并对深度学习代理模型得到的代表

性推广策略开展后验复评和作用机制分析。

7.5.1 算例数据与实验设置

(1) 算例数据

小规模算例将北京市居民出行调查中的居民构建为仿真智能体，保留其调查收集的社会经济属性、家庭结构、出行方式、出行距离与费用等特征。此外，智能体的认知、试用、订阅和留存行为参数由第5章的估计结果确定。仿真空间尺度上，将居民出行调查中 16 个具有有效样本的区级编码依据人口结构与出行特征聚合为 $Z = 5$ 个策略分区。

(2) 实验设置

从计算预算设置、参数设置、模型性能指标和计算环境四个方面说明实验设置。

计算预算上，设计低计算预算（后简称低预算）和高计算预算（后简称高预算）两档实验，分别对应 50 和 1000 个代理训练样本，用于检验代理模型在极低和适中计算资源下的效果。在实验设置中，代理训练样本数、优化初始化样本数和优化循环新增样本数分别记为 N_{train} 、 N_A 和 N_B ，具体设置如表 7-3 所示。 N_{train} 用于优化前代理模型的离线训练， N_A 用于形成已评估策略集并初始化信赖域。优化阶段设置 3 个信赖域并运行 50 轮优化进程，每轮由各信赖域产生 1 个候选策略，故每种方法新增 $N_B = 150$ 个仿真样本。低、高预算实验中，每种方法最终分别形成 250 和 1250 个仿真样本。

表 7-3 小规模算例仿真预算设置

Table 7-3 Simulation budget settings for the small-scale case.

设置项	低预算档	高预算档
代理训练样本数 N_{train}	50	1000
优化初始化样本数 N_A	50	100
信赖域数量 M	3	3
优化轮数 R	50	50
循环新增 ABM 调用数 N_B	150	150
单方法优化样本总数	250	1250
测试样本数	50	50

参数设置方面，表 7-4 汇总影响仿真模型运行的主要参数；表 7-5 给出深度学习代理模型训练、MIP 反向求解及多目标信赖域优化的主要参数。

表 7-4 小规模算例仿真模型主要参数设置

Table 7-4 Main parameter settings of the simulation model for the small-scale case.

类别	参数	取值
扩散	Bass 模型年度创新系数 p_y	0.03
	Bass 模型年度模仿系数 q_y	0.38
	本地口碑权重 β_{loc}	0.80
	全市口碑权重 β_{city}	0.20
	对数营销响应斜率 b_{mkt}	0.01
订阅	允许订阅的最低累计试用次数	2

表 7-5 小规模算例深度学习代理训练、反向求解与优化参数设置

Table 7-5 Parameter settings for deep-learning surrogate training, inverse solution, and optimization in the small-scale case.

类别	参数	取值
网络结构	时序卷积层数	3
	各时序卷积层通道数	(64, 128, 128)
	时序卷积核宽	3
	策略表征维度	128
	跨区注意力头数	4
	分区嵌入维度	8
	确定性表征维度	64
	潜变量维度	32
	共享解码器隐层维度	(512, 256)
	优化器	AdamW
离线训练	初始学习率	10^{-3}
	批量大小	64
	解析先验预训练轮数	50
	仿真样本微调轮数	800
预训练损失	过程量损失权重 w_{pro}	1
	阶段目标损失权重 w_{obj}	15
	KL 散度损失权重 w_{KL}	0.10
微调损失	过程量损失权重 w_{pro}	0.30
	阶段目标损失权重 w_{obj}	30
	KL 散度损失权重 w_{KL}	0.05
盒稳定	训练盒归一化半宽 δ_{box}	0.10
	盒稳定惩罚权重 λ_{box}	低预算档为 5, 高预算档为 6

续下页

(续表 7-5)

类别	参数	取值
MIP	相对最优间隙容差	10^{-3}
	单次求解时限	1800 s
	初始及最大宽度	低预算档为 0.01, 高预算档为 1.50×10^{-2}
信赖域	最小宽度	低预算档为 2.50×10^{-3} , 高预算档为 3.75×10^{-3}
	扩张系数	1.50
	收缩系数	0.50
	扩张阈值 η_2	0.75
	候选接受阈值 η_1	0.25

在模型性能检验上, 实验主要设置代理模型精度和优化性能两类指标。代理模型精度用于检验代理模型对仿真模型的拟合能力, 优化性能用于检验代理模型在有限仿真预算下的寻优能力。在代理模型精度上, 共设置纯解析代理、混合解析代理和深度学习代理三类待对比的代理模型。三类代理分别在优化开始前和优化结束后两个阶段, 采用表7-3中的测试样本上进行测试。代理预测误差采用归一化平均绝对误差 (Normalized Mean Absolute Error, NMAE) 度量, 以消除不同目标量纲的影响。对于目标 j , 其城市级误差定义为

$$\text{NMAE}_j(\%) = 100\% \times \frac{\sum_{i=1}^{N_{\text{test}}} |\hat{F}_{i,j} - F_{i,j}|}{\sum_{i=1}^{N_{\text{test}}} |F_{i,j}|}, \quad (7-106)$$

式中, N_{test} 为测试样本数; $F_{i,j}$ 与 $\hat{F}_{i,j}$ 分别为样本 i 在目标 j 上的仿真模型输出值和代理预测值。

优化性能指标上, 代理预测只用于生成候选策略, 随后计算候选策略下仿真模型的真实输出构成的非支配解集及其无量纲超体积。为使两种方法和两档预算的数值可直接比较, 先以所有实验设置下的全部输出的并集确定统一的最优点与最差点, 随后将目标缩放至无量纲空间, 再选取 (1.10, 1.10, 1.10) 为参考点计算精确超体积。

关于计算环境, 所有实验均在配备 Intel(R) Core(TM) i9-13950HX CPU、64 GB 内存和 NVIDIA RTX 4090 GPU (24 GB 显存) 的计算环境下完成, 并结合 NumPy 1.26.4、PyTorch 2.10.0+cu128 和 Gurobi 13.0.2 进行模型训练与反向求解。

7.5.2 深度学习代理模型有效性检验

基于深度学习的代理模型虽在拟合策略和目标的精度上具有潜力，但其非线性结构使得反向求解有效性难以保证。为此，本小节检验深度学习代理模型在有限计算预算下能否被有效转化为可被求解的混合整数规划问题，其有效性须满足两个条件：一是信赖域内需要由二元变量表示的混合 ReLU 数量应控制在求解器可处理的范围内；二是为构造 MIP 而冻结注意力权重和层归一化统计量后，所得局部分段线性模型应在当前策略盒内保持对原网络的准确近似。本小节据此分别检验反向求解的 MIP 整数变量规模、求解表现以及注意力等模块冻结后模型的预测准确度。

在7.3.3小节得到的 MIP 编码中，冻结注意力权重和层归一化统计量后，在 MIP 问题的 ReLU 单元共 14080 个。表 7-6 给出同一模型在不同预激活区间收紧方法下混合 ReLU 的数量。仅采用区间边界传播时，两档预算分别有 5816 和 6194 个单元的预激活区间跨越零点。LP-PBT 因保留了上游网络的线性连接关系，在 IBP 的基础上将混合单元减少至 3909 和 3832 个。随后，在 IBP 基础上，解码器采用反向 CROWN 线性界，将混合单元进一步减少至 2012 和 2439 个。最后，将 LP-PBT 和反向 CROWN 的结果按照式(7-93)取交集，最终只产生 139 和 219 个混合单元。

表 7-6 多种实验设置下混合 ReLU 数量统计

Table 7-6 Counts of mixed ReLU units under different experimental settings.

N_{train}	收紧方法	恒负 ReLU 数	恒正 ReLU 数	混合 ReLU 数	相对总 ReLU 数 (%)
50	IBP	5873	2391	5816	41.31
	LP-PBT	6626	3545	3909	27.76
	反向 CROWN	8280	3788	2012	14.29
	全模型	9001	4940	139	0.99
1000	IBP	5356	2530	6194	43.99
	LP-PBT	6326	3922	3832	27.22
	反向 CROWN	7577	4064	2439	17.32
	全模型	8436	5425	219	1.56

在针对 MIP 问题进行求解前，考虑到 MIP 问题的原模型为注意力层冻结后的深度学习代理模型，因此需要检验 MIP 策略采用的注意力层冻结后的代理模型与原始深度学习网络的预测差异。为此，表 7-7 给出注意力层冻结后的模型在信赖域中心、盒内代表性采样点和 MIP 预测候选策略的逐目标 NMAE。结果显示，注意力层冻结后的模型在信赖域中心的预测误差极小，且在盒内代表性采样的策略上，

最大单目标 NMAE 仅为 0.06%。在 MIP 求解候选策略上, 最大单目标 NMAE 分别为 0.46% 和 0.33%, 均在可接受范围内。这说明注意力层冻结后的模型在当前信赖域内与原深度学习网络的预测结果高度一致, 因而可将其作为 MIP 问题的原模型, 用于求解信赖域内的最优策略。

表 7-7 中心冻结模型相对原深度学习代理的逐目标 NMAE (%)

Table 7-7 Target-wise NMAE of the center-frozen model relative to the original deep-learning surrogate (%).

N_{train}	评价位置	采纳率	净收入	碳减排
50	信赖域中心	7.80×10^{-6}	3.60×10^{-5}	7.00×10^{-7}
	盒内代表性采样	0.02	0.05	0.06
	MIP 求解候选策略	0.11	0.15	0.46
1000	信赖域中心	6.70×10^{-6}	1.02×10^{-5}	3.00×10^{-6}
	盒内代表性采样	0.04	0.04	0.01
	MIP 求解候选策略	0.27	0.33	0.09

在控制混合 ReLU 数量和检验注意力冻结后模型的精度后, 进一步求解边界收紧后的 MIP 问题。将策略寻优过程每一次 MIP 问题的构建与求解过程记录后, 其相关指标结果中位数如表 7-8 所示。低预算与高预算实验中, 构建的 MIP 均能以较低的最优间隙返回候选最优策略, 求解时间中位数分别为 210.08 s 和 259.45 s, 均在可接受范围内。以上结果说明, 深度学习代理模型可被有效转化为混合整数规划问题, 且在当前信赖域内可在有限时间内求解出最优策略。

表 7-8 MIP 问题构建与求解结果 (中位数)

Table 7-8 MIP construction and solution results (medians).

N_{train}	策略盒 总宽度	二元变量	构建时间 (s)	求解时间 (s) 中位数	相对最优间隙
50	1.00%	142.50	28.57	210.08	8.47×10^{-4}
1000	1.50%	163.50	30.27	259.45	6.62×10^{-4}

7.5.3 代理模型性能对比

7.5.2 小节检验了深度学习代理模型在信赖域内可被有效转化为混合整数规划问题便于反向求解, 证明了该模型可被用于推广策略寻优问题。本小节继续检验代理模型的预测精度和优化性能。

在预测精度方面，在测试集上比较三类代理模型的预测精度。表 7-9 给出两档训练预算下的城市级目标的 NMAE，其中总体 NMAE 取三个目标 NMAE 的算术平均。

表 7-9 三类代理模型的城市级目标预测精度 (NMAE, %)

Table 7-9 City-level objective prediction accuracy of the three surrogate models (NMAE, %).

N_{train}	代理模型	采纳率	净收入	碳减排	总体
50	纯解析代理	30.15	19.66	9.71	19.84
	混合解析代理	2.32	20.07	2.74	8.38
	深度学习代理	1.92	5.99	2.91	3.61
1000	纯解析代理	30.15	19.66	9.71	19.84
	混合解析代理	2.31	19.40	2.78	8.16
	深度学习代理	1.50	5.02	2.52	3.01

纯解析代理不使用已有数据拟合，故两档预算下结果相同，其总体 NMAE 为 19.84%。加入 GP 残差校正后，采纳率和碳减排误差均降至约 2-3%，但净收入误差仍接近 20%，使总体 NMAE 分别为 8.38% 和 8.16%。深度学习代理在 $N_{\text{train}} = 50$ 时的总体 NMAE 为 3.61%，相对混合解析代理模型降低 56.90%；当训练样本增至 1000 时，总体 NMAE 进一步降至 3.01%，相对降幅为 63.10%。

城市级目标精度难以检验代理模型能否学习了仿真模型中推广策略在不同分区以及随时间演化的异质响应。为此，进一步计算代理模型在各策略阶段、各分区的多目标预测精度。具体而言，首先对 50 个测试策略在针对每个策略阶段中的每个分区计算三个目标的 NMAE，再按分区人口加权。值得说明的是，混合解析代理模型中的 GP 残差仅调整仿真结束时的三项目标，无法拟合多策略阶段残差或分区残差，因此不在本次计算范围内。多阶段、各分区的目标预测精度计算结果如表 7-10 所示。

表 7-10 纯解析代理与深度学习代理仿真过程目标预测精度 (NMAE, %)

Table 7-10 Objective prediction accuracy across the simulation process for the pure analytical and deep-learning surrogates (NMAE, %).

N_{train}	代理模型	采纳率	净收入	碳减排	总体
50	纯解析代理	28.40	38.48	11.56	26.15
	深度学习代理	4.21	13.08	7.84	8.38
1000	纯解析代理	28.40	38.48	11.56	26.15
	深度学习代理	3.42	9.73	7.21	6.79

结果表明, 纯解析代理的采纳率、净收入和碳减排 NMAE 分别为 28.40%、38.48% 和 11.56%, 总体 NMAE 为 26.15%。深度学习代理在低预算档的总体 NMAE 为 8.38%, 在高预算档进一步降至 6.79%, 均明显低于纯解析代理。同时, 两类代理的分阶段、各分区的预测误差均高于各自的针对城市级目标的误差。增加训练样本后, 深度学习代理的三个目标误差均有所下降, 其中净收入误差由 13.08% 降至 9.73%, 改善最为明显。

在优化性能方面, 表 7-11 给出优化算法初始化时以及新增 30、75 和 150 次仿真评估后的超体积值。低预算实验中, 两种代理模型初始化超体积值均为 0.30, 深度学习代理在 30 和 75 次新增仿真评估后分别领先 1.58% 和 2.34%, 终点超体积为 0.42, 较混合解析代理模型的超体积值 0.42 高 0.78%。两条轨迹均较初始值提高约 39%, 终点差异较小, 说明 50 个初始化仿真样本下两种代理均能支持信赖域搜索, 深度学习代理的预测优势尚未转化为明显扩大的求解优势。

高预算实验中的差异更为明显。混合解析代理模型前 30 次新增仿真评估后领先 0.67%, 深度学习代理在新增第 75 次仿真评估时反超, 最终超体积由初始 0.42 增至 0.73, 增幅为 71.92%; 混合解析代理模型的最终超体积为 0.67, 较初始提高 58.39%。因此, 深度学习代理通过在搜索过程中逐步形成优势, 在优化算法运行完成时领先 8.54%。综上, 在本算例和给定预算下, 深度学习代理兼具更低预测误差与更高的终点超体积, 其在两种计算预算条件下的超体积变化如图 7-5 和图 7-6 所示。

表 7-11 统一无量纲目标空间和固定参考点下的精确超体积增长

Table 7-11 Exact hypervolume growth in a unified dimensionless objective space with a fixed reference point.

N_{train}	新增 ABM 调用数	深度学习代理	混合解析代理	两者比值
50	0	0.30	0.30	1.00
	30	0.34	0.34	1.02
	75	0.38	0.37	1.02
	150	0.42	0.42	1.01
1000	0	0.42	0.42	1.00
	30	0.48	0.49	0.99
	75	0.58	0.58	1.01
	150	0.73	0.67	1.09




图 7-5 低预算档两类代理辅助优化的超体积增长曲线

Figure 7-5 Hypervolume curves of the two surrogate-assisted optimization methods under the low-budget setting.




图 7-6 高预算档两类代理辅助优化的超体积增长曲线

Figure 7-6 Hypervolume curves of the two surrogate-assisted optimization methods under the high-budget setting.

7.5.4 多目标优化结果分析

本节进一步分析两类代理模型在多目标优化中获得的 Pareto 近似集的分布特征。考虑到在 $N_{\text{train}} = 1000$ 的高预算实验下，两类代理模型的预测精度和优化性能均较优，因此本节聚焦该实验下的策略寻优结果进行分析。

在将两类代理模型分别用于推广策略寻优后，分别记录两类代理找到的非支配解。图 7-7 给出两类代理模型找到的 Pareto 近似集在两维目标空间及三维目标空间中的分布。深度学习代理找到的 Pareto 前沿的最高采纳率和最高碳减排分别为 77.36% 和 2.46 百万 kg，均高于混合解析代理的 76.29% 和 1.99 百万 kg。净收入目标方面，混合解析代理所得前沿的最高净收入为 1.67 亿元，高于深度学习代理的 0.87 亿元。




图 7-7 两类代理模型所得 Pareto 解集的分布

Figure 7-7 Distributions of the Pareto approximation sets obtained with the two surrogate models.

为进一步比较两类代理模型搜寻的目标解集分布，分别从其 Pareto 解集中选择采纳率、净收入和碳减排最大的策略，结果如表 7-12 所示。

表 7-12 两类代理模型所得 Pareto 近似集的单目标最优策略

Table 7-12 Single-objective optimal strategies from the Pareto approximation sets obtained with the two surrogate models.

代理模型	选择规则	采纳率 (%)	净收入 (亿元)	碳减排 (百万 kg)
深度学习代理	采纳率最大	77.36	-0.12	1.49
	净收入最大	56.24	0.87	1.33
	碳减排最大	74.27	-0.45	2.46
混合解析代理	采纳率最大	76.29	0.36	1.35
	净收入最大	48.96	1.67	1.39
	碳减排最大	57.61	-0.88	1.99

结果表明，两类代理在三个单目标方向上表现出不同的搜索优势。对于采纳率目标，深度学习代理所得最优方案的采纳率达到 77.36%，较混合解析代理高 1.07 个百分点，但其净收入由 0.36 亿元降至 -0.12 亿元，说明进一步扩大订阅规模需要付出更高的营销、服务或价格补贴成本。对于碳减排目标，深度学习代理所得方案的减排量达到 2.46 百万 kg，较混合解析代理高 0.47 百万 kg；与此同时，其采纳率提高 16.66 个百分点，净收入亏损也减少 0.43 亿元，表明该方案并非仅以牺牲其他目标换取减排，而是在订阅规模和单位订阅者减排效应之间形成了更有利的组合。相反，在净收入目标上，混合解析代理将最优净收入提高至 1.67 亿元，较深度学习代理高 0.80 亿元，但采纳率下降至 48.96%，较后者低 7.28 个百分点，体现出更明显的盈利导向。后一节将详细分析以上最优策略的具体取值及效果。

7.5.5 代表性推广策略效果分析

(1) 推广策略效果稳定性分析

在分析 Pareto 解集的单目标最优策略后，本节选取在采纳率和碳减排目标上均较优的深度学习代理模型的 Pareto 解集，分析其单目标策略的分阶段、分区的策略取值及效果。分别将采纳率、净收入和碳减排最优的策略记为 S1、S2 和 S3。由于最优策略对应的仿真输出结果受到随机概率抽样的影响，因此分别进行 100 次独立实验对三个单目标最优方案进行评估，以获取三目标最优方案的效果区间，计算结果如表 7-13 所示。

表 7-13 三种代表方案的独立实验稳定性结果

Table 7-13 Stability of the three representative strategies across independent simulation runs.

方案	采纳率 (%)	净收入 (百万元)	碳减排 (t)
S1	77.20 [77.18, 77.23]	-11.88 [-11.90, -11.85]	1492 [1491, 1493]
S2	56.31 [56.28, 56.34]	87.54 [87.48, 87.59]	1338 [1337, 1339]
S3	74.37 [74.34, 74.39]	-44.84 [-44.86, -44.82]	2456 [2454, 2458]

结果表明，三项目标的 95% 置信区间均较窄，说明以上单目标最优策略在仿真条件下具有较好的稳定性。此外，多次独立重复试验也并未改变三个单目标最优方案的原有定位。S1 的平均采纳率达到 77.20%，高于 S2 和 S3，但净收入为 -11.88 百万元，表明其以扩大用户覆盖为主要取向；S2 的平均净收入达到 87.54 百万元，是三个方案中唯一获得正向净收入的方案，但其采纳率和碳减排相对较低，体现出较强的平台盈利导向；S3 的平均碳减排达到 2456 t，同时保持 74.37% 的较高采纳率，但其净收入下降至 -44.84 百万元，说明更高减排效果需要承担相应的平台成本。

(2) 推广策略各阶段和空间配置

在验证各方案对独立重复试验的稳定性后，进一步分析代表性策略的阶段变化和空间配置。在阶段变化方面，将各类策略变量按照策略阶段取平均，其中面向居民的策略变量按分区样本规模加权，营销预算则按各策略分区包含的行政区数量汇总，结果如图 7-8所示。




图 7-8 三个深度学习代表方案的分阶段推广策略

Figure 7-8 Stage-wise profiles of the three representative promotion strategies obtained with the deep-learning surrogate.

图 7-8表明，三个方案均根据推广进程动态调整策略组合，但其策略配置与目标取向存在明显差异。S1 方案下，套餐额度在第 3 阶段相对较高；考虑到此时前期营销形成的认知和试用用户开始向订阅转化，提高套餐额度有助于增强套餐吸引

力并扩大订阅规模。进入第 5 阶段后，S1 降低套餐额度并提高部分定价变量，以减少对已形成订阅意愿用户的过度补贴；第 6 阶段再提高服务水平，以改善使用体验并维持后期留存。因此，S1 并非持续提高全部投入，其主要在推广中期促进转化，并在推广后期控制补贴并加强用户留存。

S2 方案下，定价变量在 6 个策略阶段中整体较高，并于第 5 阶段达到最高水平，使平台能够从逐步扩大的订阅群体中提高套餐收入。与此同时，末期套餐额度有所下降，有助于控制套餐成本。服务水平变量则由前期较低取值逐步提高，并在第 6 阶段达到最高值，以缓解较高定价和额度收缩可能对续订产生的不利影响。由此，S2 则主要在推广前中期提高运营收入，并在推广后期控制运营成本并维持用户留存，从而实现平台净收入最大化。

S3 方案下，考虑到服务改善能够增强公共交通和共享出行相对于小汽车的吸引力，因此服务水平在各阶段均保持较高取值，并在第 6 阶段进一步提高，以提高订阅者使用低碳出行方式的频率。其营销投入主要集中于前期和中后期，用于持续扩大 MaaS 的认知与订阅覆盖，而套餐额度整体低于 S1 和 S2，说明该方案并非主要依靠提高额度吸引用户，而是通过阶段性营销扩大订阅规模、通过持续服务改善增强用户的减排效应。

在分析策略随时间的变化趋势后，对各分区内 6 个阶段的策略取值进行平均，用于比较策略配置的空间差异，计算结果如图 7-9 所示。




图 7-9 三个深度学习代表方案的分区推广策略

Figure 7-9 Zone-wise profiles of the three representative promotion strategies obtained with the deep-learning surrogate.

图 7-9 表明，即使对每个分区的 6 个阶段取平均，三个方案仍保留了较为清晰

的空间差异。

S1 方案下, 分区 1 (西城、朝阳、海淀、通州、顺义和昌平) 的营销预算与认知缺口倾斜系数相对较高; 考虑到该分区覆盖 57.33% 的调查样本, 且居民收入结构和出行方式较为多样, 提高营销投入有助于将营销资源投向尚未认知 MaaS 的潜在用户。同时, 考虑到分区 4 (东城、石景山和平谷) 家庭拥车水平较低而使用出租车较多, 提高其 MaaS 多模式出行服务服务水平以增强公共交通与出租车等多模式出行服务的吸引力。此外, 针对公共交通使用较多的分区 5 (丰台、房山、大兴和门头沟), S1 方案对该分区订阅较多的主导套餐保持相对适中的价格, 同时提高部分低占比套餐的价格, 以进一步提升该分区智能体对套餐的选择意愿。最后, 针对试用向稳定订阅转化不足问题较为突出的分区 3 (怀柔和密云), S1 方案配置了较高的多模式出行服务服务水平。综上, S1 根据各分区的人口规模、出行方式和采纳阶段差异, 分别采用扩大认知覆盖、改善服务和差异化定价等策略, 以最大限度提升 MaaS 的整体采纳率。

S2 方案下, 分区 1 的定价变量整体较高, 同时采用较低的营销预算和较高的营销集中度, 从而将有限的营销资源集中于订阅率较低的高潜力交通小区, 并从规模较大的订阅群体中获得收入。对于公共交通使用较多的分区 5, S2 针对公交优先和地铁畅行等主导套餐实行差异化定价, 并进一步压缩营销预算, 在保留一定订阅规模的同时降低获客成本。分区 4 的营销投入和服务水平也相对较低, 以减少用户服务成本和推广支出。由此, S2 通过在主要用户市场提高订阅收入, 并对其他分区的营销和服务成本进行控制, 实现了平台净收入最大化, 但这种盈利导向也使其整体采纳率低于 S1 和 S3。

S3 方案下, 分区 1 采用较高的服务水平、营销预算和高潜力区域倾斜系数。该分区人口规模最大且家庭拥车水平较高, 改善多模式出行服务并将营销资源向高潜力区域倾斜, 有助于扩大 MaaS 订阅覆盖, 并增强公共交通及共享出行相对小汽车的吸引力。对于公共交通使用较多的分区 5, S3 进一步提高营销预算及其向认知缺口区域的倾斜程度, 以扩大公交优先和地铁畅行套餐的使用规模, 为居民更多使用低碳出行方式创造条件。针对出租车使用较多的分区 4, S3 则通过提高多模式出行服务水平, 增强公共交通与出租车组合出行的吸引力。综上, S3 主要在分区 1 和分区 5 扩大订阅覆盖, 并通过服务改善增强低碳出行方式的相对吸引力, 使两个分区成为累计碳减排的主要贡献来源。

(3) 推广策略效果时空分布

在分析代表性推广策略的时空配置后, 进一步分析推广策略效果的在各阶段、各分区的分布, 检验不同策略方案推广 MaaS 并实现相应优化目标的实际效果, 如图 7-10 所示。




图 7-10 小规案例三种代表方案的分阶段、分区的目标值

Figure 7-10 Stage- and zone-specific objective values of the three representative strategies in the small-scale case.

S1 方案下，前期营销和试用已经积累了较大规模的潜在用户，因此在第 5 和第 6 阶段采纳率增长较高，分别相对前一阶段增长 19.65 个和 20.14 个百分点，较大程度促进了试用用户向订阅转化行为，同时维持了用户的续订行为，使采纳率在推广后期集中提高。S2 方案下，净收入同样主要形成于第 5 和第 6 阶段，分别贡献 0.47 亿元和 0.30 亿元，说明较高定价和后期成本控制需要在订阅群体达到一定规模后才能转化为较为明显的平台收益。S3 方案下，碳减排随推广阶段持续增加，表明碳减排是订阅规模、累计订阅时长和低碳出行方式使用效果逐步累积的结果，而非仅由最后阶段的策略决定。

从空间分布看，分区 1 对三个方案的采纳率贡献均最大，同时也贡献 S3 约 1.47 百万 kg 的碳减排。究其原因，该分区涵盖 57.33% 的被调查居民，其较大的贡献主要受到人口规模的影响。S2 的净收入则主要来源于分区 1 和公共交通使用较多的分区 5，说明其收入来源主要集中在订阅群体规模较大或主导套餐较为明

确的区域。

(4) 推广策略效果分解

最后, 针对用户采纳率、净收入和碳减排三个目标, 进一步分解其在三种代表性方案下的具体形成过程。

针对用户采纳率, 分别分析三种方案下认知率、当前试用率、曾订阅率和当前订阅率随阶段变化, 如图 7-11 所示。




图 7-11 三种代表方案的用户采纳率分解

Figure 7-11 Decomposition of user adoption rates under the three representative strategies.

S1 方案下, 推广结束时认知率和曾订阅率分别达到 96.80% 和 96.28%, 当前订阅率达到三种方案中的最高值 77.20%。考虑到认知率与曾订阅率主要反映用户覆盖范围, 而当前订阅率还受到试用转化和订阅留存的影响, 该结果说明 S1 不仅使较多用户认知并尝试订阅 MaaS, 也使其中较大比例的用户在推广结束时继续保持订阅。S2 方案下, 终期认知率和曾订阅率仍分别达到 93.97% 和 91.44%, 但当前试用率和当前订阅率仅为 16.27% 和 56.31%, 表明 S2 并非没有形成足够的用户认知, 而是在提高净收入的同时, 限制了部分试用用户向长期订阅转化, 并降低

了既有订阅者的留存水平。S3 方案下, 认知率和曾订阅率分别达到三个方案中的最高值 97.95% 和 97.50%, 当前订阅率为 74.37%。因此, S3 的碳减排优势不仅来源于订阅规模, 还可能与用户在推广期内的累计订阅时长以及订阅后使用低碳出行方式的频率有关。

其次, 针对平台净收入, 按照式 (7-24) 将其分解为经营收入、服务成本和营销支出, 分析三种方案下收入与成本的形成差异, 如图 7-12 所示。




图 7-12 三种代表方案的 3 年累计净收入分解

Figure 7-12 Decomposition of three-year cumulative revenue under the three representative strategies.

S1 方案的 3 年累计经营收入为 10.37 亿元, 但为扩大订阅覆盖并维持用户留存, 其服务成本和营销支出分别达到 9.82 亿元和 0.68 亿元, 最终净收入为 -0.12 亿元。S2 的经营收入为 10.04 亿元, 虽然低于 S1 和 S3, 但通过控制营销投入和服务成本, 将两项支出分别降低至 0.47 亿元和 8.70 亿元, 最终获得最高的净收入 0.88 亿元。S3 的经营收入最高, 达到 10.44 亿元, 但较高的营销投入和服务水平使其服务成本和营销支出分别达到 10.11 亿元和 0.78 亿元, 最终净收入为 -0.45 亿元。由此可见, 净收入并不完全取决于经营收入规模, S2 的盈利优势主要来自对获客成本和用户服务成本的有效控制。

最后, 针对碳减排, 将其分解为推广期内的累计订阅人周与单位订阅人周减排量。其中, 累计订阅人周为各周订阅人数之和, 用于反映订阅规模和订阅持续时间的共同作用; 单位订阅人周减排量则反映用户处于订阅状态时平均每人每周产生的减排效果。分解结果如图 7-13 所示。




图 7-13 三种代表方案的累计碳减排分解

Figure 7-13 Decomposition of cumulative carbon emission reduction under the three representative strategies.

S1 方案的 3 年累计订阅者周为 5.82 百万人周，单位订阅者周减排效应为 $0.26 \text{ kg}/(\text{人} \cdot \text{周})$ ，对应累计碳减排 1.49 百万 kg；其期末订阅率虽然最高，但订阅增长主要集中在推广后期，因而累计订阅者周少于 S3。S2 的累计订阅者周最低，为 5.08 百万人周，单位减排效应为 $0.26 \text{ kg}/(\text{人} \cdot \text{周})$ ，最终累计减排 1.34 百万 kg。S3 不仅具有最高的累计订阅者周 8.04 百万人周，单位订阅者周减排效应也达到最高的 $0.31 \text{ kg}/(\text{人} \cdot \text{周})$ ，最终形成 2.46 百万 kg 的累计碳减排。因此，S3 的碳减排优势来自累计订阅规模和单位减排效应的共同提高，也说明期末订阅率不能完全反映整个推广期的累计减排效果。

7.6 大规模算例实验

本节基于全市合成人口与合成出行计划构建大规模算例。在小规模算例已验证深度学习代理模型有效性的基础上，本节不再重复代理模型有效性检验和方法对比，仅采用高预算档下的 $N_{\text{train}} = 1000$ 的深度学习代理模型，重点分析其多目标优化结果及代表性推广策略。

7.6.1 算例数据与实验设置

(1) 算例数据

大规模算例以第3章合成的家庭级虚拟人口为智能体，并以第4章生成的家庭活动计划为智能体赋予活动出行特征。合成人口提供居民的社会经济属性与家庭结构，活动计划提供个体层面的出行方式、出行距离与出行费用信息，两者共同构成覆盖全市的仿真数据基础。算例共包含 3158.23 万个合成智能体，共形成 6519.05

万次出行。

仿真空间覆盖 16 个有效行政区，并按照人口结构与出行特征进一步聚合为 5 个策略分区。分区 Z1 至 Z5 的人口分别为 690.63、41.95、1566.81、463.50 和 395.35 万人，分别占全市合成人口的 21.87%、1.33%、49.61%、14.68% 和 12.52%。

(2) 实验设置

大规模算例计算预算仅采用高预算档 $N_{\text{train}} = 1000$ ，除此之外，参数设置、模型性能指标和计算环境等方面均与小规模算例相同，故在此不再赘述。

7.6.2 多目标优化结果分析

对得到的优化策略进行非支配筛选后，共得到 16 个非支配解，其分布如图 7-14 所示。




图 7-14 大规模算例 Pareto 近似集的二维投影与三维分布

Figure 7-14 Two-dimensional projections and three-dimensional distribution of the Pareto approximation set for the large-scale case.

从三个目标极值看，采纳率最大方案的采纳率为 49.29%，对应平台净收入为 -121.05 亿元、碳减排为 3330.42 百万 kg。碳减排最大方案的减排量达到 3376.42

百万 kg，同时保持 48.84% 的采纳率，平台净收入为 -82.49 亿元。与采纳率最大方案相比，碳减排最大方案的采纳率仅下降 0.44 个百分点，碳减排增加 45.99 百万 kg，平台净收入提高 38.57 亿元，说明当前前沿的高采纳率区域与高碳减排区域较为接近，继续将采纳率推至极值需要同时付出一定的经济和环境机会成本。相比之下，平台净收入最大方案的净收入达到 563.74 亿元，但其采纳率和碳减排分别降至 41.82% 和 2330.73 百万 kg。相较采纳率最大方案，其采纳率下降 7.47 个百分点、碳减排减少 999.69 百万 kg，而平台净收入提高 684.80 亿元，呈现出更为明显的经济目标取向。

将上述极值方案与表 7-12 中小规模算例的深度学习代理结果对照，可以发现两种规模算例呈现出相近的目标权衡方向。小规模算例由采纳率最大方案转向平台净收入最大方案时，采纳率由 77.36% 下降至 56.24%，降低 21.12 个百分点，平台净收入则由 -0.12 亿元提高至 0.87 亿元，碳减排由 1.49 百万 kg 下降至 1.33 百万 kg。在两种算例下，两者的差异主要体现在高采纳率方案与高碳减排方案的相对优劣。小规模算例的碳减排最大方案相较采纳率最大方案，采纳率下降 3.09 个百分点、平台净收入减少 0.33 亿元。大规模算例的碳减排最大方案则仅损失 0.44 个百分点的采纳率，并同时提高平台净收入和碳减排，表明其高采纳率与高碳减排方案的重合程度更高。此外，大规模前沿的最高采纳率较小规模深度学习代理所得结果低 28.07 个百分点，说明在当前算例设定下，全市合成人口场景中的非支配解整体分布在较低的采纳率区间。

7.6.3 代表性推广策略效果分析

(1) 代表性方案选取与总体效果

为比较不同目标偏好下的推广策略，在当前非支配解集中分别选择采纳率、平台净收入和碳减排取值最大的方案，并依次记为 S1、S2 和 S3。表 7-14 给出三个方案的目标值。

表 7-14 三种代表性推广策略效果

Table 7-14 Performance of the three representative promotion strategies.

方案	选择规则	采纳率（%）	净收入（亿元）	碳减排 （百万 kg）
S1	采纳率最大	49.29	-121.05	3330.42
S2	平台净收入最大	41.82	563.74	2330.73
S3	碳减排最大	48.84	-82.49	3376.42

S1 与 S3 位于 Pareto 前沿上的高采纳率、高碳减排区域。两者的采纳率仅相差 0.44 个百分点。与 S1 相比，S3 的碳减排高 45.99 百万 kg，平台净收入高 38.57 亿元。S2 则位于 Pareto 的高净收入区域，其采纳率和碳减排分别比 S1 低 7.47 个百分点和 999.69 百万 kg，平台净收入则高 684.80 亿元。由此可见，三个方案分别代表用户覆盖、平台收益和环境效益三种不同的目标导向。

（2）推广策略各阶段和空间配置

由于各类策略变量的量纲和取值范围不同，为便于比较，将各策略取值归一化至 [0,1]。图 7-15对各阶段的分区策略取值按人口规模加权，用于比较三个方案的阶段配置。




图 7-15 三种代表方案的分阶段推广策略配置

Figure 7-15 Stage-wise configurations of the three representative promotion strategies.

图 7-15表明，三个方案均根据推广进程动态调整策略组合，但 S1 与 S3 的阶段配置更为接近。S2 的阶段配置则与 S1、S3 存在较为明显的区别。总体来看，S1 与 S3 均遵循前期识别潜在用户、第 3 阶段集中营销、中期调整套餐额度以及末期

强化服务水平的配置路径，因而二者在采纳率和碳减排目标上的表现也较为接近。S2 则将营销重点后移至第 4 阶段，并在第 6 阶段集中提高部分套餐价格，形成了区别于 S1 和 S3 的收益导向路径。

与小规模算例相比，两种算例下 S2 的营销预算均在第 4 阶段达到较高水平，S1 也均在第 6 阶段提高服务水平，说明盈利导向方案的中期营销调整 and 采纳率导向方案的末期服务改善具有一定一致性。然而，两种算例的具体阶段配置并不相同。小规模算例中，S1 主要在第 3 阶段提高套餐额度，S3 则在各阶段保持较高的服务水平。大规模算例中，S1 与 S3 均在第 3 阶段集中提高营销预算，并在第 6 阶段强化服务改善，二者的策略变化轨迹更加接近。因此，小规模算例中的 S1 与 S3 具有不同的阶段配置侧重，而大规模算例中二者的策略配置高度重合，表明在当前全市合成人口场景下，高采纳率方案与高碳减排方案对应的阶段策略组合具有更高的一致性。

随后，各分区内 6 个阶段的策略取值取平均，用于比较其空间配置，结果如图 7-16 所示。




图 7-16 三种代表方案的分区推广策略配置

Figure 7-16 Zone-wise configurations of the three representative promotion strategies.

图 7-16 表明，对各分区的 6 个阶段取平均后，三个方案仍保留了较为清晰的空间差异。S1 与 S3 的空间配置高度接近。例如，两者的营销预算均在分区 1 最高、分区 5 次之、分区 2 最低，且两者的公交优先套餐的出租车额度均在分区 5 最高、分区 3 最低。由此可见，S1 与 S3 不仅在阶段配置上较为接近，在套餐额度、定价、营销和服务水平的空间配置上也具有较高一致性。

S2 则呈现出不同的盈利导向空间配置。其各分区营销预算的差异较大，同时在分区 1、分区 3 和分区 5 的营销预算均低于另外两个方案，表明营销投入具有一定的分区偏好性。在其他变量方面，S2 在五个分区均配置了相对较高的套餐价格系数。上述结果表明，S2 并非简单降低所有策略投入，而是通过较为平缓的营销配置与差异化的套餐额度、定价和服务组合，形成了区别于 S1、S3 的空间策略结构。

与小规模算例相比，两种算例下的 S2 均表现出在主要用户市场提高部分定价变量、同时控制营销投入的偏好，与其平台盈利导向一致。大规模算例中 S2 的营销预算分布更加平缓，服务改善的区际差异也相对较小。对于 S1 和 S3，小规模算例分别形成了更具采纳率导向和碳减排导向的分区组合，二者在营销倾斜、套餐配置和服务改善方面存在较为明显的区别；大规模算例中两者的空间配置则高度重合，进一步说明当前大规模算例中前沿的高采纳率区域与高碳减排区域具有较强的策略趋同性。

还应注意，两种算例的人口空间构成并不相同。小规模算例中分区 1 约占调查样本的 57.33%，而大规模算例中人口规模最大的分区转为分区 3，占全市合成智能体的 49.61%，分区 1 占比则为 21.87%。尽管人口重心发生变化，S1 和 S3 仍将最高营销预算配置在分区 1、次高值配置在分区 5，而非简单按照分区人口规模排序，表明当前优化结果仍保留了差异化空间配置特征。

（3）推广策略效果的阶段边界与空间分布

在比较代表性方案的阶段和空间配置后，进一步描述三个方案在各策略阶段、各策略分区上的目标效果，如图 7-17 所示。




图 7-17 大规模案例三种代表方案的分阶段、分区目标值

Figure 7-17 Stage- and zone-specific objective values of the three representative strategies in the large-scale case.

从策略阶段的目标分布看，S1 与 S3 呈现出较为接近的采纳率变化路径。两者的采纳率均由第 1 阶段持续提高至第 3 阶段，第 4 阶段有所下降，随后再次提高，并在第 6 阶段分别达到 49.29% 和 48.84%。这一变化与两个方案相近的阶段策略配置相对应，即潜在转化系数在第 2 阶段较高、营销预算在第 3 阶段达到峰值，促进了前期潜在用户的识别、认知和订阅转化。第 4 阶段时间改善比例下降，同时套餐额度与定价组合发生调整，使部分用户的订阅吸引力或留存水平暂时降低。第 6 阶段服务改善再次加强后，采纳率随之恢复至最高水平。S2 的采纳率则由 10.37% 连续提高至 41.82%，但期末仍分别比 S1 和 S3 低 7.47 个和 7.02 个百分点。这与其营销投入相对后移、末期提高部分套餐价格的盈利导向配置相一致，即在逐步扩大订阅规模的同时，对用户覆盖范围作出一定让步。S2 的平台净收入在不同阶段边界上正负交替，并在第 6 阶段达到 563.74 亿元，可能是因为前期营销和服务投入尚未被用户规模及套餐收入充分覆盖，而随着订阅群体扩大并在末期

提高套餐价格系数,净收入逐步提高。S3 的碳减排目标在第 6 阶段达到最高水平,则与其较高的末期采纳率以及末期服务改善相对应。

与小规模算例相比,两种算例均表明用户规模积累、后期定价调整和服务改善是区分三种目标取向的重要因素,但目标形成的阶段和空间分布存在明显差异。小规模算例中,S1 的采纳率增长主要集中在第 5 和第 6 阶段,说明前期积累的认知和试用用户在推广后期集中转化。大规模算例中,S1 与 S3 则在第 1 至第 3 阶段已经形成较快增长,并在第 4 阶段短暂下降后再次恢复,表明全市合成人口场景下不同用户群体的转化和留存过程更加复杂。对于 S2,小规模算例的净收入主要形成于第 5 和第 6 阶段,大规模算例也在第 6 阶段取得最高净收入,二者均反映出盈利效果需要在形成一定用户规模并实施后期定价调整后才能体现。对于 S3,小规模算例采用 3 年逐期累计口径,碳减排随推广阶段持续增加。从空间分布看,小规模算例的主要目标贡献集中在占调查样本 57.33% 的分区 1,而大规模算例的人口重心转向占全市合成智能体 49.61% 的分区 3,三个方案在该分区的采纳率分别达到 58.08%、47.70% 和 58.46%,碳减排占比均接近三分之二。除此之外,大规模算例 S2 的净收入也由各分区共同形成,而不再主要集中于少数分区。

7.7 本章小结

本章围绕研究内容(4)基于城市级仿真的 MaaS 推广策略优化,提出了基于多智能体仿真的 MaaS 推广策略评估模型,并设计了两类代理模型用以辅助策略寻优,提出了基于信赖域机制的多目标优化算法获取推广策略 Pareto 前沿,并最终在居民出行调查小规模算例和北京市虚拟人口大规模算例上开展实验验证。

其一,引入空间网络效应的 Bass 扩散刻画认知传播过程,以第 5 章估计的行为模型驱动智能体的多阶段采纳决策,构建了涵盖智能体认知、试用、订阅、套餐选择与续订留存过程的 MaaS 推广策略评估模型。在此基础上,基于 330 维的动态推广策略输入,设计了采纳率、平台净收入与碳减排三目标的核算方法。由此,可通过构建的 MaaS 推广策略评估模型评估特定推广策略的实际效果。

其二,构建了混合解析代理与深度学习代理两类代理模型。混合解析代理通过状态概率递推近似仿真的主要运行机理,并结合高斯过程矫正预测误差。深度学习代理通过时序卷积、跨区注意力和解析先验预训练学习策略响应的时空关联。同时,设计了两类代理模型的反向求解算法,用以辅助策略寻优。

其三,提出了基于信赖域机制的多目标优化算法。算法以目标表量化和信赖域并行维护多个信赖域,利用代理模型反向求解生成候选策略,并将候选策略输入给多智能体仿真模型进行策略评估。在此基础上,根据评估结果动态调整信赖域范围,并利用新增仿真样本更新代理模型,形成候选策略生成、仿真评估、信赖

域调整、代理更新的搜索过程，以提高有限仿真计算预算的利用效率。

其四，通过小规模和大规模算例分析了所提优化算法的搜索效果。小规模算例表明，深度学习方法对 Pareto 近似集的总体覆盖优于混合解析方法，在高预算设置下最终超体积提高 8.54%。此外，深度学习方法获得了更高的采纳率和碳减排，混合解析方法则更关注净收入区域。针对代表性方案的分析进一步表明，用户覆盖、平台盈利和碳减排对应不同的阶段配置、空间配置与成本结构，需要根据目标偏好在 Pareto 近似集中进行权衡。在此基础上，将所提方法应用于基于虚拟人口的全市大规模算例，得到的高采纳率方案与高碳减排方案在目标表现以及阶段、空间配置上更加接近，高净收入方案则呈现出不同的营销、定价和服务配置。

综上，本章形成了从个体采纳行为仿真、代理学习、局部反向求解到多目标策略搜索的方法框架。小规模算例为代理预测、反向求解和优化方法的有效性提供了主要验证依据，大规模算例则展示了该框架在全量人口场景下的应用能力，得到的 Pareto 前沿可为 MaaS 政策制定提供参考。

8 总结与展望

本章对全文的研究内容进行归纳总结,进而提炼研究工作的主要创新点,并结合研究过程中的思考对进一步的研究方向进行展望。

8.1 研究总结

本文对城市级 MaaS 推广策略制定中的仿真基础构建、行为机理解析与推广策略优化等问题进行了深入研究。研究工作以居民出行调查、人口普查与统计年鉴、两步式陈述偏好调查等多源数据为基础,围绕家庭级虚拟人口合成-家庭活动计划生成-MaaS 多阶段采纳意愿解析-推广策略多目标优化的技术路线展开,各章研究内容构成紧密衔接的链条,具体完成了以下五个方面的工作,各部分主要工作与研究结论总结如下:

(1) 提出了面向出行分析的超大城市家庭级人口合成方法

针对既有数据无法支撑城市级别 MaaS 推广策略仿真、既有研究多以个体为基本单元进行人口合成而难以再现家庭联合出行、接送与车辆共享等行为特征的问题,本文以家庭为基本合成单元,提出了家庭画像条件下的分层扩散 Transformer 人口合成模型。以基于 HDBSCAN 的家庭画像机制压缩下层成员属性的生成空间,以异质图显式表征家庭结构与成员关系,实现家庭属性、家庭结构与成员属性的联合生成,并设计了基于能量引导的多尺度边际对齐机制、样本零与结构零双判据正则化策略以及两阶段超参数调优策略。以北京市为算例的实验表明,所提模型在家庭级、个人级与扩展家庭级的全部属性组合维度下均优于各类生成模型基准,6 维属性组合下家庭级与个人级 SRMSE 分别低至 0.389 与 1.188;引入能量引导后,栅格尺度机动车拥有比例的平均绝对误差下降 27.34%;正则化策略将结构零占比由 6.86% 降至近似为零,所合成虚拟人口的属性联合分布真实性、家庭结构合理性与多尺度边际吻合度均得到验证。

(2) 提出了考虑家庭联合活动的家庭级活动计划生成方法

活动计划界定了居民既有的出行模式与向 MaaS 转移的具体情境,而既有研究多以个体为独立生成单元,难以再现联合出行、接送与车辆共享等家庭联合活动。为此,以第3章合成的虚拟人口为输入,提出了协调式家庭活动计划生成框架 CoHACT。提出融合家庭与成员特征的多任务学习编码器以获取统一嵌入的异质化家庭与成员属性,经跨角色注意力自回归解码逐属性地同时生成全体成员的活动计划,设计基于纳什议价的可微协调层在车辆可用性等硬约束下协调各成员的

活动安排,并以考虑空间异质性的目的地注意力层完成城市级目的地选择。算例表明,CoHACT在个体与家庭两个层面的全部属性组合维度下均显著优于六个基准模型,最严格的8维联合分布下SRMSE低至1.95、生成误差约为最优基准的1/15;生成的全部家庭活动计划均不存在车辆超配问题,家庭成员的联合出行、接送与车辆共享等行为特征均得到再现;目的地分布与真实分布的JS散度仅为0.0132,验证了该框架在家庭级可行性与空间保真度上的优势。

(3) 构建了 MaaS 多阶段采纳意愿的分阶段建模框架

用户对 MaaS 的采纳行为经历从单次出行试用到长期套餐订阅的序列过程,既有研究多以单阶段选择为研究对象,难以刻画跨阶段的行为状态转移与效用迁移机制。为此,本文首先从分阶段建模视角展开研究。设计并实施了两步式 SP 调查,在北京市获得 1242 份有效问卷,单次转移与套餐订阅两阶段分别形成 5472 个与 6210 个观测样本。在单次出行阶段,构建了基于混合潜在分类模型的 MaaS 转移行为选择模型,识别出期望经 MaaS 获得高品质出行的类别 1 与偏好私家车出行的类别 2(隶属概率分别为 28.89% 与 71.11%),并构建 MaaS 转移意愿指数量化用户的初始印象,类别 1 的转移意愿峰值(0.75)远高于类别 2(0.31)。在套餐订阅阶段,构建了以转移意愿为类别划分关键变量、考虑属性无视的潜在类别潜变量模型,识别出 MaaS 存疑者与 MaaS 乐观者两类群体,转移意愿大于 0.576 者更可能成为 MaaS 乐观者,并总结出两类人群异质的套餐订阅选择偏好。灵敏度与弹性分析表明,缩短 MaaS 选项的出行时间可有效提升转移意愿且类别 1 更为敏感;两类用户对套餐价格均不甚敏感,服务品质等非价格因素对套餐订阅同样关键。

(4) 构建了 MaaS 多阶段采纳意愿的一体化建模框架

分阶段建模虽能精细刻画各阶段的选择行为与人群画像,但缺乏对多阶段间行为偏好转移的刻画能力,难以为全周期干预优先级提供依据。为此,本文进一步从一体化建模视角展开研究,以克服分阶段建模难以捕捉跨阶段行为状态转移的局限。构建了结合 MIMIC 模型的隐马尔可夫建模框架,以统一的似然函数联合刻画初始状态形成、单次出行选择、跨阶段状态转移与套餐订阅选择四个相互衔接的过程,模型拟合良好(调整后 McFadden ρ^2 为 0.200)。估计结果识别出贯穿采纳全周期的费用敏感型与时间敏感型两种行为状态(初始占比分别为 63.4% 与 36.6%),并揭示了体验驱动的状态转移机理:单次出行阶段体验到更高费用节省的用户更可能转入或保持费用敏感型状态,体验到更高时间节省的用户则更可能转入时间敏感型状态。全周期聚合弹性分析表明,单次出行阶段轨道交通车内时间的聚合弹性最大(-0.521),价格因素虽对 MaaS 套餐订阅有显著影响,但作用有限。建模范式对比结果表明,分阶段建模长于获得各阶段的选择模型与阶段内精细的人群画像,一体化建模长于刻画跨阶段转移机理与全周期干预优先级,二

者相互补充，共同为推广策略仿真提供了微观行为依据。

(5) 提出了面向超大城市 MaaS 推广的多目标策略仿真优化方法

针对既有研究多局限于单一策略或少量预设场景、城市级仿真难以直接用于策略寻优的问题，本文构建了融合认知扩散、多阶段采纳与订阅留存机制的 MaaS 采纳多智能体仿真模型，以第5章估计的行为模型驱动智能体决策，以引入空间网络效应的 Bass 扩散刻画认知传播，建立了涵盖套餐设计、套餐定价、营销投入、服务水平的动态策略空间以及用户采纳率、平台净收入与碳减排三目标评价体系。为突破昂贵仿真下的评估瓶颈，构建了混合解析代理与深度学习代理两类代理模型，并通过解析先验预训练和观测样本条件推断提高深度学习代理的小样本预测能力。进一步提出两类代理模型的反向求解方法，并将其嵌入基于信赖域机制的多目标优化算法辅助策略寻优。小规模算例实验结果表明，当训练样本预算分别设置为低预算档和高预算档位时，深度学习代理模型城市级总体 NMAE 分别为 3.61% 和 3.01%，均明显低于混合解析代理。高预算下所得 Pareto 近似解集的最终超体积较混合解析方法提高 8.54%。北京市居民出行调查小规模算例与城市级虚拟人口大规模算例结果表明，提高用户采纳率、平台盈利与碳减排依赖差异化的阶段配置、空间配置和成本结构，生成的 Pareto 前沿策略为决策者依据目标偏好选择 MaaS 推广策略提供了量化依据。

8.2 创新点

本文的创新点包括以下四个方面：

(1) 提出了可支撑大规模家庭级人口合成的分层扩散模型。为克服既有方法难以兼顾高维属性联合分布与可变家庭结构的问题，提出以家庭画像压缩生成空间、以异质图表征成员关系的分层扩散模型，并设计能量引导的多空间尺度边际分布对齐方法，提出结合变分自编码器与贝叶斯网络甄别样本零与结构零。基于北京市数据的验证结果表明，提出的模型在全部属性组合维度上均优于基准模型，能够合成属性联合分布真实、家庭结构合理且多尺度边际吻合的全市家庭级虚拟人口。

(2) 提出了考虑家庭联合活动的家庭活动计划生成方法。为克服既有研究以个体为生成单元、难以再现家庭联合活动并保障资源硬约束的问题，提出融合家庭-成员特征的多任务编码器和考虑家庭联合活动的解码器，结合考虑空间异质性目的地选择层生成家庭活动计划；进一步，将多成员活动协调建模为纳什议价问题，以保障家庭活动计划的合理性。实验结果表明，提出的方法在严格满足车辆可用性等硬约束的前提下，生成数据与既有数据的误差约为最优基准模型的 1/15，目的地分布与真实分布高度近似，表明模型能够生成家庭内部活动协调且空间精

度较高的家庭级活动计划。

(3) 提出了贯通单次出行—套餐订阅全过程的 MaaS 多阶段采纳意愿建模方法体系。为填补既有研究孤立考察单一采纳阶段、难以刻画阶段间内在联系的欠缺,设计两步式 SP 调查,并提出分阶段与一体化两种建模范式。在分阶段建模方法下,构建单次出行阶段的混合潜在分类模型,将转移意愿作为初始印象的度量,并据此构建考虑属性无视的套餐订阅潜在分类模型;在一体化建模方法下,构建结合 MIMIC 模型的隐马尔可夫框架,联合刻画初始状态形成、单次出行选择、跨阶段状态转移与套餐订阅选择。基于北京市调查数据的标定结果表明,所提方法能够识别差异化的用户群体与行为状态,验证初始印象的效用迁移机制与体验驱动的状态转移机理,并分析了两种建模范式的差异化优势与适用边界。

(4) 提出了基于多智能体仿真的超大城市 MaaS 推广策略的优化方法。为克服城市级多智能体仿真成本高、难以直接用于策略寻优的问题,提出具有小样本学习与持续学习能力的深度学习代理模型,并通过盒稳定训练、中心冻结与边界收紧,将其转化为混合整数规划问题,实现全局最优的候选策略反向求解;进一步,将反向求解嵌入基于信赖域机制的多目标优化算法,逐步逼近 Pareto 前沿。算例结果表明,深度学习代理在低、高预算下的总体 NMAE 较低且具有较好的寻优性能,验证了所提方法在有限仿真预算下开展多目标推广策略寻优的有效性。

8.3 研究展望

本文以超大城市 MaaS 推广策略的科学制定为目标,深入研究了家庭级人口合成、家庭活动计划生成、MaaS 多阶段采纳意愿建模与多目标推广策略优化等内容。虽然已经取得了一些研究成果,但仍存在如下问题值得进一步深入探讨:

(1) 基于真实运营数据的行为模型动态校准

本文的采纳行为模型基于两步式 SP 调查数据标定。在 MaaS 渗透率较低、缺乏大规模真实使用记录的背景下,SP 调查是获取多阶段采纳行为数据的必要途径,但陈述偏好与真实行为之间可能存在偏差。随着国内 MaaS 试点的持续推进,平台的注册、订单与订阅续费等显示偏好数据将逐步积累。未来可研究 SP 与 RP 数据的融合估计方法,对行为模型的偏好参数进行动态校准与迭代更新,并检验本文所得结论在真实运营场景中的有效性。

(2) 订阅后全生命周期行为的精细建模

本文将行为建模聚焦于 MaaS 发展初期的单次转移与套餐订阅两个阶段,订阅之后的留存与流失在仿真中仅以简化的满意度机制刻画,套餐升级与降级等行为未纳入研究范围。而 MaaS 平台的可持续运营在很大程度上取决于用户的长期留存。未来可依托面板调查或平台运营数据,对留存、流失、复订与套餐调整等订

阅后行为进行精细建模，并将其嵌入仿真模型，将策略评估的时间尺度由推广导入期延伸至成熟运营期。

（3）需求侧与供给侧推广策略的联合优化

本文的推广策略优化限定于定价、补贴与营销等需求侧维度，多模式网络的服务水平在仿真中给定。而推广策略改变出行方式结构之后，将反过来影响各方式的拥挤程度与服务水平。线网布局、运力配置与时刻表等供给侧资源的协同调整，同样也能放大需求侧策略的推广效果。未来可将供给侧优化变量纳入统一的优化框架，研究供需互动反馈下的联合优化问题，以期得到系统层面更优的推广方案。

（4）基于运营数据的仿真模型有效性验证

本文的仿真规则与参数主要依据调查数据、合成活动计划和既有研究构建，现阶段验证侧重于模型内部一致性及输出结果的合理性，模型对真实 MaaS 运营情境的再现能力仍需通过长期运营数据进一步检验。未来应从结果真实性和过程真实性两个层面开展验证。在结果层面，可利用平台运营记录、用户调查、出行轨迹及财务数据，将仿真得到的采纳率、套餐选择、续订与流失、平台收入与成本、出行方式转移和碳减排等指标，与真实系统在不同阶段、区域和用户群体中的观测结果进行对比，并通过跨时期和跨区域的样本检验模型的有效性。在过程层面，应重点验证用户由认知、试用到订阅，以及续订和退订的状态转移过程，比较仿真与真实运营数据中的转化概率、状态持续时间、用户异质性和空间扩散特征。通过验证仿真模型在结果和行为过程两个层面的真实性，以期为推广策略评估与政策分析提供更加可靠的依据。

参考文献

- [1] HIETANEN S. Mobility as a Service [J]. the new transport model, 2014, 12(2): 2-4.
- [2] JITTRAPIROM P, CAIATI V, FENERI A M, et al. Mobility as a service: A critical review of definitions, assessments of schemes, and key challenges [J]. Urban Planning, 2017, 2(2): 13-25. DOI: 10.17645/up.v2i2.931.
- [3] KAMARGIANNI M, LI W, MATYAS M, et al. A Critical Review of New Mobility Services for Urban Transport [J]. Transportation Research Procedia, 2016, 14: 3294-3303. DOI: 10.1016/J.TRPRO.2016.05.277.
- [4] WONG Y Z, HENSHER D A, MULLEY C. Mobility as a service (MaaS): Charting a future context [J]. Transportation Research Part A: Policy and Practice, 2020, 131: 5-19. DOI: 10.1016/j.tra.2019.09.030.
- [5] HENSHER D A. The future of mobility as a service [J]. Transportation Planning and Technology, 2024: 1-4. DOI: 10.1080/03081060.2024.2356619.
- [6] SOCHOR J, STRÖMBERG H, KARLSSON I M. The added value of a new, innovative travel service: Insights from the UbiGo field operational test in Gothenburg, Sweden [C]//Internet of Things. IoT Infrastructures: First International Summit, IoT360 2014, Rome, Italy, October 27-28, 2014, Revised Selected Papers, Part II 1. Springer, 2015: 169-175.
- [7] SOCHOR J, KARLSSON I M, STRÖMBERG H. Trying out mobility as a service: Experiences from a field trial and implications for understanding demand [J]. Transportation Research Record, 2016, 2542(1): 57-64. DOI: 10.3141/2542-07.
- [8] SOCHOR J, ARBY H, KARLSSON I C A, et al. A topological approach to Mobility as a Service: A proposed tool for understanding requirements and effects, and for aiding the integration of societal goals [J]. Research in Transportation Business & Management, 2018, 27: 3-14. DOI: 10.1016/J.RTBM.2018.12.003.
- [9] SMITH T. Mobility startup MaaS Global files for bankruptcy [J]. Sifted, 2024.
- [10] HENSHER D, HO C, MULLEY C, et al. MaaS trials—What have we learnt? [M]//2020: 59-75. DOI: 10.1016/B978-0-12-820044-5.00004-X.
- [11] HO C Q, HENSHER D A, MULLEY C, et al. Potential uptake and willingness-to-pay for Mobility as a Service (MaaS): A stated choice study [J]. Transportation Research Part A: Policy and Practice, 2018, 117(March): 302-318. DOI: 10.1016/j.tra.2018.08.025.
- [12] HENSHER D A, HIETANEN S. Mobility as a feature (MaaS): rethinking the focus of the second generation of mobility as a service (MaaS) [J]. Transport Reviews, 2023, 43(3): 325-329. DOI: 10.1080/01441647.2022.2159122.
- [13] ENOCH M, POTTER S. MaaS (Mobility as a Service) market futures explored [J]. Transport Policy, 2023, 134: 31-40. DOI: 10.1016/J.TRANPOL.2023.02.007.
- [14] HO C Q, HENSHER D A, RECK D J, et al. MaaS bundle design and implementation: Lessons

- from the Sydney MaaS trial [J]. *Transportation Research Part A: Policy and Practice*, 2021, 149(May): 339-376. DOI: 10.1016/j.tra.2021.05.010.
- [15] BECKMAN R J, BAGGERLY K A, MCKAY M D. Creating synthetic baseline populations [J]. *Transportation Research Part A: Policy and Practice*, 1996, 30(6): 415-429. DOI: 10.1016/0965-8564(96)00004-3.
- [16] MÜLLER K, AXHAUSEN K W. Population synthesis for microsimulation: State of the art [J]. *Arbeitsberichte Verkehrs-und Raumplanung*, 2010, 638.
- [17] NGUYEN N A, SCHWEIZER J, RUPI F. Large-scale activity-based demand generation modeling: A literature review and exploration of potential approaches [J]. *Transportation Engineering*, 2025, 20: 100329. DOI: 10.1016/j.treng.2025.100329.
- [18] LA D M, V, Hai L., K, Liton, et al. Population synthesis: a problem-based review [J]. *Transport Reviews*, 2025, 45(3): 366-389. DOI: 10.1080/01441647.2025.2469069.
- [19] SUN L, ERATH A, CAI M. A hierarchical mixture modeling framework for population synthesis [J]. *Transportation Research Part B: Methodological*, 2018, 114: 199-212. DOI: 10.1016/j.trb.2018.06.002.
- [20] DEMING W E, STEPHAN F F. On a least squares adjustment of a sampled frequency table when the expected marginal totals are known [J]. *The Annals of Mathematical Statistics*, 1940, 11(4): 427-444. DOI: 10.1214/aoms/1177731829.
- [21] VOAS D, WILLIAMSON P. An evaluation of the combinatorial optimisation approach to the creation of synthetic microdata [J]. *International Journal of Population Geography*, 2000, 6(5): 349-366. DOI: 10.1002/1099-1220(200009/10)6:5<349::AID-IJPG196>3.0.CO;2-5.
- [22] YE X, KONDURI K, PENDYALA R M, et al. A methodology to match distributions of both household and person attributes in the generation of synthetic populations [C]//88th Annual Meeting of the Transportation Research Board, Washington, DC: Vol. 36. 2009.
- [23] PRITCHARD D R, MILLER E J. Advances in population synthesis: fitting many attributes per agent and fitting to household and person margins simultaneously [J]. *Transportation*, 2012, 39(3): 685-704. DOI: 10.1007/s11116-011-9367-4.
- [24] BARTHELEMY J, TOINT P L. Synthetic Population Generation Without a Sample [J]. *Transportation Science*, 2013, 47(2): 266-279. DOI: 10.1287/trsc.1120.0408.
- [25] KONDURI K C, YOU D, GARIKAPATI V M, et al. Enhanced synthetic population generator that accommodates control variables at multiple geographic resolutions [J]. *Transportation Research Record*, 2016, 2563(1): 40-50. DOI: 10.3141/2563-08.
- [26] KHACHMAN M, MORENCY C, CIARI F. Integrated multiresolution framework for spatialized population synthesis [J]. *Transportation*, 2024, 51(3): 823-852. DOI: 10.1007/s11116-022-10358-w.
- [27] FAROOQ B, BIERLAIRE M, HURTUBIA R, et al. Simulation based population synthesis [J]. *Transportation Research Part B: Methodological*, 2013, 58: 243-263. DOI: 10.1016/j.trb.2013.09.012.
- [28] SUN L, ERATH A. A Bayesian network approach for population synthesis [J]. *Transportation*

- Research Part C: Emerging Technologies, 2015, 61: 49-62. DOI: 10.1016/j.trc.2015.10.010.
- [29] SAADI I, MUSTAFA A, TELLER J, et al. Hidden Markov Model-based population synthesis [J]. Transportation Research Part B: Methodological, 2016, 90: 1-21. DOI: 10.1016/j.trb.2016.04.007.
- [30] BORYSOV S S, RICH J, PEREIRA F C. How to generate micro-agents? A deep generative modeling approach to population synthesis [J]. Transportation Research Part C: Emerging Technologies, 2019, 106: 73-97. DOI: 10.1016/j.trc.2019.07.006.
- [31] GARRIDO S, BORYSOV S S, PEREIRA F C, et al. Prediction of rare feature combinations in population synthesis: Application of deep generative modelling [J]. Transportation Research Part C: Emerging Technologies, 2020, 120: 102787. DOI: 10.1016/j.trc.2020.102787.
- [32] KIM E J, BANSAL P. A deep generative model for feasible and diverse population synthesis [J]. Transportation Research Part C: Emerging Technologies, 2023, 148: 104053. DOI: 10.1016/j.trc.2023.104053.
- [33] KANG J, KIM Y, IMRAN M M, et al. Generating Population Synthesis Using a Diffusion Model [C]//2023 Winter Simulation Conference (WSC). 2023: 2944-2955. DOI: 10.1109/WSC60868.2023.10408335.
- [34] Jutras-Dubé P, Al-Khasawneh M B, YANG Z, et al. Copula-based transferable models for synthetic population generation [J]. Transportation Research Part C: Emerging Technologies, 2024, 169: 104830. DOI: 10.1016/j.trc.2024.104830.
- [35] KUKIC M, LI X, BIERLAIRE M. One-step Gibbs sampling for the generation of synthetic households [J]. Transportation Research Part C: Emerging Technologies, 2024, 166: 104770. DOI: 10.1016/j.trc.2024.104770.
- [36] LIM S Y, YUN H, BANSAL P, et al. A Large Language Model for Feasible and Diverse Population Synthesis: arXiv:2505.04196 [Z]. 2025. arXiv: 2505.04196.
- [37] GUO J Y, BHAT C R. Population synthesis for microsimulating travel behavior [J]. Transportation Research Record, 2007, 2014(1): 92-101. DOI: 10.3141/2014-12.
- [38] LOVELACE R, BALLAS D. ‘Truncate, replicate, sample’: A method for creating integer weights for spatial microsimulation [J]. Computers, Environment and Urban Systems, 2013, 41: 1-11. DOI: 10.1016/j.compenvurbsys.2013.03.004.
- [39] 诸葛承祥. 基于自组织理论的城市交通和土地利用动态演化机理研究 [D]. 北京交通大学, 2014.
- [40] Badu-Marfo G, FAROOQ B, PATTERSON Z. Composite Travel Generative Adversarial Networks for Tabular and Sequential Population Synthesis [J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(10): 17976-17985. DOI: 10.1109/TITS.2022.3168232.
- [41] AEMMER Z, MACKENZIE D. Generative population synthesis for joint household and individual characteristics [J]. Computers, Environment and Urban Systems, 2022, 96: 101852. DOI: 10.1016/j.compenvurbsys.2022.101852.
- [42] BORISOV V, SEBLER K, LEEMANN T, et al. Language Models are Realistic Tabular Data Generators: arXiv:2210.06280 [Z]. 2023. arXiv: 2210.06280.

- [43] 唐嘉. 基于深度生成模型和多源数据的高空间分辨率合成人口研究 [D]. 西南财经大学, 2024.
- [44] HU Z, XIAO Z, XIONG M, et al. Population-Aligned Persona Generation for LLM-based Social Simulation: arXiv:2509.10127 [Z]. 2025. arXiv: 2509.10127.
- [45] CASTIGLIONE J, BRADLEY M, GLIEBE J. Activity-based travel demand models: A primer: SHRP 2 Report S2-C46-RR-1 [M]. 2015.
- [46] LIAO X, JIANG Q, HE B Y, et al. Deep Activity Model: A Generative Approach for Human Mobility Pattern Synthesis: arXiv:2405.17468 [Z]. 2024. arXiv: 2405.17468.
- [47] RASOULI S, TIMMERMANS H. Activity-based models of travel demand: promises, progress and prospects [J]. *International Journal of Urban Sciences*, 2014, 18(1): 31-60. DOI: 10.1080/12265934.2013.835118.
- [48] BOWMAN J L, Ben-Akiva M E. Activity-based disaggregate travel demand model system with activity schedules [J]. *Transportation Research Part A: Policy and Practice*, 2001, 35(1): 1-28. DOI: 10.1016/S0965-8564(99)00043-9.
- [49] BRADLEY M, VOVSHA P. A model for joint choice of daily activity pattern types of household members [J]. *Transportation*, 2005, 32(5): 545-571. DOI: 10.1007/s11116-005-5761-0.
- [50] MILLER E J, ROORDA M J, CARRASCO J A. A tour-based model of travel mode choice [J]. *Transportation*, 2005, 32(4): 399-422. DOI: 10.1007/s11116-004-7962-3.
- [51] BHAT C R. The multiple discrete-continuous extreme value (MDCEV) model: Role of utility function parameters, identification considerations, and model extensions [J]. *Transportation Research Part B: Methodological*, 2008, 42(3): 274-303. DOI: 10.1016/j.trb.2007.06.002.
- [52] FU X, LAM W H K. Modelling joint activity-travel pattern scheduling problem in multi-modal transit networks [J]. *Transportation*, 2018, 45(1): 23-49. DOI: 10.1007/s11116-016-9720-8.
- [53] KHAN N A, HABIB M A. Microsimulation of activity generation, activity scheduling and shared travel choices within an activity-based travel demand modelling system [J]. *Travel Behaviour and Society*, 2023, 32: 100590. DOI: 10.1016/j.tbs.2023.100590.
- [54] POUGALA J, HILLEL T, BIERLAIRE M. OASIS: Optimisation-based Activity Scheduling with Integrated Simultaneous choice dimensions [J]. *Transportation Research Part C: Emerging Technologies*, 2023, 155: 104291. DOI: 10.1016/j.trc.2023.104291.
- [55] REZVANY N, BIERLAIRE M, HILLEL T. Simulating intra-household interactions for in- and out-of-home activity scheduling [J]. *Transportation Research Part C: Emerging Technologies*, 2023, 157: 104362. DOI: 10.1016/j.trc.2023.104362.
- [56] LEE H, BANSAL P, VO K D, et al. Collaborative generative adversarial networks for fusing household travel survey and smart card data to generate heterogeneous activity schedules in urban digital twins [J]. *Transportation Research Part C: Emerging Technologies*, 2025, 176: 105125. DOI: 10.1016/j.trc.2025.105125.
- [57] Eric Miller. The current state of activity-based travel demand modelling and some possible next steps [J]. *Transport Reviews*, 2023, 43(4): 565-570. DOI: 10.1080/01441647.2023.2198458.
- [58] HAGHIGHI M, MILLER E J. Week-long activity-based modelling: a review of the existing

- models and datasets and a comprehensive conceptual framework [J]. *Transport Reviews*, 2025, 45(1): 119-148. DOI: 10.1080/01441647.2024.2416652.
- [59] TIMMERMANS H J P, ZHANG J. Modeling household activity travel behavior: Examples of state of the art modeling approaches and research agenda [J]. *Transportation Research Part B: Methodological*, 2009, 43(2): 187-190. DOI: 10.1016/j.trb.2008.06.004.
- [60] GHADER S, CARRION C, TANG L, et al. A copula-based continuous cross-nested logit model for tour scheduling in activity-based travel demand models [J]. *Transportation Research Part B: Methodological*, 2021, 145: 324-341. DOI: 10.1016/j.trb.2021.01.001.
- [61] HASNINE M S, NURUL HABIB K. Tour-based mode choice modelling as the core of an activity-based travel demand modelling framework: A review of state-of-the-art [J]. *Transport Reviews*, 2021, 41(1): 5-26. DOI: 10.1080/01441647.2020.1780648.
- [62] JIN Z, BANSAL P, AXHAUSEN K. A novel approach to study the role of social networks in planning joint leisure activities [J]. *Transportation Research Part A: Policy and Practice*, 2025, 192: 104371. DOI: 10.1016/j.tra.2024.104371.
- [63] FU X, L, William H.K., C, Bi Yu, et al. Maximizing space-time accessibility in multi-modal transit networks: an activity-based approach [J]. *Transportmetrica A: Transport Science*, 2022, 18(2): 192-220. DOI: 10.1080/23249935.2020.1806372.
- [64] TOAZA B, Esztergár-Kiss D. Assessment of the activity scheduling optimization method using real travel data [J]. *Transportation*, 2024. DOI: 10.1007/s11116-023-10456-3.
- [65] BALMER M, RIESER M, MEISTER K, et al. MATSim-T: Architecture and simulation times [M]//Multi-Agent Systems for Traffic and Transportation Engineering. IGI Global, 2009: 57-78.
- [66] ZHUGE C, BITHELL M, SHAO C, et al. An improvement in MATSim computing time for large-scale travel behaviour microsimulation [J]. *Transportation*, 2021, 48(1): 193-214. DOI: 10.1007/s11116-019-10048-0.
- [67] ALLAHVIRANLOO M, RECKER W. Daily activity pattern recognition by using support vector machines with multiple classes [J]. *Transportation Research Part B: Methodological*, 2013, 58: 16-43. DOI: 10.1016/j.trb.2013.09.008.
- [68] HAFEZI M H, DAISY N S, MILLWARD H, et al. Ensemble learning activity scheduler for activity based travel demand models [J]. *Transportation Research Part C: Emerging Technologies*, 2021, 123: 102972. DOI: 10.1016/j.trc.2021.102972.
- [69] KIM E J, KIM D K, SOHN K. Imputing qualitative attributes for trip chains extracted from smart card data using a conditional generative adversarial network [J]. *Transportation Research Part C: Emerging Technologies*, 2022, 137: 103616. DOI: 10.1016/j.trc.2022.103616.
- [70] TAN R, XUE J, TSUBOUCHI K, et al. MoE-TransMov: A Transformer-based Model for Next POI Prediction in Familiar & Unfamiliar Movements: arXiv:2512.17985 [Z]. 2025. arXiv: 2512.17985.
- [71] HONG Y, ZHANG Y, SCHINDLER K, et al. Context-aware multi-head self-attentional neural network model for next location prediction [J]. *Transportation Research Part C: Emerging*

- Technologies, 2023, 156: 104315. DOI: 10.1016/j.trc.2023.104315.
- [72] LIANG Y, LIU Y, WANG X, et al. Exploring large language models for human mobility prediction under public events [J]. Computers, Environment and Urban Systems, 2024, 112: 102153. DOI: 10.1016/j.compenvurbsys.2024.102153.
- [73] GONG L, LIN Y, ZHANG X, et al. Mobility-LLM: Learning Visiting Intentions and Travel Preferences from Human Mobility Data with Large Language Models: arXiv:2411.00823 [Z]. 2024. arXiv: 2411.00823.
- [74] KAMARGIANNI M, LI W, MATYAS M. A comprehensive review of “Mobility as a Service” systems [M]. The National Academies of Sciences, Engineering, and Medicine, 2016.
- [75] MULLEY C, NELSON J D, HO C, et al. MaaS in a regional and rural setting: Recent experience [J]. Transport Policy, 2023, 133: 75-85. DOI: 10.1016/j.tranpol.2023.01.014.
- [76] HENSHER D A, HO C Q, RECK D J. Mobility as a service and private car use: Evidence from the Sydney MaaS trial [J]. Transportation Research Part A: Policy and Practice, 2021, 145: 17-33. DOI: 10.1016/J.TRA.2020.12.015.
- [77] HO C Q, HENSHER D A, RECK D J. Drivers of participant’s choices of monthly mobility bundles: Key behavioural findings from the Sydney Mobility as a Service (MaaS) trial [J]. Transportation Research Part C: Emerging Technologies, 2021, 124: 102932. DOI: 10.1016/J.TRC.2020.102932.
- [78] KRISWARDHANA W, Esztergár-Kiss D. Exploring the aspects of MaaS adoption based on college students’ preferences [J]. Transport Policy, 2023, 136(August 2022): 113-125. DOI: 10.1016/j.tranpol.2023.03.018.
- [79] Alonso-González M J, Hoogendoorn-Lanser S, van Oort N, et al. Drivers and barriers in adopting Mobility as a Service (MaaS) – A latent class cluster analysis of attitudes [J]. Transportation Research Part A: Policy and Practice, 2020, 132(November 2019): 378-401. DOI: 10.1016/j.tra.2019.11.022.
- [80] Lopez-Carreiro I, MONZON A, LOIS D, et al. Are travellers willing to adopt MaaS? Exploring attitudinal and personality factors in the case of Madrid, Spain [J]. Travel Behaviour and Society, 2021, 25(August 2020): 246-261. DOI: 10.1016/j.tbs.2021.07.011.
- [81] ZIJLSTRA T, DURAND A, Hoogendoorn-Lanser S, et al. Early adopters of Mobility-as-a-Service in the Netherlands [J]. Transport Policy, 2020, 97: 197-209. DOI: 10.1016/J.TRANPOL.2020.07.019.
- [82] van ’t Veer R, ANNEMA J A, ARAGHI Y, et al. Mobility-as-a-Service (MaaS): A latent class cluster analysis to identify Dutch vehicle owners’ use intention [J]. Transportation Research Part A: Policy and Practice, 2023, 169: 103608. DOI: 10.1016/J.TRA.2023.103608.
- [83] VIJ A, RYAN S, SAMPSON S, et al. Consumer preferences for Mobility-as-a-Service (MaaS) in Australia [J]. Transportation Research Part C: Emerging Technologies, 2020, 117: 102699. DOI: 10.1016/j.trc.2020.102699.
- [84] FIOREZE T, de Gruijter M, GEURS K. On the likelihood of using Mobility-as-a-Service: A case study on innovative mobility services among residents in the Netherlands [J]. Case Studies

- on Transport Policy, 2019, 7(4): 790-801. DOI: 10.1016/j.cstp.2019.08.002.
- [85] SCHIKOFSKY J, DANNEWALD T, KOWALD M. Exploring motivational mechanisms behind the intention to adopt mobility as a service (MaaS): Insights from Germany [J]. Transportation Research Part A: Policy and Practice, 2020, 131: 296-312. DOI: 10.1016/j.tra.2019.09.022.
- [86] KIM S, RASOULI S. The influence of latent lifestyle on acceptance of Mobility-as-a-Service (MaaS): A hierarchical latent variable and latent class approach [J]. Transportation Research Part A: Policy and Practice, 2022, 159(March): 304-319. DOI: 10.1016/j.tra.2022.03.020.
- [87] KIM Y, KIM E J, JANG S, et al. A comparative analysis of the users of private cars and public transportation for intermodal options under Mobility-as-a-Service in Seoul [J]. Travel Behaviour and Society, 2021, 24(August 2020): 68-80. DOI: 10.1016/j.tbs.2021.03.001.
- [88] MATOWICKI M, AMORIM M, KERN M, et al. Understanding the potential of MaaS – An European survey on attitudes [J]. Travel Behaviour and Society, 2022, 27(February): 204-215. DOI: 10.1016/j.tbs.2022.01.009.
- [89] KRAUSS K, KRAIL M, AXHAUSEN K W. What drives the utility of shared transport services for urban travellers? A stated preference survey in German cities [J]. Travel Behaviour and Society, 2022, 26(April 2021): 206-220. DOI: 10.1016/j.tbs.2021.09.010.
- [90] RECK D J, HENSHER D A, HO C Q. MaaS bundle design [J]. Transportation Research Part A: Policy and Practice, 2020, 141: 485-501. DOI: 10.1016/J.TRA.2020.09.021.
- [91] MATYAS M, KAMARGIANNI M. Survey design for exploring demand for Mobility as a Service plans [J]. Transportation, 2019, 46(5): 1525-1558. DOI: 10.1007/s11116-018-9938-8.
- [92] CAIATI V, RASOULI S, TIMMERMANS H. Bundling, pricing schemes and extra features preferences for mobility as a service: Sequential portfolio choice experiment [J]. Transportation Research Part A: Policy and Practice, 2020, 131(September 2019): 123-148. DOI: 10.1016/j.tra.2019.09.029.
- [93] GUIDON S, WICKI M, BERNAUER T, et al. Transportation service bundling – For whose benefit? Consumer valuation of pure bundling in the passenger transportation market [J]. Transportation Research Part A: Policy and Practice, 2020, 131: 91-106. DOI: 10.1016/j.tra.2019.09.023.
- [94] Esztergár-Kiss D, KERÉNYI T. Creation of mobility packages based on the MaaS concept [J]. Travel Behaviour and Society, 2020, 21: 307-317. DOI: 10.1016/j.tbs.2019.05.007.
- [95] KRAUSS K, RECK D J, AXHAUSEN K W. How does transport supply and mobility behaviour impact preferences for MaaS bundles? A multi-city approach [J]. Transportation Research Part C: Emerging Technologies, 2023, 147: 104013. DOI: 10.1016/J.TRC.2023.104013.
- [96] HO C, HENSHER DA, MULLEY C, et al. Prospects for switching out of conventional transport services to mobility as a service subscription plans—A stated choice study [C]//International Conference Series on Competition and Ownership in Land Passenger Transport (Thredbo 15). Stockholm, Sweden. 2017.
- [97] HO C Q, MULLEY C, HENSHER D A. Public preferences for mobility as a service: Insights

- from stated preference surveys [J]. *Transportation Research Part A: Policy and Practice*, 2020, 131: 70-90. DOI: 10.1016/J.TRA.2019.09.031.
- [98] LILJAMO T, LIIMATAINEN H, PÖLLÄNEN M, et al. People's current mobility costs and willingness to pay for Mobility as a Service offerings [J]. *Transportation Research Part A: Policy and Practice*, 2020, 136: 99-119. DOI: 10.1016/j.tra.2020.03.034.
- [99] TSOUROS I, TSIRIMPA A, PAGONI I, et al. MaaS users: Who they are and how much they are willing-to-pay [J]. *Transportation Research Part A: Policy and Practice*, 2021, 148: 470-480. DOI: 10.1016/j.tra.2021.04.016.
- [100] POLYDOROPOULOU A, TSOUROS I, PAGONI I, et al. Exploring Individual Preferences and Willingness to Pay for Mobility as a Service [J]. *Transportation Research Record*, 2020, 2674(11): 152-164. DOI: 10.1177/0361198120938054.
- [101] MULLEY C, HO C, BALBONTIN C, et al. Mobility as a service in community transport in Australia: Can it provide a sustainable future? [J]. *Transportation Research Part A: Policy and Practice*, 2020, 131: 107-122. DOI: 10.1016/J.TRA.2019.04.001.
- [102] Bahamonde-Birke F J, FROWIJN L, van Gils C, et al. Am I willing to replace my car with a MaaS subscription? An analysis of the willingness of Dutch citizens to adopt MaaS and the triggers affecting their choices [J]. *Transportation Research Part A: Policy and Practice*, 2023, 176: 103816. DOI: 10.1016/j.tra.2023.103816.
- [103] CISTERNA C, BIGI F, NAKAO H, et al. Assessing the willingness to pay for Mobility-as-A-Service: An Agent-Based approach [J]. *Case Studies on Transport Policy*, 2024, 17: 101221. DOI: 10.1016/j.cstp.2024.101221.
- [104] MATYAS M, KAMARGIANNI M. Investigating heterogeneity in preferences for Mobility-as-a-Service plans through a latent class choice model [J]. *Travel Behaviour and Society*, 2021, 23(October 2020): 143-156. DOI: 10.1016/j.tbs.2020.12.002.
- [105] MATYAS M, KAMARGIANNI M. The potential of mobility as a service bundles as a mobility management tool [J]. *Transportation*, 2019, 46: 1951-1968. DOI: 10.1007/s11116-018-9913-4.
- [106] WANG B, YANG M, FENG T, et al. Heterogeneous choice of personalized Mobility-as-a-Service bundles and its impact on sustainable transportation [J]. *Transportation Research Part D: Transport and Environment*, 2024, 131: 104224. DOI: 10.1016/j.trd.2024.104224.
- [107] CHEN C F, FU C, CHEN Y C. Exploring tourist preference for Mobility-as-a-Service (MaaS) – A latent class choice approach [J]. *Transportation Research Part A: Policy and Practice*, 2023, 174: 103750. DOI: 10.1016/j.tra.2023.103750.
- [108] LIU J, JIAN S, WU C, et al. Risky choice and diminishing sensitivity in MaaS context: A nonlinear logit analysis of traveler behavior [J]. *Transportation Research Part C: Emerging Technologies*, 2024, 162: 104603. DOI: 10.1016/j.trc.2024.104603.
- [109] CHEN C F, CHEN Y X. Investigating the effects of platform and mobility on mobility as a service (MaaS) users' service experience and behavioral intention: empirical evidence from MeNGo, Kaohsiung [J]. *Transportation*, 2023, 50(6): 2299-2318. DOI:

- 10.1007/s11116-022-10309-5.
- [110] KRISWARDHANA W, Esztergár-Kiss D. The role of intermodality and environmental consciousness in the preferences for MaaS bundles: A hybrid choice modeling approach [J]. *Transportation Research Part A: Policy and Practice*, 2025, 191: 104332. DOI: 10.1016/j.tra.2024.104332.
- [111] COPPOLA P, SILVESTRI F, PASTORELLI L. Mobility as a Service (MaaS) for university communities: Modeling preferences for integrated public transport bundles [J]. *Travel Behaviour and Society*, 2025, 38: 100890. DOI: 10.1016/j.tbs.2024.100890.
- [112] SILVESTRI F, SILVESTRI F, COPPOLA P. Mobility as a Service (MaaS) Bundle Uptake: a case study in Milan, Italy [J]. *European Transport Research Review*, 2025, 17(1): 3. DOI: 10.1186/s12544-024-00698-2.
- [113] CHEN C F, LU H H, TSAI W L. Investigating the unobserved heterogeneity in passenger satisfaction with Mobility-as-a-Service (MaaS) bundles [J]. *Transportation Research Part F: Traffic Psychology and Behaviour*, 2025, 109: 50-63. DOI: 10.1016/j.trf.2024.11.026.
- [114] KRISWARDHANA W, Esztergár-Kiss D. Generational differences in the preferences for MaaS bundles [J]. *Journal of Transport Geography*, 2025, 126: 104256. DOI: 10.1016/j.jtrangeo.2025.104256.
- [115] HO C Q. Can MaaS change users' travel behaviour to deliver commercial and societal outcomes? [J]. *Transportation Research Part A*, 2021, 165(August 2021): 76-97. DOI: 10.1016/j.tra.2022.09.004.
- [116] ALI N, SAGMANLI S S, OUELHADJ D, et al. Monitoring and evaluation of travel behaviour change in mobility-as-a-service (MaaS) trials: Insights from a longitudinal study [J]. *Transport Policy*, 2025, 171: 996-1011. DOI: 10.1016/j.tranpol.2025.07.020.
- [117] STRÖMBERG H, MARIANNE KARLSSON I C, SOCHOR J, et al. Inviting travelers to the smorgasbord of sustainable urban transport: evidence from a MaaS field trial [J]. *Transportation*, 2018, 45: 1655-1670. DOI: 10.1007/s11116-018-9946-8.
- [118] LIU J, WU C, JIAN S, et al. Understanding the impact of occasional activities on travelers' preferences for mobility-as-a-service: A stated preference study [J]. *Travel Behaviour and Society*, 2023, 33: 100604. DOI: 10.1016/j.tbs.2023.100604.
- [119] YU C, DONG W, YE N, et al. Transitioning from incentive-based user acquisition to loyal retention on the mobility-as-a-service platform: A large-scale social experiment [J]. *Transportation Research Part E: Logistics and Transportation Review*, 2025, 203: 104363. DOI: 10.1016/j.tre.2025.104363.
- [120] YU J, MO D, ZHU Z, et al. A high-order hidden Markov model for dynamic decision analysis of multi-homing ride-sourcing drivers [J]. *Transportation Research Part C: Emerging Technologies*, 2023, 148: 104031. DOI: 10.1016/j.trc.2023.104031.
- [121] POLYDOROPOULOU A, PAGONI I, TSIRIMPA A, et al. Prototype business models for Mobility-as-a-Service [J]. *Transportation Research Part A: Policy and Practice*, 2020, 131: 149-162. DOI: 10.1016/j.tra.2019.09.035.

- [122] van den Berg V A, MEURS H, VERHOEF E T. Business models for Mobility as an Service (MaaS) [J]. *Transportation Research Part B: Methodological*, 2022, 157(February): 203-229. DOI: 10.1016/j.trb.2022.02.004.
- [123] VIJ A, DÜHR S. The commercial viability of Mobility-as-a-Service (MaaS): what's in it for existing transport operators, and why should governments intervene? [J]. *Transport Reviews*, 2022, 42(5): 695-716. DOI: 10.1080/01441647.2022.2028032.
- [124] KRAUS L, PROFF H, JEPPE A. Estimation of joint value in mobility as a service ecosystems under different orchestrator settings [J]. *European Transport Research Review*, 2023, 15(1): 25. DOI: 10.1186/s12544-023-00594-1.
- [125] XIAO Q, KANG J E. Service Bundle Sizing and Pricing for Mobility Services: Incorporating Elastic Demand and Fleet Operations [J]. *Service Science*, 2025, 17(4): 127-148. DOI: 10.1287/serv.2024.0127.
- [126] XI H, AUSSEL D, LIU W, et al. Single-leader multi-follower games for the regulation of two-sided mobility-as-a-service markets [J]. *European Journal of Operational Research*, 2022. DOI: 10.1016/j.ejor.2022.06.041.
- [127] XI H, LIU W, WALLER S T, et al. Incentive-compatible mechanisms for online resource allocation in Mobility-as-a-Service systems [J]. *Transportation Research Part B: Methodological*, 2023, 170: 119-147. DOI: 10.1016/j.trb.2023.02.011.
- [128] LIU B, CHOW J Y J. On-demand mobility-as-a-Service platform assignment games with guaranteed stable outcomes [J]. *Transportation Research Part B: Methodological*, 2024, 188: 103060. DOI: 10.1016/j.trb.2024.103060.
- [129] YAO R, MA X, ZHANG K. Mobility-as-a-service (MaaS) system as a multi-leader-multi-follower game: A single-level variational inequality (VI) formulation [J]. *Transportation Research Part C: Emerging Technologies*, 2026, 188: 105703. DOI: 10.1016/j.trc.2026.105703.
- [130] TANG J H C G, LIU J, CHEN A, et al. Exploring the potential adoption of Mobility-as-a-Service in Beijing: A spatial agent-based model [J]. *Transportation Research Part A: Policy and Practice*, 2025, 194: 104430. DOI: 10.1016/j.tra.2025.104430.
- [131] ZHANG Y, XU M. Promoting low carbon mobility: A case study of Beijing MaaS [J]. *International Journal of Sustainable Transportation*, 2025, 19(9): 800-814. DOI: 10.1080/15568318.2024.2443657.
- [132] CHEN C F, TSAI W L. A deeper look at the effects of the Mobility-as-a-Service (MaaS) service experience on brand loyalty and brand attachment: the roles of effort and seamlessness [J]. *Transport Policy*, 2026, 183: 104155. DOI: 10.1016/j.tranpol.2026.104155.
- [133] CHEN X, LU Y, WHITEHEAD J, et al. Investigating customers' typical longitudinal behavioural responses in a large-scale mobility-as-a-service trial [J]. *Transportation*, 2025: 1-25. DOI: 10.1007/s11116-025-10643-4.
- [134] WHANG J, DELBRACIO M, TALEBI H, et al. Deblurring via stochastic refinement [C]// *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2022: 16293-16303.

- [135] SOHN K, LEE H, YAN X. Learning structured output representation using deep conditional generative models [J]. *Advances in neural information processing systems*, 2015, 28.
- [136] MCINNES L, HEALY J, ASTELS S. Hdbscan: Hierarchical density based clustering. [J]. *J. Open Source Softw.*, 2017, 2(11): 205. DOI: 10.21105/joss.00205.
- [137] KING E M, RANDOLPH H L, FLORO M S, et al. Demographic, health, and economic transitions and the future care burden [J]. *World Development*, 2021, 140: 105371. DOI: 10.1016/j.worlddev.2020.105371.
- [138] VARJAKOSKI H, KOPONEN S, KOUVO A, et al. Age Diversity in Neighborhoods—A Mixed-Methods Approach Examining Older Residents and Community Wellbeing [J]. *International Journal of Environmental Research and Public Health*, 2023, 20(16): 6574. DOI: 10.3390/ijerph20166574.
- [139] ZHANG Y, ZHANG Y, ZHANG Y, et al. Examining the Relationship between Household Vehicle Ownership and Ridesharing Behaviors in the United States [J]. *Sustainability*, 2018, 10(8). DOI: 10.3390/su10082720.
- [140] NAKAYAMA T, SATO Y, MARUYAMA T. Comparing households with every member out-of-home in developing countries using travel surveys [J]. *Cities*, 2023, 139: 104351. DOI: 10.1016/j.cities.2023.104351.
- [141] HO J, JAIN A, ABBEEL P. Denoising Diffusion Probabilistic Models: arXiv:2006.11239 [Z]. 2020. arXiv: 2006.11239.
- [142] PEEBLES W, XIE S. Scalable Diffusion Models with Transformers: arXiv:2212.09748 [Z]. 2023. arXiv: 2212.09748.
- [143] SIMONOVSKY M, KOMODAKIS N. GraphVAE: Towards Generation of Small Graphs Using Variational Autoencoders: arXiv:1802.03480 [Z]. 2018. arXiv: 1802.03480.
- [144] JANG E, GU S, POOLE B. Categorical Reparameterization with Gumbel-Softmax: arXiv:1611.01144 [Z]. 2017. arXiv: 1611.01144.
- [145] HU Z, DONG Y, WANG K, et al. Heterogeneous Graph Transformer: arXiv:2003.01332 [Z]. 2020. arXiv: 2003.01332.
- [146] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal Loss for Dense Object Detection [C]//2017 IEEE International Conference on Computer Vision (ICCV). 2017: 2999-3007. DOI: 10.1109/ICCV.2017.324.
- [147] YU J, WANG Y, ZHAO C, et al. Freedom: Training-free energy-guided conditional diffusion model [C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 23174-23184.
- [148] LIU B, LIU X, JIN X, et al. Conflict-Averse Gradient Descent for Multi-task Learning: arXiv:2110.14048 [Z]. 2024. arXiv: 2110.14048.
- [149] KINGMA D P, WELLING M. Auto-Encoding Variational Bayes: arXiv:1312.6114 [Z]. 2022. arXiv: 1312.6114.
- [150] PEARL J. Probabilistic reasoning in intelligent systems: networks of plausible inference [M]. Elsevier, 2014.

- [151] LI L, JAMIESON K, DESALVO G, et al. Hyperband: A novel bandit-based approach to hyperparameter optimization [J]. *Journal of machine learning research*, 2018, 18(185): 1-52.
- [152] CHEN C H, LEE L H. Stochastic simulation optimization: an optimal computing budget allocation: Vol. 1 [M]. World scientific, 2011.
- [153] MU X, ZHANG X, YEH A G O, et al. Evaluating the representativeness of mobile big data: A comparative analysis between China's mobile big data and census data at the county level [J]. *Applied Geography*, 2024, 166: 103260. DOI: 10.1016/j.apgeog.2024.103260.
- [154] TANG H, LIU J, ZHAO M, et al. Progressive Layered Extraction (PLE): A Novel Multi-Task Learning (MTL) Model for Personalized Recommendations [C]//RecSys '20: Proceedings of the 14th ACM Conference on Recommender Systems. New York, NY, USA: Association for Computing Machinery, 2020: 269-278. DOI: 10.1145/3383313.3412236.
- [155] LEE J, LEE Y, KIM J, et al. Set Transformer: A Framework for Attention-based Permutation-Invariant Neural Networks [C]//Proceedings of the 36th International Conference on Machine Learning. PMLR, 2019: 3744-3753.
- [156] LIU S, JOHNS E, DAVISON A J. End-to-End Multi-Task Learning with Attention: arXiv:1803.10704 [Z]. 2019. arXiv: 1803.10704.
- [157] NASH J F. The bargaining problem [J]. *Econometrica*, 1950, 18(2): 155-162. DOI: 10.2307/1907266.
- [158] B W R. A simplicial algorithm for concave programming [J]. Ph. D. Dissertation, Graduate School of Business Administration, 1963.
- [159] AMOS B, KOLTER J Z. OptNet: Differentiable Optimization as a Layer in Neural Networks: arXiv:1703.00443 [Z]. 2021. arXiv: 1703.00443.
- [160] FIACCO A V. Introduction to sensitivity and stability analysis in non linear programming [M]. New York: Academic Press,, 1983.
- [161] ALYAVINA E, NIKITAS A, NJOYA E T. Mobility-as-a-Service and unsustainable travel behaviour: Exploring the car ownership and public transport trip replacement side-effects of the MaaS paradigm [J]. *Transport Policy*, 2024, 150: 53-70. DOI: 10.1016/j.tranpol.2024.03.001.
- [162] JIN F, YAO E, AN K. Analysis of the potential demand for battery electric vehicle sharing: Mode share and spatiotemporal distribution [J]. *Journal of Transport Geography*, 2020, 82: 102630. DOI: 10.1016/j.jtrangeo.2019.102630.
- [163] RECK D J, AXHAUSEN K W. Subsidized ridesourcing for the First/Last mile: how valuable for whom? [J]. *European Journal of Transport and Infrastructure Research*, 2020, 20(4): 59-77. DOI: 10.18757/ejtir.2020.20.4.5314.
- [164] MIRAMONTES M, PFERTNER M, RAYAPROLU H S, et al. Impacts of a multimodal mobility service on travel behavior and preferences: user insights from Munich's first Mobility Station [J]. *Transportation*, 2017, 44(6): 1325-1342. DOI: 10.1007/s11116-017-9806-y.
- [165] FEDOROV V V. Theory of optimal experiments [M]. Elsevier, 2013.
- [166] PAN L, YAO E, MACKENZIE D. Modeling EV charging choice considering risk attitudes and attribute non-attendance [J]. *Transportation Research Part C: Emerging Technologies*, 2019,

- 102: 60-72. DOI: 10.1016/J.TRC.2019.03.007.
- [167] HUAN N, HESS S, YAO E. Understanding the effects of travel demand management on metro commuters' behavioural loyalty: a hybrid choice modelling approach [J]. *Transportation*, 2022, 49(2): 343-372. DOI: 10.1007/s11116-021-10179-3.
- [168] VIJ A, WALKER J L. How, when and why integrated choice and latent variable models are latently useful [J]. *Transportation Research Part B: Methodological*, 2016, 90: 192-217. DOI: 10.1016/J.TRB.2016.04.021.
- [169] DALY A, HESS S, PATRUNI B, et al. Using ordered attitudinal indicators in a latent variable choice model: a study of the impact of security on rail travel behaviour [J]. *Transportation*, 2012, 39(2): 267-297. DOI: 10.1007/s11116-011-9351-z.
- [170] YAO E, HAO H, PAN L, et al. Investigating the Willingness of Shifting to MaaS in One-Trip Scenarios: Insights From Comparative Stated Surveys: No. 4782633 [EB]. Rochester, NY, 2024[2024-04-22]. DOI: 10.2139/ssrn.4782633.
- [171] BIERLAIRE M. *PythonBiogeme: a short introduction* [R]. 2016.
- [172] HAIR J F, BLACK W C, BABIN B J, et al. *Multivariate Data Analysis* [M]. Cengage, 2019.
- [173] HUNT G L. Alternative nested logit model structures and the special case of partial degeneracy [J]. *Journal of Regional science*, 2000, 40(1): 89-113. DOI: 10.1111/0022-4146.00166.
- [174] HENSHER D A, ROSE J M, GREENE W H. Inferring attribute non-attendance from stated choice data: implications for willingness to pay estimates and a warning for stated choice experiment design [J]. *Transportation*, 2012, 39(2): 235-245. DOI: 10.1007/s11116-011-9347-8.
- [175] KIM J, RASOULI S, TIMMERMANS H. Hybrid Choice Models: Principles and Recent Progress Incorporating Social Influence and Nonlinear Utility Functions [J]. *Procedia Environmental Sciences*, 2014, 22: 20-34. DOI: 10.1016/j.proenv.2014.11.003.
- [176] ECHAVARREN J M. The Gender Gap in Environmental Concern: Support for an Ecofeminist Perspective and the Role of Gender Egalitarian Attitudes [J]. *Sex Roles*, 2023, 89(9): 610-623. DOI: 10.1007/s11199-023-01397-3.
- [177] SMITH G, SOCHOR J, KARLSSON I C M. Mobility as a Service: Development scenarios and implications for public transport [J]. *Research in Transportation Economics*, 2018, 69: 592-599. DOI: 10.1016/j.retrec.2018.04.001.
- [178] WALKER J, Ben-Akiva M. Generalized random utility model [J]. *Mathematical Social Sciences*, 2002, 43(3): 303-343. DOI: 10.1016/S0165-4896(02)00023-9.
- [179] JÖRESKOG K G, GOLDBERGER A S. Estimation of a Model with Multiple Indicators and Multiple Causes of a Single Latent Variable [J]. *Journal of the American Statistical Association*, 1975, 70(351a): 631-639. DOI: 10.1080/01621459.1975.10482485.
- [180] BIERLAIRE M. A short introduction to Biogeme: TRANSP-OR 230620 [R]. Transport and Mobility Laboratory, ENAC, EPFL., 2023.
- [181] CHEN X, BAI S, WEI Y, et al. How income satisfaction impacts driver engagement dynamics in ride-hailing services [J]. *Transportation Research Part C: Emerging Technologies*, 2023, 157: 104418. DOI: 10.1016/j.trc.2023.104418.

- [182] CHEN K, SHAMSHIRIPOUR A, SESHADRI R, et al. Potential short- to long-term impacts of on-demand urban air mobility on transportation demand in North America [J]. *Transportation Research Part A: Policy and Practice*, 2024, 190: 104288. DOI: 10.1016/j.tra.2024.104288.
- [183] BASS F M. A new product growth for model consumer durables [J]. *Management science*, 1969, 15(5): 215-227.
- [184] HORSKY D, SIMON L S. Advertising and the diffusion of new products [J]. *Marketing Science*, 1983, 2(1): 1-17.
- [185] SULTAN F, FARLEY J U, LEHMANN D R. A meta-analysis of applications of diffusion models [J]. *Journal of marketing research*, 1990, 27(1): 70-77.
- [186] ZHANG H, ZHAO F, HAO H, et al. Life Cycle Emissions of Passenger Vehicles in China: A Sensitivity Analysis of Multiple Influencing Factors [J]. *Sustainability*, 2023, 15(6): 4854. DOI: 10.3390/su15064854.
- [187] 张秀媛, 杨新苗, 闫琰. 城市交通能耗和碳排放统计测算方法研究 [J]. *中国软科学*, 2014 (6): 9.
- [188] OSORIO C, BIERLAIRE M. A Simulation-Based Optimization Framework for Urban Transportation Problems [J]. *Operations Research*, 2013, 61(6): 1333-1345. DOI: 10.1287/opre.2013.1226.
- [189] RASMUSSEN C E, WILLIAMS C K I. *Gaussian Processes for Machine Learning* [M]. The MIT Press, 2005. DOI: 10.7551/mitpress/3206.001.0001.
- [190] FRAZIER P I. A tutorial on Bayesian optimization [Z]. 2018. arXiv: 1807.02811.
- [191] ERIKSSON D, PEARCE M, GARDNER J, et al. Scalable global optimization via local Bayesian optimization [J]. *Advances in neural information processing systems*, 2019, 32.
- [192] KIM H, MNIH A, SCHWARZ J, et al. Attentive Neural Processes: arXiv:1901.05761 [Z]. 2019. arXiv: 1901.05761.
- [193] NIX D, WEIGEND A. Estimating the mean and variance of the target probability distribution [C]//*Proceedings of 1994 IEEE International Conference on Neural Networks (ICNN'94): Vol. 1*. 1994: 55-60vol.1. DOI: 10.1109/ICNN.1994.374138.
- [194] LAKSHMINARAYANAN B, PRITZEL A, BLUNDELL C. Simple and Scalable Predictive Uncertainty Estimation using Deep Ensembles: arXiv:1612.01474 [Z]. 2017. arXiv: 1612.01474.
- [195] TJENG V, XIAO K, TEDRAKE R. EVALUATING ROBUSTNESS OF NEURAL NETWORKS WITH MIXED INTEGER PROGRAMMING [M]. 2019.
- [196] XIAO K Y, TJENG V, SHAFIULLAH N M, et al. Training for Faster Adversarial Robustness Verification via Inducing ReLU Stability: arXiv:1809.03008 [Z]. 2019. arXiv: 1809.03008.
- [197] GOWAL S, DVIJOTHAM K, STANFORTH R, et al. Scalable Verified Training for Provably Robust Image Classification [C]//*2019 IEEE/CVF International Conference on Computer Vision (ICCV)*. 2019: 4841-4850. DOI: 10.1109/ICCV.2019.00494.
- [198] FISCHETTI M, JO J. Deep neural networks and mixed integer linear optimization [J]. *Con-*

- straints, 2018, 23(3): 296-309. DOI: 10.1007/s10601-018-9285-6.
- [199] ZHANG H, WENG T W, CHEN P Y, et al. Efficient Neural Network Robustness Certification with General Activation Functions [C]//Advances in Neural Information Processing Systems: Vol. 31. Curran Associates, Inc., 2018.

作者简历及攻读博士学位期间取得的研究成果

郝赫，男，汉族，中共党员，1999年11月生，河北沧州人。

一、教育经历

2022年9月至今，北京交通大学，交通运输规划与管理专业，博士研究生（直接攻博）；
2025年9月至2026年4月，新加坡国立大学，国家公派联合培养博士研究生；
2018年9月至2022年6月，北京交通大学，交通工程专业，工学学士学位，获免试推荐直接攻读博士学位资格。

二、期刊论文

发表/在投期刊论文21篇（SCI/SSCI期刊14篇，EI期刊3篇，中文核心及其他期刊4篇），其中第一/通讯作者14篇，获ESI高被引论文热点论文1篇。

- [1] **He Hao**, Enjian Yao*, Long Pan, Rongsheng Chen, Yue Wang, Hui Xiao. (2025). Exploring heterogeneous drivers and barriers in MaaS bundle subscriptions based on the willingness to shift to MaaS in one-trip scenarios[J]. **Transportation Research Part A: Policy and Practice**, 199: 104525. (中科院1区 Top, ESI高被引论文热点论文)
- [2] Enjian Yao, **He Hao***, Long Pan*, Rongsheng Chen, Yue Wang, Hui Xiao. (2025). Investigating the willingness of shifting to MaaS in one-trip scenarios: Insights from comparative stated surveys[J]. **Transportation Research Part A: Policy and Practice**, 192: 104384. (中科院1区 Top)
- [3] **He Hao**, Enjian Yao*, Long Pan, Yang Yang, Yue Wang. (2026). Understanding travel behavior change with megacity development: Insights from decade-long household travel surveys in Beijing[J]. **Journal of Transport Geography**, 131: 104565. (中科院1区 Top)
- [4] **He Hao**, Enjian Yao, Rongsheng Chen*, Yang Yang, Yue Wang, Wan Liu. (2026). AR2G-AIRL: A context-adaptive game-inverse reinforcement learning algorithm for modeling pedestrian-vehicle interaction considering group behaviors[J]. **IEEE Transactions on Intelligent Transportation Systems**. (中科院1区 Top)
- [5] **He Hao**, Enjian Yao*, Rongsheng Chen, Long Pan, Yue Wang. (2024). Dynamic passenger route guidance in the multimodal transit system with graph representation and attention based deep reinforcement learning[J]. **IEEE Transactions on Intelligent Transportation Systems**. DOI: 10.1109/TITS.2024.3390172. (中科院1区 Top)
- [6] **He Hao**, Enjian Yao*, Yang Yang, Shasha Liu, Long Pan, Yue Wang. (2024). How to build vibrant communities by utilizing functional zones? A community-detection-based approach for revealing the association between land use and community vibrancy[J]. **Cities**, 155: 105431. (中科院1区 Top)
- [7] **He Hao**, Enjian Yao*, Rongsheng Chen, Long Pan, Shasha Liu, Yue Wang, Hui Xiao. (2024). An approach for evaluating added values of MaaS bundles considering heterogeneous subscription

- willingness[J]. **Transportation**: 1–35. (学院认定 A+ 顶级期刊)
- [8] 姚恩建, 王月, 郝赫*, 杨扬, 郇宁. (2026). 城市群综合交通可达性对城际出行需求的影响研究 [J]. **中国公路学报**, 39(5): 387–399. (EI, 学院认定 A 类权威期刊)
- [9] 姚恩建, 陈卓利, 郝赫*, 陈荣升, 杨扬. (2025). 基于强化学习的自动驾驶车辆路上突发障碍物换道避障控制算法 [J]. **北京交通大学学报**, 49(5): 82–93. (学院认定 B 类鼓励期刊)
- [10] 郝赫, 姚恩建*, 陈荣升, 潘龙, 王月. (2025). 基于深度学习的多模式公交线网乘客路径诱导策略研究 [J]. **交通工程**, 25(2): 1–10. (公路运输领域高质量科技期刊)
- [11] He Hao, Enjian Yao*, Rongsheng Chen, Yue Wang, Yang Yang, Hui Xiao. (2026). From Single Trip Choice to Bundle Subscription: Understanding the Behavioral Transitions and Determinants in Two-stage MaaS Adoption Using a Jointly Estimated Model[J]. **Transportation Research Part A: Policy and Practice**. (Major Revision, 中科院 1 区 Top)
- [12] Enjian Yao, Yue Wang, He Hao*, Yang Yang*. (2026). Assessing the Alignment between Potential and Experienced Accessibility within Urban Agglomerations[J]. **Journal of Transport Geography**. (Major Revision, 中科院 1 区 Top)
- [13] He Hao, Qiang Meng, Enjian Yao*, Yang Yang. (2026). CoHACT: A Deep Generative Framework for Coordinated Household Activity-Chain Generation with Intra-Household Travel[J]. **Transportation Research Part B: Methodological**. (Under Review, 中科院 1 区 Top)
- [14] He Hao, Qiang Meng, Enjian Yao*, Yang Yang. (2026). Large-scale Household-level Population Synthesis: An Effective Hierarchical Deep Learning-based Model[J]. **Transportation Research Part B: Methodological**. (Under Review, 中科院 1 区 Top)
- [15] Ning Huan, Jiaoe Wang, Toshiyuki Yamamoto, He Hao, Hanqi Zhao, Enjian Yao*. (2026). Vehicle energy type preferences with hydrogen fuel cell vehicles as an alternative in electrified mobility. **Transportation Research Part D: Transport and Environment**, 159, 105500.
- [16] Yue Wang, Enjian Yao*, Yongsheng Zhang, Long Pan, He Hao. (2024). Deep learning model for short-term origin-destination distribution prediction in urban rail transit network considering destination choice behavior[J]. **Transportation Research Record**: 03611981241243081.
- [17] Wan Liu, Jinguang Liu, Shuai Dai, He Hao. (2026). A screening and prioritization method for urban road hazard points: Large-scale validation analysis in 18 cities[J]. **IEEE Access**.
- [18] Long Pan, Enjian Yao, Yang Yang, He Hao. (2025). Planning of energy supply facilities for highway networks: Methodology research and practical applications[J]. **Transportation Research Procedia**, 92: 53.
- [19] 王月, 姚恩建*, 郝赫, 李义罡, 史佳柠. (2025). 京津冀城市群总体与城际出行特征异同性挖掘 [J]. **地理学报**, 80(4): 1089–1102. (EI)
- [20] 王月, 姚恩建*, 郝赫. (2023). 低碳导向的多模式交通出行服务定价策略 [J]. **清华大学学报 (自然科学版)**. DOI: 10.16511/j.cnki.qhdxxb.2023.26.024. (EI)
- [21] 王学勇, 姚恩建*, 王小华, 郝赫. (2025). 我国城市停车配建标准体系研究 [J]. **综合运输**.

47(2): 22–25.

三、会议论文

发表/录用在投会议论文 8 篇，其中以第一作者或通讯作者身份完成 3 篇，相关成果在 TRB、WTC、ITSWC 及 TRS 等国际会议进行交流。

- [1] **He Hao**, Enjian Yao*, Long Pan, Yang Yang, Rongsheng Chen, Yue Wang. (2025). Understanding travel behavior change and the role of public transport with megacity development[C]. **Transportation Research Board (TRB) 104th Annual Meeting**, Washington, D.C., USA.
- [2] **He Hao**, Enjian Yao*, Long Pan, Yang Yang, Rongsheng Chen, Yue Wang. (2025). What does 2023 household travel survey in Beijing tell us? The roles of innovative survey methods and changes in travel mode preferences of residents[C]. **Transportation Research Board (TRB) 104th Annual Meeting**, Washington, D.C., USA.
- [3] Rui Chen, Enjian Yao, **He Hao***. (2026). Investigating the causal impact of subway expansion on carbon emissions in Beijing, China[C]. **World Conference on Transport Research (WCTR 2026)**, Toulouse, France.
- [4] 王昊然, 姚恩建, 陈荣升, **郝赫**. (2026). 基于紧迫度公平的混合交通流自动驾驶协同变道策略 [C]. **2026 世界交通运输大会 (WTC 2026)**.
- [5] 胡雪逸, 姚恩建, 姚辉, **郝赫**. (2026). 基于改进 YOLOv8 算法的沥青路面裂缝检测模型 [C]. **2026 世界交通运输大会 (WTC 2026)**.
- [6] Long Pan, Enjian Yao, Yang Yang, **He Hao**. (2025). Planning of energy supply facilities for highway networks: Methodology research and practical applications[C]. **Transportation Research Symposium 2025**, Rotterdam, the Netherlands.
- [7] Yue Wang, Enjian Yao, Yongsheng Zhang, Long Pan, **He Hao**. (2024). A deep learning model for short-term origin-destination distribution prediction in urban rail transit network considering destination choice behavior[C]. **Transportation Research Board (TRB) 103rd Annual Meeting**, Washington, D.C., USA.
- [8] Yue Wang, Enjian Yao, Yongsheng Zhang, **He Hao**, Long Pan. (2023). Urban rail transit short-term OD flow prediction considering temporal-spatial characteristics and probability[C]. **29th ITS World Congress**, Suzhou, China.

四、发明专利

获授权国家发明专利 2 件:

- [1] 姚恩建, **郝赫**, 陈荣升, 杨扬, 潘龙, 王月. (2025). 基于群体特征的人车交互下行人意图判断与轨迹生成方法, 专利号: ZL202510378056.9, 公告号: CN119888673B.
- [2] 姚恩建, **郝赫**, 潘龙, 杨扬, 王月. (2025). 基于居民出行影响因素与交通资源需求的预测分类方法, 专利号: ZL202510838732.6, 公告号: CN120409832B.

五、软件著作权

登记软件著作权 2 件:

- [1] 兰斌,姚恩建,郝赫等. 故障大数据分析系统 V1.0, 登记号: 2025SR1812113.
- [2] 兰斌,姚恩建,郝赫等. 故障大数据挖掘系统 V1.0, 登记号: 2025SR1812140.

六、智库与著作

撰写省部级智库建议 2 篇, 参与编写国家重点出版物科普图书 1 部:

- [1] 完善城市公交市场化运营机制. 姚恩建, 郝赫, 2024 年被中央广播电视总台内参中心采用, 并获中央广播电视总台感谢信 1 封。
- [2] 加强多模式公交线网融合, 推进北京市公交高质量发展. 姚恩建, 孙迅, 郝赫, 2023 年入选《交大智库建言》第 42 期, 并获北京市交通委员会采纳。
- [3] 姚恩建, 陈荣升等. (2026). 智慧的城市交通 [M]. 北京: 人民交通出版社. (“十四五”国家重点出版物出版规划项目、中国科协“科普中国创作出版扶持计划”项目) **主要参编人员**

七、研究经历

主持研究生创新项目 1 项, 参与国家级、省部级及企事业单位委托科研项目 17 项, 具体如下:

- [1] 出行即服务理念下分级用户需求建模与运营优化理论研究. 中央高校基本科研业务费专项资金研究生创新项目(一类), 2024.04–2026.03, 主持.
- [2] 不同自主化水平道路交通系统风险辨识与安全管控技术. 国家重点研发计划“交通载运装备与智能交通技术”重点专项课题, 2023.12–2027.11, 参加.
- [3] 大客流下综合客运枢纽多方式运力调控与韧性服务. 国家自然科学基金重点项目, 2025.01–2029.12, 参加.
- [4] 城市群尺度下城际出行行为分析与交通供给优化. 国家自然科学基金面上项目, 2022.01–2025.12, 参加.
- [5] 城轨运营突发事件下诱导信息对乘客行为影响及客流演化机理研究. 北京市自然科学基金轨道交通联合基金项目, 2022.01–2024.12, 参加.
- [6] 面向民用机场的新能源设备规划与应用研究. 中国民用航空局民航安全能力建设基金, 2023.04–2025.12, 参加.
- [7] 飞行区光伏可行性安全指标及相关政策机制研究. 中国民用航空局民航安全能力建设基金, 2024.07–2025.12, 参加.
- [8] 京津冀跨界交通基础设施规建管养一体化机制研究. 首都高端智库决策咨询重大课题(省部级), 2023.07–2025.12, 参加.
- [9] 我市轨道交通与地面公交、慢行系统多网融合发展问题研究. 首都高端智库决策咨询重大课题(省部级), 2022.03–2022.12, 参加.
- [10] “四网融合”背景下的北京市郊铁路现代化运营管理体系研究. 首都高端智库决策咨询重点课题(省部级), 2022.07–2023.03, 参加.
- [11] 北京轨道交通与地面公交融合发展研究. 首都高端智库课题, 2025.11–2026.11, 参加.

- [12] 北京市交通系统韧性提升研究. 首都高端智库课题, 2025.07–2026.03, 参加.
- [13] 北京市郊铁路郊区站点周边交通及区域微循环优化研究. 首都高端智库课题, 2024.06–2026.08, 参加.
- [14] 提高北京 45 分钟通勤比例可行措施研究. 首都高端智库决策咨询专项课题, 2022.11–2023.09, 参加.
- [15] 需求导向下的“轨道 + 公交 + 慢行”三网融合规划方法研究. 交通运输部科学研究院, 2023.11–2025.08, 参加.
- [16] 居民出行调查样本分析. 北京交通发展研究院, 2023.10–2027.09, 参加.
- [17] 地铁故障大数据挖掘技术方法研究项目. 北京市地铁运营有限公司技术创新研究院分公司, 2023.09–2023.12, 参加.
- [18] 北京市轨道交通 13 号线扩能提升工程道路交通工程方案咨询. 北京城建设计发展集团股份有限公司, 2023.02–2023.12, 参加.

八、荣誉奖励

- | | |
|-------------|--------------------------------|
| 2025 年 12 月 | 中国科协青年科技人才培育工程博士生专项计划 |
| 2026 年 5 月 | 北京交通大学研究生知行奖学金（原“校长奖学金”） |
| 2025 年 12 月 | 宝钢优秀学生奖学金（全校研究生仅 3 人） |
| 2025 年 12 月 | 博士研究生国家奖学金 |
| 2024 年 12 月 | 博士研究生国家奖学金 |
| 2025 年 5 月 | 国家留学基金委联合培养博士生奖学金 |
| 2026 年 6 月 | 北京市优秀毕业生 |
| 2026 年 3 月 | 北京市三好学生 |
| 2026 年 5 月 | 关键软件技术创新成果（全国“十大”软件，示范性软件学院联盟） |
| 2024 年 12 月 | 北京交通工程学会有奖征文一等奖（全国仅 2 项） |
| 2025 年 10 月 | 第六届智慧交通大赛全国三等奖 |
| 2024 年 11 月 | 第二届“先导杯”智能车联网开放数据挑战赛全国二等奖 |
| 2025 年 7 月 | 世界交通运输大会（WTC）推荐论文 |
| 2022 年 10 月 | “华为杯”第四届中国研究生人工智能创新大赛校二等奖 |
| 2025 年 12 月 | 北京交通大学三好学生 |