

北京交通大学

博士学位论文

XXXXXXXXXXXXXXXXXXXXX

XXXXXXXXXXXXXXXXXXXXX

作者：郝赫

导师：姚恩建

北京交通大学

2026 年 5 月

学位论文版权使用授权书

本学位论文作者完全了解北京交通大学有关保留、使用学位论文的规定。特授权北京交通大学可以将学位论文的全部或部分内容编入有关数据库进行检索，提供阅览服务，并采用影印、缩印或扫描等复制手段保存、汇编以供查阅和借阅。同意学校向国家有关部门或机构送交论文的复印件和磁盘。学校可以为存在馆际合作关系的兄弟高校用户提供文献传递服务和交换服务。

（保密的学位论文在解密后适用本授权说明）

学位论文作者签名：



导师签名：



签字日期：2026 年 5 月 27 日

签字日期：2026 年 5 月 27 日

密级: 公开

XXXXXXXXXXXXXXXXXXXX

学 号: 22110300

职 称: 教授

学位级别: 博士

i

答辩委员会名单

答辩委员会	姓名	工作单位	职称
主席	朱晓宁	北京交通大学	教授
委员	石京	清华大学	教授
委员	陈艳艳	北京工业大学	教授
委员	王艳辉	北京交通大学	教授
委员	黄爱玲	北京交通大学	教授
秘书	陈荣升	北京交通大学	讲师

致谢

XXXXXXXXXX

摘要

XXXXXXX

关键词：XXXXXX

ABSTRACT

XXXXXXXXXXXXXXXXXX

KEYWORDS: XXXXXXXXXXXXXXXX

目录

摘要	vii
ABSTRACT	ix
1 绪论	1
1.1 研究背景及意义	1
1.1.1 研究背景	1
1.1.2 MaaS 推广实践问题的思考	1
1.1.3 研究意义	1
1.2 研究目标及范围界定	1
1.2.1 研究目标	1
1.2.2 研究范围界定	1
1.3 研究内容与技术路线	1
1.3.1 主要研究内容	1
1.3.2 技术路线与结构安排	1
1.4 本章小结	1
2 国内外研究现状	3
2.1 人口合成方法研究	3
2.1.1 基于统计推断的人口合成方法	3
2.1.2 基于深度生成模型的人口合成方法	3
2.1.3 家庭-个人多层级联合合成研究	3
2.2 活动-出行计划生成研究	4
2.2.1 基于活动的出行需求模型	4
2.2.2 基于深度学习的活动-出行计划生成方法	4
2.2.3 家庭联合活动与成员协调建模研究	4
2.3 MaaS 采纳意愿研究	4
2.3.1 单次出行场景下 MaaS 选择行为研究	4
2.3.2 MaaS 套餐订阅行为研究	4
2.3.3 MaaS 多阶段采纳与跨阶段关联研究	4
2.4 MaaS 推广策略研究	4
2.4.1 MaaS 推广仿真模型研究	4
2.4.2 仿真优化与多目标优化方法研究	4

2.5	既有研究评述	4
2.6	本章小结	4
3	基于分层扩散模型的家庭级别大规模人口合成	5
3.1	本章引论	5
3.2	基于 HDBSCAN 的家庭画像机制	8
3.2.1	家庭画像特征构建与筛选	8
3.2.2	HDBSCAN 聚类与噪声样本归并	10
3.3	分层扩散 Transformer 模型构建	11
3.3.1	模型输入与总体结构	11
3.3.2	分层扩散过程定义	12
3.3.3	家庭级扩散 Transformer 模块	13
3.3.4	基于 GraphVAE 与异质图 Transformer 的家庭结构表征	14
3.3.5	个人级扩散 Transformer 模块	17
3.3.6	损失函数与模型训练	19
3.4	基于能量引导的多地理尺度边际分布对齐机制	21
3.4.1	反向去噪采样过程	21
3.4.2	多地理尺度能量函数与引导梯度计算	22
3.4.3	地理尺度间梯度冲突协调策略	24
3.5	样本零与结构零正则化策略	24
3.6	面向多样化人口分布的两阶段超参数调优策略	26
3.6.1	基于互信息的先验分布构建	27
3.6.2	考虑冲突感知的 Hyperband 搜索算法	28
3.7	算例实验	30
3.7.1	算例数据描述	30
3.7.2	实验设置与评价指标	33
3.7.3	基准模型对比分析	34
3.7.4	消融实验分析	36
3.7.5	家庭结构图生成质量分析	38
3.7.6	多地理尺度边际分布对齐效果评估	40
3.7.7	样本零与结构零处理效果评估	42
3.8	本章小结	43
4	考虑家庭联合活动的家庭级出行计划生成	45
4.1	问题描述及解决思路	47
4.2	家庭出行计划数据特征解析与统一表征	47
4.2.1	家庭活动链与联合活动模式特征分析	47

4.2.2	家庭-成员特征统一编码与活动模式先验构建	47
4.3	家庭感知的多任务编码器设计	47
4.3.1	集合注意力专家与渐进分层提取结构	47
4.3.2	家庭与个人层级活动模式先验融合	47
4.4	家庭协调式活动链解码器设计	47
4.4.1	任务特定注意力与跨角色注意力机制	47
4.4.2	自回归活动链生成与多属性预测头	47
4.4.3	空间感知的目的地注意力机制	47
4.5	基于纳什议价的可微家庭协调层	47
4.5.1	家庭协调的纳什议价问题构建与两阶段优化	47
4.5.2	KKT 条件可微性与反向传播近似	47
4.6	损失函数与模型训练策略	47
4.7	算例实验	47
4.7.1	实验设置与评价指标	47
4.7.2	基准模型对比分析	47
4.7.3	消融实验分析	47
4.7.4	家庭内部协调性分析	47
4.7.5	个体级属性分布对比分析	47
4.7.6	目的地空间分布与区域覆盖分析	47
4.8	本章小结	47
5	分阶段建模下的 MaaS 多阶段采纳意愿建模	49
5.1	问题描述及解决思路	49
5.2	MaaS 多阶段采纳意愿陈述偏好调查与特征分析	49
5.2.1	两步式比较型陈述偏好实验设计	49
5.2.2	调查实施与样本统计分析	49
5.2.3	多阶段选择行为特征分析	49
5.3	单次出行场景下 MaaS 转移意愿建模	49
5.3.1	潜在态度变量识别	49
5.3.2	融合出行习惯与跨场景变量的潜在类别选择模型	49
5.3.3	模型估计结果与异质用户类别分析	49
5.3.4	MaaS 转移意愿指数构建与分析	49
5.4	基于初始印象的 MaaS 套餐订阅异质偏好建模	49
5.4.1	单次出行偏好向套餐订阅决策的效用迁移机制	49
5.4.2	融合属性非关注的潜在类别潜变量选择模型	49
5.4.3	模型估计结果与驱动-障碍因素分析	49

5.5	灵敏度与弹性分析及政策启示	49
5.6	本章小结	49
6	一体化建模下的 MaaS 多阶段采纳意愿建模	51
6.1	问题描述及解决思路	52
6.2	态度潜变量识别与 MIMIC 模型构建	52
6.2.1	基于探索性与验证性因子分析的潜变量识别	52
6.2.2	结构方程构建	52
6.2.3	测量方程构建	52
6.2.4	似然函数与因子得分计算	52
6.3	MaaS 多阶段采纳决策的隐马尔可夫模型构建	52
6.3.1	初始行为状态隶属模型	52
6.3.2	单次出行阶段选择模型	52
6.3.3	跨阶段行为状态转移模型	52
6.3.4	套餐订阅阶段选择模型	52
6.3.5	联合似然函数与模型标定	52
6.4	模型结果分析	52
6.4.1	MIMIC 模型估计结果分析	52
6.4.2	行为状态识别与阶段偏好异质性分析	52
6.4.3	跨阶段行为状态转移机理分析	52
6.4.4	全周期弹性聚合与采纳驱动因素分析	52
6.4.5	分阶段与一体化建模范式对比分析	52
6.5	本章小结	52
7	基于深度学习仿真优化的多目标 MaaS 推广策略优化	53
7.1	问题描述及解决思路	54
7.2	MaaS 采纳多智能体仿真模型构建	54
7.2.1	涵盖试用-订阅-套餐选择的三层决策机制	54
7.2.2	扩散传播与空间网络效应建模	54
7.2.3	推广策略空间与多目标评价指标体系	54
7.3	面向仿真模型的深度学习代理模型设计	54
7.3.1	兼顾静态与动态策略特征的代理模型架构	54
7.3.2	解析先验预训练与持续微调训练策略	54
7.4	基于信赖域机制的多目标贝叶斯优化方法	54
7.4.1	多目标采集函数设计	54
7.4.2	信赖域搜索与代理模型持续微调协同机制	54

7.5	算例实验	54
7.5.1	北京市 MaaS 推广仿真场景与实验设置	54
7.5.2	代理模型精度验证与对比分析	54
7.5.3	多目标优化结果与 Pareto 前沿分析	54
7.5.4	推广策略灵敏度分析与政策启示	54
7.6	本章小结	54
8	总结与展望	55
8.1	研究总结	55
8.2	创新点	55
8.3	研究展望	55
	参考文献	57
	附录 A	61
	作者简历及攻读博士学位期间取得的研究成果	65
	答辩决议	67
	独创性声明	69
	学位论文数据集	71

图目录

图 3-1	基于分层扩散模型的家庭级别人口合成方法总体框架	8
图 3-2	分层扩散 Transformer 模型总体结构	12
图 3-3	基于能量引导的多地理尺度边际分布对齐流程	22
图 3-4	北京市人口分布	34
图 3-5	消融实验中家庭级属性分布对比	38
图 3-6	消融实验中个人级属性分布对比	38
图 3-7	家庭结构图邻接矩阵相似度分析	39
图 3-8	家庭结构图边类型与节点类型预测准确率分布	40
图 3-9	栅格尺度机动车拥有比例边际对齐误差空间分布	41
图 3-10	行政区尺度人口边际分布绝对误差对比	41
图 3-11	城市尺度人口边际分布绝对误差对比	42
图 3-12	生成样本与居民出行调查样本在 VAE 潜空间中的 Wasserstein 距离分布	43

表目录

表 3-1 北京市行政区尺度人口边际属性统计 32

表 3-2 北京市城市尺度人口边际属性统计 33

表 3-3 HiDiT 模型主要超参数设置 35

表 3-4 不同模型的平均 SRMSE 对比结果 36

表 3-5 HiDiT 模型不同模块的消融实验结果 37

表 3-6 合成样本中有效样本、潜在样本零与潜在结构零分类结果 42

1 绪论

1.1 研究背景及意义

1.1.1 研究背景

1.1.2 MaaS 推广实践问题的思考

1.1.3 研究意义

1.2 研究目标及范围界定

1.2.1 研究目标

1.2.2 研究范围界定

1.3 研究内容与技术路线

1.3.1 主要研究内容

1.3.2 技术路线与结构安排

1.4 本章小结

2 国内外研究现状

2.1 人口合成方法研究

2.1.1 基于统计推断的人口合成方法

2.1.2 基于深度生成模型的人口合成方法

2.1.3 家庭-个人多层级联合合成研究^[1]

2.2 活动-出行计划生成研究

2.2.1 基于活动的出行需求模型

2.2.2 基于深度学习的活动-出行计划生成方法

2.2.3 家庭联合活动与成员协调建模研究

2.3 MaaS 采纳意愿研究

2.3.1 单次出行场景下 MaaS 选择行为研究

2.3.2 MaaS 套餐订阅行为研究

2.3.3 MaaS 多阶段采纳与跨阶段关联研究

2.4 MaaS 推广策略研究

2.4.1 MaaS 推广仿真模型研究

2.4.2 仿真优化与多目标优化方法研究

2.5 既有研究评述

2.6 本章小结

3 基于分层扩散模型的家庭级别大规模人口合成

3.1 本章引论

本章所要解决的为问题 (1): 如何生成支撑大规模 MaaS 推广策略仿真的高保真虚拟人口? 本文研究城市范围内的 MaaS 推广策略制定与优化, 其作用对象为全市居民, 策略效果的评估以多智能体仿真为手段, 而对推广策略效果精准仿真的前提是获得有代表性的全市居民的微观人口输入。本章合成的虚拟人口是第4章家庭出行计划生成的直接输入, 二者进一步结合第5章与第6章的 MaaS 采纳意愿建模, 共同构成第7章推广策略仿真的微观基础。由于合成阶段的分布偏差会沿该链条逐级传播, 因此本章工作的质量从源头决定了整个仿真链条的可信度。下面从仿真需求与数据供给两个方面对该问题进行描述分析。

首先, 从仿真需求上看, 既有研究表明社会经济属性、出行习惯、空间分布不同的居民在 MaaS 采纳行为上具有显著的异质性。在个体层面, 年龄、职业、收入与受教育程度等社会经济属性决定了用户对定价、补贴等推广策略的敏感程度; 在家庭层面, 用户对 MaaS 的试用、订阅与套餐选择并非孤立的个体行为, 家庭车辆的可用性、成员间的接送与联合出行安排、家庭收入的预算约束, 共同塑造了个体对既有出行模式的依赖程度; 在空间层面, 居住区位决定了用户可获得的交通服务供给, 进而影响 MaaS 各组成方式对其的吸引力。若以同质化的代表性个体刻画全市居民, 上述差异化的策略响应便无从体现, 仿真所得的推广效果评估将出现系统性偏差。因此, 推广策略仿真所需的人口输入须微观到个体并覆盖到全市, 并尽量保留不同属性的联合分布与空间分布。

其次, 从数据供给上看, 尽管现有数据中居民出行调查能够提供较为详尽的人口属性与出行信息, 但其在覆盖率上仍有不足。以北京市为例, 2023 年居民出行调查完整记录了受访家庭的社会经济属性、成员构成及各成员的活动出行安排, 是粒度最细、信息最全的微观数据来源, 然而其抽样率仅约 0.40%, 若直接以调查样本作为仿真输入, 规模上远不能代表全市居民, 空间上亦存在大量未被覆盖的区域。与之相对, 人口普查与统计年鉴等宏观数据虽然覆盖城市全域以及各行政区划, 却仅能提供各属性的边际分布, 不包含个体层面的属性联合信息, 更无家庭内部的成员组织结构。换言之, 居民出行调查数据或统计年鉴等单一数据源均无法直接满足本文 MaaS 推广策略高保真仿真的数据需求。

人口合成正是弥合上述需求与供给之间缺口的技术环节。作为基于活动的出行需求模型 (Activity-Based Model, ABM) 的第一个步骤, 人口合成以小规模调查

样本为种子、以宏观统计信息为约束,将样本扩展为覆盖全域的虚拟人口,在保持属性联合分布真实性的同时满足宏观边际的吻合性,从而为 ABM 内后续的活动出行计划生成与运行仿真提供决策主体^[2]。然而,既有人口合成研究大多以单个个体为合成目标,仅追求个体属性联合分布的还原,家庭或被简化为个体的一个属性字段,或被完全忽略。然而,此类设定存在一定缺陷:一方面,缺乏家庭结构约束的个体集合在“组装”成家庭后,成员属性间往往出现逻辑矛盾,如夫妻与亲子的年龄关系失真、持照人数与车辆配置失调等;另一方面,居民的出行决策在相当程度上是家庭层面协调的产物,车辆在成员间的分配、对儿童与老人的接送、联合出行的安排均以家庭为决策单元展开,以个体为单元的人口无法承载此类协调行为的仿真。因此,仅以个人为合成的最小单元得到的虚拟人口,难以作为第4章家庭出行计划生成的可信输入。

然而,若将合成单元由个体提升至家庭,对方法本身提出了更高的要求,既有两类方法均难以应对。基于统计推断的方法以列联表为载体,家庭级合成须同时刻画家庭属性与多个成员属性的联合分布,联合状态空间随属性维数与成员数呈指数增长,维度诅咒使列联表高度稀疏、估计不再可行,而将家庭与个人两级拆分拟合又使层级间一致性失去保障;基于深度生成模型的方法虽然缓解了高维联合分布的拟合难题,但其对高阶属性组合(多维边际)的拟合能力随组合维数增长迅速衰减,且多以定长向量表征单个个体,难以容纳成员数可变的家庭结构与成员间关系,生成过程中亦缺乏施加多尺度边际约束、甄别样本零与结构零的有效手段。因此,既有方法均无法满足本文以家庭为决策单元的全市尺度仿真对人口输入的需求。

综上,本章的研究目标确定为:以小规模出行调查样本为种子,融合多源宏观统计信息,合成属性联合分布真实、家庭结构合理、多尺度边际吻合且规模覆盖全市的家庭级虚拟人口,并使方法对不同城市的人口分布特征具备可迁移性。剖析该问题的内在特性,实现上述目标须克服以下四方面困难。

(1) 家庭-个人层级间的“一对多”映射。家庭级属性与成员级属性之间不存在确定的对应关系:家庭规模、收入与车辆拥有水平相同的家庭,其成员的年龄结构、职业构成与角色关系可能差异显著。生成模型若不引入额外的条件约束,下层成员属性的生成空间过大,难以收敛到与上层家庭属性协调一致的组合;同时,成员间关系(夫妻、亲子等)须作为显式对象建模,否则无法保证家庭内部结构的合理性。

(2) 多尺度边际分布的同时对齐。为保障合成人口能够最大程度还原目标城市的人口分布特征,合成人口须在微观(如栅格)、中观(如行政区划)、宏观(如整个城市)等不同地理尺度上同时逼近来自不同数据源的边际分布。各尺度约束

并非彼此独立，生成过程中对应的调整方向可能相互冲突，仅满足单一尺度的对齐方式会以牺牲其他尺度的吻合度为代价。

(3) 样本零与结构零的甄别处置。受抽样规模限制，样本中未出现的属性组合包含真实存在但未被抽中的“样本零”与逻辑上不可能成立的“结构零”两类。生成模型若简单复刻样本分布，合成人口缺乏多样性；若放任模型自由外推，则可能产出无效组合。如何在生成过程中甄别两类零值组合，并以不同方式加以处置，是保证合成人口既具多样性又符合逻辑约束的关键。

(4) 生成模型对人口分布差异的适配。由于基于深度学习的生成模型高度依赖输入数据以及超参数、损失权重等模型结构数据，模型的最优配置往往随目标城市的人口分布特征而变化。若每个城市都需通过人工经验进行超参数调优，计算代价高昂且结果缺乏稳定性，制约方法的推广应用。

针对上述四方面困难，本章提出基于分层扩散 Transformer (Hierarchical Diffusion-Transformer, HiDiT) 模型的家庭级别人口合成方法，其总体框架如图 3-1 所示。该方法的设计与四方面困难逐一对应：针对困难 (1)，构建基于 HDBSCAN 的家庭画像机制，以画像标签作为条件信息压缩下层生成空间，并在分层扩散 Transformer 中融合图生成模块，显式表征家庭结构与成员关系；针对困难 (2)，设计基于能量引导的多尺度边际对齐机制，在扩散采样过程中注入多尺度引导梯度，将多源宏观统计信息以边际约束的形式注入到生成过程，并通过求解二次规划问题协调不同空间尺度间的梯度冲突；针对困难 (3)，设计基于变分自编码器与贝叶斯网络的双判据正则化策略，在采样阶段识别并区分两类零值组合，对结构零样本予以重生；针对困难 (4)，设计两阶段超参数调优策略，先基于属性间互信息构建超参数先验分布，再以冲突感知的 Hyperband 算法完成高效搜索。本章章节安排如下：3.2 节至 3.6 节依次阐述家庭画像机制、分层扩散 Transformer 模型、多尺度边际对齐机制、双零正则化策略与超参数调优策略；3.7 节以北京市为算例验证方法的有效性；最后总结本章工作。




图 3-1 基于分层扩散模型的家庭级别人口合成方法总体框架

3.2 基于 HDBSCAN 的家庭画像机制

困难 (1) 所述的“一对多”映射（属性相同的家庭可能呈现迥异的成员构成，使生成模型难以有效学习层级间的内在关联）在生成建模领域亦被称为不适定逆问题（Ill-posed inverse problem）^[3]。处理此类问题的有效途径之一是引入额外的条件信息约束生成过程^[4]。受此启发，本节构建家庭画像机制：综合家庭级与成员级两类属性将样本家庭划分为若干群组，并将家庭画像标签作为条件信息输入后续的分层生成过程，从而压缩下层成员属性的生成空间。

家庭画像的划分通过基于密度的聚类实现，具体采用层次密度聚类算法（Hierarchical Density-Based Spatial Clustering of Applications with Noise, HDBSCAN）^[5]。相比 K-means 等传统聚类方法，HDBSCAN 具有三方面优势：一是无需预先指定簇数，避免了主观设定对划分结果的影响；二是借助簇层级树可识别密度不一、形状任意的簇；三是依托密度层级能够更准确地甄别噪声样本。家庭画像机制的实施分为两步：首先构建并筛选用于刻画家庭的画像特征，然后执行聚类并对噪声样本进行归并，下面分别阐述。

3.2.1 家庭画像特征构建与筛选

画像特征从原始家庭级属性、成员级属性聚合统计与家庭复合指标三个方面构建。其中，原始家庭级属性直接来自调查数据，体现家庭的基本社会经济特征；成员级属性聚合统计通过对家庭内成员属性进行统计计算，反映家庭成员构成的

特征；家庭复合指标则参照既有研究选取反映家庭复杂特征的指标，综合刻画家庭的结构复杂性与角色多样性。

在原始家庭级属性方面，记 $\mathbf{X}^{\text{hh}} \in \mathbb{R}^{N \times d_1}$ 为家庭级属性矩阵，其中 N 为样本家庭数， d_1 为家庭级属性维数。家庭级属性包括家庭规模、就业人数、车辆保有量（机动车、自行车、电动自行车、摩托车与老年代步车）、是否有在校学生与家庭年收入，与人口合成所需的目标属性保持一致。其中，是否有在校学生与家庭年收入为分类变量，其余均为数值变量。

在成员级属性聚合统计方面，记 $\mathbf{X}^{\text{agg}} \in \mathbb{R}^{N \times d_2}$ 为由家庭内各成员属性聚合得到的统计特征矩阵。参与聚合的成员级属性为年龄、性别、驾照持有情况、受教育程度、与户主关系及职业，同样与人口合成的目标属性一致。对于其中的高维分类变量，即受教育程度、与户主关系与职业，先做 one-hot 编码，再按家庭计算各类别的成员占比，得到家庭级的类别比例矩阵；考虑到此类比例矩阵维数较高且存在冗余，进一步采用主成分分析（Principal Component Analysis, PCA）降维，主成分个数按累计方差贡献率首次超过预设阈值 θ （如 95%）自适应确定，由此得到降维后的受教育程度特征 $\mathbf{X}^{\text{edu}} \in \mathbb{R}^{N \times d_e}$ 、关系特征 $\mathbf{X}^{\text{rel}} \in \mathbb{R}^{N \times d_r}$ 与职业特征 $\mathbf{X}^{\text{occ}} \in \mathbb{R}^{N \times d_o}$ 。

对于数值型的成员级属性，则按家庭计算统计量。记 $\mathbf{X}^{\text{ind}} \in \mathbb{R}^{N \times d_{\text{ind}}}$ 为相应的统计特征矩阵，对成员年龄集合为 $\mathbf{a}_i = \{a_{i1}, a_{i2}, \dots, a_{im_i}\}$ 的家庭 i （ m_i 为其成员数），计算：

$$\mathbf{X}_i^{\text{ind}} = [\mu(\mathbf{a}_i), \sigma(\mathbf{a}_i), \min(\mathbf{a}_i), \max(\mathbf{a}_i), \bar{g}_i, \bar{l}_i, n_i^{\text{child}}, \rho_i^{\text{child}}, n_i^{\text{elder}}, \rho_i^{\text{elder}}, n_i^{\text{work}}, \rho_i^{\text{work}}] \quad (3-1)$$

式中， $\mu(\cdot)$ 、 $\sigma(\cdot)$ 、 $\min(\cdot)$ 与 $\max(\cdot)$ 分别为均值、标准差、最小值与最大值算子； $\bar{g}_i$ 与 $\bar{l}_i$ 分别为家庭 i 的性别比例与驾照持有率； n_i^{child} 、 n_i^{elder} 与 n_i^{work} 分别为儿童（年龄 < 18 岁）、老年（年龄 ≥ 60 岁）与家庭内就业（ $18 \leq \text{年龄} < 60$ 岁）成员数； ρ_i^{child} 、 ρ_i^{elder} 与 ρ_i^{work} 为对应的成员占比。

将上述各部分横向拼接，得到成员级属性聚合统计特征矩阵：

$$\mathbf{X}^{\text{agg}} = [\mathbf{X}^{\text{edu}} \parallel \mathbf{X}^{\text{rel}} \parallel \mathbf{X}^{\text{occ}} \parallel \mathbf{X}^{\text{ind}}] \in \mathbb{R}^{N \times d_2} \quad (3-2)$$

式中， $\parallel$ 表示矩阵的横向拼接； $d_2 = d_e + d_r + d_o + d_{\text{ind}}$ 为聚合统计特征的总维数。

在家庭复合指标方面，记 $\mathbf{X}^{\text{comp}} \in \mathbb{R}^{N \times d_3}$ 为复合特征矩阵。参照既有家庭画像研究^[6-9]，选取人均就业比例、人均机动车保有量、人均自行车保有量、抚养比与年龄差异指数五项反映家庭复杂特征的指标，对家庭 i 计算：

$$\mathbf{X}_i^{\text{comp}} = \left[\frac{n_i^{\text{work}}}{m_i}, \frac{n_i^{\text{veh}}}{m_i}, \frac{n_i^{\text{bike}}}{m_i}, \frac{n_i^{\text{child}} + n_i^{\text{elder}}}{n_i^{\text{work}} + \delta}, \frac{\sigma(\mathbf{a}_i)}{\mu(\mathbf{a}_i) + \delta} \right] \quad (3-3)$$

式中, n_i^{veh} 与 n_i^{bike} 分别为家庭 i 的机动车数与自行车数 (含电动自行车); m_i 为家庭 i 的成员数, δ 为防止除零的小正常数。

最终的家庭画像特征矩阵由三类特征拼接而成:

$$\mathbf{X} = [\mathbf{X}^{\text{hh}} \parallel \mathbf{X}^{\text{agg}} \parallel \mathbf{X}^{\text{comp}}] \in \mathbb{R}^{N \times D} \quad (3-4)$$

式中, $D = d_1 + d_2 + d_3$ 为特征总维数。

在特征筛选方面, 聚类前依次执行三步处理: 首先采用方差阈值法剔除方差接近于零的特征, 此类特征在样本间几乎不变, 对划分无贡献; 然后计算特征间的 Pearson 相关系数矩阵, 剔除高度相关的冗余特征, 避免相关特征在距离度量中被重复计入; 最后对保留特征做 z-score 标准化, 使各特征在聚类的距离计算中贡献均衡。

3.2.2 HDBSCAN 聚类与噪声样本归并

基于筛选后的特征矩阵, HDBSCAN 依据互达距离构建簇的层级结构。对样本 $\mathbf{x}_i$, 定义其核心距离 $d_{\text{core}}(\mathbf{x}_i)$ 为该样本到其第 k 近邻的距离, 其中 k 为最小邻域样本数; 在此基础上, 任意两样本 $\mathbf{x}_i$ 与 $\mathbf{x}_j$ 之间的互达距离定义为:

$$d_{\text{mreach}}(\mathbf{x}_i, \mathbf{x}_j) = \max \{d_{\text{core}}(\mathbf{x}_i), d_{\text{core}}(\mathbf{x}_j), d(\mathbf{x}_i, \mathbf{x}_j)\} \quad (3-5)$$

式中, $d(\mathbf{x}_i, \mathbf{x}_j)$ 为两样本间的欧氏距离。互达距离将低密度区域的样本间距离适度放大, 使簇层级的构建对密度差异更加稳健。算法在互达距离图上构建最小生成树并凝聚为簇层级树, 依据簇的稳定性自层级树中提取最终的簇划分, 密度过低、无法归入任何稳定簇的样本则被标记为噪声点。算法的完整细节可参阅相关文献^[5]。

聚类中需确定两个超参数: 最小簇规模 m_{clst} , 决定可被视作一个簇的最小样本数; 簇选择阈值 ϵ , 影响自层级树提取簇时的粒度。本节以轮廓系数为评价指标, 通过网格搜索确定二者的最优组合。对样本 $\mathbf{x}_i$, 其轮廓系数定义为:

$$s_i = \frac{b_i - a_i}{\max \{a_i, b_i\}} \quad (3-6)$$

式中, a_i 为样本 $\mathbf{x}_i$ 到同簇其余样本的平均距离; b_i 为其到最近异簇样本的平均距离。全体样本轮廓系数的均值越大, 表明簇内越紧致、簇间越分离, 对应的超参数组合越优。

HDBSCAN 将部分低密度样本判为噪声点, 而后续的条件生成要求每个家庭均持有画像标签, 因此需对噪声点进行归并。本节采用加权 K 近邻 (K-Nearest Neighbors, KNN) 方法: 对每个噪声样本 $\mathbf{x}_i$, 在已获得簇标签的样本中检索其 K 个

最近邻 $\mathcal{N}_K(\mathbf{x}_i)$ ，按距离倒数加权投票确定其归属：

$$c_i = \arg \max_{c \in \mathcal{C}} \sum_{j \in \mathcal{N}_K(\mathbf{x}_i)} \frac{\mathbb{I}[c_j = c]}{d(\mathbf{x}_i, \mathbf{x}_j) + \delta} \quad (3-7)$$

式中, $\mathcal{C}$ 为簇标签集合； c_j 为近邻样本 j 的簇标签； $\mathbb{I}[\cdot]$ 为指示函数。距离越近的近邻投票权重越大。上述各超参数（含近邻数 K ）均通过基于轮廓系数的网格搜索确定。

经特征构建、聚类与噪声归并，每个样本家庭均被赋予唯一的画像标签 $s_i \in \{1, 2, \dots, S\}$ ，其中 S 为画像群组总数。画像标签将作为条件信息输入3.3节的分层扩散 Transformer 模型，约束成员级属性的条件生成过程。

3.3 分层扩散 Transformer 模型构建

在家庭画像机制提供条件信息的基础上，本节构建分层扩散 Transformer 模型，用于从加噪的家庭级属性、个人级属性与家庭结构图中逐步还原真实的家庭属性与结构。本节首先定义模型的输入数据结构与总体结构，然后给出分层扩散过程的数学定义，进而依次阐述家庭级扩散 Transformer、家庭结构表征与个人级扩散 Transformer 三个核心模块，最后给出损失函数与模型训练方式。

3.3.1 模型输入与总体结构

考虑到数据的层级特性，模型须有效刻画家庭级与个人级属性间的依赖关系。为此，首先定义模型的输入数据结构。记 $\mathbf{h}_i \in \mathbb{R}^{d_h}$ 为家庭 i 的家庭级属性向量， $\mathbf{P}_i = [\mathbf{p}_{i1}, \mathbf{p}_{i2}, \dots, \mathbf{p}_{iM}]^\top \in \mathbb{R}^{M \times d_p}$ 为其个人级属性矩阵，其中 M 为成员数上限， d_p 为个人级属性维数。由于各家庭成员数不等，本节采用定长表征： M 依据样本中的最大家庭规模设定，成员数不足 M 的家庭以零向量填充个人级属性矩阵，并引入成员存在标志位指示各成员是否真实存在，非真实存在的成员标志位为零。就本文数据而言（详见??节），家庭级包含 8 种数值变量与 1 种类别变量，one-hot 编码后 $d_h = 10$ ；个人级包含年龄这 1 项数值变量与性别、驾照持有情况、与户主关系、受教育程度、职业 5 项类别变量，one-hot 编码后 $d_p = 50$ ，成员数上限 $M = 8$ 。为便于生成模型训练，所有数值属性均做 z-score 标准化。

在上述输入数据之上，为刻画家庭结构，进一步构建家庭结构图。记 $\mathcal{G}_i = (\mathcal{V}_i, \mathcal{E}_i, \mathbf{A}_i)$ 为家庭 i 的结构图，其中节点集 $\mathcal{V}_i$ 表示家庭成员，边集 $\mathcal{E}_i$ 表示成员间的两两关系， $\mathbf{A}_i \in \{0, 1\}^{M \times M}$ 为邻接矩阵。在节点类型方面，按性别与年龄组的组合将成员划分为 6 类（节点类型集 $\mathcal{T}_v$ 的规模 $|\mathcal{T}_v| = 6$ ）：年龄组分为儿童（年龄 < 18

岁)、成人 ($18 \leq \text{年龄} < 60$ 岁) 与老人 (年龄 ≥ 60 岁), 性别分为男与女, 基本覆盖调查数据中的全部成员类型; 节点特征 $\mathbf{f}_{ij} \in \{0,1\}^{|\mathcal{T}_v|}$ 为第 j 名成员节点类型的 one-hot 编码。在边类型方面, 定义配偶、亲子、祖孙、兄弟姐妹与其他亲属 5 类家庭关系 (边类型集 $\mathcal{T}_e$ 的规模 $|\mathcal{T}_e| = 5$); 边特征 $\mathbf{e}_{ijk} \in \{0,1\}^{|\mathcal{T}_e|}$ 为成员 j 与成员 k 间关系类型的 one-hot 编码。邻接矩阵在实际存在的成员间构造全连接; 成员数不足 M 的家庭, 其非真实存在成员对应的节点特征、邻接矩阵与边特征均以零填充。

基于上述定义, 分层扩散 Transformer 模型的目标是: 在画像标签 c_i 的条件下, 还原家庭级属性 $\mathbf{h}_i$ 、个人级属性 $\mathbf{P}_i$ 与家庭结构图 $\mathcal{G}_i$ 的联合分布。围绕该目标, 模型主体由四个模块构成: (1) 家庭级扩散 Transformer, 在画像条件下生成家庭级属性; (2) 图变分自编码器 (Graph Variational Autoencoder, GraphVAE) 解码器, 由生成的家庭属性预测家庭结构图; (3) 异质图 Transformer (Heterogeneous Graph Transformer, HGT), 从预测的结构图中提取成员结构特征; (4) 个人级扩散 Transformer, 在家庭属性、画像信息与结构特征的共同条件下生成个人级属性。模型总体结构如图 3-2 所示。




图 3-2 分层扩散 Transformer 模型总体结构

3.3.2 分层扩散过程定义

在阐述分层扩散 Transformer 模型各模块之前, 先给出扩散模型扩散过程的定义。本模型以去噪扩散概率模型 (Denoising Diffusion Probabilistic Model, DDPM)^[10]

为基础，其建模思想是构造前向加噪-反向去噪的双向过程：前向过程将数据逐步破坏为纯噪声，反向过程学习逆转这一破坏，从而能够由噪声生成服从数据分布的新样本。记 $\mathbf{x}_0$ 为一个原始数据样本，下标 0 表示未加噪的原始状态；在本章中， $\mathbf{x}$ 统一指代待生成的属性数据，即家庭级属性向量 $\mathbf{h}$ 或个人级属性矩阵 $\mathbf{P}$ ，两个层级共享同一扩散过程定义。前向扩散过程按预设的方差序列 $\{\beta_t\}_{t=1}^T$ 在 T 个时间步内逐步注入高斯噪声：

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I}) \quad (3-8)$$

式中， $\mathbf{x}_t$ 为经 t 步加噪后的样本； $q(\cdot | \cdot)$ 表示前向过程的条件转移分布； $\beta_t \in (0, 1)$ 为第 t 步注入噪声的方差，通常设置为随 t 递增的序列，使噪声注入由弱到强； $\mathcal{N}(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma})$ 表示均值为 $\boldsymbol{\mu}$ 、协方差矩阵为 $\boldsymbol{\Sigma}$ 的高斯分布； $\mathbf{I}$ 为单位矩阵。

令 $\alpha_t = 1 - \beta_t$ ， $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ ，则任意时间步的加噪样本可由 $\mathbf{x}_0$ 直接采样得到：

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I}) \quad (3-9)$$

式中， α_t 为第 t 步的信号保留系数； $\bar{\alpha}_t$ 为其自第 1 步至第 t 步的累积乘积，刻画第 t 步样本中原始信号的留存比例，随 t 增大而趋近于 0，故 $\mathbf{x}_T$ 趋近于标准高斯噪声， T 为扩散过程的总步数。式 (3-9) 经重参数化可写为 $\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}$ ，其中 $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 为标准高斯噪声，该形式避免了逐步采样，可一步构造任意时间步的训练样本。

值得注意的是，若对家庭级属性与个人级属性独立加噪，家庭属性与个人属性在扩散过程中的层级关联将被噪声切断。为在扩散过程中保留层级间依赖，本节为家庭属性与个人属性构造相关噪声。记 $\boldsymbol{\epsilon}^h$ 与 $\boldsymbol{\epsilon}^p$ 分别为家庭级与个人级的独立标准高斯噪声，个人级实际注入的噪声构造为：

$$\tilde{\boldsymbol{\epsilon}}^p = \rho \cdot \text{expand}(\boldsymbol{\epsilon}^h) + \sqrt{1 - \rho^2} \cdot \boldsymbol{\epsilon}^p \quad (3-10)$$

式中， $\rho \in [0, 1]$ 为控制层级依赖强度的相关系数； $\text{expand}(\cdot)$ 将家庭级噪声广播至个人级维度。该相关噪声设计使同一家庭的成员在扩散过程中共享共性的潜在成分，同时保留成员各自的随机变异。

3.3.3 家庭级扩散 Transformer 模块

家庭级扩散 Transformer 以加噪的家庭属性 $\mathbf{h}_t^h$ 为输入，在画像标签 c 与画像特征中心 $\mathbf{z}_c$ （画像 c 内样本画像特征的质心）的条件下预测原始家庭属性，以保证生成的家庭属性符合所属画像群组的特征。首先，将加噪家庭属性线性投影至隐藏维度：

$$\mathbf{h}^{(0)} = \text{Linear}(\mathbf{h}_t^h) \in \mathbb{R}^{1 \times d} \quad (3-11)$$

式中, d 为隐藏维度, $\text{Linear}(\cdot)$ 为线性变换层。

随后, 将噪声时间步 t 、画像标签 c 与画像特征中心 $\mathbf{z}_c$ 分别嵌入并融合, 构成作用于家庭属性生成的条件向量 $\mathbf{c}^h$:

$$\mathbf{c}^h = \text{TimeEmbed}(t) + \text{LayerNorm}(\text{LabelEmbed}(c) + \text{ProfileProj}(\mathbf{z}_c)) \quad (3-12)$$

式中, $\text{TimeEmbed}(\cdot)$ 为正弦位置编码接多层感知机的时间嵌入模块; $\text{LabelEmbed}(\cdot)$ 为可学习的标签嵌入表; $\text{ProfileProj}(\cdot)$ 为将画像特征中心线性投影至隐藏维度的投影层; LayerNorm 层归一化用于稳定条件向量的数值尺度。

在模块主体方面, 本节采用扩散 Transformer (Diffusion Transformer, DiT) 架构^[11], 由 L 个堆叠的 DiT 块构成, 每个 DiT 块以自注意力机制与多层感知机捕捉属性间的长程依赖与复杂模式, 并通过零初始化的自适应层归一化 (adaptive Layer Normalization, adaLN-Zero) 机制注入条件信息。各 DiT 块执行:

$$\begin{aligned} \mathbf{h}^{(\ell)} &= \mathbf{h}^{(\ell-1)} + g_1^{(\ell)} \cdot \text{Attention}\left(\text{modulate}\left(\text{LN}(\mathbf{h}^{(\ell-1)}), \beta_1^{(\ell)}, \gamma_1^{(\ell)}\right)\right) \\ \mathbf{h}^{(\ell)} &= \mathbf{h}^{(\ell)} + g_2^{(\ell)} \cdot \text{MLP}\left(\text{modulate}\left(\text{LN}(\mathbf{h}^{(\ell)}), \beta_2^{(\ell)}, \gamma_2^{(\ell)}\right)\right) \end{aligned} \quad (3-13)$$

式中,

$$\ell = 1, 2, \dots, L$$

为 DiT 块的层数; $\text{Attention}(\cdot)$ 与 $\text{MLP}(\cdot)$ 分别为自注意力模块与多层感知机模块; $\text{modulate}(\mathbf{x}, \beta, \gamma) = \gamma \odot \mathbf{x} + \beta$ 为调制运算, $\odot$ 表示逐元素相乘; 平移向量、缩放向量与门控权重 $(\beta_1^{(\ell)}, \gamma_1^{(\ell)}, g_1^{(\ell)}, \beta_2^{(\ell)}, \gamma_2^{(\ell)}, g_2^{(\ell)})$ 均由条件向量 $\mathbf{c}^h$ 经线性层预测得到; $\text{LN}(\cdot)$ 为层归一化。借助堆叠的 DiT 块, 模块在画像信息的引导下有效刻画家庭属性间的复杂关联。

经最后一个 DiT 块后, 输出表征送入末端输出层: 先施加自适应层归一化, 再经带层归一化与 GELU 激活的两层多层感知机, 得到去噪后的家庭属性预测 $\hat{\mathbf{h}}_0$ 。

3.3.4 基于 GraphVAE 与异质图 Transformer 的家庭结构表征

获得家庭属性预测 $\hat{\mathbf{h}}_0$ 后, 本文采用方法与既有文献最关键的区别在于还原家庭结构, 用以衔接生成的家庭级属性与个人级属性。本小节先以 GraphVAE 解码器由家庭属性预测家庭结构图, 再以异质图 Transformer 从预测图中提取各成员的结构特征。

在结构图预测方面, 采用 GraphVAE 解码器^[12] 对预测的家庭属性解码。解码器 GraphDecoder 由带 BatchNorm 与 ReLU 激活的四层多层感知机构成, 逐层细化潜在表征并输出软化的图结构:

$$(\tilde{\mathbf{V}}, \tilde{\mathbf{E}}, \tilde{\mathbf{A}}) = \text{GraphDecoder}(\hat{\mathbf{h}}_0) \quad (3-14)$$

式中, $\tilde{\mathbf{V}} \in \mathbb{R}^{M \times |\mathcal{T}_v|}$ 为预测的节点类型概率分布; $\tilde{\mathbf{E}} \in \mathbb{R}^{M \times M \times |\mathcal{T}_e|}$ 为预测的边类型概率分布; $\tilde{\mathbf{A}} \in \mathbb{R}^{M \times M}$ 为预测的邻接矩阵。为在保持离散结构语义的同时支持端到端训练, 对类别型输出施加 Gumbel-Softmax 松弛^[13]:

$$\tilde{\mathbf{V}} = \text{GumbelSoftmax}(\tilde{\mathbf{V}}; \kappa), \quad \tilde{\mathbf{E}} = \text{GumbelSoftmax}(\tilde{\mathbf{E}}; \kappa) \quad (3-15)$$

式中, κ 为控制松弛平滑程度的温度参数。对邻接矩阵则施加 Sigmoid 激活, 使其取值落于 (0,1) 区间:

$$\tilde{\mathbf{A}} = \text{Sigmoid}(\tilde{\mathbf{A}}) \quad (3-16)$$

在结构特征提取方面, 采用异质图 Transformer (Heterogeneous Graph Transformer, HGT)^[14] 处理预测的结构图。HGT 专为具有多样类型节点与边的异质图设计, 与家庭结构图中多样的成员类型与关系类型的特性相契合。HGT 由特征投影层与多层基于注意力的消息传递模块构成, 消息传递在聚合邻居信息时显式区分节点与边的类型。特征投影层将节点类型概率分布投影为初始节点特征:

$$\mathbf{U}^{(0)} = \mathbf{W}^{\text{proj}} \tilde{\mathbf{V}} \in \mathbb{R}^{M \times |\mathcal{T}_v|} \quad (3-17)$$

式中, $\mathbf{W}^{\text{proj}}$ 为可学习的投影矩阵; $\mathbf{U}^{(0)}$ 为初始节点特征矩阵。

每个 HGT 层执行带类型特定变换的异质消息传递, 其计算流程可概括为四步: 先按节点类型做特定投影, 再按关系类型变换键与值, 继而以预测的图结构为掩码加权聚合消息, 最后按节点类型做输出变换。下面依次阐述。

在节点类型特定投影方面, 为每种节点类型定义独立的查询、键与值投影, 以捕捉户主、配偶、子女等不同家庭角色的独有特征:

$$\mathbf{Q}^{(\tau)} = \mathbf{U}^{(0)} \mathbf{W}_Q^{(\tau)} + \mathbf{b}_Q^{(\tau)}, \quad \mathbf{K}^{(\tau)} = \mathbf{U}^{(0)} \mathbf{W}_K^{(\tau)} + \mathbf{b}_K^{(\tau)}, \quad \mathbf{V}^{(\tau)} = \mathbf{U}^{(0)} \mathbf{W}_V^{(\tau)} + \mathbf{b}_V^{(\tau)} \quad (3-18)$$

式中, $\tau \in \mathcal{T}_v$ 为节点类型索引; $\mathbf{Q}^{(\tau)}$ 、 $\mathbf{K}^{(\tau)}$ 与 $\mathbf{V}^{(\tau)} \in \mathbb{R}^{M \times d}$ 分别为假定全部节点属于类型 τ 时的查询、键与值表征矩阵; $\mathbf{W}_Q^{(\tau)}$ 、 $\mathbf{W}_K^{(\tau)}$ 、 $\mathbf{W}_V^{(\tau)} \in \mathbb{R}^{d \times d}$ 与 $\mathbf{b}_Q^{(\tau)}$ 、 $\mathbf{b}_K^{(\tau)}$ 、 $\mathbf{b}_V^{(\tau)} \in \mathbb{R}^d$ 为类型 τ 专属的可学习投影矩阵与偏置。随后, 将各表征沿特征维等分为 H 个注意力头, 记第 h 头的子表征为 $\mathbf{Q}^{(\tau,h)}$ 、 $\mathbf{K}^{(\tau,h)}$ 、 $\mathbf{V}^{(\tau,h)} \in \mathbb{R}^{M \times d_k}$, 其中 H 为注意力头数, $d_k = d/H$ 为每头的特征维度。

在关系类型特定变换方面, 按关系类型对键与值子表征进行变换, 以刻画不同关系类型对消息传递的差异化影响。对每种关系类型 $r \in \mathcal{T}_e$ 与注意力头 h :

$$\tilde{\mathbf{K}}^{(\tau,r,h)} = \mathbf{K}^{(\tau,h)} \mathbf{W}_{\text{ATT}}^{(r,h)}, \quad \tilde{\mathbf{V}}^{(\tau,r,h)} = \mathbf{V}^{(\tau,h)} \mathbf{W}_{\text{MSG}}^{(r,h)} \quad (3-19)$$

式中, $\tilde{\mathbf{K}}^{(\tau,r,h)}$ 与 $\tilde{\mathbf{V}}^{(\tau,r,h)} \in \mathbb{R}^{M \times d_k}$ 分别为类型 τ 节点的键与值经关系 r 变换后的表征; $\mathbf{W}_{\text{ATT}}^{(r,h)}$ 、 $\mathbf{W}_{\text{MSG}}^{(r,h)} \in \mathbb{R}^{d_k \times d_k}$ 分别为关系 r 在头 h 上专属的可学习注意力变换矩阵与消息

变换矩阵。在此基础上,对类型为 τ_t 的目标节点 i , 类型为 τ_s 的源节点 j 经关系 r 在头 h 上传递的注意力得分为:

$$\alpha_{ij}^{(\tau_s, \tau_t, r, h)} = \frac{\mathbf{Q}_i^{(\tau_t, h)} \cdot \left(\tilde{\mathbf{K}}_j^{(\tau_s, r, h)} \right)^\top}{\sqrt{d_k}} \cdot \mu^{(r, h)} \quad (3-20)$$

式中, $\mathbf{Q}_i^{(\tau_t, h)}$ 为矩阵 $\mathbf{Q}^{(\tau_t, h)}$ 的第 i 行, 即目标节点 i 的查询向量; $\tilde{\mathbf{K}}_j^{(\tau_s, r, h)}$ 为矩阵 $\tilde{\mathbf{K}}^{(\tau_s, r, h)}$ 的第 j 行, 即源节点 j 经关系 r 变换后的键向量; 查询由目标节点生成、键由源节点生成, 以刻画关系的方向性; $(\cdot)^\top$ 表示转置, 分母 $\sqrt{d_k}$ 为防止内积随维度增大而过大的缩放项; $\mu^{(r, h)}$ 为关系 r 在头 h 上的可学习缩放因子, 用于调节不同关系类型的整体重要性。

在消息聚合环节, 注意到上述得分是在“节点属于某类型、边属于某关系”的假定下计算的, 而预测图中节点类型、边类型与边的存在性均为预测概率, 因此构造组合掩码以加权各假定情形:

$$m_{ij}^{(r, \tau_s, \tau_t)} = \tilde{v}_{j, \tau_s} \cdot \tilde{v}_{i, \tau_t} \cdot \tilde{e}_{ij, r} \cdot \tilde{A}_{ij} \quad (3-21)$$

式中, $\tilde{v}_{j, \tau_s}$ 与 $\tilde{v}_{i, \tau_t}$ 分别为源节点 j 属于类型 τ_s 、目标节点 i 属于类型 τ_t 的预测概率; $\tilde{e}_{ij, r}$ 为边 (j, i) 属于关系 r 的预测概率; $\tilde{A}_{ij}$ 为该边存在的预测概率; $m_{ij}^{(r, \tau_s, \tau_t)}$ 即类型-关系组合 (τ_s, τ_t, r) 下消息路径 $j \rightarrow i$ 成立的联合置信权重, 当图结构退化为硬指派时其取值为 0 或 1, 组合掩码随之退化为常规的硬掩码。

以组合掩码加权, 将注意力得分与消息在全部类型-关系组合上累加, 得到源节点 j 对目标节点 i 在头 h 上的聚合注意力与聚合消息:

$$\bar{\alpha}_{ij}^{(h)} = \sum_{r \in \mathcal{T}_e} \sum_{\tau_s, \tau_t \in \mathcal{T}_v} m_{ij}^{(r, \tau_s, \tau_t)} \cdot \alpha_{ij}^{(\tau_s, \tau_t, r, h)} \quad (3-22)$$

$$\bar{\mathbf{M}}_{ij}^{(h)} = \sum_{r \in \mathcal{T}_e} \sum_{\tau_s, \tau_t \in \mathcal{T}_v} m_{ij}^{(r, \tau_s, \tau_t)} \cdot \alpha_{ij}^{(\tau_s, \tau_t, r, h)} \cdot \tilde{\mathbf{V}}_j^{(\tau_s, r, h)} \quad (3-23)$$

式中, $\bar{\alpha}_{ij}^{(h)}$ 为消息路径 $j \rightarrow i$ 在头 h 上的聚合注意力得分; $\tilde{\mathbf{V}}_j^{(\tau_s, r, h)}$ 为矩阵 $\tilde{\mathbf{V}}^{(\tau_s, r, h)}$ 的第 j 行, 即源节点 j 的变换值向量; $\bar{\mathbf{M}}_{ij}^{(h)} \in \mathbb{R}^{d_k}$ 为节点 j 向节点 i 传递的注意力加权消息。为衡量各源节点对目标节点的相对影响, 将聚合注意力在源节点维度上归一化, 并据此聚合得到目标节点的消息表征:

$$\hat{\alpha}_{ij}^{(h)} = \frac{\bar{\alpha}_{ij}^{(h)}}{\sum_k \bar{\alpha}_{ik}^{(h)} + \delta}, \quad \mathbf{m}_i^{(h)} = \sum_j \hat{\alpha}_{ij}^{(h)} \cdot \bar{\mathbf{M}}_{ij}^{(h)} \quad (3-24)$$

式中, $\hat{\alpha}_{ij}^{(h)}$ 为归一化后的注意力权重, 分母中 k 遍历全部源节点; δ 为保证数值稳定的小正常数; $\mathbf{m}_i^{(h)} \in \mathbb{R}^{d_k}$ 为目标节点 i 在头 h 上自全部源节点聚合的消息。

在类型特定输出方面, 记 $\mathbf{m}^{(h)} = [\mathbf{m}_1^{(h)}, \dots, \mathbf{m}_M^{(h)}]^\top \in \mathbb{R}^{M \times d_k}$ 为头 h 上全部节点的消息矩阵, 拼接多头输出后施加类型特定的输出变换, 并辅以可学习的残差连接与层归一化:

$$\mathbf{O}^{(\tau)} = \text{Dropout} \left(\text{GELU} \left(\text{Concat}(\mathbf{m}^{(1)}, \dots, \mathbf{m}^{(H)}) \mathbf{W}_o^{(\tau)} + \mathbf{b}_o^{(\tau)} \right) \right) \quad (3-25)$$

$$\mathbf{U}^{(\tau)} = \text{LayerNorm} \left(\text{Sigmoid}(\lambda_\tau) \cdot \mathbf{O}^{(\tau)} + (1 - \text{Sigmoid}(\lambda_\tau)) \cdot \mathbf{U}^{(\tau)} \right) \quad (3-26)$$

式中, $\text{Concat}(\cdot)$ 表示将 H 个头的消息矩阵沿特征维拼接, 拼接后维度恢复为 $\mathbb{R}^{M \times d}$; $\text{GELU}(\cdot)$ 为激活函数; $\text{Dropout}(\cdot)$ 为随机失活操作; $\mathbf{O}^{(\tau)} \in \mathbb{R}^{M \times d}$ 为类型 τ 分支的输出变换结果; $\mathbf{W}_o^{(\tau)}$ 与 $\mathbf{b}_o^{(\tau)}$ 为该类型的输出投影矩阵与偏置, 将聚合消息映射回该类型节点的特征空间; λ_τ 为类型 τ 的可学习跳连权重, 经 Sigmoid 压缩至 $(0, 1)$ 区间后实现消息支路与残差支路的自适应加权; $\mathbf{U}^{(\tau)}$ 为残差支路输入, 取初始投影特征 $\mathbf{U}^{(0)}$ 在类型 τ 分支上的对应部分; $\mathbf{U}^{(\tau)} \in \mathbb{R}^{M \times d}$ 为类型 τ 分支更新后的节点特征。

各类型的输出分支并行计算后, 节点 i 的最终表征按其软类型分布加权合成:

$$\mathbf{u}'_i = \sum_{\tau \in \mathcal{T}_v} \tilde{\mathcal{V}}_{i,\tau} \cdot \mathbf{U}'_i^{(\tau)} \quad (3-27)$$

式中, $\tilde{\mathcal{V}}_{i,\tau}$ 为节点 i 属于类型 τ 的预测概率; $\mathbf{U}'_i^{(\tau)}$ 为矩阵 $\mathbf{U}^{(\tau)}$ 的第 i 行, 即类型 τ 分支下节点 i 的更新特征; $\mathbf{u}'_i \in \mathbb{R}^d$ 为节点 i 融合全部类型分支后的最终表征。

3.3.5 个人级扩散 Transformer 模块

作为模型的末端组件, 个人级扩散 Transformer 在生成的家庭属性、画像信息与 HGT 提取的成员结构特征的共同条件下, 为全部家庭成员生成个人级属性, 保证生成的成员属性与家庭情境及家庭结构相协调。

首先, 对加噪的个人级属性做隐藏维度投影。记 $\mathbf{P}_t \in \mathbb{R}^{M \times d_p}$ 为加噪的个人级属性矩阵, $\mathcal{M} \subseteq \{1, \dots, M\}$ 为成员掩码, 即真实存在成员是否存在标识的集合。对掩码指示的有效成员逐一投影:

$$\mathbf{p}_j^{(0)} = \text{Linear}(\mathbf{P}_{t,j}) \in \mathbb{R}^d, \quad \forall j \in \{1, \dots, M\} \quad (3-28)$$

式中, $\mathbf{P}_{t,j}$ 为矩阵 $\mathbf{P}_t$ 的第 j 行, 即成员 j 的加噪属性向量; $\text{Linear}(\cdot)$ 为线性投影层; $\mathbf{p}_j^{(0)}$ 为成员 j 的初始隐藏表征。将各成员表征按行堆叠, 记 $\mathbf{p}^{(0)} = [\mathbf{p}_1^{(0)}, \dots, \mathbf{p}_M^{(0)}]^\top \in \mathbb{R}^{M \times d}$ 为初始成员表征矩阵, 后续 DiT 块在该矩阵上逐层更新。

为整合各类条件信息, 构造分别服务于交叉注意力机制与自适应层归一化机制的两个条件向量。前者融合 HGT 提取的图结构特征、家庭级模块输出的家庭属

性预测与时间步嵌入。其中，图结构特征由 HGT 末层节点表征展平后投影得到，以承载家庭内部关系与成员构成信息：

$$\boldsymbol{\psi} = \text{Linear}(\text{Flatten}(\mathbf{U}^{(L_g)})) \in \mathbb{R}^d \quad (3-29)$$

式中， L_g 为 HGT 的层数； $\mathbf{U}^{(L_g)} = [\mathbf{u}'_1, \dots, \mathbf{u}'_M]^\top \in \mathbb{R}^{M \times d}$ 为经 L_g 层消息传递后由各节点最终表征堆叠而成的末层节点表征矩阵； $\text{Flatten}(\cdot)$ 将矩阵按行展平为 Md 维向量； $\boldsymbol{\psi}$ 为图结构特征向量。交叉注意力条件向量构造为：

$$\mathbf{c}^{\text{cross}} = \text{LayerNorm}(\boldsymbol{\psi} + \text{FamilyProj}(\hat{\mathbf{h}}_0) + \text{TimeEmbed}(t)) \in \mathbb{R}^d \quad (3-30)$$

式中， $\hat{\mathbf{h}}_0$ 为3.3.3小节家庭级模块输出的去噪家庭属性预测； $\text{FamilyProj}(\cdot)$ 为将家庭属性线性投影至隐藏维度的投影层； $\text{TimeEmbed}(\cdot)$ 为与式 (3-12)相同的时间嵌入模块。

自适应层归一化条件向量则与家庭级模块一致，由画像标签 c 、画像特征中心 $\mathbf{z}_c$ 与时间步 t 构成：

$$\mathbf{c}^{\text{ada}} = \text{LayerNorm}(\text{LabelEmbed}(c) + \text{ProfileProj}(\mathbf{z}_c)) + \text{TimeEmbed}(t) \in \mathbb{R}^d \quad (3-31)$$

式中， $\text{LabelEmbed}(\cdot)$ 与 $\text{ProfileProj}(\cdot)$ 为与式 (3-12)相同的标签嵌入与画像中心投影模块。两个条件向量分工明确： $\mathbf{c}^{\text{ada}}$ 承载家庭画像类别信息，经自适应层归一化作用于全体成员； $\mathbf{c}^{\text{cross}}$ 承载本家庭特有的属性与结构信息，经交叉注意力供各成员按需读取。

基于上述条件信息，个人级扩散 Transformer 由 L 个堆叠的、以交叉注意力增强的 adaLN-Zero 式 DiT 块构成，在家庭级语境与结构信息的引导下刻画成员属性间的依赖。每个 DiT 块分两个阶段执行。第一阶段遵循标准 DiT 结构：

$$\begin{aligned} \tilde{\mathbf{p}}^{(\ell)} &= \mathbf{p}^{(\ell-1)} + g_1^{(\ell)} \cdot \text{MaskedMHA} \left(\text{modulate} \left(\text{LN}(\mathbf{p}^{(\ell-1)}), \boldsymbol{\beta}_1^{(\ell)}, \boldsymbol{\gamma}_1^{(\ell)} \right) \right) \\ \tilde{\mathbf{p}}^{(\ell)} &= \tilde{\mathbf{p}}^{(\ell)} + g_2^{(\ell)} \cdot \text{MLP} \left(\text{modulate} \left(\text{LN}(\tilde{\mathbf{p}}^{(\ell)}), \boldsymbol{\beta}_2^{(\ell)}, \boldsymbol{\gamma}_2^{(\ell)} \right) \right) \end{aligned} \quad (3-32)$$

式中， $\ell \in \{1, \dots, L\}$ 为 DiT 块索引； $\mathbf{p}^{(\ell-1)}$ 为第 $\ell-1$ 块输出的成员表征矩阵； $\tilde{\mathbf{p}}^{(\ell)}$ 为第一阶段的中间表征； $\text{MaskedMHA}(\cdot)$ 为带键端填充掩码的多头自注意力，掩码按 $\mathcal{M}$ 屏蔽无效成员，使注意力仅在真实成员间计算； $\text{modulate}(\cdot)$ 与 $\text{LN}(\cdot)$ 与式 (3-13)相同；调制参数 $(\boldsymbol{\beta}_1^{(\ell)}, \boldsymbol{\gamma}_1^{(\ell)}, g_1^{(\ell)}, \boldsymbol{\beta}_2^{(\ell)}, \boldsymbol{\gamma}_2^{(\ell)}, g_2^{(\ell)})$ 由条件向量 $\mathbf{c}^{\text{ada}}$ 经带 SiLU 激活的线性层预测，使成员特征的归一化随画像信息自适应调整。

第二阶段引入交叉注意力以吸收家庭属性与图结构条件，并辅以前馈层。该

阶段各运算对每个有效成员并行执行：

$$\begin{aligned}
 \mathbf{a}^{(\ell)} &= \text{CrossMHA}(\text{LN}(\tilde{\mathbf{p}}^{(\ell)}), \mathbf{c}^{\text{cross}}, \mathbf{c}^{\text{cross}}) \\
 \mathbf{g}^{(\ell)} &= \text{Sigmoid}(\mathbf{W}_g [\tilde{\mathbf{p}}^{(\ell)}; \mathbf{a}^{(\ell)}]) \\
 \hat{\mathbf{p}}^{(\ell)} &= \tilde{\mathbf{p}}^{(\ell)} + \mathbf{g}^{(\ell)} \odot \text{Dropout}(\mathbf{a}^{(\ell)}) \\
 \mathbf{p}^{(\ell)} &= \hat{\mathbf{p}}^{(\ell)} + \text{Dropout}(\text{MLP}(\text{LN}(\hat{\mathbf{p}}^{(\ell)})))
 \end{aligned} \tag{3-33}$$

式中， $\text{CrossMHA}(\cdot)$ 为多头交叉注意力，三个实参依次为查询、键与值，即以成员表征为查询、以条件向量 $\mathbf{c}^{\text{cross}}$ 为键与值； $\mathbf{a}^{(\ell)}$ 为交叉注意力输出，承载各成员自家庭条件中读取的信息； $[\cdot; \cdot]$ 表示将每个成员的两个 d 维表征沿特征维拼接为 $2d$ 维向量； $\mathbf{W}_g \in \mathbb{R}^{d \times 2d}$ 为可学习投影矩阵； $\mathbf{g}^{(\ell)}$ 为逐成员、逐维度取值于 $(0, 1)$ 的门控向量，自适应控制交叉注意力的信息流入，使模型依据成员特征的当前状态选择性吸收家庭级与结构信息； $\odot$ 表示逐元素相乘； $\hat{\mathbf{p}}^{(\ell)}$ 为门控融合后的表征； $\mathbf{p}^{(\ell)}$ 为该 DiT 块的最终输出。

经最后一个 DiT 块后，输出表征送入与家庭级模块同构的末端输出层，得到全部成员的去噪个人属性预测 $\hat{\mathbf{P}}_0$ 。其中，数值属性（年龄）由线性输出直接预测；分类属性（性别、驾照持有情况、与户主关系、受教育程度与职业）经 softmax 激活输出类别概率分布；成员存在标志位经 Sigmoid 激活输出存在概率。

3.3.6 损失函数与模型训练

模型的输出包括家庭属性预测 $\hat{\mathbf{h}}_0$ 、全部成员的个人属性预测 $\hat{\mathbf{P}}_0$ 与家庭结构图预测 $(\tilde{\mathbf{V}}, \tilde{\mathbf{E}}, \tilde{\mathbf{A}})$ 。为对各输出分量施加监督，总损失构造为：

$$\mathcal{L} = \mathcal{L}_{\text{family}} + \mathcal{L}_{\text{person}} + \mathcal{L}_{\text{graph}} \tag{3-34}$$

式中， $\mathcal{L}_{\text{family}}$ 、 $\mathcal{L}_{\text{person}}$ 与 $\mathcal{L}_{\text{graph}}$ 分别为家庭级损失、个人级损失与图结构损失。以下各损失均对单个家庭样本书写，实际训练中在批内取均值，下面依次阐述。

在家庭级损失方面，按属性类型分为数值与分类两个分量：

$$\mathcal{L}_{\text{family}} = w_{\text{cont}}^h \mathcal{L}_{\text{cont}}^h + w_{\text{cat}}^h \mathcal{L}_{\text{cat}}^h \tag{3-35}$$

式中， $\mathcal{L}_{\text{cont}}^h$ 与 $\mathcal{L}_{\text{cat}}^h$ 分别为数值属性分量与分类属性分量； w_{cont}^h 与 w_{cat}^h 为对应的权重。对数值属性（家庭规模、就业人数、各类车辆保有量等）采用均方误差损失：

$$\mathcal{L}_{\text{cont}}^h = \sum_{k=1}^{d_{\text{cont}}} (\hat{h}_k - h_k)^2 \tag{3-36}$$

式中, d_{cont} 为数值属性个数; $\hat{h}_k$ 与 h_k 分别为家庭属性预测 $\hat{\mathbf{h}}_0$ 与真实家庭属性 $\mathbf{h}$ 中第 k 个数值属性的取值。对分类属性 (是否有在校学生) 采用焦点损失^[15] 以应对类别不均衡:

$$\mathcal{L}_{\text{cat}}^h = -\alpha_f (1 - p_y)^{\gamma_f} \log(p_y) \quad (3-37)$$

式中, y 为该分类属性的真实类别; p_y 为模型对真实类别 y 的预测概率; α_f 为类别平衡因子; γ_f 为聚焦参数, p_y 越接近 1 (样本越易分类), 损失被压低得越多, 从而使训练聚焦于难分类样本。

在个人级损失方面, 损失在成员掩码 $\mathcal{M}$ 指示的全部有效成员上计算: 先逐成员计算各属性损失, 再按家庭聚合, 从而高效处理成员数可变的家庭。个人级损失由属性损失与两项辅助一致性损失构成:

$$\mathcal{L}_{\text{person}} = \sum_{a \in \mathcal{A}_p} w_a \mathcal{L}_a^p + w_{\text{mask}} \mathcal{L}_{\text{mask}} + w_{\text{total}} \mathcal{L}_{\text{total}} \quad (3-38)$$

式中, $\mathcal{A}_p = \{\text{年龄, 性别, 驾照, 关系, 受教育程度, 职业}\}$ 为个人属性集合; $\mathcal{L}_a^p$ 为属性 a 在全部有效成员上的损失, 其中数值属性 (年龄) 采用均方误差, 分类属性采用形如式 (3-37) 的焦点损失; $\mathcal{L}_{\text{mask}}$ 与 $\mathcal{L}_{\text{total}}$ 为掩码损失与成员总数损失; w_a 、 w_{mask} 与 w_{total} 为对应的权重。

两项辅助损失用于保证成员存在标志与家庭规模的一致性。掩码损失对各有效成员的存在标志施加二元交叉熵监督:

$$\mathcal{L}_{\text{mask}} = \frac{1}{M} \sum_{j=1}^M \text{BCE}(\hat{f}_j, f_j) \quad (3-39)$$

式中, $\hat{f}_j \in (0, 1)$ 为成员 j 的存在概率预测值; $f_j \in \{0, 1\}$ 为该成员的真实存在标志; $\text{BCE}(\cdot, \cdot)$ 为二元交叉熵损失。成员总数损失则约束存在概率之和与预测家庭规模的一致性:

$$\mathcal{L}_{\text{total}} = \left(\sum_{j \in \mathcal{M}} \hat{f}_j - \hat{n} \right)^2 \quad (3-40)$$

式中, $\hat{n}$ 为家庭级输出中的家庭规模分量经反标准化 (逆 z -score 变换) 得到的家庭规模预测值。该损失将 “存在标志求和” 与 “家庭规模属性” 两条彼此独立的预测路径绑定, 避免两级输出在家庭人数上自相矛盾。

在图结构损失方面, 以 3.3.1 小节定义的真实家庭结构图 $(\mathcal{V}, \mathcal{E}, \mathbf{A})$ 为标签, 对预测结构图的三个组成部分分别监督:

$$\mathcal{L}_{\text{graph}} = w_{\text{adj}} \mathcal{L}_{\text{adj}} + w_{\text{node}} \mathcal{L}_{\text{node}} + w_{\text{edge}} \mathcal{L}_{\text{edge}} \quad (3-41)$$

式中, $\mathcal{L}_{\text{adj}}$ 为邻接矩阵损失, 对软邻接矩阵 $\tilde{\mathbf{A}}$ 以真实邻接矩阵 $\mathbf{A}$ 为标签施加二元交叉熵, 监督边的存在性; $\mathcal{L}_{\text{node}}$ 与 $\mathcal{L}_{\text{edge}}$ 分别为节点类型损失与边类型损失, 对预

测的节点类型概率分布 $\tilde{\mathcal{V}}$ 与预测的边类型概率分布 $\tilde{\mathcal{E}}$ 以真实类型为标签施加形如式 (3-37) 的焦点损失； w_{adj} 、 w_{node} 与 w_{edge} 为三个分量的权重。

在模型训练方面，本模型采用直接预测原始属性的参数化方式：训练时对每个样本随机抽取时间步 t ，按式 (3-9) 与式 (3-10) 对两级属性施加相关噪声，模型预测原始属性与结构图，并按总损失 $\mathcal{L}$ 反向传播更新参数。值得指出的是，上述损失函数中的各分量权重共同决定了模型对不同输出分量的关注程度，其最优取值随数据分布特征而变化，是 3.6 节超参数调优策略的核心调优对象；具体训练超参数设置见 3.7 节。HiDiT 模型的编程框架与训练伪代码可见附录 A。

3.4 基于能量引导的多地理尺度边际分布对齐机制

训练完成的分层扩散 Transformer 模型刻画的是训练所用样本的联合分布，而依据引论中的困难 (2)，合成人口还须在微观、中观、宏观等多个地理尺度上对齐已知的属性边际分布。本节将该要求转化为去噪采样过程中的均值调整问题：在每个去噪步，以能量函数度量当前生成结果与目标边际分布的偏离，并以其梯度修正去噪分布的均值，使生成方向持续对齐目标边际分布；进一步地，为平衡不同地理尺度对齐目标之间的牵制与矛盾，在每步求解一个优化问题以确定最优的调整方向。该机制无需对核心模型施加任何再训练，即可在不同地理单元上灵活施加各异的边际约束，多尺度宏观统计信息正是经由这一机制注入生成过程。机制的整体流程如图 3-3 所示，下面依次阐述反向去噪采样过程、采样过程中用到的多地理尺度能量函数与引导梯度计算以及地理尺度间梯度冲突协调策略。

3.4.1 反向去噪采样过程

去噪采样遵循 DDPM 的标准流程^[10]：自纯高斯噪声 $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 出发，由训练好的模型在 T 个时间步内逐步去噪，最终得到服从数据分布的合成样本。在每个时间步 t ，给定加噪输入 $\mathbf{x}_t$ ，模型先直接预测去噪后的数据：

$$\hat{\mathbf{x}}_0 = f_{\theta}(\mathbf{x}_t, t, c, \mathbf{z}_c) \quad (3-42)$$

式中， $f_{\theta}(\cdot)$ 为参数为 θ 、训练完成的分层扩散 Transformer 模型，包含 3.3 节所述的全部模块； c 与 $\mathbf{z}_c$ 为作为条件信息的画像标签与画像特征中心； $\hat{\mathbf{x}}_0$ 为模型在第 t 步对原始数据的预测。基于 $\hat{\mathbf{x}}_0$ ，可导出反向转移分布的后验均值：

$$\mu_{\theta}(\mathbf{x}_t, t) = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t} \hat{\mathbf{x}}_0 + \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} \mathbf{x}_t \quad (3-43)$$

式中， $\mu_{\theta}(\mathbf{x}_t, t)$ 为反向转移分布 $q(\mathbf{x}_{t-1} | \mathbf{x}_t, \hat{\mathbf{x}}_0)$ 的均值； β_t 、 $\alpha_t = 1 - \beta_t$ 与 $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ 均与 3.3.2 小节的前向过程定义一致， $\bar{\alpha}_{t-1}$ 为截至第 $t-1$ 步的累积信号保留系数。




图 3-3 基于能量引导的多地理尺度边际分布对齐流程

后验均值是预测数据 $\hat{\mathbf{x}}_0$ 与当前样本 $\mathbf{x}_t$ 的加权组合，权重由方差序列决定。随后执行反向采样步：

$$\mathbf{x}_{t-1} = \mu_{\theta}(\mathbf{x}_t, t) + \sigma_t \xi, \quad \xi \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad (3-44)$$

式中， ξ 为反向采样的随机噪声项； σ_t 为后验标准差， $\sigma_t^2 = \frac{(1 - \bar{\alpha}_{t-1})\beta_t}{1 - \bar{\alpha}_t}$ 为对应的后验方差。如此自 $t = T$ 迭代至 $t = 1$ ，即得最终的合成样本 $\mathbf{x}_0$ 。

针对分层人口合成，采样过程同时维护家庭级属性 $\mathbf{x}^h$ 与个人级属性 $\mathbf{x}^p$ 两条相互耦合的去噪轨迹：每步先由家庭级模块去噪家庭属性并预测家庭结构，再以其为条件去噪个人属性。为保持训练阶段建立的层级依赖，初始噪声 $\mathbf{x}_T^h$ 与 $\mathbf{x}_T^p$ 按式 (3-10) 的方式相关化构造。

3.4.2 多地理尺度能量函数与引导梯度计算

在扩散采样过程中直接对齐多地理尺度、多属性的目标边际分布并非易事。为此，本节引入基于能量的引导机制^[16]：以能量函数 $J(\mathbf{x}_t)$ 度量当前生成结果与目标边际分布之间的偏离程度，并以其关于 $\mathbf{x}_t$ 的梯度修正后验均值，将生成方向持续引导向目标边际分布对其。该机制无需附加训练，且约束的内容与强度可逐地理单元灵活设定。调整后的均值为：

$$\hat{\mu}_t = \mu_{\theta}(\mathbf{x}_t, t) - \eta \nabla_{\mathbf{x}_t} J(\mathbf{x}_t) \quad (3-45)$$

式中, $\hat{\mu}_t$ 为调整后的均值, 替代式 (3-44) 中的 $\mu_\theta(\mathbf{x}_t, t)$ 参与采样; $\eta > 0$ 为控制引导强度的系数; $\nabla_{\mathbf{x}_t} J(\mathbf{x}_t)$ 为能量函数关于当前样本的梯度, 经由 $\hat{\mathbf{x}}_0$ 对 $\mathbf{x}_t$ 的依赖链式求导获得。

边际分布对齐的目标是全体合成人口而非单一批次, 因此占比的估计须将当前批次与此前已生成的累积人口合并。生成过程按地理单元分批进行, 对地理尺度 g 上的某一属性类别 a , 其估计占比为:

$$\hat{q}_{g,a} = \frac{\sum_{i=1}^B \mathbb{I}[\hat{a}_i = a] + N_g^{\text{prev}} \cdot q_{g,a}^{\text{prev}}}{B + N_g^{\text{prev}}} \quad (3-46)$$

式中, B 为当前批次的样本数; $\hat{a}_i$ 为当前批次第 i 个样本由预测 $\hat{\mathbf{x}}_0$ 解码得到的该属性取值; $\mathbb{I}[\cdot]$ 为指示函数; N_g^{prev} 与 $q_{g,a}^{\text{prev}}$ 分别为尺度 g 所辖范围内此前已生成人口的累计样本数与类别 a 的累计占比。

总能量函数由全部受约束地理尺度的能量分量构成:

$$J(\mathbf{x}_t) = \sum_{g=1}^G J_g \quad (3-47)$$

式中, g 为地理尺度索引; G 为施加边际约束的地理尺度总数; J_g 为尺度 g 的能量分量。各尺度对应何种地理单元 (如栅格、行政区、城市) 以及尺度总数 G 的取值, 均由目标城市可用的边际数据决定, 本方法对此不作预设, 本文算例的具体设定见??节。每个尺度分量又可进一步分解为家庭级与个人级两部分:

$$J_g = J_g^h + J_g^p, \quad g = 1, \dots, G \quad (3-48)$$

式中, 上标 h 与 p 分别标记家庭级与个人级属性对应的能量。尺度 g 的家庭级能量构造为受约束属性类别上估计占比与目标占比的加权平方误差:

$$J_g^h = \sum_{a \in \mathcal{A}_g^h} w_{g,a} \cdot (\hat{q}_{g,a} - q_{g,a}^*)^2 \quad (3-49)$$

$$w_{g,a} = w_g^{\text{base}} + \zeta \cdot |\hat{q}_{g,a} - q_{g,a}^*| \quad (3-50)$$

式中, $\mathcal{A}_g^h$ 为尺度 g 上受约束的家庭级属性类别集合; $\hat{q}_{g,a}$ 为按式 (3-46) 估计的占比; $q_{g,a}^*$ 为尺度 g 上类别 a 的目标边际分布; $w_{g,a}$ 为类别 a 在尺度 g 上的能量权重; w_g^{base} 为尺度 g 的基础权重, 体现不同尺度约束的相对优先级; $\zeta > 0$ 为自适应调节强度, 使当前偏差越大的类别获得越高的权重, 从而将引导强度动态集中于对齐欠佳的分量。个人级能量 J_g^p 将式 (3-49) 中的属性类别集合替换为相应的个人级集合 $\mathcal{A}_g^p$ 后按同样方式构造。

由式 (3-47) 至式 (3-50), 能量函数同时汇聚了多个地理尺度、多个属性的对齐目标, 各目标对应的梯度方向未必一致, 简单求和可能引发目标间此消彼长的“跷跷板”效应。为此, 下面引入梯度冲突协调策略。

3.4.3 地理尺度间梯度冲突协调策略

为消解去噪过程中不同引导目标梯度间的冲突，本节采用冲突规避梯度下降（Conflict-Averse Gradient descent, CAGrad）算法^[17]协调各目标的引导方向。考虑到家庭级与个人级属性的维度不同，协调对两个层级分别执行；执行前先将各梯度归一化至单位范数，以保证不同尺度间的公平比较。

对某一层级，记各引导目标的梯度集合为 $\{\mathbf{g}_1, \mathbf{g}_2, \dots, \mathbf{g}_K\}$ ，其中 K 为该层级下引导目标的个数；本文中引导目标按尺度划分，故 $K = G$ 。算法首先计算平均梯度：

$$\bar{\mathbf{g}} = \frac{1}{K} \sum_{k=1}^K \mathbf{g}_k \quad (3-51)$$

式中， $\mathbf{g}_k$ 为第 k 个引导目标的单位化梯度； $\bar{\mathbf{g}}$ 为平均梯度。若全部梯度与平均梯度的内积均非负，即 $\mathbf{g}_k^\top \bar{\mathbf{g}} \geq 0$ 对所有 k 成立，则目标间不存在冲突，直接以 $\bar{\mathbf{g}}$ 作为融合梯度；否则，求解如下二次规划问题以寻找冲突规避的调整权重：

$$\begin{aligned} \min_{\mathbf{w}} \quad & \left\| \bar{\mathbf{g}} + \sum_{k=1}^K w_k (\mathbf{g}_k - \bar{\mathbf{g}}) \right\|_2^2 \\ \text{s.t.} \quad & \sum_{k=1}^K w_k \leq \phi, \quad w_k \geq 0, \quad k = 1, \dots, K \end{aligned} \quad (3-52)$$

式中， $\mathbf{w} = [w_1, \dots, w_K]^\top$ 为待求的调整权重向量， w_k 越大表示融合方向越向目标 k 倾斜； $\|\cdot\|_2$ 为向量的 ℓ_2 范数； $\phi \in (0, 1]$ 为控制冲突规避强度的超参数， ϕ 越大允许融合方向偏离平均梯度的幅度越大。该问题规模仅为目标个数 K ，采用 Frank-Wolfe 算法即可高效求解。记最优解为 $\mathbf{w}^*$ ，融合梯度取为：

$$\mathbf{g}^* = \bar{\mathbf{g}} + \sum_{k=1}^K w_k^* (\mathbf{g}_k - \bar{\mathbf{g}}) \quad (3-53)$$

式中， $\mathbf{g}^*$ 为冲突协调后的融合梯度，以其替代式 (3-45) 中的原始梯度 $\nabla_{\mathbf{x}_i} J(\mathbf{x}_i)$ 参与均值调整。

借助上述带冲突协调的多尺度引导机制，合成人口能够同时逼近不同地理尺度的边际约束，且不以破坏自调查数据习得的属性联合分布为代价；引论中的困难（2）由此得到解决。

3.5 样本零与结构零正则化策略

依据引论中的困难（3），生成模型可能产出两类样本外属性组合：真实存在但未被调查抽中的“样本零”，以及逻辑上不可能成立的“结构零”。前者是合成人口多样性的合法来源，应予保留；后者属无效组合，理应剔除。然而二者在训练数

据中均表现为零频次，模型自身无从区分。为此，本节设计一种事后正则化策略：3.4节的能量引导在生成过程中施加宏观边际约束，本节则在生成结果上施加微观合法性甄别，二者互补。该策略以变分自编码器（Variational Autoencoder, VAE）^[18]构建统一的低维潜空间，以贝叶斯网络（Bayesian Network, BN）^[19]刻画合法属性组合的结构性规律，进而以 BN 对数概率与潜空间距离双判据将生成样本划分为有效样本、样本零与结构零三类，并对结构零予以重生成。策略包含训练与判别两个阶段，下面依次阐述。

在训练阶段，首先训练 VAE 以建立潜空间。VAE 的训练数据为增广数据集 $\mathcal{D}_{\text{aug}} = \mathcal{D}_{\text{hts}} \cup \mathcal{D}_{\text{gen}}$ ，其中 $\mathcal{D}_{\text{hts}}$ 为调查样本集， $\mathcal{D}_{\text{gen}}$ 为 HiDiT 模型的生成样本集。采用增广数据的动机在于：潜空间须同时覆盖真实数据分布与潜在问题样本的分布，否则问题样本在潜空间中的位置无从界定。对任一家庭样本，将其家庭级与个人级属性拼接为联合向量 $\mathbf{x} = [\mathbf{h}; \text{Flatten}(\mathbf{P})]$ ，经 VAE 编码器映射为低维潜表征：

$$\boldsymbol{\omega} = \text{Enc}(\mathbf{x}) \in \mathbb{R}^{d_{\omega}} \quad (3-54)$$

式中， $\text{Flatten}(\cdot)$ 与式 (3-29) 相同，将个人级属性矩阵按行展平； $[\cdot; \cdot]$ 表示向量拼接； $\text{Enc}(\cdot)$ 为训练完成的 VAE 编码器； $\boldsymbol{\omega}$ 为该样本的潜表征； d_{ω} 为潜空间维度。由此，全部家庭-个人属性组合获得了统一的低维表示。

随后，在潜空间上训练 BN 以刻画合法组合的结构性规律。与 VAE 不同，BN 仅以调查样本的潜表征为训练数据，从而习得真实人口模式所对应的条件依赖结构。考虑到 BN 以离散变量为对象，先对潜表征逐维做分位数分箱，将每一维离散化为 n_b 个箱，记离散化后的潜向量为 $\check{\boldsymbol{\omega}}$ ；再以爬山算法（Hill-Climbing）在赤池信息准则（Akaike Information Criterion, AIC）评分下学习网络结构^[20]。训练完成后，BN 给出任一离散化潜向量的对数概率：

$$\log p_{\text{BN}}(\check{\boldsymbol{\omega}}) = \sum_{j=1}^{d_{\omega}} \log p(\check{\omega}_j | \text{Pa}(\check{\omega}_j)) \quad (3-55)$$

式中， $\check{\omega}_j$ 为离散化潜向量的第 j 维分量； $\text{Pa}(\check{\omega}_j)$ 为网络结构中该分量的父节点集合； $p(\check{\omega}_j | \text{Pa}(\check{\omega}_j))$ 为习得的条件概率； $\log p_{\text{BN}}(\check{\boldsymbol{\omega}})$ 度量该潜表征与真实人口模式的相符程度，取值越高表明对应的属性组合越符合调查数据所体现的结构性规律。

在判别阶段，对每个生成样本 $\tilde{\mathbf{x}}$ ，先经式 (3-54) 编码得潜表征 $\tilde{\boldsymbol{\omega}}$ ，再计算两项判据。其一为 BN 对数概率 $\log p_{\text{BN}}(\tilde{\boldsymbol{\omega}})$ ，按式 (3-55) 计算；其二为潜空间距离，定义为生成样本潜表征到全体调查样本潜表征的平均欧氏距离：

$$d_{\text{lat}}(\tilde{\boldsymbol{\omega}}) = \frac{1}{N} \sum_{i=1}^N \|\tilde{\boldsymbol{\omega}} - \boldsymbol{\omega}_i\|_2 \quad (3-56)$$

式中， $\boldsymbol{\omega}_i$ 为第 i 个调查样本的潜表征； N 为调查样本家庭数； $\|\cdot\|_2$ 为向量的 ℓ_2 范数。该距离等价于将生成样本视作单点分布时，其与调查样本潜表征经验分布 μ_{hts}

之间 p 阶 Wasserstein 距离的经验形式 $(\mathbb{E}_{\omega \sim \mu_{\text{hts}}} \|\tilde{\omega} - \omega\|_2^p)^{1/p}$ 在 $p = 1$ 时的取值，从分布层面度量生成样本对调查数据主体的偏离程度。

两项判据的阈值均依据调查样本自身的分布按分位数自适应设定：对数概率阈值 ϑ_{bn} 取全体调查样本 BN 对数概率的下 10% 分位数，含义是生成样本只要不低于 90% 调查样本的模式典型性，即视为符合真实人口模式；距离阈值 ϑ_d 取全体调查样本潜空间距离的上 99% 分位数，含义是超出该界的生成样本比几乎全部调查样本都更远离数据主体。分位数化的设定使阈值随目标城市的数据分布自动适配，无需人工指定绝对数值。基于双判据，生成样本划分为三类：

$$\text{label}(\tilde{\mathbf{x}}) = \begin{cases} \text{有效样本,} & \log p_{\text{BN}}(\tilde{\omega}) \geq \vartheta_{\text{bn}} \\ \text{样本零,} & \log p_{\text{BN}}(\tilde{\omega}) < \vartheta_{\text{bn}} \text{ 且 } d_{\text{lat}}(\tilde{\omega}) \leq \vartheta_d \\ \text{结构零,} & \log p_{\text{BN}}(\tilde{\omega}) < \vartheta_{\text{bn}} \text{ 且 } d_{\text{lat}}(\tilde{\omega}) > \vartheta_d \end{cases} \quad (3-57)$$

式中， ϑ_{bn} 与 ϑ_d 分别为按上述分位数规则设定的对数概率阈值与距离阈值。该划分的直观解释如下：BN 对数概率高的样本符合自调查数据习得的人口模式，直接判为有效；对数概率低但潜表征邻近调查样本者，多为受抽样规模所限而未被 BN 覆盖的稀有合法组合，即样本零；对数概率低且远离数据主体者，则极可能是不应存在的属性组合，即结构零。

在处置方式上，有效样本与样本零均予保留，其中样本零的保留正是合成人口多样性优于简单复刻样本分布的来源；判为结构零的样本则交回 HiDiT 模型重新生成，直至其被判为有效样本或样本零为止。由式 (3-57) 可知，处置环节实际执行的是是否结构零的二元判定，即仅当低概率与远距离同时成立时才予剔除重生成；有效样本与样本零的进一步区分服务于 3.7 节对双零处理效果的统计评估。借助上述正则化策略，合成人口在纳入稀有合法组合、提升多样性的同时阻断了逻辑上不可能的组合，引论中的困难 (3) 由此得到解决。HiDiT 模型的采样流程伪代码见附录 A 中算法 2。

3.6 面向多样化人口分布的两阶段超参数调优策略

针对引论中的困难 (4)，HiDiT 模型包含多个与人口数据特征深度耦合的超参数，主要为式 (3-35) 至式 (3-41) 中的各损失分量权重 w_{cont}^h 、 w_{cat}^h 、 w_a 、 w_{mask} 、 w_{total} 、 w_{adj} 、 w_{node} 、 w_{edge} 以及式 (3-10) 中的层级噪声相关系数 ρ 。受地理区位、经济发展水平等因素影响，不同城市的人口属性分布与依赖结构差异显著，依赖人工经验逐一试错既不经济也难以保证稳定。为此，本节设计两阶段调优策略：第一阶段利用训练数据中属性间的统计依赖构建超参数的先验分布，使搜索过程能够较快

地聚焦于合理的参数空间区域；第二阶段在超参数搜索算法——Hyperband 算法框架^[21]内引入冲突感知机制，对超参数空间进行高效搜索。需要说明的是，本策略针对的是上述与数据特征耦合的超参数；网络层数、隐藏维度等架构类超参数与学习率等常规训练超参数按领域惯例设定或根据交叉验证确定，不在本策略的调优范围内。

3.6.1 基于互信息的先验分布构建

第一阶段基于如下贪心假设：针对相互依赖性越强的属性或变量，模型需投入越多的学习容量予以拟合，故其对应的损失权重应取较高的初值，以获得模型更多的注意力。该假设仅依据依赖强度确定权重初值，并未直接优化合成质量与权重之间的全局关系，所得权重为第二阶段的搜索提供初始分布，而非最终取值。为度量属性间的依赖强度，本节采用互信息以刻画属性间的非线性统计依赖，为先验分布的构建提供量化依据。首先以归一化互信息（Normalized Mutual Information, NMI）度量任意两属性间的依赖强度，对任意一对属性 (X_a, X_b) ：

$$\text{NMI}(X_a, X_b) = \frac{2I(X_a; X_b)}{H(X_a) + H(X_b)} \quad (3-58)$$

式中， X_a 与 X_b 为视作随机变量的两个属性； $I(X_a; X_b) = \sum_{x_a} \sum_{x_b} p(x_a, x_b) \log \frac{p(x_a, x_b)}{p(x_a)p(x_b)}$ 为二者的互信息， $p(x_a, x_b)$ 为联合概率分布， $p(x_a)$ 与 $p(x_b)$ 为各自的边缘分布； $H(\cdot)$ 为香农熵；数值属性在计算前先做分位数离散化。NMI 取值介于 $[0, 1]$ ，1 表示完全依赖，0 表示相互独立。对全部属性两两计算，即得属性间 NMI 矩阵。

基于 NMI 矩阵，将属性按层级划分为家庭级属性组 $\mathcal{A}_h$ 与个人级属性组 $\mathcal{A}_p$ （后者与式 (3-38) 中的个人属性集合一致），并对每个属性组 $\mathcal{A}_k$ 计算组内平均互信息度量同组属性间的平均依赖强度。组内平均互信息度量同组属性间的平均依赖强度：

$$\bar{v}_k^w = \frac{2}{|\mathcal{A}_k|(|\mathcal{A}_k| - 1)} \sum_{\substack{a, b \in \mathcal{A}_k \\ a < b}} \text{NMI}(X_a, X_b) \quad (3-59)$$

式中， k 为属性组索引， $\mathcal{K}$ 为属性组集合， $k \in \mathcal{K}$ ； $|\mathcal{A}_k|$ 为组 k 的属性个数；求和遍历组内全部无序属性对。跨组平均互信息度量组 k 属性与组外全部属性间的平均依赖强度：

$$\bar{v}_k^c = \frac{1}{|\mathcal{A}_k| \cdot |\bar{\mathcal{A}}_k|} \sum_{a \in \mathcal{A}_k} \sum_{b \in \bar{\mathcal{A}}_k} \text{NMI}(X_a, X_b) \quad (3-60)$$

式中， $\bar{\mathcal{A}}_k = \bigcup_{j \neq k} \mathcal{A}_j$ 为组 k 以外全部属性的集合。基于以上两类统计量，按超参数类别构造先验分布。

对家庭级与个人级损失权重，综合组内与跨组依赖构造重要性得分并跨组归一化，得先验均值：

$$\mu_{w_k}^{(0)} = w_0 \cdot \left(1 + \frac{\bar{v}_k^w + \bar{v}_k^c}{\sum_{j \in \mathcal{K}} (\bar{v}_j^w + \bar{v}_j^c)} \right) \quad (3-61)$$

式中， $\mu_{w_k}^{(0)}$ 为组 k 对应损失权重的先验均值，上标 (0) 标记调优起点； w_0 为基准权重。对刻画层级间交互的超参数（如层级噪声相关系数 ρ ），其先验均值基于跨组依赖构造：

$$\mu_{w_{\text{inter}}}^{(0)} = w_0 \cdot (1 + 2 \bar{v}_{\text{avg}}^c) \quad (3-62)$$

式中， $\bar{v}_{\text{avg}}^c = \frac{1}{|\mathcal{K}|} \sum_{k \in \mathcal{K}} \bar{v}_k^c$ 为全部属性组跨组平均互信息的均值；跨组依赖越强，表明层级间关联越紧密，相应超参数的初值越高。

先验标准差则依据属性组依赖结构的复杂程度设定，以组内 NMI 子矩阵的谱熵度量：

$$H_k^{\text{sp}} = - \sum_i \tilde{\lambda}_{k,i} \log \tilde{\lambda}_{k,i} \quad (3-63)$$

$$\sigma_{w_k}^{(0)} = \sigma_0 \cdot (1 + \chi_s \cdot \tilde{H}_k^{\text{sp}}) \quad (3-64)$$

式中， $\tilde{\lambda}_{k,i}$ 为组 k 组内 NMI 子矩阵的第 i 个归一化特征值（各特征值除以特征值之和）； H_k^{sp} 为组 k 的谱熵； $\tilde{H}_k^{\text{sp}} = H_k^{\text{sp}} / \max_j H_j^{\text{sp}}$ 为跨组归一化后的谱熵； $\sigma_{w_k}^{(0)}$ 为先验标准差； σ_0 为基准标准差； $\chi_s > 0$ 为谱熵敏感系数。谱熵越高表明组内依赖结构越复杂、权重最优值的不确定性越大，相应先验越宽，以保留更大的探索空间。最终，初始超参数配置自截断高斯分布 $w_k \sim \mathcal{N}(\mu_{w_k}^{(0)}, (\sigma_{w_k}^{(0)})^2)$ 采样，截断用于保证权重取值非负。

3.6.2 考虑冲突感知的 Hyperband 搜索算法

第二阶段以第一阶段的先验为起点，在 Hyperband 算法^[21] 框架内执行搜索。Hyperband 将逐次减半思想与计算资源的多档分配相结合：每次运行档位具有不同的初始配置数-总计算资源组合启动，先以少量资源粗评大量配置，逐轮淘汰表现落后者，并向保留下来的配置追加资源，从而在固定计算预算内兼顾搜索的广度与评估的深度。在该框架内，本节做两点冲突感知改造：其一，在逐轮的存活选择环节引入考虑冲突感知的最优计算预算分配（Conflict-Aware Optimal Computing Budget Allocation, CA-OCBA）规则，使存活决策同时考虑验证损失与梯度冲突暴露度；其二，设计冲突感知的分布更新机制，依据观测到的损失分量间梯度冲突调整后续档位的采样分布。两点改造的动机一致：梯度冲突暴露度高的配置，其各

目标间的平衡尚未充分显现，给予其更多的存活机会与探索空间，有助于发现更优的权衡。

在梯度冲突检测方面，训练过程中持续监测损失分量间的梯度冲突。对任意一对损失分量 $\mathcal{L}_i$ 与 $\mathcal{L}_j$ ，成对冲突分数定义为：

$$\Lambda_{ij} = \max(0, -\cos\langle \nabla_{\theta}\mathcal{L}_i, \nabla_{\theta}\mathcal{L}_j \rangle) \quad (3-65)$$

式中， $\nabla_{\theta}\mathcal{L}_i$ 为损失分量 $\mathcal{L}_i$ 关于模型参数 θ 的梯度； $\cos\langle \cdot, \cdot \rangle$ 为两向量的余弦相似度； $\Lambda_{ij} > 0$ 表明两个目标将参数推向相反的方向，取值越大冲突越剧烈。在此基础上，损失分量 k 的冲突暴露度定义为：

$$E_k = \sum_{j \neq k} w_j \cdot \Lambda_{kj} \quad (3-66)$$

式中， w_j 为当前配置下损失分量 j 的权重； E_k 越大，表明在当前权重方案下分量 k 受其他目标的压制越严重。

在 CA-OCBA 过程中的存活配置选择方面，标准 Hyperband 仅按验证损失排名决定存活，忽视了高冲突配置获取较高计算资源实现性能反超的潜力。借鉴最优计算预算分配（OCBA）将计算预算优先投向“最可能改变性能排序”的候选配置的思想^[22]，本节采用两档选择规则。记 n_s 为本轮应保留的配置数，预留 $m_e = \max(1, \lfloor n_s/3 \rfloor)$ 个探索名额：损失最低的 $n_s - m_e$ 个配置仅凭损失表现直接保留，其余 m_e 个名额按冲突感知得分竞争。具体来说，将全部配置按验证损失升序排列后，计算第 n_s 名与第 $n_s + 1$ 名之间的选择边界：

$$\vartheta_b = \frac{\mathcal{L}_{(n_s)}^{\text{val}} + \mathcal{L}_{(n_s+1)}^{\text{val}}}{2} \quad (3-67)$$

式中， $\mathcal{L}_{(n_s)}^{\text{val}}$ 与 $\mathcal{L}_{(n_s+1)}^{\text{val}}$ 分别为升序排列下第 n_s 名与第 $n_s + 1$ 名配置的验证损失。对每个未受保护的配置 i ，其到边界的调整距离为：

$$\tilde{\Delta}_i = \frac{|\mathcal{L}_i^{\text{val}} - \vartheta_b|}{1 + \chi_c \cdot \bar{E}_i} \quad (3-68)$$

式中， $\mathcal{L}_i^{\text{val}}$ 为配置 i 的验证损失； $\bar{E}_i$ 为配置 i 在全部损失分量上的平均冲突暴露度； $\chi_c > 0$ 为冲突敏感度系数。暴露度越高，有效距离被压缩得越短，高冲突配置由此获得更大的存活机会。配置 i 的选择得分为：

$$\varsigma_i = \left(\frac{\sigma_{cs}}{\tilde{\Delta}_i} \right)^2 \quad (3-69)$$

式中， σ_{cs} 为冷启动设定下对全部配置取同一数值的常数，仅起尺度作用，不改变得分的相对排序。未受保护配置中得分最高的 m_e 个保留至下一轮。

在系数分布更新方面，每个 Hyperband 档位结束后，依据冲突暴露度与存活配置更新采样分布。方差侧，高冲突暴露触发膨胀以鼓励探索：

$$\sigma_k^{(\text{new})} = \sigma_k^{(\text{old})} \cdot (1 + \chi_\sigma \cdot \hat{E}_k) \quad (3-70)$$

式中， $\sigma_k^{(\text{old})}$ 与 $\sigma_k^{(\text{new})}$ 分别为超参数 w_k 采样分布更新前后的标准差； $\hat{E}_k$ 为分量 k 的归一化冲突暴露度； $\chi_\sigma > 0$ 为方差膨胀率。均值侧，向表现优良的存活配置迁移：

$$\mu_k^{(\text{new})} = (1 - \chi_\mu) \cdot \mu_k^{(\text{old})} + \chi_\mu \cdot \bar{w}_k \quad (3-71)$$

式中， $\mu_k^{(\text{old})}$ 与 $\mu_k^{(\text{new})}$ 分别为更新前后的均值； $\chi_\mu \in (0, 1)$ 为均值迁移率； $\bar{w}_k = \sum_{k'} \pi_{k'} \cdot w_{k,k'} / \sum_{k'} \pi_{k'}$ 为超参数 w_k 在存活配置上的加权均值，其中 k' 为存活配置索引， $w_{k,k'}$ 为配置 k' 中超参数 w_k 的取值，权重 $\pi_{k'} = \exp(-\mathcal{L}_{k'}^{\text{val}} / \bar{\mathcal{L}}^{\text{val}})$ 使验证损失越低的配置获得越高的话语权， $\bar{\mathcal{L}}^{\text{val}}$ 为存活配置验证损失的均值。该更新规则在梯度冲突较大时放宽搜索范围，在配置平稳收敛时收窄搜索范围。

综上，第一阶段以数据自身的依赖结构为先验提供有信息的搜索起点，第二阶段以冲突感知机制在预算约束下高效逼近最优配置，二者协同使 HiDiT 模型能够自适应不同城市的人口分布特征，引论中的困难（4）由此得到解决。

3.7 算例实验

为验证本文所构建的 HiDiT 模型及其多地理尺度边际分布对齐和零单元处理机制的有效性，本节以北京市为研究区域设计实验算例。具体而言，本节将基于多源人口数据开展实验，依次从实验设置与评价指标、基准模型对比、消融实验、家庭结构图生成质量、多地理尺度边际分布对齐效果以及样本零与结构零处理效果等方面，对所提出模型进行系统评估。

3.7.1 算例数据描述

北京市人口规模大、行政区类型多样，不同区域在家庭规模、年龄结构、受教育水平和交通工具拥有情况等方面均存在明显差异，能够为检验模型在复杂人口结构下的生成能力提供较为充分的应用场景。本文所用基础数据包括人口样本数据、人口特征边际分布数据和人口分布数据三类。其中，人口样本数据用于学习家庭与个人属性之间的联合分布及家庭内部成员关系；人口特征边际分布数据用于约束合成人口在不同地理尺度上的属性边际分布；人口分布数据用于确定最小空间单元内的合成人口规模。上述三类数据共同构成北京市家庭级大规模人口合成实验的数据基础。

(1) 人口样本数据

人口样本数据采用 2023 年北京市居民出行调查数据。该调查覆盖北京市全部 16 个行政区，记录了受访家庭及其成员的社会经济属性与成员构成等信息，不仅能够用于学习人口属性的联合分布，也能够为家庭结构图构建提供基础。经数据清洗后，本章共使用 33,169 个家庭样本和 79,695 个个人样本，抽样率约为 0.40%。

结合人口合成对微观人口输入数据的需求，本章在家庭层级选取家庭规模、就业人数、机动车保有量、自行车保有量、电动自行车保有量、摩托车保有量、老年代步车保有量、家庭年收入和是否有在校学生共 9 项属性；在个人层级选取年龄、性别、驾照持有情况、受教育程度、与户主关系和职业共 6 项属性。上述属性既能够反映家庭资源约束和人口构成特征，也能够刻画个人活动参与能力、出行方式选择条件和家庭内部角色关系，是后续合成人口生成的核心变量。

(2) 人口特征边际分布数据

为实现合成人口在不同空间层级上的宏观分布一致性，本章将人口特征边际分布约束划分为三个空间尺度：第一是栅格尺度，以 $1, \text{km} \times 1, \text{km}$ 空间栅格作为最小控制单元，用于刻画城市内部细粒度人口属性差异；第二是行政区尺度，以北京市 16 个行政区作为中观控制单元，用于约束不同区县之间的人口结构差异；第三是城市尺度，以北京市全域作为宏观控制单元，用于保证合成人口总体属性分布与全市统计特征一致。为获取上述三个尺度的边际分布数据，本章主要依赖两类数据源：手机应用数据和统计年鉴数据。

手机应用数据取自百度地图匿名化居民画像数据，覆盖北京市 16 个行政区，共包含 15,022 个空间分辨率为 $1, \text{km} \times 1, \text{km}$ 的栅格。每个栅格中仅记录年龄组、性别、收入水平、职业和车辆拥有情况等属性的比例分布，不包含可识别的个体记录，因此能够在保护隐私的前提下反映较细空间尺度上的人口属性差异。需要说明的是，手机应用数据采集于 2021 年 5 月，而居民出行调查数据为 2023 年。两类数据之间存在一定时间差异，但考虑到北京市人口结构在短期内整体相对稳定，且本章重点在于验证模型在多尺度边际约束下进行家庭级人口合成的能力，因此认为该时间差异不会对实验目标产生实质性影响。

统计年鉴数据提供行政区尺度和城市尺度的人口边际分布信息。在行政区尺度，本章提取北京市 16 个行政区的户均家庭规模、年龄组占比和性别占比；在城市尺度，提取家庭规模占比、家庭户均就业人数、年龄组占比和受教育程度占比等统计信息。北京市行政区尺度边际属性统计如表 3-1 所示，城市尺度边际属性统计如表 3-2 所示。

(3) 人口分布数据

人口分布数据用于确定最小空间单元（栅格）内需要生成的人口规模。本章采

表 3-1 北京市行政区尺度人口边际属性统计

行政区	户均家庭规模	0-14 岁占比 (%)	15-64 岁占比 (%)	65 岁及以上占比 (%)	男性占比 (%)
东城区	2.87	13.8	65.6	20.6	48.6
西城区	3.08	14.8	63.4	21.7	49.1
朝阳区	2.54	11.3	71.9	16.8	49.2
丰台区	2.39	11.2	70.5	18.3	49.7
石景山区	2.52	11.5	71.5	17.0	50.1
海淀区	3.21	11.9	72.6	15.5	49.8
门头沟区	2.05	11.3	69.5	19.1	50.0
房山区	2.12	13.3	72.9	14.8	49.8
通州区	2.06	12.5	73.8	13.7	49.3
顺义区	2.34	11.7	74.3	14.0	49.3
昌平区	2.26	11.0	78.6	10.4	49.8
大兴区	2.52	12.3	72.9	14.8	49.5
怀柔区	2.08	11.8	69.3	18.9	49.5
平谷区	2.31	12.9	67.1	20.0	50.2
密云区	2.13	12.4	69.8	17.7	49.5
延庆区	1.95	11.7	70.8	17.5	50.2

用美国橡树岭国家实验室发布的全球人口分布数据,其空间分辨率约为 $1,km,\times,1,km$ 。该数据能够提供北京市范围内较细粒度的人口分布,因此可作为生成真实城市规模的虚拟人口的数量依据。

在具体生成过程中,模型首先根据居民出行调查样本学习家庭属性、个人属性和家庭结构之间的联合分布,并在给定地理单元条件下生成候选家庭。随后,依据人口分布数据中各栅格的人口总量控制生成规模,使每个栅格内的合成人口数量与真实人口分布保持一致。通过该处理,合成人口不仅能够在属性结构上贴近样本数据和边际分布,也能够空间总量上反映北京市真实人口分布格局。北京市人口分布如图 3-4 所示。

(4) 多源数据融合与统一口径处理

由于上述三类数据在空间粒度和属性口径上并不完全一致,实验前需要进行统一的数据融合处理。在空间维度上,为保证不同数据源能够共同作用于模型生成过程,本章建立栅格-行政区-城市的层级空间隶属关系,将最小空间单元与上级行政区和全市总体相对应,从而形成多尺度边际对齐所需的地理层级结构。

在属性维度上,不同数据源对同一社会经济属性的取值划分存在一定差异。例如,年龄、收入和受教育程度等变量在居民出行调查数据、手机应用数据和统计年鉴数据中的分组标准并不完全相同。对此,本章以居民出行调查数据中的属性

表 3-2 北京市城市尺度人口边际属性统计

属性	类别	数值	属性	类别	数值
家庭规模	1 人	26.8%	年龄结构	45-49 岁	6.5%
家庭规模	2 人	34.2%	年龄结构	50-54 岁	7.8%
家庭规模	3 人	22.3%	年龄结构	55-59 岁	7.1%
家庭规模	4 人	9.7%	年龄结构	60-64 岁	6.8%
家庭规模	5 人及以上	7.0%	年龄结构	65-69 岁	6.3%
户均就业人数	全体家庭	1.1	年龄结构	70-74 岁	4.2%
年龄结构	0-4 岁	3.4%	年龄结构	75-79 岁	2.2%
年龄结构	5-9 岁	4.9%	年龄结构	80-84 岁	1.5%
年龄结构	10-14 岁	3.7%	年龄结构	85 岁及以上	1.6%
年龄结构	15-19 岁	2.6%	受教育程度	小学及以下	5.3%
年龄结构	20-24 岁	4.8%	受教育程度	初中	19.3%
年龄结构	25-29 岁	7.5%	受教育程度	高中	17.2%
年龄结构	30-34 岁	10.1%	受教育程度	中专/职高	20.8%
年龄结构	35-39 岁	10.4%	受教育程度	大专	27.6%
年龄结构	40-44 岁	8.6%	受教育程度	本科及以上学历	8.1%

划分为基准，对其他数据源中的属性类别进行归并和映射，使各类边际约束能够与模型训练样本保持可比。

3.7.2 实验设置与评价指标

本章基于 Python 与 PyTorch 框架实现 HiDiT 模型及各类对比模型。所有实验均在配备 Intel(R) Core(TM) i9-13950HX CPU、64 GB 内存和 NVIDIA RTX 4090 GPU（24 GB 显存）的计算环境下完成。为保证模型对比的公平性，所有模型均使用相同的训练样本，且模型参数规模处于相近量级。HiDiT 模型中的超参数由 3.6 节所提出的两阶段超参数调优策略及十折交叉验证确定，具体取值如表 3-3 所示。

为评价合成人口与真实样本在属性联合分布上的一致性，采用人口合成研究中常用的标准化均方根误差（Standardized Root Mean Square Error, SRMSE）作为主要评价指标^[23–26]。对于给定属性组合，SRMSE 定义为：

$$\text{SRMSE} = \frac{\sqrt{\sum_{i=1}^{N_c} \left(n_i^{\text{synth}} - n_i^{\text{real}} \right)^2 / N_c}}{\sum_{i=1}^{N_c} n_i^{\text{real}} / N_c} \quad (3-72)$$

式中， N_c 为该组属性下所有可能属性组合的数量； n_i^{synth} 和 n_i^{real} 分别表示合成人口和真实样本在第 i 类属性组合中的样本频数。SRMSE 越小，表明合成人口与真实样本在该属性组合下的联合分布越接近。




图 3-4 北京市人口分布

考虑到本文关注的是家庭级别人口合成,评价指标从三个层面展开。家庭级属性层面,直接计算家庭规模、就业人数、车辆拥有、家庭收入等家庭属性组合的 SRMSE;个人级属性层面,计算年龄、性别、职业、受教育程度等个人属性组合的 SRMSE。为进一步检验模型是否真正学习到家庭内部成员属性之间的协调关系,提出扩展家庭级属性层面,将个人属性聚合至家庭层级,构造是否有老年人、驾照持有成员占比、男性成员占比、本科及以上成员占比、就业成员占比等扩展变量,并计算其与家庭属性组合后的 SRMSE。对于上述三个层面,均分别计算 1 维至 6 维属性组合下的平均 SRMSE,以全面刻画模型在低维边际分布和高维联合分布上的生成质量。

3.7.3 基准模型对比分析

选取人口合成领域中具有代表性的深度生成模型作为基准模型进行对比,具体包括: WGAN 模型^[27]、VAE 模型^[27,28]、条件 WGAN (Conditional WGAN, CWGAN) 模型^[29] 和条件 VAE (Conditional VAE, CVAE) 模型^[30]。上述模型均已被应用于人口合成任务,能够学习高维人口属性的复杂联合分布。其中, WGAN 和 VAE 为非条件生成模型, CWGAN 和 CVAE 则通过引入条件信息增强生成过程的可控性。

表 3-4 展示了不同模型在家庭级、个人级和扩展家庭级三个层面下的平均 SRMSE 结果。结果表明, HiDiT 模型在全部评价层面和全部属性组合维度下均取得最小的 SRMSE,说明其在家庭级别人口合成任务中整体优于各类基准生成模型。

表 3-3 HiDiT 模型主要超参数设置

类别	超参数	取值
模型结构	隐层维度	320
	Transformer 层数	30
	注意力头数	16
	图结构投影维度	24
	HGT 层数	2
	HGT 注意力头数	4
扩散过程	加噪时间步数	200
	噪声调度起始值 β_{start}	0.0001
	噪声调度终止值 β_{end}	0.02
	噪声相关系数 ρ	0.66
训练设置	训练轮数	500
	批量大小	1,024
	学习率	1×10^{-4}
损失权重	家庭级连续属性权重 w_{cont}^h	1.82
	家庭级类别属性权重 w_{cat}^h	1.82
	个人级属性权重 w_a	0.1
	成员掩码与成员总数权重 $w_{\text{mask}}, w_{\text{total}}$	0.1
	图结构权重 $w_{\text{adj}}, w_{\text{node}}, w_{\text{edge}}$	0.97

在家庭级属性层面，HiDiT 模型的优势最为明显。随着属性组合维度由 1 维增加至 6 维，各基准模型的 SRMSE 均快速增大，表明基准模型在高维联合分布还原方面存在明显误差累积。相比之下，HiDiT 模型即使在 6 维属性组合下 SRMSE 仍仅为 0.389，远低于表现相对较好的 WGAN 模型，表现出了良好的生成合理的家庭级属性的能力。

在个人级属性层面，HiDiT 模型同样保持最优表现。基准模型虽然能够在一定程度上学习个人属性的边际分布，但随着属性组合维度升高，其误差显著增大。例如，在 6 维属性组合下，VAE 模型的 SRMSE 为 5.261，WGAN 模型为 7.571，而 HiDiT 模型仅为 1.188。该结果表明，HiDiT 模型通过上层家庭属性、家庭画像条件和结构图信息对个人级生成过程进行引导，能够有效缩小个人属性生成空间，从而更准确地还原个体属性联合分布。

在扩展家庭级属性层面，HiDiT 模型在 6 维属性组合下 SRMSE 为 1.633，而 WGAN、VAE、CWGAN 和 CVAE 分别为 3.912、7.925、4.665 和 9.799，说明本文所提出的家庭画像机制与图结构建模模块能够有效捕捉家庭成员间的协同关系以及家庭内的复杂的高维依赖关系。

表 3-4 不同模型的平均 SRMSE 对比结果

层面	模型	1 维	2 维	3 维	4 维	5 维	6 维
家庭级	WGAN	0.390	0.978	1.750	2.659	3.635	4.599
	VAE	0.851	2.252	4.207	6.710	9.709	13.070
	CWGAN	0.439	1.121	2.060	3.221	4.547	5.950
	CVAE	0.896	2.381	4.493	7.257	10.651	14.562
	HiDiT	0.045	0.104	0.171	0.242	0.315	0.389
个人级	WGAN	0.603	1.615	3.028	4.662	6.260	7.571
	VAE	0.506	1.268	2.275	3.384	4.421	5.261
	CWGAN	0.522	1.372	2.572	4.048	5.612	7.061
	CVAE	0.660	1.553	2.651	3.790	4.802	5.616
	HiDiT	0.089	0.231	0.431	0.668	0.923	1.188
扩展家庭级	WGAN	0.393	0.886	1.510	2.260	3.086	3.912
	VAE	0.622	1.504	2.688	4.195	5.983	7.925
	CWGAN	0.371	0.884	1.590	2.491	3.542	4.665
	CVAE	0.720	1.751	3.181	5.049	7.305	9.799
	HiDiT	0.093	0.258	0.503	0.830	1.219	1.633

值得注意的是，CWGAN 和 CVAE 并未稳定优于其非条件版本，部分情形下甚至表现更差。这说明对于家庭级人口合成任务，简单加入条件变量并不必然能够改善生成质量。其原因在于，家庭与个人之间存在典型的“一对多”映射关系，若条件信息本身无法刻画家庭画像和成员结构差异，则可能不足以约束下层个人属性生成空间。与之相比，HiDiT 模型通过 HDBSCAN 家庭画像机制构造更具区分性的条件信息，并进一步结合 GraphVAE 和 HGT 显式建模家庭内部成员关系，从而在高维联合分布还原方面取得更稳定的效果。

3.7.4 消融实验分析

为进一步识别 HiDiT 模型中关键模块的贡献，本文设置两组消融模型进行对比：（1）移除 GraphVAE 解码器和 HGT 模块，不再显式生成和利用家庭结构图，即 HiDiT w/o Graph；（2）移除家庭画像标签条件，在训练和生成过程中不使用 HDBSCAN 聚类得到的家庭画像信息，即 HiDiT w/o Conditioning。通过与完整 HiDiT 模型对比，可以分别检验图结构建模模块和家庭画像条件信息对人口合成质量的影响。

表 3-5 展示了消融实验结果。结果表明，完整 HiDiT 模型在家庭级、个人级和扩展家庭级三个层面均取得最小 SRMSE，说明本文设计的图结构模块和画像条件

模块均对提升生成质量具有重要作用。

表 3-5 HiDiT 模型不同模块的消融实验结果

层面	模型	1 维	2 维	3 维	4 维	5 维	6 维
家庭级	HiDiT w/o Graph	0.055	0.134	0.225	0.317	0.405	0.486
	HiDiT w/o Conditioning	0.064	0.161	0.279	0.408	0.536	0.659
	HiDiT	0.045	0.104	0.171	0.242	0.315	0.389
个人级	HiDiT w/o Graph	0.667	1.676	2.896	4.158	5.352	6.465
	HiDiT w/o Conditioning	0.995	2.621	4.972	7.981	11.546	15.562
	HiDiT	0.089	0.231	0.431	0.668	0.923	1.188
扩展家庭级	HiDiT w/o Graph	0.411	1.092	2.002	3.068	4.180	5.216
	HiDiT w/o Conditioning	0.440	1.174	2.173	3.375	4.681	5.978
	HiDiT	0.093	0.258	0.503	0.830	1.219	1.633

首先，移除图结构模块后，家庭级属性 SRMSE 仅出现小幅上升。例如，6 维家庭级属性组合下 SRMSE 由 0.389 增加至 0.486，说明家庭级总体属性分布主要由上层扩散模型决定，受图结构模块影响相对有限。然而，在个人级和扩展家庭级层面，误差增幅较大。6 维个人级属性组合下以及扩展家庭级属性组合下 SRMSE 分别由 1.188 和 1.633 增至增至 6.465 和 5.216，表明 GraphVAE 和 HGT 模块的作用主要体现在刻画家庭内部成员依赖关系上。若不显式建模家庭结构，模型更容易将家庭成员视作相对独立的个体，从而破坏成员年龄、性别、职业、驾照持有情况等属性之间的协调关系。

其次，移除家庭画像条件后，模型性能在所有层面均明显下降，且个人级层面下降幅度最大。6 维个人级属性组合下 SRMSE 由 1.188 上升至 15.562，说明家庭画像条件是解决家庭-个人层级“一对多”映射问题的重要信息来源。缺少家庭画像约束时，同一家庭级属性可能对应过多成员组合，个人级扩散过程的生成空间显著扩大，模型难以稳定生成与家庭背景相匹配的成员属性。扩展家庭级属性层面的误差也由 1.633 上升至 5.978，进一步说明家庭画像信息对于维持家庭成员组合合理性具有重要作用。

为更直观地比较不同模型变体的生成效果，图 3-5 和图 3-6 分别展示了家庭级属性和个人级属性的分布对比。可以看出，完整 HiDiT 模型生成结果与真实居民出行调查样本的分布最为接近；移除图结构模块后，部分个人属性与家庭成员聚合特征出现偏差；移除家庭画像条件后，多个属性的分布偏离真实样本更为明显。上述可视化结果与 SRMSE 定量评价结果相互印证，说明完整模型结构能够更好地保证家庭属性、个人属性和家庭内部结构的一致性。




图 3-5 消融实验中家庭级属性分布对比




图 3-6 消融实验中个人级属性分布对比

3.7.5 家庭结构图生成质量分析

为进一步验证 GraphVAE 与 HGT 等模块对家庭内部关系的刻画能力，本节从邻接关系预测、边类型预测和节点类型预测三个方面分析家庭结构图生成质量。具体而言，将模型预测得到的家庭结构图与真实样本中的家庭结构图进行对比，评价其是否能够还原家庭成员之间的连接关系和关系类型。

关于预测邻接矩阵与真实邻接矩阵之间的相似性。图 3-7 展示了节点级相似度矩阵、邻接矩阵余弦相似度分布和 Jaccard 相似度分布。其中，节点级相似度矩阵中的每个元素 (i, j) 表示所有家庭中预测邻接值与真实邻接值之间的平均元素级相似度 $1 - |A_{ij}^{\text{pred}} - A_{ij}^{\text{true}}|$ 。从图中可以看出，不同节点对上的相似度整体较高，说明模型能够较好地判断家庭成员之间是否存在关系。

进一步地，本文计算每个家庭预测邻接矩阵与真实邻接矩阵之间的余弦相似度和 Jaccard 相似度。其中，余弦相似度用于衡量邻接矩阵整体结构的一致性，定义为：

$$\text{Cosine} = \frac{\text{vec}(\mathbf{A}^{\text{pred}})^{\top} \text{vec}(\mathbf{A}^{\text{true}})}{|\text{vec}(\mathbf{A}^{\text{pred}})| * 2 |\text{vec}(\mathbf{A}^{\text{true}})| * 2} \quad (3-73)$$

Jaccard 相似度用于衡量预测边集合与真实边集合之间的重合程度，定义为：

$$\text{Jaccard} = \frac{|(i, j) : A * i j^{\text{pred}} > 0 \wedge A * i j^{\text{true}} > 0|}{|(i, j) : A_{ij}^{\text{pred}} > 0 \vee A_{ij}^{\text{true}} > 0|} \quad (3-74)$$

结果显示，预测邻接矩阵与真实邻接矩阵的余弦相似度均值为 0.839，Jaccard 相似度均值为 0.805，且多数样本集中在较高相似度区间。这说明模型不仅能够还原家庭成员数量，也能够较准确地判断成员之间的连接关系。




图 3-7 家庭结构图邻接矩阵相似度分析

进一步分析边类型和节点类型预测准确率。边类型预测准确率通过比较存在关系的成员之间的预测边类型与真实边类型是否一致判断，节点类型预测准确率则通过比较每个家庭中预测节点类型与真实节点类型是否一致判断。图 3-8 展示了两类准确率的分布。

从结果看，边类型预测准确率均值为 0.889，说明模型能够正确识别 80% 以上的家庭成员关系类型，如配偶、亲子、祖孙和兄弟姐妹等，表明模型能够有效地还原家庭成员之间的关系结构。节点类型预测准确率均值为 0.839，表明模型能够较好地还原家庭成员构成，例如户主、配偶、子女和老人等角色组合。上述结果说明，本文提出的 GraphVAE 解码器能够有效生成家庭结构图，HGT 模块也能够进一步将家庭结构信息传递至个人属性生成过程，为高质量家庭级人口合成提供支撑。




图 3-8 家庭结构图边类型与节点类型预测准确率分布

3.7.6 多地理尺度边际分布对齐效果评估

为验证3.4节所提出的能量引导机制在多地理尺度边际分布对齐中的作用，本节分别在栅格、行政区和城市三个地理尺度上比较加入能量引导前后的合成人口边际分布误差。考虑到手机应用数据可能受用户群体结构影响，在部分人口属性上存在一定抽样偏差^[31]，本文在栅格尺度上选取未同时纳入行政区和城市尺度约束的属性进行引导，以减少不同数据源之间潜在口径差异造成的冲突。具体而言，栅格尺度选择机动车拥有比例作为示例属性；行政区尺度使用户均家庭规模、0-14岁占比、15-64岁占比、65岁及以上占比和男性占比共5项边际约束；城市尺度使用家庭规模、户均就业人数、年龄结构和受教育程度等共31项边际约束。

图3-9展示了栅格尺度上机动车拥有比例的边际对齐误差空间分布。其中，图中分别给出未加入能量引导和加入能量引导后的绝对误差。未加入能量引导时，栅格尺度机动车拥有比例的平均绝对误差为0.2952；加入能量引导后，平均绝对误差降低至0.2145，误差下降幅度为27.34%。该结果说明，能量引导机制能够在扩散采样过程中有效利用栅格尺度边际信息，引导生成结果更接近局部空间单元的真实属性分布。

图3-10进一步展示了行政区尺度上不同属性的边际分布绝对误差。可以看出，在北京市16个行政区中，加入能量引导后大部分属性的绝对误差均明显降低。未加入引导时，模型生成结果难以完全匹配行政区尺度的宏观统计特征，尤其在户均家庭规模和年龄结构方面存在一定偏差。加入能量引导后，户均家庭规模、15-64岁人口占比、65岁及以上人口占比以及男性占比等属性的误差均得到较明显改善。虽然引导机制对于0-14岁人口占比，部分行政区改善幅度相对有限，但整体上未




图 3-9 栅格尺度机动车拥有比例边际对齐误差空间分布

造成误差恶化，说明该机制能够在多项边际约束之间保持较好的平衡。




图 3-10 行政区尺度人口边际分布绝对误差对比

图 3-11展示了城市尺度 31 项边际属性的绝对误差对比。结果表明，加入能量引导后，几乎所有城市尺度边际属性的误差均有所下降。未加入引导时，生成数据在家庭规模分布和受教育程度分布等属性上与全市统计年鉴数据存在一定差异；加入城市尺度边际引导后，上述偏差得到明显修正，尤其是受教育程度相关属性的改善较为显著。




图 3-11 城市尺度人口边际分布绝对误差对比

综合三个地理尺度的实验结果可以看出，本文提出的能量引导机制能够有效提升合成人口与目标边际分布在三个地理尺度上的一致性，同时避免过度优化某一尺度而牺牲其他尺度的边际吻合度，能够为大规模城市人口合成提供更具可控性的宏观分布对齐能力。

3.7.7 样本零与结构零处理效果评估

为验证提出的 VAE-BN 正则化策略对样本零与结构零的处理效果，本节比较加入正则化前后生成样本的分类结果。根据3.5节定义，生成样本可分为有效样本、潜在样本零和潜在结构零三类。表 3-6展示了约 1400 万个合成家庭在加入 VAE-BN 正则化前后的分类结果。未加入正则化时，有效样本占比为 27.57%，潜在样本零占比为 65.57%，但潜在结构零占比达到 6.86%，说明若完全依赖生成模型自由外推，虽然能够生成较多训练样本外组合，但其中会混入一定比例的逻辑不合理组合。加入 VAE-BN 正则化后，有效样本占比提高至 30.10%，潜在样本零占比为 69.90%，而潜在结构零占比降至近似为 0。该结果表明，本文所提出的双判据正则化策略能够在保留稀有合法组合的同时有效剔除结构零。

表 3-6 合成样本中有效样本、潜在样本零与潜在结构零分类结果

方法	有效样本 (%)	潜在样本零 (%)	潜在结构零 (%)
未加入正则化	27.57	65.57	6.86
加入 VAE-BN 正则化	30.10	69.90	≈ 0

进一步地，为分析正则化策略对生成样本潜空间分布的影响，计算生成样本与居民出行调查样本在 VAE 潜空间中的 Wasserstein 距离。图 3-12展示了加入正则化前后 Wasserstein 距离的分布。未加入正则化时，生成样本与真实样本之间的平均 Wasserstein 距离为 2.579；加入 VAE-BN 正则化后，平均 Wasserstein 距离下降至 2.564，更接近真实调查样本内部的平均距离水平 2.556。这说明正则化机制能够引导生成样本向真实样本潜空间中的合理区域靠近，从而减少远离真实人口结构的异常组合。




图 3-12 生成样本与居民出行调查样本在 VAE 潜空间中的 Wasserstein 距离分布

上述结果说明，本文提出的 VAE-BN 正则化策略并非简单抑制所有训练样本外组合，而是能够区分样本零与结构零。对于潜在样本零，模型予以保留，从而维持合成人口的多样性和外推能力；对于潜在结构零，模型通过重生成机制予以剔除，从而避免产生逻辑不可能的家庭属性组合。

3.8 本章小结

针对 MaaS 推广策略仿真所需的高保真微观人口输入，本章研究了家庭级别大规模人口合成问题。围绕家庭-个人层级间的“一对多”映射、多地理尺度边际分布的同时对齐、样本零与结构零的甄别处置以及超参数对人口分布差异的适配四方面困难，本章提出了以分层扩散 Transformer 模型为主体的人口合成方法，并以北京市为算例进行了验证。本章的主要工作与结论如下。

其一，针对家庭与个人属性间的“一对多”映射，构建了基于 HDBSCAN 的家庭画像机制与分层扩散 Transformer 模型。家庭画像机制以画像标签作为条件信息压缩下层成员属性的生成空间，分层扩散 Transformer 以 GraphVAE 解码器与异质图 Transformer 显式表征家庭结构与成员关系。算例表明，所提模型在家庭级、个人级与扩展家庭级三个层面、全部属性组合维度下均取得最小的 SRMSE，6 维属性组合下家庭级与个人级 SRMSE 分别低至 0.389 与 1.188，显著优于各类生成模型基准；消融实验进一步表明，图结构模块与画像条件模块分别在刻画成员依赖关系与约束成员生成空间上发挥关键作用，移除后个人级 SRMSE 分别升至 6.465 与 15.562。在家庭结构图的生成质量上，预测邻接矩阵与真实邻接矩阵的余弦相似度与 Jaccard 相似度均值分别达 0.839 与 0.805，边类型与节点类型预测准确率均值分别为 0.889 与 0.839，表明模型能够准确还原家庭成员的构成与关系。

其二，针对多地理尺度边际分布的同时对齐，设计了基于能量引导的多地理尺度边际对齐机制。该机制在去噪采样过程中注入多地理尺度引导梯度，将宏观统计信息以边际约束的形式融入生成过程，并通过求解二次规划问题协调尺度间的梯度冲突。算例表明，引入能量引导后，合成人口在栅格、行政区与城市三个尺度上与目标边际的吻合度均得到提升，其中栅格尺度机动车拥有比例的平均绝对误差下降 27.34%，且冲突协调策略保证了多尺度约束间的平衡，避免了过度优化单一尺度。

其三，针对样本外属性组合中样本零与结构零的甄别处置，设计了基于变分自编码器与贝叶斯网络的双判据正则化策略。该策略以 BN 对数概率与潜空间距离双判据将生成样本划分为有效样本、样本零与结构零，保留前两类以维持多样性、剔除并重生成结构零以保证合法性。算例表明，引入正则化后结构零占比由 6.86% 降至近似为零，同时样本零得以保留；生成样本与调查样本在潜空间中的平均 Wasserstein 距离由 2.579 降至 2.564，趋近真实样本内部水平，表明该策略在剔除无效组合的同时维持了合成人口的合理外推能力。

其四，针对超参数对不同城市人口分布的适配，设计了两阶段超参数调优策略。第一阶段基于属性间互信息构建超参数的先验分布，为搜索提供有信息的起点；第二阶段在 Hyperband 框架内引入冲突感知机制，依据梯度冲突暴露度调整存活选择与采样分布，实现预算约束下的高效搜索，使方法能够自适应不同城市的人口分布特征。

综上，本章提出的方法能够由小规模调查样本合成属性联合分布真实、家庭结构合理且多尺度边际吻合的家庭级虚拟人口。所合成的虚拟人口为下一章家庭活动计划的生成提供了具备完整家庭结构与成员属性的决策主体，是后续 MaaS 推广策略仿真的微观基础。

4 考虑家庭联合活动的家庭级出行计划生成

1111

4.1 问题描述及解决思路

4.2 家庭出行计划数据特征解析与统一表征

4.2.1 家庭活动链与联合活动模式特征分析

4.2.2 家庭-成员特征统一编码与活动模式先验构建

4.3 家庭感知的多任务编码器设计

4.3.1 集合注意力专家与渐进分层提取结构

4.3.2 家庭与个人层级活动模式先验融合

4.4 家庭协调式活动链解码器设计

4.4.1 任务特定注意力与跨角色注意力机制

4.4.2 自回归活动链生成与多属性预测头

4.4.3 空间感知的目的地注意力机制

4.5 基于纳什议价的可微家庭协调层

4.5.1 家庭协调的纳什议价问题构建与两阶段优化

4.5.2 KKT 条件可微性与反向传播近似

4.6 损失函数与模型训练策略

4.7 算例实验

4.7.1 实验设置与评价指标

4.7.2 基准模型对比分析

4.7.3 消融实验分析

4.7.4 家庭内部协调性分析

4.7.5 个体级属性分布对比分析

5 分阶段建模下的 MaaS 多阶段采纳意愿建模

5.1 问题描述及解决思路

5.2 MaaS 多阶段采纳意愿陈述偏好调查与特征分析

5.2.1 两步式比较型陈述偏好实验设计

5.2.2 调查实施与样本统计分析

5.2.3 多阶段选择行为特征分析

5.3 单次出行场景下 MaaS 转移意愿建模

5.3.1 潜在态度变量识别

5.3.2 融合出行习惯与跨场景变量的潜在类别选择模型

5.3.3 模型估计结果与异质用户类别分析

5.3.4 MaaS 转移意愿指数构建与分析

5.4 基于初始印象的 MaaS 套餐订阅异质偏好建模

5.4.1 单次出行偏好向套餐订阅决策的效用迁移机制

5.4.2 融合属性非关注的潜在类别潜变量选择模型

5.4.3 模型估计结果与驱动-障碍因素分析

5.5 灵敏度与弹性分析及政策启示

5.6 本章小结

6 一体化建模下的 MaaS 多阶段采纳意愿建模

6.1 问题描述及解决思路

6.2 态度潜变量识别与 MIMIC 模型构建

6.2.1 基于探索性与验证性因子分析的潜变量识别

6.2.2 结构方程构建

6.2.3 测量方程构建

6.2.4 似然函数与因子得分计算

6.3 MaaS 多阶段采纳决策的隐马尔可夫模型构建

6.3.1 初始行为状态隶属模型

6.3.2 单次出行阶段选择模型

6.3.3 跨阶段行为状态转移模型

6.3.4 套餐订阅阶段选择模型

6.3.5 联合似然函数与模型标定

6.4 模型结果分析

6.4.1 MIMIC 模型估计结果分析

6.4.2 行为状态识别与阶段偏好异质性分析

6.4.3 跨阶段行为状态转移机理分析

6.4.4 全周期弹性聚合与采纳驱动因素分析

6.4.5 分阶段与一体化建模范式对比分析

6.5 本章小结

7 基于深度学习仿真优化的多目标 MaaS 推广策略优化

7.1 问题描述及解决思路

7.2 MaaS 采纳多智能体仿真模型构建

7.2.1 涵盖试用-订阅-套餐选择的三层决策机制

7.2.2 扩散传播与空间网络效应建模

7.2.3 推广策略空间与多目标评价指标体系

7.3 面向仿真模型的深度学习代理模型设计

7.3.1 兼顾静态与动态策略特征的代理模型架构

7.3.2 解析先验预训练与持续微调训练策略

7.4 基于信赖域机制的多目标贝叶斯优化方法

7.4.1 多目标采集函数设计

7.4.2 信赖域搜索与代理模型持续微调协同机制

7.5 算例实验

7.5.1 北京市 MaaS 推广仿真场景与实验设置

7.5.2 代理模型精度验证与对比分析

7.5.3 多目标优化结果与 Pareto 前沿分析

7.5.4 推广策略灵敏度分析与政策启示

7.6 本章小结

8 总结与展望

8.1 研究总结

8.2 创新点

8.3 研究展望

参考文献

- [1] ABERLE C, GERTZ C. Does a short journey get me to the food bank? An empirical study on fare-based public transport accessibility and its implications for social equity [J]. *Journal of Transport Geography*, 2025, 128: 104348. DOI: 10.1016/j.jtrangeo.2025.104348.
- [2] LA D M, V, Hai L., K, Liton, et al. Population synthesis: a problem-based review [J]. *Transport Reviews*, 2025, 45(3): 366-389. DOI: 10.1080/01441647.2025.2469069.
- [3] WHANG J, DELBRACIO M, TALEBI H, et al. Deblurring via stochastic refinement [C]// *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2022: 16293-16303.
- [4] SOHN K, LEE H, YAN X. Learning structured output representation using deep conditional generative models [J]. *Advances in neural information processing systems*, 2015, 28.
- [5] MCINNES L, HEALY J, ASTELS S. Hdbscan: Hierarchical density based clustering. [J]. *J. Open Source Softw.*, 2017, 2(11): 205. DOI: 10.21105/joss.00205.
- [6] KING E M, RANDOLPH H L, FLORO M S, et al. Demographic, health, and economic transitions and the future care burden [J]. *World Development*, 2021, 140: 105371. DOI: 10.1016/j.worlddev.2020.105371.
- [7] VARJAKOSKI H, KOPONEN S, KOUVO A, et al. Age Diversity in Neighborhoods—A Mixed-Methods Approach Examining Older Residents and Community Wellbeing [J]. *International Journal of Environmental Research and Public Health*, 2023, 20(16): 6574. DOI: 10.3390/ijerph20166574.
- [8] ZHANG Y, ZHANG Y, ZHANG Y, et al. Examining the Relationship between Household Vehicle Ownership and Ridesharing Behaviors in the United States [J]. *Sustainability*, 2018, 10(8). DOI: 10.3390/su10082720.
- [9] NAKAYAMA T, SATO Y, MARUYAMA T. Comparing households with every member out-of-home in developing countries using travel surveys [J]. *Cities*, 2023, 139: 104351. DOI: 10.1016/j.cities.2023.104351.
- [10] HO J, JAIN A, ABBEEL P. Denoising Diffusion Probabilistic Models: arXiv:2006.11239 [Z]. 2020. arXiv: 2006.11239.
- [11] PEEBLES W, XIE S. Scalable Diffusion Models with Transformers: arXiv:2212.09748 [Z]. 2023. arXiv: 2212.09748.
- [12] SIMONOVSKY M, KOMODAKIS N. GraphVAE: Towards Generation of Small Graphs Using Variational Autoencoders: arXiv:1802.03480 [Z]. 2018. arXiv: 1802.03480.
- [13] JANG E, GU S, POOLE B. Categorical Reparameterization with Gumbel-Softmax: arXiv:1611.01144 [Z]. 2017. arXiv: 1611.01144.
- [14] HU Z, DONG Y, WANG K, et al. Heterogeneous Graph Transformer: arXiv:2003.01332 [Z]. 2020. arXiv: 2003.01332.

- [15] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal Loss for Dense Object Detection [C]//2017 IEEE International Conference on Computer Vision (ICCV). 2017: 2999-3007. DOI: 10.1109/ICCV.2017.324.
- [16] YU J, WANG Y, ZHAO C, et al. Freedom: Training-free energy-guided conditional diffusion model [C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 23174-23184.
- [17] LIU B, LIU X, JIN X, et al. Conflict-Averse Gradient Descent for Multi-task Learning: arXiv:2110.14048 [Z]. 2024. arXiv: 2110.14048.
- [18] KINGMA D P, WELING M. Auto-Encoding Variational Bayes: arXiv:1312.6114 [Z]. 2022. arXiv: 1312.6114.
- [19] PEARL J. Probabilistic reasoning in intelligent systems: networks of plausible inference [M]. Elsevier, 2014.
- [20] SUN L, ERATH A. A Bayesian network approach for population synthesis [J]. Transportation Research Part C: Emerging Technologies, 2015, 61: 49-62. DOI: 10.1016/j.trc.2015.10.010.
- [21] LI L, JAMIESON K, DESALVO G, et al. Hyperband: A novel bandit-based approach to hyperparameter optimization [J]. Journal of machine learning research, 2018, 18(185): 1-52.
- [22] CHEN C H, LEE L H. Stochastic simulation optimization: an optimal computing budget allocation: Vol. 1 [M]. World scientific, 2011.
- [23] MÜLLER K, AXHAUSEN K W. Population synthesis for microsimulation: State of the art [J]. Arbeitsberichte Verkehrs-und Raumplanung, 2010, 638.
- [24] SUN L, ERATH A, CAI M. A hierarchical mixture modeling framework for population synthesis [J]. Transportation Research Part B: Methodological, 2018, 114: 199-212. DOI: 10.1016/j.trb.2018.06.002.
- [25] KUKIC M, LI X, BIERLAIRE M. One-step Gibbs sampling for the generation of synthetic households [J]. Transportation Research Part C: Emerging Technologies, 2024, 166: 104770. DOI: 10.1016/j.trc.2024.104770.
- [26] Badu-Marfo G, FAROOQ B, PATTERSON Z. Composite Travel Generative Adversarial Networks for Tabular and Sequential Population Synthesis [J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(10): 17976-17985. DOI: 10.1109/TITS.2022.3168232.
- [27] KIM E J, BANSAL P. A deep generative model for feasible and diverse population synthesis [J]. Transportation Research Part C: Emerging Technologies, 2023, 148: 104053. DOI: 10.1016/j.trc.2023.104053.
- [28] BORYSOV S S, RICH J, PEREIRA F C. How to generate micro-agents? A deep generative modeling approach to population synthesis [J]. Transportation Research Part C: Emerging Technologies, 2019, 106: 73-97. DOI: 10.1016/j.trc.2019.07.006.
- [29] KIM E J, KIM D K, SOHN K. Imputing qualitative attributes for trip chains extracted from smart card data using a conditional generative adversarial network [J]. Transportation Research Part C: Emerging Technologies, 2022, 137: 103616. DOI: 10.1016/j.trc.2022.103616.
- [30] AEMMER Z, MACKENZIE D. Generative population synthesis for joint household and indi-

- vidual characteristics [J]. *Computers, Environment and Urban Systems*, 2022, 96: 101852. DOI: 10.1016/j.compenvurbsys.2022.101852.
- [31] MU X, ZHANG X, YEH A G O, et al. Evaluating the representativeness of mobile big data: A comparative analysis between China's mobile big data and census data at the county level [J]. *Applied Geography*, 2024, 166: 103260. DOI: 10.1016/j.apgeog.2024.103260.

附录 A

分层扩散 Transformer 模型的实现细节与算法流程

(1) 实现细节

HiDiT 模型基于 Python 3.8 与 PyTorch 1.31.1 实现, 并采用 CUDA 13.0 进行 GPU 加速。各主要模块所依赖的程序包如下:

- `torch.nn`: 用于构建 DiT 块(采用 adaLN-Zero 条件机制的 Transformer 层)、嵌入层(正弦时间嵌入与可学习的画像嵌入)、家庭级与个人级扩散 Transformer 的线性投影模块, 以及包括 GraphVAE 与 HGT 在内的全部自定义模块。
- `torch.nn.functional`: 用于损失计算, 包括面向分类属性的焦点损失、面向数值属性的均方误差, 以及面向成员存在标志与邻接矩阵的二元交叉熵。
- `scikit-learn`: 用于家庭画像的 HDBSCAN 聚类、个人级聚合统计特征降维的主成分分析, 以及特征标准化 (`StandardScaler`)。
- `numpy` 与 `pandas`: 用于居民出行调查数据的预处理、特征工程与统计计算。

(2) 算法流程

算法 1 给出 HiDiT 模型的训练流程, 算法 2 给出引入能量引导与 VAE-BN 正则化的采样流程。

算法 1 : HiDiT 模型训练流程

Require: 居民出行调查数据 $\{(\mathbf{h}_i, \mathbf{P}_i, \mathcal{G}_i)\}_{i=1}^N$, 家庭画像标签 $\{c_i\}$, 画像特征中心 $\{\mathbf{z}_c\}$, 扩散总步数 T , 层级噪声相关系数 ρ , 学习率 lr

Ensure: 训练完成的模型参数 θ

- 1: 初始化模型参数 θ
- 2: **for** epoch = 1 至 $T_{\max}$ **do**
- 3: **for** 每个小批量 $\mathcal{B}$ **do**
- 4: 采样时间步 $t \sim \text{Uniform}(\{1, \dots, T\})$
- 5: 采样噪声 $\epsilon^h \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, $\epsilon^p \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
- 6: 构造相关噪声: $\tilde{\epsilon}^p \leftarrow \rho \cdot \text{expand}(\epsilon^h) + \sqrt{1 - \rho^2} \cdot \epsilon^p$
- 7: 家庭级加噪: $\mathbf{h}_t \leftarrow \sqrt{\bar{\alpha}_t} \mathbf{h} + \sqrt{1 - \bar{\alpha}_t} \epsilon^h$
- 8: 个人级加噪: $\mathbf{P}_t \leftarrow \sqrt{\bar{\alpha}_t} \mathbf{P} + \sqrt{1 - \bar{\alpha}_t} \tilde{\epsilon}^p$
- 9: 预测家庭属性: $\hat{\mathbf{h}}_0 \leftarrow \text{FamilyDiT}(\mathbf{h}_t, t, c, \mathbf{z}_c)$
- 10: 解码家庭结构图: $(\tilde{\mathcal{V}}, \tilde{\mathcal{E}}, \tilde{\mathbf{A}}) \leftarrow \text{GraphVAE}(\hat{\mathbf{h}}_0)$
- 11: 提取结构特征: $\mathbf{U}' \leftarrow \text{HGT}(\tilde{\mathcal{V}}, \tilde{\mathcal{E}}, \tilde{\mathbf{A}})$
- 12: 预测个人属性: $\hat{\mathbf{P}}_0 \leftarrow \text{PersonDiT}(\mathbf{P}_t, t, c, \mathbf{z}_c, \hat{\mathbf{h}}_0, \mathbf{U}')$
- 13: 计算总损失: $\mathcal{L} \leftarrow \mathcal{L}_{\text{family}}(\hat{\mathbf{h}}_0, \mathbf{h}) + \mathcal{L}_{\text{person}}(\hat{\mathbf{P}}_0, \mathbf{P}) + \mathcal{L}_{\text{graph}}((\tilde{\mathcal{V}}, \tilde{\mathcal{E}}, \tilde{\mathbf{A}}), \mathcal{G})$
- 14: 更新参数: $\theta \leftarrow \theta - lr \cdot \nabla_{\theta} \mathcal{L}$
- 15: **end for**
- 16: **end for**
- 17: **return** θ

算法 2 : 引入能量引导与 VAE-BN 正则化的 HiDiT 采样流程

Require: 训练完成的模型 f_θ , 各地理单元的家庭生成数 $\{N_g\}$, 目标边际占比 $\{q^*\}$, 引导强度 η , 扩散总步数 T

Ensure: 合成人口 $\{(\hat{\mathbf{h}}_i, \hat{\mathbf{P}}_i, \hat{\mathbf{g}}_i)\}$

- 1: **for** 每个地理单元 g **do**
- 2: 依据画像分布采样画像标签 $\{c_i\}_{i=1}^{N_g}$
- 3: 初始化 $\mathbf{h}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$; 按式 (3-10) 以相关噪声构造 $\mathbf{P}_T$
- 4: **for** $t = T, T-1, \dots, 1$ **do**
- 5: $\hat{\mathbf{h}}_0 \leftarrow \text{FamilyDiT}(\mathbf{h}_t, t, c, \mathbf{z}_c)$
- 6: $(\tilde{\mathbf{V}}, \tilde{\mathbf{E}}, \tilde{\mathbf{A}}) \leftarrow \text{GraphVAE}(\hat{\mathbf{h}}_0)$
- 7: $\mathbf{U}' \leftarrow \text{HGT}(\tilde{\mathbf{V}}, \tilde{\mathbf{E}}, \tilde{\mathbf{A}})$
- 8: $\hat{\mathbf{P}}_0 \leftarrow \text{PersonDiT}(\mathbf{P}_t, t, c, \mathbf{z}_c, \hat{\mathbf{h}}_0, \mathbf{U}')$
- 9: 由预测数据与方差序列计算后验均值 $\boldsymbol{\mu}_t$
- 10: 计算能量函数 $J \leftarrow \sum_{g'} \sum_a w_{g',a} (\hat{q}_{g',a} - q_{g',a}^*)^2$
- 11: 对各地理尺度 k 计算梯度 $\{\mathbf{g}_k\} \leftarrow \nabla_{\mathbf{x}_t} J_k$
- 12: 协调梯度冲突: $\mathbf{g}^* \leftarrow \text{CAGrad}(\{\mathbf{g}_k\})$
- 13: 调整均值: $\hat{\boldsymbol{\mu}}_t \leftarrow \boldsymbol{\mu}_t - \eta \cdot \mathbf{g}^*$
- 14: 采样 $\mathbf{x}_{t-1} \sim \mathcal{N}(\hat{\boldsymbol{\mu}}_t, \sigma_t^2 \mathbf{I})$
- 15: **end for**
- 16: 施加 VAE-BN 正则化: 剔除结构零, 保留样本零
- 17: **end for**
- 18: **return** 合成人口

作者简历及攻读博士学位期间取得的研究成果

一、作者简历

郝赫

答辩决议

XXXXXXXXXXXXXXXX

独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作和取得的研究成果，除了文中特别加以标注和致谢之处外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京交通大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

学位论文作者签名：



签字日期：

年 月 日

学位论文数据集

数据集页

关键词 *	密级 *	中图分类号	UDC	论文资助
XXXXXXXXXXXX	XXXXXX	U12		国家自然科学基金“面上”城市群尺度下城际出行行为分析与交通供给优化 52172312
学位授予单位名称 *		学位授予单位代码 *	学位类别 *	学位级别 *
北京交通大学		10004	工学	博士
论文题名 *		并列题名		论文语种 *
XXXXXXXX				中文
作者姓名 *	郝赫		学号 *	22110300
培养单位名称 *		培养单位代码 *	培养单位地址	邮编
北京交通大学		10004	北京市海淀区西直门外上园村3号	100044
学科专业 *		研究方向 *	学制 *	学位授予年 *
交通运输规划与管理		综合交通运输理论与技术	5年	2026年
论文提交日期 *	2026年5月			
导师姓名 *	姚恩建		职称 *	教授
评阅人	答辩委员会主席 *		答辩委员会成员	
朱晓宁, 石京, 陈艳艳, 王艳辉, 黄爱玲	朱晓宁		石京, 陈艳艳, 王艳辉, 黄爱玲	
电子版论文提交格式 文本 (✓) 图像 ○ 视频 ○ 音频 ○ 多媒体 ○ 其他 ○ 推荐格式: application/msword; application/pdf				
电子版论文出版(发布)者		电子版论文出版(发布)地		权限声明
论文总页数 *	193			
共33项, 其中带*为必填数据, 为22项。				